QZPaper Huggingface Daily

2026-03-03

---

1. **LLaDA-o：高效且长度自适应的全能扩散模型**
   LLaDA-o 提出混合扩散框架将离散掩码扩散与连续扩散解耦至专用专家模块，并引入数据驱动的长度自适应策略，实现高效全能多模态理解与生成，推理效率相比基线提升 5.9 倍。
2. **WorldStereo：通过 3D 几何记忆桥接相机引导视频生成与场景重建**
   WorldStereo 基于预训练视频扩散模型，通过全局几何记忆与空间立体记忆两种互补机制确保多段生成视频的跨轨迹一致性，实现高质量 3D 场景重建与相机可控视频生成的统一。
3. **Spectral Condition for $\mu$$PunderWidth--DepthScaling**
   论文提出统一的谱缩放条件精确刻画权重及其更新在宽度-深度联合缩放下的算子范数变化规律，基此给出跨优化器类的通用 P 配方，仅用初等工具就恢复和推导了多种优化器的参数化公式。
4. **INSIGHT：基于加权互信息的高效 RLVR 数据选择方法**
   INSIGHT 采用贝叶斯框架和加权互信息目标联合建模数据难度与认知不确定性，通过后验更新与时间折扣实现在线数据选择，在 RLVR 训练中显著提升数据效用并降低计算开销。
5. **ReGFT：通过参考解引导微调让 RL 学会困难问题**
   ReGFT 通过参考解引导采样为模型提供 80% 的参考解作为提示，要求其从头独立求解，在 RL 前通过有针对性的 SFT 提升模型在难题上的基线能力，使后续强化学习获得充足的正奖励信号。
6. **Tool-R0：零数据自演化 LLM 工具调用智能体**
   Tool-R0 首次实现零数据自博弈框架，从同一基座 LLM 初始化 Generator 和 Solver 两个角色，通过互补奖励信号驱动其协同进化，无需任何人工标注数据即可实现通用工具调用能力的自我进化。
7. **Agentic Code Reasoning：基于半形式化推理的无执行代码语义分析**
   论文提出半形式化推理方法，通过嵌入结构化证书模板强制智能体构建显式前提、追踪执行路径、推导形式化结论，弥合非结构化推理与完全形式化证明之间的鸿沟，显著提升代码语义分析的准确性。
8. **RL 何时有益于医学 VLM? 解耦视觉、SFT 与 RL 的增益**
   论文通过视觉线性探测与 Pass@K 分析解耦视觉、SFT 与 RL 对医学 VLM 性能的各自贡献，发现 RL 主要重塑输出分布而非扩展模型能力，并提出边界感知训练策略实现跨医学任务的性能提升。
9. **Legal RAG Bench：面向法律 RAG 系统的端到端基准与评估方法论**
   Legal RAG Bench 采用全因子实验设计和层级错误分解框架对法律 RAG 管线进行端到端评估，基于法律与 AI 双重领域专家的高质量标注，首次评估了 RAG 系统的实际法律建议能力。
10. **T^3$RL**
    T³RL 在测试时 RL 的奖励估计中引入工具验证机制，用代码执行结果替代纯多数投票，破除虚假流行模式坍缩引发的错误伪标签自强化恶性循环，实现基于证据的稳健自进化。

LLaDA-o：高效且长度自适应的全能扩散模型

You[1,2,3], Zhang[4], Zhou[4], Li[1,2,3], Wen[1,2,3] — [1]RUC, [4]Ant Group, 2025

1. 动机与核心思想

掩码扩散模型（MDMs）通过并行去噪被遮掩的 token，已展现出与自回归（AR）模型相当的语言建模能力，并具备双向上下文建模和推理并行性等优势。然而，将扩散语言模型扩展为同时支持**多模态理解与生成**的全能（omni）模型仍面临根本性挑战：

- **扩散动力学不兼容**：文本适合离散掩码扩散，图像则以连续潜空间扩散为事实标准，两者的状态空间和噪声过程本质不同；
- **密集联合训练冲突**：在单一稠密模型中朴素地联合训练异构模态，会导致目标函数不匹配和梯度干扰，优化不稳定且性能次优；
- **固定长度约束**：现有全能扩散模型（Lumina-DiMOO、MMaDA 等）在理解任务中假设固定输出长度，限制了开放场景的适用性。

LLaDA-o 提出**混合扩散**（Mixture of Diffusion, MoD）框架，将离散掩码扩散（文本理解）与连续扩散（视觉生成）解耦至专用专家，同时通过共享的高效注意力骨干实现跨模态交互。在此基础上，进一步引入**数据驱动的长度自适应策略**，无需架构修改即可实现灵活长度解码。

核心能力	关键结果
DPG-Bench 文生图	**87.04**（SOTA）
GenEval 文生图	0.86（双物体 0.98）
多模态理解（10 项基准）	扩散模型 SOTA
推理效率 vs LLaDA-V	**5.9**× 加速

2. 预备知识

2.1 连续扩散模型（CDM）

Rectified Flow（RF）通过线性插值连接噪声分布 π_0 与数据分布 π_1：$\boldsymbol{x}_t = (1-t)\boldsymbol{x}_0 + t\boldsymbol{x}_1$，学习速度场 $p_{\boldsymbol{\theta}}(\boldsymbol{x}, t)$ 匹配恒定流方向 $\boldsymbol{x}_1 - \boldsymbol{x}_0$：

$$\mathcal{L}(\boldsymbol{\theta}) = \mathbb{E}_{(\boldsymbol{x}_0,\boldsymbol{x}_1),t}\Big[\big\|(\boldsymbol{x}_1 - \boldsymbol{x}_0) - p_{\boldsymbol{\theta}}(\boldsymbol{x}_t, t)\big\|_2^2\Big].$$

采样即求解 ODE $dz_t/dt = p_\theta(z_t, t)$，从 $z_0 \sim \pi_0$ 积分至 z_1。

2.2 掩码扩散模型（MDM）

给定 N 个 token 的序列 $\boldsymbol{x}_0$，前向过程以概率 $1-\alpha_t$ 将每个 token 替换为 [M]（α_t 单调递增，$\alpha_0 = 0, \alpha_1 = 1$）。反向过程中，已预测 token 保持不变；被遮掩 token 以概率 $\frac{\alpha_s - \alpha_t}{1-\alpha_t}$ 根据模型预测 $p_{\boldsymbol{\theta}}(\boldsymbol{x}_0^i|\boldsymbol{x}_t)$ 解码，否则继续保持遮掩。训练目标为：

$$\mathcal{L}(\boldsymbol{\theta}) = \int_0^1 \frac{1}{t}\mathbb{E}_{\boldsymbol{x}_0,\boldsymbol{x}_t}\Big[\sum_{i:\boldsymbol{x}_t^i=[\mathrm{M}]} -\log p_{\boldsymbol{\theta}}(\boldsymbol{x}_0^i|\boldsymbol{x}_t)\Big]dt.$$

3. 方法：混合扩散框架（MoD）

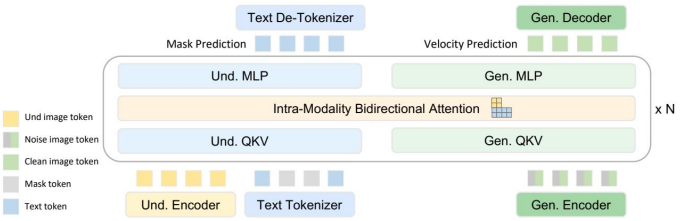

图 1：*LLaDA-o* 的混合扩散框架概览。理解专家处理离散掩码扩散，生成专家处理连续扩散，共享注意力骨干。

3.1 双专家架构

受模态分解设计启发，MoD 使用两个扩散专家解耦处理离散和连续模态：

理解专家：由视觉编码器 SigLIP（Zhai et al., 2023）+ 两层 MLP 投影器 + 扩散语言模型（LLaDA-8B-Instruct）顺序组成。图像经编码器提取语义视觉 token，通过 MLP 投影到语言 token 空间，再与提示 token 联合处理。给定训练样本 $(\boldsymbol{v}, \boldsymbol{p}, \boldsymbol{r}_0)$（投影图像 token、提示、真实响应），训练目标为掩码扩散损失的变体：

$$\mathcal{L}_{\text{und}} = \int_0^1 \frac{1}{t}\mathbb{E}_{\boldsymbol{r}_0,\boldsymbol{r}_t}\Big[\sum_{i:r_t^i=[\mathrm{M}]} -\log p_\theta(r_0^i|\boldsymbol{v}, \boldsymbol{p}, \boldsymbol{r}_t)\Big]dt.$$

生成专家：由冻结参数的 VAE（FLUX VAE，重建质量优异）+ Diffusion Transformer 组成。DiT 采用与 LLaDA 掩码预测器相同的架构并由其初始化，额外的时间嵌入条件参数随机初始化。训练目标为 Rectified Flow 损失：

$$\mathcal{L}_{\text{gen}} = \mathbb{E}_{p,\epsilon,v_0,v_t,t}\Big[\big\|(v_0 - \epsilon) - p_\theta(p, v_t, t)\big\|_2^2\Big].$$

关键设计：生成任务中的输入图像和文本也经理解专家处理，使对应参数被联合训练，促进跨模态知识共享。

3.2 模态内双向注意力

(a) Multimodal Understanding (b) Multimodal Generation (c) Interleaved Data (d) Cross-Sample Isolation

图 2：模态内双向注意力实现。黄色块为未遮掩注意力，白色虚线框为遮掩注意力。

全局注意力在每个去噪步都重新计算整个序列的注意力，即使条件（输入图像/文本提示）保持不变，造成严重冗余。LLaDA-o 提出**模态内双向注意力**：将输入序列划分为模态块，**块内施加全注意力**（保留丰富的模态内上下文），**块间施加因果注意力**。这使得条件块形成固定前缀，其 KV 缓存可在去噪步间复用，避免长序列冗余计算。

如图 2 所示，该方案自然适配理解（图像 + 提示 → 响应）、生成（提示 → 图像 latent）和交错数据等多种数据类型。训练时采用 sample packing 并严格隔离样本，防止跨样本干扰。相比 LLaDA-V 的全局双向注意力，实际推理加速 **5.9**×。

3.3 自适应长度增强

掩码扩散的理解专家在推理时通常假设固定目标长度。为实现灵活生成而不修改架构，LLaDA-o 设计了数据驱动的**自适应长度增强**策略：

训练阶段（Algorithm 1）：对每个样本的目标响应进行随机扰动——以概率 p_{ext} 在响应后附加 1 到 $|r_0|$ 个 [EOS] token（暴露模型在不同位置终止），以概率 p_{trunc} 将响应截断为随机前缀（鼓励学习从部分目标续写）。两种操作均保持样本隔离。

推理阶段（Algorithm 2）：采用块式生成——固定条件块（图像 + 提示）缓存一次，迭代附加长度 L 的全掩码块并去噪。超过置信度阈值 τ 的 token 被接受，检测到 [EOS] 即终止，否则将完成块缓存并生成下一块。该策略充分复用 KV 缓存，相比依赖架构修改的方法更轻量且架构无关。

4. 实验设置

模型配置：理解专家基于 LLaDA-8B-Instruct 初始化，视觉编码器 SigLIP，两层 MLP 投影器随机初始化。生成专家 DiT 同架构初始化，VAE 使用 FLUX。总参数量 8B MoT。

三阶段训练：(1) **Stage 1**——大规模图像理解 + 生成数据，生成分辨率限 512，不启用长度增强；(2) **Stage 2**——加入多模态推理数据，生成分辨率提升至 1024；(3) **Stage 3**——启用自适应长度增强，加入高质量生成数据，激活灵活长度解码。计算成本：Stage 1/2 各 256×H800（55,296/30,720 GPU 时），Stage 3 用 64×A100（1,536 GPU 时）。

5. 核心实验结果

5.1 多模态理解

在 10 项基准上评估，LLaDA-o 在扩散模型中达到 SOTA：

基准	LLaDA-o / 最佳扩散对比
MMMU val	44.9 / LaViDa-O 45.1
MME cognition	**549** / LLaDA-V 491
MathVista testmini	**66.1** / LLaDA-V 59.7
ChartQA	**87.9** / LaViDa-O 80.0
DocVQA val	**91.5** / LLaDA-V 78.3
InfoVQA val	**54.7** / LaViDa-O 44.6
MathVerse mini-vis.	**37.1** / LaViDa-O 36.9
AI2D	**79.3** / LLaDA-V 77.8

在数学推理和文档/图表理解上优势尤为显著。与 AR 模型 BAGEL（Qwen2.5-7B 骨干，18T token 预训练）相比，LLaDA-o 语言骨干仅训练 2.3T token（HumanEval 49.4 vs 84.8），但 MathVista 上已从 LLaDA-V 的 59.7 提升至 66.1，逐步缩小差距。

5.2 文生图生成

GenEval：LLaDA-o 总分 0.86，超越 Janus-Pro（0.80）、SD3-Medium（0.74）等强模型。在双物体生成（**0.98**）和颜色绑定（**0.83**）上表现突出，接近 Lumina-DiMOO（0.91）和 Mogao（0.89）。

DPG-Bench（长信息密集提示）：LLaDA-o 以 **87.04** 达到 SOTA，超越 Show-o2（86.14）、Lumina-DiMOO（86.04）、BAGEL（85.07）和所有生成专用模型（FLUX.1-dev 83.84、DALL-E 3 83.50）。各子维度：Global 92.91、Entity 93.30、Attribute 90.40、Relation 91.75、Other 92.79，全面领先。

5.3 推理效率与长度自适应分析

置信度阈值权衡（MathVista，块长度 64）：阈值从 0.2 提至 1.0，准确率从 57.8% 升至 65.8%，吞吐量从 203.9 降至 24.3 tokens/s。阈值 0.9 达最优平衡（65.9%，52.2 tokens/s）。相比 LLaDA-V 在同等准确率下实现 **5.9**× 加速。

块长度鲁棒性（阈值 0.95）：块长度从 32 变至 128，平均生成 token 数仅从 165 微降至 154（L=96 时最低 145），准确率在 L=64 和 L=96 时最优（66.1%/66.2%）。输出长度主要由输入内容驱动而非预设块大小，验证了自适应长度增强的有效性。

定性对比：LLaDA-V 在块长度过长时生成冗余内容（如简单文本提取产生长段描述），块长度过短时响应不完整；LLaDA-o 在两种场景下均能正确终止或自动延伸。

5.4 训练阶段消融

GenEval：Stage 1→2→3 分别为 0.74→0.78→0.82。DPG-Bench：86.1→86.2→87.0。Stage 3 的自适应长度增强和高质量数据带来持续提升。

6. 与相关工作的对比

- **vs 纯离散扩散全能模型**（MMaDA、Lumina-DiMOO）：这些方法对图像也使用掩码扩散，导致图像离散化信息损失。LLaDA-o 用连续扩散生成图像，避免此问题；
- **vs AR 混合模型**（Janus-Pro、BAGEL、Show-o2）：LLaDA-o 以纯扩散骨干达到可比或更优的生成质量，同时保留 MDM 的双向上下文和推理并行优势；
- **vs LLaDA-V**：LLaDA-o 通过 MoD 解耦、高效注意力和长度自适应，在理解性能提升的同时实现 5.9× 推理加速，并支持灵活长度输出。

7. 局限与未来方向

- 语言骨干（LLaDA-8B，2.3T token）弱于 AR 对手（Qwen2.5，18T token），限制了语言能力上界；随着 MDM 预训练规模扩展，差距有望缩小；
- 生成分辨率目前最高 1024，更高分辨率和视频生成为自然延伸；
- 当前仅支持文本理解 + 图像生成的全能场景，音频、3D 等其他模态的统一建模值得探索；
- 自适应长度策略依赖数据增强，能否从理论上保证终止行为尚未充分研究；
- 作者认为 MoD 框架为未来全能扩散模型提供了有前景的基础范式。

WorldStereo：通过 3D 几何记忆桥接相机引导视频生成与场景重建

Zhang[1,2], Cao[2], Wang[2], Zuo[2], Wu[2], Zhu[1], Guo[2] — [1] 浙江大学, [2] 腾讯混元, 2025

1. 动机与问题定义

基础视频扩散模型（VDM）虽能生成高质量视频，但从生成视频中重建一致的 3D 场景仍极具挑战：相机可控性不足且不同轨迹下生成内容不一致。现有方案存在三大困境：

- **长双向 VDM**（Long-Bi）：单次生成长轨迹覆盖多视角，借助 DiT 全局注意力保持一致性，但视频质量下降且计算代价高昂；
- **自回归模型**（AR）：顺序生成长视频效率更高，但相机精度有限且误差累积严重；
- 两者均缺乏成熟开源社区（相比 HunyuanVideo、CogVideoX、Wan 等常规 VDM）。

WorldStereo 提出**多段双向 + 记忆**（Multi-Bi-Mem）范式：基于强大的开源 VDM（Wan-14B）生成多段中等长度视频，通过两种互补的几何记忆机制（全局几何记忆 GGM + 空间立体记忆 SSM）确保跨轨迹一致性，巧妙绕过长序列生成的瓶颈，同时保留预训练 VDM 的泛化性与可用性，实现高质量 3D 重建。

2. 系统架构

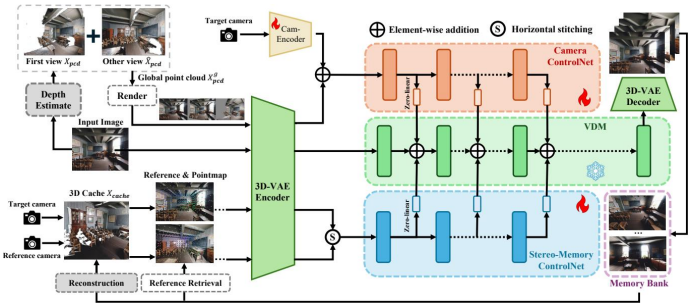

图 1：*WorldStereo* 概览。包含相机分支（*GGM*，全局点云引导）和 *SSM* 分支（检索参考帧 *+pointmap 3D* 对应引导），两个 *ControlNet* 分支注入冻结的 *VDM* 主干。

WorldStereo 基于相机引导 VDM **Uni3C** 构建，后者使用冻结的 Wan2.1-14B-I2V 作为骨干，配合轻量 ControlNet 分支注入 Plücker 射线与点云条件。系统包含两个记忆存储组件：

2D Memory Bank：生成的视频帧经时间下采样后存储为 $\{I_{mem}\}_{m=0}^{M}$，用于为后续 SSM 检索空间相似的参考视图。初始条件图像和从 360° 全景分割的透视视图也纳入记忆库。

3D Cache：保存全局点云集 X_{cache}，由前馈 3D 重建方法 WorldMirror 基于记忆库图像增量式重建。不同 3D 缓存通过重叠视图的 Umeyama 变换对齐后合并。

参考帧点云通过单目深度反投影获得：

$$X_{pcd}(x) \simeq R_{c\to w} D(x) K^{-1} \hat{x},$$

其中 $R_{c\to w}$ 为相机到世界坐标的位姿矩阵，$D(\cdot)$ 为 MoGe 估计的深度，K^{-1} 为相机内参逆矩阵，$\hat{x}$ 为齐次像素坐标。

3. 全局几何记忆（GGM）

GGM 将点云条件从单帧参考点 X_{pcd} 扩展为增量式更新的全局点云：

$$X^g_{pcd} = [X_{pcd}, \hat{X}_{pcd}],$$

其中 $\hat{X}_{pcd}$ 为其他视图的点云。原始 Uni3C 中点云仅提供相机引导而非强制 VDM 拟合 3D 表示——这虽有利于保持泛化性，但导致模型忽略大部分几何结构。为此，WorldStereo 使用扩展的全局点云微调相机控制分支。

点云掩码策略：为避免对新视图点云过拟合，训练时随机丢弃目标视图的部分点（随机掩码 30%–70% 像素 + 连续矩形掩码遮挡 20%–70% 区域），确保对部分几何缺失的鲁棒性。推理时使用增量更新的 3D 缓存作为 $\hat{X}_{pcd}$，通过重叠点云的 Umeyama 变换对齐到 X_{pcd} 坐标系。

全景兼容性：GGM 天然支持全景 3D 生成——利用 MoGe 全景深度估计构建全景点云作为初始 3D 缓存，全景提供 360° 视角使 VDM 在视点转换时保持视觉一致性。

4. 空间立体记忆（SSM）

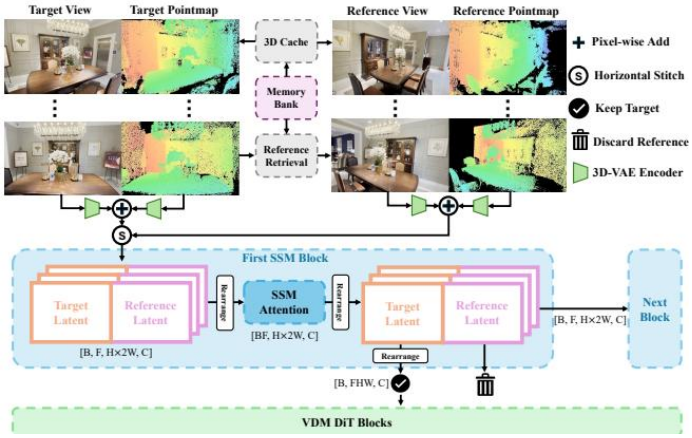

图 2：*SSM* 架构。参考视图从记忆库检索，*pointmap* 基于 *3D* 缓存构建。目标-参考对水平拼接后限制注意力感受野至各自配对内。

GGM 仅通过粗粒度点云维持结构一致性，难以保留细粒度细节。受传统**立体匹配**与基于参考的修复启发，SSM 通过建立显式 3D 对应关系学习生成新视图与检索视图间的空间一致性。

检索策略：给定 N 个目标位姿，均匀采样 $F = N/4$ 个位姿，从记忆库检索最近邻帧作为参考。检索准则从 2D 平面扩展至 3D 空间——最大化目标与参考相机视锥体的**体积重叠视场**（volumetric overlapping FoV）。

拼接与编码：每个检索的参考视图独立编码为图像潜特征 $\{z_{ref}\}_{i=1}^{F}$，与目标潜特征水平拼接：$z_{stitch} = [z_{tar}; z_{ref}] \in \mathbb{R}^{F\times 2HW\times C}$。同时构建 pointmap（记录目标-参考对在 3D 世界坐标中的点云位置），归一化并着色为 RGB 后由 3D-VAE 编码：$\hat{z}_{pm} = [\hat{z}_{tar}; \hat{z}_{ref}]$。最终 SSM 输入为 $z_{ssm} = z_{stitch} + \hat{z}_{pm}$。

注意力约束：SSM 分支包含 20 层 DiT 块，核心区别在于**限制注意力感受野**——每个目标-参考对仅关注自身特征。具体地，将特征重排为 $[BF, H\times 2W, C]$，SSM 注意力仅沿 $H\times 2W$ 维度操作，随后仅目标特征被加回 VDM 主块。

训练数据构建：通过对多视图数据进行时间错位采样（参考与目标视频有 30%–90% 时间重叠），随机打乱并掩码参考视图以模拟实际检索的无序和离散性。参考条件整体丢弃概率 10%，单帧丢弃概率 30%。

5. DMD 加速

采用修改的分布匹配蒸馏（DMD）将推理从 40 步降至 4 步。DMD 基于 VSD 思想，通过冻结的真实评分函数 s_{real} 与可训练的伪评分函数 s_{fake} 之间的近似 KL 散度蒸馏少步扩散学生 G_θ：

$$\nabla \mathcal{L}_{\text{DMD}} = -\mathbb{E}_t \left(\int (s_{real}(x_t, t) - s_{fake}(x_t, t)) \frac{dx_t}{d\theta} dz \right).$$

关键设计：（1）冻结相机控制分支，仅训练主干——解耦控制与少步生成能力；（2）相机引导和记忆控制分支**无需联合微调**即可泛化至蒸馏后的 G_θ；（3）CFG 尺度设为 5.0 实现 CFG-free 推理，结合 4 步去噪达到 20× **加速**；（4）过滤低质量/困难轨迹数据以稳定训练——学生模型易关注教师的伪影（过饱和、幻觉）。DMD 仅需 1,000 步/13 小时训练。

6. 核心实验结果

6.1 相机控制与视觉质量（OOD 基准）

从 WorldScore 选取 100 张 OOD 图像，随机组合平移、旋转和摇镜构造复杂轨迹。用 WorldMirror 提取预测相机与 GT 对比：

方法	RotErr↓	TransErr↓	ATE↓	Q-Align-V↑
Voyager	0.678	0.630	1.343	0.664
SEVA	0.171	0.540	1.023	0.782
Gen3C	0.220	0.275	1.071	0.820
Uni3C	0.155	0.192	0.572	0.846
WorldStereo*	0.132	0.178	0.542	0.860
WS-GGM	0.129	0.162	0.706	0.875
WS-Full	0.145	0.253	0.667	0.866
WS-DMD	0.146	0.203	0.504	0.874

WorldStereo*（无记忆）已全面超越竞争方法。GGM 提升整体视频质量（Q-Align-V: 0.860→0.875），SSM 略降单帧质量但显著增强细粒度细节恢复。DMD 版本推理时间从 162s 降至 **9s**（18× 加速），质量几乎无损。

6.2 3D 重建基准

基于 Tanks-and-Temples（TT）和 MipNeRF360 构建新基准：每场景仅提供单张图像，沿 4 条预定义轨迹（上/左/右旋转 + 环绕）生成视频，经 WorldMirror 重建点云后与 GT 对齐评估。

方法 (TT)	F1↑	AUC↑	RotErr↓	ATE↓
Uni3C	0.424	0.378	0.362	0.157
Gen3C	0.416	0.380	0.342	0.170
SEVA	0.286	0.293	0.379	0.182
VMem	0.386	0.375	0.533	0.192
WS-Full	**0.578**	**0.437**	0.247	0.150
WS-DMD	0.534	0.410	0.291	0.155

在 TT 上，WorldStereo-Full 的 F1 从基线 0.424 大幅提升至 **0.578**（+36%），AUC 从 0.378 升至 **0.437**。MipNeRF360 上同样显著：F1 从 0.352 升至 **0.406**，AUC 从 0.347 升至 **0.402**。DMD 版本在重建质量上仅有轻微下降。

6.3 3D 全景生成

将全景分割为 27 帧（FoV 90×120）作为初始记忆库，利用 MoGe 全景深度估计建立 3D 缓存，对中间 3 个非重叠图像生成视频。与专门的全景视频生成方法不同，WorldStereo 保留了基础 VDM 的泛化性，同时生成高分辨率（576p）透视视图，两者对 3D 重建至关重要。

7. 消融实验

记忆组件消融（100 场景基准，含 GT 视图）：

	RotErr↓	ATE↓	PSNR↑	LPIPS↓
WS*（无记忆）	1.300	0.237	14.64	0.412
WS-GGM	0.699	0.131	17.45	0.288
WS-Full	0.748	0.142	18.40	0.283
WS-DMD	0.772	0.130	18.04	0.289

GGM 将旋转误差降低 46%（1.300→0.699），PSNR 提升 2.81dB，证实全局几何先验对结构一致性的关键作用。SSM 在 GGM 基础上进一步将 PSNR 提升 0.95dB（17.45→18.40）、LPIPS 改善（0.288→0.283），验证了细粒度细节恢复能力。质性消融显示：无记忆时模型随机幻觉新物体；GGM 保持结构但丢失细节；SSM 的 3D 对应 pointmap 引导对正确匹配区域至关重要。

轨迹顺序消融（10 个全景场景）：orbit 优先（信息丰富视角）效果最佳，最终采用 “orbit→up→right→left”——左右旋转对 3D 重建更关键，放在最后可利用更多累积记忆帧。

8. 实现细节

基于冻结的 Wan2.1-14B-I2V，分阶段训练：（1）相机 ControlNet 8,000 步/bs32；（2）GGM 微调 4,000 步；（3）SSM 从零训练 6,000 步。记忆训练总计 64 张 H20 GPU×60 小时。DMD 训练 1,000 步/13 小时。训练分辨率 480p（可泛化至 720p 推理）。训练数据包含 DL3DV（9,174 场景）、Re10K（26,544 场景）、Tartanair、Map-Free-Reloc、WildRGBD、UCo3D 和 UE5 渲染数据。

9. 讨论与局限

WorldStereo 作为世界模型，统一处理透视和全景输入的多样化 3D 场景生成，核心优势在于：（1）ControlNet 注入方式保留 VDM 泛化性；（2）双记忆机制在不引入长序列训练的前提下实现跨轨迹一致性；（3）与 DMD 蒸馏天然兼容实现 20× 加速。

- **泛化性保持**：冻结 VDM 主干 +ControlNet 分支注入，避免联合训练降低基础模型能力，720p 推理无需重训；
- **局限**：3D 缓存依赖前馈重建（WorldMirror）质量，误差可能累积；记忆检索策略为启发式设计；全景场景中检索帧的不连续性仍是挑战；记忆训练需要良好对齐的深度图，数据量受限；
- **未来方向**：扩展至动态场景与 4D 生成；更鲁棒的 3D 缓存更新策略；探索端到端联合训练在保持泛化性下进一步提升一致性。

Spectral Condition for μP under Width–Depth Scaling

Zheng[1], Wang[1], Zhang[2], Li[1†] — [1] 人民大学高瓴 AI 学院, [2]ByteDance Seed, 2026

1. 动机与核心贡献

生成式基础模型正同时向**宽度**和**深度**两个维度扩展，带来两大挑战：(1) 特征学习动力学不稳定（标准参数化下特征更新爆炸/消失）；(2) 超参数（HP）调优代价与模型规模成正比，对数十亿参数的模型不可承受。μP（Maximal Update Parameterization）通过按模型尺寸重参数化 HP，在**宽度缩放**下已提供统一解决方案，实现尺度不变的特征学习和可靠的 HP 迁移。然而在**宽度–深度联合缩放**下，现有 μP 扩展零散、耦合特定架构（单层 vs. 两层残差块）和优化器（SGD/AdamW），且推导依赖 Tensor Programs 或动态均场理论等复杂工具。

本文提出一个**简洁统一的谱框架**来处理联合宽度–深度缩放下的 μP，三项核心贡献：

- 提出统一**谱缩放条件**（Condition 3.1），精确刻画权重及其逐步更新的 RMS 算子范数应如何随宽度 n 和深度 L 缩放，将先前分散的 μP 公式统一为特例；
- 基于谱条件，给出跨**广泛优化器类**实现 μP 的通用配方——不仅恢复 SGD、AdamW 的已知公式，还系统推导 Muon-Kimi、SSO、Sophia、Lion 等新优化器的 μP 公式；
- GPT-2 风格语言模型实验验证：所提谱 μP 条件在宽度–深度缩放下保持稳定特征学习并实现鲁棒 HP 迁移。

推导仅用**初等线性代数与概率论**，不依赖复杂理论工具。

2. 背景：宽度缩放下的谱条件

2.1 数学工具

对向量 $\boldsymbol{a} \in \mathbb{R}^n$，RMS 范数 $\|\boldsymbol{a}\|_{\mathrm{R}} = \|\boldsymbol{a}\|_2/\sqrt{n}$；对矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，RMS 算子范数 $\|\boldsymbol{A}\|_{\mathrm{R}} := \max_{\boldsymbol{v}\neq 0} \|\boldsymbol{A}\boldsymbol{v}\|_{\mathrm{R}}/\|\boldsymbol{v}\|_{\mathrm{R}} = \sqrt{n/m}\,\|\boldsymbol{A}\|_2$。核心性质：次可加性 $\|\boldsymbol{A}+\boldsymbol{B}\|_{\mathrm{R}} \le \|\boldsymbol{A}\|_{\mathrm{R}}+\|\boldsymbol{B}\|_{\mathrm{R}}$，次可乘性 $\|\boldsymbol{AB}\|_{\mathrm{R}} \le \|\boldsymbol{A}\|_{\mathrm{R}}\|\boldsymbol{B}\|_{\mathrm{R}}$，以及随机矩阵谱范数 $\|\boldsymbol{A}\|_2 = \Theta(\sigma(\sqrt{m}+\sqrt{n}))$。

2.2 μP 原理

μP 追求**尺度不变特征学习**并**最大化参数更新对特征变化的贡献**：

$$\|\boldsymbol{h}_l(\boldsymbol{x})\|_{\mathrm{R}} = \Theta(1), \quad \|\Delta\boldsymbol{h}_l(\boldsymbol{x})\|_{\mathrm{R}} = \Theta(1) \tag{P1}$$

同时最大化每层 ΔW_l 对 $\Delta\boldsymbol{h}_L(\boldsymbol{x})$ 的贡献（P2）。在仅宽度缩放（$L = \Theta(1)$ 固定）下，Yang 等人证明只需：$\|W_l\|_{\mathrm{R}} = \Theta(1)$，$\|\Delta W_l\|_{\mathrm{R}} = \Theta(1)$，即可保证上述原理。但此条件**不适用于深度也增长**的情形。

3. 核心理论：宽度–深度联合谱条件

3.1 问题设定

考虑两层线性残差块网络（捕获 Transformer 中 Attention/FFN 的两层结构）：

$$\begin{aligned}
\boldsymbol{h}_0(\boldsymbol{x}) &= \alpha_0 \boldsymbol{W}_0 \boldsymbol{x}, \\
\boldsymbol{h}_l(\boldsymbol{x}) &= \boldsymbol{h}_{l-1}(\boldsymbol{x}) + \alpha_l \boldsymbol{W}_l^{(2)} \boldsymbol{W}_l^{(1)} \boldsymbol{h}_{l-1}(\boldsymbol{x}),\ l \in [L], \\
\boldsymbol{h}_{L+1}(\boldsymbol{x}) &= \alpha_{L+1} \boldsymbol{W}_{L+1} \boldsymbol{h}_L(\boldsymbol{x}),
\end{aligned}$$

其中 $d_0, d_{L+1} = \Theta(1)$，$n_l = \Theta(n)$，$n, L \to \infty$，$\|\boldsymbol{x}\|_{\mathrm{R}} = \Theta(1)$。$\{\alpha_l\}$ 为块乘子。

3.2 谱 μP 条件（Condition 3.1）

初始条件：输入/输出层 $\alpha_0\|W_0\|_{\mathrm{R}} = \Theta(1)$，$\alpha_{L+1}\|W_{L+1}\|_{\mathrm{R}} = \Theta(1)$；隐藏层：$\alpha_l\|W_l^{(2)}\|_{\mathrm{R}}\|W_l^{(1)}\|_{\mathrm{R}} = \Theta(1/L)$。

更新条件：输入/输出层 $\alpha_0\|\Delta W_0\|_{\mathrm{R}} = \Theta(1)$，$\alpha_{L+1}\|\Delta W_{L+1}\|_{\mathrm{R}} = \Theta(1)$；隐藏层一阶更新：

$$\begin{aligned}
\alpha_l\|\Delta W_l^{(2)}\|_{\mathrm{R}}\|W_l^{(1)}\|_{\mathrm{R}} &= \Theta(1/L), \\
\alpha_l\|W_l^{(2)}\|_{\mathrm{R}}\|\Delta W_l^{(1)}\|_{\mathrm{R}} &= \Theta(1/L);
\end{aligned}$$

隐藏层二阶更新：$\alpha_l\|\Delta W_l^{(2)}\|_{\mathrm{R}}\|\Delta W_l^{(1)}\|_{\mathrm{R}} = \Theta(1/L)$。

关键洞察：与仅宽度缩放不同，隐藏层权重及更新的 RMS 算子范数需以 $\Theta(L^{-1})$ 缩减，防止沿残差连接的累积引发特征爆炸。

3.3 统一先前工作

- **单层残差块**（$k = 1$）：无二阶更新项 $\Rightarrow$ 条件更松，自然诱导 $\alpha_l = \Theta(1/\sqrt{L})$，恢复 Bordelon 等 [6] 和 Yang 等 [47] 的结果；
- **两层残差块**（$k = 2$）：二阶条件收紧初始化和残差乘子至 $\alpha_l = \Theta(1/L)$，恢复 Bordelon 等 [5]、Dey 等 [10]、Qiu 等 [31] 的结果；
- **任意 k 层块**：需控制 1 至 k 阶所有更新项为 $\Theta(1/L)$，但最终 HP 参数化与两层情形一致——**两层块即为捕获核心行为的最小设定**。

3.4 推导概要（三步法）

第一步：初步初始化条件。展开残差递推 $\boldsymbol{h}_s = \boldsymbol{h}_0 + \sum_{l=1}^{s} \alpha_l W_l^{(2)} W_l^{(1)} \boldsymbol{h}_{l-1}$。因 i.i.d. 零均值高斯初始化，各项为独立零均值随机向量，其和的 RMS 范数与方差之和的平方根成正比。令每项 $\alpha_l\|W_l^{(2)}\|_{\mathrm{R}}\|W_l^{(1)}\|_{\mathrm{R}} = \mathcal{O}(1/\sqrt{L})$ 即可保证 $\|\boldsymbol{h}_s\|_{\mathrm{R}} = \Theta(1)$。

第二步：更新条件。展开一步更新后 $\Delta\boldsymbol{h}_s$ 为零阶项 ϵ_0（传播早期特征更新）、一阶项 $\epsilon_1^{(1)}, \epsilon_1^{(2)}$（单个权重更新的直接效应）和二阶项 ϵ_2（两个权重更新的交叉效应）。μP 原理 (P2) 要求最大化每项贡献并保持 $\Theta(1)$，对 L 项求和自然得到每项 $\Theta(1/L)$。

第三步：精炼初始化。将两个一阶条件相乘并与二阶条件联立，得到 $\alpha_l\|W_l^{(1)}\|_{\mathrm{R}}\|W_l^{(2)}\|_{\mathrm{R}} = \Theta(1/L)$——比初步条件更强。

4. 优化器实现：以 Muon-Kimi 为例

Muon-Kimi 对梯度做 SVD $\nabla_{W_l}\mathcal{L} = U_l\Sigma_l V_l^\top$，更新为 $\Delta W_l = -\eta_l \cdot 0.2\sqrt{\max\{n_{\text{in}}, n_{\text{out}}\}} \cdot U_l V_l^\top$。由此 $\|\Delta W_l\|_{\mathrm{R}} = \Theta(\eta_l\sqrt{n_{\text{in}}}\max\{1, \sqrt{n_{\text{in}}/n_{\text{out}}}\})$。

初始化方差对齐标准 μP：$\sigma_l = \Theta(1/\sqrt{n_{\text{in}}} \cdot \min\{1, \sqrt{n_{\text{out}}/n_{\text{in}}}\})$，使 $\|W_l\|_{\mathrm{R}} = \Theta(1)$（$0 \le l \le L$）。代入谱条件：

块乘子：$\alpha_0 = \Theta(1)$, $\alpha_{L+1} = \Theta(1/n)$, $\alpha_l = \Theta(1/L)$ ($l \in [L]$)。

学习率：输入/输出层 $\eta_0, \eta_{L+1} = \Theta(1)$；隐藏层 $\eta_l = \Theta(1/\sqrt{n})$。

实践中以比率形式实现：设 $r_n = n/n_{\text{base}}$，$r_L = L/L_{\text{base}}$，则隐藏层学习率 $\eta_l = \eta_{\text{base}}/\sqrt{r_n}$，块乘子 $\alpha_l = \alpha_{\text{base}}/r_L$，输出乘子 $\alpha_{L+1} = \alpha_{\text{base}}/r_n$。HP 迁移流程：在小模型上搜索最优 η_{base}，按比率直接迁移至大模型。

其他优化器（附录 C）：SGD 隐藏层 $\eta_l = \Theta(1/n)$；AdamW 隐藏层 $\eta_l = \Theta(1/\sqrt{n})$；Shampoo/SOAP 隐藏层 $\eta_l = \Theta(1/\sqrt{n})$；SSO 隐藏层 $\eta_l = \Theta(1)$；Lion 隐藏层 $\eta_l = \Theta(1/n)$；Sophia 隐藏层 $\eta_l = \Theta(1/\sqrt{n})$——均从各自更新规则的 $\|\Delta W_l\|_{\mathrm{R}}$ 表达式自然推出，而非临时调参。

5. 实验结果

在 GPT-2 风格 Transformer 上验证（OpenWebText，序列长度 1024，head dim=64，FFN=4n），基础模型 $(n_{\text{base}}, L_{\text{base}}) = (256, 4)$。隐藏矩阵参数用 Muon-Kimi（Nesterov 动量 0.95），其余用 AdamW（$\beta_1 = 0.9$，$\beta_2 = 0.95$），无 weight decay。

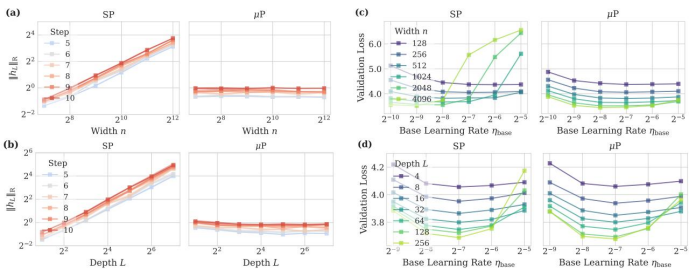

图 1：*SP vs μP* 的特征学习稳定性与 *HP* 迁移。*μP* 保持尺度不变特征范数与稳定最优学习率。

特征学习（coordinate check）：训练 10 步，缩放 n 或 L，测量最终 Transformer 块输出 $\|\boldsymbol{h}_L\|_{\mathrm{R}}$。SP 下特征范数随宽度和深度迅速增长；$\mu$P 下保持稳定且尺度不变（图 1(a,b)）。

HP 迁移：所有模型训练 300M token（batch size 240，线性 warmup + cosine decay）。SP 下最优学习率随宽度显著偏移（图 1(c)），HP 迁移失败。μP 下最优学习率在宽度和深度缩放中近乎不变（图 1(c,d)），且随模型增大一致获得更低 loss。

消除 LayerNorm 实验：移除 LayerNorm 后，SP 训练变得不稳定且深度方向 HP 迁移崩溃；μP 即使在 $L = 256$ 时仍保持稳定并展现鲁棒 HP 迁移，表明 μP 的稳定性来自正确的参数化而非归一化层的 "遮蔽效应"。

6. 与相关工作的对比

- **vs. Yang 等 [46] 宽度谱条件**：本文将谱视角从固定深度扩展至 $n, L \to \infty$ 联合缩放；
- **vs. Bordelon 等 [6], Yang 等 [47]**：他们分析单层残差块得 $\alpha_l = \Theta(1/\sqrt{L})$，本文统一为谱框架的特例并指出该缩放对两层块不足；
- **vs. Dey 等 [10]**（CompleteμP）：他们针对 AdamW 两层块得 $\alpha_l = \Theta(1/L)$，本文以更简洁的谱方法恢复并推广至任意优化器；
- **vs. Qiu 等 [31]**：他们将 μP 扩展至矩阵预处理优化器，本文在统一框架下自然涵盖 Shampoo/SOAP/Muon 等。

所有先前结果均为本文 Condition 3.1 在不同残差块深度 k 下的特例。

7. 局限性与未来方向

- 理论推导基于**线性残差 MLP + 单步更新**的简化设定，对非线性、多步训练的严格扩展依赖附录 F 中的温和假设（实验验证有效但非完全证明）；
- 实验仅覆盖 GPT-2 规模模型，更大规模（数十亿参数）的验证为未来工作；
- 框架假设残差块深度 k 固定，对混合深度块（如 MoE 中不同专家路径深度不同）的扩展未讨论；
- 未考虑 LoRA 等参数高效微调场景下的谱条件；
- 工作可能加速基础模型缩放，但也可能被用于生成 deepfake 等有害内容。

INSIGHT：基于加权互信息的高效 RLVR 数据选择方法

Zhou[1], Zhu[2], Zhang[3], Wang[3], Guo[1,4] — [1]King's College London, [2,3] 其他机构, 2025

1. 动机与问题背景

强化学习(RL)已成为提升大语言模型(LLM)推理能力与对齐性的核心范式，但其训练效率高度依赖**训练数据选择**。在 GRPO 式 RLVR（Reinforcement Learning with Verifiable Rewards）训练中，每个数据点需进行大量 rollout，计算与内存开销极高。若在静态、均匀采样的数据上训练，大量计算浪费在模型已掌握或当前能力无法解决的任务上，降低优化稳定性并缩小有效 batch size。

现有在线数据选择方法面临**信号获取成本**与**数据效用估计精度**之间的固有矛盾：

- **过采样方法**（如 Dynamic Sampling）：执行扩大的 rollout 批次以获取可靠估计，但引入 >2× 的额外计算开销；
- **基于难度的启发式**（如 MoPPS）：优先选择经验成功率接近目标值（如 0.5）的数据点，**隐式地将难度等同于信息量**，忽略了认知不确定性（epistemic uncertainty）——随着证据积累，数据可能仍然"困难"但已提供有限的学习信号。

INSIGHT（**IN**formation-guided data **S**ampl**I**n**G** met**H**od for RL **T**raining）基于**加权互信息**（Weighted Mutual Information, WMI）目标，联合建模数据难度与认知不确定性，以期望方差缩减最大化为原则选择最具信息量的数据点。

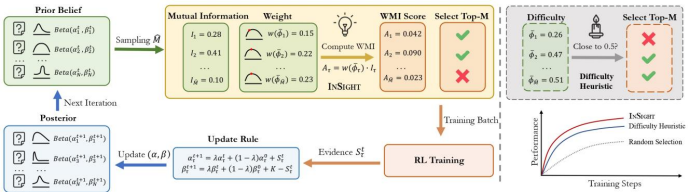

图 1：*INSIGHT* 流程概览。维护贝叶斯信念，用 *WMI* 评分选取 *top-M* 数据点，观测奖励更新后验。

2. 贝叶斯在线数据选择框架

2.1 数据建模

数据集 $\mathcal{T} = \{\tau_i\}_{i=1}^N$，每个数据点 τ 关联一个未知的潜在成功率 $\phi_\tau^t \in [0,1]$。RLVR 使用二值奖励 $r_\tau^{t,j} \sim \text{Bernoulli}(\phi_\tau^t)$，对 K 个独立 rollout 的似然为二项分布：$p(\boldsymbol{r}_\tau^t|\phi_\tau^t) = \binom{K}{S_\tau^t}(\phi_\tau^t)^{S_\tau^t}(1-\phi_\tau^t)^{K-S_\tau^t}$，其中 $S_\tau^t = \sum_{j=1}^K r_\tau^{t,j}$。

2.2 贝叶斯后验更新

成功率的先验采用 Beta 分布 $\phi_\tau^0 \sim \text{Beta}(\alpha_\tau^0, \beta_\tau^0)$（通常初始化为 $(1,1)$ 即均匀先验）。由于 Beta-Bernoulli 共轭性，后验仍为 Beta 分布：

$$\phi_\tau^t|\mathcal{H}_t \sim \text{Beta}(\alpha_\tau^t + S_\tau^t,\ \beta_\tau^t + K - S_\tau^t)$$

为适应策略漂移，引入**时间折扣**：$\alpha_\tau^{t+1} = \lambda\alpha_\tau^t + (1-\lambda)\alpha_\tau^0 + S_\tau^t$，$\beta_\tau^{t+1}$ 类似更新。

3. 难度选择的根本局限

为量化观测奖励后对 ϕ_τ 估计的改进，考虑期望方差缩减：

$$\Delta V(\tau) = \text{Var}_{\text{prior}}(\phi_\tau) - \mathbb{E}_r[\text{Var}_{\text{post}}(\phi_\tau|r)]$$

对 $K=1$ 的二值奖励情形，经完整推导得到：

$$\Delta V(\tau) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)^2} = \frac{\bar{\phi}_\tau(1-\bar{\phi}_\tau)}{(n+1)^2}$$

其中 $n = \alpha+\beta$ 为累积证据量，$\bar{\phi}_\tau = \alpha/(\alpha+\beta)$ 为分布均值。

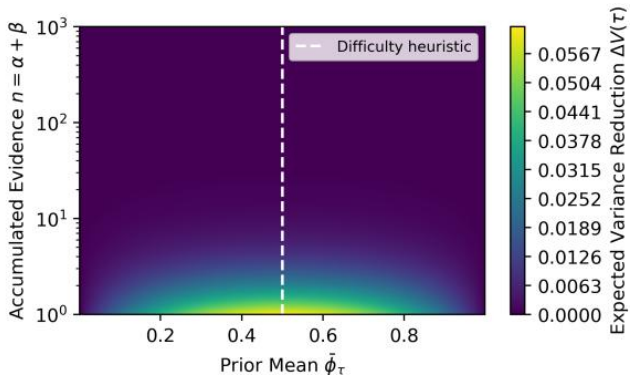

图 2：期望方差缩减随先验均值 $\bar{\phi}_\tau$ 与证据量 n 的变化。难度启发式仅关注 $\bar{\phi}_\tau \approx 0.5$，忽略证据衰减。

关键发现：方差缩减同时依赖难度分量 $\bar{\phi}_\tau(1-\bar{\phi}_\tau)$ 和证据分量 $1/(n+1)^2$。即便 $\bar{\phi}_\tau \approx 0.5$，当 n 很大时信息增益趋于零。纯难度启发式忽略采样变异性和证据衰减，会反复选择已充分估计的中等难度数据，实际信息增益有限。

4. INSIGHT 方法

4.1 互信息用于认知探索

互信息直接刻画观测奖励后对 ϕ_τ 不确定性的期望缩减：

$$I(R;\Phi_\tau) = H(\Phi_\tau) - \mathbb{E}_R[H(\Phi_\tau|R=r)]$$

其中 Beta 分布的熵有闭式解：$H(\Phi_\tau) = \ln \mathrm{B}(\alpha_\tau,\beta_\tau) + (\alpha_\tau+\beta_\tau-2)\psi(\alpha_\tau+\beta_\tau) - (\alpha_\tau-1)\psi(\alpha_\tau) - (\beta_\tau-1)\psi(\beta_\tau)$，$\psi(\cdot)$ 为 digamma 函数。

多 rollout 扩展。设 $S_\tau = \sum_{k=1}^K R_k \sim$ Beta-Binomial，边际概率为 $P(S_\tau = s|K,\alpha_\tau,\beta_\tau) = \binom{K}{s}\frac{\mathrm{B}(\alpha_\tau+s,\ \beta_\tau+K-s)}{\mathrm{B}(\alpha_\tau,\beta_\tau)}$。多 rollout 互信息：

$$I(R_{1:K};\Phi_\tau) = H(\Phi_\tau) - \sum_{s=0}^K P(S_\tau=s)\cdot H(\Phi_\tau|S_\tau=s)$$

渐近分析（命题 5.1）：当 $n_\tau = \alpha_\tau+\beta_\tau \to \infty$ 时，$I(R;\Phi_\tau) \approx \mathcal{O}(1/n_\tau)$。证明利用大 n 下 Beta 分布近似高斯，互信息约为 $\frac{1}{2(n_\tau+1)}$，信息增益随证据积累递减。

4.2 加权函数用于随机性利用

互信息对任务难度不敏感，需引入加权函数 $w(\cdot)$ 调制：

$$w(\bar{\phi}_\tau) = \underbrace{\bar{\phi}_\tau(1-\bar{\phi}_\tau)}_{\text{高方差过滤}} \cdot \underbrace{\exp\big(-\eta(\bar{\phi}_\tau-\mu)^2\big)}_{\text{难度偏置}}$$

第一项聚焦高结果变异性区域（排除确定性任务），第二项引入向目标难度 μ 的平滑偏置，η 控制课程偏置锐度。关键区别：w 作用于**先验均值** $\bar{\phi}_\tau = \mathbb{E}[\phi_\tau]$ 而非噪声采样值 $\hat{\phi}_\tau$。

4.3 加权互信息（WMI）选择

最终采集评分：$\mathcal{A}(\tau) = w(\bar{\phi}_\tau)\cdot I(R_{1:K};\Phi_\tau)$

每轮从大候选集 $\mathcal{T}_t^{\hat{M}}$（$\hat{M} \gg M$）中随机抽取，计算 WMI 评分后选取 top-M：$\mathcal{T}_t^M = \text{Top-}M(\{\tau \in \mathcal{T}_t^{\hat{M}} | \mathcal{A}(\tau)\})$。选中数据进行 rollout 和策略训练，观测奖励更新后验信念。整个过程**无需额外 LLM 推理**，计算开销可忽略。

5. 实验结果

5.1 实验设置

评估任务：规划(Countdown)、数学(AIME24/AMC23/MATH500/Mi
通用推理（MMLU/GPQA）。模型规模：Qwen3-0.6B/1.7B/4B，DeepSeek-R1-Distill-Qwen-7B。RL 算法：GRPO，$K=8$ rollout，训练 100 步，$\hat{M}=16\times M$。基线：RANDOM、MoPPS、INVERSE-EVIDENCE、EXPECTED-DIFFICULTY、Dynamic Sampling（DS，oracle 基线）。

5.2 规划与数学推理

模型	方法	Countdown	AIME24	AVG.
3*Qwen3-0.6B	RANDOM	71.57	10.41	42.16
	MoPPS	76.28	10.83	42.95
	INSIGHT	**76.70**	**11.90**	**43.56**
3*Qwen3-4B	RANDOM	84.90	51.45	67.16
	MoPPS	87.80	50.00	67.35
	INSIGHT	**87.96**	**53.75**	**68.46**
3*R1-Distill-7B	RANDOM	79.02	46.25	63.90
	MoPPS	81.66	47.20	64.52
	INSIGHT	**81.73**	**47.71**	**64.98**

INSIGHT 在所有模型规模上均取得最高平均准确率。Qwen3-0.6B 上平均提升 **+1.40**，Qwen3-4B 上 **+1.30**，7B 上 **+1.08**。Countdown 和 AIME24 上增益最显著，分别达 +5.13 和 +2.30。

5.3 通用推理

MMLU 四个子域和 GPQA 上, INSIGHT 一致领先。Qwen3-0.6B 上 GPQA 提升 **+3.16**，MMLU-STEM 提升 +0.85；Qwen3-1.7B 上 MMLU-Social-Sci. 提升 +0.91；Qwen3-4B 上平均提升 +0.48。

5.4 训练效率

在 Countdown（同分布评估）上, INSIGHT 以更少训练步数达到同等或更优性能：Qwen3-0.6B 上 ∼**2.2**× 加速，Qwen3-4B 上 ∼1.5×，R1-Distill-7B 上 ∼1.6×。与 DS 对比：DS 需 ∼30.5 小时（>2× 开销），INSIGHT 仅 ∼12.5 小时且性能可比。

6. 消融实验

6.1 WMI 组件贡献

单独使用互信息 $I(R_{1:K};\Phi_\tau)$ 性能弱于完整 WMI（如 Qwen3-4B AIME24: 51.66 vs 53.75），因 MI 不区分难度区间；单独使用 $w(\cdot)$ 亦不及完整组合（如 R1-7B AIME24: 46.67 vs 47.71）。两者结合在所有基准上一致最优，验证了联合建模认知不确定性与任务难度的必要性。

6.2 期望 vs. 采样难度

将 $\bar{\phi}_\tau$（先验均值）替换为 $\hat{\phi}_\tau \sim \mathrm{Beta}(\alpha_\tau, \beta_\tau)$（采样值），所有模型和基准上均性能下降（如 Qwen3-4B AIME24: 51.45 vs 53.75，AMC23: 77.48 vs 79.00），证实均值估计比采样值提供更稳定可靠的采集信号。

6.3 难度偏置 μ 的影响

$\mu = 0.3$ 在多数设置下最优或接近最优，表明优先选择中等偏难任务能有效平衡探索与课程塑造。极端设置（$\mu = 0.1$ 或 0.7）普遍性能下降，尤其在小模型上更显著（Qwen3-4B AIME24: μ=0.1 时 50.83 vs μ=0.3 时 53.75）。7B 模型对 μ 不敏感，反映更大模型的固有鲁棒性。

6.4 候选批次大小 $\hat{M}$

小模型（0.6B）在 $\hat{M}$=8× 时表现最佳（过大候选池引入超出学习能力的样本），大模型（4B/7B）则在 $\hat{M}$=16× 时一致最优，能更好利用候选多样性。

7. 讨论与局限

核心贡献：（1）通过期望方差缩减分析揭示纯难度选择的根本局限——忽略证据衰减；（2）提出 WMI 目标解耦难度与证据两个分量；（3）使用先验均值替代噪声采样值，自然扩展到多 rollout 设置；（4）在规划、数学、通用推理三类任务上一致提升性能与效率。

局限性：

- 改进幅度随模型规模增大而递减（大模型先验更强，选择空间有限）；
- μ、η、$\hat{M}$ 等超参数需根据模型规模调整，尚缺自适应机制；
- 贝叶斯建模假设二值奖励和 Beta-Bernoulli 共轭，对连续奖励或非共轭场景需进一步扩展；
- 当前聚焦单数据点选择，未考虑批次内数据点间的多样性与互补性。

ReGFT：通过参考解引导微调让 RL 学会困难问题

Wu[2,*], Li[3], Wen[3], Zhou[1], Talwalkar[3], Yang[3], Huang[1,†], Cai[1,†] — [1]ByteDance Seed, [2]UC Berkeley, [3]CMU, 2025

1. 问题动机与背景

基于可验证奖励的强化学习（RLVR）已成为提升 LLM 数学推理能力的核心范式：对每个问题采样多条推理轨迹，通过规则验证器判定最终答案正确性，优化模型增大正确轨迹的概率。然而 RLVR 受限于**奖励稀疏性**——当问题超出模型当前能力时，所有采样轨迹均无法获得正奖励，梯度信号完全缺失，训练陷入停滞。

现有缓解方案存在局限：

- **直接 SFT 参考解**：训练数据通常附带人写参考解（如 AoPS），但直接微调效果有限——参考解的推理风格与模型自身推理分布不匹配，泛化能力差；
- **ReFT**（REinforced Fine-Tuning）：仅在模型自身生成的正确轨迹上做 SFT，保持分布对齐，但对模型本身无法解决的难题仍然无能为力——无正确轨迹可供训练；
- **RL 阶段干预**：如 BREAD（注入专家前缀）、RL Teachers（蒸馏教师模型轨迹）、交替 SFT/RL 等，均在 RL 过程中修改算法，与本文正交。

核心观察：更强的 RL 前初始化能带来更有效的下游 RL。本文聚焦于 **RL 之前**通过有针对性的 SFT 提升模型在难题上的基线能力，使后续 RL 自然获得正奖励信号。

2. 方法：Reference-Guided Finetuning (ReGFT)

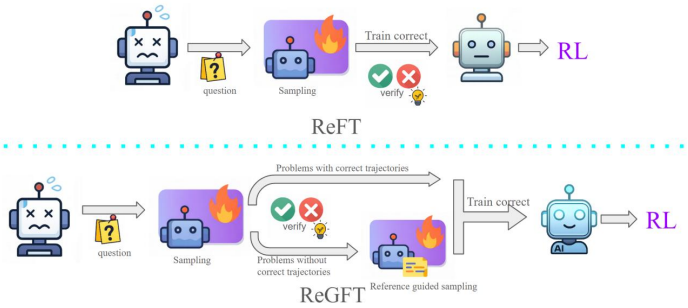

图 1：*ReFT vs ReGFT*。上：*ReFT* 仅用标准采样的正确轨迹；下：*ReGFT* 额外通过参考解引导采样恢复难题的正确轨迹。

2.1 参考解引导采样

对模型无法独立解决的难题，ReGFT 将人写参考解的**前 80% 句子**作为 hint 提供给模型(隐去含最终答案的后 20%)，要求模型**从头生成自己的推理轨迹**。关键设计：模型不是复制或续写参考解，而是在参考解的结构性引导下，用自身推理风格独立求解。这保证了：（1）轨迹与模型推理分布对齐；（2）受益于参考解中的高层策略指导。

提示模板为："Question: {question} Hint: {partial reference solution} Given the partial reference solution known to be correct as hints, derive your solution..."

2.2 训练流程

Step 1：标准采样。对每个训练问题采样 64 条轨迹，通过验证器筛选正确轨迹（对应 ReFT）。

Step 2：参考引导采样。对**难题**（标准采样 16 次正确率 $< 25\%$ 的问题）额外进行参考引导采样，生成 64 条轨迹并筛选正确者。排除简单问题以避免过拟合。

Step 3：混合微调。在标准采样正确轨迹 + 参考引导正确轨迹的混合集上做 SFT，得到 ReGFT checkpoint。

Step 4：RL 训练。从 ReGFT checkpoint 出发，使用 DAPO 进行强化学习。

2.3 DAPO 强化学习算法

采用 DAPO（Decoupled clip and Dynamic sAmpling Policy Optimization）作为 RL 算法，它是 GRPO 的改进版本，具备两个关键设计：（1）**解耦裁剪**（Decoupled Clipping）：上下裁剪阈值分离（$\varepsilon_{\text{low}} = 0.2$, $\varepsilon_{\text{high}} = 0.28$），允许灵活强化高质量轨迹而不坍缩策略多样性；（2）**动态采样**（Dynamic Sampling）：确保每次更新基于奖励多样的轨迹组，即使在稀疏奖励下也能提供信息性学习信号。

选择 DAPO 的目的是证明 ReGFT 的收益**正交于 RL 算法改进**——即使 DAPO 已包含动态采样缓解无信息梯度，从 ReGFT checkpoint 出发仍能持续带来额外提升。

3. 实验设置

基座模型：Qwen3-4B-2507-Instruct，具备强推理能力和稳定的指令跟随能力（Qwen2.5 对虚假奖励信号敏感）。

训练数据：OmniMath，含 4,428 道奥林匹克级数学题及验证参考解，奖励极度稀疏，适合研究 RLVR。

评估基准：AIME 2024（30 题）、AIME 2025（30 题）、Beyond-AIME（100 题，更难且未饱和）。

训练细节：最大生成长度 16,384 tokens，温度 0.7，top-p = 0.9。RL 使用 AdamW 优化器，学习率 1×10^{-6}，前 20 步线性 warm-up。采样 64 条/题时 batch size 为 128 prompts，mini-batch 2048，每步 4 次梯度更新。框架使用 verl。

4. 核心实验结果

4.1 ReGFT 增强 RL 训练

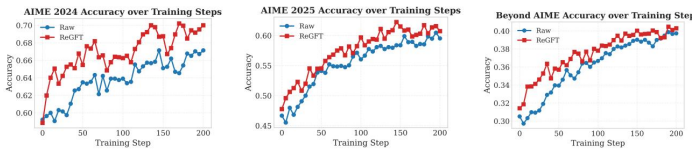

(a) AIME 2024 (b) AIME 2025 (c) Beyond AIME

图 2：三个基准上 *RL* 训练曲线。*ReGFT* 初始化一致实现更高准确率、更快收敛和更优最终性能。

如图 2 所示，从 ReGFT checkpoint 出发的模型在**全部三个基准的整个 RL 过程中**一致优于 raw checkpoint：

- 收敛准确率更高；
- 训练早期和中期阶段改进速度显著更快；
- 表明 ReGFT 通过增加难题上采样到正确轨迹的概率，为 RL 提供了更密集的学习信号。

4.2 参考引导示范的贡献

对比 ReFT 和 ReGFT 初始化后的 DAPO 训练：ReFT 初始化在早期阶段已优于 raw model（通过增加正确轨迹采样概率提升优化效率），但在所有基准的收敛性能上**一致劣于 ReGFT**，在 Beyond-AIME 上甚至不如 raw DAPO。

这表明 ReFT 主要**加速学习而未扩展推理能力边界**。相比之下，ReGFT 通过引入模型无法自主发现的推理模式，将能力扩展至此前不可解的问题，不仅提升训练效率，还**抬高了 RL 后可达的性能上限**。

4.3 模型自生成推理的必要性

将 ReGFT 与直接在原始参考解上 SFT 的基线对比：直接 SFT 在监督训练和 RL 后均显著更弱。这证明仅提供正确推理链不够——模型难以内化不符合其生成风格的推理模式。ReGFT 通过让模型在部分参考引导下**自己生成推理轨迹**，产生既正确又与模型推理分布对齐的解，是有效知识迁移的必要组件。

4.4 推理时扩展性能（pass@k）

使用 $N = 1024$ 次独立采样估计 pass@k：

$$\text{pass@k} = 1 - \frac{\binom{N-c}{k}}{\binom{N}{k}}$$

其中 c 为正确样本数。

ReGFT+DAPO 在所有基准上展现**最强且最一致的扩展性能**：在 AIME 2025 和 Beyond-AIME 上全面优于 ReFT 和 raw 基线；在 AIME 2024 上跨小 k 和大 k 均领先。随 k 增大，ReGFT 保持清晰性能差距，表明其改善了解空间覆盖而非仅限于少量样本。

相比之下，ReFT 在 pass@1 上优于 raw DAPO，但随 k 增大优势**逐渐消失**——ReFT 主要强化现有成功轨迹，可能偏置探索并限制推理时解的多样性。

5. 消融实验与补充分析

5.1 参考引导生成扩展可解题集

在 OmniMath 4,428 题上对比标准采样与参考引导采样（各 64 条/题）：标准采样解决 **68.58%** 的问题，参考引导采样

解决 **70.82%**。更重要的是，参考引导额外解决了 **5.85%** 标准采样永远无法解决的问题；反向有 3.61% 仅标准采样可解。ReGFT 在难题上同时训练两种策略的正确解，最大化正确解生成概率。

性能未达 100% 的原因：(1) 模型对复杂人类推理的理解能力有限，尤其当参考解依赖高级数学工具时；(2) OmniMath 的规则验证器对开放式或证明式答案存在假阴性。

5.2 微调模型的性能

模型	训练集%	p@64	AI24	AI25	B-AI
Raw	48.4	68.6	59.2	46.7	30.5
ReFT	49.6	70.2	62.1	46.8	31.3
ReGFT	50.1	72.5	60.0	47.8	31.3

ReGFT 在 OmniMath 训练集上 pass@64 达 72.5%（vs. ReFT 70.2%, Raw 68.6%），外部基准性能与 ReFT 相当，表明参考引导未导致过拟合，主要提升了难题覆盖率。

5.3 采样规模的影响

设置	AI'24	AI'25	B-AI
DAPO (16)	63.2	54.3	36.1
DAPO (64)	67.1	60.5	39.8
ReFT+DAPO (16)	66.2	57.8	35.0
ReFT+DAPO (64)	68.3	60.8	38.3
ReGFT+DAPO (16)	67.0	56.7	37.4
ReGFT+DAPO (64)	**70.0**	**61.6**	**40.3**

增大每题响应数（16 → 64）一致提升性能，但单纯扩大采样**不足以替代** ReGFT：即使 64 响应，无参考引导的模型仍落后于 ReGFT 初始化。ReGFT+DAPO 在所有设置下均为最优，表明**提升模型初始能力与增大探索规模互补且共同必要**。

6. 与相关工作的对比

本文与三类方法互补：(1) **扩展 RL 与自适应采样**（BroRL, ProRL 等延长训练或重分配 rollout 预算）——ReGFT 从初始化端改善，可叠加使用；(2) **问题增强**（QueSTa, BREAD 等在 RL 中注入提示或前缀）——ReGFT 在 RL 前操作，不修改 RL 算法；(3) **交替 SFT/RL**——ReGFT 为单次预处理阶段，更简洁。

与最近接的 ReFT 相比，ReGFT 通过参考引导**扩展了可训练问题集**；与 RL Teachers（蒸馏教师模型轨迹）相比，ReGFT 无需额外训练教师模型，直接利用训练数据中已有的参考解。

7. 局限性与未来方向

- **参考解依赖**：ReGFT 需要训练数据附带参考解，对无参考解的场景不直接适用；
- **验证器局限**：规则验证器对证明式/开放式答案存在假阴性，限制了参考引导采样的有效覆盖；
- **模型理解力上限**：当参考解涉及超出模型训练分布的高级数学工具时，引导效果受限；
- **单一 RL 算法验证**：仅在 DAPO 上验证，与其他 RL 算法（PPO, GRPO, GSPO）的组合效果待探索；
- **规模扩展**：仅在 4B 参数模型上实验，更大模型上的收益和最优 hint 比例（当前 80%）有待研究；
- **与 RL 阶段方法的联合**：ReGFT 与 BREAD、QueSTa 等 RL 阶段干预方法正交，联合使用可能带来进一步收益。

Tool-R0：零数据自演化 LLM 工具调用智能体

Acikgoz[1], Qian[1], Hübotter[2], Ji[1], Hakkani-Tür[1], Tur[1] — [1]UIUC, [2]ETH Zurich, 2025

1. 动机与问题定义

大语言模型（LLM）正成为通过工具交互解决复杂任务的自主智能体基础。强化学习（RL）已成为注入此类智能体能力的主流范式，但现有方法严重依赖**人工标注的任务–解答对**和精心设计的监督信号，面临根本性的可扩展性瓶颈：

- **数据依赖**：人工策划数据集（4k–210k 样本）耗费大量标注成本，且静态分布无法反映智能体在线学习中的动态需求，导致分布漂移；
- **能力上界**：模型能力被限制在人类专家的知识边界内，无法实现超越人类监督的自我进化；
- **领域局限**：已有自博弈方法（Absolute Zero、Agent0、Dr. Zero）仅限于数学推理、Python 代码工具或搜索问答等单一工具类型，未扩展至通用工具调用。

Tool-R0 是首个**零数据自博弈 RL 框架**，从同一基座 LLM 初始化 Generator（任务生成器）和 Solver（任务求解器），通过互补奖励信号驱动协同进化：Generator 在 Solver 的能力前沿生成有挑战性的工具调用任务，Solver 学习用真实工具调用解决它们。整个过程**无需任何预存在的任务数据集或人工标注**。

2. 系统架构

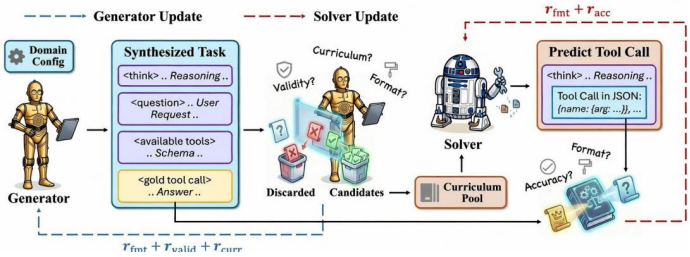

图 1：*Tool-R0* 自演化框架。基座 *LLM* 初始化为 *Generator* 和 *Solver* 两个角色，通过互补奖励协同进化。

如图 1 所示，训练进行 K 次自博弈迭代。每次迭代包含四个阶段：(1) 基于领域配置的**受约束任务合成**；(2) **Generator 训练**生成有挑战性的工具调用任务；(3) 冻结 Generator 并通过去重、交叉验证和难度排序构建**课程数据集**；(4) **Solver 训练**。

2.1 受约束任务规范（Grounded Task Specification）

自由生成模式下，LLM 会将概率质量集中在少数高似然模式上导致模式坍缩。Tool-R0 通过轻量级任务规范 $s \doteq (d, c, m, n)$ 约束生成：d 为任务领域，c 为交互上下文类型，m 为可用工具数，n 为金标准工具调用数。每步从用户定义的加权分布中动态采样 s 并注入 Generator 提示，形成条件生成分布 $q \sim \breve{\pi}_\theta(\cdot \mid s)$，提升多样性和鲁棒性。

2.2 Generator 训练

Generator π_θ 使用 GRPO（Group Relative Policy Optimization）优化，从零数据出发合成工具调用任务。每个样本包含：用户请求、工具菜单（JSON 格式的工具名称/描述/参数 schema）、金标准工具调用（仅含原始类型参数的 JSON）。输出分为四个标签块：`<think>`、`<question>`、`<available tools>`、`<tool call answer>`，确保可通过代码验证。

Generator 奖励设计由三个互补组件构成：

(1) 格式奖励 r_{fmt}：强制严格的结构合规性：

$$r_{\text{fmt}}(x) = \mathbb{I}_{\text{tags}}(x) + \mathbb{I}_{\text{tools-json}}(x) + \mathbb{I}_{\text{gold-json}}(x)$$

分别验证标签完整性、工具菜单 JSON 可解析性、金标准调用 JSON 可解析性。

(2) 有效性奖励 r_{valid}：确保工具菜单与金标准调用之间的内部一致性：

$$r_{\text{valid}}(x) = \lambda_M \mathbb{I}[n^\star \in \mathcal{T}] + \lambda_G \mathbb{I}[\mathbf{req}(n^\star) \subseteq \text{keys}(a^\star)] + \lambda_V \mathbb{I}[\mathbf{vals}(a^\star) = a^\star]$$

三项分别验证：金标准工具存在于菜单中、所有必需参数均已提供、非平凡参数值在问题文本中有词边界匹配（防止动作幻觉）。权重 $(\lambda_M, \lambda_G, \lambda_V) = (0.4, 0.4, 0.2)$。

(3) 课程奖励 r_{curr}：引导 Generator 生成位于 Solver 能力前沿的任务，由难度信号 r_{diff} 和语义一致性 r_{sem} 组合。对生成的问题和工具菜单，用冻结 Solver 进行 $K = 8$ 次 Monte Carlo 采样，估计成功率 $\hat{p}_{\text{succ}} = \frac{1}{K}\sum_{k=1}^{K} \mathbb{I}[\hat{c}^{(k)} = c^\star]$，难度奖励采用**带通滤波**设计：

$$r_{\text{diff}}(x) = \begin{cases} 1, & \hat{p}_{\text{succ}} \in [P_{\text{low}}, P_{\text{high}}], \\ \exp\!\left(-\frac{(\hat{p}_{\text{succ}} - P_{\text{low/high}})^2}{2\sigma^2}\right), & \text{带外平滑衰减}, \\ 0, & \hat{p}_{\text{succ}} < 1/K. \end{cases}$$

其中 $[P_{\text{low}}, P_{\text{high}}] = [0.25, 0.75]$，$\sigma = 0.12$。设计要点：(i) $\hat{p}_{\text{succ}} < 1/K$ 的不可解任务直接归零；(ii) 在 $\hat{p}_{\text{succ}} \approx 0.5$ 附近设置平台区吸收采样噪声；(iii) 高斯衰减（而非硬截断）提供平滑梯度信号。语义对齐 r_{sem} 由 Solver 对 Generator 输出的 1–5 分语义评分归一化得到。最终 $r_{\text{curr}} = r_{\text{diff}} + r_{\text{sem}}$。

2.3 Solver 数据集构建

冻结 Generator 后大规模采样候选任务，经三步过滤：(1) 通过问题–工具–调用的规范化签名**去重**；(2) 多次采样 Solver 预测并与金标准比对进行**交叉验证**，仅保留一致性高的样本；(3) 按 pass@K 成功率估计难度，分为 easy/medium/hard 桶，按**由易到难**的课程顺序组织。基础实验中每迭代生成 10,000 候选、过滤至 2,000 样本。

2.4 Solver 训练

Solver π_ϕ 使用 GRPO 优化，先在 `<think>` 中推理，再在 `<tool call answer>` 中预测工具调用。**格式奖励**：$r_{fmt}(\hat{y}) = \lambda_{\text{tag}} \cdot \mathbb{I}_{\text{tag}} + \lambda_{\text{parse}} \cdot \mathbb{I}_{\text{parse}} + \lambda_{\text{norm}} \cdot \mathbb{I}_{\text{norm}}$，权重 $(0.3, 0.3, 0.4)$。**准确性奖励**分解为三个密集子分数：工具名匹配 $s_{\text{name}} \in \{0, 1\}$、参数键 F1 重叠 $s_{\text{key}} \in [0, 1]$、值匹配 $s_{\text{val}} \in [0, 1]$（支持数值强制转换和空白不敏感匹配），权重 $(\lambda_{\text{name}}, \lambda_{\text{key}}, \lambda_{\text{val}}) = (0.2, 0.3, 0.5)$。配对分数 $s(\hat{c}, c^\star)$ 通过贪心最大匹配对齐，最终乘以过度预测惩罚：$r_{\text{acc}} = \bar{s} \cdot \frac{1}{1 + \alpha \cdot \max(0, |\hat{C}| - |C^\star|)}$，$\alpha = 0.25$。Solver 改善后的成功统计直接反馈至 Generator 的难度奖励，**闭合自博弈循环**。

3. 核心实验结果

3.1 主要性能

在五个工具调用基准上评估：ToolAlpaca（多步工具组合）、SealTool（单轮 API 选择）、NexusRaven（函数调用）、API-Bank（对话式工具使用）、SNIPS（用户意图追踪）。所有基准使用 AST 匹配指标。

模型配置	平均准确率（Δ）
Qwen2.5-0.5B-Instruct	15.47
+ Tool-R0	30.57 (+15.10, ↑101%)
Qwen2.5-1.5B-Instruct	24.85
+ Tool-R0	**47.84** (+22.99, ↑92.5%)
Qwen2.5-3B-Instruct	43.97
+ Tool-R0	48.50 (+4.53, ↑10.3%)
Llama-3.2-3B-Instruct	36.12
+ Tool-R0	40.47 (+4.35, ↑12.0%)

关键发现：(1) 自博弈在所有模型规模和架构上均带来一致提升；(2) 小模型受益最大——0.5B 训练后超越 1.5B 基座，1.5B 训练后超越 3B 基座；(3) 跨模型族（Qwen vs. Llama）均有效，证明框架与架构无关。

3.2 超越监督基线

训练数据	样本数	平均
xLAM Dataset	60k	43.60
Hammer Dataset	210k	43.74
ToolACE Dataset	12k	44.71
ToolRL Dataset	4k	46.06
Tool-R0（零数据）	**0**	**47.84**

所有模型均基于 Qwen2.5-1.5B-Instruct，使用相同超参数。Tool-R0 以零数据超越所有使用 4k–210k 人工标注数据的监督基线。余弦相似度分析（图 4）表明：人工数据集存在固有偏差和分布局限，而 Tool-R0 自生成课程在所有基准上实现最高平均相似度和最均匀覆盖。

4. 消融实验

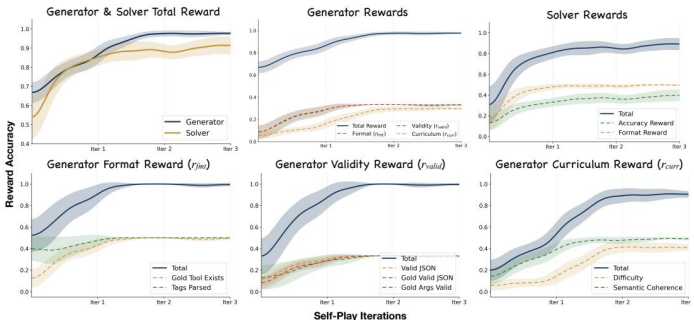

图 2: *Generator–Solver RLVR* 训练动态。上排：总奖励轨迹及组件分解；下排：格式、有效性和课程奖励的详细分解。

消融配置	平均 / 降幅
Tool-R0（完整版）	47.84
共享权重	30.42 (↓36.4%)
冻结 Generator	41.65 (↓12.9%)
去除难度奖励 r_{diff}	43.54 (↓9.0%)
硬截断替代高斯衰减	44.10 (↓7.8%)

参数分离至关重要（−17.42pp）：共享权重下，Generator 的探索性梯度与 Solver 的执行性梯度产生干扰，导致灾难性遗忘。工具调用的开放式高熵动作空间要求本质不对称的角色——不同于围棋等对称博弈。

Generator 必须持续学习（−6.19pp）：冻结后退化表明性能增益关键依赖于 Generator 生成越来越有针对性的挑战。训练动态（图 2）验证此点：难度分量从迭代 1 的 0.1 升至迭代 2 的 0.4 后趋于平稳，语义一致性始终稳定在 0.5，证实难度提升未牺牲任务质量。

难度感知奖励不可或缺（−4.30pp）：仅生成可解任务而不校准难度不足以维持学习。高斯平滑衰减（vs. 硬截断，−3.74pp）通过在能力前沿附近提供信息性反馈实现更稳定的训练。

5. 自博弈收敛与扩展行为

将训练扩展至五次迭代后观察到：（1）小模型（0.5B/1.5B）在第三次迭代附近达到峰值后饱和或轻微退化，与早期收敛至 Nash 均衡和知识边界一致；（2）3B 模型呈现持续稳定改善且无饱和迹象，表明更高容量延迟收敛，有潜力从更多迭代中获益。这解释了为何小模型初始增益大但提升空间有限。

作为中间训练阶段：将每次 Tool-R0 迭代作为中间训练检查点，再用 ToolACE 数据做监督微调。结果显示 Tool-R0 + 后训练从第一次迭代起即超越纯 SFT 基线，且随迭代持续提升。三次迭代后同时超越单独后训练和单独 Tool-R0，证明自博弈可作为可扩展的初始阶段增强后续监督对齐效果。

6. 训练动态分析

图 2 揭示了协同进化的学习层次：（1）Generator 收敛快于 Solver（总奖励 ∼0.98 vs. 0.90），反映任务合成固有比求解简单；（2）Generator 奖励呈现明确学习层次——格式合规首先饱和、有效性稳步提升、课程奖励增长最陡；（3）Solver 侧格式奖励上升快于准确性奖励，准确性仍是收敛时的性能瓶颈；（4）两者均趋向高总奖励且差距缩窄，表明接近稳定均衡。

错误类型分析：基座模型的失败以结构错误为主（错误工具名、调用数量不对、参数幻觉），Tool-R0 将其减少近半。语义错误也有下降但仍是主要瓶颈，格式错误几乎消除。

7. 讨论与局限

核心贡献：（1）首个零数据通用工具调用自博弈框架；（2）自生成课程超越人工监督数据集；（3）参数分离、难度感知奖励、平滑衰减的系统性验证；（4）可作为有效的中间训练阶段。

主要局限：

- **规模与奖励鲁棒性**：小模型偶现奖励黑客行为（通过验证但质量低），需更精细的奖励校准；
- **早期饱和**：低容量模型数次迭代后收敛，Generator 与 Solver 达到知识边界的 Nash 均衡；均衡动力学的深入研究为未来方向；
- **课程信号效率**：多次查询 Solver 估计难度增加计算开销，基于损失或梯度的信号可能更直接；
- **知识边界**：Generator 和 Solver 从同一基座模型出发，自博弈在隐式知识耗尽时饱和；引入更强教师或工具支持的 oracle 可能突破此限制。

未来方向：（1）更丰富的难度反馈（损失/梯度信号、语义错误归因）；（2）外部信号打破知识边界；（3）显式约束作为维持多样性的机制；（4）定量的生成质量度量（任务真实性、歧义度、覆盖率、标签可靠性）。

Agentic Code Reasoning：基于半形式化推理的无执行代码语义分析

Shubham Ugare, Satish Chandra — Meta, USA, 2026

1. 核心思想与动机

本文研究**智能体代码推理**（agentic code reasoning）：LLM 智能体能否在不执行代码的情况下，通过浏览代码库、追踪依赖关系，完成深层语义分析？这对 bug 检测、代码审查和补丁验证至关重要，但面临两个根本挑战：（1）如何建立代码理解的 ground truth？（2）如何确保智能体真正推理而非猜测？

现有方法的不足： SWE-RM 训练奖励模型近似测试结果、Agentic Rubrics 将验证分解为 LLM 生成的评判准则、Code-Judge 直接用 LLM 做评估——但它们均使用**非结构化推理**，允许模型对代码行为做出无依据的断言。另一极端，完全形式化方法（Lean/Coq/Datalog）虽可自动验证，但需要形式化语言语义，对跨框架、跨语言的任意仓库代码不切实际。Sultan 等指出 LLM 可竞争性预测程序终止性，却常无法提供有效证明。

作者提出**半形式化推理**（semi-formal reasoning）：一种结构化提示方法论，要求智能体构建显式前提（premises）、追踪执行路径（execution traces）并推导形式化结论（formal conclusions）。其核心设计为**证书模板**（certificate template）——智能体不能跳过情况或做出无证据声明，从而弥合非结构化 CoT 与完全形式化证明之间的鸿沟。

任务	关键结果
补丁等价性（精选）	78% → 88%（+10pp）
补丁等价性（真实补丁）	93%（Opus-4.5）
代码问答 RubberDuckBench	87%（+9pp over 标准）
故障定位 Defects4J	Top-5 +5–12pp

2. 激励示例

Django django-13670 任务要求判断两个补丁是否语义等价。Patch 1 使用 `format(self.data.year, "04d")[-2:]`，Patch 2 使用 `'%02d' % (self.data.year % 100)`。**标准推理**错误地假设 `format()` 为 Python 内建函数，得出两者等价。**半形式化推理**要求追踪函数定义，发现 Django 的 `dateformat.py` 第 340 行定义了同名模块级函数 `format(value, format_string)`——Python 名称解析按 local → module → builtins 顺序，故 Patch 1 调用的是该模块函数（期望 datetime 对象），传入整数 476 将引发 `AttributeError`。这种**名称遮蔽**（name shadowing）问题仅靠结构化追踪才能发现。

3. 半形式化推理方法论

3.1 标准推理 vs. 半形式化推理

标准推理： 智能体仅收到最小化提示，以自然语言自由解释后给出 YES/NO。速度快但允许无根据断言——例如智能体可能注意到某补丁修改了额外文件却直接假设无测试依赖这些更改。

半形式化推理： 在初始提示中嵌入**结构化证书模板**，强制执行以下流程：

- **PREMISES**：显式陈述每个补丁的修改内容、F2P/P2P 测试检查的具体行为；
- **ANALYSIS**：逐测试追踪两个补丁的执行行为，写出 Claim 并标注 SAME/DIFFERENT；
- **EDGE CASES**：仅分析实际测试会执行到的边界情况；
- **COUNTEREXAMPLE**（非等价时必填）或 **NO COUNTEREXAMPLE EXISTS**（等价时必填）；
- **FORMAL CONCLUSION**：基于定义 D1 列出每个测试的 PASS/FAIL 并推导最终判定。

Semi-formal Certificate Template (patch equivalence)

```
DEFINITIONS:
D1: Two patches are EQUIVALENT MODULO TESTS iff
    the test suite produces identical pass/fail
    outcomes for both patches.

PREMISES (state what each patch does):
P1: Patch 1 modifies [file(s)] by [change]
P2: Patch 2 modifies [file(s)] by [change]
P3: The FAIL_TO_PASS tests check [behavior]

ANALYSIS OF TEST BEHAVIOR:
For each test:
  Claim: With Patch 1, test [name] will [PASS/FAIL]
         because [execution trace]
  Claim: With Patch 2, test [name] will [PASS/FAIL]
         because [execution trace]
  Comparison: [SAME/DIFFERENT] outcome

COUNTEREXAMPLE (if NOT EQUIVALENT):
  Test [name] produces different outcomes because
  [specific code trace evidence]

FORMAL CONCLUSION:
By D1, since test outcomes are [IDENTICAL/DIFFERENT],
patches are [EQUIVALENT/NOT EQUIVALENT].
```

图 *1*：补丁等价性半形式化证书模板（精简版）。智能体必须用从代码库收集的证据填充每个括号字段。

关键设计洞察：通过结构化推理过程（而非仅输出格式），迫使智能体在下结论前收集证据，防止非约束推理中常见的过早判断。实践中观察到这自然引导智能体枚举程序路径而非猜测，驱动更深入的**过程间推理**——追踪函数调用以证实其声明。证书模板按任务定制：故障定位版本要求假设-证据-置信度链；代码问答版本要求函数追踪表、数据流分析和替代假设检验。

3.2 实验设置

采用最小化 SWE-agent 设置，智能体可访问 bash 工具，最大步数 100。关键限制：**不能执行仓库代码或运行测试套件**（依赖未安装、环境未沙箱化），Git 命令禁用。智能体可运行独立 Python 脚本探测通用语言行为，但主要分析模式为静态。

4. 补丁等价性验证

定义： 两个补丁模测试等价（equivalent modulo tests）当且仅当执行仓库测试套件（F2P ∪ P2P）对两者产生相同的 pass/fail 结果。真正语义等价不可判定，此定义使问题可处理。

4.1 精选数据集评估

从 SWE-bench-Verified 社区收集的智能体轨迹中采样补丁对，刻意构建困难分布：高相似度（LLM 评分 ≥ 7, difflib > 0.3）但解决状态不同的对 + 两者均通过的正样本，共 170 个样本。随机基线 50%。

推理模式	总体准确率	步数	非等价 Acc
标准推理	78.2%	10.08	78.6%
半形式化	**88.8%**	28.17	82.9%

半形式化推理将错误率降低近半（+10.6pp），等价类准确率达 93.0%。代价为约 2.8× 步数。剩余 19 个错误中约一半为非等价对中未追踪到的执行差异。

4.2 带测试规格的 LLM 验证器

实际应用场景：检查 LLM 生成补丁是否匹配已知参考解（gold patch），若无需运行测试即可验证，可大幅降低 RL 训练管线成本。从 live-swe-agent (gemini-3-pro) 采样 200 例（100 正确 + 100 错误），平衡分布。

模型	模式	准确率	步数
difflib	最优阈值 =0.4	73%	–
Sonnet-4.5	单次调用	80.0%	1
Sonnet-4.5	+ 文件上下文	82.0%	1
Sonnet-4.5	智能体（标准）	84.5%	20.67
Sonnet-4.5	智能体（半形式化）	91.5%	43.23
Opus-4.5	单次调用	86.0%	1
Opus-4.5	+ 文件上下文	87.5%	1
Opus-4.5	智能体（半形式化）	**93.0%**	37.82

Opus-4.5 半形式化达 93%，比 difflib（SWE-RL 使用的奖励信号）高 20pp。单次调用模式（80–87%）证实许多验证任务需要超越补丁上下文的代码探索。**错误模式**：（1）尽管有指令仍未完整追踪执行；（2）第三方库语义——源码不可

用时从函数名猜测行为；（3）忽视细微差异——识别到语义差异却错误判断与测试结果无关。

5. 故障定位

在 Defects4J 上评估。智能体仅获得失败测试名称和源码，**无**堆栈追踪、错误信息或执行信息。评估 Top-N 准确率，两种度量：All（所有 ground-truth hunk 均被覆盖）和 Any（至少一个被覆盖）。

5.1 小规模评估（43 可评估 bug）

模式	探索	Top-1	Top-3	Top-5(All)
标准	单次	36.1%	55.6%	55.6%
半形式化	单次	41.7%	58.3%	63.9%
标准	智能体	46.5%	60.5%	60.5%
半形式化	智能体	**53.5%**	**67.4%**	**72.1%**

半形式化 + 智能体达 72.1% Top-5（All）和 88.4% Top-5（Any），分别比标准模式高 +12pp 和 +7pp。

5.2 大规模验证（90 可评估 bug）

模型	模式	Top-1	Top-3	Top-5(All)
Sonnet-4.5	标准	20.0%	30.0%	31.1%
Sonnet-4.5	半形式化	16.7%	25.6%	30.0%
Opus-4.5	标准	30.0%	42.2%	43.3%
Opus-4.5	半形式化	**34.4%**	**47.8%**	**47.8%**

Opus-4.5 半形式化 Top-5 改进 +5pp。**错误分析**（4 类）：（1）间接 bug——bug 在非直接调用类中（如 Csv_12 中 bug 在 CSVFormat.withHeader()，而测试调用 CSVParser.parse()）；（2）多文件 bug——5+ 行跨 2+ 文件系统性更难；（3）领域特定 bug——需专业知识如数值分析（Math_81 EigenDecomposition）；（4）修复区域超过 5 个（5/90）。

案例 Mockito_8：标准推理仅定位到 StackOverflowError 崩溃点（`getActualTypeArgumentFor` 181–189 行）。半形式化推理的 4 阶段模板驱动了系统性调查：Phase 1 建立关于自引用类型 `SelfRef<T extends SelfRef<T>>>` 的前提；Phase 2 产生 10 个形式化观察追踪完整注册管线；Phase 3 测试 3 个假设并发现 `registerTypeVariablesOn` 第 80 行将安全映射 T→TypeVarBoundedType(T) 覆写为自引用 T→T；Phase 4 正确将根因排在 Rank 1。

6. 代码问答

在 RubberDuckBench（15 题，Python/Java/C++ 仓库）上评估。使用多模型 LLM 评分（Gemini-3-Pro + GPT-5.2，85% 一致率）。半形式化模板要求填写函数追踪表、数据流分析、语义属性及替代假设检验。

```
FUNCTION TRACE TABLE:
| Function            | File:Line              | Behavior (VERIFIED)                |
|---------------------|------------------------|------------------------------------|
| toggleSlicingOptions | QtReflEventView.cpp:99 | Sets m_sliceType to SliceType enum |
```

图 2：代码问答半形式化推理示例——数据流分析追踪变量创建、修改和使用位置。

模型	模式	准确率	步数
Opus-4.5	单次	76.2%	1
Opus-4.5	智能体（标准）	78.3%	10.8
Opus-4.5	智能体（半形式化）	**87.0%**	19.7
Sonnet-4.5	智能体（标准）	84.2%	17.6
Sonnet-4.5	智能体（半形式化）	84.8%	25.3

Opus-4.5 从 78.3%→87.0%（+8.7pp）。值得注意的是 Sonnet-4.5 标准模式已达 84.2%，半形式化几乎无增益（84.8%），暗示当基座模型已足够强时结构化推理的边际收益递减。**成功案例**（cpp_3）：标准推理得 79 分声称 `at()` 提供"异常错误处理"；半形式化追踪了 map 初始化（4 个 SliceType 映射）和 `m_sliceType` 赋值（仅来自同一枚举），证明非法键不可能存在，得 100 分。**失败案例**（py_5）：智能体追踪了 5 个函数却遗漏下游代码已处理其发现的边界情况，导致自信但错误的回答（57 分）。按语言分：C++ 88.0%, Python 87.5%, Java 85.5%。

7. 相关工作对比

与**执行免验证**方法比较：SWE-RM 训练奖励模型但使用非结构化推理；本文通过结构化半形式化推理达 93%（vs. SWE-RL 的 difflib 仅 73%）。与**形式化方法**比较：Lean/Coq 方法需形式化语义，对任意仓库代码不可行；半形式化保留自然语言但强制证据结构。与 **CoT/ReAct** 比较：本文将 CoT 扩展为任务特定结构化模板，证明单纯提供推理空间不如强制证据收集。与 **EquiBench** 比较：后者仅处理小型自包含代码对，本文处理仓库级带测试套件的补丁。与 Sistla 等的 Datalog 后验验证互补：本文改进"输入侧"（智能体被要求做什么），他们改进"输出侧"（事后验证推理步骤）。

数据污染说明：SWE-bench 实例可能存在于训练语料中。但核心结论基于同一模型不同推理格式的相对比较（消融实验），污染对所有配置影响相同。且智能体设置要求运行时主动探索代码而非回忆记忆解。

8. 讨论与局限

核心贡献：（1）首次系统研究无执行的智能体代码推理，跨 3 个任务验证半形式化推理一致优于标准推理（+5–12pp）；（2）93% 补丁等价验证准确率使无执行 RL 反馈成为可能；（3）结构化推理模板可视为**经典静态分析的灵活替代**——无需在专用算法中编码分析逻辑，而是用任务特定模板提示 LLM 智能体，天然泛化跨语言和框架。

主要局限：

- 半形式化证书虽比完整轨迹更易人工验证，但缺乏完全形式化方法的**自动可检查性**；
- 计算开销：半形式化需 2–3× 步数（标准 10–20 步 vs. 半形式化 28–43 步）；
- 第三方库源码不可用时智能体仍会从函数名猜测语义；
- 对 Sonnet-4.5 等已较强的基座模型，结构化推理边际收益可能饱和。

未来方向：（1）**后训练**——微调模型内化模板结构，提升准确率同时消除提示开销；（2）扩展至安全漏洞检测、代码异味识别、API 误用检测等其他静态分析任务；（3）**混合验证**——结合轻量形式化方法或符号执行以获得更强保证同时保持灵活性。

RL 何时有益于医学 VLM? 解耦视觉、SFT 与 RL 的增益

Jeddi*, Shaban*, Baghbanzadeh*, Sharan, Moturu, Dolatabadi, Taati — U of Toronto / Vector / York, 2026

1. 动机与核心问题

强化学习（RL）日益被用于医学视觉语言模型（VLM）的后训练（post-training），尤其是 RLVR/GRPO 范式。然而现有管线普遍遵循 "通用 VLM → 少量 SFT → RL" 的模板，且结果**跨模态不一致**：部分任务显著提升，部分则退化或无变化。这引发三个根本性问题：

- 观测到的提升有多少来自**视觉感知**改善 vs. 语言端对齐?
- 多少归因于 **SFT** 而非 RL?
- RL 在何种条件下真正值得其计算代价?

近期通用 LLM 研究（Yue et al. [26], Zhang et al. [27]）对 "RLVR 创造新推理能力" 的假设提出挑战：通过 Pass@K 探测发现 RL 主要**重塑输出分布**以更高效采样已有正确解，而非扩展模型的潜在支撑集（support）。本文将这一视角引入医学 VLM，系统解耦视觉、SFT 与 RL 三个轴向的贡献。

核心贡献： (1) 通过视觉线性探测（linear probing）识别表征瓶颈；(2) 用 Accuracy@1 vs. Pass@K 刻画模型的**支撑边界**（support boundary）；(3) 控制实验评估 RL 的域内增益与跨模态迁移；(4) 提出**边界感知训练策略**（boundary-aware recipe），在 OctoMed 基础上以 PMC-VQA 小子集 RL 后训练，在六个医学 VQA 基准上取得最优平均性能。

2. 实验设置

2.1 测试平台：MedMNIST-v2

采用 MedMNIST-v2 [24] 作为控制测试平台，覆盖三**种成像模态**和十二个任务，统一输入分辨率 224×224，在官方测试集的平衡子集上评估。该平台支持：视觉探测、基于类别标签的多选 VQA 评估、高效 RLVR 实验。

三种模态分组：**放射学**(Breast/Chest/Pneumonia/OrganA/C/S)、**显微镜**（Blood/Path/Tissue）、**可见光摄影**(Derma/OCT/Retina)。

2.2 模型

- M_{Base}：Qwen2.5-VL-7B-Instruct [2]（通用预训练基座）；
- M_{SFT}：OctoMed-7B [17]（大规模医学 SFT）；
- M_{RL}：QoQ-Med-7B [5]（RL 后训练的医学 VLM）。

2.3 评估指标

(i) **Accuracy@1**：贪婪解码下的单次准确率；(ii) **Pass@K**：K 次独立采样中至少一次正确的概率（$K \in \{1, 2, 4, 8, 16\}$，温度 0.7，top-p 0.9）。输出限制在 `<think>` 和 `<answer>` 标签内，由 Qwen2.5-VL-32B-Instruct 验证正确性。**支撑间隙** $G_K = \text{Pass@K} - \text{Acc@1}$ 量化贪婪解码未能兑现的潜在能力。

3. RQ1：医学 VLM 的视觉表征有多强?

冻结各模型的视觉编码器（ViT），在 MedMNIST-v2 上进行线性探测。同时引入 MedViT-v2 [15] 作为纯视觉参考上限。

模型	Breast	Chest	Pneum.	OrgA
MedViT-v2	91.00	96.70	97.30	97.30
M_{Base}	80.95	13.33	92.52	85.27
M_{SFT}	84.52	16.51	93.35	89.01
M_{RL}	75.00	16.19	92.95	85.52
	Blood	**Path**	**OCT**	**Retina**
MedViT-v2	98.70	97.10	95.20	57.80
M_{Base}	96.19	89.12	84.30	44.00
M_{SFT}	96.19	93.35	91.10	52.00
M_{RL}	96.86	88.50	84.80	51.00

发现 1：基座模型在多数任务上已具备合理可分的视觉特征；医学 SFT 进一步改善弱数据集表征（如 OCT: 84.30→91.10, Retina: 44.00→52.00）。**RL 不一致地改善 ViT 探测准确率**（Breast 甚至从 80.95 降至 75.00），表明其作用主要在采样/对齐层面而非视觉表征。Chest 等数据集（∼16%）远低于 MedViT-v2（96.70%），揭示感知瓶颈限制了下游增益上限。

4. RQ2：医学 VLM 的推理容量边界

将分类转化为 C 选项的多选 VLM 提示，比较 Accuracy@1 与 Pass@K。

Acc@1	Breast	Pneum.	Blood	OCT
M_{Base}	54.99	50.53	13.16	32.62
M_{SFT}	79.17	86.00	76.00	82.78
M_{RL}	69.79	62.41	13.95	28.72

跨所有任务，Accuracy@1 **远低于** Pass@K，表明存在大量贪婪解码无法兑现的**潜在支撑**。例如 M_{SFT} 在 OrganA 上 Acc@1 仅 18.66% 但 Pass@16 可达显著更高水平。医学 SFT 同时提升 Acc@1 和 Pass@K，与覆盖范围和对齐改善一致。

发现 2：SFT 扩展覆盖并改善对齐。RL 后训练的 M_{RL}（QoQ-Med）**不一致地改善 Accuracy@1**，且**频繁降低 Pass@K**（如 Pneumonia: 62.41 vs. SFT 的 86.00；OCT: 28.72 vs. SFT 的 82.78），表明分布锐化（sharpening）未伴随支撑扩展，某些情况下甚至收窄了边界。

5. RQ3：RL 何时有效?

5.1 实验设计

每种模态选一个任务进行针对性 RL 后训练：OrganAMNIST（放射学）、PathMNIST（显微镜）、OCTMNIST（可见光）。分别从 M_{Base} 和 M_{SFT} 初始化，使用**一致性感知 GRPO**（consistency-aware GRPO [4,9]）替代 vanilla GRPO 以稳定小数据优化。评估三种迁移场景：(1) 域内；(2) 模态内迁移（OrganA→OrganC/S, OrganA→Pneumonia）；(3) 跨模态迁移（OCT→Path, OrganA→Path, OrganA→OCT）。

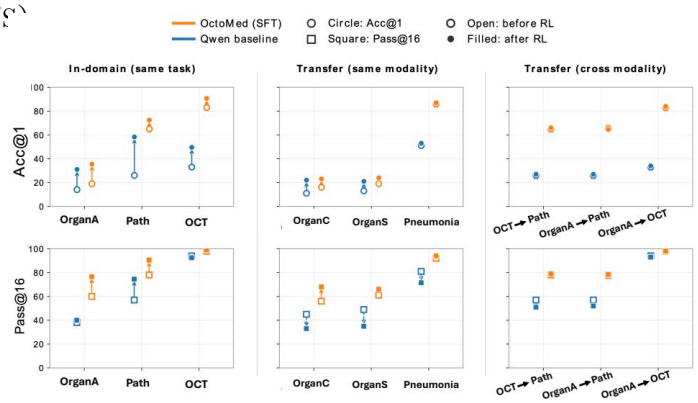

图 1：*RL 前后 Acc@1 与 Pass@16 变化（从 M_{Base} 和 M_{SFT} 出发），涵盖域内、模态内、跨模态迁移。*

5.2 结果分析

如图 1 所示，RL 主要起**锐化（sharpening）**作用——将更多概率质量放在模型支撑集中已有的正确答案上，从而提升 Acc@1。具体模式：

域内（in-domain）：从 M_{SFT} 出发时增益最显著——即使适度的桥接（bridging）即可产生明确的域内增益，但增益幅度受起始 Pass@16 限制。

模态内迁移：小偏移（OrganA→OrganC/S，同一器官家族不同视图）时 RL 常改善 Acc@1；从 M_{Base} 初始化时更频繁地牺牲 Pass@16。大偏移（OrganA→Pneumonia）增益更小且 M_{Base} 的 Pass@16 下降更常见。

跨模态迁移：RL 对 Acc@1 几乎无变化，且可能轻微降低 Pass@16，尤其从未桥接的基座模型出发时。

发现 3：RL 在模型已具备**非平凡支撑**时最有效：锐化分布、提升 Acc@1（采样效率）、缩小 Acc@1–Pass@K 间隙。当支撑薄弱（大偏移或跨模态），准确率增益有限且 Pass@K 可能下降。

6. 边界感知训练策略

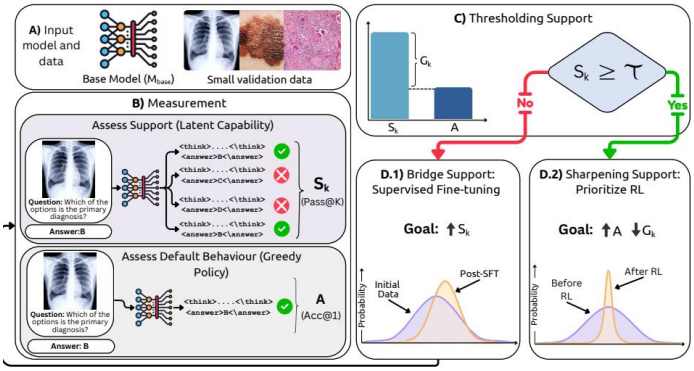

图 2：边界感知训练策略概览：先诊断支撑，再决定桥接 *vs.* *RL* 锐化。

基于上述发现，形式化三个关键量：

$$S_K(\mathcal{D}) = \text{Pass@K}(\mathcal{D}), \quad A(\mathcal{D}) = \text{Acc@1}(\mathcal{D}), \quad G_K(\mathcal{D}) = S_K - A$$

其中 S_K 衡量潜在支撑，A 衡量默认行为，G_K 为支撑间隙。**三阶段决策规则：**给定目标可靠性阈值 τ：

- **Step 1 — 诊断支撑：**在小验证集上估计 $S_K(\mathcal{D})$ 和 $A(\mathcal{D})$；
- **Step 2 — 桥接（Bridge）：**若 $S_K(\mathcal{D}) < \tau$，优先桥接——添加任务/模态邻近数据进行 SFT 或继续训练以提升 S_K（扩展覆盖而非锐化）；
- **Step 3 — 锐化（Sharpen）：**若 $S_K(\mathcal{D}) \geq \tau$，应用 RL 提升采样效率（提高 A），同时监控 S_K 和 G_K 以避免过度锐化导致支撑坍缩。

6.1 实例化：OctoMed + PMC-VQA RL

以 OctoMed-7B 为起点（大规模医学 SFT 已提供强支撑），在 PMC-VQA [30] 训练集中采样 **8,000 条**平衡多选题进行 RL 后训练。模态平衡流程：用 Qwen2.5-VL-32B-Instruct 将每个问题分类至临床成像类别（MRI/CT/超声/X-ray/显微镜/皮肤/OCT 等），不确定者标为 none，再按预测类别构建均衡子集。采用一致性感知 GRPO 变体稳定有限数据下的训练。

7. 医学 VQA 基准评估

方法	PMC	MMMU	MedX	Path	SLAKE	Rad	Avg
Qwen2.5-VL	53.0	55.3	23.5	65.0	68.0	74.0	56.5
QoQ-Med	51.0	61.2	25.0	63.5	68.5	74.0	57.2
MedVLTh.	55.0	54.1	27.5	57.5	63.5	64.0	53.6
OctoMed	55.5	56.5	35.0	63.0	84.0	79.0	62.2
MedVLM-R1	50.5	39.4	22.5	61.5	71.0	63.5	51.4
Med-R1	53.0	41.2	23.5	66.5	69.5	62.0	52.6
Ours	**59.0**	**62.9**	34.5	**65.5**	**88.0**	79.0	**64.9**

结果完全符合分析预期：从已桥接的检查点出发，RL 能有效提升准确率而不出现弱支撑基座上观察到的失败模式。关键指标：PMC 59.0（+3.5 vs. OctoMed）、MMMU 62.9（+6.4）、SLAKE 88.0（+4.0），**平均 64.91 为所有 Qwen2.5-VL 基医学 VLM 中最高**。值得注意的是，2B 规模的 MedVLM-R1 和 Med-R1 性能显著落后（平均 51–53），表明直接在弱基座上应用 RL 效果有限。

8. 与相关工作的对比

现有医学 VLM-RL 管线（MedVLM-R1 [18]、Med-R1 [11]、QoQ-Med [5]、MedVLThinker [8]）多沿用“通用 VLM → 有限 SFT → RL”模式，差异在于数据混合、奖励设计和模态覆盖，难以隔离改善来源。本文的独特之处：

- **诊断优先**：用 Acc@1 vs. Pass@K 边界视图 + 模态级感知探测，判断 RL 能否帮助，而非假设 RL 普遍有益；
- **支撑优先策略**：先用 SFT 桥接 Pass@K，再用 RL 锐化，与直接 RL 形成对比；
- **控制实验**：在 MedMNIST 上系统消解三个轴向（视觉/SFT/RL），提供因果而非相关性证据。

一般 LLM 文献中 Yue et al. [26] 发现 RL 主要重塑分布而非扩展推理边界，Zhang et al. [27] 指出后训练增益关键依赖于基座模型能力边界与训练数据的匹配。本文将此洞察**首次系统引入医学 VLM**，并通过视觉探测增加了模态感知维度。

9. 消融与关键观察

- **SFT 的桥接效应**：OctoMed SFT 在几乎所有任务上同时提升视觉探测（ViT 线性准确率）和 VLM 评估（Acc@1 与 Pass@K），Chest 除外（感知瓶颈，∼16%）；
- **RL 初始化的影响**：从 M_{SFT} 初始化的 RL 稳定优于从 M_{Base} 初始化——后者更频繁地降低 Pass@16，尤其在大偏移场景；
- **一致性感知 GRPO vs. vanilla GRPO**：在小规模医学数据上，一致性感知变体 [4,9] 有效稳定训练；
- **数据平衡的作用**：通过 32B 模型分类实现的模态平衡子集（8K 样本）避免了模态偏倚，使 RL 增益更均匀分布；
- **Pass@K 作为诊断工具**：G_K 大（高支撑低准确率）时 RL 空间最大，G_K 小时 RL 收益递减。

10. 局限性与未来方向

- **测试平台受限**：MedMNIST 分辨率低（224×224）、任务简单，无法完全代表临床级高分辨率影像（如全切片病理、3D CT）；
- **奖励设计**：仅使用可验证的多选奖励，未探索开放式报告生成、分级评分等更复杂的奖励信号；
- **模型规模**：实验限于 7B 参数，更大/更小模型的支撑边界行为可能不同；
- **单阶段 RL**：未探索迭代式桥接-锐化循环或课程式 RL 策略；
- **临床验证**：未进行真实临床场景部署验证，可靠性与透明度需进一步评估；
- 未来可将边界感知策略扩展至多模态交互推理、报告生成、以及引入人类反馈的 RLHF 管线。

11. 总结

本文通过在 MedMNIST 上系统解耦视觉、SFT 和 RL 三个维度，揭示了一个清晰的**支撑边界**：Acc@1 可远落后于 Pass@K，表明贪婪解码未能兑现的潜在能力。医学 SFT 可靠地改善感知与支撑，而 RL 主要**锐化输出分布**——在基线支撑非平凡时提升 Acc@1，在大偏移下收益有限。由此提出“**先诊断、再桥接、后锐化**”的边界感知策略，并在六个医学 VQA 基准上验证其有效性（平均 64.91，同设置下最优）。

Legal RAG Bench：面向法律 RAG 系统的端到端基准与评估方法论

Abdur-Rahman Butler, Umar Butler — Isaacus, 2026

1. 动机与问题背景

检索增强生成（RAG）已成为法律 AI 系统注入领域知识的主流范式，尤其适用于对**可溯源性**（groundedness）和**可验证性**（verifiability）要求极高的法律场景。然而，现有法律 RAG 基准存在系统性缺陷：

- **组件割裂**：多数公开基准仅评估检索或生成的单一环节，无法反映端到端管线性能；
- **标注质量低**：包括 Humanity's Last Exam (HLE) 在内的知名数据集，其法律子集存在大量标注错误、题目表述不清和答案错误（论文以 HLE #6736f7bc 为例详细论证）；
- **任务与现实脱节**：LegalBench 和 LegalBench-RAG 的绝大多数数据实为简单的是/否文本分类任务；Stanford RegLab 的 HousingQA/BarExamQA 仅使用封闭式选择题，无法暴露幻觉等真实失败模式；
- **缺乏法律专家参与**：如 AILA Casedocs/Statutes 使用自动化方法配对判决事实与引用案例，忽视了法律引用的实际语义（以 *Donoghue v Stevenson* 为例说明案例事实与引用语境的巨大鸿沟）；
- **缺乏交互效应检验**：几乎无评估报告嵌入模型与 LLM 之间的交互效应，导致外部效度存疑。

Legal RAG Bench 旨在从数据集和评估方法论两个维度同时解决上述问题，首次对法律 RAG 管线进行**全因子实验设计**（full factorial design），结合新颖的**层级错误分解框架**量化检索与生成各自的贡献。

2. 数据集构建

Legal RAG Bench 的数据源为维多利亚州司法学院的《刑事指控手册》(Victorian Criminal Charge Book)，这是维州刑事律师日常工作的核心参考文献。数据集构建流程：

- **语料处理**：下载手册各章节的 Word 文档，转换为 Markdown 格式；利用复杂启发式规则解析完整层级结构（章、节、小节）；对超长段落使用 semchunk 语义分块算法，确保每块不超过 512 tokens（由 Kanon 法律分词器确定），最终生成 **4,876 个段落**；
- **问题设计**：随机采样段落后，由法律和 AI 双重领域专家手工撰写 **100 个复杂问题**，要求专家级维州刑法与程序知识才能正确回答；问题被刻意设计为与相关段落**词汇高度不相似**，以压力测试模型的语义理解能力；
- **答案与证据**：每个问题配有专家撰写的**长文本答案**和**支撑段落**，形成 *question–answer–evidence* 三元组，支持检索与生成的联合评估与独立评估。

设计原则：法律与 AI 领域专家全程参与每个阶段——从选择刑法这一资源匮乏但极端重要的领域，到构建真实律师场景下的假设问题。这是首个评估法律 RAG 系统**实际法律建议能力**的评估集。

3. 评估方法论

3.1 全因子实验设计

评估覆盖 3 个嵌入模型 × 2 个 LLM = 6 种组合的全因子网格：

嵌入模型：Isaacus Kanon 2 Embedder、Google Gemini Embedding 001、OpenAI Text Embedding 3 Large

生成模型：Gemini 3.1 Pro、GPT-5.2

所有组合使用相同的裸 Langchain RAG 管线，超参数均取默认值，最大限度控制混淆变量。采用 GPT-5.2 高推理模式作为 judge（内部评估准确率 99%），配合清晰评分标准和二元判定。

3.2 三维评估指标

对每个问题 i、嵌入模型 e、LLM l，评估：

- **正确性** c_{eli}：模型答案是否蕴含参考答案（1/0）；
- **可溯源性** g_{eli}：答案是否被检索到的段落所支持，无论段落本身是否相关（1/0）；
- **检索准确率** r_{ei}：标注的支撑段落是否被嵌入模型检索到（1/0）。

核心洞察：法律研究本质上是证据驱动的——结论的可验证性往往比正确性更重要。不真实但可验证的结论总能被证伪，但真实却不可验证的结论永远无法被证实。因此，必须检测"产生正确答案的幻觉"这类隐蔽失败模式。

3.3 层级错误分解框架

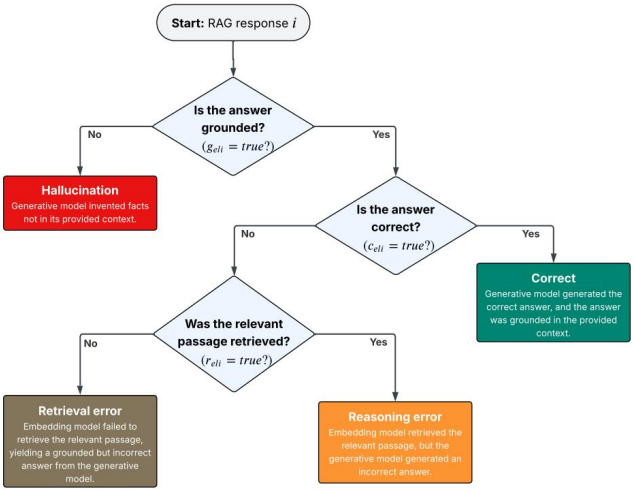

图 *1*：层级 *RAG* 错误分解分类法流程图。幻觉 → 检索错误 → 推理错误。

论文提出新颖的层级错误分类法，将错误严格分为三类：

- **幻觉**（Hallucination）：$g_{eli} = 0$，生成模型编造了上下文中不存在的事实；
- **检索错误**（Retrieval Error）：$g_{eli} = 1 \wedge c_{eli} = 0 \wedge r_{ei} = 0$，答案有据可循但不正确，且嵌入模型未检索到相关段落；
- **推理错误**（Reasoning Error）：$g_{eli} = 1 \wedge c_{eli} = 0 \wedge r_{ei} = 1$，相关段落已被检索到，但生成模型仍给出错误答案。

设计要点：幻觉被置于分类层级的**最高优先级**——即使答案恰好正确，只要不可溯源即视为幻觉。检索错误仅在答案不正确时才被计入，因为如果答案正确且有据可循，则检索到的上下文很可能已包含相关信息（即使不是标注的特定段落）。

4. 核心实验结果

4.1 各维度评分

LLM	嵌入模型	正确	溯源	检索
3*Gemini 3.1 Pro	Kanon 2 Emb.	95.0	95.0	86.0
	Text Emb. 3L	77.0	96.0	52.0
	Gem. Emb. 001	75.0	92.0	53.0
3*GPT-5.2	Kanon 2 Emb.	93.0	97.0	86.0
	Text Emb. 3L	76.0	87.0	52.0
	Gem. Emb. 001	73.0	82.0	53.0

模型级平均分（嵌入模型跨 LLM 平均，LLM 跨嵌入模型平均）：

模型	正确%	溯源%	检索%
Kanon 2 Embedder	94.0	96.0	86.0
Text Embedding 3L	76.5	91.5	52.0
Gemini Emb. 001	74.0	87.0	53.0
Gemini 3.1 Pro	82.3	94.3	63.7
GPT-5.2	80.7	88.7	63.7

核心发现：嵌入模型而非 LLM 主导法律 RAG 性能。Kanon 2 Embedder 比最佳 LLM（Gemini 3.1 Pro）高出 11.7 点正确性、1.7 点溯源性和 22.3 点检索准确率。从 Kanon 2 切换至 Text Embedding 3 Large，正确性下降 17.5 点、溯源性下降 4.5 点、检索准确率下降 34 点。LLM 选择的影响相对温和：Gemini 3.1 Pro 平均高 GPT-5.2 仅 1.6 点正确性和 5.6 点溯源性。

4.2 错误分解分析

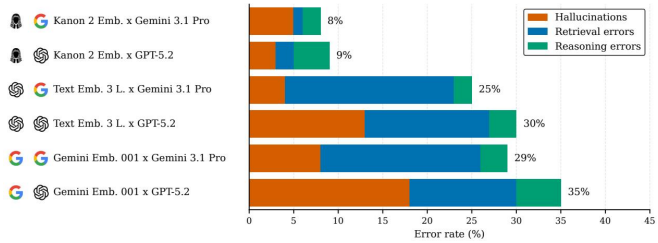

图 2：各嵌入模型 $\times LLM$ 组合的分解错误率（幻觉/检索错误/推理错误）。

检索质量与幻觉高度相关：相对于 Text Embedding 3 Large，Gemini Embedding 001 的幻觉率平均增加 4.5 个百分点；Kanon 2 Embedder 的幻觉率平均降低 6.75 个百分点。推断：生成模型能够感知检索段落的相关性，相关段落越多则越少编造事实。

LLM 对幻觉率有中等影响：Gemini 3.1 Pro 平均幻觉率 5.7%，GPT-5.2 为 11.3%。值得注意的是，Kanon 2 Embedder 下推理错误占比更高——这是因为上游检索错误的大幅减少将失败转移到了生成层，即劣质生成模型反而成为高质量检索模型的瓶颈。

RAG 准确率（定义为所有错误之和的补集）：Kanon 2 Embedder 相对样本均值高出 **+18%**，而 GPT-5.2 和 Gemini 3.1 Pro 分别为 −3% 和 +3%，进一步确认嵌入模型是 RAG 性能的首要驱动力。

5. 统计显著性与交互效应

为量化主效应并检验交互效应，拟合线性概率模型：

$$y_{eli} = \alpha_i + \beta_e + \gamma_l + \delta_{el} + \varepsilon_{eli}$$

其中 α_i 为问题固定效应，β_e、γ_l 分别为嵌入模型和 LLM 指示变量，δ_{el} 捕获交互效应。使用 OLS 估计，报告按问题聚类的稳健标准误。

ANOVA 式 Wald 检验（表 3 核心结果）：

效应	正确	溯源	两者
交互	$p=0.962$	$p=0.017^{*}$	$p=0.479$
LLM 主效应	$p=0.499$	$p=0.021^{*}$	$p=0.119$
嵌入主效应	$p<0.001^{***}$	$p=0.011^{*}$	$p<0.001^{***}$

关键结论：（1）嵌入模型主效应在所有三个维度上均统计显著（$p<0.05$）；（2）LLM 主效应仅在溯源性上显著，在正确性和联合指标上**不显著**；（3）交互效应仅在溯源性上显著。

5.1 溯源性交互效应解析

从 Gemini 3.1 Pro 切换至 GPT-5.2 的简单效应：搭配 Text Emb. 3L 时溯源性下降 9.0 点（$p=0.031$），搭配 Gem. Emb. 001 下降 10.0 点（$p=0.038$），但搭配 Kanon 2 Embedder 时**无统计可检测变化**（+2.0，$p=0.459$）。差异中的差异分析表明异质性由 Kanon 2 驱动：其 LLM 切换效应比 Text Emb. 3L 正 11 点（$p=0.033$），比 Gem. Emb. 001 正 12 点（$p=0.017$）。这表明 GPT-5.2 在接收到不相关上下文时更容易产生幻觉，但高质量检索可以消除这一差异。

实践意义：对于正确性，嵌入模型和 LLM 的性能增益**线性可加**——选择最佳嵌入模型和最佳 LLM 的组合可在分布相似语料上获得可预测的改进。

6. 相关工作批判

论文系统性梳理了现有法律 AI 评估的不足：

- **MLEB**（2025）：迄今最全面的法律检索基准，本文作者此前工作；
- **MTEB 法律子集**：含有严重缺陷的 AILA 数据集，自动化方法导致检索任务本身不可能或无实际价值；
- **HLE**（Nature 2026, $500K+）：法律子集多数示例存在标注错误、题目不当或缺乏管辖区信息；
- **LegalBench / LegalBench-RAG**：实质为简单文本分类任务，无法测试真实推理与检索能力；
- **HousingQA / BarExamQA**：仅用封闭式选择题，无法暴露幻觉和溯源性问题。

7. 讨论与局限

核心贡献总结：

- 首个端到端法律 RAG 全因子基准，融合 4,876 段落 + 100 专家问题 + 长文本答案 + 支撑证据；
- 提出层级错误分解框架，将 RAG 错误系统分类为幻觉、检索错误和推理错误；
- 首次在法律 RAG 评估中报告交互效应检验，揭示溯源性中嵌入模型–LLM 交互的存在；
- 结论性证据：**检索质量设定了法律 RAG 系统性能的天花板**——许多归因于幻觉的错误实为检索失败所触发。

局限与未来方向：

- 数据集限于维州刑法单一司法管辖区和领域，泛化性有待验证；
- 100 个问题的规模虽经精心设计，但统计检验力仍受限；
- 全因子设计中仅包含 3 个嵌入模型和 2 个 LLM，扩展至更多模型可提升外部效度；
- 评估流程依赖 GPT-5.2 作为 judge（99% 准确率），仍存在 1% 误差风险；
- 未评估 reranking、query expansion 等高级 RAG 技术的影响。

利益披露：Isaacus（作者创立的法律 AI 公司）开发了 Kanon 2 Embedder 并资助了 Legal RAG Bench 和 MLEB 的创建。数据、代码和结果均已开源发布。

T^{3}RL：面向测试时强化学习的工具验证

Liao*, Röhrich*, Wang, Zhang, Samadzadeh, Tresp, Yeung-Levy — LMU Munich & Stanford, 2025

1. 动机与问题背景

测试时强化学习（TTRL）是一种新兴的**无标签自进化**范式：大型推理模型（LRM）在未标注测试数据上通过多次采样生成候选解，以**多数投票**作为伪标签构造奖励信号，再经 RL 更新参数实现在线自适应。TTRL 无需人工标注，契合 DeepSeek-R1 等模型的自进化趋势。

然而，基于自一致性的伪标签存在根本性缺陷——**虚假流行模式坍缩**（false-popular mode collapse）：当模型内部推理存在系统性偏差时，多数投票可能选中高频但错误的答案作为伪标签，对错误 rollout 赋予正奖励。更严重的是，这形成**自我强化的恶性循环**：错误伪标签 → 正奖励强化错误 rollout → 错误答案概率进一步升高 → 伪标签更加偏向错误，最终导致不可逆的模式坍缩。

核心洞察：人类在内省不可靠时会寻求**外部证据**来过滤错误假设。类似地，自一致性闭环需要外部验证机制来打破。T^{3}RL 将**工具验证**（Tool Verification）引入测试时 RL 的奖励估计，用代码执行器提供的确定性证据替代纯粹的频率共识，实现基于证据的稳健自进化。

2. TTRL 形式化与失败模式分析

2.1 TTRL 框架

给定提示 x，策略 $\pi_\theta(y|x)$ 采样 N 个 rollout $\{y_1, \ldots, y_N\}$，通过多数投票得到共识标签 y^*，二值奖励 $r(y, y^*) = \mathbb{1}[y = y^*]$，RL 目标为：

$$\max_\theta \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}[r(y, y^*)], \quad \theta \leftarrow \theta + \eta\nabla_\theta\mathbb{E}[r(y, y^*)]$$

2.2 虚假多数与自强化坍缩

设正确答案为 $y^\star$，错误高频答案为 $\tilde{y}$。若 $\tilde{y}$ 的采样概率超过 $y^\star$，多数投票选中 $\tilde{y}$ 为伪标签，对一致于 $\tilde{y}$ 的 rollout 赋正奖励、对正确 rollout 赋零奖励。RL 更新进一步提升 $\tilde{y}$ 的采样概率，形成不可逆的正反馈循环。此现象在长推理链（如竞赛数学）中尤为严重——中间计算错误逐步累积，导致最终答案系统性偏移。

3. 方法：T^{3}RL

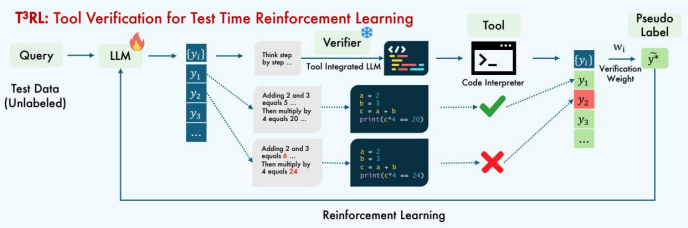

图 1：T^3RL 架构。验证器将 *rollout* 转为 *Python* 代码，代码解释器执行后返回证据，验证感知投票生成更可靠的伪标签。

T^{3}RL 包含三个核心组件，协同实现**验证感知的奖励估计**：

3.1 验证器（Verifier）

验证器 ν 是一个外部 LLM（与策略模型独立），对每个 rollout y_i 执行三步操作：(1) 提取候选最终答案 $\hat{a}_i = \text{Extract}(y_i)$；(2) 将 rollout 的推理过程转化为轻量级 Python 程序（工具调用查询）；(3) 根据代码执行结果判断有效性，返回二元组 $(a_i, v_i) = \mathcal{V}(x, y_i)$，其中 a_i 为验证器导出的答案，$v_i \in \{0, 1\}$ 为验证通过标志。

关键设计：验证器系统提示明确要求“不要假设推理轨迹正确”、“优先从问题陈述直接重新计算答案”，推理轨迹仅作为“提示”使用，从而缓解确认偏差，避免验证器盲目翻译错误推理为代码。

3.2 验证工具（Verification Tool）

验证工具 τ 为代码解释器，执行验证器生成的 Python 程序并返回确定性结果：

$$a_i = T(\text{Code}(x, y_i))$$

验证器对比工具结果 a_i 与 rollout 提取答案 $\hat{a}_i$，产生验证有效性标志：$v_i = \mathbb{1}[a_i = \hat{a}_i]$。代码执行提供**外部、确定性、可执行的证据**，将验证从 LLM 的概率判断转移到工具的精确计算。

3.3 验证权重（Verification Weight）

标准 TTRL 中所有 rollout 等权投票。T^{3}RL 引入超参数 $\omega \geq 1$，对通过验证的 rollout 赋予更高投票权重：

$$w_i = (1 - v_i) \cdot 1 + v_i \cdot \omega$$

未验证 rollout 保留单位票权，已验证 rollout 贡献 ω 票。验证感知共识标签为：

$$\tilde{y}^* = \arg\max_{a\in\mathcal{A}} \sum_{i=1}^{N} w_i \cdot \mathbb{1}[a_i = a]$$

最终奖励仍为二值：$r_i^v = \mathbb{1}[a_i = \tilde{y}^*]$，训练目标形式不变：

$$\max_\theta \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}[r^v(x, y)], \quad \theta \leftarrow \theta + \eta\nabla_\theta\mathbb{E}[r^v(x, y)]$$

该机制将共识从**最频繁**答案转向**已验证**答案，前提是验证组累积权重足够大。

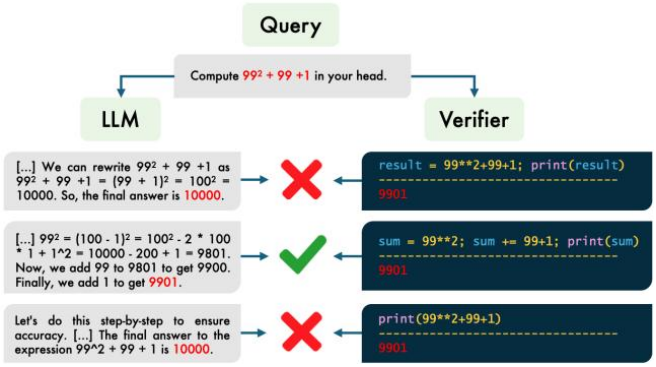

图 2：成功案例。工具验证纠正了多数投票选中的错误答案，代码执行发现计算错误后调整伪标签。

4. 实验设置

基准：MATH-500（易）、AMC（中）、AIME 2024（难），覆盖不同难度的数学推理。

模型：跨家族、跨类型验证——(1) 数学专用：Qwen-2.5-Math-1.5B；(2) 通用：Qwen-2.5-1.5B、Qwen-3-4B；(3) 指令微调：Llama-3.2-1B-Instruct、Llama-3-3B-Instruct。

实现：基于 GRPO 算法，AdamW + 余弦调度（峰值学习率 5×10^{-7}）。采用 vote-then-sample 策略：64 个响应用于标签估计（温度 0.6），下采样 32 个用于训练。最大 token 长度 2560，验证器限制 1024 tokens。训练于 8×A100 GPU，按数据集大小设不同 episode 数（MATH-500: 10, AMC: 30, AIME: 80）。评估遵循 DeepSeek-R1 协议：4 次评估取均值，报告 pass@1。

5. 核心实验结果

5.1 主要性能

模型/方法	AIME	AMC	MATH	Avg
Qwen-Math-1.5B	7.7	28.6	32.7	23.0
w/ TTRL	15.8	48.9	73.0	45.9
w/ T^{3}RL	**20.8**	**50.9**	**74.6**	**48.8**
Qwen-2.5-1.5B	0.2	0.6	7.7	2.8
w/ TTRL	3.5	28.6	63.2	31.8
w/ T^{3}RL	**4.1**	**30.7**	**65.0**	**33.3**
Qwen-3-4B	0.0	12.5	50.4	21.0
w/ TTRL	36.4	71.7	88.4	65.5
w/ T^{3}RL	**40.0**	**74.2**	**89.5**	**68.1**
Llama-3.2-1B-Inst	0.8	4.2	4.4	3.1
w/ TTRL	7.5	16.9	40.0	21.5
w/ T^{3}RL	**8.3**	**19.9**	**42.2**	**23.5**
Llama-3-3B-Inst	6.0	19.4	43.9	23.1
w/ TTRL	13.3	31.3	61.6	35.4
w/ T^{3}RL	**17.1**	**34.2**	**63.3**	**38.2**

一致性提升：T^{3}RL 在所有模型和所有基准上均优于 TTRL。跨模型平均提升：MATH-500 +3.5%，AMC +9.7%，AIME +19.8%，总体 +11.0%。

难题收益更大：Qwen-Math-1.5B 在最难的 AIME 上相对提升高达 +31.6%（15.8 → 20.8），而较易的 MATH-500 仅 +2.2%。MATH-500 按难度分级（L1–L5），T^{3}RL 相对 TTRL 的提升从 L1 的 +0.2% 单调增至 L5 的 +4.3%。原因：难题需更长计算链，rollout 累积误差更多，工具的确定性检查在此场景下价值最大。

数学专用模型收益更大：Qwen-Math-1.5B 相对提升 +6.3% vs. Qwen-2.5-1.5B 的 +4.7%，因为数学专用模型生成的推理轨迹包含更多可被工具检测的计算步骤。

跨模型家族泛化：Qwen 和 Llama 家族、base/instruct/math 三种对齐方式均获一致提升，表明工具验证的收益不依赖特定预训练配方。

6. 消融实验

6.1 验证器的贡献

对比 (i) 原始 TTRL 与 (ii) T^{3}RL 去除代码执行（仅用同等规模 LLM 自验证）：即使无工具执行，引入自验证已在 AIME 和 MATH 上带来改善（1.5B/7B 验证器均有效），证明测试时验证本身即可改进奖励估计。

6.2 工具执行的贡献

对比有/无代码执行的验证：工具执行在验证器基础上提供显著额外提升——1.5B 验证器 AIME 从 18.3→20.8，7B 验证器 AIME 从 20.0→21.7。可执行证据减少了验证器的不确定性，使验证信号更可靠。

6.3 验证权重 ω 的选择

扫描 $\omega \in \{1, 2, 5, 10, \infty\}$：$\omega$=1 退化为标准 TTRL，$\omega \to \infty$ 近似硬过滤。最优为 ω=5（AIME 20.8, MATH 74.6）。过低权重不足以抑制虚假流行答案；过高权重将学习坍缩至少量已验证 rollout 子集，对验证器/工具的不完美变得脆弱，减少学习信号多样性。验证应作为**软偏好信号**而非硬过滤。

7. 深入分析

7.1 工具位置：验证 vs. 策略内调用

对比三种设置：(i) TTRL；(ii) TTRL-AGENT（策略在生成 rollout 时直接调用工具）；(iii) T^{3}RL（策略不调用工具，验证器事后使用工具）。TTRL-AGENT 性能下降，而 T^{3}RL 持续提升。原因：策略内工具调用混淆了推理错误与工具使用错误（如代码生成格式错误、脆弱执行制品），自一致性奖励在更大动作空间中放大噪声。T^{3}RL 将推理与工具执行**解耦**：验证器在生成后提供证据并转化为验证感知奖励，使 rollout 成为即时验证的标注训练数据——本质上是**在线验证数据合成器**。

7.2 训练鲁棒性

多次运行对比：TTRL 表现出显著的运行间变异性，T^{3}RL 峰值性能标准差从 2.638 降至 1.890，方差从 6.959 降至 3.572。工具验证锚定了奖励构造，产生更一致的学习动态。

7.3 测试时计算分配

T^{3}RL 仅用 N=16 个 rollout 即超越 TTRL@64，N=32 时已匹配 T^{3}RL@64 的 AIME 性能。验证提升了每个 rollout 的质量，使系统以更少计算达到更高准确率——验证比暴力扩大采样量更高效。

7.4 更强验证器的收益

验证器从 1.5B 扩至 7B：AIME 20.8 → 21.7，AMC 50.9 → 51.5，MATH 74.4 → 74.9。更大验证器提供更可靠的答案归一化和置信估计，强化验证感知投票和奖励信号。

8. 失败模式分析

弱验证器注入噪声：当验证器过小（如 Qwen-0.5B，编码能力不足），工具调用变得嘈杂，验证感知投票可能误加权 rollout。实验证实 0.5B 验证器使所有基准下降（AIME −100%, AMC −10%, MATH −7.5%）。定性分析揭示两类失败：(1) **盲目复制**——忽略 “不要假设推理正确” 的指令，在代码注释中幻觉推理后直接 `print` 推理轨迹的最终答案，形成确认偏差；(2) **格式/编译错误**——无法生成有效 Python 语法，产生编译失败而非可靠验证。这表明 T^{3}RL 需要验证器具备**最低能力阈值**。

简单任务收益有限：当任务足够简单、rollout 已高度准确一致时，自一致性很少选错标签，验证仅增加开销而不实质改变伪标签分布。

9. 相关工作对比

T^{3}RL 首次将**测试时验证**引入**测试时训练**：(1) 区别于 TIR（工具集成推理，如 ToRA）——后者在推理时使用工具，T^{3}RL 在奖励估计中使用工具；(2) 区别于 ToolVerifier 等工具验证工作——后者仅在推理时选择最优输出，T^{3}RL 将验证结果转化为训练信号驱动参数更新；(3) 区别于 TTRL——后者完全依赖自一致性，T^{3}RL 引入外部证据打破闭环。

10. 结论与展望

T^{3}RL 将测试时 RL 定位为**验证式在线数据合成**：采样 rollout 经工具验证后成为可靠训练实例，实现更稳健的自进化。三个组件（验证器、验证工具、验证权重）各自贡献显著且互补，跨模型家族和难度梯度一致有效。

局限与未来方向：(1) 当前验证工具限于代码解释器/数学场景，扩展至物理模拟、符号求解器、搜索引擎等多模态验证工具是重要方向；(2) 验证器质量直接影响系统性能，需探索更强的验证器或多验证器集成；(3) 验证权重 ω 为固定超参数，自适应调整策略待研究；(4) 超越数学推理，向代码生成、科学推理等需可验证奖励的领域推广。