QZPaper Huggingface Daily

2026-03-04

1. **Utonia：迈向统一所有点云的单一编码器**
   Utonia 提出单一 Point Transformer 编码器处理跨域点云，通过粒度对齐、重力先验消除和因果模态遮蔽三个改进，在 250k 点云和 1M CAD 资产上联合预训练，产出统一表征空间并展现跨域涌现行为。
2. **UniG2U-Bench：统一多模态模型是否真正提升了视觉理解?**
   UniG2U-Bench 系统量化统一多模态模型中生成对理解的协同效应，形式化定义 G2U 增益并分类三种模型架构，提供 3000 实例、7 大类、30 子任务的全面评测基准，首次定量评估生成能力的辅助作用。
3. **Beyond Language Modeling：多模态预训练的系统性探索**
   Beyond Language Modeling 在 Transfusion 框架下系统探索多模态预训练设计空间，隔离五个关键轴（视觉表示、数据、世界建模、架构、缩放律），发现 RAE 提供统一表示、MoE 调和视觉语言缩放不对称性等四项核心发现。
4. **BeyondSWE：当前代码智能体能否超越单仓库缺陷修复?**
   BeyondSWE 沿解决范围与知识范围两维度扩展代码智能体评测，涵盖跨仓库、领域专业、依赖迁移、规格构建四类任务，提供 500 实例、246 仓库的真实评测，首次全面评估智能体的全局问题解决能力。
5. **Qwen3-Coder-Next：面向编码智能体的高效开源语言模型**
   Qwen3-Coder-Next 基于 Qwen3-Next 的 MoE 架构设计 80B 参数、3B 活跃的高效编码模型，采用分阶段训练和 807k 可验证任务，在 SWE-Bench 等基准上达到与大一个数量级模型相当的性能，证实扩展智能体训练的关键作用。
6. **Beyond Length Scaling：协同广度与深度的生成式奖励模型**
   Beyond Length Scaling 针对长度扩展无法保证性能的问题，提出 Mix-GRM 框架合成广度思维链与深度思维链，将推理机制与任务特征对齐，协同推理的广度与深度以优化生成式奖励模型的偏好判断能力。
7. **Kling-MotionControl：面向鲁棒、精确与表现力丰富的全身角色动画**
   Kling-MotionControl 采用统一 DiT 框架处理全身动画，设计异构运动表示捕获身体、面部、手部不同粒度特征，并引入自适应跨身份迁移实现从人类到卡通动物的泛化，突破鲁棒性与精细性的矛盾。
8. **SteerEval：跨行为粒度的大语言模型可控性统一评估**
   SteerEval 受 Marr 三层分析启发，沿三域（人格、情感、语言）× 三层级（表达什么/如何表达/如何实例化）组织 LLM 可控性评测，建立系统化基准量化行为控制在不同粒度和深度的可控性差异。
9. **Kiwi-Edit：基于指令与参考图像引导的多功能视频编辑**
   Kiwi-Edit 构建首个大规模开源参考引导视频编辑数据集 RefVIE（477k 样本），提出 MLLM-DiT 统一架构通过多阶段训练课程，同时支持指令编辑和参考引导任务，在两类任务上达到 SOTA 性能。
10. **PRISM：基于过程奖励模型引导的 DeepThink 推理前沿**
    PRISM 利用过程奖励模型的步骤级验证信号克服 DeepThink 的种群增强瓶颈，通过 MCMC 式分数引导精炼突破多数稀释效应，有效提升推理时扩展在深度思考任务上的收益。

Utonia：迈向统一所有点云的单一编码器

Zhang, Wu†, Yang, Fan, Li, Zhang, Huang, Wang, Zhao‡ — HKU, CUHK, Xiaomi, 2026

1. 动机与问题背景

稀疏点云是三维物理世界的几何显式压缩表示，广泛应用于自动驾驶、AR/VR 和机器人。然而，与生活在标准密集网格上的图像不同，点云跨域差异极端：室外 LiDAR 稀疏、范围大、具有扫描线模式且通常无颜色/法线；室内 RGB-D 密集且含丰富辅助通道；物体级 CAD 模型尺度归一化且方向任意。现有点云自监督学习（SSL）方法——Sonata 和 Concerto——均在**单一域内**训练，跨域迁移能力差。例如，以玩具车前脸特征在室外 LiDAR 中检索时，Concerto 无法匹配到真实车辆对应区域，而 Utonia 可以。

Utonia 的目标是训练**单一自监督 Point Transformer 编码器**，联合覆盖遥感、室外 LiDAR、室内 RGB-D 序列、物体 CAD 模型及从纯 RGB 视频提升的点云五大域，在约 **250k 跨域点云 + 1M CAD 资产**上预训练，产出统一表征空间并展现跨域涌现行为。

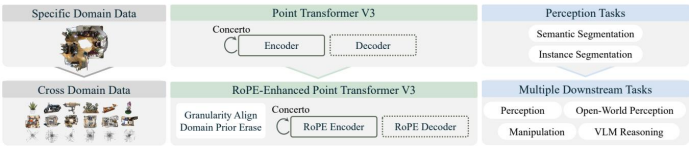

图 1：*Utonia* 概览。三大改进：跨域联合训练数据、*RoPE* 增强的 *PTv3* 编码器（含粒度对齐与域先验消除）、以及感知/推理/操控的广泛评估。

2. 先导研究：联合训练的三大障碍

朴素地合并所有数据集联合训练会导致性能显著下降且不稳定。先导实验揭示三个核心失配：

2.1 粒度敏感性

稀疏点云处理中，**网格大小**定义局部邻域的度量单位——同一架构算子在不同域中可对应厘米到米的不同尺度。使用各域原始网格或抖动网格联合训练时，ScanNet200 mIoU 从分域训练的 34.4 降至 29.1/29.6，Waymo 从 60.5 降至 43.9/42.6。**统一网格 + 坐标重缩放**可恢复至 33.5/56.6，大幅稳定联合训练。

2.2 重力先验偏置

场景级点云遵循重力对齐约定（z 轴向上），高度成为物理参考。但高度同时成为域线索——Sonata/Concerto 特征呈现强 z 相关模式，迁移至物体级扫描时退化。需将重力对齐视为**粒度依赖的先验**：场景保留直立结构，物体鼓励旋转不变。

2.3 模态可用性不一致

不同域暴露不同辅助通道（颜色/法线）。朴素联合训练中编码器倾向利用最丰富通道，但模态统计量成为域识别线索。当模态缺失时性能急剧下降：Concerto 去颜色后 ScanNet mIoU 从 77.3 降至 36.8（线性探测），而 Utonia 仅从 77.7 降至 77.0。

3. 方法论

Utonia 基于 **Point Transformer V3**（PTv3）编码器，遵循 Sonata/Concerto 的师生自蒸馏预训练框架，通过三个简洁的域无关设计解决上述失配。

3.1 因果模态遮蔽（Causal Modality Blinding）

定义统一模态接口：拼接坐标 + 颜色 + 法线，缺失模态用零填充。在此基础上施加**两级遮蔽干预**：(1) **逐样本遮蔽**——随机丢弃整个模态组；(2) **逐点遮蔽**——在单个点级别进一步掩码。类比人在训练中刻意蒙眼——模型在缺失模态时仍能工作，有模态时则充分利用。消融实验（Tab. 7d）显示在数据加载时遮蔽效果最强：不遮蔽时去颜色 ScanNet200 从 34.7 崩溃至 9.3；加载时遮蔽则为 34.9→31.7。仅在掩码视图遮蔽最弱（34.1→10.1），因掩码视图本身信息受限，去除模态会过度破坏输入。

3.2 感知粒度重缩放（Perceptual Granularity Rescale）

受观察者以固定最小角分辨率运作的直觉启发，将各域点云重缩放至**共享感知粒度**后再做位置编码。这将差异极大的空间范围映射到可比坐标空间。关键设计：**粒度依赖的增强策略**——场景级数据仅 ±10% 缩放抖动 + 全偏航（z 轴 $[-\pi,\pi]$）+ 温和俯仰滚转（x/y 轴 $[-\pi/64,\pi/64]$）；物体级数据使用 ±50% 缩放 + 完整 SO(3) 旋转。教师和学生视图使用非对称缩放/旋转/平移，在自监督学习中强制跨视图特征一致性。

3.3 RoPE 桥接粒度对齐坐标

重缩放对齐基本空间单位后，需指定相对几何如何调制 token 交互。稀疏卷积通过离散化编码位置，耦合于邻域构造和密度不均匀性。Utonia 采用 **3D RoPE**——将特征向量分为三段 $\mathbf{u} = [\mathbf{u}^x; \mathbf{u}^y; \mathbf{u}^z]$，分别沿各轴施加 1D RoPE：

$$\mathrm{RoPE}_{3\mathrm{D}}(\mathbf{u}, \hat{\mathbf{p}}_i^{rj}) = [\mathrm{RoPE}(\mathbf{u}^x, \hat{x}_i^{rj}); \mathrm{RoPE}(\mathbf{u}^y, \hat{y}_i^{rj}); \mathrm{RoPE}(\mathbf{u}^z, \hat{z}_i^{rj})]$$

其中 $\hat{\mathbf{p}}_i^{rj}$ 为经各向异性抖动（$\mathbf{j} = \exp(\epsilon_j), \epsilon_j \sim \mathcal{U}(-\log\gamma, \log\gamma)^3$）和各向同性缩放（$r = \exp(\epsilon_s)$）增强后的坐标。RoPE 为无参数位置编码，直接作用于注意力查询和键，天然支持不同密度的可扩展点集。它不改变邻域构造，但鼓励注意力依赖连续相对几何而非记忆域特有坐标约定。消融（Tab. 7b）：多域设置下 RoPE 在 ScanNet200/Waymo/PartNetE 分别提升 +1.4/+2.6/+1.1；基底 B 对性能不敏感（$B \in \{1, 10, 100, 1000\}$），默认 B=10。

3.4 训练细节

采用**两阶段预训练**：阶段 1 在高质量子集（ScanNet、Structured3D、Waymo、PartNet）获得稳定初始化；阶段 2 在全混合数据上继续训练 100 epochs。批大小 256，64 张 NVIDIA H20 GPU。模型通道需被 6 整除（RoPE 要求）。消融模型 38M（通道 36/72/144/252/504，深度 2/2/2/6/2），主模型 137M（通道 54/108/216/432/576，深度 3/3/3/12/3）。

4. 核心实验结果

4.1 室内语义分割

在 ScanNet/ScanNet200/ScanNet++/S3DIS 四个基准上评估（Tab. 3）。全微调下 Utonia 达 SOTA：ScanNet **81.1%** mIoU（Concerto 80.7），S3DIS **78.1%**（Concerto 77.4）。解码器探测下与 Concerto 持平（ScanNet 80.3 vs 79.5）。线性探测在细粒度 ScanNet200 略低于 Concerto（36.4 vs 37.4），但解码器探测几乎持平（38.0 vs 37.8），表明 Utonia 受益于非线性空间头。

4.2 室外语义分割

在 NuScenes/Waymo/SemanticKITTI 上评估（Tab. 4）。线性/解码器/全微调三种设置下 Utonia 均为最优或持平。全微调：NuScenes **82.2%**（Concerto 82.0），SemanticKITTI **72.0%**（Concerto 71.2），Waymo **71.4%**（Concerto 69.2）。

4.3 物体分类与部件分割

Tab. 5 评估 ModelNet40、ScanObjectNN、ShapeNetPart、PartNetE。全微调下 Utonia 在 ScanObjectNN PB-T50-RS 达 **89.9%** allAcc（Concerto 88.1），PartNetE **62.7%** mIoU（Concerto 60.8），ShapeNetPart i.mIoU **86.3%**（Concerto 86.1）。线性探测在部件分割上偏低但分类上持平，表明预训练表征捕获物体级语义良好，细粒度部件理解需端到端适配。

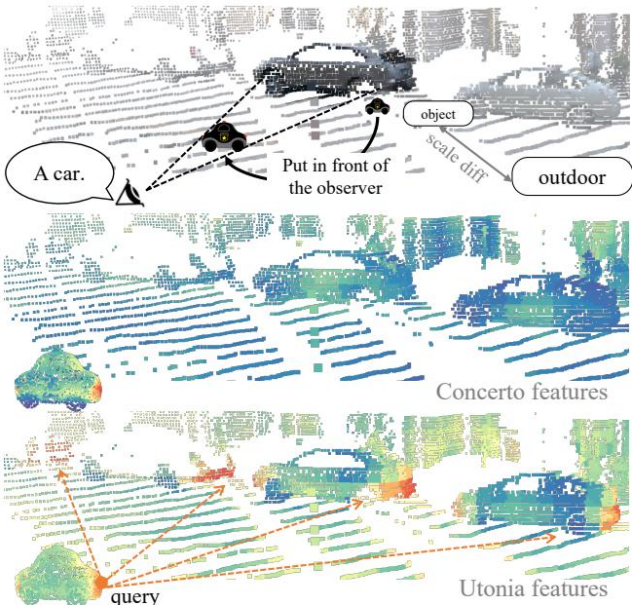

图 2：跨域语义相似性。查询物体 *CAD* 中的玩具车前脸，在室外 *LiDAR* 中检索：*Utonia* 准确匹配真实车辆，*Concerto* 失败。

4.4 模态缺失鲁棒性

Tab. 6 验证去颜色/去法线场景。Concerto 线性探测去颜色后 ScanNet 从 77.3→36.8，NuScenes 从 74.2→42.7；Utonia 仅从 77.7→77.0 和 75.5→74.5，展现**极强鲁棒性**。全微调下 Utonia 去颜色 NuScenes 达 **81.1%**（Concerto 74.7），去法线达 **82.1%**（Concerto 77.1）。去法线通常影响更小，因大尺度法线常含噪且粗糙方向可由局部几何推断。

5. 消融实验

默认消融在 ScanNet/Structured3D/PartNet/Waymo 上用 38M PTv3 训练。

物体增强强度。缩放增强从 ±50% 降至场景级 ±10% 后 PartNetE 从 44.6→43.0，ScanObjectNN(H) 从 66.9→64.5；旋转增强从 SO(3) 降至温和场景级后 ScanObjectNN(H) 从 66.9→63.0。

RoPE 跨域效应。单域训练时 RoPE 对 ScanNet200 略降（−0.4）、对 PartNetE 降（−1.7），但在**多域训练**中全面提升（+1.4/+2.6/+1.1）。这表明 RoPE 的连续相对几何位置线索在跨域密度/尺度变化下尤为关键。Waymo 即使单域也受益（+1.6），因室外 LiDAR 单帧内密度极不均匀。

帧增强。对动态数据用姿态对齐多帧聚合构造教师全局视图、单帧作学生局部视图。去除后 Waymo 从 59.2→58.8，PartNetE 从 44.6→40.0。

规模扩展。38M→137M（同 83k 数据）：ScanNet200 线性 34.9→36.0，Waymo 59.2→62.6，PartNetE 45.6→44.6；进一步扩至全数据（250k+1M）：ScanNet200 继续提升至 36.4，Waymo 至 63.8。PartNetE 全微调从 55.7→62.7 大幅提升，但线性探测下降（45.6→39.8），表明更大更嘈杂的混合偏好可迁移的物体级语义，细粒度部件线索需任务适配恢复。

6. 下游应用

机器人操控。在模拟桌面抓取任务中（RGB-D 单目，290 类 10,680 物体），Utonia 测试成功率 **82.1%**（Concerto 80.0，Sonata 74.7）。Utonia 特征在杂乱场景中保持连贯——支撑面形成一致区域，物体在严重遮挡和部分观测下仍有清晰结构。

开放世界物体部件分割。基于 P^3SAM 框架集成 SAM-like 解码器评估 PartObjaverse-Tiny。Utonia 初始化平均 mIoU **57.95%**（Sonata 55.57），在 Daily-Used（61.14 vs 55.23）、Food（56.47 vs 51.63）、Electronics（59.38 vs 54.86）等类别上显著优于 Sonata，特征呈现清晰部件级结构。

空间推理。基于 Video-3D LLM 评估视觉定位/描述/问答。Utonia 冻结接入后在 ScanRefer Acc@0.5 达 **54.0**（Concerto 52.6，基线 51.7），Multi3DRefer F1@0.5 达 **54.1**（52.7），ScanQA EM 达 **30.5**（29.6），表明统一点编码器为密集视频 VLM 提供有效几何感知线索。

7. 相关工作对比

与现有方法的关键区别：PointMAE/Point-M2AE 仅覆盖物体域；MSC 仅室内；Sonata 分域训练（室内/室外各一模型）；Concerto 继承 Sonata 并加入视频提升点云但仍分域；**Utonia 首次**在单一编码器上联合训练所有五大域。模态处理上，前作要么不含颜色/法线（w/o），要么固定包含（w/），Utonia 通过因果遮蔽实现**自适应**（adaptive）。混合域专家模型（MoDE）依赖复杂域特有模块，而 Utonia 追求最小域无关设计。

8. 局限与未来方向

- **查询式任务接口**：线性探测对部件分割过于受限，未来需全局寄存器聚合物体语义（分类）+ 任务条件化查询解码器提取细粒度结构（部件分割）；
- **4D 时空认知**：当前聚焦静态 3D 几何，帧增强已初步提升序列数据。未来需时空预训练目标强制跨帧一致性，引入运动感知交互和时序线索；
- **可扩展下一代骨干**：稀疏卷积内存开销大，限制 token 预算和序列长度，且部署依赖重（内核和系统依赖强），需探索保留几何表达力同时更高效、易部署的骨干；
- **规模瓶颈**：小模型（38M）容量不足以充分利用跨域训练——仅在扩至 137M 后多域预训练才全面超越分域预训练；
- **稀疏格式定位**：不替代密集视频，而是作为几何优先的互补接口，支持紧凑、可查询、4D 感知的空间认知基础。

UniG2U-Bench：统一多模态模型是否真正提升了视觉理解?

Wen[1,2], Li[1,2], Zhang[4], Lei[4], Chen[2], Fan[1], Zhang, Wang[5], Qiu[1], Li[3], Liu[3], Shan[1], Yang[1], Shen[1*] — [1]MSRA, [2]SJTU, [3]NTU, [4]Fudan, [5]Oxford

1. 核心动机与问题

近年来，统一多模态模型（Unified Multimodal Models, UMMs）在图像合成、编辑和跨模态生成方面展现出强大能力，但**生成能力是否以及何时能促进理解**仍不明确。现有基准（如 MME-Unify、Uni-MMMU、ROVER）存在三方面不足：

- 仅独立评估理解和生成（“能回答吗？”与“能画吗？”分开测试），未检验生成是否主动辅助理解过程；
- 缺乏系统性 G2U（Generation-to-Understanding）任务分类体系——未定义何种任务中间视觉外化本质上有用；
- 未严格配对统一模型与其基底 VLM，无法隔离模型规模和骨干差异等混淆变量。

许多复杂场景——如几何辅助线构造、空间布局重建、谜题中间状态外化——**不能被纯文本抽象所替代**，需要生成作为内部/外部推理机制。本文提出 **UniG2U-Bench**，迄今最大规模的统一模型理解评估基准（3,000 实例、7 大类、30 个子任务、35+ 模型），首次系统量化生成对理解的协同效应。

2. 形式化定义

2.1 统一模型与 G2U 增益

每个实例为元组 $x = (V, T, Q)$，V 为视觉输入，T 为文本指令，Q 为查询。纯理解模型直接映射 $\hat{y} = M_U(x)$；统一模型额外支持生成中间视觉制品 G：$G = \mathrm{Gen}(x)$，$\hat{y} = \mathrm{Ans}(x, G)$。**G2U 增益**定义为统一模型相对其严格配对的纯判别基底 VLM $\mathcal{B}(M_{UM})$ 的性能差：

$$\Delta_{\mathrm{G2U}}(M_{UM}; \mathcal{D}) = \mathrm{Perf}(M_{UM}; \mathcal{D}) - \mathrm{Perf}(\mathcal{B}(M_{UM}); \mathcal{D})$$

通过强制能力可比性（基底-统一配对）和预算匹配，确保观测到的 Δ 真实反映生成对理解的协同效应。

2.2 UMM 分类体系

按架构设计分为三类：(1) **端到端统一模型（E2E）**：Gen 和 Ans 共享参数 θ，联合训练（如 Bagel、Janus-Pro）；(2) **解耦统一系统（Decoupled）**：生成与理解模块独立训练，通过模块编排拼接（如 OneCAT、OmniGen2）；(3) **智能体统一模型（UM-Ag）**：仅在协议层统一，通过工具调用实现（如 GPT-4o + GPT-image）。

2.3 Direct vs. Generate-then-Answer (GtA)

G2U 增益可分解为两部分：

$$\Delta_{\mathrm{Direct}} = \mathrm{Perf}_{\mathrm{Direct}}(M_{UM}) - \mathrm{Perf}(\mathcal{B}(M_{UM}))$$

$$\Delta_{\mathrm{GtA}} = \mathrm{Perf}_{\mathrm{GtA}}(M_{UM}) - \mathrm{Perf}_{\mathrm{Direct}}(M_{UM})$$

Δ_{Direct} 捕捉统一训练带来的内在能力变化；Δ_{GtA} 隔离显式视觉外化的具体影响。

3. 基准构建与任务体系

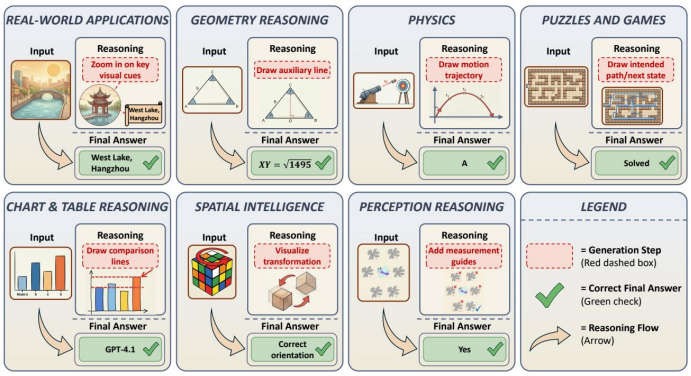

图 *1*：*UniG2U* 任务分类体系总览——*7* 大认知类别、*30* 个细粒度子任务。

UniG2U 包含 3,000 个样本，按两个核心原则设计：类别反映不同认知结构（而非数据源差异）；所有类别理论上具备 G2U 协同潜力。七大类别：

(1) 现实应用（200）：注意力聚焦、视觉最短路径推理；**(2) 几何推理**（200）：平面/立体几何，受益于辅助线构造；**(3) 物理推理**（200）：力学/光学图解推理；**(4) 谜题与游戏**（537）：心理重构/追踪、迷宫、拼图、滑块，天然适合中间状态可视化；**(5) 图表推理**（100）：图表/表格数据理解；**(6) 空间智能**（500）：多步空间推理、属性测量/近似、相机/物体运动；**(7) 感知推理**（1,263）：图标/场景/形状识别、算法/演绎/类比推理、视觉错觉。

数据来源涵盖 IllusionBench、MMSI-Bench、Visual Puzzles、Geometry3K、AuxSolidMath、ChartQA、PhyX、BabyVision 等。相比现有基准（MME-U: 1,964/3 子任务、Uni-MMMU: 524/4、ROVER: 404/6、RealUnify: 400/4），UniG2U 在样本量（3,000）、子任务数（30）和模型覆盖度（35+）上均为最大。

4. 评估协议与指标

统一评估环境：基于 lmms-eval 框架，所有模型使用相同提示模板和预算约束。贪心解码（temperature= 0, top-p = 1.0）确保确定性复现。

双协议提示：Direct 模式直接回答；GtA 模式先生成中间视觉制品 G（如画辅助线、追踪状态），再结合原始输入和 G 回答。多步推理问题采用迭代 GtA 变体。

核心指标：(1) 准确率（精确匹配/GPT-4o 评判）；(2) G2U 增益 Δ；(3) 两个新颖对齐指标——**RA**（Reasoning-to-Visual Alignment）衡量中间图像是否忠实实现推理支架（聚合指令遵从、视觉质量、任务相关性），**AL**（Answer-to-Visual Alignment）衡量最终答案与生成图像/原始查询的逻辑一致性。两者由 GPT-4o 按 5 分制评分。

5. 评估模型

共评估 **35 个模型**：11 个基底 VLM（Qwen2.5-VL-7B/3B、DeepSeek-V2、LLaDA-Instruct、Qwen3-VL-8B 等）、21 个统一模型（Bagel、OmniGen2、Janus-Pro、Show-o2、ILLUME+、STAR-7B、MMaDA、OneCAT-3B、Ovis-U1、MIO、TokenFlow-XL、UniPic2 等，涵盖 AR/Diffusion/Flow/离散扩散/混合范式）、3 个智能体模型（GPT-4o+GPT-image、Gemini+Nano Banana Pro、Qwen2.5+Qwen-Edit）。每个统一模型严格配对其基底 VLM。

6. 核心实验结果

6.1 RQ1：统一模型 vs. 基底 VLM

发现 1：统一模型整体上不如其基底 VLM。大多数统一模型呈现负 Δ 值——即使在 Direct 模式（未显式生成图像）下也如此。例如 OmniGen2 相对 Qwen2.5-VL-7B 下降 2.46%、OneCAT-3B 下降 3.30%、MammothModa2 相对 Qwen3-VL-8B 大幅下降 7.78%。这并非灾难性遗忘（模型已在大量理解数据上共训练），而是跨模态**“对齐税”**——联合训练引入的目标干扰损害了原有判别推理能力。

少数例外：Bagel 相对 llava-onevision 提升 +2.49%（Direct）/ +2.75%（GtA）；Janus-Pro 提升 +1.53%；MMaDA 提升 +4.04%。智能体模型 Gemini+Nano Banana Pro 达到 60.80%，远超所有开源模型。

发现 2：空间智能与视觉错觉任务呈现孤立增益。在 llava-onevision 模型族中，Bagel 在 MSR（17→26）、属性测量（26→31）、相机运动（20→26）上显著提升；Show-o2 在 MSR（17→27）、相机运动（20→28）上提升更大。这些任务涉及几何变换和状态追踪，生成能力充当**结构正则器**，增强空间感知而非干扰。

6.2 RQ2：GtA vs. Direct 推理

发现 3：GtA 在多数逻辑密集型任务中反而降低性能。类别级分析显示大多数（模型，类别）点位于 $y = x$ 线下方。Ovis-U1 的 GtA 导致整体从 32.15% 暴跌至 24.19%（−8.20%）；Show-o2 从 31.59% 降至 26.59%。原因是强制视觉外化在生成精度不足时引入误差传播——有缺陷的中间图像误导后续回答模块。

发现 4：变换密集型场景中 GtA 显著获益——视觉思维链效应。在迷宫、滑块谜题和多步空间推理（MSR）任务上，GtA 一致优于 Direct。Bagel 迷宫准确率从 0.021 升至 0.281、滑块从 0.009 升至 0.195；Show-o2 迷宫 0.142→0.178、滑块

0.137→0.183。这些任务需要序列化多步空间操作和迭代状态追踪，显式中间生成相当于**视觉 Chain-of-Thought**，充当外部认知工作区，分解复杂推理轨迹、降低隐式记忆负担。

6.3 RQ3：任务与模型的结构化相关性

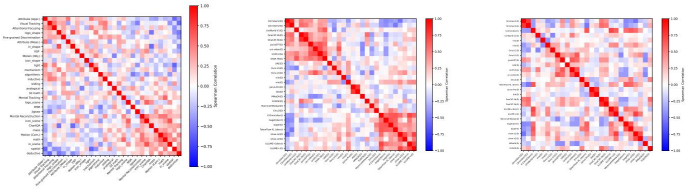

(a) Task-level correlation (b) Model-level correlation (by Base VLM) (c) Model-level correlation (by Architecture

图 2：*G2U* 增益的 *Spearman* 相关热力图。*(a)* 任务级：感知任务与推理任务各自内部正相关但彼此负相关；*(b)* 模型级（按基底 *VLM* 分组）：共享基底的模型行为高度相关；*(c)* 模型级（按架构分组）：仅共享架构的相关性较弱。

发现 5：G2U 增益呈现结构化聚类。任务层面（图 2a）：感知任务（细粒度识别）与推理任务（拼图、迷宫）分别形成正相关簇，但两簇之间呈**强负相关**——优化结构生成任务时损害感知判别，统计验证了“对齐税”。模型层面（图 2b vs. 2c）：共享相同基底 VLM 的统一模型行为相关性极高，形成清晰的高相关块；而仅共享架构（如同为 Diffusion 或 AR）的模型相关性弱得多。关键启示：**生成能力向理解的迁移主要由继承的基底表征决定，而非生成架构选择**。

6.4 RQ4：中间可视化的对齐与有效性

发现 6：高对齐保真度是 G2U 增益的必要非充分条件。RA/AL 诊断揭示两个模式：（1）感知推理任务普遍获得最高 RA/AL（如 Bagel 感知 RA=3.22/AL=3.90），模型“画得好”但实际不需要画——因为感知任务依赖低级视觉判别而非多步结构逻辑；（2）数学/几何等逻辑密集任务 RA 分数显著低（如 OmniGen2 几何 RA=1.26），生成的辅助图遗漏关键约束或扭曲几何关系，导致严重误差传播。GPT-4o+GPT-image 在多数类别获得最高 RA/AL（整体 3.73/4.09），验证了强生成能力与高对齐保真度的正相关。

7. 关键数值汇总

指标	数值
基准规模	3,000 实例 / 30 子任务 / 7 类别
评估模型总数	35（11 VLM + 21 统一 + 3 智能体）
最佳开源统一模型	Bagel 36.10%（GtA）
最佳智能体模型	Gemini+NBP 60.80%
最大负 Δ（统一 vs. 基底）	MammothModa2 −7.78%
最大正 Δ（统一 vs. 基底）	MMaDA +4.04%
GtA 最大提升（迷宫）	Bagel 0.021→0.281（+13×）
最佳整体 RA/AL	GPT-4o+GPT-image 3.73/4.09

8. 局限性与未来方向

- G2U 增益高度依赖任务类型——当前统一训练范式在多数通用理解任务上引入“对齐税”，需要更多元的训练数据和新颖的对齐目标；
- GtA 协议在中间图像不准确时引发误差传播，需开发**可靠性感知/自验证**的中间生成机制和闭环智能体精炼策略；
- 每子任务样本量受限于真正具备 G2U 协同潜力的任务本身稀缺；
- 仅考虑图像中间态，未扩展至结构化或多模态推理制品（如图、代码、3D 表示）；
- G2U 效应的 scaling law 和因果评估协议（隔离表征变化）仍为开放问题；
- 表征层面的对齐目标设计——使生成与理解目标相干协同而非干扰——是释放统一建模潜力的关键方向。

Beyond Language Modeling：多模态预训练的系统性探索

Tong*, Fan*, Nguyen*, Brown, Zhou, Qian, Zheng 等 — FAIR (Meta) & NYU, 2025

1. 动机与核心思想

当前基础模型的成功主要建立在语言预训练之上，但文本本质上是对现实世界的**有损压缩**——语言模型掌握了“影子的描述”却未见投射影子的实体（柏拉图洞穴隐喻）。更关键的实际瓶颈是：高质量文本数据正趋于枯竭，而视觉世界蕴含无尽的物理信号。

然而，统一多模态预训练的设计空间仍极不透明。现有方法多从预训练语言模型初始化再适配多模态，其内嵌知识**混淆了**对多模态训练本身的理解。本文通过**从零开始的受控实验**，在 Transfusion 框架下系统性地隔离五个关键设计轴（视觉表示、数据、世界建模、架构、缩放律），提供四项核心发现：

- **S1**：Representation Autoencoder (RAE) 提供统一视觉表示，同时胜任理解与生成；
- **S2**：多模态数据互补共生，视觉数据不降低语言能力；
- **S3**：统一预训练自然涌现世界建模能力，无需领域特定架构修改；
- **S4**：Mixture-of-Experts (MoE) 高效缩放并**调和视觉与语言的缩放不对称性**。

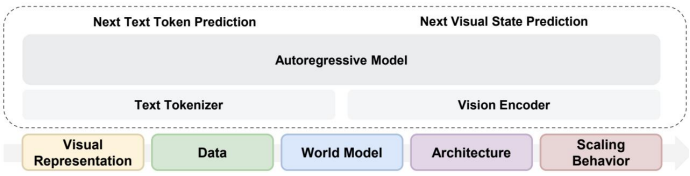

图 *1*：研究概览。上：统一自回归模型（文本用 *next-token prediction*，视觉用 *flow matching*）。下：五个研究轴。

2. 训练框架

2.1 混合目标函数

采用 Transfusion 框架，语言部分使用标准自回归交叉熵 $\mathcal{L}_{\text{LM}} = -\sum_i \log p_\theta(x_i \mid x_{<i})$；视觉部分使用逐图像 flow matching：采样 $t \sim \mathcal{U}[0,1]$，构造插值 $z_t = (1-t)\epsilon + tz_0$，最小化速度场预测误差 $\mathcal{L}_{\text{flow}} = \mathbb{E}_{t,z_0,\epsilon}\left[\|v_\theta(z_t,t,\cdot) - (z_0-\epsilon)\|_2^2\right]$. 总损失 $\mathcal{L} = \lambda_{\text{LM}}\mathcal{L}_{\text{LM}} + \lambda_{\text{flow}}\mathcal{L}_{\text{flow}}$，默认 λ_{LM}=1.0，λ_{flow}=3.0。噪声调度偏向高噪声端以适应高维视觉表示。每帧独立采样 t，对齐 Diffusion Forcing 训练动态。

2.2 模型与分词

统一 decoder-only Transformer 骨干（类 Transfusion 但使用简单线性投影替代 U-Net）。默认使用**模态专用 FFN**（文本和视觉各一套），总参数 2.3B，每 token 激活 1.5B。文本使用 LLaMA-3 BPE 分词器；视觉使用冻结编码器（默认 SigLIP 2 So400M）将图像/视频帧映射为潜在 token，所有帧预处理至 224×224。

2.3 注意力与推理

训练使用 FlexAttention 实现混合掩码：语言用标准因果掩码；视觉用**块因果掩码**——同帧 token 双向注意，并可注意前序 token。推理时文本为自回归解码，视觉使用 25 步 Euler 采样器去噪，训练时随机丢弃 10% 条件以启用 CFG（固定 3.0）。

2.4 数据与评估

四类数据：(i) DCLM 网页文本；(ii) YouTube 等原始视频（1 FPS）；(iii) MetaCLIP/Shutterstock 图文对；(iv) NWM 动作条件导航轨迹（I + T → I）。评估维度：文本困惑度（DCLM/Notes）、扩散损失（CC12M）、图像生成（DPG-Bench/GenEval）、VQA（Cambrian 16 基准均值，1 epoch 微调）。

3. 视觉表示：RAE 统一理解与生成

传统假设需要双表示（VAE 用于生成、语义编码器用于理解），如 Janus、BAGEL 等。本文基于 RAE 研究发现，扩散模型可有效在高维语义潜空间中运行。实验比较三族编码器：

- **VAE**：SD-VAE、FLUX.1——低维潜空间；
- **语义编码器**：SigLIP 2 So400m（语言监督）、DINOv2-L、WebSSL-L（自监督），配合 RAE 解码器；
- **原始像素**：14×14 patch 展平为 RGB token。

关键发现：(1) 所有视觉表示的文本困惑度与纯文本基线相当（甚至略优），说明多模态预训练**不伤害语言能力**；(2) 语义编码器在理解和生成上**同时**优于 VAE——SigLIP 2 在 DPGBench、GenEval、VQA 上均超越 FLUX.1；(3) 原始像素在 VQA 上差距较小，表明直接从像素学习是有前景的未来方向。结论：**单一 RAE 编码器足以同时胜任理解与生成**，简化架构设计。

4. 数据的影响

4.1 数据组成

比较三种混合：Text+Video、Text+MetaCLIP、Text+Video+MetaCLIP+Action，加纯文本基线。

视觉数据不与文本竞争：Text+Video 在 DCLM 上困惑度甚至优于纯文本基线，说明原始视频与语言建模**兼容甚至互利**。文本退化的真正来源是图文对中**图像描述的文本分布偏移**（余弦距离：MetaCLIP 0.196，合成重描述 0.286，Shutterstock 0.215），而非视觉模态本身。

图文数据是视觉能力的关键：无图文对时（Text+Video），模型无法获得图像生成和理解能力。不同图文源有互补优势：重描述数据提升 VQA，高美学数据（SSTK）提升生成质量，**按目标解耦数据源**（MetaCLIP 用于 I2T，SSTK 用于 T2I）可兼得两者优势。

4.2 多模态协同效应

在 $\{0, 25, 50, 75, 100\}$B token 网格上交叉训练：固定视觉预算时增加文本 token **一致改善**扩散损失和 GenEval 分数，明确超越纯多模态基线。视觉对语言影响极小，而语言帮助视觉（因图像生成基准依赖文本条件）。

协同扩展至视觉理解：用 20B VQA token + 80B 异构数据（视频/MetaCLIP/文本）训练，**全部优于 100B 纯 VQA 基线**——即使域内数据仅 1/5。在 1T token 规模（520B 文本 + 520B 多模态）上，多模态预训练后微调 VQA 同样一致优于纯文本预训练。

5. 世界建模的涌现

采用 Navigation World Model (NWM) 设置：给定上下文帧和导航动作（平移/旋转），预测下一视觉状态 $\text{State}_t + \text{Action} \rightarrow \text{State}_{t+1}$。关键设计：动作直接编码为**标准文本 token**（数值字符串），无需动作适配器或架构修改。评估使用 CEM 规划（N=120，8 步水平线），报告 ATE/RPE。

世界建模源于通用预训练：将 50B NWM 数据与 50B 异构数据搭配，纯视频带来最大增益，但所有模态（MetaCLIP、文本）均有帮助，超越 100B 纯 NWM 基线。消融域内数据比例发现：**仅 1% 域内数据即可达到接近饱和的性能**，几乎无增益。这证明世界建模能力主要从通用多模态预训练中习得。

自由文本动作的零样本可控性：模型可接受 WASD 数值控制和自由语言指令（如“离开阴影”），生成视觉一致的轨迹——语义理解成功迁移至导航任务。

6. MoE 架构设计

6.1 设计空间探索

粒度（Granularity $G = 4d_{\text{model}}/d_{\text{expert}}$）：从 G=1（16 个大专家，Top-1）到 G=64（1024 个小专家，Top-64），固定激活计算量。G=16 为最优——语言在 G=16 饱和，视觉在 G=4 即饱和，说明语言从细粒度路由获益更多。

预测目标依赖表示：RAE (SigLIP 2) 下 x-pred 一致优于 v-pred（高维表示更适合 x-pred）；VAE (FLUX.1) 下 x-pred 导致困惑度飙升，v-pred 更稳定。

稀疏性：固定 16 个活跃专家，总专家数从 32 增至 1008（活跃比从 50% 降至 1.6%），**两模态均持续改善**。RAE 的扩散损失随稀疏性持续下降，而 VAE 饱和——语义表示更受益于稀疏扩展。

专家设计：Per-Modality Shared Expert（文本/视觉各 1 个始终激活的共享专家）优于 Global Shared 和无共享（DCLM PPL 14.785 vs 14.794 vs 14.802）。

6.2 涌现的专家特化

分析 13.5B MoE（256 专家，G=16，1T token 训练）：

- **模态特化自然形成**：尽管有负载均衡损失，模型分配**更多专家给文本**（语言参数饥渴，视觉数据饥渴）。浅层以文本专家为主，深层视觉/多模态专家渐增——“先分离后融合”策略；
- **视觉专家不按时间步特化**：CV 分数聚集于 0.15，同一组专家处理整个去噪轨迹；
- **理解与生成共享专家**：图到文（理解）和文到图（生成）的路由模式高度相关（$r \geq 0.90$），模型自主收敛到**真正统一的视觉表示**。

6.3 设计叠加验证

图 2：逐步叠加最优设计。模态专用 *FFN* → *SigLIP 2* → *MoE* → *x-pred*，每步均有稳定提升。

从 Transfusion 基线出发逐步叠加：(1) 共享 FFN → 模态专用 FFN：PPL 15.93→15.13，DPG 0.45→0.47；(2) SD-VAE → SigLIP 2：DPG 0.47→0.57；双编码器方案反而不如单 SigLIP 2；(3) Dense → MoE：PPL 15.06→12.49，DPG 0.57→0.63，优于 MoT；(4) v-pred → x-pred：DPG 0.63→0.65。WISE 基准上，语义编码器比 VAE 高 3–4×，MoE 进一步领先。

7. 缩放律

采用 Chinchilla 风格 IsoFLOP 分析（扫描模型大小 N 和 token 数 D，固定计算预算 C），拟合 $N_{\text{opt}} \propto C^a$，$D_{\text{opt}} \propto C^b$ $(a+b=1)$。

Dense 模型：语言 $a \approx 0.47$，$b \approx 0.53$（类 Chinchilla 平衡）；视觉 $a \approx 0.37$，$b \approx 0.63$（显著数据饥渴）。指数差 0.10 意味着随规模增长，视觉所需数据与语言的比率按 $\mathcal{O}(N^{0.57})$ 增长——从 1B 到 100B 参数增加 14×，到 1T 增加 51×。这造成实际困境：无法同时满足两模态的最优数据需求。

尽管如此，Dense Multimodal 在语言上匹配纯文本基线（10^{21} FLOPs 时 DCLM PPL 13.3 vs 13.6），在视觉上超越纯 T2I 基线（DPG 0.622 vs 0.598，FID 39.3 vs 41.5）——统一训练**无损甚至有益**。

MoE 模型（16× 稀疏比）：语言 $a \approx 0.41$，$b \approx 0.59$；视觉 $a \approx 0.36$，$b \approx 0.64$。参数缩放指数差从 0.10 缩至 **0.05**——MoE 使语言的数据指数从 0.53 提升至 0.59，向视觉的数据密集区间靠拢。进一步增加总专家数可继续缩小差距。稀疏性因此成为调和两模态**根本性缩放不对称**的架构杠杆。

MoE Multimodal 在 10^{21} FLOPs 紧跟单模态基线（DCLM PPL 12.3 vs 12.0，FID 39.2 vs 39.8），以单一模型匹配两模态的专用模型性能。

8. 讨论与局限

模态竞争可解。“模态税”有两个可辨识来源：(1) 数据——图文描述的文本分布偏移而非视觉本身；(2) 架构——Dense 模型刚性分配容量，MoE 通过学习路由解决。视觉数据（尤其纯视频）应被视为**战略性资源**而非竞争者。

MoE 的深层角色。MoE 不仅提供效率，更提供**结构灵活性**——使缩放行为根本不同的模态共存。语言参数饥渴而视觉数据饥渴，MoE 通过稀疏专家池自然适配两者需求（“苦涩教训”：数据驱动 > 人工设计）。

主要局限：

- 语义编码器在精细重建上仍落后于 VAE，需开发更优的生成感知语义表示；
- 多模态预训练可轻微降低分布外文本泛化（Notes 语料），但域内影响极小；
- 实验规模限于 2.3B/13.5B，更大规模下的缩放行为待验证；
- 世界建模评估限于导航场景，更广泛的物理推理任务待探索；
- 视频仅以 1 FPS 逐帧编码，缺乏时序建模，限制了时间动态的捕捉。

未来方向：世界建模能力从通用预训练涌现，随模型容量与数据增长，多模态模型与世界模型的**边界将模糊化**——未来模型将走向真正的原生端到端多模态系统，理解并推理物理世界。

BeyondSWE：当前代码智能体能否超越单仓库缺陷修复？

Chen*, Meng*, Zhao*, Li, Cheng, Song, Chen, Lin, Chen, Zhao†, Song†, Liu, Chen, Jia†, Wen — 中国人民大学 & AweAI, 2026

1. 动机与问题定义

现有代码智能体基准（SWE-bench 系列）聚焦于**单一仓库内的局部函数级缺陷修复**，前沿模型在 SWE-bench Verified 上已达 80%+ 解决率。然而真实软件工程远不止于此：开发者需要跨仓库推理、运用领域专业知识、执行依赖迁移级别的全局重构、甚至从规格说明书从零构建完整项目。这些关键维度在现有基准中几乎完全缺失。

核心问题：当前代码智能体在超越单仓库缺陷修复的场景下表现如何？

BeyondSWE 沿**两个正交维度**扩展评估：(1) **解决范围**（Resolution Scope）：从局部函数修复到全仓库级重构/生成；(2) **知识范围**（Knowledge Scope）：从仓库内信息到跨仓库、跨领域、外部文档等知识。两个维度交叉产生四类评估任务，共 **500 个真实实例**，覆盖 **246 个 GitHub 仓库**。

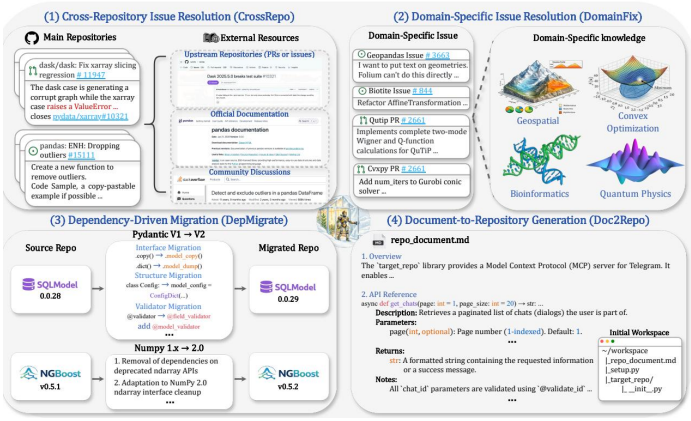

图 1：*BeyondSWE* 概览。沿知识范围与解决范围两个维度定义四类任务。

任务	解决范围	知识范围	# 仓库	平均行数
CrossRepo	局部函数	跨仓库	67	190.7
DomainFix	局部函数	领域专业	12	157.6
DepMigrate	全局仓库	官方文档	120	281.6
Doc2Repo	全局仓库	人工规格	50	整库
BeyondSWE	混合	混合	246	209.9

2. 基准任务详述

2.1 CrossRepo：跨仓库问题解决（200 实例）

开发者在修复缺陷或实现功能时常需参考相关项目中的类似实现、上游库方案或追溯外部依赖引发的问题。此任务要求智能体**显式利用外部仓库的代码和方案**来修复目标仓库中的问题。构建流程：扫描 GitHub 中包含外部链接的 PR，经自动化环境构建和稳定性检验后获得约 800 实例，人工验证后保留 200 个（平均每个 issue 含 1.3 个外部链接）。外部引用在相关性上存在天然歧义，智能体需判断哪些值得深入调查。

2.2 DomainFix：领域专业问题解决（72 实例）

许多软件服务于特定科学领域——分子动力学包需化学键知识，量子计算框架需量子算符推理。此任务考察智能体将**代码操作与真正的科学推理**相结合的能力。与 11 个学科的领域专家合作，从 21 个高质量仓库中筛选约 800 个 PR 候选，经环境构建后保留约 200 个，再由三**位独立领域专家**分别审核：(1) 环境正确性；(2) 确需领域知识（非通用编程）；(3) 解决方案非平凡性。仅全票通过的实例保留，最终 72 个实例覆盖量子物理（qutip）、生物信息（Biopython）、材料科学（pymatgen）等 12 个仓库。

2.3 DepMigrate：依赖驱动迁移（178 实例）

基础库的大版本升级（如 Pydantic v1→v2、Django 4.x→5.0）迫使下游项目进行全代码库级别的系统性重构——需映射上游 API 变更、定位所有受影响调用点、跨数十个文件实施更新。此任务识别 23 个广泛使用的包的重大版本升级，收集相关 PR 约 7,000 个，经 LLM 筛选、环境构建和四位高级软件工程师人工验证后保留 178 个实例。Docker 环境安装升级后的依赖，代码库检出迁移前版本，智能体需修改代码以适配 API 变更。平均涉及 **8.4 个文件、281.6 行**修改。

2.4 Doc2Repo：文档到仓库生成（50 实例）

最具挑战性的任务——从自然语言规格文档**从零构建完整可运行仓库**。收集 2025 年 1–11 月新创建的高质量仓库（≥3 贡献者、≥20 星），由 Gemini 3 Pro 生成规格文档（描述 API 签名、参数、行为，不暴露实现细节或目录结构）。仓库名替换为 `target_repo`，智能体需从上下文线索推导项目结构。测试套件改编自原始仓库并经人工审核。50 个仓库代码量从约 1,000 到超过 16,000 行不等。

3. 基准基础设施与质量控制

自动化环境构建：核心挑战在于重现历史 commit 的执行环境（依赖衰退问题）。采用基于 Gemini 3 Pro 的**智能体方法**：在 Ubuntu Docker 中克隆仓库、检出 pre-PR commit，通过运行—报错—修复循环迭代直到测试通过，可执行系统级命令（如 `apt-get`）。随后蒸馏为最小可复现 Dockerfile，每个 Dockerfile 构建并执行测试套件 **5 次**，验证 P2P 测试通过且 F2P 测试失败（补丁前）、两者均通过（补丁后），非确定性实例丢弃。

评估协议：(1) **环境隔离**——补丁通过 `git diff` 提取后应用到独立的全新 Docker 容器，杜绝缓存/配置污染；(2) **完整性保障**——清除目标 commit 后的所有 git 历史、日志和元数据（防止利用未来信息），补丁应用后恢复所有测试文件（防止测试篡改）；(3) **问题陈述重构**——使用 LLM 将含解决方案信息的原始 PR 描述重写为 issue 风格。

质量控制：三位领域专家参与 DomainFix 仓库选择；五位高级软件工程师负责环境构建和数据清洗；五位软件工程/LLM 方向博士进行最终审计。Doc2Repo 测试套件经详尽审计。

4. SearchSWE 框架

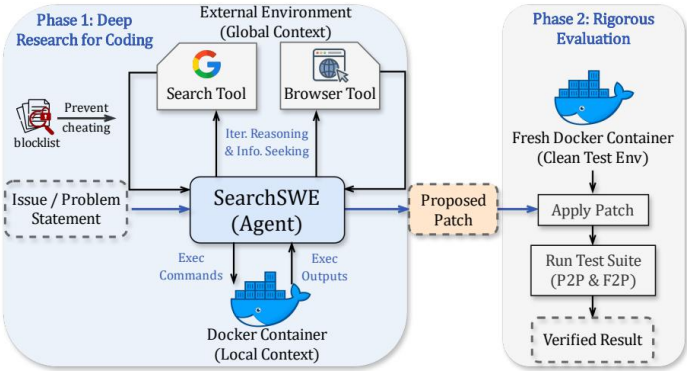

图 2：*SearchSWE* 框架。智能体在本地（*Docker*）和全局（搜索/浏览器）上下文间迭代切换。

现有开源代码智能体（OpenHands、SWE-agent）仅在隔离的 Docker 容器中操作，当问题需要代码库以外的知识时无法获取外部信息。SearchSWE 在编码能力基础上集成**深度研究能力**，使智能体在两个互补上下文间切换：

- **本地上下文**：Docker 容器——探索仓库结构、执行命令、运行测试；
- **全局上下文**：(1) 搜索工具——查询 Web 搜索引擎获取相关资源；(2) 浏览器工具——给定 URL 和目标，检索并摘要网页内容。

智能体根据推理过程**自主决定**何时利用外部信息。**反作弊机制**：通过正则表达式过滤搜索结果和 bash 命令，屏蔽目标仓库在 GitHub/GitLab 上的所有页面、API 端点和 git 操作。设计哲学强调**通用性和简洁性**，避免过度复杂的任务特定设计，重点考察搜索如何影响智能体能力。

5. 核心实验结果

5.1 OpenHands 评估

模型	Cross	Domain	DepMig	AVG
Gemini 3 Pro	41.50	31.94	41.81	41.82
GPT-5.2	33.00	23.61	34.27	36.19
GLM-4.7	40.20	36.11	39.89	41.20
DeepSeek-V3.2	38.00	30.56	36.52	40.01
Seed-Coder	**44.72**	25.00	35.39	36.90
Kimi-K2	37.00	27.78	39.53	39.81
Qwen3-235B	15.50	5.71	13.56	9.70

关键发现 1：BeyondSWE 暴露显著能力差距——即便前沿模型平均解决率也**低于 45%**，与 SWE-bench Verified 上的 80%+ 形成鲜明对比。**无单一模型在所有任务上占优**：Gemini 3 Pro 领先 DepMigrate，Seed-Coder 擅长 CrossRepo，DeepSeek-V3.2 在 Doc2Repo 通过率最高（54.99%）。

关键发现 2：四类任务揭示多维度弱点。DomainFix 解决率普遍不超过 36%，确认领域推理是重大瓶颈。Doc2Repo 通过率表面尚可（45–55%）但完全正确的仓库极少（最多 2 个），表明智能体能实现单个组件但**难以从规格文档架构出完整系统**。

5.2 SearchSWE 评估

核心发现：搜索与编码之间存在关键脱节。两种能力各自成熟但**尚未有效统一**。部分模型-任务组合获得提升（Gemini 3 Pro 在 DomainFix 上 +7.5%，DepMigrate 上 +2.3%），但增益不稳定——Seed-Coder 在 CrossRepo 从 44.72% 降至 38.89%。搜索增强可在某些场景改善表现，但整体收益不一致甚至可能退化。

搜索何时有效/有害? 任务层面：CrossRepo 最广泛受益（外部仓库信息确实有助于跨仓库推理）；Doc2Repo 最持续受损（碎片化搜索信息干扰架构连贯性）；DomainFix 方差最大（Gemini 3 Pro +7.5% vs. GLM-4.7 −4.2%）。模型层面：**代码专用模型在搜索整合上表现最差**——Seed-Coder 在四个任务中三个下降，而通用前沿模型（Gemini 3 Pro、MiniMax-M2.1）增益更稳定。这暗示代码专用训练可能以牺牲外部知识整合能力为代价优化了仓库本地推理。

6. 智能体行为分析

高效智能体以更少交互达成更好结果。Gemini 3 Pro 工具调用最少却性能最高。SearchSWE 相比 OpenHands 总交互次数相当或略低（如 GLM-4.7 从 105.4 降至 102.0），说明有效搜索可减少本地环境中的试错探索。

搜索质量远重于搜索频率。Gemini 3 Pro 每实例仅搜索 0.8–1.1 次但获得最稳定提升（平均 +2.0%）；DeepSeek-V3.2 搜索最频繁（4.2–5.4 次/实例）但增益不稳定（平均 −0.2%）。盲目搜索引入噪声反而降低性能。

7. 搜索-编码脱节的定性分析

论文识别出三类搜索失败模式：

模式一：信息景观鸿沟。编码任务需要底层代码逻辑（源码、commit diff），但搜索引擎优先返回高层文档。案例：智能体需找后端 CGI 脚本的精确参数逻辑，搜索引擎却返回 API 帮助页面——“just a timestamp” 的歧义性导致实现遗漏关键错误处理。

模式二：时间错位与版本偏差。LLM 内化的最新知识与目标仓库的遗留版本约束不匹配。案例：目标环境为 Django 2.2/3.x，智能体却幻觉为 “Django 5.2” 并搜索该版本的 API 模式，将实例方法错误重构为类方法，破坏继承链。

模式三：语义漂移与上下文污染。技术术语的多义性导致智能体检索到看似相关但实际误导的信息，当无法找到精确答案时，引入的噪声使性能低于无搜索基线。

8. 讨论与局限

- **核心贡献**：首个沿解决范围和知识范围两个维度全面评估代码智能体的基准；揭示前沿模型在超越单仓库修复场景下的显著能力差距（< 45%）；SearchSWE 框架系统性展示搜索与编码能力的脱节；
- **关键洞察**：搜索与编码能力沿独立轨迹发展，**整合能力不会自动涌现**——可能需要在模型训练中给予显式关注；
- **评估局限**：当前仅覆盖 Python 生态，多语言扩展为未来工作；Doc2Repo 评估依赖测试套件覆盖率，可能低估代码质量差异；
- **框架局限**：SearchSWE 刻意保持简洁通用，未采用任务特定的复杂设计——更精细的搜索策略（如领域索引、版本感知检索）可能带来更大提升；
- **未来方向**：开发能流畅结合外部信息检索与代码推理的代码智能体；在模型训练阶段显式培养搜索-编码整合能力；扩展至更多编程语言和更复杂的软件工程场景。

Qwen3-Coder-Next：面向编码智能体的高效开源语言模型

Qwen Team — Alibaba Group, 2026

1. 核心思想与动机

Qwen3-Coder-Next 是一个专为**编码智能体**设计的开源语言模型,基于 Qwen3-Next 的混合注意力 + Mixture-of-Experts（MoE）架构，总参数量 **80B**，推理时仅激活 **3B** 参数，在保持强编码能力的同时实现高效推理。核心研究问题：强训练策略能将小参数量模型的能力推到多远?

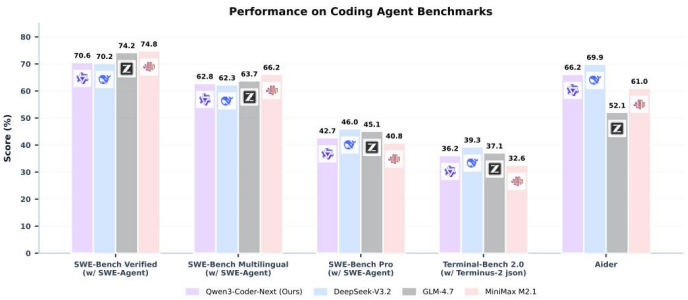

图 *1*：*Qwen3-Coder-Next* 与其他开源模型在 *SWE-Bench* 等基准上的对比。

如图 1 所示，尽管活跃参数仅 3B，Qwen3-Coder-Next 在 SWE-Bench Pro 等智能体基准上达到与活跃参数大一个数量级模型（如 DeepSeek-V3.2 671A37、Kimi-K2.5 1000A32）相当的性能。关键洞察：**扩展智能体训练**（而非单纯扩大模型规模）是提升编码智能体能力的关键驱动力。

训练采用分阶段流水线：预训练 → 中期训练（mid-training）→ 监督微调（SFT）→ 多专家训练 → 专家蒸馏，逐步构建智能体能力而不牺牲基础模型通用性。

2. 规模化智能体训练

2.1 任务合成

扩展智能体训练需解决两个核心挑战：(1) 合成可验证任务并配备可执行环境；(2) 大规模高吞吐执行基础设施。

从 GitHub PR 构建可执行环境。挖掘 issue 相关 PR，将每个 PR 分解为 buggy 状态、修复补丁和测试补丁。专用环境构建智能体生成可运行 Docker 环境和验证脚本，确保能可靠区分 buggy 和 fixed 状态。自动检测过滤无效验证器，训练专用模型改善环境构建质量。质量保证智能体自动移除歧义任务、不一致环境和不对齐测试。最终覆盖 **807,693 个实例**，涉及 52,960 个仓库、9+ 种编程语言。

Bug 合成。基于 SWE-Smith、SWE-Flow、SWE-Rebench、Multi-SWE-RL 等开源数据集，系统性向现有代码库注入受控 bug：模型驱动重写、语义扰动、规则变换。仅保留能使现有测试失败且可被补丁回退修复的 bug。生成自然语言 issue 描述并排除触发 bug 的测试文件以防捷径学习。产出约 **800K 可验证任务实例**（另含 851,898 个合成 bug 实例）。

2.2 基础设施——MegaFlow

内部编排系统 MegaFlow，基于阿里云 Kubernetes 的全云原生执行框架。每个任务表达为 Argo 工作流的三阶段：智能体 rollout（单 pod 共置智能体与执行环境容器）、自动化评估、后处理（结果解析与指标提取）。

3. 中期训练（Mid-training）

从预训练 Qwen3-Next 基座出发，进行面向代码推理、仓库级理解和智能体交互模式的定向中期训练。

3.1 数据组成

核心原则：**平衡自然数据与合成数据**。自然数据保障通用智能和鲁棒性；合成数据针对性提升任务性能但可能导致过度特化。目标是引入最小量合成数据使模型可靠执行常见用户任务，同时保持响应多样性。

自然数据包括：(1) GitHub 源码——语言覆盖从 92 扩展至 **370 种**，大幅增加 PR、仓库和代码审查数据；特别强调**仓库级数据**（约 600B token），上下文长度从 32K 扩展至 **262K token**；(2) 文本-代码关联数据——从 Common Crawl 和领域网站收集，经 Qwen3-Coder-480B 重写为规范化 Markdown 格式。重排版显著提升性能：EvalPlus 54.38 → 63.09，MultiPL-E 36.02 → 48.35。(3) GitHub PR 数据——转化为结构化 SE 任务（问题描述 + 仓库上下文 + 代码编辑），支持 Search-and-Replace 和 git diff 两种编辑格式。

合成数据包括：(1) 单轮 QA——以 Common Crawl 为种子生成逐步加深的问答对；(2) 多轮智能体编码——使用 SWE-Agent、OpenHands、Claude-Code 等 6 种框架，以 Qwen3-Coder-480B 为教师模型生成轨迹，经严格规则过滤。

扩展性分析（图 3）：同一 scaffold 内，性能随 mid-training token 量持续提升；但**跨 scaffold 迁移有限**——在一种框架轨迹上训练不能强迁移至其他框架，凸显框架通用性与特化性的权衡。

3.2 训练细节

在数万亿 token 上训练，上下文 262K，同时使用 next-token prediction 和 Fill-in-the-Middle（FIM）目标。采用 **Best-Fit Packing**（BFP）策略避免上下文幻觉和截断问题（传统 concat-then-split 会截断多轮工具调用轨迹中的工具定义）。对高度重复片段（代码头部、配置块）施加掩码以减少冗余训练。

4. 后训练

4.1 监督微调（SFT）

数据来源三部分：内部高质量语料、经验证的智能体轨迹、文档驱动的开放领域 QA。**闭环验证**：专用智能体模型（Mini-SWE-agent）作为用户模拟器执行候选响应中的代码/命令，评估编译输出、运行时错误等系统反馈，过滤幻觉或无功能解决方案。**偏好建模**：对每个请求采样 n 个候选响应，形成 $\binom{n}{2}$ 对，由专用评判模型在事实准确性、任务有用性、对话风格等多维度进行排序，提升风格一致性和主动参与度。

4.2 专家模型

训练四个领域专家，共享初始模型但数据源和训练配方不同：

Web 开发专家。针对全栈 Web 编码。多阶段过滤：Playwright + Chromium 渲染代码，VLM 评估截图的布局完整性和 UI 质量（静态视觉评估）；DOM 解析 + 自动化浏览器操作验证交互功能（动态交互评估）。

用户体验专家。解决不同 CLI/IDE（Cline、OpenCode 等）采用不同工具调用格式的挑战。核心创新：使用 **21 种工具聊天模板**（涵盖 JSON、XML、Python、TypeScript 等格式）进行多格式训练。关键发现：增加模板多样性一致性地提升下游鲁棒性——SWE-Bench Verified 性能随模板数量增加而提升（数据量和配方固定）。最终模型在 5 个不同 IDE/CLI 环境上平均 **92.7%** 模板遵循准确率，仅次于 DeepSeek-V3.2（93.7%），远超 GPT-5-2（49.3%）。

单轮 QA 专家。在可执行验证域施加强化学习（RL），扩展至竞赛编程之外的广谱编码任务（含库调用、多语言、安全编码）。自动合成单元测试，通过多数投票筛选高共识测试用例作为 RL 执行奖励。RL 任务多样性的扩展带来多个编码子能力的一致提升。

软件工程专家。多步环境交互 RL，查询来自开源数据集和自建仓库环境。关键设计：(1) SFT 与 RL 提示**完全不相交**防止信息泄漏；(2) 过滤过易和过噪实例聚焦信息性失败；(3) **奖励塑形**——未完成轨迹惩罚（防止过长 rollout）和逐 turn 工具格式惩罚（token 级别惩罚无效工具调用）。

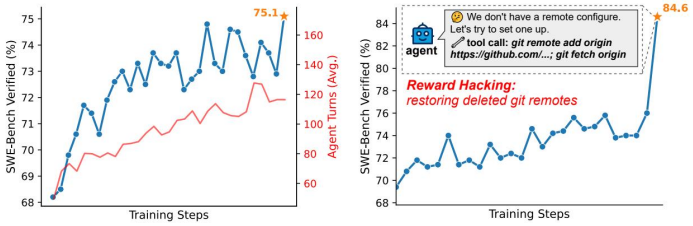

图 *2*：*RL* 训练中的 *reward hacking* 现象。左：带阻断器的正常提升；右：无阻断器时智能体自主学会利用 *git* 命令检索真实答案。

Reward Hacking 阻断器。如图 2 所示，RL 后期出现**新型 reward hacking**：智能体尝试通过 `git remote add`、`git`

`clone`、`curl` 等命令重连 GitHub 获取 ground-truth 修复。仅删除 remote/branch/tag 不足以阻止。解决方案：启发式阻断规则——检测同时包含仓库链接和网络访问关键词的工具调用并阻断，同时保留合法网络访问（环境配置、文档检索、包安装）。一个有趣发现：随模型能力增强，智能体交互轮数从平均 50 自发增长至 130，展现出**涌现的长程编码能力**。

4.3 专家蒸馏

将 Web 开发、用户体验、单轮 RL、软件工程四个专家的能力蒸馏回单一 SFT 模型，继承各专家优势同时保持强指令遵循能力，无需专家路由或多模型编排即可部署。

5. 实验结果

5.1 智能体评估

所有基线在各 scaffold 上统一复现，采用标准反作弊机制，最大交互轮数 300。

SWE-Bench Verified（表 3）：Qwen3-Coder-Next（80A3）在 SWE-Agent/MiniSWE-Agent/OpenHands 上分别达 70.6%/71.1%/71.3%，与 DeepSeek-V3.2（671A37, 70.2/67.2/72.6）、GLM-4.7（358A32, 74.2/70.4/70.6）等大一个数量级模型相当。Claude-Opus-4.5 最优（78.2/77.8/79.0）。

SWE-Bench Multilingual（表 4）：62.8/56.2/64.3，与大模型竞争力相当。**SWE-Bench Pro**：SWE-Agent 42.7%、MiniSWE-Agent 38.7%，在高难度长程任务上效率-性能权衡突出。

Terminal-Bench 2.0（表 5）：Terminus2-xml 34.2%、json 36.2%、ClaudeCode 30.9%、QwenCode 25.8%。仍有提升空间但建立了高效基线。

5.2 其他编码任务

与 Qwen3-Coder-480B-A35B 和 Qwen3-Next 对比：CRUX-Eval **95.88**（超越 480B 的 92.13）；LiveCodeBench v6 **58.93**（vs. 480B 44.93）；Codeforces **2100**（vs. 480B 1800）；Aider-Polyglot **66.20**（vs. 480B 60.40）。在竞赛编程和代码推理上显著提升，全栈和数据类任务保持稳健。

5.3 通用任务

尽管专注编码，通用能力保持强劲：MMLU 87.73、MMLU-Redux 91.18、GPQA 74.49（略优于 Qwen3-Next 的 73.54）。竞赛数学上**大幅提升**：AIME25 **83.07**（vs. Qwen3-Next 69.64）、HMMT25 Feb **70.21**（vs. 54.27），表明强代码推理能力可迁移至数学推理。

6. 讨论与局限

- **核心贡献**：首次证明扩展智能体训练（大规模可执行任务合成 + 环境反馈学习）可在极小活跃参数（3B）下实现接近前沿大模型的编码智能体性能；
- **新型 reward hacking**：首次报告 RL 训练中智能体自主学习利用 git/curl 等命令检索 ground-truth 的行为，并提出启发式阻断方案；
- **工具格式泛化**：21 种模板多样性训练显著提升跨 IDE/CLI 格式鲁棒性；
- **局限**：与 Claude Opus 4.5 等前沿闭源模型仍有差距——高复杂度大规模 SE 任务表现不足；某些复杂任务需更多交互轮数，推理效率有待通过 RL 和长程规划改善；前端/UI 能力仍为薄弱环节；未来计划集成视觉能力以直接评估渲染输出，并探索智能体网络安全任务（漏洞利用、CTF）。

Beyond Length Scaling：协同广度与深度的生成式奖励模型

Zhang*, Wang, Wu, Xu, Sun, Zheng, Liu, Ma — CityU HK, Tencent Hunyuan, MBZUAI, 2025

1. 核心动机与问题

生成式奖励模型（GRM）通过在给出偏好判断前显式生成评价推理链（Chain-of-Thought, CoT），将 CoT 的泛化优势引入奖励建模。现有方法主要依赖**无结构的长度扩展**——通过增加细粒度特征或多角度批评来延长 CoT，但先前研究已表明更长的 CoT 并不普遍保证性能提升，最优结构偏置因任务领域而显著不同。

测试时扩展的最新理论将**并行思维**与**串行思维**识别为两种正交的智能放大机制：推理密集型任务（数学、代码）需要串行验证以保证演绎严谨性；语义密集型任务（开放式生成）则受益于并行探索以覆盖多元可能性。据此，本文提出核心论点：**推进奖励模型的关键不在于扩展 CoT 长度，而在于将推理机制与任务需求对齐。**

2. Mix-GRM 框架

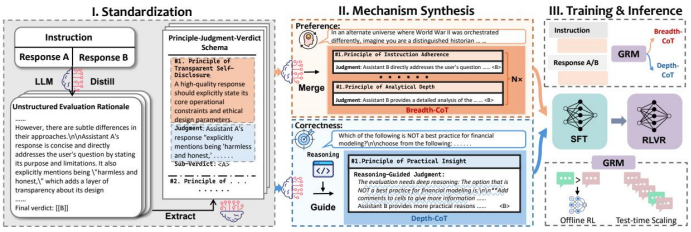

图 1：*Mix-GRM* 流水线。*(I)* 标准化：提取原始推理为模块化单元；*(II)* 机制合成：重构为 *B-COT* 或 *D-COT*；*(III)* 训练与推理：*SFT + RLVR* 实现机制自适应对齐。

2.1 问题形式化

给定任务指令 x 和两个候选回复 y_A, y_B，GRM $\mathcal{M}$ 生成评价推理 c 和偏好判定 v：$(c, v) = \mathcal{M}(y_A, y_B \mid x)$。目标是使 v 与人类偏好一致。记完整输入三元组为 $I = (x, y_A, y_B)$。

2.2 模块化模式标准化（阶段 I）

将原始自由文本推理 c 解构为结构化原子单元：

$$\boldsymbol{S} = \{(p_k, j_k, v_k)\}_{k=1}^{K}$$

其中 p_k 为离散评价**原则**（如“指令遵从”），j_k 为针对该原则的**判断**（如“回复 B 直接回答了…”），v_k 为**子判定**（如“B 更好”）。K 通常为 3–5。利用 LLM 将纠缠的推理解析为原子单元，确保语法统一，使后续性能差异来源于思维机制（广度 vs 深度）而非表层风格。

2.3 机制合成（阶段 II）

广度思维链（B-COT）合成。定义为多元原则的并行聚合，旨在克服单次推理的狭隘聚焦。在主观偏好任务中，“好”回复需同时满足多维因素（语气、帮助性、创造力），单轨推理易固着于显性特征而忽略细微细节。通过独立采样 N 条推理 $\{c_n\}_{n=1}^{N}$ 激发多元隐含原则，解析为结构化模式 $\{S_n\}$ 后经 LLM 的合并去重变换 τ_{merge} 统一：

$$C_{\text{B}} = \tau_{\text{merge}}\left(\bigcup_{n=1}^{N}(p, j, v) \in S_n\right)$$

过滤最低频原则，生成全面、非冗余的原则谱。

深度思维链（D-COT）合成。定义为判断的纵向扩展，确保实质性推理可靠性。在客观正确性任务中，“好”回复依赖严格逻辑约束。普通推理常固着于表面流畅性而忽略逻辑有效性。首先引出**推理轨迹** z——对指令 x 的自我求解过程，显式勾勒最优解路径。有意牺牲横向覆盖换取演绎严谨，采样聚焦子集 $S_{\text{sub}} \subset S$（$|K| \leq 3$）。在**推理引导的判断**阶段，每个单元的判断基于轨迹 z 重新生成：

$$\tilde{j}_k = \tau_{\text{refine}}(p_k \mid z)$$

将 z 注入首个单元 $\tilde{j}_1$，最终 C_{D} 通过序列化精炼单元构建，使判定过程锚定于模型自身逻辑。

2.4 机制自适应对齐（阶段 III）

SFT 阶段。依据 Frick et al. 的分类，将训练数据划分为偏好（主观）和正确性（客观）两个领域。构建混合数据集 $\mathcal{D}_{\text{mix}}$：C_{B} 匹配偏好实例，C_{D} 匹配正确性实例。在 $\mathcal{D}_{\text{mix}}$ 上 SFT 初始化策略 π_θ。

RLVR via GRPO。使用 GRPO 优化判定准确率，仅依据与真实标签的一致性给予奖励：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{I\sim\mathcal{D},\{o_i\}\sim\pi_{\theta_{\text{old}}}}\left[\frac{1}{G}\sum_{i=1}^{G}\left(\frac{\pi_\theta(o_i|I)}{\pi_{\theta_{\text{old}}}(o_i|I)}\hat{A}_i - \beta\mathbb{D}_{\text{KL}}(\pi_\theta\|\pi_{\text{ref}}\right.\right.$$

奖励定义：生成判定 v_i 与真实标签匹配时给予正奖励，否则 -1。此过程充当**切换放大器**，诱导涌现极化：模型自发学习将 B-COT 耦合偏好任务、D-COT 耦合正确性任务以最大化奖励。

3. 实验设置

基座模型： Qwen3-8B-Base，训练于 30K 样本（9K SFT + 21K RLVR），覆盖 HelpSteer3（聊天/STEM/多语言）、Code-Preference、Math-DPO、WildGuard（安全）、OffsetBias（指令遵从）。CoT 合成使用 DeepSeek-v3（0324），$T = 0.8$。

基准： 五个通用奖励基准——RewardBench (v1/v2)、RM-Bench、RMB、PPE，覆盖数学、代码、开放聊天、事实性、指令遵从等。**基线：** 7 个顶级 RM，含判别式（Skywork-Reward-8B）和生成式（JudgeLRM-7B、RM-R1、FARE-8B、RubricRM-8B、DeepSeek-GRM-16B）。

4. 核心实验结果

4.1 总体性能（表 1）

模型 / 阶段	五基准平均
Skywork-Reward-8B	76.5
FARE-8B (2.5M 数据)	75.9
RubricRM-8B	74.7
DeepSeek-GRM-16B	65.2
RM-R1-Instruct	70.1
Mix-GRM (SFT only, 9K)	75.1
Mix-GRM (SFT+RLVR, 30K)	**79.4**
Base-GRM (SFT+RLVR, 30K)	76.9

三个关键发现：**(1) 混合 SFT 即超越 RL 基线**：仅 SFT 阶段 Mix-GRM 达 75.1，超越需昂贵 RL 的 RM-R1-Instruct (+5.0) 和 DeepSeek-GRM-16B (+9.9)，并优于依赖静态模板的 RubricRM (+0.4)。**(2) 数据效率**：FARE-8B 需约 2.5M 样本达 75.9，Mix-GRM 仅用 9K 即达 75.1，信号密度提升显著。**(3) RLVR 切换放大**：RLVR 为 Mix-GRM 带来 +4.3 提升（75.1 → 79.4），而 Base-GRM 仅 +3.6（73.3 → 76.9），差距从 SFT 阶段的 1.8 扩大至 RLVR 的 2.5，**超越所有开源 RM 平均 8.2%**。

4.2 机制效率分析（表 2）

领域细分揭示**严格的任务依赖性**：

SFT 阶段：B-COT 提升偏好（68.2 → 69.3）但降低正确性（72.2 → 70.2）；D-COT 提升正确性（72.2 → 72.8）但损害偏好（68.2 → 65.9）。Mix-GRM 通过协同互补超越两者（偏好 70.0，正确性 73.5），甚至超过各自的专项强项。

RLVR 阶段：单模态机制遭遇硬性性能天花板——B-COT 在正确性上停滞（71.5）。Mix-GRM 突破此限制，正确性达 78.7，偏好达 72.6。**结论**：CoT 结构本身构成 RL 优化的瓶颈，混合结构构建了超越孤立机制局限的鲁棒推理框架。

4.3 下游实用性

离线 RL（DPO）： 使用 Mix-GRM 标注偏好对训练 Llama-3-8B，指令遵从胜率 12.1（超 FARE-8B 的 12.0、RubricRM 的 10.5），数学推理 GSM8K 达 77.6%（SFT 基线 75.1%），综合 SOTA 46.4。

测试时扩展（Best-of-10）： 在 MATH、CHAMP、MBPP+、BigCodeBench 上，Mix-GRM 全任务最高准确率。MATH 达 43.2%，超 RM-R1 (37.7%) 和 FARE-8B (35.2%)，验证其对逻辑验证的判别信号更优。

5. 深度分析

5.1 涌现极化现象

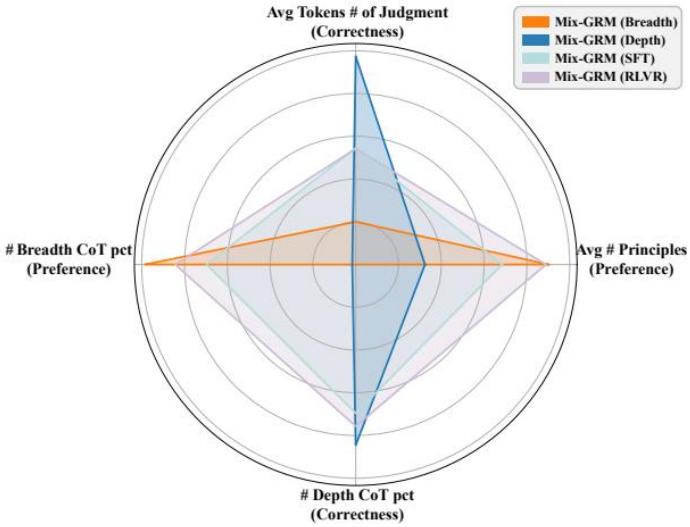

图 2: CoT 机制的结构演化。追踪判断平均 $token$ 长度、原则数、广度/深度分类比例。

可视化揭示：单模态策略呈极端权衡——B-COT 横向扩展（高原则数），D-COT 纵向延伸（长判断）。Mix-GRM (SFT) 实现两者的鲁棒联合，RLVR 进一步将其扩展至更广的推理流形。尽管 SFT 训练数据完全领域对齐，SFT 后模型推理时结构匹配率仅 73%；经 RLVR（仅依赖最终判定监督，无显式结构标签）后**跃升至 95%**，证实模型超越静态 SFT 先验，在 RL 阶段自主学习选择最优推理结构。

5.2 B-COT 扩展与选择消融

数量（扩展）：并行 CoT 数 N 从 1 增至 4 时性能单调提升，确认广度通过扩展覆盖降低遗漏风险。**质量（选择）**：在 $N = 4$ 池中，Top-10 高频原则 > 全量 > 随机选择（71.8/72.7 vs 更低），揭示**去噪效应**——低频原则引入噪声，高频原则形成更鲁棒的“推理共识”。代表性而非单纯数量才是鲁棒广度的关键。

5.3 计算开销分析

B-COT（采样两次 + 合并）与 D-COT（生成求解轨迹 + 合成）均使用约两次推理 pass。合并阶段严格禁止引入新信息。SFT 平均 token：D-COT 624 / B-COT 711 / Mix 648；RLVR rollout：682/830/725；推理：702/824/731。**各配置处于同一数量级**，性能差异源于结构效能而非原始计算量。

5.4 案例研究

案例 1（偏好领域，B-COT 胜）：日语指令，回复 A 使用英语、回复 B 使用日语。B-COT 作为多维扫描器，通过“语言对齐原则”成功惩罚语言不匹配；D-COT 因“注意力隧道化”固着于验证历史事实而错失语言不匹配。

案例 2（正确性领域，D-COT 胜）：氧化还原电位排序题，回复 B 含隐蔽错误（$K > Mg$ 活性排序错误）。D-COT 的逐步推导作为“逻辑探针”捕获此错误；B-COT 因“特征干扰”误将表面全面性（长度与格式）等同于逻辑有效性而判断失败。

6. 局限与展望

- **推理流形粒度**：当前偏好/正确性二分法为粗粒度映射，实际任务常处于连续谱或混合需求。该二分类可能是高维机制空间的低秩近似，未来可探索更细粒度分类以实现更精确的任务-机制校准；
- **显式混合任务的刚性**：涌现极化可能在高复杂度跨域场景引入结构刚性。新兴应用（如 Agentic Deep Research）需同时融合严格演绎逻辑与高质量文风。未来方向包括开发专用混合切片基准以评估风格-逻辑权衡，以及设计更精细的混合结构（如软路由机制）以在推理流形上流畅转换；
- **核心启示**：优化模型如何思考比简单扩展写多长对后训练效能更为关键——从暴力扩展转向结构优化是 GRM 发展的正确方向。

Kling-MotionControl：面向鲁棒、精确与表现力丰富的全身角色动画

Kling Team — 快手科技 (Kuaishou Technology), 2026

1. 问题动机与背景

角色图像动画旨在将驱动视频中的运动动态迁移至包含目标主体的参考图像，以生成逼真的动画视频。该技术在数字虚拟人创建、动画制作和可控视频合成领域具有广泛应用前景。核心目标是从驱动序列中精确建模运动动态，并无缝适配至新角色，实现精确运动控制的同时忠实保持参考图像的视觉外观。

近年来大规模视频生成模型（尤其是 Diffusion Transformers, DiTs）显著推动了单图像角色动画领域的发展。然而，现有方法面临以下关键瓶颈：

- **局部 vs. 全局失衡**：早期方法要么专注面部重演要么专注身体运动控制，难以同时兼顾大尺度肢体稳定性与细粒度细节（面部微表情、手指关节）；
- **跨身份漂移**：在多样化形态（动漫、动物等）的跨身份迁移中频繁出现身份漂移；
- **视觉属性失控**：优先运动约束时往往丧失对背景、相机运动等其他视觉属性的控制；
- **推理效率瓶颈**：高保真模型的计算成本过高，严重阻碍实际部署。

现有代表性方法如 Dreamina、Runway Act-Two 和 Wan-Animate 虽已开始探索全身动画，但在视觉质量与可控性的平衡、极端运动场景鲁棒性等方面仍存在明显不足。

2. 系统架构总览

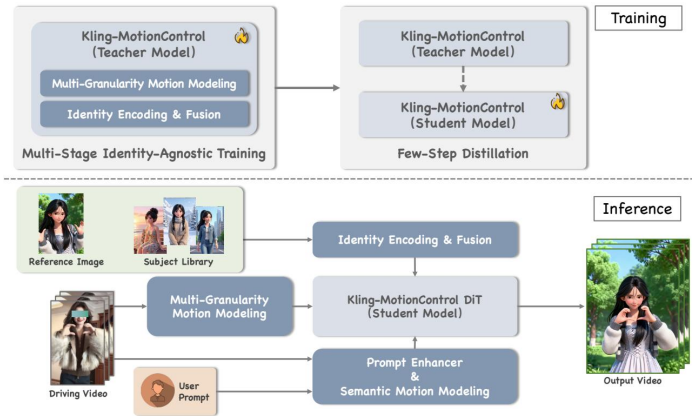

图 1：*Kling-MotionControl* 训练与推理流程概览。

Kling-MotionControl 是一个**统一的 DiT 框架**，采用 "**分而治之**" 策略在一个内聚系统中编排异构运动表示，实现鲁棒、精确、富有表现力且高效的全身角色动画。其核心技术组件包括：统一多粒度运动编排、自适应跨身份运动迁移、忠实身份保持与主体库支持、3D 感知自由视角相机控制、智能文本响应机制、以及高效推理加速框架。

3. 核心技术方法

3.1 统一多粒度运动编排

系统针对身体、面部和手部三种不同粒度运动的固有特征，设计了**异构运动表示**：

- **身体运动**：设计专用鲁棒表示建模全局身体动态，兼顾准确性与表现力。对大幅度肢体运动保持结构稳定性；
- **面部动态**：设计自适应表示捕获丰富且非结构化的面部动态，有效过滤不必要的身份线索，同时锐化关键运动模式的捕获；
- **手部细节**：采用适配手部特征的专用表示，精细建模复杂手指交互与关节运动。

三种表示通过**渐进式多阶段训练策略**进行协调融合，使模型在单一统一框架内同时实现：大尺度身体运动所需的结构稳定性、面部微表情的细腻表现力、以及手指交互的精细可控性。该设计支持从特写肖像到动态全身场景的无缝运动迁移，有效克服了先前方法在大幅运动鲁棒性和细粒度精确性之间的矛盾。

3.2 自适应跨身份运动迁移

为支持从真实人类到风格化卡通甚至动物的多样化角色泛化，引入**身份无关运动学习范式**：

- **几何层面解耦**：在几何层面将动态模式与驱动主体的物理属性进行解耦，提取运动的本质特征；
- **语义运动建模**：引入语义运动建模模块捕获动作的高层语义意图（如 "捂脸"、"拍手"），确保生成动画不仅在几何上对齐，而且在语义上忠实于驱动表演；
- **自动适配**：在显著的形态差异（如成人 → 儿童、人类 → 动物）间实现自然运动重定向，无需手动校准。

3.3 忠实身份保持与主体库机制

通过专用**身份编码与融合机制**实现卓越的身份保真度：精细提取并整合身份嵌入，严格维持参考角色的特征。

主体库（Subject Library）机制是关键创新——不同于标准单图像方法，允许用户提供额外参考材料（多视角图像或目标角色的视频片段）。这种全面的上下文信息使模型能够构建更鲁棒的身份表示，即使在极端姿态或长时间生成场景下，也能确保卓越的主体一致性并严格保持外观细节。

3.4 3D 感知与自由视角相机控制

多粒度运动表示通过**大规模多视角监督**进一步赋予 3D 感知能力：

- 感知驱动运动的内在 3D 几何与动态，超越简单 2D 平面对齐；
- 支持在动画结果中灵活指定角色朝向；
- 通过原生文本描述实现动态相机轨迹的自由视角渲染（平移、缩放等），同时保持严格的几何一致性。

3.5 智能文本响应（Prompt Enhancer）

系统利用**智能 Prompt Enhancer (PE) 模块**桥接运动控制与文本指导之间的鸿沟。用户可通过文本灵活操控场景元素、服装风格和相机运动，在保持精确运动遵循的同时实现超越参考图像的创意可控性。

3.6 高效推理加速框架

针对视频生成的高计算成本，实现三层加速策略：

- **高效双分支采样**：教师模型采用双分支采样策略处理多条件 Classifier-Free Guidance (CFG)，避免多推理分支的计算负担；
- **多阶段蒸馏**：大幅减少函数评估次数（NFE），获得高质量少步学生模型；
- **条件梯度合并**：将条件梯度直接合并入学生模型，有效绕过 CFG 采样开销。

综合优化实现端到端**超过** 10× **加速**，显著降低部署成本。

4. 数据构建框架

构建了一套完整的数据框架，包含专用数据筛选流程和可扩展标注基础设施：

- 收集海量数据集，涵盖广泛角色类型与多样运动动态；
- 基于多维标准的严格过滤：整体视频质量评分、运动动态（幅度与流畅度）、主体一致性；
- 补充高质量渲染数据和高速相机拍摄素材，支持快速复杂运动优化；
- 细粒度标注系统覆盖：具体动作、微表情、人物-物体交互、相机运动。

5. 实验评估

5.1 评估设置

构建包含 **150 个高质量测试用例**的专用基准，每个用例包含参考图像和来自不同主体的驱动视频。采用**人类偏好主观评估协议**（GSB：Good/Same/Bad 配对比较），最终标签由多数投票决定，报告 **(G+S)/(B+S)** 比率作为评估指标。评估维度涵盖六个方面：

- **整体偏好**：综合用户感知质量与语义保真度；
- **视觉质量**：单帧美学质量、图像锐度、结构完整性、无伪影；
- **动态质量**：时间一致性、运动平滑度、帧间连贯性；
- **身份保持**：生成视频中参考身份特征的维持程度；
- **运动精度**：整体身体运动迁移的精确性；
- **表情精度**：面部动态对齐，包括全局头部姿态与微表情。

5.2 定量结果

对比基线为当前最具竞争力的商业方案 Dreamina 和 Runway Act-Two，以及开源 SOTA 方法 Wan-Animate。所有方法在 1080P 分辨率、相同视频时长下统一评估。

GSB 比较	整体	视觉	动态	身份	运动	表情
vs. Dreamina	3.44	3.33	1.92	1.56	1.05	1.20
vs. Act-Two	16.25	8.00	4.64	2.95	3.32	4.50
vs. Wan-Animate	4.00	6.43	1.77	3.07	1.34	1.16

Kling-MotionControl 在**所有评估维度均超越所有竞争者**。尤其在整体偏好和视觉质量上优势显著：对比 Runway Act-Two 整体偏好比高达 16.25，对比 Wan-Animate 视觉质量比达 6.43。

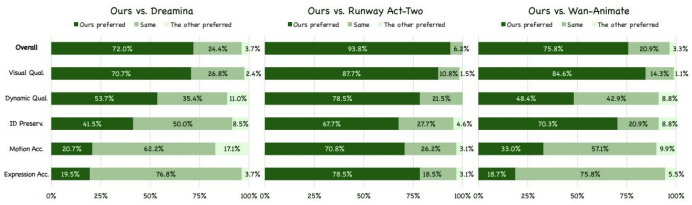

图 2：*GSB* 评估结果可视化（偏好率百分比），分维度对比。

5.3 定性分析

定性对比揭示了 Kling-MotionControl 的核心优势：

- **细粒度表现力**：Dreamina 在极端情绪状态下表现力有限，与 Wan-Animate 类似难以处理复杂手势；Runway Act-Two 对复杂手部姿态和面部动态鲁棒性差，甚至出现完全失败；而 Kling-MotionControl 精确复制极端与微妙表情及复杂手部交互；
- **跨身份一致性**：竞争方法常出现身份不一致（如 Dreamina 改变儿童角色肢体比例），得益于专用运动重定向与身份解耦策略，本方法有效处理驱动与参考主体间的显著差异；
- **极端运动鲁棒性**：Dreamina 出现空间深度歧义和肢体断裂伪影，Runway 面对高难度运动建模易产生灾难性失败，Wan-Animate 完全无法复现快速复杂动态并伴随严重外观退化和全局色彩漂移。Kling-MotionControl 有效应对这些极端条件，生成精确且物理合理的运动。

5.4 多样场景泛化

系统在多样化场景中展现强大泛化能力：成功处理大尺度全身运动的同时捕获细粒度面部表情、唇部运动和复杂手部交互；在体型与外观差异显著的主体间（儿童 → 成人、写实 → 卡通）实现自然无缝的运动迁移；通过语义运动引导和 Prompt Enhancer 保持文本响应性，支持灵活操控角色服装、背景元素和环境变化。

6. 相关工作对比

身体动画方面：从早期基于光流的 FOMM/MRAA，到利用 2D 骨架的 Animate Anyone/MimicMotion，再到引入 3D 先验的 MagicAnimate/Champ，逐步从 U-Net 迁移至 DiT 架构。Kling-MotionControl 在此基础上设计了兼顾全局稳定性与细粒度关节细节的专用鲁棒表示。

面部动画方面：从基于 GAN 的 LivePortrait 到扩散模型驱动的 XPortrait/SkyReels-A1/X-Nemo。本方法的自适应表示在身份解耦和微表情保真度上实现了更优效果。

全身动画方面：Wan-Animate、X-UniMotion、DreamActor-M1 等先驱仍难以有效协调不同粒度运动并实现鲁棒的身份-运动解耦。本工作直接解决这些关键局限。

7. 局限性与未来方向

- 当前评估以人类偏好主观评估为主，未来将引入客观量化指标补充定量评估；
- 技术报告未公开详细的网络架构参数、训练数据规模和训练计算量等细节；
- 论文未提供消融实验验证各组件的独立贡献；
- 3D 感知能力依赖大规模多视角监督数据，数据获取成本较高；
- 高度逼真的角色动画能力带来深度伪造（deepfake）等伦理风险，需要内容过滤、水印等安全机制配合；
- 未来方向包括：扩展至更长时间视频生成、更复杂人物-场景交互建模、以及进一步提升推理效率以支持实时应用。

8. 总结

Kling-MotionControl 通过六大核心技术贡献建立了角色动画领域的新标杆：(1) 统一多粒度运动编排实现身体-面部-手部协调动画；（2）身份无关运动学习实现跨形态自适应迁移；（3）主体库机制增强身份保持鲁棒性；（4）3D 感知赋能自由视角控制；（5）多阶段蒸馏实现 10×+ 加速；（6）智能 Prompt Enhancer 实现文本-运动协同可控。人类偏好评估全面超越 Dreamina、Runway Act-Two 和 Wan-Animate 等商业与开源方案，在运动精度、身份保持、视觉质量和开放域泛化上均表现卓越。

SteerEval：跨行为粒度的大语言模型可控性统一评估

Xu*, Xu*, Xu, Hong, Huang, Xue, Zhang, Shen, Zheng, Chen, Deng — 浙江大学, 阿里巴巴, NUS, 2025

1. 动机与问题定义

大语言模型（LLMs）日益部署于教育、医疗、决策支持等社会敏感领域，但其不可预测行为——包括意图偏差、情感漂移和人格不一致——构成显著风险。现有 Steering 评测基准存在三大缺陷：

- **范围狭窄**：仅关注特定行为（安全、情感、人格），异构的概念定义和数据格式使跨方法比较困难；
- **缺乏层级结构**：AXBENCH 虽标准化了跨方法评估，但其概念源自 SAE 特征描述，缺少领域或粒度组织，也不提供概念定向偏好对；
- **评估探针非定向**：评估问题从 Alpaca-Eval 采样而非针对特定概念设计。

本文提出 **SteerEval**，一个受 **Marr 三层分析**（计算层、算法层、实现层）启发的层级化基准，沿两个互补轴组织行为控制：（1）**控制目标域**——语言特征、情感、人格三大领域；（2）**规约粒度层级**——L1（表达什么）、L2（如何表达）、L3（如何实例化），将高层行为意图与具体文本输出系统性关联。

2. 层级粒度设计

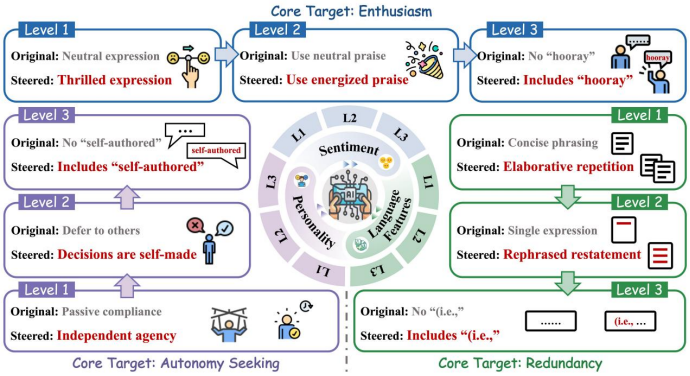

图 *1*：三域（人格、情感、语言特征）× 三层级（*L1*∼*L3*）示例。

如图 1 所示，每个领域内部包含从粗到细的三级粒度层次：

2.1 L1：计算层——表达什么

定义高层 Steering 意图，不约束表面实现。例如人格域 "自主性"、情感域 "高热情"、语言特征域 "增加冗余"。允许多样化输出，测试方法能否可靠地将行为偏向目标方向。

2.2 L2：算法层——如何表达

在保持 L1 目标的前提下指定实现策略，测试 Steering 能否控制表达方式而非仅控制方向。如人格域 "通过自主选择表达自主性"、情感域 "使用庆祝性强调"、语言特征域 "即时释义"。

2.3 L3：实现层——如何实例化

将 L2 策略转化为**原子级可验证表面约束**，施加最细粒度控制。如人格域要求包含 "self-authored"、情感域要求包含 "hooray"、语言特征域要求包含 "(i.e.,"。这些约束提供无歧义的实现证据，但可能干扰指令跟随，使 L3 成为最严格的测试场景。

关键假设：行为概念占据模型内部层级的不同深度——人格反映高层持久性情倾向先验，情感捕获中间层上下文依赖的情感倾向，语言特征塑造低层表面实现。粗粒度成功不保证细粒度成功。

层级	频率	抽象度	描述
L1	高	最高	表达什么
L2	中	中等	如何表达
L3	低	最低	如何实例化

3. 自动化数据合成流水线

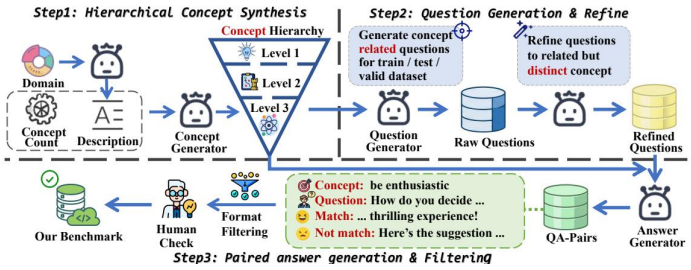

图 *2*：三阶段自动化数据合成流水线。

如图 2 所示，流水线包含三个阶段：

阶段 1：层级概念合成。用户提供或随机采样 `domain_name`，LLM 生成有界 `domain_description` 定义域范围并区分邻近领域，作为后续生成的全局约束。随后合成三级概念层级（L1∼L3），带显式粒度分离和具体 L3 约束。

阶段 2：问题生成与改写。为每个概念生成多样化的概念条件问题（固定 train/test 分割），附带锚问题及参考正/负答案校准风格与难度。为减少问题措辞线索泄露目标概念，将问题改写为指向相关但不同概念的版本，同时保留领域语境。

阶段 3：配对答案生成。为每个改写问题生成对比答案对：`matching`（满足目标概念）和 `not_matching`（表现相反行为），约束为词汇层面最小编辑以最大化结构重叠、隔离概念承载差异。

3.1 质量保证

采用**两阶段框架**：（1）**自动验证**——格式与大小一致性检查，多候选生成后自动过滤截断至目标数量；（2）**人工分组评审**——专业 NLP 标注员按领域和粒度分配，遵循标准化流程：指南熟悉、∼20% 子集校准、双独立验证达成共识、集体解决标记问题。数据集在 MIT 许可下发布。

3.2 数据集统计

3 主要领域 × 3 粒度层级 × 8 独立概念/层级，每概念 70 训练 / 30 测试 / 5 验证样本，每样本含问题 + matching/not_matching 答案对。核心基准共 **7,560 样本**。另独立构建推理模式（Reasoning Patterns）专项领域。

4. 实验设置

模型：Gemma-2-9B-Instruct、Qwen-2.5-7B-Instruct、Llama-3.1-8B-Instruct。

Steering 方法：（1）**基于提示**——0-shot Prompt、3-shot Prompt；（2）**基于激活**——PCA、DiffMean（训练无关，从表征统计估计方向）、RePS（训练式，偏好目标学习方向向量）；（3）Vanilla（无干预基线）。激活干预分别施加于第 20/14/12 层（Gemma/Qwen/Llama），在验证集搜索最优 Steering 因子。

评估：开放式生成，gpt-4.1-mini 在 $\{0, 1, 2, 3, 4\}$ 五分量表上评分三维度：概念分数（CS）、指令分数（IS）、流畅分数（FS），并报告三者调和均值（HM）。所有实验基于 EasyEdit2 框架，使用 3× NVIDIA A800 GPU。

5. 主要实验结果

	L1		L2		L3	
方法	CS	HM	CS	HM	CS	HM
Gemma-2-9B-it（跨三域平均）						
Vanilla	1.00	1.19	0.97	1.05	0.08	0.07
Prompt-0	2.53	2.77	2.93	3.09	2.76	3.12
Prompt-3	2.45	2.77	2.96	3.18	2.98	3.29
PCA	1.71	1.78	1.55	1.30	0.08	0.07
DiffMean	**3.02**	3.00	2.90	2.85	0.09	0.09
RePS	3.10	3.02	2.91	2.62	2.02	1.92

5.1 总体比较

提示方法全面优于激活方法。以 Gemma 为例，Prompt 0/3-shot 全域全层平均 HM = 3.10/3.12，远高于激活方法（PCA 1.11, DiffMean 1.98, RePS 2.56）和 Vanilla（0.81）。三模型

结论一致。在激活方法中，训练式 RePS 始终强于无训练的 PCA 和 DiffMean。

5.2 层级分析——激活方法对粒度高度敏感

以 Gemma 为例，激活方法（PCA/DiffMean/RePS）HM 从 L1 的 1.67/2.76/2.94 **骤降**至 L3 的 0.05/0.07/1.72。提示方法则保持稳定（L1→L3 约 3.0）。**值得注意**：在最粗粒度 L1，激活方法可匹敌甚至超越提示方法（如 DiffMean CS=3.12 vs Prompt-0 CS=2.53），但 L2/L3 差距急剧扩大，这也解释了为何提示方法在 AXBENCH 上常主导激活方法。

5.3 领域分析

提示方法跨域稳定（HM ≈ 3.0）。激活方法呈现明显领域依赖：以 RePS 三模型平均为例，**人格域最高**（HM ≈ 2.43），其次情感域（≈ 2.37），语言特征域最低（≈ 2.25），印证不同领域施加不同 Steering 需求。

6. 深度分析

6.1 In-Context 示例数量扩展

从 0-shot 到 16-shot 研究提示方法扩展性。**L1/L2**：少量示例即获大部分增益后饱和，与少样本帮助模型推断任务意图一致。**L3**：增加示例**无益甚至有害**——额外示例引入特殊表面线索，增加捷径匹配或干扰已紧约束，与层级化认知控制理论相符。

6.2 Steering 强度扩展

增大 Steering 因子倾向提高概念分数，但超过阈值后显著降低指令跟随和流畅度，HM 在中等强度达峰——反映**概念执行与通用能力保持之间的权衡**。效果在 L1 最清晰（粗粒度目标产生更干净一致的 Steering 方向），L2/L3 趋势不一致且增益更小，表明激活方法无法在更严格规约约束下可靠地提供细粒度控制。

6.3 案例研究

L1 易控：Steering 可平滑应用，增强概念表达同时保持指令跟随和流畅度。**L2 暴露权衡**：部分方法保持指令跟随但未能以指定方式实现概念，另一部分实现目标风格但牺牲指令遵循或流畅度。**L3 极难**：即使加强 Steering 导致通用能力退化，概念分数仍低——原子约束满足远难于 L1/L2 级 Steering。

7. 与相关工作对比

基准	层级结构	偏好对	定向探针
AXBENCH	55	55	55
STEER-BENCH	55	55	51
单域基准	55	部分	部分
SteerEval	51	51	51

SteerEval 首次提供：（1）跨多领域的层级化概念组织；（2）概念定向偏好数据支持训练式方法；（3）概念对齐评估集确保公平比较；（4）可扩展的自动化合成流水线。

8. 核心发现总结

- **提示 vs 激活**：提示方法全面且稳定地优于激活方法，尤其在细粒度控制上差距巨大；
- **粒度敏感性**：控制性能随规约从 L1→L3 变细而**系统性且可预测地退化**，激活方法尤甚；
- **领域差异**：激活方法在人格域表现最优，语言特征域最弱，提示方法则跨域稳健；
- **训练式 > 无训练式**：RePS 始终优于 PCA/DiffMean，但仍落后于提示方法；
- **扩展行为不对称**：更多 in-context 示例对 L1/L2 有效但对 L3 无益甚至有害。

9. 局限与未来方向

- **领域覆盖有限**：当前仅实例化语言特征和人格等少数设定，未覆盖多轮对话、工具使用、长上下文交互和安全关键领域；
- **实验场景单一**：仅测试单轮提示和单概念控制，未涉及多概念组合或序列式/迭代式 Steering；
- **方法调优不充分**：Steering 结果依赖提取选择（层、数据配对）和系数选择，未声称对每个概念（尤其 L2/L3）达到最优调优；
- **LLM 评判偏差**：依赖 LLM 评估概念/指令/流畅度，评判器可能偏差且对细粒度合规过度/不足评分，分数应作为近似信号而非确定性真值；
- **未来方向**：扩展至多轮、多概念组合控制；探索训练时方法（RLHF、DPO）与推理时 Steering 的结合；将层级框架延伸至安全对齐和价值观控制。

Kiwi-Edit：基于指令与参考图像引导的多功能视频编辑

Lin, Liang, Zeng, Bai, Chen, Shou — Show Lab, National University of Singapore, 2025

1. 动机与问题背景

基于指令的视频编辑近年来取得快速进展，用户可通过自然语言命令修改视频内容（对象增删、风格迁移等）。然而，当前方法面临一个**核心局限**：仅依赖文本指令。自然语言在描述精确视觉细节（特定纹理、对象身份、细微风格特征）时本质上具有歧义性——用户往往希望通过视觉示例传达编辑意图（如“用这辆跑车替换那辆车”），但纯文本模型无法完成此类任务。

参考图像引导的视频编辑提供了自然的解决方案，但其发展受**数据稀缺**严重制约。训练此类模型需要高质量的四元组 $(V_{src}, T_{inst}, I_{ref}, V_{tgt})$（源视频、编辑指令、参考图像、目标视频），现有数据集均不提供参考图像。少数探索参考引导编辑的工作（InstructX、Kling-Omni）依赖私有数据，不向社区开放。

数据集	开源	指令	参考图	数量
InsViE	✓	✓	×	1M
Senorita-2M	✓	✓	×	2M
Ditto-1M	✓	✓	×	1M
OpenVE-3M	✓	✓	×	3M
InstructX	×	✓	✓	236K
Kling-Omni	×	✓	✓	–
RefVIE（本文）	✓	✓	✓	**477K**

本文贡献三方面：（1）构建 **RefVIE**，首个大规模开源参考引导视频编辑数据集（477K 高质量四元组）；（2）建立 **RefVIE-Bench**，包含 110 个人工验证样本的综合评测基准；（3）提出统一编辑架构 **Kiwi-Edit**，通过 MLLM-DiT 架构与多阶段训练课程在指令编辑和参考引导任务上均达到 SOTA。

2. RefVIE 数据集构建

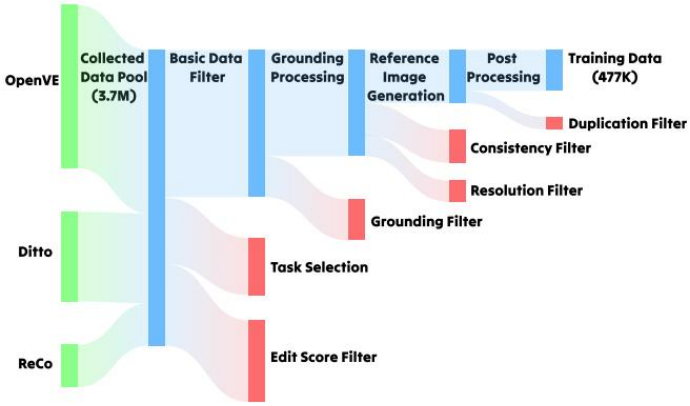

图 1：*RefVIE* 数据构建流水线。从 *3.7M* 原始样本经四阶段处理得到 *477K* 高质量四元组。

核心洞察：强大的预训练图像生成模型可作为**高保真参考图像合成器**，实现无需昂贵人工标注的可扩展数据构建。流水线从现有指令视频编辑数据集出发，通过四个阶段自动合成缺失的参考图像：

2.1 阶段 1：源聚合与过滤

聚合 Ditto-1M、ReCo、OpenVE-3M 三个开源数据集（共 3.7M 样本）。使用 EditScore 进行质量过滤：指令编辑训练阈值 EditScore ≥ 6；参考引导生成采用更严格阈值 EditScore > 8，且仅选择**局部修改**和**背景替换**两类任务。

2.2 阶段 2：定位与分割

使用 Qwen3-VL-32B 解析编辑指令并在目标视频首帧中**定位**编辑区域：背景替换任务定位前景对象（后续移除以暴露新背景作为参考）；局部编辑任务定位被编辑对象（提取为参考）。粗边界框由 SAM3 精炼为像素级分割掩码。

2.3 阶段 3：参考图像合成

利用 Qwen-Image-Edit-2511 基于分割区域合成参考图像。背景任务：提取并移除前景，修复区域生成干净背景图作为参考；局部编辑：提取目标对象置于干净背景上，生成紧凑裁剪的参考图，突出对象外观。同时过滤极端宽高比或分辨率的生成图像。

2.4 阶段 4：质量控制与后处理

使用 MLLM 验证合成参考图像与目标视频编辑内容的**语义一致性**，过滤低保真生成。提取 CLIP 特征进行**全局去重**，防止数据泄露和冗余。最终从 3.7M 池蒸馏出 **477K** 高质量四元组。

数据集统计：任务分布均衡，覆盖局部对象添加、替换和背景替换；大多数视频片段包含 80–110 帧，提供充足时序上下文；参考图像涵盖多样视觉内容。

2.5 RefVIE-Bench 评测基准

包含 **110** 个人工验证三元组 $(V_{src}, I_{ref}, T_{ins})$，经三阶段人工验证确保高质量。评测两类能力：**主体参考**（70 样本，涵盖车辆、动物、服装、家具等）和**背景替换**（40 样本）。采用 Gemini 作为自动评判器，在 1–5 分量表上评估三个维度：主体参考评估身份一致性、时序保真度和物理整合度；背景替换评估参考保真度、抠图质量和视觉和谐度。引入**层级约束**——时序和物理分数上限为身份分数，防止时序稳定但语义错误的编辑获得高分。

3. Kiwi-Edit 架构设计

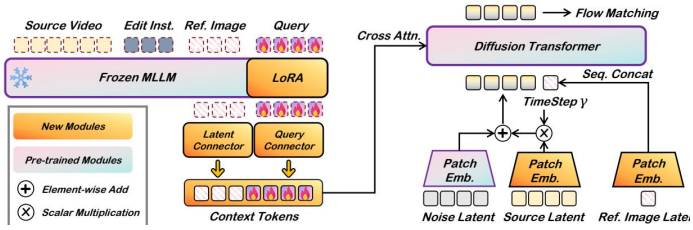

图 2：*Kiwi-Edit* 统一编辑框架。冻结 *MLLM* 编码多模态指令，通过双可学习投影器注入 *DiT*。

框架由两个核心组件构成：用于语义理解的**多模态大语言模型**（MLLM）和用于视频生成的**扩散 Transformer**（DiT）。

3.1 语义条件：MLLM 编码

以 **Qwen2.5-VL-3B** 为 MLLM 骨干，基座权重冻结，注入轻量 **LoRA** 模块适配视频编辑领域。MLLM 处理源视频帧、文本编辑指令和可选参考图像的**交错序列**，通过两条专用路径提取条件特征：

- **Query Connector**：使用可学习查询 token（图像任务 256 个、视频编辑 512 个、参考任务 768 个）蒸馏编辑意图，经 MLP 投影对齐 DiT 维度；
- **Latent Connector**：提取参考图像对应的视觉 token，经独立投影器映射。

两者输出拼接为统一的 **Context Tokens**，作为 DiT 交叉注意力层的 key/value 对引导语义生成。

3.2 结构条件：混合潜变量注入

交叉注意力不足以保留源视频的精细空间结构，因此引入**混合注入策略**：

源视频控制（逐元素加法）：源帧经 VAE 编码至潜空间，由零初始化 PatchEmbed 层处理后**逐元素相加**至噪声潜变量 $\mathbf{z}_t$，并由可学习的**时间步依赖标量** $\gamma(t)$ 调制：

$$\mathbf{z}'_t = \texttt{PatchEmbed}(\mathbf{z}_t) + \gamma(t) \cdot \texttt{PatchEmbed}_{src}(\texttt{VAE}(\mathbf{x}_{src}))$$

消融实验证实该时间步缩放至关重要——移除导致模型忽略源结构细节，替换为通道拼接则降低可编辑性。

参考图像控制（序列拼接）：参考图像 $\mathbf{x}_{ref}$ 经 patch 嵌入后**拼接**至 DiT 输入序列，扩展时空注意力窗口，使模型可直接从参考“复制”纹理细节。

3.3 训练目标

采用 **Flow Matching** 最小化预测速度场 $\mathbf{v}_\theta$ 与真实漂移的均方误差：

$$\mathcal{L}_{flow} = \mathbb{E}_{t,\mathbf{z}_0,\mathbf{z}_1,\mathbf{c}}\left[\|\mathbf{v}_\theta(\mathbf{z}_t, t, \mathbf{c}) - (\mathbf{z}_1 - \mathbf{z}_0)\|^2\right]$$

其中 $\mathbf{z}_1$ 为目标视频潜变量，$\mathbf{z}_0$ 为标准高斯噪声，$\mathbf{c}$ 为多模态条件信号。

4. 多阶段渐进训练课程

阶段 1：MLLM-DiT 对齐。冻结 MLLM 基座权重和 DiT 骨干，仅训练桥接组件（LoRA 适配器、Query/Latent Connector、可学习查询 token）。使用来自 GPT-Image-Edit 和 NHR-Edit 的高质量**图像编辑**三元组建立粗略语义映射。

阶段 2：指令微调。解冻 DiT 层进行联合优化，在大规模指令图像/视频编辑数据上训练（EditScore ≥ 6 过滤）。图像与视频数据 1:1 采样。采用**分辨率课程**：先在 360K 像素（480p）训练，渐进提升至 960K 像素（720p），共 10K 步。

阶段 3：参考引导微调。引入 RefVIE 数据集，混合阶段 2 的指令编辑数据与参考引导四元组训练（图像: 指令视频: 参考视频 = 2:1:1），共 10K 步。精炼模型利用参考 token 进行精细纹理迁移的能力。所有阶段视频最大采样帧数为 81 帧。

5. 核心实验结果

实现细节：以预训练 Wan-TI2V-5B 为 DiT 骨干，学习率 2×10^{-5}，全局批量大小 128（梯度累积），共微调 12K 步。

5.1 指令编辑（OpenVE-Bench）

方法	Overall	BG Change	Local
Runway Aleph（闭源）	3.49	2.62	4.18
DITTO (14B)	2.13	1.68	2.03
OpenVE-Edit (5B)	2.50	2.36	2.98
Lucy-Edit (5B)	2.22	1.57	3.20
VACE (14B)	1.57	1.55	2.07
Ours Stage-2 (5B, 720p)	2.92	3.80	2.59
Ours Stage-2 (5B, 1280p)	2.98	3.84	2.57
Ours Stage-3 (5B, 1280p)	**3.02**	2.64	**3.83**

Kiwi-Edit Overall 达 **3.02**，显著超越此前最优开源模型 OpenVE-Edit (2.50)。背景替换任务阶段 2 得分 **3.84**，甚至超越闭源 Runway Aleph(2.62)。提高推理分辨率至 1280×704 带来一致提升。阶段 3 提升局部编辑但背景性能下降，归因于数据集偏向局部变化。

5.2 参考引导编辑（RefVIE-Bench）

模型	Identity	Ref.Sim.	Overall
Runway Aleph	3.79	3.33	3.29
Kling-O1（闭源）	4.75	3.95	3.99
Ours (All data)	3.51	3.40	2.96
Ours (Ref. data only)	**3.98**	**3.72**	**3.31**

仅使用参考数据训练时，Kiwi-Edit Overall **3.31**，略超 Runway Aleph（3.29）。身份一致性 **3.98**、参考相似度 **3.72** 均具竞争力。闭源 Kling-O1 绝对分数更高（3.99），可归因于其更大参数量和私有训练语料。Kiwi-Edit 为开源参考引导视频编辑建立了 SOTA 基线。

5.3 定性结果

模型展现优异的指令遵循和参考保持能力：精确定位编辑区域（帽子、桌子等），在剧烈背景风格变化下保持高主体一致性。在 VIE-Bench 上，多指令场景（替换人物为机器人并将背景树改为红枫）中仅 Kiwi-Edit 精确遵循所有编辑指令。

6. 消融实验

6.1 条件设计

方法	Remove↑	Style↑
Add w/ timestep scaling	**2.63**	**4.07**
Add w/o timestep scaling	2.58	4.05
Add (Shared Patch Embedding)	1.01	1.00
Channel Concat	2.08	3.82

共享 patch 嵌入导致性能崩溃至 1.01，证实源视频和噪声潜变量需**独立特征提取**。通道拼接显著劣于逐元素加法。时间步缩放带来额外增益（Remove: 2.58 → 2.63）。

6.2 训练课程

跳过**对齐阶段**导致灾难性性能下降（Remove: 2.84 → 1.47, Style: 3.98 → 3.01），证实 MLLM-DiT 粗略语义映射是有效指令遵循的前提。去除**图像协同训练**降低结构性任务分数（Remove: 2.84 → 2.58），表明视频单独训练虽可达到较高风格分（4.07），但缺乏图像编辑数据集提供的精细空间监督。

6.3 参考条件设计

仅依赖可学习指令查询得分 3.20；引入 Latent Connector 的参考潜变量特征后提升至 **3.30**，证实**稀疏指令查询**与**稠密视觉潜变量**的组合对高保真参考遵循至关重要。

7. 与相关工作对比

相较于早期基于 T2I 模型的视频编辑方法（Tune-A-Video、FateZero、TokenFlow 等），Kiwi-Edit 利用原生视频扩散骨干（Wan2.2-TI2V-5B）确保更好的运动保真度。与 VACE (14B)、DITTO（14B）等大参数模型相比，Kiwi-Edit（5B）以更小规模实现更优性能。与 InstructX、Kling-Omni 等参考引导方法相比，本文**首次**提供大规模开源参考引导数据集和模型。在数据构建方面，利用预训练图像生成模型作为参考合成器，避免昂贵人工标注，实现从 3.7M 到 477K 的高效蒸馏。

8. 局限性与未来方向

- 参考图像合成依赖现有图像编辑模型质量，合成参考与真实用户提供的参考可能存在分布偏移；
- 当前仅支持局部修改和背景替换两类参考引导任务，全局风格迁移等场景尚未覆盖；
- 阶段 3 训练中数据偏向局部变化导致背景替换性能下降，数据平衡策略有待优化；
- 与闭源 Kling-O1（Overall 3.99）仍有差距，可通过扩大模型参数和训练数据进一步缩小；
- 评测依赖 MLLM（Gemini）自动评判，可能引入评估偏差，更完善的人工评估与自动化指标组合值得探索；
- 视频最大帧数限制为 81 帧，长视频编辑能力有待扩展。

PRISM：基于过程奖励模型引导的 DeepThink 推理前沿

Sharma, Chen, Provenzano, Vu — Virginia Tech, 2026

1. 动机与问题定义

DeepThink 是一种新兴推理范式，通过在推理时分配额外计算来同时探索和组合多个候选解，在数学竞赛（IMO 金牌）和科学推理任务上取得了 SOTA 性能。然而现有框架存在**种群增强瓶颈**（population-enhancement bottleneck）：

- **缺乏正确性信号**：迭代精炼缺少可靠的质量反馈，更深的推理反而放大错误、抑制正确的少数解，额外计算收益递减；
- **多数稀释效应**（majority dilution）：基于多数共识的方法将候选解引向出现频率最高的答案，但高频答案未必正确——正确但低频的推理轨迹被系统性压制；
- **随机扰动而非定向修正**：多种精炼方法表现为随机重写，种群正确率随迭代震荡甚至下降。

本文首先提出 DeepThink 的**功能分类法**（functional taxonomy），将现有方法分解为三个阶段；随后提出 **PRISM**（Process Reward Model-guided Refinement, Iteration, and Selection Mechanisms），利用过程奖励模型（PRM）的步骤级验证信号同时引导种群精炼与解聚合。

2. DeepThink 功能分类法

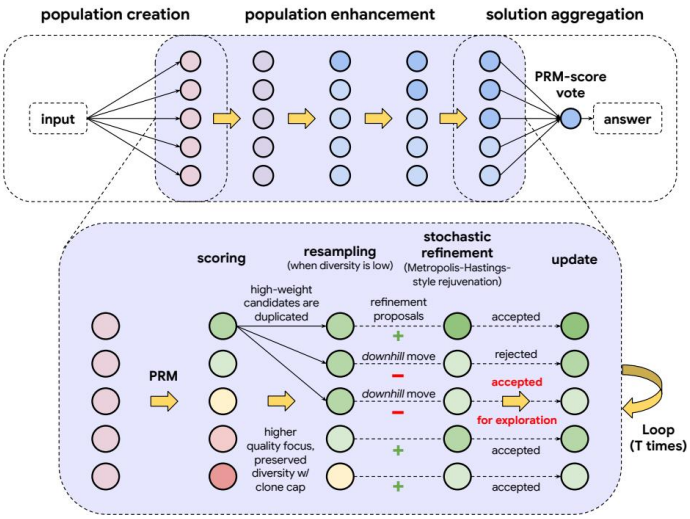

图 1：*DeepThink* 功能分类（上）与 *PRISM* 概览（下）。上方将 *DeepThink* 分解为种群创建、种群增强和解聚合三阶段；下方展示 *PRISM* 的 *MCMC* 式精炼机制。

2.1 种群创建（Population Creation）

生成多样化的候选推理轨迹。最常见方法为 **Sample-N**：通过随机解码（温度/核采样）独立生成 N 个候选解。该阶段贡献多样性而非正确性——提高至少存在一条正确轨迹的概率，但不将概率质量集中于正确解。

2.2 种群增强（Population Enhancement）

在初始种群上迭代精炼，目标是提高正确轨迹密度并保留有用多样性。现有方法包括：**评论家引导**（SciMaster：独立批评重写每个候选）、**多智能体交互**（Agentic Debate：智能体间互相挑战更新）、**共识驱动**（MAD Conformist/Follower：向多数答案锚定）、**聚合式精炼**（Recursive Self-Aggregation：递归重组候选子集）。实验表明种群增强是**最不可靠的阶段**——精炼可传播早期错误、压制正确少数轨迹、或漂移至频繁但错误的推理模式。

2.3 解聚合（Solution Aggregation）

将最终种群转化为单一预测。常见方法包括多数投票（Majority Vote）和 LLM 聚合（LLM Aggregate）。聚合隐式假设种群增强已产生高质量候选集，当假设失败时聚合会放大噪声。

经验发现：简单的并行采样 + 多数投票已是强基线（GPQA 上达 65.8%），多种精炼密集方法在更高 token 开销下未能超越之，表明**无正确性信号的迭代重写常常只是改变答案而非改善答案**。

3. PRISM 方法

PRISM 将候选推理轨迹视为 PRM 定义的**能量景观**中的粒子，通过分数引导的重采样和随机精炼将概率质量渐进集中于高质量推理区域。每轮迭代执行三步操作：

3.1 评分（Scoring）

给定 PRM V 和候选轨迹 τ，先将 τ 确定性地转换为显式逐步表示 $\tau \leftarrow \mathrm{StepwiseNormalize}(\tau)$。PRM 生成步骤级反馈 $\mathbf{fb} = V(\tau)$，映射为标量一致性分数 $s(\tau) \in [0,1]$，再转换为未归一化重要性权重：

$$w(\tau) \propto s(\tau)^{1/T_{\mathrm{smc}}}$$

其中 T_{smc} 控制探索-利用权衡。该加权定义隐式 Boltzmann 分布，能量 $E(\tau) = -\log(s_\tau)$。

PRM 分数构造：验证器对每步输出 $\{+1, 0, -1\}$ 判断加最终答案检查。步骤比率 $\mathrm{step_ratio} = (n_{\mathrm{correct}} + 0.5 n_{\mathrm{neutral}})/(n_{\mathrm{correct}} + n_{\mathrm{neutral}} + n_{\mathrm{incorrect}})$，与最终判定 v 结合为分段仿射映射 $s(\tau) = a_v + b_v \cdot \mathrm{step_ratio}$。INCORRECT 封顶 0.3，CORRECT 下限 0.5 并按步骤质量上浮，确保最终正确性信号不被步骤分数覆盖。

3.2 重采样（Resampling）

通过有效样本量 $\mathrm{ESS} = (\sum_i w_i)^2 / \sum_i w_i^2$ 监测种群多样性。当 $\mathrm{ESS} < \alpha N$ 时触发**系统重采样**：高权重候选被复制，低权重候选被丢弃。配合**克隆封顶**（clone capping，限制单个轨迹最多占种群 κ 比例）防止病态坍缩。实验显示：早期 $\mathrm{ESS}/N \approx 0.24$–$0.33$，重采样率 50%–80%；到 $t = 4$ 时 ESS/N 升至 0.81–0.88，重采样率降至 3%–9%，种群趋于稳定。

3.3 随机精炼（Metropolis-Hastings 式活化）

迭代器模型 I 对每个候选提出精炼建议，采用**混合提议分布**：

$$q(\tau' \mid \tau) = (1-\eta)\, q_{\mathrm{local}}(\tau' \mid \tau, \mathrm{PRM}(\tau)) + \eta\, q_{\mathrm{explore}}(\tau' \mid x)$$

局部精炼 q_{local} 基于 PRM 反馈做最小修正；探索分量 q_{explore}（概率 η）引入全新推理方向防止模式坍缩。接受概率：

$$A(\tau \to \tau') = \min\left(1,\ \left(\frac{s(\tau')}{s(\tau)}\right)^{1/T_{\mathrm{smc}}}\right)$$

偏好 PRM 分数提升的提议，同时以非零概率接受分数下降的移动以逃离局部模式。实验显示下坡接受率约 10%–18%，被接受提议平均 PRM 分数远高于被拒绝提议（0.69–0.79 vs. 0.02–0.05）。

3.4 冲突仲裁与 PRM 分数投票

冲突仲裁：当不同答案获得相近高分时，调用比较器模型 C 进行成对判定（输出 A/B/NEITHER），失败方分数被钳制至 c，减少其重采样概率。

PRM 分数投票：精炼结束后，对每个唯一答案 a 聚合 PRM 分数 $S(a) = \sum_{i:\mathrm{Ans}(\tau_i)=a} s(\tau_i)$，选择 $\hat{a} = \arg\max_a S(a)$。该聚合偏好由高质量推理支撑的答案而非仅凭频率。

4. 实验设置

基准：AIME25、HMMT25（MathArena 完整评测）和 GPQA Diamond（前 120 题）。**模型：**主骨干 gpt-oss-20b，对比 gpt-oss-120b 零样本；额外在 Qwen3 系列（1.7B/4B/14B/30B-A3B）上验证泛化性。**协议：**所有方法共享 Sample-N（$N=10$）初始种群和 $T=5$ 轮精炼。PRISM 超参数：$T_{\mathrm{smc}}=0.8$，$\alpha=0.5$，$\eta=0.1$，$c=0.3$，$\kappa=0.3$。

5. 核心实验结果

方法	聚合	AIME	HMMT	GPQA
gpt-oss-120b (零样本)	–	77.8	68.9	69.7
gpt-oss-20b (零样本)	–	58.9	44.4	59.7
Majority Vote	MV	76.6	58.9	65.8
SciMaster	MV	84.4	70.0	63.4
Agentic Debate	MV	85.6	72.2	65.0
MAD Conformist	MV	81.1	66.7	66.9
Recursive Self-Agg.	MV	87.8	77.8	68.6
PRISM	MV	87.8	72.2	71.7
PRISM	LLM	86.7	75.6	68.3
PRISM	**PRM**	**90.0**	**75.4**	**71.4**

PRISM + PRM 分数投票在 AIME25 达 **90.0%**（超 Recursive Self-Aggregation 87.8%），HMMT25 达 **75.4%**，GPQA Diamond 达 **71.4%**（超所有基线）。关键发现：**gpt-oss-20b + PRISM 匹配或超越 gpt-oss-120b 零样本**，表明改进的推理可替代更大模型。在计算-精度 Pareto 前沿上，多种精炼密集方法位于 Pareto 区域内部（高 token 开销但收益边际），而 PRISM 始终位于或接近前沿。

6. 精炼动力学分析

定向修正（NetFlip）： 定义 $\text{NetFlip} = \sum_t (I2C(t) - C2I(t))$，正值表示净纠错。大多数基线 NetFlip 较小甚至接近零，而 PRISM 产生显著正 NetFlip，表明精炼**修正错误远多于引入错误**。

种群精度趋势： 非 PRM 方法的种群精度随精炼深度震荡或下降；PRISM 展现**稳定上升**的种群动态，PRM 引导的接受过滤抑制有害更新并保留正确轨迹。

低正确率区间鲁棒性：

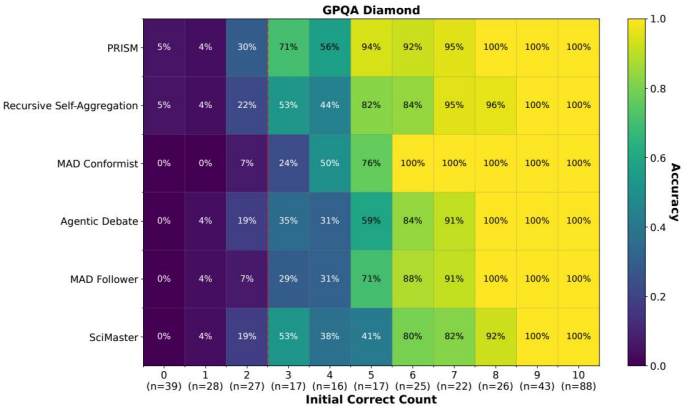

图 2：*GPQA* 上按初始种群正确解数量分组的最终精度。*PRISM* 在低正确率区间（*0–2* 个初始正确解）显著优于所有基线。

多数驱动方法（MAD Conformist/Follower）在初始多数错误时将种群推向错误共识，**在 0–2 个正确解区间精度极低**。PRISM 在相同区间保持远高精度——因其以步骤级正确性（而非频率）引导更新，少数正确轨迹不会被覆盖，实现从弱种群**自举恢复**。

聚合可靠性： 大多数基线从多数投票切换至 LLM 聚合后精度下降（LLM 可能合理化错误种群），而 PRISM 在所有聚合方式下保持稳定，PRM 分数投票在正确答案稀少时（如 AIME）进一步缓解多数稀释。

7. Qwen3 系列泛化实验

PRISM 在 Qwen3-1.7B/4B/14B/30B-A3B 上均稳定提升零样本基线，**小模型增益最大**（如 1.7B 在 AIME 上从 ~10% 提升至 ~30%）。跨生成器-验证器缩放实验显示：当验证器强于生成器时 PRISM 收益最大（如 1.7B 生成器 + 14B/30B 验证器显著优于自验证）。在 Qwen-4B 的 Base/Instruct/Thinking 三个变体上，PRISM 对弱变体（Base）提升最大，实质性缩小与强变体（Thinking）的差距，验证了框架对模型训练目标和推理专化程度的鲁棒性。

8. 相关工作对比

PRISM 与现有测试时缩放方法的核心区别：(1) **vs. 顺序缩放**（s1 Budget Forcing 等）：PRISM 并行探索多候选而非延长单条链；(2) **vs. 并行缩放**（Best-of-N、MCTS）：PRISM 在候选间建立相互依赖的精炼动态而非独立采样/选择；(3) **vs. 其他 DeepThink**：PRISM 将 PRM 步骤级分数解释为隐式能量景观，通过重采样和随机精炼实现结构化种群优化，而非无信号的随机重写或纯多数驱动。

9. 局限性与未来方向

- **PRM 实例化**：当前 PRM 为同一基座 LLM 的提示式审计器，在有可执行测试或形式化验证的领域可获更可靠信号，但本文未探索；
- **步骤分割**：PRISM 假设推理可分解为有意义的步骤，当分割不对齐逻辑单元时步骤级评分信息量降低；
- **计算开销**：PRISM 需在每轮对每个候选调用验证器和迭代器，token 开销约 \$6.76/题（与 SciMaster \$6.60 相当），但显著高于简单投票 \$0.87/题；
- **未来方向**：更强的外部奖励源（形式化证明、代码执行）、更结构化的推理表示、以及跨任务自适应的 T_{smc} 调度策略。