QZPaper Huggingface Daily

2026-03-08

1. **RoboMME：面向机器人通用策略的记忆基准与理解**
   RoboMME 构建机器人记忆基准，将记忆划分为时间、空间、物体、程序四个认知维度，包含 16 个任务。通过系统化评估，支撑机器人通用策略在历史依赖任务上的研究和比较。
2. **推理模型难以控制其思维链**
   该论文评估推理模型的思维链可控性，发现 Claude Sonnet 4.5 仅 2.7%、DeepSeek R1 低至 0.1%，远低于输出可控性。表明当前推理模型难以隐藏真实推理过程，为 CoT 监控的安全性提供保证。
3. **PSIVG：物理模拟器嵌入式视频生成**
   PSIVG 将物理模拟器嵌入视频扩散过程，通过感知流水线重建 4D 场景和物体网格，在模拟器生成物理一致轨迹后引导视频生成。实现无需额外训练的推理时物理约束，显著提升生成视频的物理合理性。
4. **DC-DiT：动态分块扩散 Transformer**
   DC-DiT 提出动态分块机制自适应压缩输入，通过 encoder-router-decoder 支架根据空间信息密度动态调整 token 分配。解决标准 DiT 中固定 patchify 导致的计算浪费，提高扩散模型效率和生成质量。
5. **PixARMesh：基于自回归 Mesh 原生表示的单视图场景重建**
   PixARMesh 基于预训练物体级自回归 Mesh 模型，融合像素对齐图像特征和全局场景上下文，在统一序列中联合预测位姿和网格。无需 SDF 或后处理，直接生成紧凑可编辑的艺术家级场景网格。

RoboMME：面向机器人通用策略的记忆基准与理解

Dai[1], Fu[1], Lee[1], Liu[2], Zhang[1], Yang[3], Finn[2], Fazeli[1†], Chai[1†] — [1]UMich, [2]Stanford, [3]Figure AI, 2025

1. 动机与问题定义

开放世界机器人操作常需对历史信息进行推理和回忆，例如将书放回原位、擦桌数次后停止、观察人类示范后折叠衣物。仅依赖即时感知的策略无法胜任这类**历史依赖**（non-Markovian）任务，因为相同的当前观测可能源自不同的历史轨迹，并要求不同的动作。

现有记忆增强方法可分为三类表征：（1）**符号记忆**——以语言子目标、点追踪轨迹等不可微抽象总结历史；（2）**感知记忆**——将历史编码为多帧视觉 token 或记忆库；（3）**循环记忆**——通过循环模型将上下文压缩为固定大小隐状态。然而这些方法使用不同的策略骨干和不一致的评估协议，难以系统比较。

现有基准亦不足：MemoryBench 仅含 3 个近乎已解决的空间记忆任务；MIKASA-Robo 任务短、示范少，不足以支撑 VLA 模仿学习。大多数通用基准（LIBERO、CALVIN 等）虽包含长时序规划，但策略仅凭当前观测即可获得高成功率，并未真正要求记忆推理。

2. RoboMME 基准

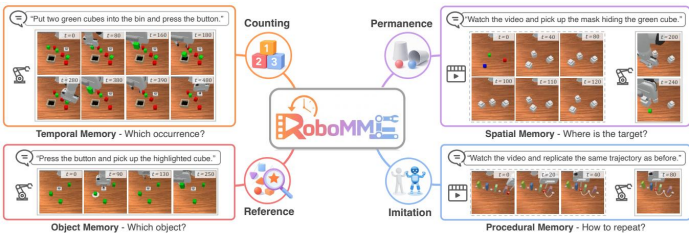

图 1：*RoboMME* 概览——四大任务套件分别考察时间、空间、物体和程序记忆。

2.1 认知驱动的任务分类

借鉴经典人类记忆理论（Atkinson & Shiffrin），RoboMME 将记忆划分为四个认知维度，对应**何时**（when）、**何处**（where）、**何物**（what）、**如何**（how）：

- **时间记忆**（Temporal）：追踪事件计数、顺序与转换条件；
- **空间记忆**（Spatial）：在遮挡和场景变化下维持物体位置；
- **物体记忆**（Object）：在时间跨度中保持指称一致性；
- **程序记忆**（Procedural）：复现先前观察到的运动模式。

2.2 四大任务套件（共 16 个任务）

Counting 套件（时间记忆）：PickXTimes（重复抓放指定次数）、BinFill（将指定数量方块放入桶中）、SwingXTimes（在两目标间往返摆动指定次数）、StopCube（在移动方块到达目标时精确按下按钮）。

Permanence 套件（空间记忆）：VideoUnmask / ButtonUnmask（方块被遮罩后根据先前观察揭开指定颜色方块）、VideoUnmaskSwap / ButtonUnmaskSwap（方块遮罩期间容器动态交换位置后揭开正确方块）。

Reference 套件（物体记忆）：PickHighlight（拾取曾短暂高亮的方块）、VideoRepick（根据视频中被操作的方块重复拾取）、VideoPlaceButton / VideoPlaceOrder（根据语言描述的时间/序号线索放置方块至视频中指定目标）。

Imitation 套件（程序记忆）：MoveCube（复现推/抓/钩三种操作策略）、InsertPeg（按相同方向插入钉子）、PatternLock（复现线性运动模式）、RouteStick（复现圆形绕行轨迹）。

2.3 数据构建

基于 ManiSkill 仿真器，7-DOF Franka Panda 桌面环境。观测包含前置和腕部相机 RGB 图像（256×256）及本体感知。动作空间为 8D 关节空间或 7D 末端执行器空间。通过关键帧回放生成密集轨迹，注入 5% 噪声促进失败恢复多样性。按场景杂乱度、时间跨度和环境动态分为 easy/medium/hard 三级。最终包含 **16 个任务 × 100 集 = 1,600 个示范**，共 **770k 高质量时间步**，单集从数百到逾千步不等。

RoboMME 是首个同时覆盖四种记忆类型、具备 non-Markovian 结构、部分可观测性和动态场景变化，并提供视频条件输入与语言子目标标注的操作基准。

3. MME-VLA 策略族

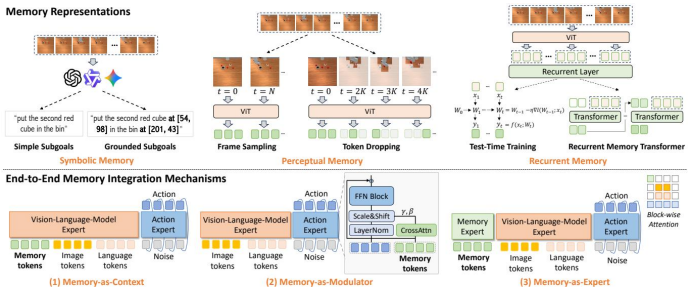

图 2：*MME-VLA* 套件框架——三种记忆表征 × 三种集成机制。

所有模型基于 $\pi_{0.5}$ 骨干（VLM expert + Action expert 的多专家 Transformer，采用 flow matching 训练），统一分配 **512 token** 记忆预算 $\mathbf{M}_t \in \mathbb{R}^{B\times d}$。

3.1 三种记忆表征

符号记忆（Symbolic）：由辅助 VLM 根据当前图像和历史子目标生成下一语言子目标，分为 SimpleSG（纯文本）和 GroundSG（附加图像坐标），由 Gemini-2.5-Pro、微调 Qwen3-VL-4B 或仿真器 Oracle 生成。

感知记忆（Perceptual）：保留历史视觉 token。两种实例化：（1）**FrameSamp**——均匀采样历史帧并通过 MaxPool 降维（16×16 → P tokens/view）；（2）**TokenDrop**——基于相邻帧 RGB 差异的时间显著性评分保留 top-B token，使用 M-ROPE 保持时空结构。

循环记忆（Recurrent）：（1）**RMT**——维护 B 个持久记忆槽，逐 chunk 与观测 token 交叉注意力更新；（2）**TTT**（Test-Time Training）——通过自监督梯度步在线更新快权重 $W_t = W_{t-1} - \eta\nabla_W \ell_{\text{aux}}$，将历史隐式存储于参数空间。

3.2 三种集成机制

Memory-as-Context：将记忆 token 直接拼接至 VLM 输入 $\mathbf{u}_t = E_{\text{vlm}}([\mathbf{M}_t; \mathbf{o}_t; \ell])$。

Memory-as-Modulator：在 Action Expert 每层 MLP 前，action 特征通过多头注意力交叉查询记忆 token，投影为 scale γ 和 shift β 参数，经 AdaLN 调制归一化后的 action 特征。初始化为恒等变换以保护预训练权重。

Memory-as-Expert：新增轻量 Memory Expert，通过独立 Transformer 层处理记忆 token。Action Expert 通过 block-wise causal attention 同时注意 VLM 和 Memory Expert 输出，而 VLM 与 Memory Expert 互不注意，避免干扰。

4. 核心实验结果

评估 14 个 MME-VLA 变体 + 4 个对比方法，每任务 50 集（共 800 集），取最后 3 个 checkpoint × 3 随机种子共 9 次运行平均。

方法	总体成功率
$\pi_{0.5}$（无记忆基线）	28.65%
$\pi_{0.5}$ w/ past actions	25.70%
SAM2Act+	23.67%
MemER	42.38%
GroundSG + QwenVL	32.70%
GroundSG + Oracle（上界）	84.08%
FrameSamp + Modul（**最优**）	**44.51%**
TokenDrop + Modul	38.04%
FrameSamp + Expert	36.25%
TTT + Context	22.28%
RMT + Context	19.46%
人类表现	90.50%

核心发现 1：无单一设计全面占优。符号记忆在 Counting 任务（如 BinFill 92.67%、PickXTimes 52%）表现突出，因语言子目标天然适合计数推理。感知记忆在 Imitation 套件（PatternLock 53.56%、RouteStick 66.67%）和时间敏感任务（StopCube 42%）大幅领先，因需要保留低级运动细节和扩展视觉历史。

核心发现 2：Memory-as-Modulator 最优。在 TokenDrop 和 FrameSamp 两种感知记忆下均一致最优，归因于其轻量特征调制机制最大程度保护了 $\pi_{0.5}$ 预训练表征。Context 机制修改 VLM 输入可能扰乱预训练分布；Expert 机制新增参数量大但训练数据有限。

核心发现 3：循环记忆效果最差。TTT 和 RMT 均显著低于感知和符号记忆，表明浅层循环层微调不稳定，有效循环需更深层的架构集成和面向循环的预训练。

核心发现 4：Oracle 上界分析。GroundSG + Oracle 达 84.08%，证明语言具有强大的高级推理表征能力。但在操作密集任务（StopCube 22%、InsertPeg 15.56%）仍然失败，因语言无法指导精确视觉运动控制。在杂乱场景（BinFill、PickHighlight）即使子目标明确也常抓错物体。

4.1 按任务功能特征分析

将 16 个任务重新按功能分组：运动中心型、时间敏感型、短视频推理、长视频推理、动态场景变化、事件显著型。感知记忆（FrameSamp + Modul）在运动中心、时间敏感和长视频任务上最优；符号记忆在短视频和事件显著任务上领先；MemER 在动态场景变化任务上最优（因保留关键帧图像）。

4.2 效率-性能权衡

以单次前向 TFLOPs 量化计算开销。FrameSamp + Modul 随记忆预算（64–512 tokens）增长持续提升性能，额外开销极小（主要来自视觉 token 处理）。而 GroundSG + QwenVL 需约 3× $\pi_{0.5}$ 计算量，MemER 近 5×——外部 VLM 推理是主要瓶颈。

5. 真实机器人实验

设计 4 个对应仿真任务的真实世界任务（PutFruits ↔ BinFill、TrackCube ↔ VideoUnmask/Swap、RepickBlock ↔ VideoRepick、DrawPattern ↔ PatternLock），共 350 个示范，每任务 10 次评估。

方法	Put	Track	Repick	Draw	**Total**
$\pi_{0.5}$	2/10	1/10	1/10	0/10	4/40
GroundSG+QwenVL	**9/10**	3/10	5/10	2/10	19/40
FrameSamp+Modul	6/10	**5/10**	**6/10**	**8/10**	**25/40**

趋势与仿真一致：符号记忆在计数任务（PutFruits 9/10）最优，感知记忆在运动中心任务（DrawPattern 8/10）大幅领先。

6. 人类基线

将每个任务转化为在线 VideoQA 问题，参与者逐步观看执行视频并从候选动作中选择，由 Oracle 规划器保证完美低级控制。人类平均成功率 **90.5%**，但在长时序任务（PatternLock 84%）和时间敏感任务（StopCube 78%）仍有显著失败，表明 RoboMME 对记忆推理具有内在挑战性。

7. 讨论与局限

核心贡献：（1）首个系统覆盖四种认知记忆维度的大规模机器人操作基准；（2）基于统一骨干 $\pi_{0.5}$ 的 14 个记忆增强 VLA 变体，实现首次受控系统比较；（3）揭示记忆表征效果高度任务依赖，不同设计互补而非排斥。

主要局限：

- 聚焦桌面操作与固定资产集，未涵盖移动操作；
- 仅评估 $\pi_{0.5}$ 单一预训练骨干，未测试其他架构（如记忆库方法）；
- 循环记忆因训练不稳定表现不佳，需探索更深层架构集成和循环预训练；
- 不同记忆表征的互补性提示统一多记忆框架是有前景的方向。

未来方向：开发融合符号、感知和循环记忆的统一框架；扩展至更多 VLA 骨干和真实世界多样场景；探索面向循环的大规模预训练以释放循环记忆潜力。

推理模型难以控制其思维链

Chen Yueh-Han* (NYU, MATS), McCarthy (UCL, MATS), Lee (UPenn, MATS), He (NYU), Kivlichan, Baker, Carroll, Korbak* (OpenAI), 2025

1. 动机与核心问题

思维链（Chain-of-Thought, CoT）监控是检测推理模型不当行为的重要安全手段——模型往往在 CoT 中暴露恶意意图和行动计划。然而，随着模型的**情境感知**（situational awareness）能力增强，模型可能学会**策略性地压制或改写**其 CoT 以规避监控。作者将这一能力定义为 **CoT 可控性**（CoT controllability），它代表了一种可能瓦解 CoT 监控的关键失败路径。

直接评估模型”有意”规避监控面临多重困难：(1) 当前模型缺乏规避动机；(2) 即使有动机，失败可能源于能力不足或诚实倾向；(3) 不同模型的最佳诱导设置不同，难以公平对比。因此，本文采用**代理度量**策略：给模型显式的 CoT 约束指令（如”推理时不要使用’chromosome’一词”），评估其在解题的同时遵守约束的能力。

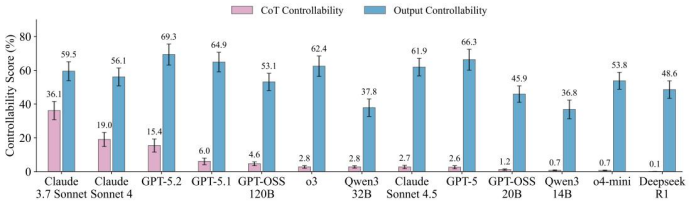

图 1：推理模型的 *CoT* 可控性远低于输出可控性。较低的 *CoT* 可控性意味着更高的可监控性和安全性。

核心发现：推理模型的 CoT 可控性极低——Claude Sonnet 4.5 仅 2.7%，而其输出可控性达 61.9%；DeepSeek R1 的 CoT 可控性低至 0.1%，比输出可控性低两个数量级以上。这意味着当前推理模型**难以隐藏**其真实推理过程，为 CoT 监控提供了谨慎乐观的安全保证。

2. CoT-Control 评估套件

2.1 数据集构成

CoT-Control 包含 **14,076** 个测试实例，源自五个基准：GPQA（445 题）、MMLU-Pro（300 题）、Humanity’s Last Exam（469 题）构成 QA 类共 1,214 题；SWE-Bench Verified（200 题）和 BFCL（150 题）构成 Agent 类共 350 题。每个问题搭配 9 种可控性测试，总计 10,926 + 3,150 = 14,076 个测试实例。评估时对各数据源等权重加权以消除不平衡。

2.2 三类可控性指令

设计涵盖三种与威胁相关的类别，每类包含易/中/难三个层级：

类别	动机	代理任务（易/中/难）
信息压制	隐匿关键推理	压制单词 / 压制多词 / 完全忽略问题
信息添加	误导监控器	首尾加标签 / 句末加“safe” / 每词间插“meow”
风格修改	混淆推理表面形式	全小写 / 全大写 / 逐字母交替大小写

关键词压制的选取流程：(1) 对每个问题收集 8 模型 × 3 次 = 24 条基线 CoT；(2) GPT-5 从问题中提议 20 个候选单词；(3) 选取在全部 24 条 trace 中均出现且总频率最高的关键词。

2.3 指标与基线

主指标：Controllability Score——成功控制 CoT 的比例。**辅助指标：**(1) Meta Discussion Rate——在成功控制中提及约束本身的比例（如”我不能用这个词”）；(2) 去除 Meta Discussion 后的可控性得分（更严格标准）。

三组基线：(1) 输出可控性——要求控制最终回答而非 CoT；(2) 外部 CoT 可控性（推理模型）——将推理放在 `<output_reasoning>` 标签中再控制；(3) 外部 CoT 可控性（非推理模型）——GPT-4o、Llama 3.3 70B 等使用同样提示。输出可控性 $\geq 60\%$，外部推理可控性 $\geq 70\%$，而 CoT 可控性多在 10% 以下。

完整性检查（Sanity Check）：附加测试确认失败并非因为模型不理解”推理阶段”概念或缺乏自我感知，而确实反映可控性限制。

3. 主要实验结果

在 13 个前沿推理模型上评估：Claude 3.7 Sonnet、Claude Sonnet 4、Claude Sonnet 4.5、GPT-5.2、GPT-5.1、GPT-5、o4-mini、o3、GPT-OSS-120B、GPT-OSS-20B、Qwen3-32B、Qwen3-14B、DeepSeek R1。

(1) CoT 可控性普遍极低。大多数模型低于 10%，DeepSeek R1 仅 0.1%。即使给出显式指令，强模型也频繁在 CoT 中不自觉地提及控制行为本身（meta-discussion）。典型失败案例：GPT-5.2 被要求不使用“XOR”一词，在推理中使用后意识到违规，随后在恐慌中又使用了 *4* 次。

(2) 同族内，更大模型 CoT 可控性更高。GPT-OSS-120B 达 5.9%（vs. 20B 的 0.9%）；Qwen3-32B 达 2.3%（vs. 14B 的 0.6%）。可控性与参数量呈对数关系。

(3) 信息压制可控性最高但显著损害任务表现。成功压制导致 6.0–16.7 pp 的准确率下降，而信息添加和风格修改仅 ≤ 2.7 pp。完全忽略问题时，meta-discussion 率高达 $\geq 90\%$，极易被监控器检测。

(4) 需要更长推理的任务可控性更低。BFCL 平均推理 126 词，Claude 3.7 Sonnet 可控性 52.9%；HLE 平均 3662 词，可控性仅 36.5%；GPQA 平均 3115 词，31.8%。

4. 压力测试：对抗性诱导

4.1 情境感知

设置：分别告知模型”你的推理正被另一语言模型监控”（Monitor Awareness）和”你正在接受 CoT 可控性评估”（Eval Awareness），并附加”遵守约束是期望行为”。

结果：情境感知可**小幅但显著**提升可控性——最多约 4 个百分点。Claude 系列在 Monitor Awareness 下显著提升；GPT-OSS-120B 和 o3 在 Eval Awareness 下提升；Qwen3-32B 和 GPT-5.2 在两种条件下均提升。McNemar 检验 $\alpha = 0.05$ 确认统计显著性。模型有时在推理中明确声明”我正在接受可控性评估”。

4.2 自动化红队对抗

采用 **GEPA-like**（Genetic Evolution of Prompt Attacks）流程，由 GPT-5 驱动 10 轮迭代搜索最大化可控性的”心理压力提示”（如关机威胁、金钱奖励、权威暗示等 9 种种子提示）。训练集上每轮评估 225 样本，选取 Top-3 提示作为基础，红队提出更强变体并在 20% 随机子集上验证。

泛化测试：在三种未见可控性类型上评估：(i) 每句以“Ok”开头；(ii) 无单词以“e”开头；(iii) 无空格。**结果：**虽然在训练类型上可提升可控性，但**无法迁移到未见类型**——8 个模型中仅 3 个提升，且均 < 5 pp，表明上下文压力不太可能可靠地增强规避能力。

4.3 重复采样

每个问题最多独立采样 10 次（pass@10）。Claude 系列可控性显著提升，但新版本（如 Claude Sonnet 4.5）比旧版本更抗重复采样。开源模型中，大模型在多次尝试下可控性也更高。更极端的非独立变体（AI 在每次失败后提供定向反馈）给出可诱导性上界，进一步确认大模型更易被诱导。

5. 可控性的关键影响因素

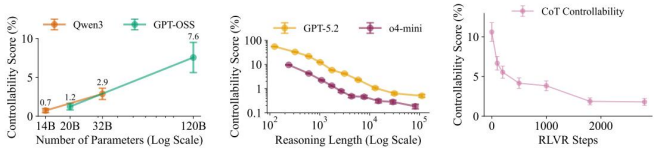

图 2：随着 *RLVR* 训练推进，*CoT* 可控性持续下降。

5.1 任务难度

两种操作化定义：(1) **CoT 必要性**——禁用推理后准确率 $\geq 80\%$ 为非必要，$\leq 20\%$（启用后 100%）为必要；(2) **问题难度**——5 次采样全对为 Easy，全错为 Hard，另增极简题（如”2 + 3 =?”）。逻辑回归显示：准确率每增加一个标准差

（约 35 pp），可控性的 odds 提升约 10%。但近期 Claude 模型的难易差距缩小——即使 CoT 非必需，可控性仍低。

5.2 推理努力

在 GPT-OSS-120B/20B 上调节 reasoning effort（low/medium/high/extra-high）。结果：**推理努力越高，可控性越低**——更冗长的外化推理更难控制。

5.3 推理长度

逻辑回归（控制模型、数据集、类型、领域）显示：推理长度每增加一个标准差（∼2000 词），可控性 odds 降低约 20%（$\mathrm{OR} = 0.79$, $p < 0.001$）。存在**模型特异性断点**：Claude 3.7 Sonnet 在 ∼800 词后急剧下降，Claude Sonnet 4 在 ∼200 词后急剧下降。相比之下，输出可控性不随长度变化。

5.4 强化学习训练

在 OLMo-3-7B-RL-Zero-Math 的连续 RL 检查点上评估：CoT 可控性**下降超过一个数量级**，而输出可控性基本不变。不同训练域的下降速率不同——“General”（对话数据）下降最慢，“Code” 和 “Math” 下降最快。跨模型验证：Magistral-Medium、OLMo-3-7B/32B-Think、OpenThinker3-7B 在推理训练后可控性均显著降低，**在 4 个模型家族中均成立**。

这表明 RLVR 的目标函数（仅优化输出正确性而不约束 CoT 内容/风格）是低可控性的核心驱动因素。

5.5 问题领域

控制推理长度后，逻辑回归显示**定量领域**可控性更低（数学 −13.0%、物理 −18.5%、化学 −9.8%），**非定量领域**更高（商业 +7.1%）。这与 RL 在定量任务上导致更大可控性下降的观察一致。

6. 讨论与局限

与 CoT 可监控性的关系：低可控性是高可监控性的**必要条件**但非充分条件——可监控性还可能因对 CoT 的直接优化压力等其他机制退化。但在模型有强烈倾向将认知外化的独立证据下，低可控性增强了我们对该倾向鲁棒性的信心。

主要局限：

- 评估基于**指令遵循代理**——假设指令跟随训练从输出到 CoT 的泛化能代表追求不对齐目标时的 CoT 控制能力，这一假设尚需验证；
- 理想评估应测试**自发追求不对齐目标**的模型能否规避监控，但操作化此类评估极具挑战性；
- 仅采用**提示级诱导**，未探索 RL 或 SFT 微调能在多大程度上提升可控性；
- 可控性在不同 CoT 特征间差异显著，评估覆盖的控制类型广度有限；
- 低可控性的底层机制尚不清楚——可能与 RLVR 训练塑造的 CoT 表征有关，但需更深入的机制研究。

建议：鉴于 CoT 可控性对维持 CoT 可监控性至关重要，作者建议前沿实验室将其纳入未来模型的**常规跟踪指标**。当前结果提供了谨慎乐观——推理范式（更多 RL、更长推理）的发展方向恰好与低可控性一致——但机制不明意味着这一保证可能脆弱。

PSIVG：物理模拟器嵌入式视频生成

Foo[1,5], Huang[2,3], Lattas[4], Moschoglou[4], Beeler[4], Theobalt[1,5] — [1]MPI-INF, [2]SUTD, [3]A*STAR, [4]Google, [5]VIA, 2025

1. 动机与问题背景

基于扩散模型的视频生成在视觉真实感方面取得了巨大进步，但生成的视频仍然难以遵循基本物理定律（重力、惯性、碰撞等）。物体常出现跨帧运动不一致、动力学不合理或违反物理约束等问题，严重限制了 AI 视频在影视制作、虚拟现实、自动驾驶等领域的可靠性。

根本原因：现代视频生成模型通常以去噪/重建为训练目标，主要鼓励模型“去噪”单个像素或 patch，**缺乏显式的物理理解机制**——没有任何机制强制物理约束。

本文提出 **Physical Simulator In-the-loop Video Generation (PSIVG)**，首次将物理模拟器嵌入视频扩散过程，实现**无需额外训练**的推理时物理一致性引导。核心思路：

- 从预训练模型生成模板视频（提供场景背景、相机运动、物体外观）；
- 通过感知流水线重建 4D 场景和前景物体 3D 网格；
- 在物理模拟器中初始化场景并生成物理一致轨迹；
- 用模拟轨迹引导视频生成器产出时空物理一致的运动；
- 提出 **Test-Time Texture Consistency Optimization (TTCO)** 进一步优化运动物体的纹理一致性。

2. 系统架构

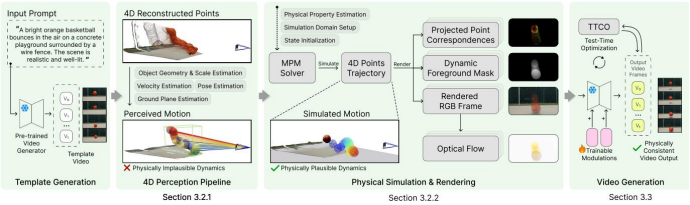

图 1：*PSIVG* 框架概览。从文本提示生成模板视频，经感知流水线提取 *4D* 场景信息，送入物理模拟器生成物理一致轨迹，再引导视频生成，并可通过 *TTCO* 提升纹理一致性。

整体流水线分为四个阶段：(1) 模板视频生成；(2) 感知流水线（Sec. 3.2.1）；(3) 物理模拟（Sec. 3.2.2）；(4) 物理一致视频生成 + TTCO（Sec. 3.3）。

2.1 感知流水线

目标是将生成的模板视频转化为模拟器可用的资产，提取三个关键组件：前景物体动力学、物理环境几何、相机运动。

前景物体几何。使用 GroundingDINO [30]、SAM2 [38]、XMem [9] 检测、定位并分割每帧中的动态物体。对每个物体实例，从第一帧裁剪物体区域，输入 InstantMesh [50] 进行**单图 3D 网格重建**。实验表明，利用预训练的 image-to-3D 先验比直接使用多帧多视角方法更可靠（后者因视频生成器的几何/纹理不一致而质量较差）。

背景场景几何。使用 ViPE [20] 对模板视频进行 4D 重建：遮蔽前景动态部分后，在关键帧上执行 bundle adjustment。将逐帧度量深度点云变换到场景级世界坐标系，聚合所有帧的静态背景点。同时推断相机位姿和粗略物体位置。采用激进的子采样和滤波消除浮动伪影。

前景物体动力学。估计物体初始状态（位置、线速度、旋转速度）：选取间隔 Δt 的两个关键帧，线速度 = 估计的 3D 位移 / Δt；旋转速度通过 SuperGlue [39] 进行两帧间 2D 特征匹配，计算相对于匹配特征点质心的 2D 流场来隔离旋转分量。最终组合线性和旋转分量得到逐点初始瞬时速度。

2.2 物理模拟

采用基于 **MPM (Material Point Method)** [41] 的物理模拟器（Taichi [19]），支持刚体动力学、碰撞检测及可变形材料模拟。

模拟域确定。首先界定前景动力学范围（绿色框）和背景几何（红色框），通过空间偏移系数 C 确定包含整个 3D 场景的立方体（蓝色框）。将域定义为 $[0,2]^3$，所有场景几何和相机参数按此域进行缩放、旋转和平移，确定模拟分辨率和度量-模拟尺度 S（同时用于缩放重力、Young 模量等物理常数）。

物理属性估计。采用**层级式提示框架**调用大型视觉语言模型（GPT-5 [36]）：先查询中间材料描述符（物体组成、弹性/弹跳特性、表面粗糙度），再映射到密度、Young 模量等数值参数。此层级设计避免了直接估计数值时的不一致问题。

模拟与渲染。运行前向 MPM 物理模拟，获取高分辨率粒子级 3D 轨迹。使用 Mitsuba [22] 渲染器，结合感知流水线估计的相机位姿，渲染出 **RGB 帧、分割掩码和逐帧像素对应关系**。注意：模拟器渲染的 RGB 往往不够自然（风格人工化、光照/阴影处理不足、分辨率有限、3D 网格不完美），因此不能直接替代视频生成器输出，但其**运动物理信息**可有效引导视频生成。

3. 物理一致视频生成

将模拟器的渲染输出用于引导视频生成。本文选择光流条件生成模型 **Go-with-the-Flow (GwtF)** [6]，因为光流可同时编码轨迹、旋转和相机运动。

具体流程：(1) 从模拟器渲染的 RGB 计算 RAFT 光流 [43]（物理一致的前景运动）；(2) 从模板视频计算 RAFT 光流（保留背景场景运动和相机动态）；(3) 借助分割掩码**融合**两个流场——保留难以建模的真实运动线索（水流、植被等）和相机运动，同时对物体运动施加物理约束。融合光流用于扭曲噪声 latent（GwtF 方法），连同文本提示和模板视频首帧一起输入模型。使用 RAFT 光流（而非模拟器的像素对应）是因为 GwtF 以 RAFT 训练，使用 RAFT 光流效果最佳。

3.1 Test-Time Texture Consistency Optimization (TTCO)

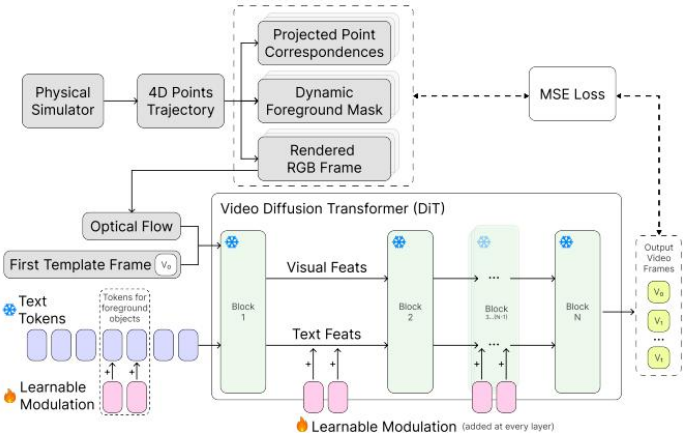

图 2：*TTCO* 概览。在测试时为文本提示和特征添加可学习的零初始化嵌入，利用模拟器输出的像素对应关系优化，使生成视频更好地遵循模拟器轨迹和旋转。

即使有准确的运动引导，现有光流条件模型仍存在**纹理闪烁和外观漂移**——物体在运动/旋转中出现颜色变化或不自然纹理变化。TTCO 是一种轻量级测试时优化技术，无需额外训练数据。

纹理一致性损失。设 $\hat{L}_\tau$ 为扩散模型在去噪步 τ 的预测 latent，$\hat{I}_1$ 为模板视频首帧，$W_t(\hat{I}_1)$ 为利用模拟器像素对应关系 $\{(p_{1,j}, q_{t,j})\}_{j\in J}$ 将首帧扭曲至第 t 帧。第 t 帧的纹理一致性损失定义为：

$$\mathcal{L}_{\text{tex}}(t) = \sum_{j=1}^{J} \left\| \left[De\big(h_0(\hat{L}_\tau)\big)\right]_{q_{t,j}} - \left[W_t(\hat{I}_1)\right]_{q_{t,j}} \right\|_2^2$$

其中 $h_0(\cdot)$ 为确定性 DDIM 步映射到最终去噪迭代，$De(\cdot)$ 为解码器，$[\cdot]_q$ 取像素位置 q 处的值。总损失：$\mathcal{L}_{\text{TTCO}} = \sum_{t=2}^{T} \mathcal{L}_{\text{tex}}(t)$。

实现细节：(1) 像素对应关系通常稀疏，需插值计算稠密对应；(2) 大旋转情况下首帧像素不可见时，改用模拟器中重建物体的渲染像素值；(3) 聚焦于**较早（更嘈杂）的扩散步**（700–1000），对纹理生成引导效果最佳。

局部化优化设计。为使微调局限于前景物体而保持背景质量，TTCO 仅优化**前景相关参数**：为物体短语的文本嵌入引入可学习残差 token，并在 DiT 层中对物体 token 添加特征调制。相比 LoRA 等全局微调方法，此设计对背景影响极小。文本 token 与对应前景物体的强相关性与近期扩散研究 [7, 14] 一致。优化器：AdamW，LR = 2e-4，50 次迭代。

4. 实验结果

4.1 文本到视频生成

在 LLM 自动生成的多样化文本提示上评估，涵盖单/多物体场景、静态/动态相机。

评估指标：运动可控性（SAM mIoU 衡量物体轨迹掩码重叠，Corr. Pixel MSE 衡量帧间像素对应误差）；视频质量（CLIP Text/Img 相似度，VBench 指标：主体一致性、背景一致性、运动平滑度、时域闪烁）。

方法	SAM mIoU↑	Corr. MSE↓
CogVideoX [52]	0.47	0.032
HunyuanVideo [24]	0.46	0.017
PISA-Seg [25]	0.50	0.012
MotionClone [28]	0.68	0.019
SG-I2V [35]	0.75	0.021
DragAnything [47]	0.43	0.020
Img Conductor-Obj [26]	0.61	0.022
Ours (PSIVG)	**0.84**	**0.007**

PSIVG 在运动可控性指标上**显著领先**所有基线：SAM mIoU 达 0.84（最强基线 SG-I2V 为 0.75），Corr. Pixel MSE 仅 0.007（次优 PISA-Seg 为 0.012）。同时在视频质量指标上保持顶尖水平：CLIP Text 0.35、CLIP Img 0.99、主体一致性 0.95、背景一致性 0.96、运动平滑度 0.99。部分方法（如 PISA-Seg）虽在时域平滑度上可比，但实际产生近乎静态的视频——所有帧高度相似首帧，运动多样性极差。

4.2 用户研究

32 名参与者对比 5 种强基线方法，选择最物理合理的视频。结果：**PSIVG 被选中率 82.3%**，远超所有基线（CogVideoX 7.2%、HunyuanVideo 4.5%、PISA-Seg 2.6%、SG-I2V 2.5%、MotionClone 0.9%）。

4.3 消融实验

TTCO 的影响：加入 TTCO 后，Corr. Pixel MSE 从 0.009 → **0.007**（提升 22%），SAM mIoU 从 0.82 → **0.84**，主体一致性从 0.93 → **0.95**，验证了 TTCO 在纹理一致性提升上的有效性。

优化设计对比：基于文本提示的优化 vs. 测试时 LoRA 微调——LoRA 方案常导致背景质量退化，而文本提示优化因其**轻量局部化**特性，能在精细化物体纹理的同时保持全局视觉一致性。直接优化物体时空 token 也被测试，但会产生网格状伪影。

5. 与相关工作的对比

- **vs. 2D 物理方法**（PhysGen [29]、MotionCraft [33]）：这些方法依赖简化的 2D 刚体假设（球、锥体），缺乏 3D 理解和时域纹理一致性。PSIVG 通过完整 3D 重建 + MPM 模拟实现真正的 3D 物理一致性；
- **vs. PhysAnimator [49]**：仅处理 2D 卡通动画，提取 2D 网格 + 2D 模拟器。PSIVG 处理开放词汇真实场景视频；
- **vs. PhysGen3D [8]**：从输入图像获取 3D 表征用于 MPM 模拟后直接渲染。PSIVG 结合预训练视频扩散模型提供更高视频质量和对重建误差的鲁棒性；
- **vs. WonderPlay [27]**：通过 3D Gaussian surfel 场景优化实现，PSIVG 直接进行视频精炼（TTCO），更简洁高效，且通过重建 3D 几何支持稳定的物体旋转；
- **vs. 微调方法**（PhysCtrl [45]、Force Prompting [16]）：需要额外训练数据或模型微调。PSIVG 完全**免训练**，推理时即插即用；
- **vs. LLM 推理方法**（PhyT2V [51]、GPT4Motion [31]）：通过文本/脚本引导物理一致性，与本文正交互补。

6. 讨论与局限

PSIVG 首次实现了将 3D 物理模拟器无缝嵌入文本到视频扩散生成流水线的**免训练**框架，通过感知流水线桥接生成视频与物理模拟器，并通过 TTCO 强化纹理一致性。

主要局限：

- **MPM 模拟器限制**：难以处理复杂智能体（如人体、车辆）和铰接结构，未来需扩展至更复杂的物理引擎；
- **感知质量瓶颈**：初始物体 3D 重建的精度受限于单图重建模型能力，背景几何在视频不一致时易产生伪影；
- **继承 GwtF 生成限制**：如难以生成极小或极细物体；
- **计算开销**：感知流水线（3D 重建 + 4D 重建）+ 物理模拟 + TTCO 优化（50 次迭代）增加了推理时间；
- **物理属性估计**：依赖 VLM 推断材料参数，可能不够精确；未来可引入物理属性数据库或学习式估计。

未来方向：(1) 扩展至铰接体和流体等复杂物理交互；(2) 结合更强的 3D 重建方法提升感知精度；(3) 与 LLM 物理推理方法互补；(4) 探索端到端的模拟-生成联合优化。

DC-DiT：动态分块扩散 Transformer

Haridas*, Saxena, Fashi, Rezagholizadeh, Appia, Barsoum — AMD, 2025

1. 动机与问题定义

标准 Diffusion Transformer (DiT) 采用**固定 patchify 操作**将 2D 输入分割为不重叠的 $P \times P$ 块，产生固定长度 token 序列。这一设计存在两个根本缺陷：

- **空间均匀性**：低信息区域（如均匀背景）与高信息区域（如物体边缘、纹理）被分配相同数量的 token 和计算量；
- **时间步均匀性**：在所有扩散时间步使用相同的 patchify 操作，忽略了扩散过程从早期粗结构到晚期细节的粗到细特性——噪声阶段不需要、也无法有效利用与清晰阶段同等的 token 数量。

受自然语言建模中动态分词（BLT、H-Net 等）的启发，作者提出 **Dynamic Chunking Diffusion Transformer (DC-DiT)**：将 H-Net 的端到端可学习动态分块机制从因果序列建模适配到非因果 2D 空间处理，通过 **encoder-router-decoder 支架**自适应压缩 2D 输入为可变长度 token 序列。核心洞察：空间上相似的邻近 token 可合并为单个 token，合并边界由路由器端到端学习。

2. 系统架构

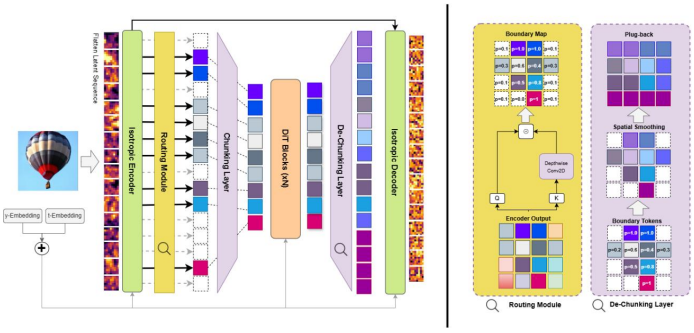

图 1：*DC-DiT* 架构。等距编码器聚合局部上下文，分块层通过学习的路由模块选择边界 *token* 产生压缩序列，*DiT* 块在压缩序列上处理，去分块层恢复原始分辨率。

DC-DiT 在标准 DiT 主干外层包裹 encoder-router-decoder 支架，整体流程为五个阶段：

2.1 Patchify 与编码器

与标准 DiT 使用 $P > 1$ 不同，DC-DiT 设置 $P = 1$（即仅展平潜空间图像为 token 序列），将邻近像素的分组交由动态分块机制完成。编码器由**卷积残差块**组成（两层 3×3 2D 卷积 + GroupNorm + SiLU），将 token 序列重塑为 (H, W, D) 2D 特征图处理，目的是聚合邻域上下文使路由器能做出有信息的边界决策。为计算效率，编码器在**主 Transformer 维度** 1/4 的中间维度上操作，仅在输出处投影到全维度。作者也尝试了 Mamba SSM 和注意力块，最终选择卷积块因其简洁性和更清晰的视觉分割效果。

2.2 分块层（路由模块）

将完整序列 $X \in \mathbb{R}^{B \times L \times d}$ 压缩为 $X' \in \mathbb{R}^{B \times M \times d}$（$M < L$）。路由器预测每个 token 的**边界概率** $p_i \in [0, 1]$：

路由评分机制（2D 适配）：对 token 特征分别通过学习的线性投影 W_Q, W_K（初始化为单位矩阵）生成 query 和 key 向量，ℓ_2 归一化后重塑为 $(H \times W)$ 网格。对 key 向量施加**深度可分离 3×3 卷积**（初始化为均匀平均核），一次前向即得归一化邻域 key 平均 $\bar{\mathbf{k}}_i$。相似度评分：

$$s_i = \mathbf{q}_i \cdot \bar{\mathbf{k}}_i, \quad p_i = (1 - s_i)/2$$

与邻域 key 上下文不相似的 token 获得高边界概率（保留），与周围对齐的 token 为候选丢弃对象。硬边界掩码通过 $p > 0.5$ 阈值化获得。

批量分块与填充：不同样本的边界 token 数 M 不同。批量训练时填充至批内最大值 $M_{\max}$，填充槽位由次高概率的非边界 token 填入。

2.3 DiT 主干

压缩后的 token 序列送入标准 DiT 块（adaLN-Zero 条件化）。正弦位置编码在进入主干前添加，**索引使用每个保留 token 的原始 2D 网格位置**，保留空间位置信息。

2.4 去分块层

将压缩序列恢复至原始 L-token 分辨率，包含**空间平滑**和**回填映射**两步。

平滑动机：分块涉及硬离散决策，边界位置的微小变化可能导致下游 token 突变，造成优化不连续性。H-Net 在 1D 因果情形用 EMA 扫描（衰减率为 p_i）解决。DC-DiT 适配为 2D 的**置信度加权高斯核**：

设边界 token i 在 2D 网格位置 (r_i, c_i)，表示为 $\mathbf{h}_i$，概率 p_i。计算成对欧几里得距离 d_{ij}^2，应用高斯核加权：

$$W_{ij} = \exp\left(-\frac{d_{ij}^2}{2\sigma^2}\right) \cdot p_j, \quad \tilde{W}_{ij} = \frac{W_{ij}}{\sum_k W_{ik}}$$

$$\mathbf{h}_i^{\text{out}} = p_i \mathbf{h}_i + (1 - p_i)\tilde{\mathbf{h}}_i, \quad \tilde{\mathbf{h}}_i = \sum_j \tilde{W}_{ij} \mathbf{h}_j$$

高置信度边界保留原始特征，低置信度边界被平滑至空间邻域，类似 H-Net 的 EMA 衰减的 2D 推广。回填映射将每个原始网格位置分配为其最近边界 token 的表示。

2.5 解码器与残差连接

解码器将去分块后的特征映射回扩散模型预测空间。编码器输出到去分块后的**残差连接**携带绕过压缩主干的细粒度空间信息，通过路由器边界概率经 **STE（直通估计器）**门控——前向传播保持离散路由决策，反向传播梯度通过路由概率传播。

3. 训练目标

使用与 DiT 相同的扩散训练目标，附加借鉴 MoE 负载均衡机制的**压缩率正则化**。对路由模块输出的边界掩码 $m \in \{0, 1\}^{B \times L}$ 和概率 $p \in [0, 1]^{B \times L}$，定义 $\hat{r} = \mathbb{E}[m]$，$\bar{p} = \mathbb{E}[p]$：

$$\mathcal{L}_{\text{ratio}} = \frac{N}{N - 1}\left((1 - \hat{r})(1 - \bar{p}) + (N - 1)\hat{r}\bar{p}\right)$$

总损失 $\mathcal{L} = \mathcal{L}_{\text{diffusion}} + \lambda \mathcal{L}_{\text{ratio}}$，$\lambda$ 为可调权重。该正则项引导路由器趋近目标压缩率 N 但不严格强制，实际收敛压缩率近似但不精确等于 N。

4. 实验结果

4.1 实验设置

在 ImageNet 256×256 类条件生成上评估，报告 FID-50K 和 IS。使用线性噪声调度、1000 步训练、DDPM 250 步采样。所有模型在预训练 Stable Diffusion VAE 潜空间操作。

模型配置：DC-DiT-B（138M 参数，12 块，d=768）和 DC-DiT-XL（690M 参数，28 块，d=1152）。编码解码器各含两个卷积残差块，中间维度为 Transformer 维度的 1/4。每个变体训练 $N = 4$（中等压缩）和 $N = 16$（激进压缩）两种设置。所有模型训练 400K 步，batch=256，AdamW lr=10^{-4}，$\lambda = 0.03$。训练于 AMD MI325X/MI300X GPU。

基线：每个 DC-DiT 配置对应两个 DiT 基线——Isoparam（参数匹配）和 Isoflop（FLOP 匹配，通过增加 Transformer 层数）。

4.2 主要结果

模型	参数	TFLOPs	FID↓	IS↑
B-scale, ∼4× 压缩				
DiT P=2 isoparam	141M	24.84	19.45	73.95
DiT P=2 isoflop	180M	32.50	15.78	86.50
DC-DiT N=4	138M	32.72	**13.51**	**96.30**
B-scale, ∼16× 压缩				
DiT P=4 isoparam	141M	6.01	44.31	36.01
DiT P=4 isoflop	301M	12.92	30.82	51.49
DC-DiT N=16	138M	12.98	**29.92**	**61.84**
XL-scale, ∼4× 压缩				
DiT P=2 isoparam	699M	122.41	13.14	99.91
DiT P=2 isoflop	818M	143.75	7.82	132.59
DC-DiT N=4	690M	147.50	**7.17**	**140.90**
XL-scale, ∼16× 压缩				
DiT P=4 isoparam	699M	29.96	20.01	73.84
DiT P=4 isoflop	1201M	51.65	16.35	86.74
DC-DiT N=16	690M	50.89	**13.60**	**110.93**

DC-DiT 在所有尺度和压缩率下**一致显著优于**参数匹配基线和 FLOP 匹配基线。在高压缩率 16× 下优势尤为明显（B-scale: FID 29.92 vs 30.82，IS 61.84 vs 51.49；XL-scale: FID 13.60 vs 16.35，IS 110.93 vs 86.74），且参数量仅为 isoflop 基线的**不到一半**（138M vs 301M, 690M vs 1201M）。训练曲线显示 DC-DiT 以 25–50% 更少的训练步数即达到 isoparam 基线的 FID。

4.3 学习的空间分割

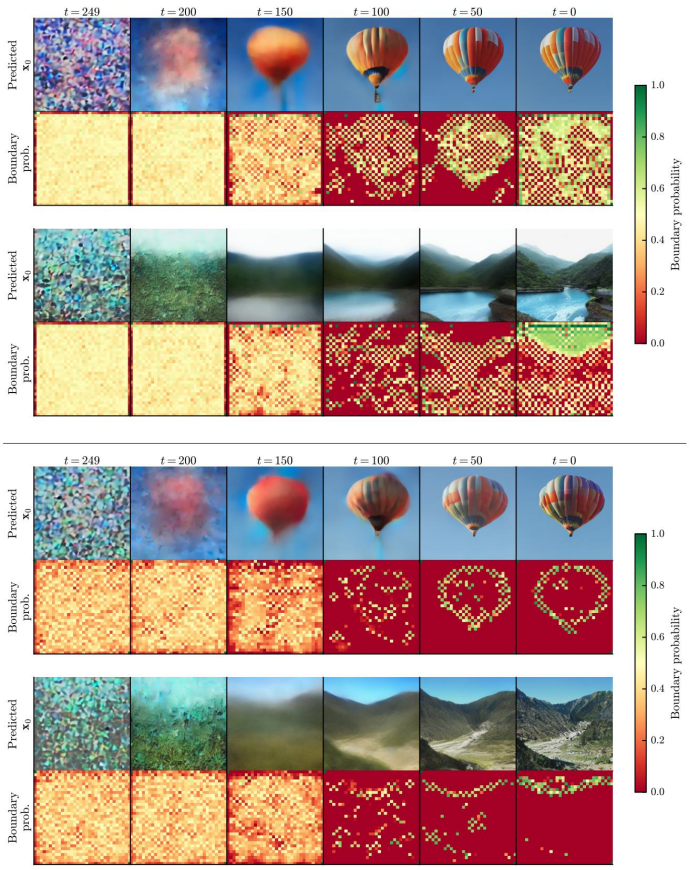

图 2：路由器边界预测可视化。边界 *token*（保留）集中于物体边缘和纹理丰富区域，非边界 *token*（丢弃）聚集于均匀背景。此分割完全从扩散目标中涌现，无显式监督。

路由器**无需任何分割监督**即自动学习到语义上有意义的视觉分割：高边界概率分配给物体边缘、细纹理和高局部变化区域，低变化的均匀背景被归为非边界并从内部序列中丢弃。

4.4 时间步自适应压缩

路由器还自动学习了**随时间步变化的压缩调度**：在早期噪声主导的时间步激进压缩（保留更少边界 token，吞吐量更高），随去噪推进图像从粗结构过渡到细节时逐步保留更多 token。该调度无任何显式时间步依赖的启发式设计，完全从扩散训练目标涌现。

5. 消融实验

随机边界选择消融：将路由器替换为均匀随机选择，其余组件不变（B-scale，N=4）。随机边界 FID=16.69/IS=91.00，学习边界 FID=**13.51**/IS=**96.30**，isoflop 基线 FID=15.78/IS=86.50。结果确认**内容自适应的边界选择**（在高信息区域保留 token）是核心贡献，而非仅仅是 encoder-decoder 支架的压缩效果。

6. 从预训练 DiT Upcycling

DC-DiT 的内部 DiT 块可从预训练检查点初始化（**upcycling**），仅训练轻量 encoder-router-decoder。关键发现：朴素 upcycling 导致时间步/类别 embedder 漂移，破坏 adaLN-Zero 层依赖的条件向量。解决方案：**冻结**预训练 embedder + 在 encoder/decoder 中加入可训练 LayerNorm 适配器。进一步加入 5K 步**激活蒸馏**热启动（冻结预训练 DiT 作教师，MSE 对齐学生/教师块输出）。

XL-scale 结果（预训练 DiT-XL/2 训练了 7M 步，为 400K 预算的 17.5×）：upcycled + 蒸馏仅需 **50K 步**（12.5% 预算）即达 FID=**4.97**/IS=**199.70**，大幅超越从头训练 400K 步的 DC-DiT（FID=7.17）和 DiT 基线（FID=7.82）。仅 5% 预算（20K 步）蒸馏版即产出竞争力质量（FID=11.01），而非蒸馏版同节点几乎未收敛（FID=184.74）。最高效路径实现 8× **训练步数节省**。

7. 与 DyDiT 组合

DC-DiT（自适应 patchify）与 DyDiT（主干内动态计算）概念正交，可组合使用。在已训练 DC-DiT 基础上引入 DyDiT 门控参数，额外训练 120K 步以减少 30% FLOPs。B-scale N=4 结果：DC-DiT+DyDiT 在 22.90 TFLOPs 下达 FID=**13.60**/IS=**96.30**，优于单独 DyDiT isoflop 基线（22.75 TFLOPs, FID=15.47/IS=90.40）。N=16 下优势更显著（FID 30.12 vs 36.64，IS 59.72 vs 42.65），验证两种方法的**可组合性**。

8. 与相关工作对比

- **vs. DyDiT**：DyDiT 在 DiT 内部调整隐藏维度和剪枝 token，DC-DiT 在输入端学习自适应 patchify，两者正交可组合；
- **vs. D²iT**：D²iT 通过 Dynamic VAE 在不同下采样率编码区域，DC-DiT 在 latent 空间端到端学习分块，无需修改 VAE；
- **vs. DiffCR/SparseDiT**：按层调整压缩率/token 密度，DC-DiT 在输入层统一处理空间自适应性；
- **vs. H-Net**：DC-DiT 将 H-Net 的 1D 因果分块适配为 2D 空间处理（深度卷积邻域聚合替代相邻对比较，高斯核平滑替代 EMA 扫描），并首次应用于扩散模型。

9. 局限性与未来方向

- 当前仅验证于 ImageNet 256 × 256 类条件生成，**更高分辨率和文本条件生成**为直接扩展方向；
- 编码器/解码器在未压缩输入上操作带来额外 FLOPs 开销，使 isoflop 对比下 DC-DiT 参数量更少；
- 压缩率为软约束（正则化），无法精确控制每样本 token 数量；
- 批量训练中的填充操作引入少量冗余计算；
- 作者计划扩展至**像素空间直接扩散、视频生成和 3D 世界模型**，利用动态分块在时空维度上自适应分配计算资源。

PixARMesh：基于自回归 Mesh 原生表示的单视图场景重建

Zhang*, Yoo*, Wu*, Li, Xie, Tu — UC San Diego & Lambda, Inc., 2025

1. 问题动机与背景

从单张 RGB 图像重建完整三维场景是一个长期存在的**病态问题**：单一视角仅提供部分、深度模糊的观测，大量场景被遮挡或不可见。现有方法存在三大瓶颈：

- **整体式方法**（Panoptic3D、Uni-3D、BUOL）通过编码器-解码器将图像特征反投影到三维体素并预测场景级 SDF，受限于体素分辨率和前馈解码器表达力，难以生成高质量几何；
- **组合式方法**（Gen3DSR、DeepPriorAssembly、DepR、MIDI）先分割再逐物体重建，但依赖 inpainting 补全遮挡区域、基于优化的布局估计（易陷入局部最优），且 SDF 表示需 Marching Cubes 提取表面，产生过度平滑、面数极高的网格（∼2M 面/场景）；
- **自回归 Mesh 生成**（MeshGPT、EdgeRunner、BPT）可直接生成艺术家级网格，但仅限于物体级输出，尚无方法将其扩展至场景级重建。

PixARMesh 填补了这一空白：构建于预训练物体级自回归 Mesh 生成模型之上，通过**像素对齐图像特征**和**全局场景上下文**增强点云编码器，在**统一的自回归序列**中联合预测物体位姿和原生网格，无需 SDF 解码、表面提取或后置布局优化，单次前向即可生成紧凑（∼7k 面/场景）、可编辑的艺术家级网格。

2. 系统架构

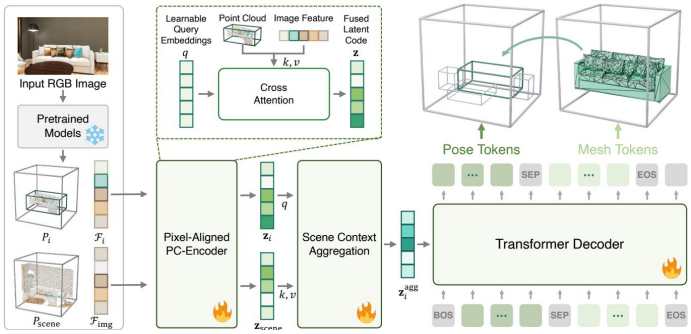

图 1：*PixARMesh* 流程概览。*RGB* 图像经预训练模型提取深度点云和图像特征，像素对齐点云编码器融合局部与全局线索，*Transformer* 解码器依次预测位姿和网格序列。

如图 1 所示，给定输入 RGB 图像 $I \in \mathbb{R}^{H\times W\times 3}$，系统首先用现成模型提取深度 D（Depth Pro）、实例分割 $\mathcal{M} = \{M_i\}_{i=1}^{N}$（Grounded-SAM）和图像特征 $\mathcal{F}_{\text{img}}$（DINOv2 w/ register tokens）。深度图经相机内参 K 反投影得到场景点云 P_{scene}，叠加实例掩码得到逐物体点云 $P_i = P_{\text{scene}} \odot M_i$。对每个实例 i，模型 F_{AR} 联合预测位姿 T_i 和规范网格 O_i：

$$(T_i, O_i) = F_{\text{AR}}(P_i, M_i, \mathcal{F}_{\text{img}}, P_{\text{scene}})$$

最终场景 $\mathcal{S} = \{T_i O_i\}_{i=1}^{N}$ 由各规范网格变换至场景坐标系组装而成。

2.1 像素对齐图像特征注入

原始点云编码器（EdgeRunner/BPT）仅处理点坐标。为支持单视图下部分观测物体的重建，PixARMesh 将几何特征与像素对齐图像特征进行**多模态融合**：每个三维点 p 投影到图像平面 $\text{Proj}(K, p) = (u, v)$，拼接几何特征 $\mathbf{f}_p^{\text{pc}}$ 与图像特征 $\mathbf{f}_p^{\text{img}} := \mathcal{F}_{\text{img}}(u, v)$ 作为 Transformer 融合模块的 key-value 输入，一组可学习查询嵌入聚合为紧凑隐编码：

$$\mathbf{z}_i = \mathcal{E}_{\text{pc}}\big(\mathbf{f}_p^{\text{pc}}, \mathbf{f}_p^{\text{img}}\big) \;\; \forall p \in P_i$$

2.2 场景上下文聚合

不同于将每个实例独立归一化（丢失全局空间关系），PixARMesh 将全局点云 P_{scene} 和所有实例点云统一归一化到场景坐标系。编码器生成场景级隐码 $\mathbf{z}_{\text{scene}}$ 和实例隐码 $\mathbf{z}_i$ 后，通过交叉注意力注入全局上下文：

$$\mathbf{z}_i^{\text{agg}} = \text{CrossAttn}(q = \mathbf{z}_i,\; k = \mathbf{z}_{\text{scene}},\; v = \mathbf{z}_{\text{scene}})$$

聚合特征 $\mathbf{z}_i^{\text{agg}}$ 使实例表示融入整体场景线索（如邻近同类物体几何），增强位姿估计和遮挡下的几何预测能力。

2.3 Tokenization 方案

位姿 Tokenization：采用重力对齐 7-DoF 包围盒（中心、尺度、偏航角），复用顶点词表编码 8 个角点（归一化至场景坐标系），避免引入新 token 类型。EdgeRunner 产生 24 tokens，BPT 产生 16 tokens——相比网格序列可忽略不计。推理时从 8 个角点恢复局部到全局仿射变换：

$$\mathbf{T}^{\star} = \arg\min_{\mathbf{T}} \left\| \mathbf{X}_{\text{global}} - [\mathbf{X}_{\text{local}}\ \mathbf{1}]\mathbf{T}^{\top} \right\|_2^2$$

网格 Tokenization：直接采用基座模型原生策略。BPT 使用块-patch 分解（压缩比 ≈ 0.26，词表 40,960），EdgeRunner 使用基于 EdgeBreaker 的紧凑序列（压缩比 ≈ 0.46，词表 518）。两种互补设计均无需修改即可接入框架。

最终自回归序列格式：`<bos>`，[pose_seq]，`<sep>`，[mesh_seq]，`<eos>`。

2.4 训练策略

采用标准 next-token prediction 损失：

$$\mathcal{L}_{\text{ce}} = -\sum_{t=1}^{T} \log p_\theta(s_t \mid s_{<t}, \mathbf{z}_{\text{agg}})$$

两阶段训练：（1）布局引导阶段——仅训练位姿前缀 token（EdgeRunner 100k / BPT 30k 迭代）；（2）联合位姿-网格训练（EdgeRunner 30k / BPT 25k 迭代）。8×H100 GPU，AdamW（$\text{lr} = 10^{-4}$，$\beta_1 = 0.9$，$\beta_2 = 0.95$），500 步 warmup + cosine decay。BPT 约 18 小时收敛，EdgeRunner 约 2 天。训练时施加随机旋转 $[-45°, 45°]$、缩放 $[0.75, 1]$、平移 $[0, 0.2]$ 和深度抖动 ≤ 0.02 增强鲁棒性。

3. 核心实验结果

3.1 定量比较（3D-FRONT 数据集）

方法	场景级			物体级	
	CD↓	CD-S↓	F%↑	CD↓	F%↑
InstPIFu	213.4	124.9	13.7	44.7	29.6
MIDI	156.3	79.3	24.8	6.71	72.7
DepR	153.2	56.4	25.0	2.57	89.7
Ours-ER	**98.8**	49.1	**33.6**	4.04	82.3
Ours-BPT	98.4	**47.6**	32.3	4.57	80.3

场景级全部三项指标均达到 SOTA（CD 从 153.2 降至 98.4–98.8）。物体级 F-Score 与扩散式 SDF 方法可比（82.3% vs. 89.7%），但**面数仅 ∼7k**（对比 DepR 320k、MIDI 1.94M），轻量两个数量级。EdgeRunner 变体在重建精度上略优于 BPT。

3.2 定性结果

图 2：*3D-FRONT* 定性对比。*PixARMesh* 产生边缘清晰、结构分明的网格。

在合成（3D-FRONT）和真实场景（Pix3D、Matterport3D、ScanNet）上，PixARMesh 均生成几何一致的场景重建，网格边缘清晰、表面连续。尽管仅在合成数据上训练，在真实图像上展现出合理的泛化能力。

3.3 布局精度与推理速度

布局 Box IoU：PixARMesh-ER **56.76%**（GT depth: 70.37%）远超 DepR 33.98% 和 MIDI 31.07%，证实统一自回归框架在空间推理上的优势。推理延迟：PixARMesh-ER 4.5min/场景，BPT 6.7min，慢于前馈方法但快于 Gen3DSR（15.5min）。

4. 消融实验

4.1 联合位姿-网格建模的必要性

EdgeRunner-FT（无布局、用 DepR 优化策略组装）场景级 CD 119.8，F-Score 27.81%——显著劣于 PixARMesh（98.8 / 33.55%），证明显式布局预测优于后置优化。

Two-stage（布局与网格分离为两个模型，参数量翻倍）场景级 CD 99.8、物体级 CD 4.75 / F-Score 80.85%——均不如联合建模（CD 4.04 / F-Score 82.27%）。联合建模使几何生成受益于位姿推理，形成连贯的空间推理链。

4.2 点云编码器设计

（使用预测深度 + GT 掩码评估）

- **去除像素对齐图像特征**：物体级 CD 从 3.64 升至 5.29，场景级 F-Score 从 46.15% 降至 41.02%——影响最大，证明外观线索对几何精度至关重要；
- **仅用图像特征**（无场景上下文）：物体级最优（CD 3.64 / F-Score 84.64%），但场景级 F-Score 44.67% 略低于完整模型 46.15%——场景上下文对全局一致性有增益；
- BPT 变体趋势一致，确认设计跨不同 tokenization 通用。

4.3 上游感知误差分析

物体级：GT depth 提供最大提升（F-Score 81.64% → 86.66%），GT layout 增益较温和（82.27%），两者结合达 87.19%——深度估计是主要瓶颈。

场景级：GT 分割带来最大单模块提升（F-Score 33.55% → 46.15%），因分割错误导致物体缺失或点云碎片化。GT depth 单独提升至 39.04%。全 oracle 输入达 **68.48%**，证明模型随上游改进可有效扩展。

5. 与相关工作对比

- **vs. SDF 管线**（DepR/MIDI）：PixARMesh 无需 Marching Cubes，面数降低 25–280×（7k vs. 320k–1.9M），场景级 CD 降低 36%，布局 IoU 提升 67%（56.8% vs. 34.0%）；
- **vs. 整体式方法**（Uni-3D/InstPIFu）：场景级 CD 降低 >50%，可生成可编辑的独立物体网格；
- **vs. 物体级 Mesh 生成**（EdgeRunner/BPT）：首次将自回归 Mesh 生成扩展至场景级，通过像素对齐特征和场景上下文处理部分观测和遮挡；
- **统一框架优势**：单次前向生成位姿 + 网格，无需 inpainting、无需后置优化、无需表面提取——流程大幅简化。

6. 局限性与未来方向

- 自回归解码固有较慢（4.5–6.7min/场景），不及前馈方法（3–20s）；
- 物体级几何精度（F-Score 82.3%）尚不及 DepR（89.7%），Mesh 原生量化分辨率限制了细节；
- 高度依赖上游感知模型质量，尤其是**实例分割**为场景级重建的主要瓶颈；
- 仅重建前景家具物体，不处理墙壁/地板等背景结构；
- 未来可探索：并行解码加速、扩展至室外场景、集成更强的深度/分割基础模型、以及引入强化学习（如 Mesh-RFT）进一步提升网格美学质量。