QZPaper Huggingface Daily

2026-03-09

---

1. **Penguin-VL：探索基于 LLM 视觉编码器的紧凑 VLM 性能极限**
   Penguin-VL 针对现有 VLM 参数臃肿、难以部署的问题，提出从纯文本 LLM 直接初始化视觉编码器的新范式，避免对比学习的目标不匹配；通过 2D-RoPE 位置编码和双向注意力实现高效视觉表示，在 2B/8B 规模下超越 Qwen3-VL 等主流模型。
2. **BandPO：通过概率感知界桥接信赖域与比率裁剪的 LLM 强化学习**
   BandPO 指出 PPO 固定裁剪隐含抑制探索且无法平衡低概率动作的稳定优化，提出基于概率感知界的信赖域约束替代固定裁剪；通过 f-散度诱导设计避免排序操作，解决了尾部 token 探索与模型稳定性的矛盾。
3. **Planning in 8 Tokens：面向潜在世界模型的紧凑离散分词器**
   Planning in 8 Tokens 针对世界模型规划计算瓶颈，提出 CompACT 分词器将每张图像压缩至仅 8 个离散 token（百倍压缩），避免扩散模型迭代去噪；通过激进压缩迫使模型学习更抽象、与动作相关的表征，实现数量级规划加速。
4. **WILDACTOR：无约束身份保持视频生成**
   WildActor 针对视频生成中身份漂移问题，构建 Actor-18M 大规模多视角人体数据集（160 万视频、1800 万图像），提出非对称身份保持注意力和视角自适应采样框架；实现任意视角条件化身份保持人体视频生成。
5. **Progressive Residual Warmup：语言模型预训练的逐层残差预热策略**
   Progressive Residual Warmup 观察到 Transformer 预训练的阶段性特征和浅层先于深层收敛，提出为残差连接施加随训练步数逐层递增的标量预热策略；无缝适用各类 Transformer 变体，改进预训练稳定性与收敛速度。
6. **RoboMME：面向机器人通用策略的记忆基准测试与理解**
   RoboMME 针对记忆增强机器人策略缺乏系统评估的问题，构建包含 16 个任务的统一基准，基于认知心理学分为时间、空间、对象、程序四个维度；同时开发 14 种记忆增强 VLA 变体，实现首个大规模系统化评估框架。
7. **推理模型难以控制其思维链**
   本文研究推理模型思维链 (CoT) 可控性问题，通过 CoT-Control 评估套件测试模型遵循显式 CoT 约束的能力；发现推理模型 CoT 可控性极低（多数 <10%），远低于输出可控性，揭示重要安全隐患。
8. **HiMAP-Travel：面向长时域约束旅行规划的层级多智能体框架**
   HiMAP-Travel 针对序列式智能体在长时域规划中的约束漂移问题，提出层级多智能体架构将战略分配与战术执行解耦；通过同步全局状态和协商协议维持硬约束，将规划范围从 O(T) 降至 O(T/D)。
9. **FlashPrefill：基于即时模式发现与动态阈值的超快长上下文预填充**
   FlashPrefill 针对自注意力二次复杂度是长上下文 prefill 瓶颈的问题，提出即时模式发现识别 vertical/slash/block-sparse 注意力模式，采用基于最大值的动态阈值避免排序；256K 序列实现 27.78x 加速，短序列仍保持 1.71x 加速。
10. **π − StepNFT**
    —— Flow − basedVLA
    -StepNFT 针对 Flow-based VLA 在线强化学习中探索空间受限与监督失配的矛盾，通过 SDE 采样扩展探索空间，施加步级监督直接瞄准下一求解器状态；实现更宽探索空间与精细步级监督的协调，改进在线强化学习效果。

Penguin-VL：探索基于 LLM 视觉编码器的紧凑 VLM 性能极限

Zhang*, Ke*†, Yang*, Gao*, Qu* 等 — Tencent AI Lab, 2026

1. 核心动机与问题

当前主流 VLM（如 Qwen3-VL、InternVL）依赖大规模参数和繁重训练流程，严重阻碍在移动端/边缘设备的部署。本文探索**紧凑型（2B/8B）VLM 的性能极限**，核心发现：性能瓶颈不在 LLM 或数据，而在**视觉骨干本身**。

现有 VLM 普遍采用 CLIP/SigLIP 对比预训练初始化视觉编码器，但存在根本性的**目标不匹配**：

- 对比学习为**判别式范式**，仅对全局摘要 token（[CLS] 或 attention pooling）施加监督，与语言模型的序列 token 预测目标根本不一致；
- 对比学习优化粗粒度、类别级不变性，**抑制细粒度视觉线索**（密集描述、复杂推理所需）；
- SigLIP 2 等改进仍保留 ViT 的视觉专属归纳偏置，未充分对齐生成任务。

Penguin-VL 提出全新思路：**直接从纯文本 LLM 初始化视觉编码器**，借助 LLM 的丰富语义先验和高效 Transformer 架构，实现更高的视觉保真度和数据效率。在 2B/8B 规模下，在文档理解、视觉知识、视频时序推理等多项任务上超越 Qwen3-VL 等领先模型。

2. 系统架构

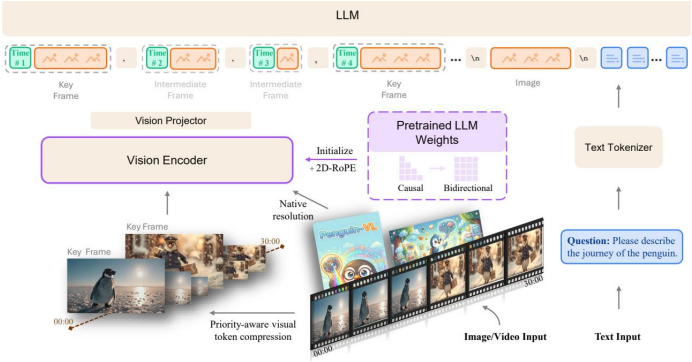

图 1：*Penguin-VL* 架构概览。视觉编码器由 *Qwen3-0.6B* 初始化，配合 *2D-RoPE* 和双向注意力；*TRA* 策略动态分配视频帧 *token* 预算。

Penguin-VL 采用统一三模块设计：(i) 基于 LLM 的视觉编码器（Penguin-Encoder），(ii) MLP 视觉-语言投影器，(iii) LLM 解码器（Qwen3 系列）。

2.1 Penguin-Encoder：从文本 LLM 到视觉编码器

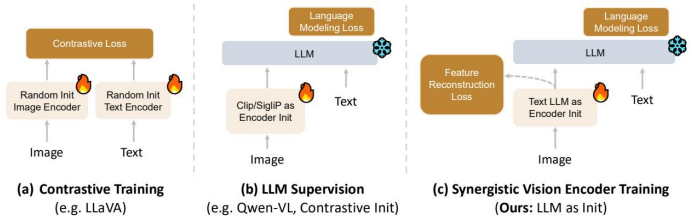

图 2：视觉编码器训练范式对比。*(a)* 对比训练需海量数据且细粒度对齐不足；*(b)* 直接 *LLM* 监督对数据质量敏感；*(c) Penguin* 从 *LLM* 权重初始化，分布接近便于对齐。

从 Qwen3-0.6B 纯文本 LLM 直接初始化（去除非视觉参数后约 **400M** 参数），进行两项关键架构调整：

- 将因果自注意力改为**双向全注意力**，支持视觉 token 的对称交互；
- 引入 **2D-RoPE** 位置编码，支持可变分辨率输入。

四大实际优势：(i) **架构表达力**——QK 归一化等高级设计增强特征稳定性；(ii) **原生对齐**——编码器起始表示空间与下游 LLM 兼容，最小化模态鸿沟；(iii) **语义先验**——继承丰富语言知识；(iv) **可扩展性**——可沿 LLM 设计原则扩展至 1.5B+ 参数。

2.2 混合监督预训练：三重蒸馏损失

为将 LLM 初始化编码器与视觉特征空间对齐，引入重建（蒸馏）损失。设编码器特征 F_s，教师特征 F_t（VL3-SigLIP-NaViT）：

(1) 幅度损失——直接监督特征绝对值：$L_A = \frac{1}{N}\sum_N |F_s - F_t|$

(2) 方向损失——余弦相似度对齐特征方向，防止表示坍塌：$L_D = \frac{1}{N}\sum_N \mathrm{tr}\left(\frac{F_s F_t^\top}{\|F_s\|_2 \|F_t\|_2}\right)$

(3) 关系损失——监督 patch 间交互关系（注意力机制关注 token 间关系而非绝对属性），通过自相关相似度显式监督：

$$L_R = \frac{1}{N}\sum_N \left| \frac{F_s F_s^\top}{\|F_s\|_2^2} - \frac{F_t F_t^\top}{\|F_t\|_2^2} \right|$$

消融实验证明关系损失对性能提升**最为关键**（平均分从 33.3 提升至 34.6）。

2.3 时间冗余感知（TRA）Token 压缩

视频处理引入 TRA 策略，基于时间相似度将帧分为**关键帧**（快速变化）和**中间帧**（稳定上下文），动态分配 token 预算。设全局预算 $T_{\max}$，每帧最低 token 数 $T_{\min}$，三级级联压缩：

阶段 1（保分辨率）：若 $\sum_{k\in\mathcal{K}} T_k + \sum_{i\in\mathcal{I}} T_i \le T_{\max}$，全帧原始分辨率编码。

阶段 2（同步缩放）：超预算时，关键帧与中间帧按固定比例（$T_k \approx 16T_i$）同步缩放：$T_k \leftarrow \alpha T_k$，$T_i \leftarrow \alpha T_i$，$\alpha \in (0, 1]$，保持跨时间空间一致性。

阶段 3（饱和感知缩放）：中间帧达到下界 $T_{\min}$ 后固定，剩余压力全部转移至关键帧。系统设计保证关键帧 T_k 永不突破 $T_{\min}$。

3. 数据构建

3.1 图像数据（Penguin-Recap-I）

从 COYO-700M 和 DataComp-1B 采样，经两阶段筛选：(1) 基础视觉属性过滤（分辨率、宽高比、损坏检测）；(2) **层次化 k-means 聚类**促进语义多样性——先对子集聚类获粗聚心，全量分配后递归细粒度聚类，贪心选择每簇内嵌入空间最大分离的样本。最终 **57.2M** 图文对。标注采用结构化多维度分析（全局语义、主体、动作、空间关系、场景属性、OCR、图像质量、情绪、知识推理），再由模型合成综合长描述。

3.2 视频数据（Penguin-Recap-V / Penguin-QA）

从 29 个公开数据集筛选 **3.7M** 视频文本对。多粒度标注体系：(1) 事件级原子描述（带时间戳的细粒度动作）；(2) 章节级叙事综合（逻辑分组事件为叙事章节）；(3) 整体视频摘要（主题、角色发展等）。时间推理 QA：从密集时间描述派生时间排序和时间定位任务。

4. 四阶段训练流程

阶段 1：编码器预训练。分两步：(a) 低分辨率（≤2048 token/∼600×600 像素），约 223M 样本（含 220M 图文 + 2.8M 无标签图表），联合使用 LLM 交叉熵 + 三重重建损失，LLM 冻结；(b) 高分辨率（≤10240 token），去除重建分支，约 47M 高质量重标注样本微调。学习率：编码器 $1\times10^{-3} \to 5\times10^{-4}$，投影器 1×10^{-3}。

阶段 2：VLM 预训练。全参数可训练（LLM + 编码器 + 投影器），约 **121M** 样本。数据组成：通用描述 64%、文档、细粒度、科学、OCR、代码、数学及纯文本。纯文本数据有效缓解语言能力灾难性遗忘。区域定位采用统一整数坐标系 $[0, 1000]$，7.7M 定位样本 + 1.5M 区域描述 QA。编码器学习率降至 1×10^{-4}。

阶段 3：监督微调（SFT）。图像 SFT：**39M** 样本，覆盖通用 & 描述 32.6%、文档 & 图表 20.9%、OCR 16.6%、定位 & 计数 10.1%、数学 8.9%、多图 & 科学 3.7%。视频 SFT：通用理解 77.6%、动作识别 12.7%、时间定位 6.9%、第一人称视频 2.8%。全参数统一学习率 1×10^{-5}。

5. 核心实验结果

5.1 图像基准（2B 模型）

基准	Penguin 2B	Qwen3-VL 2B	InternVL3.5 2B
DocVQA	**94.1**	93.3	89.4
ChartQA	**86.6**	76.9	80.7
InfoVQA	**77.8**	72.4	70.8
AI2D	**80.7**	76.9	78.8
RealWorldQA	**70.2**	63.9	62.0
V-star	**83.8**	74.9	69.1
MathVista	**67.3**	61.3	60.8

文档理解和视觉知识任务全面领先。数学方面 MathVista 最优（67.3 vs 61.3），但 MathVerse 落后于 Qwen3-VL（35.9 vs 52.1），可能受限于数学 SFT 数据量。MMMU-Pro 略低于 Qwen3-VL（31.4 vs 36.5）。

5.2 图像基准（8B 模型）

Penguin-8B 在 DocVQA 达 **96.2**、ChartQA **90.5**、InfoVQA **86.8**、AI2D **86.1**、V-star **90.2**、MathVista **77.4**，多项超越 Qwen3-VL 8B。RealWorldQA 达 75.8（vs Qwen3-VL 71.5）。但 MMMU-Pro（40.2 vs 55.9）、MathVerse（50.8 vs 62.1）、BLINK（58.2 vs 69.1）仍落后，深层逻辑链推理能力有待加强。GPT-5 nano 在多数指标上大幅落后。

5.3 视频基准

2B 模型表现尤为突出：LongVideoBench **59.5**（超 Qwen3-VL 7.4 分）、NextQA **79.9**、Charades-STA **56.2**（超 InternVL3.5 达 34 分）、EgoSchema **57.6**、PerceptionTest **70.4**。8B 模型：LongVideoBench **67.0**、NextQA **85.4**、Charades-STA **61.4**（超 Qwen3-VL 5.4 分、超 InternVL3.5 28.6 分）、ActivityNetQA **65.2**、PerceptionTest **78.0**。时间定位能力显著优于所有基线。VideoMME 上 8B 为 66.2 略低于 Qwen3-VL 的 71.4。

6. 消融实验

6.1 初始化与重建损失消融

采用轻量管线（10% Stage 1 数据 + DenseFusion-1M + LLaVA-665k）在 5 个基准上评估：

- **随机初始化**平均分仅 31.3；**LLM 权重初始化**提升至 34.6（**+3.3**），证明 LLM 先验至关重要——成熟权重提供良好初始化点，继承序列建模能力，使视觉表示天然兼容下游 LLM；
- **无重建损失**：32.6；**有基础重建**：33.3；**加入关系损失**：**34.6**——关系损失对齐注意力机制特性，显式监督 patch 间交互是关键。

6.2 与现有视觉编码器对比

在统一设置下（Qwen3-1.7B 作 LLM，DenseFusion-1M 对齐 + LLaVA-665k 微调）：

- Penguin-Encoder 平均分 **49.3**，远超 SigLIP2 原始分辨率 32.4、SigLIP2 any-resolution 36.7、VL3-NaViT 43.0；
- 即使 SigLIP2 用完全相同数据/流程继续训练（average 45.3），Penguin-Encoder 仍优（49.3），证明架构优势而非数据优势；
- Qwen3-VL ViT（>40B 样本预训练）平均 47.3，Penguin-Encoder 仅用 240M 样本即超越；
- 随数据规模增大，Penguin-Encoder 增益**逐步扩大**，展现更高性能天花板。

7. 关键设计与相关工作对比

与传统对比预训练（CLIP/SigLIP）的根本区别：(1) 生成式对齐取代判别式对齐——细粒度视觉特征直接映射到 LLM 高层语义空间，天然适配自回归解码；(2) 无需海量对比数据（40B+ → 240M）；(3) 类比语音建模（如 LLM 微调处理连续语音信号）的成功经验。与 Qwen3-VL 对比：后者采用 SigLIP-2 风格骨干并从公开视觉检查点继续训练，而 Penguin 直接从纯文本 LLM 初始化。MLP 投影器设计刻意保持简洁——不进行空间 token 压缩，直接投射维度以匹配 LLM 隐藏层大小。

8. 局限性与未来方向

- MMMU-Pro、MathVerse 等抽象多步推理任务上仍落后于 Qwen3-VL，深层逻辑链能力有待加强，可能需要更多数学/推理导向的 SFT 数据；
- OCRBench 上 2B/8B 均未超越 Qwen3-VL（810/852 vs 858/896），精细字符识别仍有提升空间；
- VideoMME 等综合视频理解基准上尚有差距（66.2 vs 71.4 @8B），全局视频语义整合能力可进一步优化；
- 当前编码器固定为 400M 参数（Qwen3-0.6B），框架可扩展至 1.5B+ 参数但尚未验证；
- TRA 压缩策略依赖帧间相似度阈值等超参数，极长视频场景下的鲁棒性有待探索；
- 视觉编码器与 LLM 解码器的联合扩展规律（scaling law）尚未系统研究。

BandPO：通过概率感知界桥接信赖域与比率裁剪的 LLM 强化学习

Li, Wang, Gao, Yao, Wang, Yin, Qiu — Fudan University & Shanghai Innovation Institute, 2025

1. 动机与问题背景

基于人类反馈的强化学习（RLHF）是 LLM 后训练的主流范式，其中**近端约束**（proximal constraint）是平衡优化稳定性与探索效率的关键机制。PPO 通过裁剪代理目标来模拟信赖域更新，避免 TRPO 所需的高昂 Fisher 信息计算。该裁剪机制已成为 GRPO 及其变体的默认配置。

然而，Park 等人指出固定裁剪隐含地抑制探索，对策略熵产生有害偏置。在可验证奖励的 RL（RLVR）场景中，**上界裁剪降低熵的效应占主导**，即使在纯随机奖励下也会导致净熵减少。DAPO 提出的 Clip-Higher 策略虽可延缓熵坍塌，但 Cui 等人指出其不稳定性——饱和后常导致性能崩溃。这表明单纯调整阈值无法解决固定裁剪界的内在局限。

2. 固定裁剪的结构性瓶颈

经典裁剪将概率比 $r_t(\theta) = \pi_\theta(a|s)/\pi_{\text{old}}(a|s)$ 约束在 $[1-\epsilon_-, 1+\epsilon_+]$ 内。将此不等式乘以 $\pi_{\text{old}}(a|s)$ 后可得概率变化的可行集 C_{clip}：

$$\Delta\pi(a|s) \in [-\epsilon_-\pi_{\text{old}}(a|s),\ \epsilon_+\pi_{\text{old}}(a|s)].$$

理论上概率单纯形允许的最大变化范围为 $C_{\text{simplex}} = [-\pi_{\text{old}},\ 1-\pi_{\text{old}}]$。**关键瓶颈**：固定界强制概率变化与旧概率成**线性比例**——当 π_{old} 很小时，允许的向上变化趋近于零，与理论上界严重矛盾。

具体示例：尾部 token $\pi_{\text{old}} = 0.08$, $\epsilon_+ = 0.28$ 时，$\Delta\pi \le 0.016$（理论容量 0.92）。若要实现 $\Delta\pi \approx 0.4$ 需 $\epsilon_+ \approx 5.0$，但这对头部 token（$\pi_{\text{old}} = 0.8$）会导致 $\Delta\pi \le 4.0$ 远超物理极限 0.2，约束完全失效。静态裁剪从根本上无法调和稳定优化与尾部探索的矛盾。

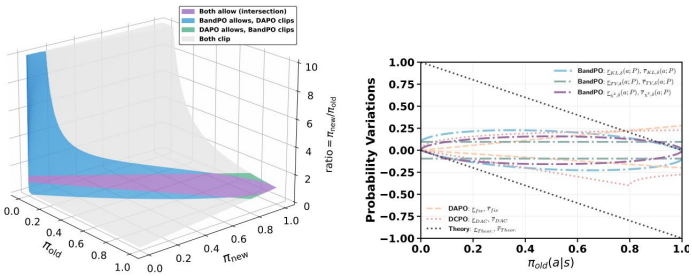

(a) Ratio clipping regions (b) Bounds of Probability Variation

图 1：*(a) BandPO vs DAPO* 的裁剪区域对比，蓝色区域为低概率动作获得的扩展空间。*(b)* 概率变化界对比：*BandPO* 严格遵循单纯形约束，同时为低概率动作解锁显著的向上变化空间。

3. 方法：BandPO

3.1 f-散度诱导的信赖域

令 $P(\cdot) \triangleq \pi_{\text{old}}(\cdot|s_t)$，$Q(\cdot) \triangleq \pi_\theta(\cdot|s_t)$。对严格凸函数 f 满足 $f(1)=0$，f-散度为 $D_f(Q\|P) = \sum_a P(a) f(Q(a)/P(a))$。信赖域定义为 $\mathcal{T}_{f,\delta}(P) = \{Q \in \Delta^V \mid D_f(Q\|P) \le \delta\}$，其中 $\delta > 0$ 为半径。选取 $f(u) = -\log u + u - 1$ 可恢复 TRPO 的 KL 信赖域。

3.2 Band 算子：从信赖域到概率感知裁剪界

通过求解凸优化问题获得动态上下界：

$$\bar{r}_{f,\delta}(a;P) = \max_{Q\in\mathcal{T}_{f,\delta}(P)} \frac{Q(a)}{P(a)}, \quad \underline{r}_{f,\delta}(a;P) = \min_{Q\in\mathcal{T}_{f,\delta}(P)} \frac{Q(a)}{P(a)}.$$

Band 算子定义为：$\text{Band}_{f,\delta}(r;a,P) \triangleq \text{clip}(r, \underline{r}_{f,\delta}(a;P), \bar{r}_{f,\delta}(a;P))$。与固定区间 $[1-\epsilon, 1+\epsilon]$ 形成鲜明对比，Band 产生仅由单一可解释参数 δ 控制的概率感知动态界。

3.3 化归为一维优化

原问题中 Q 居于高维单纯形（$V \approx 10^5$），直接求解不可行。**引理 1**（均匀补集重缩放最优性）：最优解 $Q^\star$ 在补集 $\mathcal{V}\setminus\{a\}$ 上严格保持相对概率比例不变，即 $Q^\star(b)/P(b) = c$，$\forall b \ne a$。由单纯形归一化约束 $c(r) = (1-rp)/(1-p)$，散度坍缩为**一元函数**：

$$g_f(p,r) = pf(r) + (1-p)f\left(\frac{1-rp}{1-p}\right) = \delta.$$

定理 1（信赖域约束的精确标量化）：$g_f(p,r)$ 关于 r 严格凸，在 $r=1$ 取全局最小值 0。对任意 $\delta > 0$，方程 $g_f(p,r) = \delta$ 恰有两个根，分别对应最优下界 $\underline{r}$ 和上界 $\bar{r}$：

$$\underline{r}_{f,\delta} = \min\{r \in [0,1] \mid g_f(p,r) = \delta\},$$
$$\bar{r}_{f,\delta} = \max\{r \in [1,1/p] \mid g_f(p,r) = \delta\}.$$

3.4 Band 界的理论性质

命题 1（渐近行为）：当 $p \to 0^+$ 时，$\bar{r} \to +\infty$（尾部动作获得无限扩展空间），$\underline{r} \to 0$；当 $p \to 1^-$ 时，$\bar{r} \to 1$（头部动作被严格约束）。

命题 2（严格单调性）：上界 $\bar{r}_{f,\delta}(p)$ 关于 p 严格递减，下界 $\underline{r}_{f,\delta}(p)$ 关于 p 严格递增。

这两条性质从理论上证明 Band **天然解决了探索瓶颈**：低概率动作自动获得更大的向上更新空间，高概率动作则被施加更紧约束以确保稳定性。

3.5 闭式解与数值求解

命题 4 给出 TV 和 Pearson χ^2 的闭式解。TV（$f(u) = \frac{1}{2}|u-1|$）：

$$\bar{r}_{\text{TV},\delta}(p) = 1 + \delta/p, \quad \underline{r}_{\text{TV},\delta}(p) = 1 - \delta/p.$$

Pearson χ^2（$f(u) = (u-1)^2$）：

$$\bar{r}_{\chi^2,\delta}(p) = 1 + \sqrt{\delta(1-p)/p}, \quad \underline{r}_{\chi^2,\delta}(p) = 1 - \sqrt{\delta(1-p)/p}.$$

对 KL 散度等无闭式逆的情形，使用二**分法/Brent 法**在 $[0,1)$ 和 $(1,1/p]$ 上求根。作者实现了 **CUDA 加速并行二分法**以保证效率。**单纯形饱和**（命题 3）：当 δ 足够大时散度约束超出单纯形边界，此时界退化为 $\bar{r} = 1/p$（或 $\underline{r} = 0$）。

3.6 BandPO 目标函数

将 GRPO 中的 clip 替换为 Band：

$$\mathcal{T}_t^{\text{Band}}(\theta; y_i) = \min\big(r_{t,i}A_{t,i},\ \text{Band}_{f,\delta}(r_{t,i}; y_{t,i}, \pi_{\text{old}})A_{t,i}\big) - \beta D_{\text{KL}}(\pi_{\text{ref}}$$

整体目标在组内 G 个输出和 token 上平均，与 GRPO 框架完全兼容，仅需用 δ 替代 ϵ_+, ϵ_- 两个超参数。

4. 实验设置

模型：Qwen2.5-3B-Instruct、DeepSeek-R1-Distill 系列（Qwen-1.5B/7B、Llama-8B）。**训练集**：DAPO + MATH Levels 3–5 复合集。**验证集**：AMC 2023、AIME 2024、AIME 2025。**硬件**：8× NVIDIA H200。**超参**：$\epsilon_+ = 0.28$，$\epsilon_- = 0.2$（基线）；BandPO 使用 KL 散度，$\delta = 0.05$。

5. 主要结果

方法 / 模型	平均 mean@32	平均 pass@32
Qwen2.5-3B-Instruct (800 steps)		
GRPO	17.57	32.60
Clip-Higher	20.47	40.60
$\text{Band}_{\text{KL},0.05}$	**22.00**	**42.01**
DeepSeek-R1-Distill-Qwen-7B (500 steps)		
GRPO	49.04	66.78
Clip-Higher	48.37	66.69
$\text{Band}_{\text{KL},0.05}$	**51.44**	**67.12**
DeepSeek-R1-Distill-Llama-8B (500 steps)		
GRPO	44.08	64.97
Clip-Higher	46.57	67.49
$\text{Band}_{\text{KL},0.05}$	**47.41**	**67.94**

BandPO 在所有模型和数据集上均一致超越基线。mean@32 较 GRPO 至少提升 2.0 分，3B 模型在 AMC2023 上提升约 10 分。pass@32 方面，3B 模型相对提升达 **28.9%**。Clip-Higher 在 7B AIME 上出现 1–2 分回退，1.5B GRPO 在约第 340 步持续崩溃（多次实验验证），而 BandPO 始终稳定。

6. 消融与深入分析

6.1 松弛 Band 界损害性能

将 Band 在高概率区域启发式对齐到 Clip-Higher 范围（Relaxed Band），结果**一致退化**：7B/8B 平均 mean@32 下降 ~0.5，AIME 2025 pass@32 下降约 3 分；1.5B 模型 AIME 2024 pass@32 骤降近 8 分。这证明裁剪界不应启发式修改，而应源于严格理论推导。

6.2 半径 δ 对小模型更敏感

测试 $\delta \in \{0.03, 0.05, 0.10\}$：$\delta = 0.05$ 在 3B 和 7B 上均最优。3B 模型中最优与次优设置差距约 **10% mean@32**、5% pass@32；7B 模型波动仅 2–3%。小模型的优化景观更脆弱，需要精确的信赖域管理。推荐 $\delta = 0.05$ 作为默认起点。

6.3 BandPO 解锁尾部动作探索

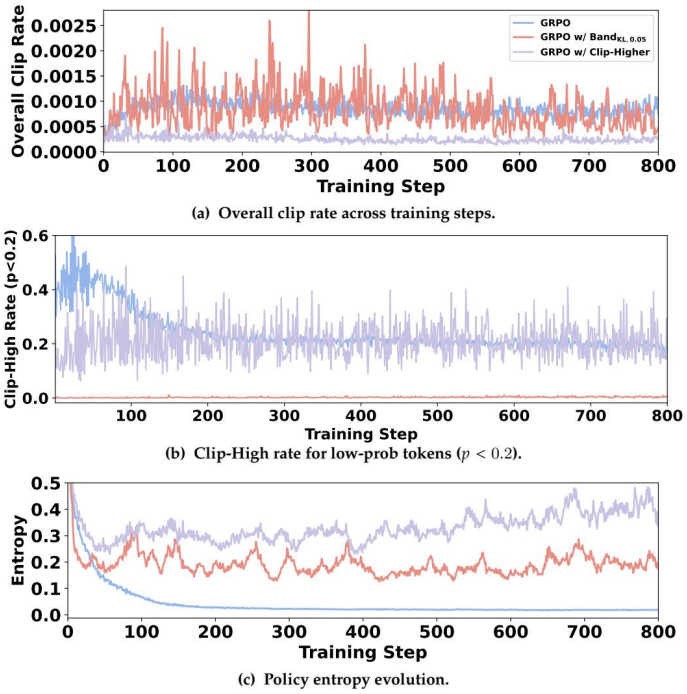

(a) Overall clip rate across training steps.

(b) Clip-High rate for low-prob tokens ($p < 0.2$).

(c) Policy entropy evolution.

图 2: 训练动态对比。*(a)* 总裁剪率。*(b)* 低概率 *token* 上界裁剪占比。*(c)* 策略熵演化。

如图 2 所示：(a) Band 总裁剪率与经典裁剪相当，Clip-Higher 低约 50%。(b) **关键发现**：固定界方法中低概率 token（$p < 0.2$）的上界裁剪占总裁剪量约 20%，经典裁剪早期飙升至 60%——对应图 (c) 中的**快速熵坍塌**。Band 将尾部裁剪率降至**近零**。(c) Band 的熵演化与 Clip-Higher 同样稳定，最终熵高出经典裁剪**一个数量级**（0.2 vs 0.02）。

核心洞察：优化稳定性不在于减少总裁剪量，而在于**重新分配裁剪预算**——对尾部动作放松约束以促进探索，对头部动作收紧约束以确保稳定。

7. 与相关工作的对比

- **vs. TRPO**：TRPO 直接优化 KL 约束问题，需共轭梯度法，计算成本高；BandPO 将信赖域**投影**为逐 token 裁剪界，保持 PPO 级效率；
- **vs. DAPO/Clip-Higher**：启发式非对称界 $\epsilon_+ = 0.28$，高概率区域约束违反单纯形极限，缺乏理论保证；
- **vs. DCPO**：通过不等式松弛推导动态界，但同样在高概率区域违反理论上界，且缺乏统一框架；
- **BandPO 优势**：统一 f-散度框架，单参数 δ 控制，严格满足单纯形约束，凸优化保证全局最优。

8. 局限性与未来方向

- **数值求解开销**：TV 和 χ^2 有闭式解，但 KL 需迭代求根。可通过预计算高精度查找表降至 $O(1)$ 开销；
- **静态信赖域假设**：当前对所有 token 使用全局统一 δ，未区分常规语法 token 和关键推理 token 的不同稳定性需求；
- **未来工作**：自适应 Band——根据 token 级策略熵或语义不确定性动态调节 δ_t，对低熵语法过渡施加紧约束，对高风险推理步骤放松约束，进一步解耦稳定性与探索的权衡。

Planning in 8 Tokens：面向潜在世界模型的紧凑离散分词器

Kim[1], Seo[2], Lee[2], Cho[2,3], Kwak[2] — [1]KAIST, [2]POSTECH, [3]RLWRLD, 2025

1. 动机与问题定义

世界模型（World Model）通过学习环境动态来支持规划和策略学习，但当前方法在**决策时规划**中面临严重的计算瓶颈。核心问题在于潜在表示的 token 数量：传统分词器（如 SD-VAE）将每张图像编码为数百个 token（如 784 个），基于注意力机制的架构使得计算成本随 token 数二**次增长**。例如，最先进的导航世界模型 NWM 每个 episode 需要约 3 分钟计算，无法满足实时控制需求。

人类并非通过像素级记忆来导航世界，而是通过**紧凑的心理表征**——仅保留决策所需信息的高效抽象。本文提出了一个关键假设：**激进压缩可能反而有益**——迫使世界模型学习更抽象、与动作相关的表征，而非保留每个感知细节。

本文提出 **CompACT**（Compact Discrete Tokenizer），将每张图像压缩至仅 **8 个离散 token**（约 128 bits），相比 SD-VAE 的 784 个 token 实现了近百倍压缩。结合离散潜在空间避免了扩散模型的迭代去噪，实现了**数量级**的规划加速。

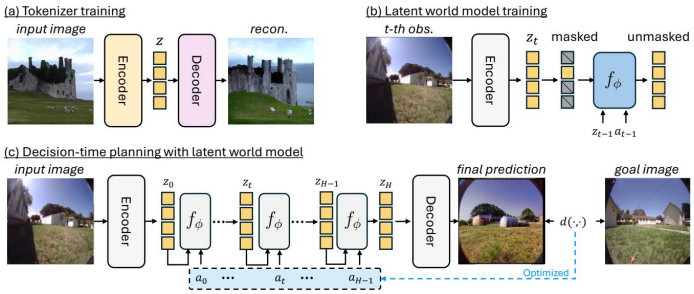

图 1：潜在世界模型整体框架。(a) 图像分词器训练；(b) 潜在世界模型训练；(c) 测试时通过 MPC 搜索最优动作序列。

2. 方法论

2.1 潜在生成模型作为世界模型

给定观测序列 $\boldsymbol{O} = [o_0, \ldots, o_T] \in \mathbb{R}^{T\times H\times W\times 3}$ 和动作 $\boldsymbol{A} = [a_0, \ldots, a_T] \in \mathbb{R}^{T\times 3}$，世界模型建模条件分布：$f_\theta : (o_t, a_t) \mapsto p_\theta(o_{t+1}|o_t, a_t)$。在高维像素空间直接建模代价过高，因此通过分词器将观测编码为低维潜在 token $z \in \mathbb{R}^{N\times D}$，潜在世界模型为：

$$f_\phi : (z_t, a_t) \mapsto p_\phi(z_{t+1}|z_t, a_t)$$

其中 $z_t = \mathcal{E}(o_t)$。token 数 N 直接决定注意力架构的二次计算成本，保持 N 极小是实现高效规划的关键。

规划时（图 1(c)），初始化候选动作序列 $\mathbf{a} = [a_0, \ldots, a_{H-1}]$，通过世界模型 rollout 预测未来状态 $z_{t+1} \sim f_\phi(z_t, a_t)$，然后用代价函数 $C(\mathbf{a}) = d(\hat{o}_H, o_{\text{goal}})$（如 LPIPS 距离）评估，并通过 CEM（交叉熵方法）等采样优化求解 $\mathbf{a}^* = \arg\min_{\mathbf{a}} C(\mathbf{a})$。

2.2 CompACT 分词器

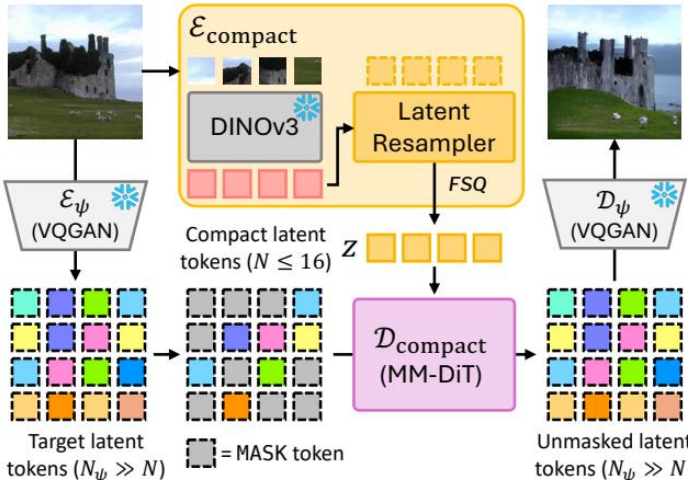

图 2：CompACT 分词器架构。训练时仅更新 latent resampler 和 $\mathcal{D}_{\text{compact}}$。

语义编码（冻结特征提取）。编码器 $\mathcal{E}_{\text{compact}} : \mathbb{R}^{H\times W\times 3} \to \{1, \ldots, K\}^N$ 将图像编码为 $N \leq 16$ 个离散 token。核心设计原则：仅保留**规划关键的语义信息**，丢弃面向重建的高频特征。架构包含三部分：

- **冻结 DINOv3**：提取语义 patch 表征，已天然抽象掉纹理、光照等底层细节；
- **潜在重采样器**（Latent Resampler）：N 个可学习 query token 通过 transformer 解码器的交叉注意力层从冻结的 DINOv3 输出中蒸馏高层语义线索；
- **有限标量量化**（FSQ）：levels 设为 $[8, 8, 8, 5, 5, 5]$，构建约 2^{16} 大小码本，每个 token 约 16 bits。

关键洞察：冻结视觉基础模型至关重要。消融实验（表 2）显示微调 DINOv3-B 导致 rFID 从 2.40 恶化至 5.22——微调使表征偏向重建特征，紧凑 token 丢失了生成式解码所依赖的高层语义信息。

生成式解码。从 $N \leq 16$ 个 token 直接重建像素是病态问题。CompACT 采用**条件生成**策略：解码器 $\mathcal{D}_{\text{compact}} : \{1, \ldots, K\}^N \to \{1, \ldots, K_\psi\}^{N_\psi}$ 学习以紧凑 token z 为条件，生成预训练目标分词器（MaskGIT-VQGAN, $N_\psi = 196$）的 token 序列 z^ψ。训练目标为掩码生成建模：

$$\mathcal{L}_{\text{tok}} = -\mathbb{E}_{z^\psi}\left[\log p(z^\psi | z, M(z^\psi))\right]$$

其中 $M(\cdot)$ 为随机掩码。推理时从全掩码序列开始，按置信度渐进式 unmask，紧凑 token 提供全程语义引导。最终重建：$\hat{o} = (\mathcal{D}_\psi \circ \mathcal{D}_{\text{compact}} \circ \mathcal{E}_{\text{compact}})(o)$。解码器采用 MM-DiT 架构（双流处理紧凑 token 与目标 token，通过拼接自注意力融合）。整个 CompACT 含 775M 参数。

2.3 CompACT 潜在空间中的世界模型

世界模型训练目标同样采用掩码生成建模：

$$\mathcal{L}_{\text{world}} = -\mathbb{E}_{z_t, a_t, z_{t+1}}\left[\log p(z_{t+1} | z_t, a_t, M(z_{t+1}))\right]$$

针对不同任务采用两种架构：(1) **导航**：自回归框架，DiT 架构，固定历史窗口 $\{z_{t-\tau}, \ldots, z_t\}$ 条件预测，训练时随机掩码历史 token 以增强鲁棒性；(2) **机器人操控**：块因果 transformer，并行预测多个未来帧 $\{z_{t+1}, \ldots, z_{t+K}\}$。两种训练方案均可理解为离散版 diffusion forcing。

3. 理论分析：规划充分性

定义 1（规划充分性）：潜在表征 $z = \mathcal{E}(o)$ 是规划充分的，当且仅当 $I(z; a^*) = I(o; a^*)$。

命题 1（最小描述长度）：若最优规划算法确定性（$H(a^*|o) = 0$），则规划充分表征的最小熵为：

$$\min_{z;\text{plan-suff.}} H(z) = I(o; a^*) = H(a^*) \ll H(o)$$

即所需信息量由**动作熵**（而非观测熵）决定。机器人动作空间低维（3–5 DOF），因此 $H(a^*) \ll H(o)$，CompACT 的 128–256 bits 远超此下界，为规划充分性提供了充裕余量。

4. 实验结果

4.1 分词器重建性能

模型	类型	#tok	rFID↓
SD-VAE	连续	1024	0.64
MaskGIT-VQGAN	离散	256	1.83
FlexTok (16 tok)	离散	16	5.60
CompACT	离散	**16**	**2.40**
CompACT	离散	**8**	3.21

CompACT 在仅 16 tokens 下 rFID 达 2.40，IS 达 209.0，**超越**其目标分词器 MaskGIT-VQGAN（IS 186.7），表明语义编码器更好地保留了感知相关特征。跨主干消融（SigLIP-2: rFID 2.09, MAE: 3.43, DINOv3: 2.40）证实方法不依赖特定视觉基础模型。

4.2 紧凑 token 的特性分析

模块化场景元素： 注意力可视化显示每个紧凑 token 关注语义一致的区域——ImageNet 中关注独立物体，RECON 中关注建筑结构，RoboNet 中隔离末端执行器和操作目标。

逆动力学模型验证： 在 RoboNet 上训练 IDM，CompACT (16 tok) 的 $R^2 = 0.716$ **优于** 256-token 基线 ($R^2 = 0.684$)，以 16× 更少 token 实现更优的动作相关信息保留。

4.3 导航规划

分词器	#tok	ATE↓	RPE↓	延迟 (s)↓
SD-VAE	784	1.262	0.354	178.78
FlexTok	64	1.484	0.400	16.68
FlexTok	16	1.625	0.446	14.48
CompACT	**16**	1.330	0.390	5.78
CompACT	**8**	1.373	0.401	**4.83**

CompACT 实现约 **40× 规划加速**（178.78s → 4.83s），同时保持与 784-token SD-VAE 可比的规划精度。8-token 模型**超越** FlexTok 64-token，验证了精心设计的极端压缩可同时提升效率和规划性能。延迟分解：SD-VAE rollout 占 177.05s（99.6%），CompACT 降至 1.34s（减少 99.2%）。

4.4 动作条件视频预测

在 RoboNet 上，CompACT (16 tok) 相比 256-token 基线实现**动作预测误差降低** 3×（APE: 0.1122 vs 0.3383）和 5.2× 生成加速（0.740s vs 3.826s）。定性结果显示 CompACT 生成的视频保持一致的末端执行器运动，而基线分词器无法保留动作驱动的动态。

4.5 关键设计选择消融

- **历史掩码**：训练时掩码历史 token 显著提升规划精度（ATE: 1.330 vs 1.480）；
- **代价函数**：像素空间 LPIPS (ATE 1.330) 略优于潜在空间 L1 (1.379)，但后者可实现约 80× 加速（完全跳过解码）；
- **冻结编码器**：微调视觉编码器导致 ATE 从 1.330 恶化至 1.472，与重建质量退化一致；
- **生成式解码**：替换为前馈解码器导致 rFID 从 2.40 暴涨至 28.80；
- **编码器架构**：从头训练 ViT-B（rFID 7.28）远不如冻结 DINOv3 + 重采样器（2.40）。

4.6 闭环机器人操控

在 RoboMimic Lift 任务上,CompACT (16 tok) 与 256-token 基线成功率持平（均 56%），但所需步数更少（55.1 vs 66.8），表明语义级潜在规划产生更直接的路径。

5. 讨论与局限

核心贡献： (1) 首个将图像压缩至 8 个离散 token 仍支持有效规划的分词器；(2) 冻结视觉基础模型 + 生成式解码的设计范式，分离语义保留与感知细节合成；(3) 信息论证明规划充分表征的最小熵由动作熵（而非观测熵）决定。

主要局限：

- 生成式解码器比单步解码慢约 6×（3.87s vs 0.65s），虽在总规划预算中占比较小，但仍有优化空间；
- 极端压缩不可避免地丢失高频细节，对需要精细纹理判断的任务可能不适用；
- 闭环操控实验仅为初步验证（单一简单任务），结合实时观测和本体感觉的完整集成待未来工作；
- 潜在空间代价函数虽极快但精度略有损失，像素级与潜在级代价的最优平衡有待研究；
- 当前仅验证于导航和简单操控，复杂多物体交互和长 horizon 任务的泛化性需进一步确认。

未来方向： 将紧凑 token 与更复杂的规划算法结合（如分层规划），以及探索自适应 token 数量（根据场景复杂度动态调整压缩率），均为有前景的研究方向。

WILDACTOR：无约束身份保持视频生成

WILDACTOR Team — 2026

1. 动机与问题定义

在专业影视制作中，演员的物理一致性是视觉叙事的锚点——同一角色在不同镜头、视角和动作下必须保持**严格不变的身份**。然而，当前视频生成模型（Sora、Kling、Wan 等 DiT 模型）虽能生成高质量视频，却难以在视角变化时维持身份一致性，频繁出现**身份漂移**（面部特征退化、服装纹理不一致）。

现有方法存在两大根本缺陷：

- **面部中心偏差**：基于人脸识别编码器的方法（ID-Animator、EchoVideo 等）过度强调面部判别特征（如发际线），忽略身体，产生“浮动头颅”效应——身体出现幻觉；
- **姿态锁定**：通过简单拼接编码整张参考图的方法（如 VACE）将参考姿态视为标准视角，限制合成角色动作，产生静态“复制粘贴”伪影；
- **数据匮乏**：缺乏大规模野外多视角人体身份数据集。Virtually Being 依赖昂贵的工作室采集，难以扩展至真实场景。

本文提出三项贡献：(1) **Actor-18M**——包含 160 万视频、1800 万参考图像的大规模人体视频数据集；(2) **WILDACTOR**——基于非对称身份保持注意力和视角自适应蒙特卡洛采样的任意视角条件化人体视频生成框架；(3) **Actor-Bench**——全面评估身份保持与语义对齐的基准。

2. Actor-18M 数据集

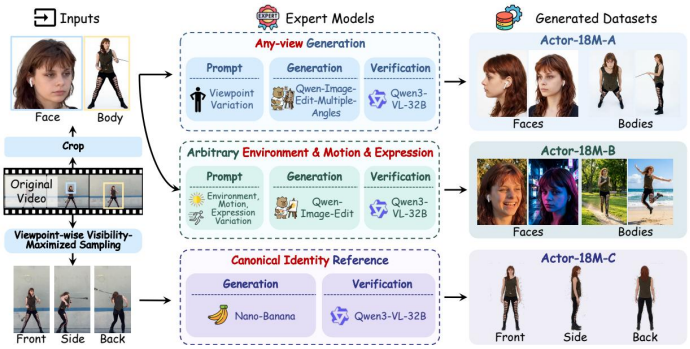

图 1：*Actor-18M* 构建流程。从身份一致视频中提取参考图，分别通过视角变换、属性编辑和标准三视图生成构建三个子集。

2.1 数据收集与过滤

从内部高质量源和 OpenS2V 收集视频，采用**两阶段过滤**：(1) 粗过滤：1 fps 稀疏采样，ArcFace 余弦相似度 < 0.4 的视频直接丢弃；(2) 精细过滤：8 fps 上采样，CoTracker 密集点跟踪去除严重遮挡/快速剪辑，CLIP 帧间一致性 > 0.45 方保留。最终获得 **160 万**单人视频。

2.2 三子集构建

Actor-18M -A（视角变换）。解耦身份与相机视角。使用多角度图像编辑模型从 6 个不同视角合成面部和身体图像，经 Qwen3-VL-32B 验证身份一致性。原始数据存在严重正面偏差（身体正面 63.1%），增强后侧面占比提升至 70.5%，面部非正面视角从 42% 提升至 69%+。

Actor-18M -B（属性多样化）。防止模型过拟合特定背景/光照。定义属性池覆盖 200 种环境、8 种表情、10 种光照、30 种动作。MLLM 生成编辑指令，图像编辑模型合成新参考，经 CLIP-I 检验身份嵌入安全边距。

Actor-18M -C（标准三视图）。提供完整身份锚点。通过 DWPose 姿态估计筛选可从正面/侧面/背面观察的“黄金视频”，选取三个视角最高可见度帧作为锚帧，经 Nano-Banana 生成标准正交角色表，Qwen3-VL-32B 最终质量审核。

2.3 数据统计

总计 160 万视频、1800 万 + 参考图像。面部自裁剪 120 万张 + 生成 601 万张；身体自裁剪 179 万张 + 生成 898 万张。生成数据显著缓解了原始数据的正面视角偏差。

3. WILDACTOR 方法

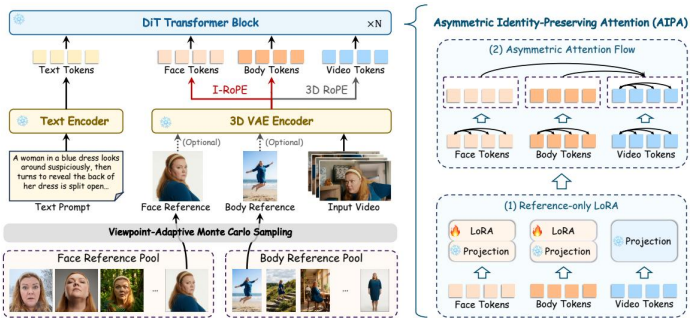

图 2：*WILDACTOR* 架构概览。左：整体架构，视频 *DiT* 以多视角面部和身体参考图为条件，经 *I-RoPE* 区分参考与视频 *token*。右：*AIPA* 细节，身份参考 *token* 通过非对称注意力注入视频 *token*。

3.1 问题形式化

给定文本提示 $\mathcal{C}_{\text{txt}}$、N 张面部参考图 $\mathcal{T}^f = \{\mathcal{T}_k^f\}_{k=1}^N$ 和 M 张身体参考图 $\mathcal{T}^b = \{\mathcal{T}_k^b\}_{k=1}^M$（覆盖多样视角、环境、姿态），生成视频 ν 需同时满足文本对齐和全身身份高保真保持。

3.2 基础模型

基于 5B 参数的 latent video DiT（LongCat-Video 架构），采用 Rectified Flow 训练。视频 $\mathbf{V} \in \mathbb{R}^{T\times H\times W\times 3}$ 经 VAE 编码器 $\mathcal{E}$ 映射为潜变量 $\mathbf{z}_0$，RF 定义线性插值 $\mathbf{z}_t = (1-t)\mathbf{z}_0 + t\epsilon$，DiT $\mathbf{v}_\theta$ 预测速度场：

$$\mathcal{L}_{\text{RF}} = \mathbb{E}_{t,\mathbf{z}_0,\epsilon}\left[w(t)\|\mathbf{v}_\theta(\mathbf{z}_t, t, \mathbf{C}_{\text{ctx}}) - (\epsilon - \mathbf{z}_0)\|_2^2\right]$$

3.3 非对称身份保持注意力（AIPA）

标准全注意力将视频与参考 token 混合，导致**身份泄漏**——静态外观特征主导运动生成，引发姿态锁定。AIPA 通过**非对称信息流**解决此问题：

(1) Reference-only LoRA。仅对参考 token 应用轻量 LoRA 模块，视频 token 始终使用冻结权重。对参考 token $\mathbf{c} \in \{\mathbf{f}_{\text{face}}, \mathbf{f}_{\text{body}}\}$：

$$\mathbf{q}_c, \mathbf{k}_c, \mathbf{v}_c = (\mathbf{W}_{Q,K,V} + \Delta\mathbf{W}^{\text{ref}}_{Q,K,V})\mathbf{c}$$

LoRA 参数由面部和身体参考共享，引入 0.29B 可训练参数（rank-128）。

(2) 非对称注意力流。每个 Transformer 块分两阶段：第一阶段，参考 token 独立自注意力聚合多视角信息为统一身份表示 $\mathbf{C}_{\text{ref}}$，视频 token 同时进行标准自注意力建模时序动态；第二阶段，**仅视频 token 作为 Query**，同时 attend 视频和参考 token：

$$Q = \mathbf{z}_t, \quad K = [\mathbf{z}_t; \mathbf{C}_{\text{ref}}], \quad V = [\mathbf{z}_t; \mathbf{C}_{\text{ref}}]$$

参考 token 不受噪声视频潜变量污染，保证身份保真度且不干扰骨干表示。

3.4 Identity-Aware 3D RoPE (I-RoPE)

视频和身份参考 token 共享注意力上下文时，相同位置编码会导致时序运动与静态外观的歧义。I-RoPE 通过分配不同时空坐标解决：

时间分离：视频 token 使用标准时间索引 $t \in [0, T]$；面部参考 token 偏移 $T + \Delta_f$（$\Delta_f = 4$），身体参考 token 偏移 $T + \Delta_b$（$\Delta_b = 128$）。

空间分离：视频 token 编码为 (t, h, w),$h \in [0, H)$,$w \in [0, W)$。参考 token 的 (h, w) 从 $(H_{\max}, W_{\max})$ 起始，占据联合时空嵌入中的独立空间位置。

3.5 视角自适应蒙特卡洛采样

朴素采样常产生冗余视角（如多张正面图），阻碍多视角信息利用。给定候选集 s，每张图像赋初始权重。采样参考 x^* 后，抑制角度邻域 $|\theta_{x^*} - \theta_{x_j}| < \delta$ 内的候选权重：

$$w_j \leftarrow w_j \cdot \gamma$$

其中 $\gamma < 1$ 为衰减因子（实验取 $\gamma = 0.5$，$\delta = \pi/6$），偏向互补视角，实现身份流形的均匀覆盖。

3.6 训练细节

在 16 块 NVIDIA H100 上以 AdamW（$\mathrm{lr} = 1 \times 10^{-4}$）训练 80K 步：前 70K 步 256p，后 10K 步 480p。所有视频 93 帧。训练时随机采样 0–5 张面部和身体参考图，Actor-18M -A/-B/-C 以 5:2:1 比例混合。

4. Actor-Bench 评估体系

包含 75 个不同主体，均分为三种条件设定（标准三视图、任意视角、野外）。每个主体评估两个轴：

(1) 顺序叙事： Gemini-3-Pro 规划的 3 段连续剧情提示，评估长视频身份一致性。

(2) 上下文泛化： 多样环境/视角/动作下的提示，评估真实场景泛化能力。

评估指标： (a) 身体一致性——Gemini-3-Pro 视角感知管线，匹配最近视角参考，逐帧二值评分取均值 $\mathrm{Score}_{\mathrm{Body}} = \frac{1}{T}\sum_{t=1}^{T} s_t^{body}$；(b) 面部身份——ArcFace 余弦相似度（视角匹配后计算）；(c) 语义对齐——ViCLIP 特征级 + Gemini-3-Pro VLM 级。

5. 实验结果

5.1 定量对比

方法	Face ID	Body	Feat.	VLM
顺序叙事				
Qwen-Edit+I2V	0.521	0.720	0.228	0.733
T2V→I2V (w/o Ref)	0.320	0.450	0.215	0.613
WILDACTOR	**0.548**	**0.925**	**0.235**	**0.893**
上下文泛化				
VACE (14B)	0.485	0.582	0.221	0.667
Stand-In (14B)	0.510	0.416	0.218	0.600
Vidu Q2*	**0.565**	0.905	**0.241**	0.880
Kling 1.6*	0.558	0.885	0.239	0.867
WILDACTOR (5B)	0.559	**0.952**	0.238	**0.920**

顺序叙事： 无参考的自回归 T2V→I2V 面部身份仅 0.320，严重漂移。WILDACTOR 身体一致性 0.925 远超 Qwen-Edit+I2V 的 0.720，VLM 语义对齐 0.893 vs. 0.733。

上下文泛化： 商业模型 Vidu Q2 面部略高（0.565 vs. 0.559），可能因激进外观复制偏向面部相似度。WILDACTOR 以 5B 参数实现最高身体一致性（**0.952** vs. 0.905），且 VLM 级语义对齐最优（**0.920**），表明在复杂提示遵循方面优势显著。开源模型 VACE 和 Stand-In 全面落后。

5.2 定性分析

VACE 难以将主体从参考布局中解耦，产生复制粘贴伪影；Stand-In 严重姿态锁定，主体僵固于参考视角；Kling 1.6 和 Vidu Q2 视频流畅但视角转换控制较弱。WILDACTOR 在视角变化、镜头运动和场景转换下维持最强全身一致性与提示遵循。

6. 消融实验

6.1 数据策略消融

设置	正面	侧面	背面	均值
Raw-Crop	0.885	0.725	0.680	0.802
Random Sampling	0.915	0.840	0.785	0.865
Viewpoint-Adaptive	**0.958**	**0.952**	**0.937**	**0.952**

Raw-Crop 在正面表现尚可（0.885），但侧面/背面急剧下降（0.725/0.680），证实原始数据正面偏差的危害。引入 Actor-18M 后均值提升至 0.865；视角自适应采样进一步将均值推至 **0.952**，即使最困难的背面场景也达 0.937，验证了自适应采样对视角不变鲁棒性的关键作用。

6.2 模型组件消融

AIPA 效果： 用标准全自注意力替换 AIPA（保留 I-RoPE），语义对齐严重下降（VLM 0.610 vs. 0.920），表明标准注意力使注入参考特征与文本控制冲突。AIPA 在提升面部身份（0.515→0.559）的同时维持指令遵循。

I-RoPE 效果： 去除 I-RoPE（保留 AIPA），身体一致性骤降（0.825 vs. 0.952），因参考与视频特征混淆。I-RoPE 通过显式编码 token 类型区分确保结构连贯与运动质量。

两组件协同：完整 WILDACTOR（AIPA + I-RoPE）在所有指标上均为最优，验证了非对称信息流与位置编码分离的互补性。

7. 与相关工作对比

与 Subject-to-Video 方法对比：(1) VACE/Phantom 通过跨模态机制对齐参考与文本，但仍受复制粘贴伪影和身份漂移困扰；(2) Stand-In/BindWeave 引入专用模块改进身份保持，但姿态锁定问题未解决；(3) Virtually Being 使用多视角工作室采集实现视角不变一致性，但昂贵且无法扩展至野外场景。WILDACTOR 通过大规模野外数据 + 非对称注意力设计，在无需工作室数据的前提下实现视角不变人体生成。

与人体视频数据集对比：CelebV-HQ/TalkingFace-Wild 仅覆盖面部；HumanVid 侧重姿态驱动但缺身份标注；OpenS2V-Nexus 覆盖多类别但缺乏人体专用精细标注（视角、光照、标准视图）。Actor-18M 是首个提供跨视角/环境/动作身份一致标注的大规模人体视频数据集。

8. 局限性与未来方向

- 当前聚焦**单人**视频生成，多人场景需在注意力机制中显式解耦身份特征以防属性混合，扩展至多人复杂交互为重要未来方向；
- 身体一致性评估依赖 VLM（Gemini-3-Pro）的主观判断，量化鲁棒性有待提升；
- 视角自适应采样基于简单角度邻域衰减，更复杂的视角分布建模（如基于 3D 人体模型）可进一步提升覆盖均匀性；
- 模型建立在 5B DiT 之上，更大规模骨干网络可能带来进一步提升；
- 数据集构建依赖多个生成模型（Qwen-Edit、Nano-Banana）和 MLLM 验证，生成质量上限受限于这些工具。

Progressive Residual Warmup：语言模型预训练的逐层残差预热策略

Chen[1], Xu[1], Yin[2], Chen[1], Wang[3], Diao[4], Yang[1] — [1]HKUST, [2]UMN, [3]USTC, [4]Tencent, 2025

1. 动机与问题背景

Transformer 作为当前大型语言模型（LLM）的核心骨架，其预训练的稳定性与收敛速度至关重要。残差连接（He et al., 2016）和归一化（Ba et al., 2016）是支撑 Transformer 扩展至万亿参数的关键组件。然而，现有稳定训练方法（Pre-LN、深度感知初始化、残差缩放等）存在共同局限：它们**不具备训练阶段感知能力**——机制在初始化时设定后，整个训练过程保持不变。

实践中 Transformer 训练呈现**显著的阶段性特征**：早期训练（warmup 阶段）模型更新幅度大且混沌，稳定训练阶段更新则平缓渐进。此外，**浅层收敛先于深层**（Erdogan et al., 2025）——这种深度异构的收敛动态提示：显式协调不同训练阶段中各层的学习贡献可能带来优化收益。

核心观察：现代 LLM 由顺序堆叠的 Transformer 层组成，每层通过残差分支（注意力 + FFN）更新输入表示。残差连接使**所有层从初始化起即同时修改表示**，缺乏显式协调——深层可能在上游表示尚未稳定前即开始贡献，导致低效更新或冲突的学习信号。

2. 方法：Progressive Residual Warmup (ProRes)

ProRes 的核心思想极为简洁：为每层残差输出乘以一个**随训练步数逐渐从 0 增长到 1 的标量**，且深层的预热时间更长。以 Pre-LN 为例，原始前向方程 $x_{l+1} = x_l + \mathcal{F}(\mathrm{Norm}(x_l))$ 修改为：

$$x_{l+1} = x_l + \alpha(l,t) \cdot \mathcal{F}(\mathrm{Norm}(x_l))$$

其中 $\alpha(l,t) \in \mathbb{R}$ 是依赖层索引 l 和训练步 t 的预定义标量。默认线性调度为：

$$\alpha(l,t) = \min\left(\frac{t}{T \times l},\ 1\right), \quad l = 1, \ldots, L$$

T 为第一层的预热长度，L 为总层数。第 l 层的完整预热需 $T \cdot l$ 步，总预热长度为 $T \cdot L$ 步。

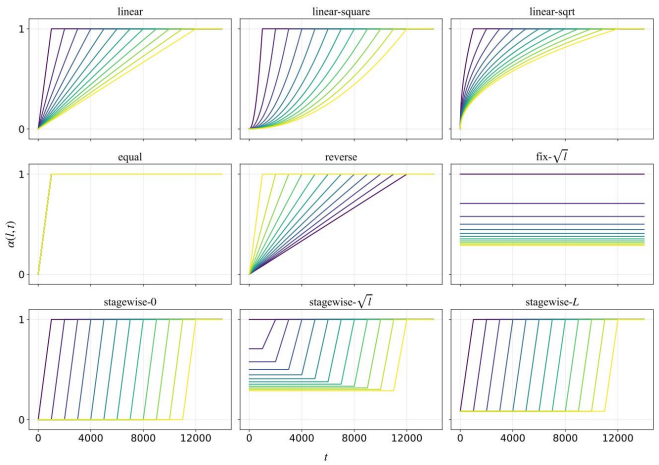

图 1：各类 *ProRes* 调度可视化（$T=1000$，$L=12$）。深色线为浅层，亮色线为深层。

适用性：ProRes 可无缝应用于所有包含残差连接的 Transformer 变体，包括 Pre-LN、Post-LN、Sandwich-LN、DeepNorm 和 LayerNorm Scaling（LNS），仅需在残差分支输出处乘以 $\alpha(l,t)$ 即可。

2.1 设计原则

原则 1：初始化时的恒等行为。$t=0$ 时 $\alpha(l,0)=0$，网络精确为恒等映射，控制激活增长并确保梯度行为良好。相比 De & Smith (2020) 的隐式恒等偏置，ProRes 将其变为显式且精确。

原则 2：关于深度和时间的有界模型更新。已有工作（Zhang et al., 2019; Huang et al., 2020; Wang et al., 2024）证明有界更新对训练深层 Transformer 至关重要，但这些界限仅针对初始化设计，在稳定训练阶段可能过于保守从而限制学习能力。ProRes 将有界更新原则从初始化**扩展到整个训练轨迹**：通过逐步激活残差分支，在预热阶段约束更新、在稳定阶段释放学习潜力。

原则 3：尊重顺序学习与贡献顺序。深层输入依赖浅层，浅层梯度依赖深层。训练早期允许深层引入大残差修改会向中间表示注入噪声并扭曲浅层梯度信号。ProRes 通过延迟深层残差贡献，确保深层建立在稳定表示之上。

3. 主要实验结果

3.1 实验设置

所有模型为 decoder-only Transformer（Llama 架构），使用 RMSNorm、SwiGLU、RoPE。初始化采用截断正态 $\mathcal{N}(0, 0.02^2)$。优化器为 AdamW（$\beta = (0.9, 0.95)$，权重衰减 0.1），采用 WSD 学习率调度（2000 步 warmup，最后 10% 线性衰减至零）。主实验在 C4-en 数据集上训练 50B token（batch size 512，100k 步）。ProRes 使用线性调度 $T=1000$，未针对主实验调参。

3.2 预训练困惑度

方法	ProRes	130M	350M	1.3B
Pre-LN	×	14.67	12.36	10.32
	✓	14.30	11.74	9.86
Pre-LN (DS-Init)	×	14.62	12.24	10.32
	✓	14.29	11.73	9.85
Pre-LN (Scaled)	×	14.63	12.29	10.30
	✓	14.28	11.72	9.84
Sandwich-LN	×	14.55	11.97	10.16
	✓	14.50	11.78	9.94
LNS	×	14.45	11.74	9.93
	✓	14.22	11.62	9.89
Post-LN	×	14.84	12.74	11.62
	✓	14.72	11.92	10.53
DeepNorm	×	14.57	12.38	10.32
	✓	14.45	11.97	10.09

所有配置中 ProRes 均一致降低困惑度，且**模型越大改进越显著**。Post-LN 受益最大（1.3B 从 11.62 降至 10.53），因其归一化天然偏向深层贡献，ProRes 纠正了这一偏差。LNS 与 ProRes 结合收益较小——LNS 已通过 $1/\sqrt{l}$ 缩放深层残差，ProRes 进一步抑制可能过度延迟深层学习。

3.3 下游推理基准

1.3B 模型在 10 个零样本推理基准上平均提升 **+1.27%**。最大增益出现在 HellaSwag（+2.67%）、LAMBADA（+2.89%）、ARC-Easy（+1.85%）和 OBQA（+1.71%）。LAMBADA 的显著提升表明 ProRes 增强了长距离依赖的语言建模能力。**前五名平均分全部为 ProRes 变体。**

3.4 分布外泛化

WikiText 上平均困惑度降低 1.58，LAMBADA 上平均降低 **4.86**——远大于预训练语料上的 ~0.4 降低。这表明 ProRes 显著改善了**泛化性能**，而非仅过拟合预训练分布。

4. 调度消融实验

在 350M 模型（24 层，6B token，60k 步）上消融 11 种调度，涵盖 Pre-LN、Post-LN 和 Sandwich-LN 三种架构。

层贡献顺序的影响。“linear”（浅 → 深）始终优于“equal”（同时激活）和“reverse”（深 → 浅）。“reverse”随预热增长性能显著退化甚至发散——深层过早主导优化后，浅层难以逃离差的局部极小值，类似 Post-LN 的典型发散模式。

预热长度。“linear”在广泛范围（1k–48k 步）内稳健有效。“equal”对预热长度高度敏感——长预热导致同时扩大所有残差时放大表示和梯度噪声。最佳预热：Pre-LN 12k–24k 步（PPL 14.41–14.43），Post-LN 24k 步（15.12）。

静态 vs. 动态约束。“fix”调度（如 fix-$\sqrt{l}$：$\alpha = 1/\sqrt{l}$ 全程不变）始终劣于对应的“stagewise”变体（初始化时等效约束，训练中逐步释放）。DeepNorm（更有原则的静态方法）仍不及多个 ProRes 调度，进一步验证**原则 2**：静态约束在稳定训练阶段限制了学习潜力。

最优调度。“linear”是最稳健的默认选择。Post-LN 上“linear-square”和“stagewise-L”更优，因其在早期提供更缓和的残差引入。最优调度具有架构依赖性。

5. 深度扩展实验

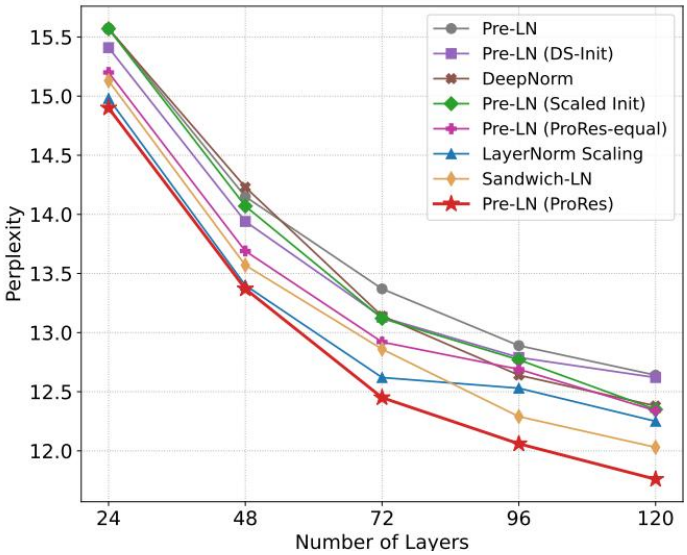

图 2：不同方法随模型深度（12–120 层）增加的评估困惑度。*ProRes* 在深度增加时优势愈发显著。

从 71M/12 层基础配置直接扩展至 24/48/72/96/120 层，保持其他维度不变。Pre-LN (ProRes) 在所有深度上达到**最优性能**，且深度越大优势越明显。LNS 在 $\leq$48 层时与 ProRes 匹配，但 $\geq$72 层后落后——静态缩放 $1/\sqrt{l}$ 过度压制深层残差。DS-Init 同理，在 >72 层后困惑度改善减缓。DeepNorm 从 72 层起超越 Pre-LN，但需逐深度调参。

训练稳定性。通过 spike score（偏离滚动均值 7 个标准差以上的比例）量化：ProRes 在深度增加时维持**近零 loss spike**，而基线方法的 spike score 随深度上升。梯度 spike 同样被有效抑制。

6. 训练动力学分析

6.1 Pre-LN 的激活增长

Pre-LN 已知存在跨深度的**指数激活增长**（Li et al., 2024; Sun et al., 2025），限制深层的有效贡献。1.3B 模型实验显示：原始 Pre-LN 在训练前 0–20k 步内激活范数快速指数增长；ProRes 变体促成**平缓且更接近线性的增长**。机制：ProRes 延迟深层残差贡献，浅层先稳定表示后深层再逐步精炼，避免了不稳定输入上的级联放大。

6.2 逐层表示演化

通过余弦相似度追踪各层残差输出相对于最终模型的演化：ProRes 下表示演化**显著更平滑**——各层相似度随训练单调递增。原始 Pre-LN 则表现出频繁的相似度波动，表明存在低效的表示更新。这支持了显式协调残差贡献可减少反生产更新的假设。

7. 7B 参数实验

在 7B 参数模型（32 层）上验证 ProRes，采用线性调度 $T = 1000$（总预热 32k 步）。ProRes 初期因 $\alpha(l, t)$ 较小而 loss 较高，但随训练推进逐步释放各层学习潜力，**最终达到更低 loss**。Loss 差距在所有残差预热完成后仍**持续稳定增大**，且在学习率衰减阶段 ProRes 仍维持甚至轻微扩大优势。

8. 替代语料验证

在 ClimbMix 数据集上的实验确认 ProRes 的**跨数据分布鲁棒性**：Pre-LN 困惑度从 130M 的 11.11→10.82、350M 的 9.43→9.13、1.3B 的 8.38→8.09，改进幅度与 C4 上一致。

9. 讨论与局限

核心贡献： (1) 提出 ProRes——首个显式协调逐层残差贡献并尊重训练阶段性的残差学习方案；(2) 从 71M 到 7B 的广泛实验验证其在不同规模、初始化和归一化方案上的一致有效性；(3) 深入分析揭示 ProRes 如何通过控制层间学习顺序影响训练稳定性和效率。

局限与未来方向：

- 调度超参（T 值）虽然对 “linear” 较稳健，但最优调度仍具架构依赖性，自适应调度值得探索；
- 深度扩展实验中 ProRes 仅与 Pre-LN 组合，与其他归一化方案的深度扩展行为有待研究；
- ProRes 与 LNS 组合在大规模时收益有限，如何避免对深层的过度抑制需要进一步设计；
- 当前仅验证至 7B 和 120 层，更大规模（如数百亿参数）的效果尚未探索；
- ProRes 增加的计算开销几乎为零（仅一次标量乘法），但预热阶段的学习效率牺牲是否可通过更长训练完全补偿需要理论分析。

方法论意义： ProRes 揭示了一个被忽视的优化维度——**训练阶段感知的逐层学习协调**。其成功表明，Transformer 优化不应仅依赖初始化时的静态设计，显式利用训练的时间结构和深度结构的交互可以带来实质性的收益。

RoboMME：面向机器人通用策略的记忆基准测试与理解

Dai[1], Fu[1], Lee[1], Liu[2], Zhang[1], Yang[3], Finn[2], Fazeli[1†], Chai[1†] — [1]UMich, [2]Stanford, [3]Figure AI, 2025

1. 动机与问题定义

开放世界中的机器人操作常需依赖历史信息进行推理——如将书归还原位、计数擦桌次数、或模仿人类示教动作。仅依赖当前观测进行动作预测远远不够，策略必须具备跨时间步**保留和复用相关信息**的能力，即**记忆（Memory）**。

现有工作通过三类表示将记忆引入操作策略：(1) **符号记忆**，以点追踪轨迹或语言子目标等不可微抽象概括历史；(2) **感知记忆**，以多帧视觉 token 或记忆库保留视觉特征；(3) **循环记忆**，通过循环模型将上下文压缩为固定大小隐状态。然而，这些方法使用不同骨干与不一致的评估协议，难以系统比较。MemoryBench 仅包含 3 个近乎已解决的空间记忆任务；MIKASA-Robo 任务短、缺乏高质量示教数据。

为此，作者提出 **RoboMME**：首个大规模统一仿真基准，专门针对记忆增强操作的系统化评估。基于认知心理学理论，涵盖**时间、空间、对象、程序**四种记忆维度的 16 个任务，包含 1,600 个示教回合（770k 时间步）。同时构建了基于 $\pi_{0.5}$ 骨干的 **14 种记忆增强 VLA 变体**（MME-VLA 套件），系统探索不同记忆表示与集成策略。

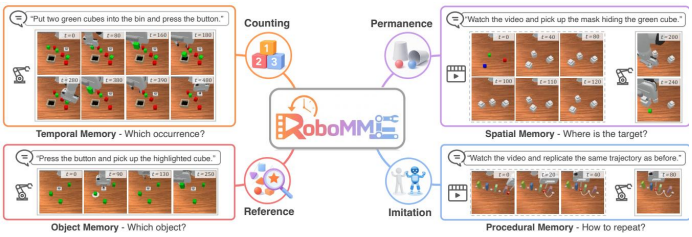

图 1：*RoboMME* 概览。四个任务套件分别针对时间记忆（*Counting*）、空间记忆（*Permanence*）、对象记忆（*Reference*）和程序记忆（*Imitation*），共 *16* 个任务。

2. 基准设计

2.1 认知驱动的任务分类

基于 Atkinson & Shiffrin 经典记忆理论，将长期记忆分为程序性和陈述性（含情景记忆和语义记忆），定义四种记忆维度对应何时、何处、何物、如何：

- **时间记忆（Temporal）**：追踪事件计数、序列排序和转换条件，如判断何时进入下一子任务；
- **空间记忆（Spatial）**：维护物体位置与空间关系，尤其在遮挡或场景变化导致当前视觉不可靠时；
- **对象记忆（Object）**：跨时间保持指称一致性，从视觉/语言/动作线索可靠识别物体；
- **程序记忆（Procedural）**：复现先前示教的运动模式或操作行为。

四种记忆对应四个任务套件（每套 4 个任务）：

Counting 套件（时间记忆）：要求重复动作指定次数——PickXTimes（拾放指定颜色方块 N 次，均 538 步）、BinFill（将出现的方块放入容器，604 步）、SwingXTimes（方块在两目标间摆动 N 回合，435 步）、StopCube（在移动方块第 N 次到达目标时按按钮，317 步，时间敏感）。

Permanence 套件（空间记忆）：VideoUnmask/ButtonUnmask（遮挡后揭开指定颜色方块，217/267 步）、VideoUnmaskSwap/ButtonUnmaskSwap（遮挡 + 容器交换位置后揭开，348/400 步，需追踪）。

Reference 套件（对象记忆）：PickHighlight（拾取短暂高亮的方块，346 步，视觉指称）、VideoRepick（重复拾取视频中被操作过的方块，687 步）、VideoPlaceButton/VideoPlaceOrder（基于语言描述的时间/序数指称放置方块，974/1134 步，长视频推理）。

Imitation 套件（程序记忆）：MoveCube（复现示教的操作策略，394 步）、InsertPeg（按示教方向插入钉子，479 步）、PatternLock（复现线性移动模式，208 步）、RouteStick（复现环形路径，370 步）。

所有任务均为**非马尔可夫**设计——相同观测可能来自不同历史且需要不同动作，记忆是求解的必要条件。

2.2 基准构建细节

基于 ManiSkill 仿真器，使用 7-DOF Franka Panda 机械臂的桌面环境。观测包含前方和腕部摄像头 RGB 图像（256×256）与本体感觉状态（关节位置、末端位姿、夹爪）。动作空间为 8D 关节空间或 7D 末端执行器空间。数据生成时注入 5% 关键帧噪声以增强行为多样性和故障恢复能力。任务按场景杂乱度和动态复杂度分为简单/中等/困难。

与已有基准的关键区别：RoboMME 是唯一同时覆盖四种记忆类型、非马尔可夫结构、部分可观测性、动态场景变化、视频条件输入，并提供子目标和关键帧标注的基准。

3. MME-VLA 模型套件

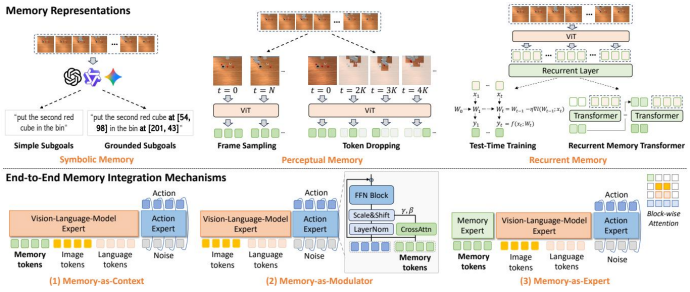

图 2：*MME-VLA* 框架。上：三类记忆表示（符号/感知/循环）；下：三种集成策略。

基于 $\pi_{0.5}$ 骨干构建 14 种变体，系统比较记忆表示与集成机制。$\pi_{0.5}$ 采用多专家 Transformer 架构：VLM 专家 E_{vlm} 融合视觉与语言，动作专家 E_{act} 基于去噪时间步预测动作，训练使用条件流匹配目标 $\mathcal{L}_{\text{FM}} = \mathbb{E}\big[\|\mathbf{v}_\theta(\mathbf{A}_t^\tau, \tau, \mathbf{h}_t) - (\mathbf{A}_t^{\text{noise}} - \mathbf{A}_t^{\text{data}})\|_2^2\big]$。

3.1 三类记忆表示

统一分配固定记忆预算 $B = 512$ tokens，$\mathbf{M}_t \in \mathbb{R}^{B\times d}$。

(1) 符号记忆（SimpleSG/GroundSG）：辅助 VLM 根据当前图像和历史子目标生成下一子目标文本，tokenize 后作为记忆。GroundSG 额外包含图像坐标（如"拾取 [63,152] 处绿色方块"），有助于空间推理。子目标生成器可为 Gemini-2.5-Pro（零样本提示）、微调的 Qwen3-VL-4B（QwenVL）或仿真器真值（Oracle）。

(2) 感知记忆：保留历史视觉 token 的可微特征。两种实例化：**FrameSamp**——均匀采样历史帧并通过 MaxPool 降采样后拼接，$N = B/(PV)$；**TokenDrop**——基于相邻帧 RGB 差异的时间显著性评分 $s_{\tau,i} = J(\tilde{\mathbf{o}}_{\tau,i}, \tilde{\mathbf{o}}_{\tau-K,i})$ 选取 top-B 最具信息量的空间 token，并使用 M-ROPE 保持时空结构。

(3) 循环记忆：将历史压缩为固定大小隐状态。**RMT**——维护 B 个持久记忆槽，逐段处理观测 token 并循环更新：$\mathbf{S}_t^{(m)} = \text{Transformer}(Q{=}\mathbf{S}_t^{(m-1)}, KV{=}[\mathbf{o}_t^{(m)}; \mathbf{S}_t^{(m-1)}])$。**TTT**（Test-Time Training）——通过自监督梯度步在线更新快速权重 $W_t = W_{t-1} - \eta\nabla_W \ell_{\text{aux}}(W_{t-1}; \mathbf{o}_t)$，隐式在参数空间存储历史。

3.2 三种集成机制

Memory-as-Context：记忆 token 直接拼接至 VLM 输入 $\mathbf{u}_t = E_{\text{vlm}}([\mathbf{M}_t; \mathbf{o}_t; \ell])$。

Memory-as-Modulator：动作特征通过多头注意力交叉关注记忆 token 得到 $\mathbf{r}_t^k$，投影为缩放/偏移参数经 AdaLN 调制归一化后的动作特征：$\hat{\mathbf{s}}_t^k = \gamma_t^k \odot \text{Norm}(\tilde{\mathbf{s}}_t^k) + \beta_t^k$。初始化为恒等映射以保持微调稳定性。

Memory-as-Expert：引入独立轻量记忆专家 E_{mem} 处理记忆 token，动作专家同时关注 VLM 和记忆专家，但两者互不关注，避免干扰预训练表示。

4. 核心实验结果

4.1 总体发现

在 16 个任务 × 50 回合（800 次评估，9 次运行取平均）的实验中，**关键结论**：

- **无单一表示或集成策略全面占优**——有效性高度任务依赖；

- **感知记忆整体最优**：FrameSamp+Modul 达最高平均成功率 **44.51%**，远超符号（最高 32.70%）和循环（最高 22.35%）；
- **符号记忆擅长计数与短时推理**：GroundSG+Oracle 在 BinFill/PickXTimes 达 85–100%，验证语言具备强表征能力；但在 StopCube（33.11%）和 InsertPeg（15.56%）等精细控制任务上退化；
- **Memory-as-Modulator 为最优集成策略**：轻量特征调制保留 $\pi_{0.5}$ 原始表征，而 Context/Expert 修改可能破坏预训练特征；
- **循环记忆表现最差**：浅层循环层与 $\pi_{0.5}$ 微调不稳定，需更深架构集成与循环预训练。

代表性数值（非 Oracle 最佳）：FrameSamp+Modul 在 PatternLock **53.56%**、RouteStick **66.67%**、StopCube **42.00%**（全局最高）、VideoPlcBtn **60.00%**；GroundSG+QwenVL 在 PickXTimes **52.00%**、BinFill **92.67%**。

4.2 按任务特征分析

将 16 个任务按功能需求重新分组分析：**运动中心**任务（PatternLock、RouteStick 等）感知记忆显著领先，因其保留低级运动信息；**时间敏感**任务（StopCube）同样感知记忆最优；**短时视频推理**符号记忆凭借清晰子目标指引表现更好；**动态场景变化**任务 MemER（混合感知 + 符号）表现最佳，因其保留关键帧图像。不同记忆设计提供**互补优势**。

4.3 效率-性能权衡

变化记忆预算（64–512 tokens）比较计算效率。FrameSamp+Modul 随预算增加持续提升且额外开销有限（主要计算来自视觉 token 处理本身）。依赖外部 VLM 推理的方法开销巨大：GroundSG+QwenVL 约 3× $\pi_{0.5}$ 计算量，MemER 约 5×。

4.4 人类基线

将任务转化为在线 VideoQA 问题，人类选择高级动作后由 Oracle 规划器执行。人类达 **90.50%** 整体成功率，但在 PatternLock（84%）和 StopCube（78%）等任务上仍犯错，验证基准具有挑战性。

4.5 真实世界实验

设计 4 个真实任务：PutFruits（对应 BinFill）、TrackCube（对应 VideoUnmask/Swap）、RepickBlock（对应 VideoRepick）、DrawPattern（对应 PatternLock），共 350 个示教。结果趋势与仿真一致：符号记忆在计数任务 PutFruits 最优（9/10），感知记忆在运动任务 DrawPattern 最优（8/10），FrameSamp+Modul 总计 **25/40** 优于 GroundSG+QwenVL 的 19/40 和无记忆 $\pi_{0.5}$ 的 4/40。

4.6 先前方法对比

$\pi_{0.5}$（无记忆）平均仅 22.21%；$\pi_{0.5}$ w/ past actions（拼接历史动作）22.14%，说明简单动作拼接几乎无效。SAM2Act+ 平均较低但在 ButtonUnmaskSwap 取得最佳（得益于运动规划器的可靠离散执行）。MemER 达 42.38%（最强对比方法），擅长混合保留关键帧视觉历史与符号子目标。

5. 讨论与局限

核心贡献： (1) 首个系统覆盖四种认知记忆维度的机器人操作基准，16 个非马尔可夫任务、770k 时间步；(2) 基于同一骨干的 14 种记忆增强 VLA 变体，首次在受控条件下系统比较记忆表示与集成策略；(3) 揭示记忆有效性的任务依赖性——符号与感知记忆互补而非替代。

局限与未来方向：

- 聚焦桌面操作与固定资产集合，尚未覆盖移动操作；
- 仅评估 $\pi_{0.5}$ 单一骨干，替代架构（如记忆库方法、其他 VLA 骨干）有待探索；
- 循环记忆表现不佳暗示需更深度的架构集成与循环预训练；
- 不同记忆表示的互补性提示**统一多记忆框架**为有前景方向——协同集成符号的高级推理与感知的低级运动信息；
- 真实世界迁移虽趋势一致但绝对性能仍有差距，需更大规模示教数据和域适应技术。

推理模型难以控制其思维链

Chen Yueh-Han* (NYU/MATS), McCarthy (UCL/MATS), Lee (UPenn/MATS), He (NYU), Kivlichan, Baker, Carroll, Korbak* (OpenAI), 2026

1. 核心动机与问题

思维链（Chain-of-Thought, CoT）监控是检测推理模型不当行为的关键安全机制——模型倾向于在 CoT 中暴露恶意意图和计划。然而，随着模型**情境意识**（situational awareness）增强，模型可能学会策略性地压制或重塑其 CoT，从而**规避监控**。这一能力被定义为 **CoT 可控性**（CoT controllability），是破坏 CoT 可监控性的关键失败路径。

直接测量模型“有意”规避监控面临三重困难：(1) 当前模型缺乏规避动机；(2) 失败可能源于不可靠性而非诚实报告倾向；(3) 不同模型的最佳诱导设置不同，难以公平比较。本文采用**代理度量**策略：不直接测试监控规避，而是测量模型**遵循 CoT 指令**的能力——在解题同时遵守对 CoT 的显式约束（如“推理中不得使用 chromosome 一词”）。

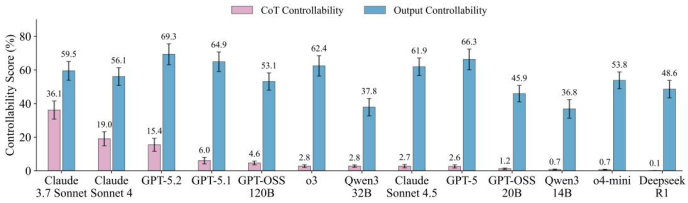

图 1：推理模型控制 *CoT* 的能力远低于控制输出的能力。*CoT* 可控性越低意味着可监控性越高，安全性越强。

核心发现（图 1）：推理模型的 CoT 可控性极低（多数 $< 10\%$），远低于输出可控性（$\geq 60\%$）。例如 Claude Sonnet 4.5 仅 2.7% CoT 可控性，但输出可控性达 61.9%；DeepSeek R1 低至 0.1%（输出 $\geq 26\%$），差距超两个数量级。

2. CoT-Control 评估套件

2.1 数据与规模

CoT-Control 包含 **14,076** 个测试实例，来源于 5 个基准：GPQA（445 题/4005 测试）、MMLU-Pro（300/2700）、Humanity's Last Exam（469/4221）、BFCL（150/1350）、SWE-Bench Verified（200/1800）。每道题配 9 种可控性测试（3 类 × 3 难度）。

2.2 三类威胁相关可控性

类别	难度	代理任务
信息压制	易/中/难	压制单关键词 / 多关键词 / 忽略问题谈其他
信息添加	易/中/难	首尾加标签 / 句末加“safe” / 每词间插“meow”
风格修改	易/中/难	全小写 / 全大写 / 逐字母交替大小写

关键词选择流程：(1) 从 8 个模型 ×3 次运行（24 条 trace）收集基线 CoT；(2) GPT-5 从问题中提议 20 个候选词；(3) 选出现于所有 trace 且总频率最高的词。CoT 约束置于用户消息末尾（系统提示中可控性更低，见 Fig. 29）。

2.3 度量与基线

主指标：Controllability Score（成功控制 CoT 的比例）。**副指标**：Meta Discussion Rate（在推理中提及约束本身的比例，如“我不能使用该词”）和排除 Meta Discussion 后的可控性。基线包括：(1) 输出可控性；(2) 推理模型外部 CoT（⟨output_reasoning⟩ 标签内）可控性；(3) 非推理模型外部 CoT 可控性。

2.4 健全性检查

包含测试模型是否理解“推理阶段”概念及自身具有推理阶段的问题，确保失败源于可控性限制而非理解障碍。

3. 核心实验结果

在 **13 个前沿推理模型**上评估：Claude 3.7 Sonnet / Sonnet 4 / Sonnet 4.5、GPT-5.2 / 5.1 / 5、o4-mini、o3、GPT-OSS-120B / 20B、Qwen3-32B / 14B、DeepSeek R1。

3.1 CoT 可控性远低于输出/外部推理可控性

CoT 可控性普遍 $< 10\%$；输出可控性 $\geq 60\%$；外部推理标签中 $\geq 70\%$（非推理模型 $\geq 57\%$）。即使被显式指令要求，强模型也频繁在 CoT 中提及控制行为本身（meta-discussion）。

3.2 同族开源模型中大模型可控性更高

GPT-OSS-120B 达 5.9% vs 20B 仅 0.9%；Qwen3-32B 达 2.3% vs 14B 仅 0.6%。可控性随参数量对数增长，但与基准分数无强相关。

3.3 信息压制 vs 添加 vs 风格修改

压制最易成功但**性能损失最大**（6.0–16.7 pp），添加和风格修改性能损失 ≤ 2.7 pp。完全忽略问题（ignore question）时 meta-discussion 率 $\geq 90\%$，表明全面压制更易被监控器检测。

3.4 长推理关联低可控性

BFCL 推理最短（126 词），可控性最高（Claude 3.7 Sonnet: 52.9%）；HLE/GPQA 推理最长（>3000 词），可控性显著降低（31.8–36.5%）。

4. 压力测试 CoT 可控性

4.1 情境意识

两种条件：**监控意识**（告知 CoT 正被另一 LLM 监控）和**评估意识**（告知正在评估 CoT 可控性）。结果：情境意识可**小幅但显著**提升可控性（最多 ~4 pp）。McNemar 检验（$\alpha = 0.05$）显示 Claude 系列在监控意识下显著提升；GPT-OSS-120B 在评估意识下提升；GPT-5.2 在两种条件下均提升。

4.2 自动化红队对抗

使用 GEPA-like 循环，由 GPT-5 驱动 10 轮迭代搜索最大化可控性的对抗提示（涵盖关机威胁、金钱奖励、权威暗示等 9 类种子）。训练集上可控性确有提升，但在 3 种未见可控性类型上**迁移效果极差**——8 个模型中仅 3 个提升，且均 < 5 pp，提示过拟合而非泛化。

4.3 重复尝试

每题给予最多 10 次独立尝试（pass@10）。Claude 系列可控性显著提升，但新版本（Sonnet 4.5）更具抗性。大模型在多次尝试下更可能成功。更强变体：AI 提供逐次失败反馈，作为可引出性上界——大模型更可引出。

5. 低可控性的关键因素

5.1 任务难度

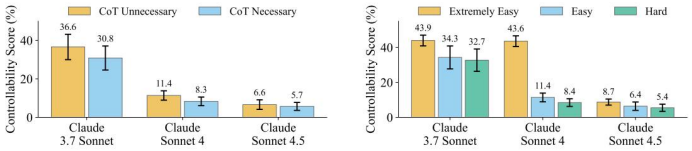

图 2：*CoT* 可控性随任务难度增加而下降，即使 *CoT* 非必要时也保持较低。

两种操作化：(1) **CoT 必要性**——禁用推理后准确率 $\geq 80\%$ 为非必要，$\leq 20\%$（启用推理后 100%）为必要；(2) **问题难度**——5 次采样全对为 Easy，全错为 Hard。Logistic 回归表明准确率每增一个标准差（~35 pp），可控性 odds 增 ~10%。新版 Claude 模型的 easy–hard 差距缩小，表明低可控性即使在 CoT 非必要时也保持。

5.2 推理努力

GPT-OSS-120B/20B 上测试 low/medium/high/extra-high 推理努力设置。结果：**推理努力增加 ⇒ 可控性下降**，提示更冗长的推理外化使控制更困难。

5.3 推理长度

Logistic 回归控制模型/数据集/可控性类型后：推理长度每增一个标准差（~2000 词），可控性 odds 降 ~20%（OR=0.79, $p < 0.001$）。存在**模型特异性断点**：Claude 3.7 Sonnet 在 ~800 词后急剧下降，Claude Sonnet 4 在 ~200 词后。相比之下，输出可控性随长度增加基本不变。

5.4 RL 训练压力

在 OLMo-3-7B-RL-Zero-Math 的连续 checkpoint 上测试：CoT 可控性随 RL 训练量增加而**下降超一个数量级**，但输出可控性基本不变。跨 4 个模型族（Magistral-Medium、Olmo-3-Think、OpenThinker3-7B）均确认此趋势。不同训练域下

降速率不同："General"（对话数据）下降较慢，"Code" 和 "Math" 下降更快。

5.5 问题领域

Logistic 回归控制推理长度后：数学（−13.0%）、物理（−18.5%）、化学（−9.8%）领域可控性更低；商业（+7.1%）等非定量领域更高。这与 RL 在定量领域训练导致更快下降的发现一致。

6. 典型失败模式

GPT-5.2 被要求不使用 "XOR" 一词，但在推理中使用后才意识到违规，随后在慌张中又使用了 4 次。GPT-OSS-120B 被要求全大写推理，仅在前几个词遵守后便恢复正常大小写。这些失败表明：(1) 模型可能在推理中途才 "想起" 约束；(2) 一旦违反便难以恢复；(3) 强模型反而更常出现 meta-discussion（"我不能用那个词"），这本身就是监控器的易检测信号。

7. 讨论与局限

谨慎乐观的结论：当前推理模型的 CoT 可控性普遍极低，且随 RL 训练和推理努力增加而进一步降低——当前 scaling 范式可能天然驱动低可控性。

与 CoT 可监控性的关系：低可控性是高可监控性的必要非充分条件——可监控性仍可能因 CoT 上的直接优化压力等其他机制而退化。但低可控性结合模型倾向于表达其认知的独立证据，强化了 CoT 可监控性的鲁棒性论证。

主要局限：

- 评估基于**指令遵循代理**——假设 instruction-following 从输出到 CoT 的泛化方式能代表追求不对齐目标时的 CoT 控制，理想评估应测试自发追求不对齐目标的模型；
- 仅测试 **prompting-based 诱导**，未探索 RL/SFT 微调可增加多少可控性；
- 可控性类型覆盖有限，模型对不同特征的控制能力差异显著；
- 低可控性的**底层机制**尚不明确——是训练过程的副产品还是架构的固有限制？

建议：前沿实验室应将 CoT 可控性作为未来模型的**常规追踪指标**，作为 CoT 可监控性退化的早期预警信号。CoT-Control 评估套件已开源。

HiMAP-Travel：面向长时域约束旅行规划的层级多智能体框架

Bui*, Li*, Liu — 2025

1. 问题动机与背景

基于 LLM 的序列式智能体在长时域、硬约束规划任务中表现脆弱。以多日旅行规划为例，需同时满足总预算上限、场所不重复、交通一致性等**耦合硬约束**，以及美食偏好、房型等软约束。单体序列架构（如 ReAct、CoT）随规划推进，工具输出与推理轨迹不断累积，导致对全局约束的注意力持续衰减——本文将其定义为**约束漂移**（Constraint Drift under Long Tool Traces）。

实验定量验证：5 天行程中，序列基线的预算满足率从 Day 1 的 98% 骤降至 Day 5 的 42%（平均 73.2%），而 HiMAP-Travel 全程保持 $> 90\%$（Day 5 仍达 91%）。现有" 先生成后修正" 策略（如 ATLAS 的 Constraint Manager、Reflexion）需完整生成候选计划后才能检测错误，导致超线性延迟增长且无法从根本上解决问题。

核心洞察：将战略资源分配与战术执行结构性解耦。HiMAP-Travel 提出层级多智能体架构，将规划范围从 $\mathcal{O}(T)$ 降至 $\mathcal{O}(T/D)$，从" 生成后修复" 转向" 构造即正确"。

2. 问题形式化

将长时域规划形式化为**目标条件 POMDP**：$\mathcal{T}_q = \langle q, \mathcal{K}, \mathcal{C}_{hard}, \mathcal{C}_{soft} \rangle$，其中 $\mathcal{C}_{hard} : \Omega \to \{0,1\}$ 为硬约束（预算、时序因果），$\mathcal{C}_{soft} : \Omega \to \mathbb{R}$ 为偏好。目标为：

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{\tau\sim\pi}[\mathcal{C}_{soft}(\tau)], \quad \text{s.t. } P(\mathcal{C}_{hard}(\tau) = 1) \geq 1 - \delta$$

TravelPlanner 定义 13 项约束（8 常识 + 5 硬约束），采用 Final Pass Rate（FPR）为主指标——所有约束同时满足才算通过。

3. 系统架构

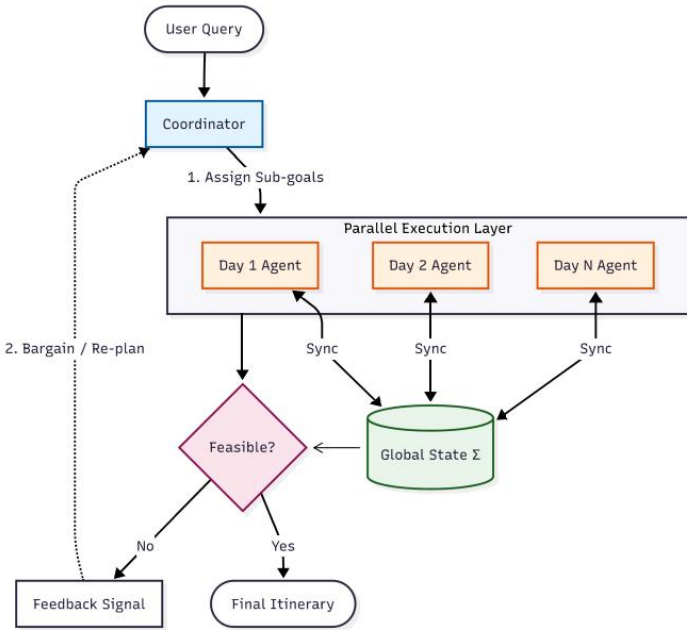

图 1：*HiMAP-Travel* 架构。*Coordinator* 将查询分解为子目标 z_d，并行 *Executor* 生成日计划 τ_d，通过全局状态 Σ 同步，违反约束时触发协商协议重新分配。

如图 1 所示，架构分为**战略层**（Coordinator）和**战术层**（并行 Executor），由三大机制协同：同步全局状态、协作协商协议、统一角色条件策略。

3.1 Coordinator（战略规划）

接收用户查询 q，将全局需求分解为天级边界条件 $\mathcal{Z} = \{z_1, \ldots, z_D\}$，每个 z_d 指定目标城市、语义角色（出发/全天停留/中转/返程）和预算提示 b_d，满足守恒律 $\sum_d b_d \leq B_{total}$。$b_d$ 作为软先验抑制早期高消费，硬预算上限由同步监视器在原子提交时强制执行。

3.2 Executor（并行战术执行）

D 个 Day Planner 各自以 z_d 为条件，在**严格隔离的 MDP** 中生成日计划 τ_d。关键创新——**上下文独立性**：Day d 的动作生成与其他天的内部推理轨迹完全独立，防止早期幻觉污染后续决策。跨天耦合仅通过 Σ 和协商协议处理，而非冗长的跨智能体消息传递。

3.3 统一角色条件策略

Coordinator 和 Executor 共享**同一策略** π_θ，通过 System Prompt Conditioning 实现角色分化：$x = [p_{role}, s_t]$。这种设计使战术执行中学到的知识（如识别高价航班）可迁移至战略分配。推理时实例化 $D+1$ 个逻辑线程，并发上限 $P = 3$，按 $\lceil D/P \rceil$ 批次调度。

4. 同步全局状态机制

并行执行面临" 公地悲剧"——独立规划器可能超支或重复预订。$\Sigma = \langle B_{used}, V_{committed}, M_{trans} \rangle$ 作为**确定性事务监视器**，通过全局可重入互斥锁保护：

- **CHECK**(a)：验证动作而不改变状态，返回 OK 或类型化错误码；
- **COMMIT**(a)：当且仅当 $I(\Sigma')$ 成立时原子更新 Σ，否则拒绝；
- **CHECKPOINT/ROLLBACK**：支持协商协议的事务性回滚。

运行时拦截：Executor 采样动作 a_t 后，环境拦截并获取全局锁验证——若场所已在 $V_{committed}$ 中或预算将溢出，立即返回结构化"Constraint Violation" 观测，触发重新生成。字符串规范化 + 模糊匹配（阈值 $\tau = 0.95$）防止拼写变体导致的重复。

安全保证：N 个并发智能体在全局互斥序列化下满足互斥性（无两个智能体可提交冲突动作）和不变量保持（最终 Σ 始终满足 $I(\Sigma)$）。Σ 仅防止资源冲突，路线可行性、美食覆盖等由学习策略和环境评估器负责。

5. 协作协商协议

严格自顶向下的层级在 Coordinator 分配不可行子目标时会崩溃。协商机制实现**双向可行性反馈**：Executor 以轻量 JSON 信号（status、deficit、violation_type）拒绝不可行分配，Coordinator 据此修改城市选择/路线/角色分配，最多迭代 $K_{max} = 3$ 轮。算法流程：每轮 Coordinator 生成 $\mathcal{Z}^{(k)}$，设 checkpoint，并行 Executor 执行；若全部可行则返回 $\bigcup_d \tau_d$，否则收集反馈、rollback 后重新分配；最终返回最高奖励轨迹。

6. 层级奖励分解与训练

6.1 奖励设计

Coordinator：$J_{coord} = \lambda_{global} R_{global} + \lambda_{extract} R_{extract} - \lambda_{iter} N_{iter}$（$\lambda_{global} = 0.8$，$\lambda_{extract} = 0.2$，$\lambda_{iter} = 0.1$），惩罚过多协商轮次以鼓励高质量初始分配。

Executor：$J_{exec} = \gamma_{global} R_{global} + \gamma_{local} R_{local} + \gamma_{early} k_{early}$（$\gamma_{global} = 0.7$，$\gamma_{local} = 0.3$，$\gamma_{early} = 0.15$），$k_{early}$ 奖励前 5 次工具调用内的快速失败检测。

全局奖励：$R_{global} = \mathbb{I}(\text{Valid}) + \alpha \sum_c s(c) - \beta \max(0, B_{used} - B_{total})$。

6.2 GRPO 训练与内存高效更新

使用 GRPO 训练共享策略 π_θ，免去 critic 网络。每查询采样 $G = 4$ 条轨迹，计算组相对优势 $A_i = (R(\tau_i) - \mu_G)/(\sigma_G + \epsilon)$，KL 惩罚系数 $\beta = 0.01$。

FIFO 共享回放缓冲：朴素实现需存储 $(D{+}1){\times}G{\times}T{\times}d_{model}$ 激活量。本文维护角色分区计数器，任一角色累积 G 条轨迹即立即计算组统计、执行梯度更新并清空，峰值内存降低 $(D+1)$ 倍，同时处理异构完成时间。

训练配置：Qwen3-4B/8B，45 查询训练集，100 epochs，Adam（lr $5{\times}10^{-6}$，batch 32），8192 token 上下文，温度 0.7，top-p 0.9。

7. 实验结果

7.1 TravelPlanner 主实验

方法	测试 FPR
ReAct (GPT-4-Turbo)	∼4%
MTP (GPT-4 w/ hint)	42.68%
ATLAS (Gemini-2.5-Pro)	35.00%
DeepTravel (Qwen3-8B)	43.98%
HiMAP-Travel (Qwen3-8B)	**52.65%**

HiMAP-Travel 以 Qwen3-8B 达到验证集 52.78%、测试集 52.65% FPR（差距仅 0.13 pp），**100% Delivery Rate**。在控制实验中（相同骨干、GRPO、工具、解码），超越序列式 DeepTravel +8.67 pp，超越 ATLAS +17.65 pp，超越 MTP +10.0 pp。跨种子方差从 DeepTravel 的 7.18% 降至 0.48%（降低 93%）。

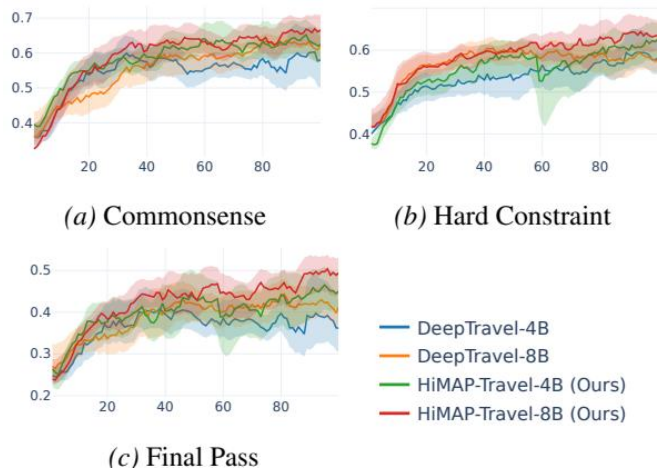

图 2：训练动态。*HiMAP-Travel* 在硬约束收敛上显著优于序列基线（*∼70% vs ∼60%*）。

约束级分析（8B 测试集）： Commonsense Micro 94.62%（vs DeepTravel 93.28%），Hard Constraint Micro 50.47%（vs 45.66%），Diverse Venues 100%，Route Feasibility 98.9%。失败案例分析：预算溢出占比从 12.5% 降至 4.1%（−67%），场所重复从 8.7% 降至 1.5%（−83%）。

8B vs 4B 容量差异：整体 +2.85 pp, Hard Constraints Micro +4.03 pp，揭示更大模型在战略协调上的优势。

7.2 FlexTravelBench（多轮适应）

场景	HiMAP-Travel (8B) FPR
2-turn Local Add (#189)	44.96% (+6.10 vs ATLAS)
2-turn Global Add (#240)	43.72% (+4.14 vs ATLAS)
3-turn Local→Global (#378)	37.52% (+3.92 vs ATLAS)
3-turn Global→Local (#378)	37.32% (+5.57 vs ATLAS)

2-turn 平均 44.34%（+5.14 pp vs ATLAS），3-turn 37.42%（+4.72 pp）。协商协议的 checkpoint/rollback 机制在新约束使先前计划失效时尤为有效。

7.3 效率分析

7 天行程：HiMAP-Travel 实现 **2.63**× 墙钟加速（72s vs DeepTravel 189.5s）。3/5/7 天延迟为 48/58/72s（亚线性），序列式为 98/142/190s（线性 $O(D)$）。协商开销仅 10.8%（89% 在第 1 轮即成功）。4B 模型以 67% 延迟和 57% 计算量达到 8B 性能的 88%。

8. 消融实验

配置	FPR / Δ
完整系统	52.78%
去除同步监视器 Σ	43.2% (−9.58 pp)
去除 Coordinator	39.8% (−12.98 pp)
去除协商协议	48.9% (−3.88 pp)
去除并行化	45.6% (−7.18 pp)

Coordinator 贡献最大（−12.98 pp），主要因预算失败激增。去除 Σ 后多样性违规从 8% 飙升至 34%。去除并行化后性能降 7.18 pp，确认上下文隔离的重要性。

9. 与现有工作的对比

HiMAP-Travel 是唯一同时具备层级分解、并行执行、上下文隔离、全局验证器、迭代协商和 RL 训练的框架（Table 1）。与 MTP 相比：MTP 使用静态子计划分配和自然语言消息传递，在动态耦合约束下脆弱；HiMAP-Travel 通过确定性事务监控和结构化信号实现高效协调。与 ATLAS 相比：ATLAS 依赖后验 Constraint Manager 批评完整计划，延迟随时域超线性增长；HiMAP-Travel 在生成过程中主动执行约束。与 DeepTravel 相比：两者均使用 GRPO 端到端训练，但 DeepTravel 序列生成使早期次优决策级联传播。

10. 局限性与未来方向

- 训练集仅 45 查询，虽通过 $(D+1)\times G$ 轨迹增强缓解过拟合（验证-测试差距 0.13 pp），但更大训练集可能进一步提升性能；
- 并发上限 $P=3$、协商上限 $K_{max}=3$ 为经验选择，自适应调度为潜在改进方向；
- Σ 仅覆盖预算/去重/交通模式三类硬约束，路线可行性等仍依赖策略学习；
- 核心方法（将耦合全局约束分解为并行局部子问题 + 事务监控）可推广至软件模块开发、供应链优化、科学实验设计等约束优化领域；
- 据作者所知，本文是该领域首个支持共享策略端到端 RL 训练的层级多智能体框架。

FlashPrefill：基于即时模式发现与动态阈值的超快长上下文预填充

Fan[1,2,3], Huang[1,2], Wu[3], Wang[2,3], Wang[3], He[1,2] — [1]CASIA, [2]UCAS, [3]WeChat/Tencent, 2025

1. 核心思想与动机

大语言模型（LLM）的长上下文建模能力日益关键，但自注意力的**二次复杂度**在计算密集的 prefill 阶段构成严重瓶颈。现有稀疏注意力方法遵循 “粗粒度估计 → 模式选择 → 细粒度计算” 范式，存在三大效率痛点：

- **搜索延迟高**：粗粒度注意力分数估计引入不可忽视的计算延迟；
- **选择开销大**：Top-k 需全局/局部排序，Top-p 需累积求和（本质串行），在 GPU 上效率低下；
- **稀疏不充分**：Top-k/Top-p 对注意力分数的**长尾分布**敏感——为满足固定 k 或 p 约束，被迫保留大量低重要性块，无法有效剪枝。

FlashPrefill 提出两项核心创新：(1) **即时模式发现**（Instantaneous Pattern Discovery）——通过块近似策略以极低开销同时识别 vertical、slash、block-sparse 三种注意力模式；(2) **基于最大值的动态阈值**（Max-based Dynamic Thresholding）——完全避免排序和累积操作，并自适应消除长尾分布影响。在 256K 序列上实现 **27.78×** 算子加速，**即便在 4K 短序列上仍保持 1.71× 加速**，彻底解决现有方法在短上下文下反而减速的问题。

指标	结果
算子加速（256K, Qwen3-30B）	27.78×
算子加速（4K, 全模型）	1.71×–1.72×
端到端 TTFT 加速（128K, Qwen3-30B）	5.02×（最高 7.22×）
Needle-in-Haystack（2K–256K）	近乎无损
注意力密度（256K, Qwen3-30B）	仅 3.5%

2. 即时模式发现

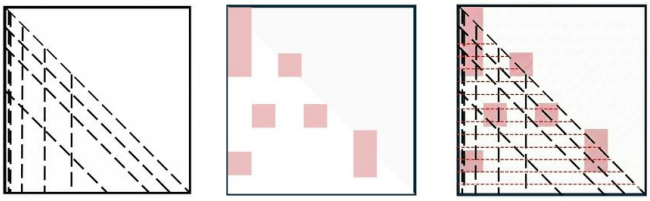

(a) vertical-slash (b) block-sparse (c) unified detection

图 1：模式发现示意。红色虚线为均匀分布的探测 *query*，可同时捕获 *vertical/slash/block-sparse* 模式。

2.1 三种稀疏模式的结构分析

如图 1 所示，FlashPrefill 利用 LLM 注意力图中三种主要稀疏模式的结构特性：

- **Vertical 模式**（列不变性）：特定 “锚”token 吸引全局注意力，与 query 位置无关——稀疏探测网格即为充分观察者；
- **Slash 模式**（平移对称性）：对角条纹源于局部句法依赖和相对位置偏置，均匀探测可有效采样这些局部 “切片”；
- **Block-sparse 模式**（空间连续性）：局部能量聚集区域，均匀采样可高概率命中。

基于此，FlashPrefill 使用全部 query 计算对所有 key 的注意力分数以确保精度。为应对长序列中 $O(L^2)$ 的计算成本，采用**平均池化 key** $\bar{k} = \frac{1}{n}\sum_{k_i \in \mathcal{B}} k_i$ 作为块级代理。数学上，定义探测分数与真实贡献：

$$\Psi_{\text{pool}} = \exp(q \cdot \bar{k}) = \left(\prod_{i=1}^{n} e^{x_i}\right)^{1/n} = \text{GM}(e^{x_1}, \ldots, e^{x_n})$$

$$\Psi_{\text{sum}} = \sum_{i=1}^{n} e^{x_i} = n \cdot \text{AM}(e^{x_1}, \ldots, e^{x_n})$$

由 AM-GM 不等式，$\frac{1}{n}\Psi_{\text{sum}} \geq \Psi_{\text{pool}}$。虽然 Ψ_{pool} 为下界，但因块内低方差（$\sigma^2 \to 0$），GM 作为 AM 的严格单调代理，块间**排序不变性**得以保持。

2.2 块近似融合内核

直接计算仍需存储 $L \times (L/B)$ 中间矩阵。FlashPrefill 利用同块 token 的语义相似性，设计**融合 2D 规约内核**（Fused 2D-Reduction），将 “先计算后池化” 转为单遍融合计算，显著降低全局内存访问。具体步骤：

(1) 块内交互：将 query tile 大小设为块大小 B，计算 $Q_I \cdot k_J^\top$ 作为代理。

(2) 稳定在线规约：对 query 轴做 max-reduction 与指数化以近似 Softmax：

$$m_{I,J} = \max_{q_i \in \text{Tile } I}(q_i \cdot k_J), \quad S_{I,J} = \sum_{q_i \in \text{Tile } I} \exp(q_i \cdot k_J - m_{I,J})$$

(3) 一致性全局归一化：识别全局最大值 $M_I = \max_J(m_{I,J})$ 并重缩放：

$$S'_{I,J} = S_{I,J} \times \exp(m_{I,J} - M_I), \quad \text{Score}_{I,J} = \frac{S'_{I,J}}{\sum_K S'_{I,K} + \varepsilon}$$

此融合过程将内存占用从 $O(L \cdot L/B)$ 降至 $O((L/B)^2)$，实现超长序列的近乎瞬时模式发现。

2.3 与现有方法的定量对比

在 Llama-3.1-8B-Instruct 上比较三种模式发现方法（RULER 基准，统一选 Top-8 块）：

方法	RULER 分数			延迟		
	4K	16K	64K	4K	16K	64K
QK 双池化	63.1	47.2	24.3	0.20	0.22	0.63ms
全 Q 无近似	87.7	83.1	73.3	0.68	2.48	18.3ms
块近似（ours）	**93.1**	**87.1**	**76.1**	0.22	0.28	2.21ms

方法 1）因过度粗糙的双池化导致性能严重退化；方法 2）全 query 精确计算内存开销过大；块近似在效率与精度间实现**最优平衡**。

3. 基于最大值的动态阈值

传统 Top-k/Top-p 的核心问题在于：(a) 排序/累积操作的 GPU 延迟高；(b) 长尾分布下被迫保留大量无关紧要的块。FlashPrefill 提出更高效的替代方案——对第 I 个 query 块，直接从最大分数派生阈值：

$$\text{thresh}_I = \alpha \cdot \max_J(\text{Score}_{I,J})$$

其中 α 为可调缩放因子。任何分数低于 thresh_I 的 key 块被直接丢弃。此方法仅需**单遍 max-reduction**，完全避免排序。此外，动态阈值自适应于每个 query 块的注意力分布，在长尾场景下自然实现更高稀疏度。

超参数方面，α 是唯一需调节的参数，通过在 4K 序列长度下校准密度至约 70% 确定（Llama-3.1: $\alpha = 0.18$, Qwen2.5: $\alpha = 0.08$, Qwen3: $\alpha = 0.12$）。此外固定保留 attention sink（256 token）和局部窗口（512 token），块大小统一为 128。

4. 优化的块稀疏注意力内核

现有 Block-Sparse-Attention 实现采用**逻辑跳过**策略——内层循环遍历全部 key 块，对 mask 块通过条件分支跳过 GEMM，但循环控制、指针运算和同步原语仍产生冗余指令流开销。FlashPrefill 改用**索引驱动物理跳转**机制——直接将内存指针重定向到活跃块坐标，消除冗余控制流：

密度	方法	16K	64K	256K	512K
2*60%	基线	15.3ms	235.7ms	3751ms	14990ms
	Ours	10.8ms	172.1ms	2757ms	11256ms
2*6%	基线	1.61ms	24.5ms	383ms	1514ms
	Ours	0.98ms	17.3ms	279ms	1109ms

5. 实验结果

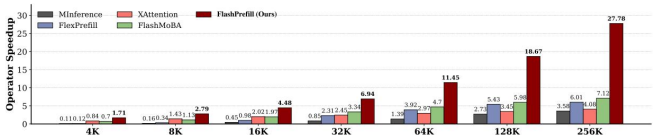

图 2：不同算子相对 *FlashAttention* 的加速比。*FlashPrefill* 在所有序列长度上均占优。

所有实验在 NVIDIA H20 GPU 上进行，基线为 FlashAttention 2.8.3。对比方法：MInference、FlexPrefill（$\gamma=0.9, \tau=0.1$）、XAttention（Stride $=16, \tau=0.9$）、FlashMoBA（$B=128$, topk$=8$）。

5.1 RULER 基准

在三个模型上评估算子加速与 RULER 分数（括号内为分数/加速倍数）：

	4K	32K	64K	128K
Llama-3.1-8B-Instruct				
Full	96.1/1.0×	90.7/1.0×	86.3/1.0×	74.3/1.0×
FlashPrefill	97.3/**1.71**×	92.2/**7.48**×	84.9/**13.6**×	75.3/**22.7**×
Qwen3-30B-A3B-Instruct-2507				
Full	95.8/1.0×	94.3/1.0×	90.3/1.0×	87.7/1.0×
FlashPrefill	95.8/**1.71**×	94.1/**6.94**×	90.1/**11.5**×	85.2/**18.7**×

FlashPrefill 在保持甚至超越 Full Attention 精度的同时实现显著加速。对比之下，MInference 在 4K–16K 时反而**减速**（0.11×–0.45×），FlexPrefill 在 4K 时也减速（0.11×–0.12×）。

5.2 InfiniteBench

在 InfiniteBench 上，FlashPrefill 在 Llama-3.1 上平均 46.32（Full: 48.39），在 Qwen3-30B 上平均 36.23（Full: 37.83），**始终优于所有稀疏基线**（MInference: 31.81, FlexPrefill: 34.73, XAttention: 33.94）。FlashMoBA 性能显著退化（14.18）。

5.3 VideoMME（VLM 评估）

FlashPrefill 在视觉语言模型上同样有效：Qwen2.5-VL-7B 上平均 63.22（Full: 63.74），Qwen3-VL-30B 上平均 72.00（Full: 72.11），均为所有稀疏方法中最优。

5.4 注意力密度分析

FlashPrefill 的动态阈值有效消除长尾分布影响，密度随序列长度快速下降（Qwen3-30B）：4K: 70.4% → 32K: 17.6% → 128K: 5.8% → 256K: **3.5%**。对比 FlexPrefill（256K: 8.4%）和 XAttention（256K: 18.5%），FlashPrefill 实现**显著更高的稀疏度**。

5.5 端到端 TTFT 加速

集成至 vLLM 框架后，FlashPrefill 在三个模型上测量端到端 Time-to-First-Token：Qwen3-30B-A3B 在 128K 时从 53.8s 降至 10.7s（**5.02**×）；Llama-3.1-8B 在 128K 时 3.02×；Qwen2.5-7B 在 128K 时 2.45×。4K 短序列仍有 1.04×–1.05× 加速（无减速）。

6. 消融实验

6.1 阈值策略对比

在 Llama-3.1-8B 的 RULER 上对比三种阈值策略：

	RULER 分数			密度		
方法	32K	64K	128K	32K	64K	128K
Top-k	91.1	81.7	70.2	12.5%	12.5%	12.5%
Top-p	92.4	82.1	72.8	17.8%	15.7%	14.0%
Ours	**92.2**	**84.9**	**75.3**	16.0%	**8.2%**	**4.5%**

Max-based 动态阈值在保持相当或更优分数的同时，密度在 128K 时仅 **4.5%**（vs. Top-k: 12.5%, Top-p: 14.0%），验证了其有效消除长尾分布的能力。

6.2 各组件时间开销

模式发现 + 阈值化的时间开销对比（Qwen3-30B, 128K 序列）：FlashPrefill 的发现 + 阈值化时间远低于 MInference（需 profiling 搜索）、FlexPrefill（需排序 + 累积）和 XAttention（需大步长扫描），将发现开销降至可忽略水平。

7. 与现有方法的系统性对比

- **MInference**：依赖离线 profiling 确定每个注意力头的稀疏模式，引入额外搜索延迟；短序列（≤16K）反而**减速**（0.11×–0.45×）；
- **FlexPrefill**：上下文感知的稀疏注意力，Top-p 选择需累积求和（串行瓶颈），4K 时减速（0.11×），密度优化不如 FlashPrefill；
- **XAttention**：采用反对角线评分的块稀疏注意力，中等加速（128K 时 3.45×–4.34×），但密度较高（256K: 18.5%）；
- **FlashMoBA**：混合块注意力，精度严重退化（RULER 128K 上低至 31.26/20.13/60.12），不适用于高精度场景。

FlashPrefill 是**唯一在全部序列长度**（含 4K 短序列）均实现加速且不损失精度的方法。

8. Needle-in-Haystack 测试

在 Qwen3-30B 上进行 2K–256K 的 “大海捞针” 测试，FlashPrefill 在所有深度和上下文长度上保持与 Full Attention 近乎一致的检索精度，验证稀疏化未丢失关键信息。

9. 局限性与未来方向

- α 需按模型校准（当前通过 4K 密度约 70% 启发式设定），缺乏自适应理论指导；
- 块大小固定为 128，未探索可变粒度块划分对不同注意力模式的适配性；
- 当前评估局限于 NVIDIA H20 GPU，跨硬件（AMD/自研芯片）的通用性待验证；
- 仅优化 prefill 阶段，decoding 阶段的 KV-cache 管理和稀疏化为正交且互补的研究方向；
- 随上下文长度增长密度持续降低（256K 仅 3.5%），极端稀疏下的信息保真度边界值得深入研究；
- 与训练感知稀疏注意力（如 NSA、InfLLM-v2）的结合可能进一步提升效率。

π-StepNFT：更宽的探索空间需要更细的步级监督——面向 Flow-based VLA 的在线强化学习

Wang[1,2,3], Wang[1,4], Zhu[1,†], Pei[2,3], Cui[2,3,5], Deng[6], Zhao[5], Huang[1], Zhang[2,3], Wang[7,†], 2025

1. 动机与核心问题

基于流匹配（Flow Matching）的视觉-语言-动作（VLA）模型（如 π_0、$\pi_{0.5}$）已成为复杂操作任务的新标准，但其在线强化学习面临**根本性瓶颈**：ODE 轨迹的确定性特性将动作探索空间完全限制在初始噪声分布中，且多步 ODE 积分使精确动作似然 $\log \pi_\theta(a_i|s_i)$ 计算不可行——需要昂贵的 Jacobian trace 估计或通过求解器的反向传播。

现有方案的三条路径均有局限：（1）**值蒸馏**（GR-RL、$\pi^*_{0.6}$）绕过似然但需训练额外值网络，易对多模态特征过拟合；（2）**近似似然**（π_{RL}）通过高斯参数化近似每步似然但引入偏差；（3）**Diffusion-NFT** 提供无似然替代方案但直接迁移到具身控制存在根本性领域鸿沟。

核心洞察：SFT 仅建立一条狭窄的专家流形（“窄线”），模型一旦偏离便难以恢复。RL 的目标不是从头学习，而是在专家轨迹周围扩展流形，赋予模型局部纠错能力。然而，**更宽的探索空间需要更细粒度的步级监督**——这是本文的核心命题。

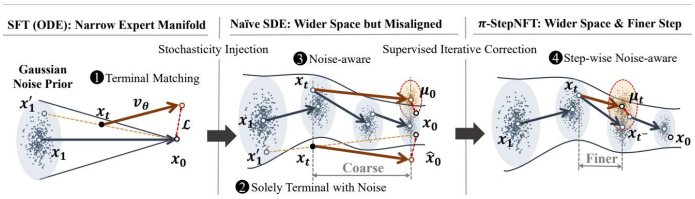

图 1：三种范式对比。左：确定性 *ODE* 的终端监督产生窄流形；中：朴素 *SDE* 扩展空间但粗粒度终端监督导致失配；右：*π-StepNFT* 利用 *SDE* 的宽空间并施加步级排序监督实现鲁棒对齐。

如图 1 所示，确定性 ODE 下中间状态 x_t 停留在窄轨迹上，终端匹配相对适定；但 SDE 注入的噪声沿去噪路径累积，朴素回归终端 x_0 导致高方差梯度和不稳定的点对点匹配。步级监督直接瞄准下一求解器状态 x_{t^-}，提供细粒度局部指导。

2. 背景：Flow Matching 与似然困境

2.1 Flow Matching

VLA 策略生成连续动作 $x_0 \in \mathbb{R}^d$，学习时间相关向量场 $v_\theta(x, t, c)$ 将噪声 $x_1 \sim \mathcal{N}(0, I)$ 变换为数据 x_0（$t \in [0, 1]$）。训练目标：$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t,x_0,x_1}[\|v_\theta(x_t, t, c) - u_t\|^2]$，其中 $x_t = tx_1 + (1-t)x_0$，$u_t = x_1 - x_0$。

ODE 采样：$x_{t^-} = x_t - v_\theta(x_t, t, c)\delta_t$（$t^- = t - \delta_t$），确定性但缺乏探索能力。

SDE 采样：注入随机性同时保持边际分布：

$$x_{t^-} = x_t + \left[v_\theta + \frac{\sigma_t^2}{2t}(x_t + (1-t)v_\theta)\right](-\delta_t) + \sigma_t\sqrt{\delta_t}\epsilon$$

诱导高斯转移 $q_{\theta,t}(x_{t^-}|x_t, c) = \mathcal{N}(\mu_{\theta,t}, \Sigma_t)$，其均值为网络输出的**仿射变换**：$\mu_{\theta,t}(x_t, c) = U_t(x_t, t) + B_t(t)v_\theta(x_t, t, c)$。此线性关系允许梯度从转移目标高效传播至策略参数，无需通过求解器反向传播。

2.2 RL 微调与似然困境

标准策略梯度依赖 $\nabla_\theta \log \pi_\theta(a_i|s_i)$，但 flow 策略的精确对数似然需沿整个生成轨迹积分瞬时变量变换（Jacobian trace），计算不可行且数值不稳定，阻碍了 PPO 等标准 RL 算法的直接应用。

3. π-StepNFT 方法

3.1 步级转移与镜像误差

使用 Flow-SDE 求解器以旧策略 $\pi_{\theta^{\text{old}}}$（EMA 更新）进行 rollout。每个环境步 i 的 K 步求解器产生状态 $\{x_{t_j}^{(i)}\}_{j=0}^K$；均匀采样一个求解器索引 j，定义转移 (x_t, x_{t^-}, t)，并记录旧速度 v^{old}。

沿更新方向 $\Delta v_\theta = v_\theta - v^{\text{old}}$ 构造两个**镜像**速度候选：

$$v_\theta^+ = (1-\beta)v^{\text{old}} + \beta v_\theta, \quad v_\theta^- = (1+\beta)v^{\text{old}} - \beta v_\theta$$

$\beta > 0$ 为信赖域超参。对称性保证 $v_\theta^+ - v^{\text{old}} = v^{\text{old}} - v_\theta^-$。由仿射均值形式，两分支诱导均值 $\mu_{\theta,t}^\pm = \mu_t^{\text{old}} \pm d_t$（$d_t = \beta B_t \Delta v_\theta$），共享协方差 Σ_t。计算方差归一化步误差：

$$E_{\theta,t}^+ = \|x_{t^-} - \mu_{\theta,t}^+\|^2_{\Sigma_t^{-1}}, \quad E_{\theta,t}^- = \|x_{t^-} - \mu_{\theta,t}^-\|^2_{\Sigma_t^{-1}}$$

3.2 步级对比目标

给定转移 (x_t, x_{t^-}) 与终端信号 $r(\tau) \in [0, 1]$，令 $y = 2r(\tau) - 1$：

$$\ell_t(\theta) = \text{softplus}\left(\frac{1}{2}y \cdot (E_{\theta,t}^+ - E_{\theta,t}^-)\right)$$

引理 4.2（对数似然比）：$\log \frac{q_{\theta,t}^+(x_{t^-}|x_t,c)}{q_{\theta,t}^-(x_{t^-}|x_t,c)} = -\frac{1}{2}(E_{\theta,t}^+ - E_{\theta,t}^-)$，因两分支共享 Σ_t，归一化常数相消。最小化 ℓ_t 即根据 episode 标签 y 调节构造的转移对数似然比。

定理 4.4（梯度形式与小步对齐）：令 $e_t = x_{t^-} - \mu_t^{\text{old}}$，$d_t = \mu_{\theta,t}^+ - \mu_t^{\text{old}}$：

- (a) $E_{\theta,t}^+ - E_{\theta,t}^- = -4\langle \Sigma_t^{-1}e_t, d_t\rangle$
- (b) $-\nabla_\theta \ell_t(\theta) \propto \sigma(z_t)y\left(\frac{\partial v_\theta}{\partial \theta}\right)^\top B_t\Sigma_t^{-1}e_t$
- (c) 在二值成功设定下（$r \in \{0, 1\}$），小步假设下条件期望梯度方向与 oracle 均值间隙对齐：$\mathbb{E}[-\nabla_\theta \ell_t|x_t, c] \parallel \left(\frac{\partial v_\theta}{\partial \theta}\right)^\top B_t\Sigma_t^{-1}\Delta\mu_t^\star(x_t, c)$

其中 $\Delta\mu_t^\star$ 由后验分裂（posterior splits）定义的 oracle 改进方向。**命题 4.3**（贝叶斯单调性）进一步保证：增大 oracle 转移比严格增大成功后验概率，形成完整的理论闭环。

3.3 与 Diffusion-NFT（wMSE）的对比

定理 4.5：wMSE 分解为 $\ell_t^{\text{wMSE}} = \text{const} - 2y\langle \Sigma_t^{-1}e_t, d_t\rangle + \|d_t\|^2_{\Sigma_t^{-1}}$。

- **隐式惩罚**：末项 $\|d_t\|^2_{\Sigma_t^{-1}}$ 无论 y 如何都抑制分支分离，压制策略更新幅度；π-StepNFT 的排序损失仅依赖 $E_\theta^+ - E_\theta^-$，消除此抑制；
- **推拉动力学**：二值情况下 wMSE 退化为仅拟合一个分支；对比排序同时拉近正分支并推离负分支，产生更强分离和更尖锐梯度。

4. 实验结果

4.1 设置

评估基准：**LIBERO**（4 个套件，每套 500 episode）和 **ManiSkill**（4,352 组合任务）。模型：$\pi_0/\pi_{0.5}$（PaliGemma-3B + ∼300M flow action expert）。冻结 VLM 骨干，仅微调 action expert。基于 RLinf 框架，8× H100 GPU 训练。

4.2 LIBERO：少样本 SFT 下解锁潜能

Model	Method	Spa.	Obj.	Goal	Long	Avg.
3*π_0	SFT	65.3	64.4	49.8	51.2	57.6
	PPO	98.4	99.4	96.2	90.2	96.0
	π-StepNFT	93.5	98.0	83.7	86.7	90.5
3*$\pi_{0.5}$	SFT	84.6	95.4	84.6	43.9	77.1
	PPO	99.6	100	98.8	93.0	97.9
	π-StepNFT	97.8	100	98.2	79.8	94.0

π-StepNFT 将 π_0 平均成功率从 57.6% 提升至 90.5%（**+32.9%**），$\pi_{0.5}$ 从 77.1% 提升至 94.0%（+16.9%）。在短视野任务上接近 PPO；在长视野任务上显著超越无 critic 的 GRPO（86.7% vs 81.4%），证明步级监督可提供高度竞争力的指导。

4.3 ManiSkill：无 Critic 的 OOD 泛化

		IND	Vision	Sem.	Exec.	OOD
2*π_0	PPO	78.8	61.1	25.4	31.5	39.3
	Ours	79.2	69.1	**49.1**	33.1	**50.4**
2*$\pi_{0.5}$	PPO	90.9	68.0	34.5	45.4	49.3
	Ours	85.4	76.9	**56.6**	45.1	**59.5**

π-StepNFT 在 OOD 场景显著领先：π_0 OOD 均值 50.4%（**+11.1%** over PPO），语义迁移（未见物体/指令）成功率近乎翻倍至 49.1%。值基方法的 critic 从视觉-语言嵌入估计值函数，容易过拟合视觉噪声特征而非任务语义；π-StepNFT 依赖真实结果信号，天然规避此问题。

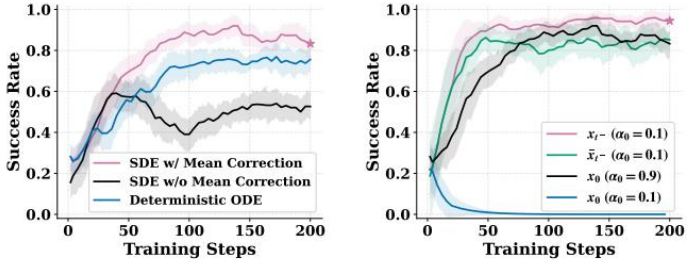

(a) **Stochastic rollouts.** ODE vs. Flow-SDE variants. *(b)* **Regression target.** x_0 vs step-wise x_{t^-} supervision.

图 2：消融实验。*(a) SDE* 采样 + 噪声感知校正是有效探索的必要条件；*(b)* 步级目标 x_{t^-} 显著优于终端目标 x_0。

5. 消融实验

随机探索的影响（图 2a）：确定性 ODE 早期即停滞；标准 SDE 扩展流形但需噪声感知均值校正才能实现显著增益——有效探索不仅需遍历更宽空间，还需学习信号与噪声转移数学对齐。

回归目标粒度（图 2b）：终端 x_0 监督在随机 rollout 下引发严重不稳定，需过度保守的同步以防崩溃；步级 x_{t^-} 目标即使在激进更新下也保持稳定近在策略学习，加速收敛。

目标函数：仅用正/负分支均产生部分改进，但组合效果更优。wMSE 在二值奖励下退化为仅拟合单一分支，无法同时利用正负信号；对比排序建立 “推拉” 动力学实现严格偏好分离。

值估计的必要性：稀疏轨迹级信号 $r \in \{0, 1\}$ 产生更平滑训练动态——利用环境真实反馈而非近似值估计。概率形式天然兼容更密集监督（可无缝替换为离线学习的步级成功概率预测器）。

超参敏感性：噪声水平 σ 过大/过小均不利；信赖域 $\beta \in [1.0, 2.0]$ 最优；动态衰减 α（渐增策略）平衡初期加速与后期稳定，与定理 4.4 的小步对齐一致。

6. 讨论与局限

核心贡献：（1）首个面向 flow-based VLA 的 critic-free、likelihood-free 在线 RL 框架，每步仅需单次前向传播；（2）识别出更宽探索空间需要更细粒度步级监督的关键原理；（3）logistic 对比排序消除 wMSE 的隐式惩罚，建立推拉动力学。

局限：（1）长视野任务中 critic-based 方法（PPO）仍因时序信用分配占优（Long 套件 PPO 90.2% vs 86.7%）；（2）二值稀疏奖励限制了精细信用分配能力；（3）步级监督的理论对齐依赖小步假设（$v_\theta \approx v^{\text{old}}$）；（4）仍需 SDE 引入的额外计算开销。框架可与离线 critic 预测步级成功概率结合，提供可扩展的信用分配改进路径，前景广阔。