QZPaper Huggingface Daily

2026-03-10

1. **GKD：面向语义分割的视觉基础模型可泛化知识蒸馏**
   本文发现传统知识蒸馏在域泛化语义分割中存在优化冲突导致泛化退化。提出 GKD 多阶段框架，通过解耦表征和任务学习增强蒸馏模型的跨域泛化能力。在多个评估设定上相比基线方法显著提升，F2L 场景获得 10.6% 的 mIoU 增益。

GKD：面向语义分割的视觉基础模型可泛化知识蒸馏

Lv[1]*, Zhao[2]*, Wang[1], Quan[1], Huyan[3], Sebe[2], Zhong[4] — [1] 西安电子科技大学, [2]Trento 大学, [3] 清华大学, [4] 合肥工业大学, 2025

1. 问题动机与背景

知识蒸馏（KD）广泛应用于语义分割的模型压缩，但传统方法仅关注**域内精度**，忽视了**域外泛化能力**。随着视觉基础模型（VFMs，如 DINOv2、EVA02）的兴起，这一局限更加突出：VFMs 在未见数据上表现出强鲁棒性，但传统 KD 蒸馏后学生模型的泛化能力显著退化。

核心发现：传统 KD 在域泛化语义分割（DGSS）中存在根本性缺陷——任务损失驱动学生学习源域特定的决策边界，而蒸馏损失要求学生逼近教师的域不变表征，两者**优化冲突**导致不稳定收敛和泛化退化。实验表明，CWD、Af-DCD 等增强型 KD 方法在未见域上的学生性能一致低于教师，尤其在 Foundation-to-Local（F2L）场景下更为严重。

核心问题：能否将 VFMs 蒸馏为紧凑模型，在降低计算开销的同时保留其域外泛化能力？

本文提出 **Generalizable Knowledge Distillation (GKD)**，一个多阶段框架，通过**解耦表征学习与任务学习**显式增强泛化。两个评估设定：

- **F2F**（Foundation-to-Foundation）：教师和学生均为 VFMs（如 DINOv2-L → DINOv2-B）；
- **F2L**（Foundation-to-Local）：教师为大型 VFM，学生为小型本地训练模型（如 DINOv2-B → ViT-S）。

核心贡献	量化结果
F2F 平均增益	+1.9% mIoU
F2L 平均增益	+10.6% mIoU
1/16 标签 F2L DeiT-S	超越 Af-DCD 5.4%
DeiT-B (GKD) vs DINOv2-B	57.9% vs 58.8%（接近）

2. 动机验证

作者在 GTAV → Citys+BDD+Map 设定上进行预实验。传统单阶段 KD 将任务损失和蒸馏损失联合优化学生编码器：

$$\min_{\theta_s,\theta_h} \mathbb{E}_{(x_S,y_S)\sim D_S}\left[\mathcal{L}(\mathcal{H}_{\theta_h}(\mathcal{F}_{\theta_s}(x_S)), y_S) + \|\mathcal{F}_{\theta_t}(x_S) - \mathcal{F}_{\theta_s}(x_S)\|_2^2\right]$$

实验发现：(1) 传统 KD 在未见域上仅有微弱增益，远低于教师；(2) 引入两阶段 KD（先蒸馏特征、再冻结编码器训练解码器）后，损失曲线更平滑、跨域性能显著提升。这验证了**解耦表征学习与任务学习**的必要性——去除任务梯度对表征学习的干扰是关键。

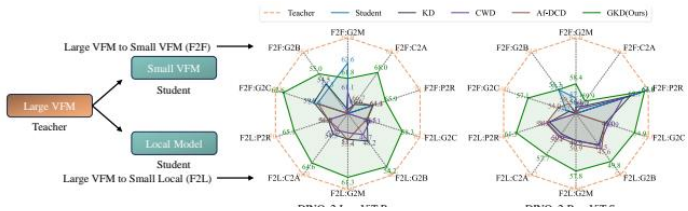

图 1：*GKD* 与传统 *KD* 及增强变体在未见域上的泛化对比。*GKD* 一致超越已有方法。

3. 系统架构与方法

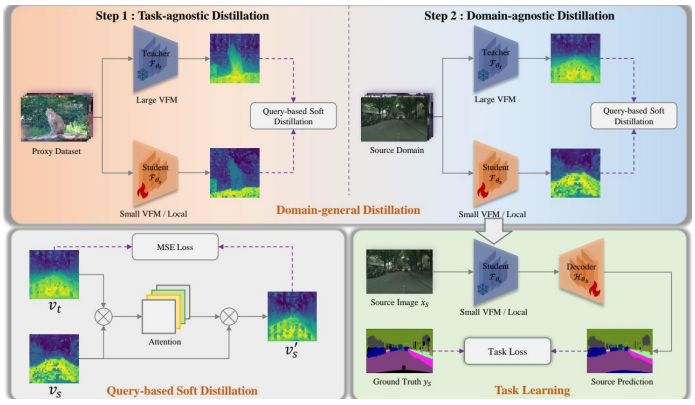

图 2：*GKD* 框架概览。分为域通用蒸馏（含任务无关与域无关蒸馏）和任务学习两大阶段。

如图 2 所示，GKD 包含两个主阶段：**域通用蒸馏**（表征学习）和**任务学习**（下游分割）。

3.1 域通用蒸馏

VFMs 在大规模多样数据上训练，而轻量学生通常仅用 ImageNet 初始化，存在**表征鸿沟**。为此，域通用蒸馏分为两个顺序步骤：

(1) 任务无关蒸馏。使用代理数据集 D_P（ImageNet，多样且无任务偏置）将 VFMs 的通用视觉表征迁移至学生，缩小初始表征差距：

$$\min_{\theta_s} \mathbb{E}_{x_P\sim D_P}[\mathcal{L}_{QSD}(\mathcal{F}_{\theta_t}(x_P), \mathcal{F}_{\theta_s}(x_P))]$$

(2) 域无关蒸馏。在源域图像 D_S 上继续蒸馏，使学生接触任务相关但**域无关**的特征（如城市物体、场景理解），不引入域特定监督偏置：

$$\min_{\theta_s} \mathbb{E}_{x_S\sim D_S}[\mathcal{L}_{QSD}(\mathcal{F}_{\theta_t}(x_S), \mathcal{F}_{\theta_s}(x_S))]$$

3.2 任务学习

域通用蒸馏完成后，**冻结学生编码器**，仅训练解码器（Mask2Former）完成下游分割任务：

$$\min_{\theta_h} \mathbb{E}_{(x_S,y_S)\sim D_S}[\mathcal{L}(\mathcal{H}_{\theta_h}(\mathcal{F}_{\theta_s}(x_S)), y_S)]$$

冻结编码器确保域通用表征不被源域任务监督所污染，是防止域过拟合的关键设计。

3.3 Query-based Soft Distillation (QSD)

传统逐点特征对齐无法保留空间结构和全局关系依赖。VFMs 表现出鲁棒的**域不变空间结构**，GKD 通过基于查询的软蒸馏选择性检索教师的空间语义。

给定学生特征 $v_s \in \mathbb{R}^{B\times N\times C_s}$ 和教师特征 $v_t \in \mathbb{R}^{B\times N\times C_t}$（$N$ 为空间 token 数），先计算注意力权重 $W \in \mathbb{R}^{B\times N\times N}$：

$$W_{ij} = \langle \varphi(v_s^i),\ v_t^j \rangle$$

其中 $\varphi(\cdot)$ 为线性投影层（将 v_s 适配至 C_t 维）。然后基于注意力重构学生特征：

$$v_s' = \sigma\big(\varphi(v_s)\cdot v_t^\top\big)\cdot \phi(v_s)$$

$\sigma(\cdot)$ 为 softmax，$\phi(\cdot)$ 为另一线性投影。此过程使每个空间位置融合**内在局部信息**与**从教师聚合的全局上下文**。最终通过 MSE 约束重构特征与教师对齐：

$$\mathcal{L}_{feat} = \|v_s' - v_t\|_2^2$$

Masked Patch 蒸馏。受 DINOv2 启发，随机遮蔽图像 patch 并将遮蔽图像输入学生，获取遮蔽特征 v_s^{mask}，经同样重构后计算：

$$\mathcal{L}_{mask} = \|v_s'^{mask} - v_t\|_2^2$$

CLS Token 蒸馏。对 CLS token 执行相同 QSD 过程以迁移全局语义：

$$\mathcal{L}_{cls} = \|v_s'^{cls} - v_t^{cls}\|_2^2$$

总蒸馏损失：$\mathcal{L}_{QSD} = \alpha\mathcal{L}_{feat} + \beta\mathcal{L}_{mask} + \gamma\mathcal{L}_{cls}$，默认 $\alpha=\beta=\gamma=1$。

QSD 的核心优势：注意力图呈强对角线模式（保持空间对应），同时非对角元素实现选择性语义聚合，使学生内化教师的**域不变关系结构**而非简单模仿局部激活。

4. 实验设置

数据集：5 个驾驶场景数据集（19 类）+ 2 个遥感数据集（6 类）。三个评估设定：GTAV → Citys+BDD+Map；Citys → ACDC（Night+Snow+Fog+Rain）；Potsdam-RGB → Potsdam-IRRG+Vaihingen-IRRG。指标为 mIoU。

实现：AdamW (lr=5e-4, wd=0.05)。F2L 先在 ImageNet 蒸馏 100 epochs (batch 512, 224^2)，再在源域蒸馏 300 epochs (batch 128, 512^2)。F2F 直接在源域蒸馏 300 epochs。任务训练用 Mask2Former，40K iterations，batch 4，512^2。

5. 核心实验结果

5.1 F2L 设定

以 DeiT 为学生、DINOv2 为教师。DINOv2-B → ViT-S 设定下（GTAV → Citys+BDD+Map）：

方法	Citys	BDD	Map	Avg.
DeiT-S（基线）	34.9	33.8	42.8	37.2
+Vanilla KD	45.0	44.2	49.9	46.4
+CWD	45.9	44.5	49.8	46.7
+Af-DCD	44.7	45.6	50.9	47.1
+G2SD	45.2	45.9	52.3	47.8
+Proteus	47.4	44.6	50.2	47.4
+GKD	**54.9**	**49.8**	**57.8**	**54.1**

GKD 超越最强基线 G2SD +**6.3**%，逼近教师 DINOv2-S（53.9%），甚至超越 0.2%。在强设定（DINOv2-L → ViT-B）下，GKD 达 57.9%，接近 DINOv2-B 的 58.8%。Citys → ACDC 上 GKD 达 57.7%（vs Vanilla KD 49.1%），遥感上达 61.3%（vs Vanilla KD 54.0%）。

5.2 F2F 设定

学生从官方 VFM checkpoint 初始化。DINOv2-L → DINOv2-B：GKD 达 59.8%（GTAV），超 Vanilla KD 1.6%；ACDC 上从 66.2% 提至 68.0%；遥感从 64.1% 提至 65.9%。EVA02-L → EVA02-B：GKD 在 GTAV 上提升 2.0%，遥感上 +4.0%。传统 KD 方法在 F2F 下甚至**损害**学生泛化（Vitkd 使 DINOv2-B 从 58.8% 降至 56.7%），而 GKD 始终正向提升。

5.3 多源域扩展

逐步加入 SYNTHIA 和 UrbanSyn 合成数据集。即使仅用于蒸馏（不参与任务训练），GKD 仍从更丰富的视觉分布中获益，验证了其域无关知识迁移能力。当合成数据同时参与蒸馏和任务训练时，性能进一步提升。

5.4 标签稀缺场景

GKD 在标签稀缺下表现尤为突出（多阶段蒸馏减少对标注的依赖）。F2L DeiT-S 仅用 1/16 标签：GKD 达 51.4%，超 Af-DCD 5.4%，超基线 15.7%。F2F DINOv2-S 用 1/16 标签：GKD 达 54.7%，超基线 2.3%。GKD 显著提升标签效率，在资源受限场景下优势巨大。

6. 消融实验

6.1 蒸馏策略对比

在 DINOv2-B → ViT-S 下（GTAV → Citys+BDD+Map）对比不同策略：

策略	Avg. mIoU
MSE†（单阶段）	46.4
QSD†（单阶段）	48.8
MSE（两阶段）	53.1
CWD（两阶段）	51.9
Vitkd（两阶段）	52.3
QSD（两阶段）	**54.1**

关键发现：（1）**两阶段 vs 单阶段**：MSE 从 46.4% 提升至 53.1%（+6.7%），证明解耦优化的核心价值；（2）QSD 在两阶段框架下进一步贡献 +1.0%，验证关系空间知识迁移的有效性。

6.2 组件消融

逐步叠加各组件：基线 Vanilla KD 46.4% → 加域无关蒸馏 50.9% → 加任务无关蒸馏 53.1% → 加 CLS token 蒸馏 53.4% → 加 Feature QSD 54.0% → 加 Mask Patch 蒸馏 54.1%。域无关蒸馏贡献最大增益（+4.5%），任务无关蒸馏进一步提升（+2.2%）。冻结编码器在保持性能的同时降低训练开销。

7. 可视化分析

特征距离：QSD 训练的学生特征与教师的欧氏距离更小且更紧凑，表明更好的特征对齐。**注意力图：**强对角线模式表明 QSD 保持师生空间对应，非对角响应显示学生选择性聚合相关教师语义。**PCA 可视化：**GKD 有效蒸馏了 VFMs 的空间结构信息，学生在未见域上的特征模式与教师高度相似。

8. 与相关工作对比

- **vs 传统分割 KD**（CWD, IFVD, CIRKD, Af-DCD）：聚焦域内结构语义传递，未考虑域泛化。GKD 在 F2L 上平均超越 +10.6%；
- **vs VFM 蒸馏**（DeiT, TinyMIM, SAMI, G2SD, Proteus）：关注效率和任务适配，跨域泛化未被探索。GKD 在 F2F 上平均超越 +1.9%；
- **vs 多阶段蒸馏**（G2SD, Vemulapalli 等）：采用 generic-to-specific 范式，第二阶段仍耦合特征蒸馏与任务损失，偏向源域。GKD 第二阶段完全冻结编码器，彻底隔离域无关表征与任务优化。

9. 局限性与未来方向

- 多阶段训练增加了总训练时间（ImageNet 蒸馏 100 epochs + 源域蒸馏 300 epochs + 任务训练 40K iterations），计算成本高于单阶段方法；
- 代理数据集依赖 ImageNet，对非自然图像域（如医学影像）的最优代理数据集选择尚未探索；
- QSD 的注意力计算复杂度为 $O(N^2)$，对高分辨率输入（大量 spatial tokens）可能成为瓶颈；
- 当前仅验证 ViT 架构族，对 CNN 学生的适用性未验证；
- 冻结编码器策略可能在源域与目标域差异极大时限制任务适配能力；
- 未来方向包括：扩展至更多下游任务（检测、实例分割）、探索更高效的蒸馏策略、结合域自适应技术进一步提升泛化。