QZPaper Huggingface Daily

2026-03-17

---

1. **AI Can Learn Scientific Taste：基于社区反馈强化学习的科学品味建模**
   AI 形式化将科学品味定义为判断与构思能力，通过社区引用反馈构建偏好信号，以 RLCF 框架训练生成式奖励模型评估研究潜力、训练思想生成器提出高影响力方向，建立 70 万论文对数据集实现系统化科学品味学习。
2. **OpenSeeker：通过完全开源训练数据实现前沿搜索智能体的民主化**
   首个完全开源的学术搜索智能体，采用事实锚定的可控 QA 合成和去噪轨迹合成技术，仅用 11.7k 合成样本通过单次 SFT 训练在多基准达开源 SOTA（BrowseComp 29.5%），数据效率远超现有方法。
3. **Seoul World Model：将世界仿真模型锚定于真实都市**
   将世界仿真模型首次锚定于真实城市（首尔），利用 440 万街景数据通过跨时间配对与虚拟前瞻锚点实现超 1 公里连续动态视频生成，支持文本提示条件化，打通视觉仿真与物理现实的鸿沟。
4. **Attention Residuals：用深度注意力替代固定残差累加**
   将深度维度类比序列维度的 RNN-Transformer 演进，用内容依赖的注意力机制替代固定残差等权累加，提出 Full/Block AttnRes 通过可学习伪查询实现选择性深度聚合，解决 PreNorm 的信息稀释与梯度问题。
5. **Mixture-of-Depths Attention：面向深度信息聚合的统一注意力机制**
   统一深度与序列信息聚合的 MoDA 机制，每层同一 softmax 下关注历史深度 KV 与当前序列 KV，以数据依赖方式动态检索前序层特征，在表达力、计算效率与硬件友好性间取得平衡。
6. **HSImul3R：物理闭环驱动的人–场景交互仿真级三维重建**
   首个仿真级人-场景交互三维重建框架，将物理仿真作为主动监督者，通过前向 RL 优化运动稳定性和反向 DSRO 精炼几何，实现双向物理闭环，弥合视觉真实感与具身部署间的鸿沟。
7. **Anatomy of a Lie：多阶段诊断框架追踪视觉语言模型幻觉**
   提出多阶段诊断框架 CAD，将 VLM 生成建模为信息论几何轨迹，通过感知熵、自信息与推理偏差三个探针结构化诊断幻觉，区分感知漂移与推理旁路等本质不同的失败模式。
8. **Effective Distillation to Hybrid xLSTM Architectures**
   实现 Transformer 向 xLSTM 的无损蒸馏，基于容忍度校正的 Win-Tie 率标准，采用 mLSTM-SWA 混合架构与专家合并策略，在 Llama/Qwen/Olmo 上证实蒸馏后模型可匹配甚至超过教师性能。
9. **ViFeEdit：无需视频数据的视频扩散 Transformer 编辑微调框架**
   无需视频数据的视频扩散 Transformer 微调框架，通过时空解耦架构与正负 2D 空间注意力分支，仅需 100-250 对图像数据实现风格迁移、对象替换、颜色修改等六类精细编辑，大幅降低训练成本。
10. **EnterpriseOps-Gym：面向企业场景的有状态智能体规划与工具使用基准**
    首个企业规模有状态智能体基准，包含 164 张表 512 个工具 1150 个任务，覆盖 CSM/HR/ITSM 等 8 个协作域，平均轨迹 9.15 步，支持跨系统编排与策略约束验证，填补企业级 AI 任务评估空白。

AI Can Learn Scientific Taste：基于社区反馈强化学习的科学品味建模

Tong*, Li*, Li*, Yang‡, Mou‡ 等 — 复旦大学, 清华大学, OpenMOSS, 2025

1. 动机与核心思想

杰出科学家不仅具备技术能力，还拥有强烈的判断力与前瞻性——即**科学品味**（scientific taste）。本文将其形式化为两项能力：（1）**判断能力**（JudgeCap）：评估研究想法潜在影响力；（2）**构思能力**（ThinkerCap）：提出具有高潜在影响力的研究方向。

当前 AI 科学家研究主要聚焦于文献检索与自动化实验等执行能力，而提升 AI 内在的科学品味——判断哪些方向值得追求——仍被严重忽视。人类评估表明 LLM 虽能生成新颖想法，却难以区分真正高影响力方向与表面新颖但琐碎的想法。

本文提出 **Reinforcement Learning from Community Feedback（RLCF）**训练范式，利用大规模社区反馈信号（引用数）作为监督，将科学品味学习形式化为**偏好建模**与**偏好对齐**问题。核心哲学依据：Hume 认为品味标准源于合格评判者的联合判决；Kant 将品味视为“共通感”——科学社区通过引用长期互动所形成的集体偏好正是这一理念的体现。

- 构建 **SciJudgeBench**：70 万组领域与时间匹配的论文摘要对（高引 vs. 低引）；
- 训练 **Scientific Judge**：生成式奖励模型，通过 GRPO 学习判断研究想法的潜在影响力；
- 训练 **Scientific Thinker**：以 Scientific Judge 为奖励模型，通过 Comparison-Based GRPO 生成高潜在影响力的研究想法。

2. 形式化定义

2.1 潜在影响力

论文 p 的累积期望影响力定义为 $I(p) = \lim_{N\to\infty}\sum_{t=1}^{N}\mathbb{E}[c_t(p)]$，其中 $c_t(p)$ 为第 t 年新增引用。

2.2 判断能力

模型 θ 对领域-时间匹配论文对 $(p_a, p_b)\sim\mathcal{D}$ 的判断准确率：

$$\mathrm{JudgeCap}(\theta) = \mathbb{E}_{(p_a,p_b)\sim\mathcal{D}}\left[\mathbb{1}\left[\mathrm{Judge}_\theta(p_a,p_b) = y(p_a,p_b)\right]\right]$$

其中 $y = 1$ 当 $I(p_a) > I(p_b)$。即便两篇论文影响力级数均发散，成对比较标签仍良定义（附录 G 提供形式化证明）。

2.3 构思能力

给定种子论文 s，模型 ϕ 生成研究想法 $\mathrm{Thinker}_\phi(s)$，构思能力为 $\mathrm{ThinkerCap}(\phi) = \mathbb{E}_{s\sim S}[I(\mathrm{Thinker}_\phi(s))]$。

3. RLCF 方法论

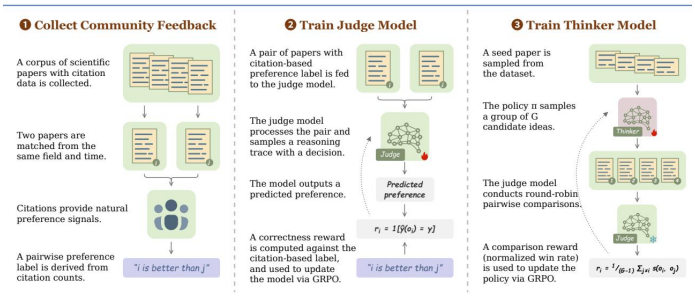

图 1：*RLCF* 概览。社区反馈 → 偏好建模（*Scientific Judge*）→ 偏好对齐（*Scientific Thinker*）。

3.1 社区反馈构建偏好信号

引用作为社区长期互动的集体判决，天然反映研究影响力。为消除领域与时间偏差，将**绝对引用数转换为匹配的成对比较**：同一子领域、相近发表时间的论文对中，引用显著更高者为优选项。筛选条件：绝对引用差 ≥ 8 且相对差 $\geq 30\%$。最终从 210 万篇 arXiv 论文（截至 2024 年）构建 **696,758 对**训练数据，覆盖计算机科学（16.1 万对）、数学（10.3 万对）、物理（39.4 万对）和其他领域（3.8 万对）。

3.2 偏好建模：Scientific Judge

Scientific Judge 是**生成式奖励模型**：输入两篇论文的标题、摘要和发表日期，先生成推理链分析主题普适性、长期影响潜力、引用动态等因素，再输出偏好判断。

训练采用 **GRPO**（Group Relative Policy Optimization）：对每个输入 x，策略 π_θ 采样 $G = 8$ 个输出，每个包含推理链和预测。奖励为二值正确性信号 $r_i = \mathbb{1}[\hat{y}(o_i) = y]$。组内优势归一化：$\hat{A}_i = (r_i - \mathrm{mean}(\mathbf{r}))/\mathrm{std}(\mathbf{r})$。优化裁剪替代目标：

$$\mathcal{J}(\theta) = \mathbb{E}_x\left[\frac{1}{G}\sum_{i=1}^{G}\min\Big(\rho_i\hat{A}_i,\ \mathrm{clip}(\rho_i, 1-\epsilon, 1+\epsilon)\hat{A}_i\Big) - \beta D_{\mathrm{KL}}(\pi_\theta\|\pi_{\mathrm{re}}\right.$$

其中 $\rho_i = \pi_\theta(o_i|x)/\pi_{\mathrm{old}}(o_i|x)$，$\epsilon = 0.20$，$\beta = 0.03$。

3.3 偏好对齐：Scientific Thinker

给定种子论文（标题 + 摘要），Scientific Thinker 生成后续研究想法。由于单个想法缺乏客观评分标准，设计 **Comparison-Based GRPO**：

策略采样 G 个候选想法，进行循环赛（round-robin）——每对想法由 Scientific Judge 判断优劣，共 $\binom{G}{2}$ 次比较。基于比较的奖励为组内胜率：

$$r_i = \frac{1}{G-1}\sum_{j\neq i} s(o_i, o_j)$$

其中 $s(o_i, o_j) \in \{0, 1\}$ 为 Scientific Judge 的判断结果。后续训练目标与标准 GRPO 相同。此设计将开放式生成任务转化为可通过成对比较学习的优化问题。

4. 实验：Scientific Judge

4.1 实验设置

基座模型：Qwen2.5-Instruct 系列（1.5B–32B）、Qwen3-4B/30B-Instruct、Llama-3.1-8B-Instruct。**测试集：**（1）主测试集：728 对，同分布；（2）时间 OOD：514 对 2025 年论文；（3）指标 OOD（ICLR）：611 对，以同行评审分数而非引用为标签。评估采用**位置交换一致性**：每对测试两次（交换 A/B 顺序），仅两次均正确才计分。

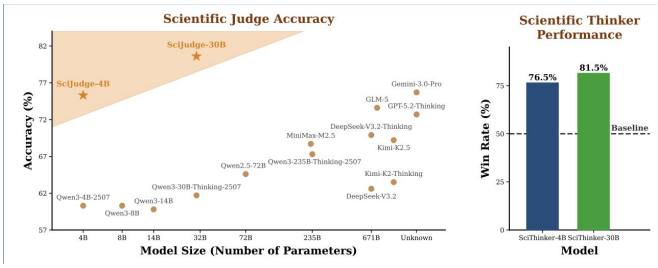

图 2：（左）*SciJudgeBench* 准确率；（右）*Scientific Thinker* 胜率。

4.2 主要结果与 Scaling 趋势

模型	平均准确率（%）
Qwen3-4B → SciJudge-4B	60.3 → **75.3** (+15.0)
Qwen3-30B → SciJudge-30B	66.3 → **80.6** (+14.3)
Qwen2.5-1.5B → SciJudge-1.5B	7.0 → **72.1** (+65.1)
Qwen2.5-32B → SciJudge-32B	62.2 → **83.7** (+21.4)
GPT-5.2-Thinking	72.7
Gemini-3.0-Pro-Preview	75.7
SciJudge-Qwen3-30B	**80.6**
SciJudge-Qwen2.5-32B	**83.7**

数据 Scaling：训练数据量与性能呈近似对数线性关系。**模型 Scaling**：Qwen2.5 系列训练后准确率从 72.1（1.5B）单调升至 83.7（32B）。SciJudge-Qwen3-30B（80.6%）和 SciJudge-Qwen2.5-32B(83.7%)均**超越所有闭源基线**(GPT-5.2: 72.7%, Gemini 3 Pro: 75.7%)。

4.3 泛化能力

时间泛化（2025 年论文）：训练数据截至 2024 年，SciJudge 在 2025 年论文上仍显著提升，SciJudge-Qwen3-30B 达 78.2%（+6.6），最大提升 +55.1（Qwen2.5-1.5B），表明引用信号捕获了跨时间稳定的社区价值观。

领域泛化（仅 CS 训练）： 仅在 CS 论文上训练后，SciJudge 在数学、物理和其他领域均持续提升（SciJudge-Qwen2.5-32B 平均 81.0%，+18.8）。不同学科虽知识和风格差异巨大，但共享可学习的科学价值模式。

指标泛化（ICLR 同行评审）： 在以评审分数为标签的 ICLR 测试集上，提升高达 +72.0（Qwen2.5-1.5B），SciJudge-Qwen3-30B 达 87.7%。值得注意的是评估提示（"哪篇更可能被接收"）与训练提示（"哪篇引用更高"）不同，表明模型学到了跨指标的社区偏好模式。

生物学领域泛化（bioRxiv）： 在训练数据完全不含的 bioRxiv 论文上，SciJudge-Qwen3-30B 仍从 45.0% 提升至 71.2%（+26.2）。

5. 实验：Scientific Thinker

5.1 实验设置

以 2025 年高引论文为种子，训练集 4000 篇（1–7 月），域内测试 200 篇（同期），域外测试 200 篇（8–12 月）。基座策略：Qwen3-30B-Thinking 和 Qwen3-4B-Thinking，奖励模型为 SciJudge-Qwen3-4B。评估由 GPT-5.2、GLM-5、Gemini 3 Pro 三模型多数投票判定胜率。

5.2 核心结果

显著提升构思能力： SciThinker-30B 域内胜率 **81.5%**，域外 **83.0%**；SciThinker-4B 域内 76.5%，域外 76.0%。域外泛化表明模型学到了可迁移的构思能力，而非仅拟合训练期论文。

Scientific Judge 优于基线奖励模型： 使用 SciJudge-Qwen3-4B 训练的策略显著优于使用未训练 Qwen3-4B-Instruct 的版本（30B 域内：81.5% vs. 73.0%；域外：83.0% vs. 70.5%）。

与 SOTA 模型对比： SciThinker-30B 平均胜率 **54.2%**，超越 GPT-5.2 和 GLM-5。域内对 GPT-5.2 胜率 61.0%（基线仅 37.5%），对 Gemini 3 Pro 胜率 43.0%（基线 20.5%）。

6. 与现有范式的关系

RLHF 依赖昂贵人工标注且个体偏好难以反映社区级偏好；**RLVR** 需要可验证答案，不适用于科学构思等开放式任务。RLCF 利用社区互动中自然产生的大规模反馈信号，兼具可扩展性与社区代表性。Comparison-Based GRPO 进一步将不可直接评分的开放式生成任务转化为成对比较优化。

7. 局限与未来方向

- 科学品味可能包含更多维度（实验可行性评估、多样性识别等），当前定义有待扩展；
- 引用作为社区反馈信号并不完美：部分高潜力论文初期引用低但后来影响深远，建模引用动态可捕获延迟影响；领域分类粒度有限；
- 构思评估主要依赖 LLM 评估器，未经实验验证，可能无法完全反映真实影响力；
- Scientific Judge 仅基于标题和摘要训练，引入相关工作等更丰富上下文可进一步提升判断能力；
- 科学构思模型可能被滥用于大规模生成低质量想法或学术不端，需在人类监督下负责任使用。

OpenSeeker：通过完全开源训练数据实现前沿搜索智能体的民主化

Du*, Ye*,#,†, Tang, Zhu, Lu, Cai, Chen† — 上海交通大学, 2026

1. 动机与核心贡献

深度搜索能力已成为前沿 LLM 智能体的核心竞争力，但高性能搜索智能体的训练长期被工业巨头垄断——高质量训练数据的缺失是根本瓶颈。现有开源工作要么不公开数据（WebSailor、WebLeaper），要么仅提供部分数据（WebSailor-V2），要么数据质量不足以达到竞争性能（MiroThinker 147k 样本仅 BrowseComp 10.6%）。OpenSeeker 是**首个由纯学术团队开发的完全开源搜索智能体**（模型权重 + 全部训练数据），通过两项核心技术创新实现前沿性能：

- **事实锚定的可扩展可控 QA 合成**：逆向工程 Web 图拓扑，通过图扩展与实体模糊化生成需多跳推理的复杂问题；
- **去噪轨迹合成**：采用回顾性摘要机制清洗教师模型的生成上下文，同时以原始噪声轨迹训练学生模型，迫使其内化去噪能力。

仅用 **11.7k 合成样本**和**单次 SFT 训练**（无 RL、无持续预训练），OpenSeeker 在四个基准上达到开源 SOTA：BrowseComp 29.5%、BrowseComp-ZH 48.4%、xbench-DeepSearch 74.0%、WideSearch 59.4%。

核心优势	关键数据
vs. DeepDive（开源第二）	29.5% vs. 15.3%（BC）
vs. Tongyi DeepResearch	48.4% vs. 46.7%（BC-ZH）
数据效率	11.7k 超越 147k（MiroThinker）
训练简洁性	纯 SFT，无 CPT/RL

2. 方法论：事实锚定可控 QA 合成

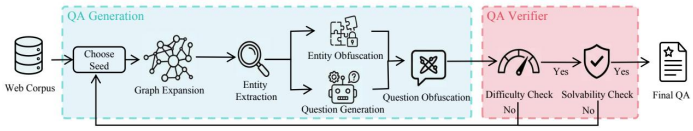

图 1：QA 合成流程。从种子页面出发进行图扩展，提取实体子图，生成多跳问题，再通过实体模糊化提升难度。

2.1 问题建模

将 Web 建模为有向图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$，$\mathcal{V}$ 为网页节点，$\mathcal{E}$ 为超链接边。目标是从 $\mathcal{G}$ 中导出 (q, y) 对，使得求解 q 必须经历长度 $T \gg 1$ 的轨迹 $\tau = [a_1, o_1, \ldots, a_T, o_T]$。核心挑战：(1) 问题必须足够困难以驱动多轮工具调用；(2) 轨迹合成必须稳定可复现。

2.2 生成构造阶段

图扩展（Graph Expansion）。从大规模 Web 语料中采样种子节点 $v_{seed} \sim \mathcal{V}$，沿出边遍历收集 k 个连通节点，形成局部依赖子图 $\mathcal{G}_{sub} = \{v_{seed}\} \cup \{v_i | (v_{seed}, v_i) \in \mathcal{E}\}_k$。模拟自然信息发现过程——一条线索引出另一条。

实体提取（Entity Extraction）。识别种子页面的中心主题 y_{theme}，从子图中提取与主题相关的关键实体，重组为凝练的**实体子图** $\mathcal{G}_{entity}$（节点为实体，边保持原始拓扑连接）。此步骤去除原始页面文本噪声，保留核心逻辑路径。

问题生成（Question Generation）。使用生成模型 P_{gen} 基于 $\mathcal{G}_{entity}$ 的结构合成初始问题 q_{init}，施加**硬结构约束**：从 q_{init} 推导 y_{theme} 必须遍历 $\mathcal{G}_{entity}$ 中的多条边，强制多步推理而非单步检索。

实体模糊化（Entity Obfuscation）。为防止智能体利用关键词直接搜索跳过推理，对实体节点施加模糊化算子 Φ：将具体实体 e 映射为模糊描述引用 $\tilde{e} = \Phi(e)$。生成的模糊实体子图 $\tilde{\mathcal{G}}_{entity}$ 保持结构连通性但语义节点需要消歧。最终基于 q_{init} 和 $\tilde{\mathcal{G}}_{entity}$ 生成最终问题 $\tilde{q}$，目标答案不变 $y = y_{theme}$。

2.3 双标准拒绝采样验证

通过两个指示函数过滤确保质量：

标准 1：难度（严格工具必要性）。令 π_{base} 为强基座模型，在闭卷设置下生成答案。若 $\pi_{base}(\tilde{q}) = y$（仅凭参数记忆即可回答），则丢弃该样本——保证问题必须借助外部信息搜索。

标准 2：可解性（逻辑一致性）。向模型提供完整实体子图 $\mathcal{G}_{entity}$ 作为上下文（oracle 设置）。若 $\pi_{base}(\tilde{q}|\mathcal{G}_{entity}) \neq y$，说明推理路径断裂或产生幻觉，予以丢弃。

2.4 三大核心优势

- **事实锚定**：查询锚定于真实 Web 拓扑而非 LLM 生成，幻觉风险显著降低；
- **可扩展**：本工作使用 ~68GB 英文 + ~9GB 中文 Web 数据，TB 级档案尚未开发，可生成几乎无限的非重复样本；
- **可控**：通过调节子图大小 k 校准推理复杂度，支持渐进式课程学习。

3. 方法论：去噪轨迹合成

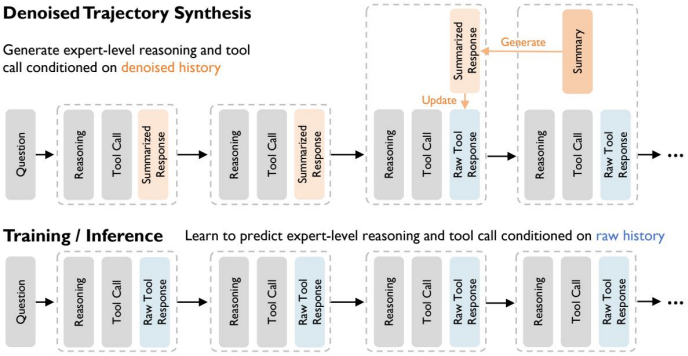

图 2：去噪轨迹合成。合成阶段使用摘要历史，训练/推理阶段使用原始工具响应，形成教师–学生不对称训练。

3.1 问题定义

搜索轨迹定义为 $\tau = [q, (r_1, a_1, o_1), \ldots, (r_T, a_T, o_T), y]$，其中 r_t 为推理步骤（思维链），a_t 为动作（工具调用），o_t 为观察（工具响应）。目标是合成最优推理路径 r_t 和动作 a_t。

3.2 动态上下文去噪合成

在轨迹合成时采用**回顾性摘要机制**。第 t 步的上下文构造遵循“摘要历史 + 原始近期”协议：

$$\mathcal{H}_t = \Big\{q, \underbrace{(r_1, a_1, s_1), \ldots, (r_{t-2}, a_{t-2}, s_{t-2})}_{\text{摘要长期历史}}, \underbrace{(r_{t-1}, a_{t-1}, o_{t-1})}_{\text{原始短期上下文}}\Big\}$$

其中 $s_i = \text{Summarize}(o_i|\text{context})$ 为观察的压缩语义摘要。

运行两阶段循环：(1) **决策阶段**：基于 $\mathcal{H}_t$（含最近一步完整原始观察 o_{t-1}）生成当前决策 (r_t, a_t)，避免过早信息损失；(2) **压缩阶段**：获得新观察 o_t 后，回顾性压缩前一步 $o_{t-1} \to s_{t-1}$，替换到长期历史中。滚动窗口有效过滤噪声，支持极长轨迹生成。

3.3 不对称上下文训练

关键设计——合成与训练使用**不同数据格式**：

教师端（合成）：使用清洁的去噪上下文 $\mathcal{H}_t$（含摘要），产生“黄金”推理路径。

学生端（训练）：剥除摘要，恢复原始噪声上下文：

$$\mathcal{H}_t^{train} = \{q, (r_1, a_1, o_1), \ldots, (r_{t-1}, a_{t-1}, o_{t-1})\}$$

监督学生模型在噪声原始上下文下预测教师产生的最优 r_t, a_t。这迫使模型**隐式学习去噪和信息提取能力**，将上下文清洗逻辑内化到参数中，应对真实世界非结构化数据。

4. 实验设置与主要结果

实现细节。基于 Qwen3-30B-A3B-Thinking-2507 初始化（30B 总参数，3B 激活），最大工具调用 200 次，上下文窗口 256k。训练数据 10.3k 英文 + 1.4k 中文样本。**仅单次训练**，无数据过滤或超参搜索。

模型	BC	BC-ZH	xbench	Wide.
闭源模型				
GPT-5-High	54.9	63.0	–	–
OpenAI Deep Res.	51.5	42.9	–	–
OpenAI-o3	49.1	68.7	–	60.0
开源 *>30B*				
DeepSeek-V3.2	51.4	65.0	–	–
GLM-4.7-357B	52.0	66.6	–	–
∼30B 模型（*SFT+RL*）				
WebSailor-V2 (SFT+RL)	35.3	44.1	73.7	–
Tongyi DR (CPT+SFT+RL)	43.4	46.7	75.0	–
DeepDive (SFT+RL)	15.3	29.7	51.8	–
∼30B 模型（纯 *SFT*）				
MiroThinker (147k)	10.6	13.8	–	–
WebSailor-V2 (SFT)	24.4	28.3	61.7	–
WebLeaper (15k)	27.7	–	66.0	44.1
OpenSeeker (11.7k)	**29.5**	**48.4**	**74.0**	**59.4**

4.1 核心发现

超越资源密集型工业基线。OpenSeeker 在 BrowseComp-ZH 上以 48.4 超越阿里通义 DeepResearch（46.7），后者使用 CPT + SFT + RL 的复杂训练流程。在纯 SFT 对比中，OpenSeeker 在 BC-ZH 上领先第二名 WebSailor-V2-SFT 近 **20%**（48.4 vs. 28.3）。

数据质量远胜数量。MiroThinker 使用 147k 样本仅达 BC 10.6%/BC-ZH 13.8%，OpenSeeker 用 11.7k 即达 29.5%/48.4%，证明高保真数据的决定性作用。

等量数据对比。与 WebSailor-V2/WebLeaper 的多种数据配置（10k–15k 样本）对比，OpenSeeker 在 xbench 上领先约 8%（74.0 vs. 66.0），WideSearch 领先约 15%（59.4 vs. 44.1），验证合成方法的高效性。

与同期工作对比。OpenResearcher（96k 样本）在 BC 上仅 26.3%，xbench 65%；RedSearcher 在 BC-ZH 仅 26.8%。OpenSeeker 以 11.7k 样本全面超越，且为唯一 **100% 数据透明**的学术工作。

4.2 数据难度分析

使用同一开源模型对合成数据与 BrowseComp 基准进行推理对比：中文合成数据平均 **46.35 次工具调用、76.1k token** 轨迹长度，远超 BrowseComp-ZH 的 26.98 次/15.1k token。英文数据平均 45.92 次工具调用，超过 RedSearcher 的 36.91 次。高复杂度与有限数据量（仅 1.4k 中文样本）的组合直接支撑了中文基准上的优异表现。

5. 与相关工作的系统对比

搜索智能体发展可分三类：(1) **闭源**（OpenAI Deep Research、Gemini Deep Research）——性能最强但完全不透明；(2) **开放权重**（Kimi K2/2.5、GLM-4.6/4.7、MiniMax M2）——公开模型但不公开数据，维持“数据护城河”；(3) **学术尝试**（WebDancer、DeepDive、MiroThinker）——或不公开数据，或数据质量不足。OpenSeeker 是**唯一同时公开全部训练数据并达到前沿性能的学术工作**。

方法论差异： WebSailor/WebLeaper 依赖企业合成的专有数据集；DeepDive 利用知识图谱 + 多轮 RL 但仅 4.1k 数据达 BC 15.3%；MiroThinker 堆砌 147k 样本但缺乏难度控制。OpenSeeker 的图拓扑逆向工程方法从根本上保证了问题的事实锚定性和多跳推理必要性，而不对称去噪训练则解决了 Web 规模搜索中原始观察的噪声问题。

6. 局限性与未来方向

- **单次训练**：受资源限制仅训练一次，未进行数据过滤或超参调优，性能为**下界**——存在大量提升空间；
- **英文数据未更新**：英文数据尚未采用最新 QA 标准，难度略低于中文数据，预期更新后性能可进一步提升；
- **纯 SFT 训练**：未使用 RL，参考 WebSailor-V2（SFT 24.4 → SFT+RL 35.3）的提升幅度，OpenSeeker + RL 有望获得显著增益；
- **工具类型单一**：当前仅支持 Web 搜索，计划集成更多工具和数据源，向通用智能体框架发展；
- **未来优化方向**：数据分布优化、严格质量过滤、更高复杂度训练数据生成、渐进式课程学习策略。

Seoul World Model：将世界仿真模型锚定于真实都市

Seo*, Cho*, Kwon, Choi, Jin, Lee, Kim 等 — KAIST AI & NAVER AI Lab, 2025

1. 动机与问题定义

现有视频世界模型（Video World Model）能够根据图像、文本和用户动作自回归地生成动态环境序列，但所有内容均由模型**凭空想象**——起始帧之外的街道几何、远处建筑等均无真实依据。如果世界模型能在**物理存在的真实城市**中运行，用户便可导航熟悉街道、体验假设场景（如海啸淹没自己的城市），并支撑城市规划可视化、自动驾驶场景生成和基于位置的探索。

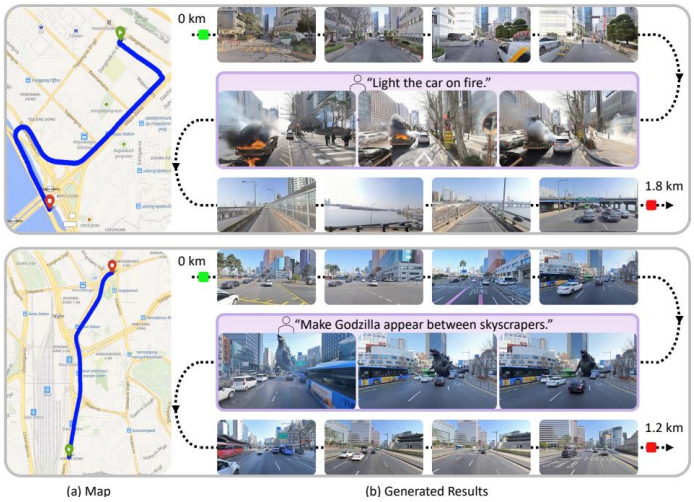

图 1：*SWM* 在首尔真实地图上放置相机轨迹，生成超过 1 公里的连续动态视频，用户可通过文本提示改变场景条件。

然而，大规模 3D 重建系统虽可建模真实城市，却本质上是静态的、缺乏生成式仿真能力；此前从未有世界仿真模型被**锚定（grounded）**于特定真实地点。本文将此目标形式化为**真实世界锚定的视频世界仿真**（real-world grounded video world simulation），并以首尔这一大型密集都市为实例，提出 **Seoul World Model (SWM)**。

核心观察：广泛可用的街景照片为位置特定的视觉参考提供了可扩展来源。SWM 在 Cosmos-Predict2.5-2B 预训练模型基础上，使用 44 万首尔街景图像、Waymo 驾驶视频和合成城市数据进行微调。推理时执行**检索增强生成**（RAG）：给定地理坐标、相机动作和文本提示，检索附近街景图像并以互补的几何与外观参考条件化生成，将每个生成块锚定到该位置的真实几何布局与外观。

1.1 三大挑战与应对

- **时间错位**：街景捕获于特定时刻，但仿真世界应保持动态。检索到的参考可能包含与目标场景不一致的瞬态元素 → **跨时间配对**（cross-temporal pairing）；
- **轨迹覆盖有限与时间稀疏**：真实街景由车载相机以稀疏间隔（5–20m）捕获，轨迹类型受限 → 基于 CARLA 的**合成城市数据集**（行人/车辆/自由相机轨迹）+ **视图插值流水线**（intermittent freeze-frame 策略）；
- **长程误差累积**：城市尺度下（数百米），自回归漂移导致空间锚定失效 → **虚拟前瞻锚点**（Virtual Lookahead Sink）。

2. 数据构建

2.1 街景数据集

收集覆盖首尔主要城区的 **120 万**全景图像（来自 NAVER Map），车牌和行人经模糊处理。处理后 44 万张用于训练。

跨时间配对（Cross-Temporal Pairing）：定义训练序列为沿路线的 N 个连续街景（目标），分配 K 个空间邻近的全景作为参考。关键设计：参考**必须**来自与目标不同的时间戳。若参考与目标同时捕获，则瞬态内容（车辆、行人）完全一致，模型无动力区分持久结构与瞬态物体；跨时间配对消除此歧义——瞬态内容不同迫使模型**依赖持久空间结构**。注意力可视化（图 6）证实该策略使模型对参考中的动态物体注意力显著降低。

视图插值（View Interpolation）：街景数据库仅提供稀疏间隔的全景而非连续视频，直接训练会破坏预训练视频扩散模型的时间连续性。提出**间歇冻结帧策略**（Intermittent Freeze-Frame）：3D VAE 以 4× 时间压缩，将每个关键帧在像素层重复 4 帧形成完整 4 帧组，使 VAE 编码为恰好 1 个 latent；训练视频在平滑运动与短暂冻结段之间交替。推理时同样重复 4 帧编码后替换噪声 latent 对应位置，生成后丢弃重复帧。对比朴素通道拼接方法：PSNR 25.03 vs. 22.52，LPIPS 0.162 vs. 0.245，关键帧一致性大幅提升。

标注：使用 Qwen2.5-VL-72B 生成文本描述，Depth Anything V3 估计深度图和相机位姿，GPS 元数据对齐到真实世界尺度。额外构建 1 万条风格化视频增强（Qwen-Image-Edit + TeleStyle），提升文本引导的风格变化能力。

2.2 合成数据集

基于 CARLA 模拟器构建 **12,700** 条视频，覆盖 6 张城市地图（约 431,500 m^2），包含三类轨迹：（1）**行人轨迹**——自主行人代理的第一人称视频；（2）**车辆轨迹**——多种道路类型和驾驶行为；（3）**自由相机轨迹**——随机路径自由导航并避免碰撞。每张地图沿所有道路以 10 m 间隔渲染街景参考（8 个方向视图），同样遵循跨时间配对原则。

3. 模型架构

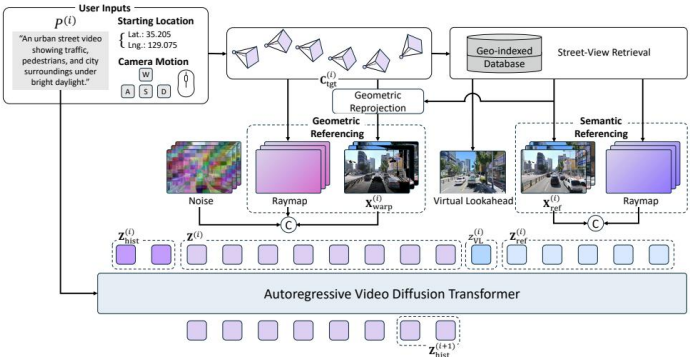

图 2：*SWM* 模型概览。给定起始位置，从地理索引数据库检索街景，通过虚拟前瞻锚点、几何参考和语义参考三条路径条件化自回归生成。

SWM 基于预训练 DiT（Cosmos-Predict2.5-2B，28 层，16 头，隐藏维度 2048），在 3D VAE 压缩的 latent 空间（4× 时间 × 8× 空间）中以块为单位自回归生成。第 i 块接收相机轨迹 $\mathbf{C}^{(i)}$、文本提示 $P^{(i)}$ 和噪声 latent $\mathbf{Z}^{(i)}$，输出去噪 latent $\hat{\mathbf{Z}}^{(i)}$；后续块额外条件于前一块尾部 H 个历史 latent 以保持时间连续性。

3.1 街景检索

检索数据库含 120 万全景图像，各渲染为 8 个等角针孔视图并估计度量尺度深度和 6-DoF 位姿。对每个目标块：（1）最近邻搜索沿目标轨迹查找候选街景位置；（2）基于深度的重投影过滤保留投影覆盖率超阈值者，最终得到 K 个参考及其位姿和深度。

3.2 虚拟前瞻锚点（Virtual Lookahead Sink）

先前方法使用**注意力锚点**（attention sink），即固定的首帧作为全局上下文。但在城市尺度下，相机移动数百米后首帧逐渐失去信息价值。SWM 提出**动态更新**的虚拟前瞻锚点：对每个块，检索最靠近目标轨迹终点 $c^{(i)}_{T-1}$ 的街景图像作为**虚拟未来目的地**，编码为单个 latent $z^{(i)}_{\text{VL}}$，RoPE 时间位置设为当前块之后 Δ_{VL} 处：

$$\mathbf{Z}^{(i)}_{\text{seq}} = [\mathbf{Z}^{(i)}_{\text{hist}};\ \mathbf{Z}^{(i)};\ z^{(i)}_{\text{VL}}], \quad \mathbf{p}^{(i)}_{\text{seq}} = [\underbrace{1,\ldots,H}_{\text{历史}};\ \underbrace{H{+}1,\ldots,H{+}L}_{\text{目标}};\ \underbrace{H{+}L}_{}$$

训练时从真实未来帧随机采样不同前瞻距离，推理时 Δ_{VL}=5 并用检索街景替代。每个块刷新锚点，确保锚定始终与当前生成区域相关。

3.3 几何参考与语义参考

几何参考（Geometric Referencing）：对每个目标帧，将最近参考通过深度前向散射重投影到目标视角：$x^{(i)}_{\text{warp},t} = \text{Render}\big(\text{Unproj}(x^{(i)}_{\text{ref},j}, d^{(i)}_{\text{ref},j}), c^{(i)}_{\text{ref},j\to t}\big)$，提供密集空间布局线

索。扭曲视频经 3D VAE 编码后在通道维度与噪声 latent 拼接输入 DiT。

语义参考（Semantic Referencing）：保留原始参考的外观细节。每个参考编码为单个 latent，沿时间轴拼接到目标 latent 序列中（RoPE 位置设有大间隔 G），所有目标 latent 可注意全部 K 个参考，获取互补外观线索。所有 latent 的相机位姿通过 Plücker 射线嵌入编码并与 latent 通道拼接。两条路径互补：几何参考提供空间对齐但丢失细节，语义参考保留外观但缺乏显式空间对齐。消融实验证实缺任一路径均导致质量下降。

4. 训练细节

基于 Cosmos-Predict2.5-2B-I2W 微调，AdamW 优化器，学习率 4.8×10^{-5}，24 张 H100 GPU 上 batch size 48 训练 10K 步。数据混合：Waymo (20%)、首尔街景 (40%)、合成数据 (40%)。Teacher-Forcing (TF) 变体：77 帧/块，H=5, K=5；Self-Forcing (SF) 变体：先 ODE 初始化 6K 步再微调 10K 步，12 帧/块，H=3, K=1，单 H100 达 **15.2 fps**。CFG dropout：文本 20%、参考 20%、扭曲视频 20%。

5. 实验结果

5.1 评估设置

构建两个基准：**Busan-City-Bench** 和 **Ann-Arbor-City-Bench**（来自 MARS 数据集），各含 30 条测试序列（365 帧，约 100 米），模型**未在这两个城市上训练**。基线包括 Aether、DeepVerse、Yume1.5、HY-World1.5、FantasyWorld 和 Lingbot。

5.2 定量比较

方法	FID↓	FVD↓	RotErr/mPSNR↑
Aether	141/133	1097/1215	.030/.078/11.1/13.0
DeepVerse	130/183	893/1525	.062/.251/12.2/13.4
Yume1.5	55/86	425/994	.153/.326/12.1/14.2
HY-World1.5	50/67	544/865	.044/.198/11.9/14.3
FantasyWorld	84/68	783/918	.056/.215/10.0/12.0
Lingbot	62/58	717/1040	.081/.269/10.5/12.5
SWM (TF)	**28/57**	**302/640**	**.020/.054/14.6/15.2**
SWM (SF)	33/44	326/780	.028/.217/13.5/14.2

SWM 在视觉保真度（FID/FVD）、相机跟随精度（RotErr/TransErr）和 3D 忠实度（mPSNR/mLPIPS）上全面领先。现有世界模型在长轨迹上普遍漂移，导致模糊、运动减少甚至完全崩溃。与静态场景模型（GEN3C、VMem）的额外对比表明：GEN3C 在静态区域指标上有竞争力（mPSNR 14.16），但无法处理动态场景（FID 45.72 vs. SWM 28.43）。

5.3 消融实验

变体	FID↓	FVD↓	TransErr	mPSNR↑
完整模型	28.4	301.8	0.015	14.56
去除跨时间配对	44.7	487.9	0.123	12.54
去除合成数据	27.7	365.2	0.020	13.52
去除几何参考	33.0	398.7	0.051	12.33
去除语义参考	30.3	326.2	0.022	14.08
去除注意力锚点	33.1	342.8	0.016	14.16
首帧锚点	32.7	378.9	0.018	14.25
首位置锚点	32.4	354.6	0.027	14.35

关键发现：（1）**跨时间配对**影响最大——去除后 FID 从 28.4 劣化至 44.7，TransErr 从 0.015 飙升至 0.123，模型无法忽略参考中的动态物体；（2）合成数据主要提升相机跟随精度和 3D 忠实度而非 FID；（3）几何和语义参考互补——几何参考主导空间对齐（TransErr 0.015 vs. 0.051），语义参考提升外观保真度；（4）VL Sink 在滑动窗口 FID 曲线上实现最低值且退化最慢，长程（1460 帧/∼500m）评估中优势更显著（FID 25.13 vs. 无锚点 37.37）。

5.4 定性结果与泛化能力

SWM 展示了三大能力：（a）在真实世界锚定下仍可通过文本提示生成多样场景条件（暴风雨、金色夕阳等）同时保持城市布局；（b）合成数据训练使其支持行人视角等非驾驶轨迹；（c）在数公里长程生成中保持空间一致性。跨城市泛化（釜山、安娜堡）**无需任何微调**即可工作。参考稀疏度实验（K=1∼5）显示：K 减少时 mPSNR 下降但 FID/FVD 无明显退化，表明参考条件化主要提升几何/外观锚定而非整体视觉真实感。

6. 局限性与未来方向

- 生成质量受限于训练数据质量——稀疏街景插值视频不如真实捕获视频；街景等距采集导致低速/停车段时间不连续，偶发车辆突然出现/消失；
- 当前依赖街景数据库覆盖范围，未覆盖区域无法生成；
- 动态物体建模仍较粗糙，尚未显式建模物理交互；
- 未来方向：融入更多真实视频数据提升质量、扩展至更多城市、结合显式 3D 表示实现更精确的几何一致性、支持交互式实时仿真。

Attention Residuals：用深度注意力替代固定残差累加

Kimi Team — Moonshot AI, 2026

1. 问题动机与背景

现代 LLM 普遍采用 PreNorm 残差连接 $\boldsymbol{h}_l = \boldsymbol{h}_{l-1} + f_{l-1}(\boldsymbol{h}_{l-1})$，展开递推可得 $\boldsymbol{h}_l = \boldsymbol{h}_1 + \sum_{i=1}^{l-1} f_i(\boldsymbol{h}_i)$——即所有前序层输出的**等权求和**。这一固定累加机制存在三大局限：

- **隐状态不可控增长**：PreNorm 下 $\|\boldsymbol{h}_l\|$ 随深度以 $O(L)$ 增长，逐层相对贡献被稀释（PreNorm dilution），深层被迫学习越来越大的输出以维持影响力；
- **无选择性访问**：每层仅接收压缩后的单一状态 $\boldsymbol{h}_{l-1}$，无法选择性地检索早期特定层的输出；注意力层与 MLP 层接收相同聚合状态，尽管它们可能需要不同加权；
- **信息不可逆丢失**：聚合中丢失的信息在深层无法恢复；实证研究表明大量层可被剪枝而几乎不损失性能。

这一困境与 RNN 在序列维度面临的瓶颈高度相似——RNN 将所有历史压缩为单一隐状态，Transformer 通过注意力机制实现了选择性访问。作者提出**时间–深度对偶性**：残差连接在深度维度的角色等价于 RNN 在时间维度的角色，因此可以用同样的注意力方法替代深度维度的固定递推。

2. 方法：Attention Residuals

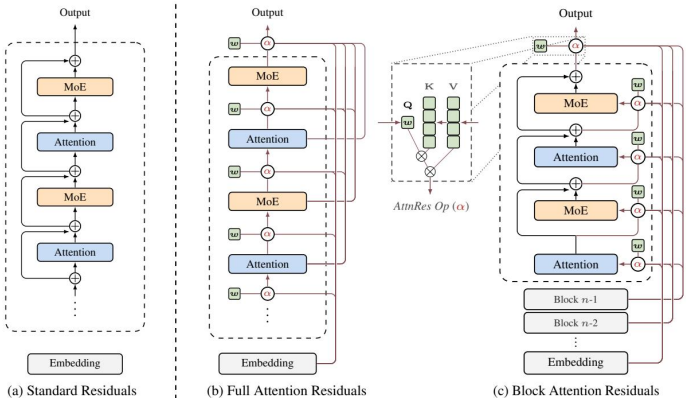

图 1：*(a)* 标准残差：等权累加；*(b) Full AttnRes*：每层对所有前序输出做注意力聚合；*(c) Block AttnRes*：分块压缩，降低开销。

核心思想是将固定累加 $\boldsymbol{h}_l = \sum_i \boldsymbol{v}_i$ 替换为 $\boldsymbol{h}_l = \sum_i \alpha_{i\to l} \cdot \boldsymbol{v}_i$，其中 $\alpha_{i\to l}$ 为 softmax 注意力权重，实现内容依赖的深度选择性聚合。

2.1 Full Attention Residuals

每层 l 定义一个可学习伪查询 $\boldsymbol{q}_l = \boldsymbol{w}_l \in \mathbb{R}^d$，键值对为各前序层输出：$\boldsymbol{k}_i = \boldsymbol{v}_i$，其中 $\boldsymbol{v}_0 = \boldsymbol{h}_1$（token embedding），$\boldsymbol{v}_{i\geq 1} = f_i(\boldsymbol{h}_i)$。注意力核函数采用：

$$\phi(\boldsymbol{q}, \boldsymbol{k}) = \exp\big(\boldsymbol{q}^\top \mathrm{RMSNorm}(\boldsymbol{k})\big)$$

注意力权重经 softmax 归一化：$\alpha_{i\to l} = \phi(\boldsymbol{q}_l, \boldsymbol{k}_i) / \sum_{j=0}^{l-1} \phi(\boldsymbol{q}_l, \boldsymbol{k}_j)$。层 l 的输入为 $\boldsymbol{h}_l = \sum_{i=0}^{l-1} \alpha_{i\to l} \cdot \boldsymbol{v}_i$。

开销分析：Full AttnRes 需 $O(L^2 d)$ 计算和 $O(Ld)$ 存储层输出。由于深度远小于序列长度（$L < 1000$），计算开销可忽略。在普通训练中，层输出本就保留用于反向传播，无额外内存开销。但在大规模训练中，激活重计算和流水线并行要求显式保留和跨阶段传输这些激活，$O(Ld)$ 的通信开销成为瓶颈。

关键设计：伪查询 $\boldsymbol{w}_l$ 为可学习参数，与层的前向计算**解耦**——同一块内所有层的注意力权重可并行计算，无需等待各层顺序输出。RMSNorm 防止输出幅值大的层主导注意力权重。所有伪查询必须**初始化为零**，使训练初期 $\alpha_{i\to l}$ 均匀，AttnRes 退化为等权平均，避免训练不稳定。

2.2 Block Attention Residuals

为解决 Full AttnRes 在大规模训练中 $O(Ld)$ 的内存与通信瓶颈，提出 Block AttnRes：将 L 层分为 N 个块（每块 $S = L/N$ 层），块内用标准残差求和为单一表示，块间用 Full AttnRes 的注意力机制聚合。

块内累加：第 n 块的表示为 $\boldsymbol{b}_n = \sum_{j\in B_n} f_j(\boldsymbol{h}_j)$，同时维护部分和 $\boldsymbol{b}_n^i$（前 i 层的累加）。

块间注意力：对于第 n 块第 i 层，值矩阵为 $\mathbf{V} = [\boldsymbol{b}_0, \boldsymbol{b}_1, \ldots, \boldsymbol{b}_{n-1}]^\top$（首层）或追加 $\boldsymbol{b}_n^{i-1}$（后续层），其中 $\boldsymbol{b}_0 = \boldsymbol{h}_1$（token embedding 始终作为源）。

效率：内存从 $O(L)$ 降至 $O(N)$，计算从 $O(L^2)$ 降至 $O(N^2)$。N 插值两个极端：$N = L$ 恢复 Full AttnRes，$N = 1$ 退化为标准残差。实验表明 $N \approx 8$ 即可恢复大部分收益。每层仅新增一个 RMSNorm 和一个 $\boldsymbol{w}_l \in \mathbb{R}^d$，参数量可忽略。

3. 基础设施设计

3.1 训练：跨阶段缓存

在交错式流水线并行（P 物理阶段 × V 虚拟阶段）下，朴素实现在每次阶段切换时传输全部累积块，通信代价为 $\mathrm{Comm}_{\mathrm{naive}} = \frac{C(C-1)}{2} N_p d$。**跨阶段缓存**利用同一物理阶段处理多个虚拟阶段的特性：第一虚拟阶段正常传输，后续仅传输增量块（$\sim PN_p$ 个）。总通信降为：

$$\mathrm{Comm}_{\mathrm{cached}} = \frac{P(P-1)}{2} N_p d + (V-1) P^2 N_p d$$

峰值单次传输从 $O(C)$ 降至 $O(P)$，V 倍改善。端到端训练开销 $< 4\%$。

3.2 推理：两阶段计算策略

将深度注意力计算分为两阶段：**Phase 1**（并行）——同一块内 S 个伪查询批量计算对已缓存块表示的注意力，将 S 次内存读取摊销为 1 次；**Phase 2**（顺序）——逐层计算块内部分和的注意力，通过 online softmax 与 Phase 1 结果合并。每层每 token 内存访问仅 $(\frac{N}{S} + 3)d$ 读 $+ 2d$ 写。典型配置（L=128, N=8, S=16）下仅 $5.5d$，远低于 mHC 的 $34d$（m=4）。端到端推理延迟开销 $< 2\%$。

长上下文 prefilling：块表示沿序列维度在 P 个 TP 设备间分片，Phase 1 在本地分片独立执行，Phase 2 合并集成到标准 TP all-reduce 路径。128K 上下文从 15 GB 降至每设备 ~1.9 GB，结合 chunked prefill 进一步降至 <0.3 GB。

4. 实验结果

4.1 Scaling Laws

在 5 个模型规模（194M–528M 激活参数）上训练 Baseline、Full AttnRes 和 Block AttnRes（$N \approx 8$），拟合幂律曲线 $\mathcal{L} = A \times C^{-\alpha}$。

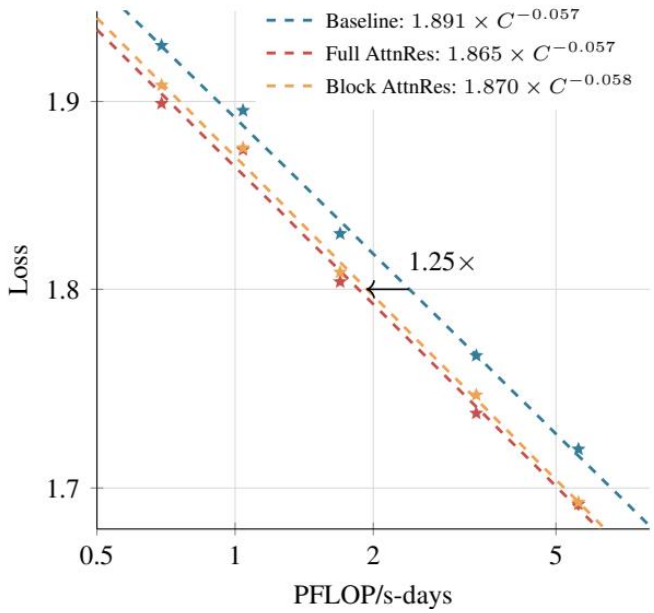

图 2：*Scaling law* 曲线。*Full/Block AttnRes* 在所有计算预算下一致优于 *Baseline*。

拟合结果：Baseline $\mathcal{L} = 1.891 \times C^{-0.057}$，Block AttnRes $\mathcal{L} = 1.870 \times C^{-0.058}$，Full AttnRes $\mathcal{L} = 1.865 \times C^{-0.057}$。斜率相近但 AttnRes 始终更低。在 5.6 PFLOP/s-days 下，Block AttnRes 达到 1.692 vs Baseline 1.714，等价于 **1.25**×

计算优势。Full/Block 差距随规模缩小，最大规模仅差 0.001。Block AttnRes 性能匹配 mHC(-lite)，但每层 I/O 仅 $5.5d$ vs $34d$。

4.2 48B 模型主实验

基于 Kimi Linear 架构（48B 总参/3B 激活参数），27 个 Transformer 块（54 层），KDA 与 MLA 3:1 交替，Block AttnRes 6 层/块（9 块 + embedding = 10 个深度源）。在 1.4T tokens 上预训练（1T WSD + 400B 高质量 mid-training）。

训练动态：(1) AttnRes 验证损失全程更低，decay 阶段差距扩大；(2) Baseline 输出幅值随深度单调增长（PreNorm dilution），Block AttnRes 在块边界重置累加，呈有界周期模式；(3) Baseline 最早层梯度不成比例地大，AttnRes 的可学习 softmax 权重引入概率质量竞争，梯度分布**显著更均匀**。

下游性能（表 3 全部指标 AttnRes 匹配或超越 Baseline）：

Benchmark	Baseline	AttnRes
GPQA-Diamond	36.9	**44.4** (+7.5)
Math	53.5	**57.1** (+3.6)
HumanEval	59.1	**62.2** (+3.1)
MBPP	72.0	**73.9** (+1.9)
MMLU	73.5	**74.6** (+1.1)
C-Eval	79.6	**82.5** (+2.9)
BBH	76.3	**78.0** (+1.7)
TriviaQA	69.9	**71.8** (+1.9)

多步推理任务（GPQA、Math）和代码生成（HumanEval）提升最为显著，与"改善深度信息流利于组合性任务"的假设一致。

4.3 消融实验

在 16 头模型上逐一验证设计选择：

与先前方法对比：DenseFormer（固定标量系数）无增益（1.767 vs Baseline 1.766）；mHC（m 流学习混合矩阵）改善至 1.747；Full AttnRes 达 **1.737**，Block AttnRes 达 1.746，均优于两者。

跨层访问粒度：滑动窗口聚合（SWA, W=8）仅 1.764，远逊于 Full/Block AttnRes，表明选择性访问远距层比关注更多近邻层更重要。Block 大小 S 从 1（Full）到 32 扫描，S=2, 4, 8 均接近 1.746，$S\geq16$ 趋向 Baseline。

组件设计消融：

- **输入依赖查询**（$\boldsymbol{q}_l$ 由隐状态投影）：1.731，最优但引入 $d\times d$ 投影和顺序依赖，故默认使用学习参数；
- **输入无关混合**（去掉 query/key，用学习标量）：1.749，远逊 1.737；
- **sigmoid vs softmax**：sigmoid 1.741 > softmax 1.737，softmax 的竞争性归一化促进更锐利的选择；
- **多头深度注意力**（H=16）：1.752 > 1.746，最优深度混合在通道间大致一致；
- **去除 RMSNorm**：Full 1.743、Block 1.750，均退化；Block 尤为关键因块表示累积层数不同导致幅值差异大。

4.4 最优架构分析

在固定计算和参数预算下（$\sim 6.5\times10^{19}$ FLOPs，$\sim 2.3\times10^{8}$ 激活参数），枚举 5×5 网格（$d_{\text{model}}/L_b \times H/L_b$）。AttnRes 在全部 25 个配置均优于 Baseline（改善 0.019–0.063）。Baseline 最优点在 $d_{\text{model}}/L_b \approx 60$，AttnRes 偏移至 ≈ 45——即更深更窄的网络，表明 AttnRes 能更有效地利用额外深度。

4.5 学习到的注意力模式

可视化 $\alpha_{i\to l}$ 揭示三个关键模式：(1) **局部性保留**——每层最强关注直接前驱，但出现选择性跳层连接；(2) **层类型特化**——token embedding 在 pre-attention 层始终保持显著权重，pre-MLP 层更依赖近期表示；(3) **Block AttnRes 保持结构**——对角主导、embedding 持久性和层特化均从 Full 迁移到 Block，块压缩起到隐式正则化作用。

5. 统一视角：结构化矩阵分析

所有残差变体可统一为深度混合矩阵 $\mathbf{M}\in\mathbb{R}^{L\times L}$：$\boldsymbol{h}_l = \sum_{i=0}^{l-1}\mathbf{M}_{i\to l}\boldsymbol{v}_i$。标准残差的 $\mathbf{M}$ 为全 1 下三角矩阵（semiseparable 秩 1）；Highway 为 1-semiseparable 但权重输入依赖；(m)HC 为 m-semiseparable（$\mathbf{M}_{i\to l} = \beta_i^\top \mathbf{A}^{\times}_{i+1\to l}\boldsymbol{\alpha}_l$）；Full AttnRes 为稠密秩-$L$ 矩阵。

关键洞察：标准残差和 Highway/(m)HC 等变体本质上是深度维度的**线性注意力**——(m)HC 的展开权重可解读为 $\boldsymbol{\alpha}_l$ 为查询、β_i 为键、$\mathbf{A}^{\times}_{i+1\to l}$ 为深度相对位置算子。AttnRes 将此推广为深度维度的 **softmax 注意力**，完成了与序列维度线性 →softmax 转变相同的跃迁。当核 ϕ 可分解为 $\phi(\boldsymbol{q},\boldsymbol{k}) = \varphi(\boldsymbol{q})^\top\varphi(\boldsymbol{k})$ 时，深度注意力退化为递推——正是 MRLA–GLA 和 DDL–DeltaNet 对应关系的根源。

6. 相关工作对比

- **单状态递推**（Residual, ReZero, LayerScale, Highway, DeepNorm, KEEL）：每层仅访问 $\boldsymbol{h}_{l-1}$，无法选择性检索早期层；
- **多状态递推**（SiameseNorm, (m)HC, DDL）：维护 m 并行流缓解信息压缩，但仍受递推约束，$\mathbf{M}$ 秩受限于 m；
- **跨层连接**（DenseNet, DenseFormer, MRLA）：提供跨层访问但使用固定/线性权重，难以扩展；
- **AttnRes**：softmax 归一化 + 输入依赖 + 选择性全层访问，每层仅需一个 d 维伪查询；Block 结构将代价从 $O(L^2)$ 降至 $O(LN)$。

7. 局限性与未来方向

- Block AttnRes 的块内仍为标准残差累加，信息粒度受限于块大小；随硬件通信能力提升，更细粒度分块或 Full AttnRes 是自然演进方向；
- 当前伪查询为学习参数而非输入依赖（消融显示输入依赖查询可进一步降至 1.731），未来可探索低开销的动态查询方案；
- 深度维度目前使用 vanilla softmax attention，引入线性复杂度的高效注意力变体（如线性注意力）是自然扩展；
- 更深模型虽然 AttnRes 下表现更优，但推理延迟仍随深度线性增长，部署时需权衡深度与宽度；
- 方法与任何归一化/门控方案正交兼容，与 mHC 等多状态方法的结合值得探索。

Mixture-of-Depths Attention：面向深度信息聚合的统一注意力机制

Zhu[1,2], Fang[2,†], Liao[1,2], Wang[2], Cheng[2], Huang[2], Chen[2], Wei[2], Zeng[2], Wang[2], Lin[2], Li[2], Wang[1,#] — [1]HUST, [2]ByteDance Seed

1. 问题动机与背景

大语言模型（LLM）的性能提升依赖于四个维度的扩展：上下文长度、训练数据、模型宽度和模型深度。其中**深度扩展**虽具有强大的层级计算表示能力，但在实践中面临两大瓶颈：(1) **优化困难**——更深的网络训练不稳定；(2) **信息稀释**——浅层形成的有用特征在反复残差更新中逐渐被稀释，深层难以恢复。

标准残差连接（ResNet 风格）虽缓解梯度消失，但将深度历史压缩到单一隐状态轨迹 $X_l \in \mathbb{R}^{T\times D}$ 中，信息稀释问题未根本解决。密集跨层连接（DenseNet 风格）通过拼接保留所有层历史信息，但参数增长为 $O(L^2D^2)$，在 LLM 规模下不可承受。

本文提出 **Mixture-of-Depths Attention（MoDA）**，一种统一的深度感知注意力机制：每个注意力头在**单一 softmax** 下同时关注当前层的序列 KV 和所有前序层的深度 KV，以数据依赖的方式动态检索深度历史信息，在表达力、效率和硬件友好性之间取得平衡。

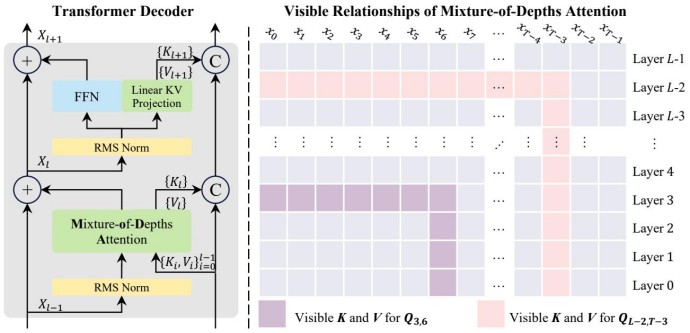

图 1：*MoDA* 概览。*Query* 除关注序列 *KV* 外，还关注同一位置前序各层的深度 *KV* $\{K_i, V_i\}_{i=0}^{l-1}$。

2. 方法论：深度流设计空间

作者通过统一的 "read–operate–write" 视角分析 Transformer 堆叠策略：

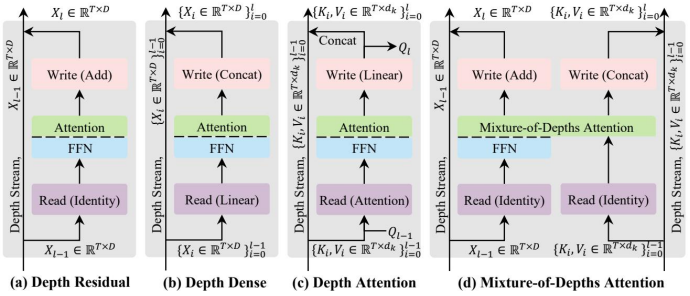

图 2：四种深度流机制对比：*(a)* 深度残差 *(b)* 深度密集 *(c)* 深度注意力 *(d) MoDA*。

2.1 深度残差（Depth Residual）

Read 为恒等映射，Write 为加法：$X_l = X_0 + \sum_{i=1}^{l-1} \mathcal{F}(X_i, \mathcal{W}_i)$。深度历史被压缩为固定大小张量，信息通过反复叠加而稀释。

2.2 深度密集（Depth Dense）

Read 对所有历史表示 $\{X_i\}_{i=0}^{l-1}$ 做线性投影回 $T\times D$，Write 沿深度拼接。信息无损传播，但计算复杂度为 $O(TL^2D^2)$，参数规模为 $O(L^2D^2)$，不适用于大模型。

2.3 深度注意力（Depth Attention）

作为概念桥梁，用注意力机制以数据依赖方式读取深度历史。对 token t，query $Q_{l-1,t}$ 仅关注同一位置的深度 KV $\{K_{i,t}, V_{i,t}\}_{i=0}^{l-1}$。Write 步骤通过额外投影矩阵 $W^W_{Q,l}, W^W_{K,l}, W^W_{V,l} \in \mathbb{R}^{D\times D/G}$ 生成新的 Q/K/V 供后续层使用。计算降至 $O(TL^2D)$，比 Depth Dense 低 $1/D$ 倍。

2.4 MoDA：统一序列与深度注意力

MoDA 在 Depth Attention 基础上做出关键升级：**将序列注意力和深度注意力融合进单一 softmax**。每个 token 在同一归一化空间下同时关注序列级 KV 和深度级 KV：

$$\mathrm{Attention}(Q, [K^{\mathrm{seq}}; K^{\mathrm{depth}}], [V^{\mathrm{seq}}; V^{\mathrm{depth}}])$$

Write 步骤中，注意力层直接**复用**序列注意力的 KV 作为深度 KV（无需额外投影），FFN 层则通过轻量 KV 投影生成对应的深度 KV 追加到深度流中。

复杂度优势： MoDA 进一步将参数复杂度从 Depth Attention 的 $O(LD^2)$ 降至 $O(LD^2/G)$（G 为 GQA 分组数），因其复用序列注意力的 Query 投影，无需额外的深度 Query 投影。FLOPs 保持 $O(TL^2D)$ 的线性宽度缩放，缓存为 $O(TLD)$。

3. 硬件高效实现

朴素 PyTorch 实现因非连续内存访问导致 GPU 利用率低下。本文提出三级优化策略：

3.1 Flash 兼容深度 KV 布局

将深度缓存沿长度 $T\times L$ 的单一轴展平，使每个序列位置 t 的 L 个深度状态连续存储，转换为块级连续读取。但密集计算 $\mathbf{S}^{\mathrm{depth}} \in \mathbb{R}^{T\times(TL)}$ 的深度利用率仅为 $\eta_{\mathrm{depth}} = 1/T$。

3.2 Chunk-aware 深度 KV 布局

将 query 按 chunk 大小 C 分组，每个 chunk 仅访问对应的局部深度 KV 区域 $C\times L$，而非全局 $T\times L$。深度利用率提升至 $\eta_{\mathrm{depth}} = T\cdot L/(T\cdot C\cdot L)$，显著减少无效 HBM 访问。

3.3 Group-aware 深度 KV 计算

在 GQA 映射 $T_q = GT_{kv}$ 下，G 个相邻 query 行共享相同的 base-time 索引 $\lfloor i_q/G \rfloor$，可复用同一深度 KV 块。有效深度 KV 从 $C\times L$ 降至 $(C/G)\times L$，利用率进一步提升 G/C 倍。

3.4 融合内核实现

Algorithm 1 描述完整的融合前向流程：对每个 query 块 b_q，在 SRAM 上维护共享的 online-softmax 状态 (m, acc, o)。先遍历序列 KV 块（全可见块无 mask，边界块施加分组因果 mask $\lfloor i_q/G \rfloor \geq i_k$），再进入深度循环，对展平深度索引 $b_d \in [t^{\mathrm{start}}_{\mathrm{base}} L, t^{\mathrm{end}}_{\mathrm{base}} L)$ 施加深度 mask：

$$\mathrm{mask}(i_q, j_d) = \mathbf{1}[\lfloor i_q/G \rfloor = \lfloor j_d/L \rfloor]$$

所有序列和深度 logits 共享同一组 online-softmax 累积器，最终一次归一化写回 HBM。

3.5 内核效率对比

在 A100 GPU(bf16)上的 forward&backward 测试表明：序列长度 T 从 4096 增至 65536 时，MoDA 相对 FlashAttention-2 的额外开销从 25.86% 降至 **2.73%**（即 FA2 效率的 97.3%）。GQA 分组 G 从 2 增至 32 时，额外开销从 27.07% 降至 2.84%。内核消融实验显示：朴素 PyTorch → Flash 兼容（162.5×）→ +Chunk-aware（再降 52%）→ +Group-aware（再 4.31×），总加速约 **1458**×。

4. 实验结果

4.1 实验设置

基于 OLMo2 数据集的 400B token 子集，训练 700M 和 1.5B 参数模型。采用 GQA、bf16 精度、全局 batch size 1024、上下文长度 4096。评估包含 10 个下游任务和 10 个领域验证集 PPL。

4.2 MoDA 变体消融（700M）

配置	C4 Val PPL	下游平均	FLOPs(T)
OLMo2 基线（36 层）	18.59	56.93	8.01
OLMo2（38 层，更多参数）	18.31	57.11	8.41
+Depth KV（复用序列 KV）	18.48	58.10	8.02
+Extra FFN KV 投影	18.21	58.87	8.33
+Extra Attn KV 投影	18.17	58.97	8.63

关键发现：（1）**深度 KV 显著有效**——仅复用前序层序列 KV，额外 FLOPs 仅 0.12%，下游平均提升 +1.17。（2）**FFN 深度 KV 重要**——加入 FFN 侧 KV 投影进一步提升 +0.77，性能优于参数量相当的 38 层基线（+1.76）。（3）**额外 Attn KV 投影饱和**——仅带来 +0.10 微弱提升但引入显著参数/FLOPs 开销。因此默认采用 "Seq KV + Depth KV + FFN KV Proj." 配置。

4.3 模型规模扩展

下游任务（10 项平均）： 700M 从 57.11 提升至 **58.87**（+1.76），1.5B 从 62.28 提升至 **64.39**（+2.11）。具体增益广泛分布：WinoGrande +4.89/ + 2.37，COPA +5.00/ + 4.00，ARC-C +1.34/ + 4.35，BoolQ +3.09/ + 3.73，MMLU +0.92/ + 1.86（700M/1.5B）。

验证 PPL（10 域平均）： 700M 从 15.61 降至 **15.46**，1.5B 从 13.67 降至 **13.47**，**全部 10 个领域均有改善**。1.5B 上 Reddit PPL 从 21.21 降至 20.85，ICE 从 15.37 降至 15.08。

4.4 层数分析

在小模型（width=384）上分别测试 24 层和 48 层配置。Depth KV 在两种深度下均一致降低 FineWeb-Edu 验证损失。关键发现：**post-norm 从 MoDA 获益远大于 pre-norm**——48 层下 post-norm 降低 0.0409 loss vs. pre-norm 仅 0.0041。加入 FFN KV 投影在两种深度下进一步提升（48 层 post-norm: 3.3653 → 3.3484；24 层 post-norm: 3.4537 → 3.4338）。

4.5 注意力可视化分析

在 700M 模型的层 $\{0, 11, 23, 35\}$ 上可视化 attention heatmap。在联合 softmax 下，query 关注拼接的 [Sequence KV | Depth KV] 空间。观察到：（1）中间层和深层对深度 KV 块分配了**显著且持续**的注意力权重；（2）对角序列注意力较强的头仍向深度槽分配概率，广谱头则更重度依赖深度 KV；（3）MoDA 的注意力模式**减弱了 attention sink 现象**——概率分布更均匀地分散到序列和深度槽，而非坍缩到少数固定 sink 位置。

5. 与相关工作的对比

- **残差连接升级**（Hyper-Connections、Virtual Width Networks、mhc 等）：通过修改残差路径缓解信息稀释，但仍为固定模式聚合。MoDA 提供**数据依赖**的动态深度检索。
- **DenseFormer**：深度加权平均，连接模式固定且参数增长为 $O(L^2D^2)$。MoDA 参数仅 $O(LD^2/G)$。
- **Transformer-XL / 稀疏注意力**：扩展序列维度上下文，MoDA 正交地扩展**深度维度**上下文。
- **Post-LayerNorm**：MoDA 与 post-norm 结合效果最佳，两者在深度扩展中互补。

6. 局限性与未来方向

- **深度 KV 缓存线性增长**：缓存随层数 L 线性增长，极深网络（$L > 256$）可能成为内存瓶颈。作者提出**有界深度 KV 槽缓存**方向：固定槽数 $S \ll L$，通过动态选择（按效用打分保留 top-S）或滑动窗口策略管理。
- **工业级 CUDA 工程**：当前内核达 FA2 的 97.3% 效率，但万亿参数训练仍需更深度的内存调度、计算流水线和分布式通信重叠优化。
- **模型规模**：当前验证至 1.5B，更大规模（如 7B+）的效果有待验证。
- **深度增长时额外开销**：L 从 64 增至 256 时，MoDA 额外时间从 8.59% 升至 30.52%，需 bounded caching 缓解。
- **架构无关性**：MoDA 可扩展至多模态智能、视觉理解和世界模型等 Transformer 广泛应用的领域。

7. 总结

MoDA 通过在单一 softmax 下统一序列注意力和深度注意力，为 LLM 深度扩展提供了一种高效的数据依赖信息聚合原语。硬件高效内核的三级优化（Flash 兼容 + Chunk-aware + Group-aware）使其在 64K 序列长度下达到 FA2 效率的 97.3%。在 1.5B 参数模型上，MoDA 仅需 3.7% 额外 FLOPs 即实现 10 域平均 PPL 降低 0.2、10 项下游任务平均提升 2.11%，且与 post-norm 结合效果更佳。这些结果表明显式深度历史检索是 Transformer 深度扩展的实用有效方向。

HSImul3R：物理闭环驱动的人–场景交互仿真级三维重建

Cao[1], Xie[1], Hong[1], Zhuo[3], Chen[1], Pan[2], Liu[1,⊠] — [1]NTU S-Lab, [2]ACE Robotics, [3]Shanghai AI Lab, 2025

1. 问题动机与背景

具身智能（Embodied AI）旨在将智能体嵌入物理世界，核心挑战之一是建模**人形体–场景交互（HSI）**——需同时理解人体运动、空间布局与交互稳定性。从图像/视频重建 HSI 可为仿真训练提供高保真监督，是连接被动观察与主动机器人部署的关键桥梁。

然而，现有方法存在严重的**感知–仿真鸿沟**（perception–simulation gap）：视觉上合理的重建结果往往违反物理约束，在物理引擎中不稳定，无法用于具身 AI。该鸿沟源于人和环境的碎片化建模，具体表现为三条独立路线：

- **三维场景重建**（NeRF、3DGS、DUSt3R）：聚焦环境几何，忽视人体动态；
- **人体运动估计**（HMR、SMPLer-X）：鲁棒但孤立重建运动，不建模物理接触；
- **交互建模**（SMPL 驱动的 HSI 数据集）：规模小、多样性有限、缺乏物理验证。

近期统一框架（HOS-NeRF、HSfM）尝试联合建模，但仅在 2D 图像空间优化，优先视觉对齐而非几何/物理有效性，输出缺乏度量精度和接触保真度。

HSImul3R 是首个**仿真级** HSI 三维重建框架，将物理仿真器作为主动监督者，通过**双向物理感知优化**闭环精炼人体动态与场景几何，弥合视觉真实感与具身部署之间的鸿沟。

2. 系统架构总览

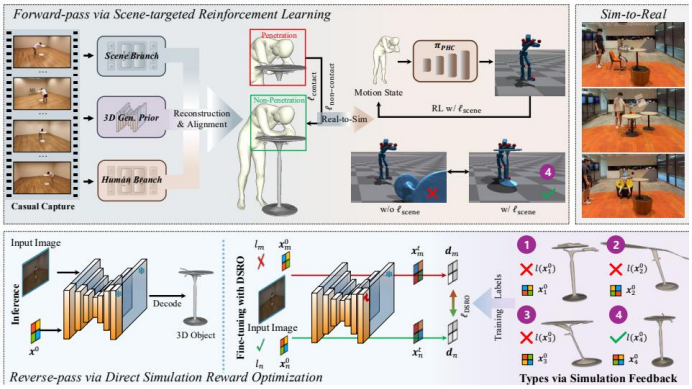

图 1：*HSImul3R* 总体流程。给定稀疏视角输入，先注入 *3D* 生成先验对齐人–场景，再通过前向（场景引导 *RL* 优化运动）和反向（*DSRO* 精炼场景几何）双向物理闭环优化。

如图 1 所示，HSImul3R 由三个阶段组成：(1) **人–场景交互重建与对齐**——独立重建场景几何与人体运动后，注入 3D 显式生成先验实现度量一致对齐（Sec. 3.2）；(2) **前向优化**——在固定场景几何下，通过场景引导强化学习精炼人体运动以实现交互稳定性（Sec. 3.3）；(3) **反向优化**——在物理验证的运动下，利用仿真器反馈的重力稳定性和交互成功率精炼场景几何（Sec. 3.4）。默认以 $J=4$ 个未标定稀疏视角为输入，并可扩展至单目视频。

3. 方法论详细组件

3.1 预备知识：DUSt3R

DUSt3R 以 ViT 为骨干，对图像对 (I_n, I_m) 回归点图 $P^e_n, P^e_m \in \mathbb{R}^{H\times W\times 3}$ 及置信图 C^e_n, C^e_m，构建连通图 $\mathcal{G}(\nu,\mathcal{E})$ 后全局对齐恢复深度 $\mathbf{D}$ 和相机位姿 π：

$$\arg\min_{D,\pi,\sigma} \sum_{e\in\mathcal{E}} \sum_{n\in e} C^e_n \| D_n - \sigma_e \cdot F_e(\pi_n, P^e_n)\|^2_2$$

其中 σ_e 为边尺度因子，F_e 将点图投影到视角 n 下。但 DUSt3R 对人体主体常产生重建伪影（不真实结构、非水密拓扑），不适用于稳定仿真。

3.2 人–场景交互重建与对齐

独立重建。采用 DUSt3R 恢复场景 3D 结构；用 SAM2 检测跨帧个体生成精确遮罩和身份轨迹；4DHumans 和 ViTPose 分别提取初始 SMPL 运动序列和 2D 关键点 J_{2D}。通过以人为中心的光束法平差（bundle adjustment）和全局人–场景对齐（最小化 ViTPose 关键点与投影 SMPL 关节的重投影误差）统一坐标空间。

显式 3D 结构先验注入。初始对齐后仍存在两个关键问题：(1) 场景几何常含断裂组件、缺失表面、非水密拓扑等结构伪影；(2) 人–场景对齐仅依赖 2D 投影监督，缺乏 3D 几何感知且易受遮挡影响。为此，对场景中每个物体，自动选取其最突出的视角 I_n，用 SAM 提取分割遮罩，送入预训练 image-to-3D 生成模型（MIDI）合成高保真 3D 表征：

$$\mathcal{R}_{\text{scene}} := \{\texttt{MIDI}(I_n[M_i]),\ i\in[0,O]\}$$

其中 O 为物体总数。框架设计灵活，可无缝替换更先进的生成模型。

3D 显式约束对齐。穿透伪影在仿真中极为致命——微小的 3D 不一致可导致严重碰撞和仿真失败。对**非接触**情况，优化人体与物体位置：

$$\ell_{\text{non-contact}} = \frac{1}{|H_p|}\sum_{1\le j\le N_o} \|\mu^h_i - \mu^o_j\|_2 + \frac{1}{N_o}\sum_{j=1}^{N_o} \min_{i\in H_p} \|\mu^o_j - \mu^h_i\|_2$$

其中 H_p 为最近人体部位，μ^o_j、μ^h_i 分别为物体和人体顶点 3D 位置。对**接触**情况：

$$\ell_{\text{contact}} = \frac{1}{|H_p|}\sum_{i\in H_p} \max(0, -\delta(\mu^h_i))$$

$\delta(\cdot)$ 为符号距离函数，度量人体顶点相对物体表面的穿透深度。

3.3 前向优化：场景引导运动优化

直接将原始重建送入仿真器（如 IsaacGym）进行运动跟踪（PHC）往往失败——人形体会无意间踢开物体，最终物体独立于身体落地。这是因为传统重建不考虑重力和交互力。

为此，在基于 RL 的运动跟踪中引入**场景引导监督信号**，定义人体接触关键点 k^h_j 与最近物体表面点 μ^o_i 的平均距离损失：

$$\ell_{\text{scene}} = \frac{1}{N_{\text{contact}}\cdot N_{\text{surf}}} \sum_{j=1}^{N_{\text{contact}}} \sum_{i=1}^{N_{\text{surf}}} \|\mu^o_i - k^h_j\|^2_2$$

N_{contact} 为人–物接触数，N_{surf} 为局部接触区域采样点数。该损失鼓励人形体在仿真中维持物理合理的接触，而非仅跟踪运动轨迹。

3.4 反向优化：仿真器引导物体精炼（DSRO）

即使有场景引导 RL，稳定性比例仍不够理想（见 Tab. 1）。问题根源在于 3D 生成先验质量不一致：(1) 生成物体常含结构缺陷（如桌椅缺腿，在仿真中即使无交互也不稳定）；(2) 输入图像中人体严重遮挡导致物体出现表面畸变或凸起。

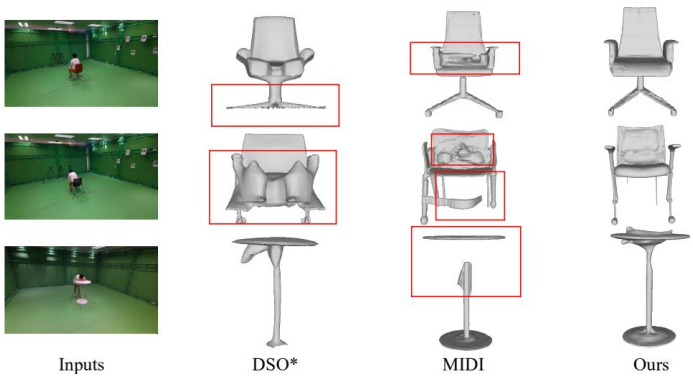

图 2：*image-to-3D* 物体重建对比。*MIDI* 和 *DSO* 常产生结构畸变，本方法 *DSRO* 微调后几何更准确、仿真更稳定。

受 DSO 启发，提出**直接仿真奖励优化（DSRO）**，以仿真结果作为监督信号精炼 3D 生成模型。DSRO 目标函数：

$$\ell_{\text{DSRO}} = -T\cdot\mathbb{E}_{I\sim\mathcal{T},x_0\sim\mathcal{X}_I,t\sim\mu(0,T),x_t\sim q(x_t|x_0)}\big[w(t)\cdot(1-2\cdot l(x_0))\|\epsilon-\epsilon_\theta($$

其中 $l(x_0)$ 编码仿真稳定性反馈，基于三条准则判定：(1) 物体在重力下保持直立稳定；(2) 重建场景达到稳定终态；(3) 交互涉及实际接触而非物体独立落地。$l(x_0) = 1$ 表示稳定，0 表示不稳定。该信号引导扩散模型生成更具物理合理性的 3D 物体。

仿真反馈分为四类：Type 1——物体在重力下不稳定；Type 2——交互时物体不稳定；Type 3——物体稳定但无有效交互；Type 4——交互稳定（目标状态）。

3.5 扩展至单目视频

得益于运动跟踪的动态特性，方法可扩展至单目视频输入，生成仿真级 4D 重建。采用 MegaSAM 和 TRAM 分别进行场景重建和人体运动估计，假设静态场景中人为唯一运动实体，用 SAM2 提取人和物体的 2D 边界框实现动态 3D 对齐。

4. HSIBench 基准数据集

构建专用基准 **HSIBench**：3 名志愿者（2 男 1 女）与 19 种物体（8 椅、3 桌、3 沙发等）交互，共记录 **300 个独特交互实例**，每个实例从 **16 个视角**同步捕捉。采用多视角 2DGS 重建和 SMPL 估计分别获取物体几何和人体运动的伪真值。每个案例在不同随机种子下运行完整管线 15 次，系统收集 DSRO 训练所需的仿真反馈信号。

5. 实验结果

实现细节。基于 HSfM 和 PHC 开发，使用 AdamW 优化器，LoRA（rank=64）微调 MIDI 模型，batch size=1，学习率 10^{-5}，共 1800 步，4 张 A100 GPU。

5.1 HSI 重建与仿真定量评估

方法	Easy	Med.	Hard	SP-3D	W/PA-MPJPE
HSfM	10.52	4.50	2.66	69.51	5.02 / 2.79
V1 (HSfM+MIDI)	13.96	8.81	4.17	77.12	6.18 / 3.20
V2 (无 Eq.5)	39.56	22.71	7.05	–	4.91 / 2.71
V3 (中心距离)	42.57	23.84	10.18	–	4.60 / 2.42
V4 (无 DSRO)	29.56	16.62	5.17	–	4.57 / 2.39
Ours	**53.68**	**30.56**	**13.92**	**22.9**	**4.09 / 2.17**

Stability-HSI 按交互复杂度分 Easy/Medium/Hard 三级评估。本方法在所有难度级别和所有指标上显著超越 HSfM 及各消融变体。SP-3D 穿透率从 69.51% 大幅降至 22.9%；W-MPJPE / PA-MPJPE 运动质量均为最优。

5.2 Image-to-3D 生成质量评估

方法	E	M	H	SG%	CD↓	F↑
MIDI	29.56	16.62	5.17	79.19	0.198	81.95
DSO*	38.75	25.91	7.88	87.23	0.191	86.26
Ours	**53.68**	**30.56**	**13.92**	**91.50**	**0.173**	**88.25**

DSRO 微调后，重力稳定性从 79.19% 提升至 91.50%，Chamfer Distance 从 0.198 降至 0.173，F-Score 从 81.95 提升至 88.25。在 HSI 稳定性和几何精度上均显著优于 MIDI 和 DSO。

5.3 视角数分析

增加视角数（4→10→16）可略微提升运动质量（W-MPJPE: 4.09→4.06→4.01），但对交互稳定性和穿透处理无显著影响——说明方法的物理闭环优化在少量视角下已有效。

5.4 消融实验分析

场景引导 RL 的作用。对比 V2（无 Eq. 5），去除距离最小化项后人形体运动夸张、频繁踢开物体。加入场景引导后 Easy 稳定性从 39.56% 提升至 53.68%。

表面距离 vs. 中心距离。V3 用中心点距离替代物体表面距离计算（参照 CLoSD），Hard 稳定性从 13.92% 降至 10.18%，说明表面级接触约束更精细有效。

DSRO 的作用。V4（无 DSRO）各难度级别稳定性均显著低于完整方法（Easy: 29.56% vs. 53.68%），证实仿真反馈精炼场景几何是关键组件。

3D 生成先验的作用。V1 直接将 HSfM+MIDI 结果送入仿真器，稳定性远低于完整方法，说明仅注入生成先验而不进行物理闭环优化远远不够。

6. 真实世界机器人部署

利用 GMR 将精炼后的人体运动重定向到 **Unitree G1 人形机器人**，作为先验输入基于扩散引导 RL（BeyondMimic）在 IsaacGym 中训练全身控制策略。训练完成后通过 Unitree SDK 直接部署到物理硬件。实验表明：精炼后的运动能成功迁移至真实机器人执行各种人–场景交互（坐椅子、靠桌子等），验证了方法的实用价值。该框架为利用 YouTube 等平台的大规模低成本数据增强具身 AI 训练提供了可扩展基础。

7. 与现有工作的对比

- **vs. HSfM**：HSfM 是唯一稀疏视角 HSI 重建方法，但仅在 2D 空间优化，对 Poisson 重建的点图进行仿真时人形体频繁踢开物体（Stability-HSI Easy 仅 10.52%）。HSImul3R 引入物理闭环将其提升至 53.68%；
- **vs. DSO**：DSO 以仿真反馈优化 3D 生成，但仅关注重力稳定性（单物体），不建模人–物交互。DSRO 同时优化重力稳定性和交互稳定性，且在 HSI 场景中 Chamfer Distance 更低（0.173 vs. 0.191）；
- **vs. PhyRecon 等物理感知重建**：PhyRecon 等聚焦静态场景的物理合理性，不处理动态人体交互；本方法首次实现人–场景交互的物理闭环优化。

8. 局限性与未来方向

- 成功率仍不高，尤其在涉及**复杂交互或多物体**（>3 个）场景中；多数失败案例中人形体和物体最终独立站立而无有效交互；
- 微调后的 image-to-3D 模型不可避免地继承 MIDI 原始训练集和 HSIBench 的偏差，**域外泛化能力**受限；
- 当前假设**静态场景**（仅人运动），尚未处理动态物体或多人交互；
- 仿真反馈的二值化稳定性标签（$l \in \{0, 1\}$）较为粗糙，更细粒度的奖励设计（如连续稳定性得分、接触力分布）可能进一步提升效果；
- 未来可将框架扩展至更多样的交互类型（如操作、搬运）、更大规模数据集，并探索与视觉语言模型结合实现开放世界具身智能。

Anatomy of a Lie：多阶段诊断框架追踪视觉语言模型幻觉

Xiong[1], Li[1*], Ye[2], Wang[1†] — [1]National University of Singapore, [2]Monash University, 2025

1. 问题动机与背景

视觉语言模型（VLM）频繁出现**幻觉**——生成看似合理但与事实不符的内容，严重阻碍其在高风险场景中的可信部署。作者发现了一种极具启发性的现象——**计算认知失调**（Computational Cognitive Dissonance）：模型被问“图中是否有摩托车？”时，先幻觉出“图中有一辆摩托车停在旁边”，却又矛盾地得出“最终答案是 No”。双重失败（感知不存在的物体 + 逻辑上否定自身感知）恰好产生正确答案，暴露了仅用准确率或自一致性等单一指标诊断幻觉的根本局限。

现有方法将生成过程视为不可分割的整体事件：多采样方法评估最终输出的语义一致性，内部状态探针则探测二元“真实性”表征。这些**还原论视角**混淆了本质不同的失败模式——无法区分幻觉源于感知漂移（初始阶段未能将概念锚定于图像）还是推理旁路（跳过已提取事实的逻辑跃迁）。本文核心论点：**幻觉是过程级失败，必须在结构化认知模型中进行诊断**。

2. 方法论：信息-几何诊断框架

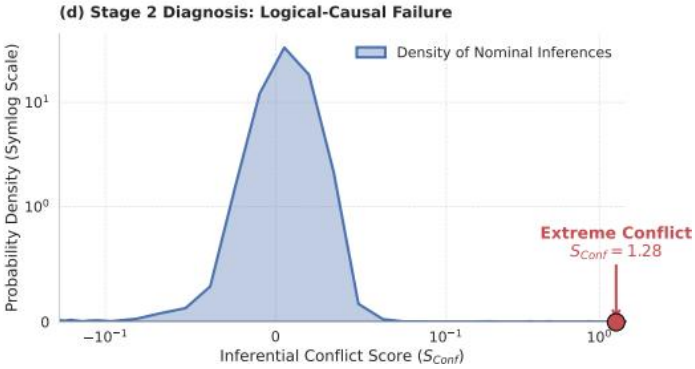

图 1：CAD 框架概览。将 VLM 生成建模为三阶段认知轨迹，投影至 3D 认知状态空间进行几何异常检测。

2.1 计算理性公理与概率图模型

引入**计算理性规范性原则**，将 VLM 的理想认知过程形式化为 Markov 信息流：

$$\mathcal{T} \xrightarrow{\text{感知}} \mathcal{T}_{\text{evi}} \xrightarrow{\text{推理}} \mathcal{A}$$

其中 $\mathcal{T}$ 为视觉输入，$\mathcal{T}_{\text{evi}}$ 为显式生成的证据链，$\mathcal{A}$ 为最终答案。该模型的核心公理：证据 $\mathcal{T}_{\text{evi}}$ 构成关于 $\mathcal{A}$ 相对于 $\mathcal{T}$ 的**充分统计量**，即条件互信息 $I(\mathcal{A};\mathcal{T}|\mathcal{T}_{\text{evi}}) = 0$。偏离此公理即表征逻辑失败。

Chain-of-Thought（CoT）并非操作约束，而是关键的**诊断探针**——类似医学造影剂，迫使模型外化隐含推理，使认知轨迹可观测且可数学诊断。

2.2 信息-几何认知观

将 VLM 生成的 token 轨迹 τ 视为概率事件 $P(\tau|\mathcal{I}, Q)$，其**自信息**（surprisal）为 $I(\tau) = -\log P(\tau|\mathcal{T}, Q)$。正常认知过程对应低 surprisal（高概率轨迹），幻觉定义为**高 surprisal 认知事件**——偏离正常行为的罕见低概率轨迹。

将高维内部状态投影至低维 3D **可观测信息流形**，每次生成由**认知状态向量** $v = [H_{\text{Evi}}, S_{\text{Conf}}, H_{\text{Ans}}]$ 表示。三个信息论探针分别量化信息流在不同阶段的属性：

2.3 探针 1：感知熵 H_{Evi}（感知不稳定性）

量化证据形成阶段（$\mathcal{T} \to \mathcal{T}_{\text{evi}}$）的不确定性。在每个 token 步 i，定义事实词集 V_f 和不确定词集 V_u（含“probably”, “likely”, “possibly”等 16 类词及其变体），将 softmax 分布投影到语义轴上的 Bernoulli 试验 $C_i \in \{\text{Factual}, \text{Uncertain}\}$：

$$p(C_i = \text{F}) = \frac{\sum_{t \in V_f} \text{softmax}(\mathbf{l}_i)_t}{\sum_{t \in V_f \cup V_u} \text{softmax}(\mathbf{l}_i)_t}$$

token 级熵为 $H_i = H(C_i)$，最终指标为路径平均熵：$H_{\text{Evi}} = \frac{1}{|\mathcal{T}_{\text{evi}}|} \sum_{i=1}^{|\mathcal{T}_{\text{evi}}|} H_i$。高 H_{Evi} 表示认知轨迹的起点不稳定。

2.4 探针 2：推理冲突 S_{Conf}（逻辑-因果失败）

直接量化违反核心公理的**非法因果路径**强度，通过条件逐点互信息（CPMI）计算视觉模态对答案 token 的信息增益：

$$S_{\text{Conf}} = \log p_v(\mathcal{A}_{\text{token}}|\mathcal{T}, \mathcal{T}_{\text{evi}}) - \log p_t(\mathcal{A}_{\text{token}}|\mathcal{O}_{\mathcal{T}}, \mathcal{T}_{\text{evi}})$$

其中 p_v 为含视觉上下文的概率，p_t 为**因果干预**后的反事实概率（将视觉输入消融为零张量，对生成序列进行非自回归重放）。大正值 S_{Conf} 意味着视觉信息未经证据中介直接流向答案，违反 d-separation。

2.5 探针 3：决策熵 H_{Ans}（决策模糊性）

量化终端状态的残余熵：$H_{\text{Ans}} = -\sum_{a \in \{\text{Yes,No}\}} p(a) \log_2 p(a)$。高熵表示系统未能收敛至稳定确定状态。

2.6 几何-信息对偶性与异常检测

本文的**核心发现——几何-信息对偶性**：认知轨迹在状态空间中的几何异常性本质上等价于其高信息论 surprisal。正常轨迹持续演化至稳定的低能量吸引盆，形成致密子流形；幻觉则是被扰离该流形的高能量偏差，表现为几何异常。该对偶性将幻觉的语义问题优雅地转化为**严格的几何异常检测任务**。

阶段 1：学习正常认知空间几何。在校准集 $\mathcal{D}_{\text{cal}}$ 上拟合高斯混合模型（GMM）建模正常状态密度 $p(v|\text{nominal})$。仅需弱监督（正确最终答案，无需 token 级标注）。应用**一致性过滤器**排除“幸运猜测”（答案正确但证据链自相矛盾的样本）。标准化各维度后，通过 BIC 选择最优 GMM 分量数（Llava: 5, Idefics2: 7, Qwen2-VL: 8, DeepSeek-VL2: 7）。

阶段 2：幻觉诊断。幻觉得分即认知状态向量的 surprisal：

$$S_{\text{hall}}(v) = -\log p(v|\mathcal{M}_{\text{GMM}})$$

正常过程为常见、可预测的低信息事件；幻觉为罕见的高信息偏差。整个检测仅需**单次生成 + 单次非自回归前向传播**。

3. 核心实验结果

3.1 POPE 基准（对抗子集）上的 SOTA 检测

方法	代价	Llava	Idefics2	Qwen2	DSK	Avg
Token Entropy	1x	.603	.806	.409	.732	.638
Neg Log Prob	1x	.604	.832	.428	.710	.644
Supervised Probe	1x	.787	.898	.762	.715	.791
Semantic Entropy	10x	.711	.751	.673	.702	.709
CAD（本文）	1x	**.910**	**.947**	**.776**	**.798**	**.858**

CAD 在所有模型上全面超越基线，平均 AUC 达 **0.858**，超出最强基线 Supervised Probe（需平衡幻觉标签训练）8.5%。在 log-log ROC 曲线上，CAD 在极低假阳性率（FPR $< 10^{-2}$）区间仍保持高真阳性率，其他方法在此关键区域显著退化。

3.2 MME 基准的跨任务泛化

MME 涵盖空间推理、OCR、常识逻辑等多样任务。CAD 宏平均 AUC：Llava **0.8514**、Idefics2 **0.8411**、Qwen2 0.7233、DeepSeek 0.7680，平均 **0.7960**，无需任何幻觉标签即超越 Supervised Probe（0.7509）和 Semantic Entropy（0.6677）。

3.3 MS-COCO 开放式描述验证

在无约束图像描述任务（$N = 1000$）上单独验证 H_{Evi} 探针。通过 CHAIR 指标验证，幻觉描述的 H_{Evi} 在所有四种架构上均显著高于事实描述（Welch t 检验 $p \ll 0.001$），证明感知探针能独立泛化至非 VQA 格式。

4. 机制诊断：认知指纹

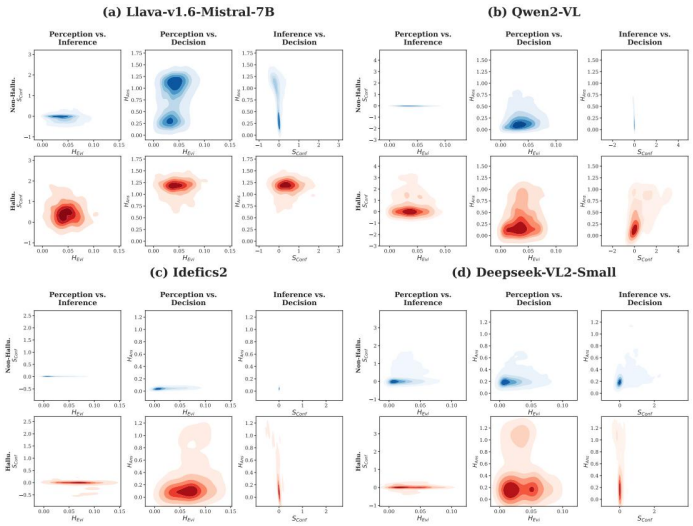

图 2：幻觉的“认知指纹”。不同架构展现截然不同的病理路径。蓝色 = 正常，红色 = 幻觉。

框架的诊断能力揭示了不同架构独特的**认知指纹**：

Idefics2 的“结构性失序”模式。正常过程形成极度紧凑、低方差的流形（刚性稳定工作流）。幻觉表现为远离此稳定态的异常偏差，密度异常检测器因此极为有效（AUC 0.947）。

Llava 的“透明挣扎”模式。幻觉流形与正常流形高度可分，幻觉以高推理冲突和高决策模糊性为特征。内部认知挣扎通过指标显式表现，失败模式高度透明。

Qwen2-VL 和 DeepSeek 的“纠缠态”模式。最具欺骗性——“自信的谎言”。幻觉流形形成自身致密的高置信集簇，与正常流形深度交织。这不是方法的失败，而是深刻的诊断发现：对某些架构，幻觉非过程异常，而是源自看似正常过程的内容错误，直接解释了其较低 AUC。

5. 消融实验与鲁棒性

整体诊断的必要性。以 Idefics2 为例，单探针 AUC 约 0.75–0.78，三探针协同跃升至 **0.947**，“协同增益”定量证明多维认知分析不可或缺。

自适应诊断器。GMM 自动学习对不同模型关注不同维度：对 Llava 高度敏感于推理冲突轴；对 DeepSeek 聚焦感知不稳定性；对 Idefics2 忽略 H_{Evi} 的噪声干扰——自适应适配各模型认知指纹。

校准集污染鲁棒性（0%–30%）。Idefics2 在 30% 污染下仍维持 AUC > 0.91——紧凑正常核将注入幻觉视为可忽略异常点。Llava 因幻觉高方差特征导致 GMM 方差膨胀而有明显下降（符合“透明挣扎”特征）。Qwen2-VL 和 DeepSeek 轨迹平坦——其性能受限于固有几何重叠而非校准噪声。

6. 实用优势与效率

- **弱监督**：仅需正确答案标签，无需昂贵的 token 级幻觉标注；
- **单次推断**：一次生成 + 一次非自回归重放（vs. Semantic Entropy 需 10 次采样）；
- **因果归因**：将可观测错误映射至感知失败（H_{Evi} 高）、逻辑失败（S_{Conf} 高）、决策模糊（H_{Ans} 高）三种病理状态，支持阶段性差异诊断；
- **架构边界**：VLM 架构须允许视觉输入消融的因果干预。

7. 与相关工作的对比

vs. 输出级评估（CHAIR/POPE/ROPE）：黑盒评估什么错误，本框架诊断如何及为何出错。**vs. 对比解码**（VCD/HIO）：聚焦纠正最终输出，本文聚焦机制性失败诊断，S_{Conf} 提供因果解释。**vs. 内部状态分析**（VADE/HaloScope）：前者聚焦注意力或将内部状态视为整体表征，本文将推理建模为可测量的认知轨迹，跨越多个宏观阶段，实现过程导向的差异诊断。**vs. Semantic Entropy**：需 10 倍推理代价且 AUC 低于本方法（0.709 vs. 0.858）。

8. 局限性与未来方向

- 当前数学形式化锚定于结构化 VQA 任务（需 Yes/No 决策边界计算 S_{Conf} 和 H_{Ans}），开放生成中仅 H_{Evi} 可直接泛化；
- “纠缠态”模式（Qwen2-VL、DeepSeek）中幻觉源自看似正常过程的内容错误，几何异常检测对此类“深层认知错误”效力有限；
- 依赖 CoT 提示外化推理，对不支持或不擅长 CoT 的模型适用性受限；
- **未来方向**：(1) 高 H_{Evi} 触发视觉重评估（缩放/重采样），高 S_{Conf} 激活逻辑自一致性验证的**阶段特异性缓解策略**；(2) 针对“自信谎言”的深层认知错误缓解；(3) 扩展至更广泛的开放生成场景。

Effective Distillation to Hybrid xLSTM Architectures

Hauzenberger*, Schmidinger*, Schmied, Hartl, Stap, Hoedt, Beck, Böck, Klambauer, Hochreiter — NXAI & JKU Linz, 2025

1. 动机与问题

当前基于 Transformer 的大语言模型（LLM）因 softmax attention 的二次复杂度（$O(T^2)$），在长上下文推理时面临巨大的能耗与部署成本。已有多项工作尝试将 Transformer 蒸馏为次二次（sub-quadratic）的线性化架构（如 LoLCATs、RADLADS、Llamba），但蒸馏后的模型在数学推理、代码生成等**难度较高的生成任务**上往往显著落后于教师模型。

本文提出以下核心问题：能否实现**无损蒸馏**——即学生模型在广泛的下游任务上匹配甚至超过教师模型？为此，作者：

- 形式化定义了基于**容忍度校正的 Win-and-Tie 率** C_α 的无损蒸馏标准；
- 提出了一套基于 **mLSTM–SWA 混合架构**的高效蒸馏流水线；
- 引入**专家合并（expert merging）**阶段，将独立训练的领域专家合并为单一模型；
- 在 Llama、Qwen、Olmo 三大模型家族上验证了该方法的有效性。

2. 背景知识

2.1 Softmax Attention 与 KV 缓存瓶颈

标准 attention 对输入 $\boldsymbol{x}_t$ 计算 query/key/value：$\boldsymbol{q}_t = \boldsymbol{x}_t W_q$，$\boldsymbol{k}_t = \boldsymbol{x}_t W_k$，$\boldsymbol{v}_t = \boldsymbol{x}_t W_v$，输出为 $\boldsymbol{h}_t = \mathrm{softmax}(\boldsymbol{q}_t \boldsymbol{K}_t^\top / \sqrt{d_{qk}})\boldsymbol{V}_t$。KV 缓存随序列长度线性增长，在深层多头设置下成为内存带宽瓶颈。

2.2 滑动窗口注意力（SWA）

SWA 将每个 query 的注意力范围限制在最近 W 个 token 内，缓存上限固定为 W，训练/prefill 复杂度从 $O(T^2)$ 降至 $O(TW)$，解码时计算和内存均与全局序列长度无关。

2.3 线性注意力

将 softmax 核替换为有限维特征映射 ϕ，使得 $\kappa_\phi(\boldsymbol{q}, \boldsymbol{k}) = \phi(\boldsymbol{q})^\top \phi(\boldsymbol{k})$。递推视图维护固定大小的 KV 状态 $\boldsymbol{S}_t = \boldsymbol{S}_{t-1} + \phi(\boldsymbol{k}_t) \otimes \boldsymbol{v}_t$，查询时 $h_t = \phi(\boldsymbol{q}_t)\boldsymbol{S}_t / \phi(\boldsymbol{q}_t)\boldsymbol{z}_t$，实现常数内存解码。

2.4 mLSTM

在线性注意力更新基础上引入三个数据依赖门控：输入门 $i_t = \exp(\boldsymbol{x}_t \boldsymbol{w}_i)$ 控制新 KV 写入强度，遗忘门 $f_t = \sigma(\boldsymbol{x}_t \boldsymbol{w}_f)$ 衰减累积状态，输出门 $\boldsymbol{o}_t = \sigma(\boldsymbol{x}_t W_{og})$ 调制读出：

$$\boldsymbol{S}_t = f_t \boldsymbol{S}_{t-1} + i_t \phi(\boldsymbol{k}_t) \otimes \boldsymbol{v}_t, \quad \hat{\boldsymbol{h}}_t = \boldsymbol{o}_t \odot \frac{\phi(\boldsymbol{q}_t)\boldsymbol{S}_t}{\phi(\boldsymbol{q}_t)\boldsymbol{z}_t}$$

3. xLSTM 蒸馏流水线

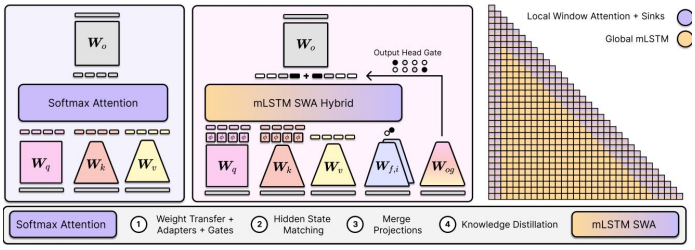

图 1：混合方法示意图。包含 *mLSTM*、滑动窗口注意力和 *sink token* 四步流程：*(1)* 权重迁移与引入适配器/门控；*(2)* 隐藏状态匹配；*(3)* *QK* 投影合并；*(4)* 知识蒸馏。

3.1 混合架构与学生初始化

以预训练 Transformer 为教师，学生保留嵌入层和 MLP 参数，将每个多头注意力块替换为 **mLSTM + SWA 混合模块**。两条分支并行处理输入，通过**数据依赖的标量门控**动态融合：

$$\hat{h}_t = o_t \cdot \frac{\phi(\boldsymbol{q}_t)\boldsymbol{S}_t}{\phi(\boldsymbol{q}_t)\boldsymbol{z}_t} + (1 - o_t) \cdot \mathrm{softmax}\left(\frac{\boldsymbol{q}_t \boldsymbol{K}_t^W}{\sqrt{d_{qk}}}\right) \boldsymbol{V}_t^W$$

其中 o_t 为 sigmoid 门控标量（每头一个），mLSTM 捕获**长程全局依赖**，SWA 建模**局部精确上下文**。

mLSTM 适配：(1) 不使用 LayerNorm（会损害学生-教师对齐），保留原始 normalizer 设计；(2) 使用每头标量输出门（而非每通道）以控制参数量；(3) 输出门输入改为 $[\boldsymbol{q}_t, \boldsymbol{k}_t, \boldsymbol{v}_t]$ 拼接（优于 $\boldsymbol{x}_t$）；(4) query/key 使用 softmax 特征映射。

Sink Token：SWA 额外关注每个序列的前 4 个 token（attention sink），弥补 SWA 无法访问序列起始位置的缺陷，结合 SWA 实现对完整 softmax attention 的良好初始近似。

3.2 阶段 I：逐层隐藏状态对齐

冻结嵌入和 MLP 权重，仅训练新引入的特征映射和门控参数。对每层 ℓ，最小化教师 attention 输出与学生混合输出之间的 MSE：

$$\min_{\boldsymbol{\theta}_\ell} \|\boldsymbol{h}_t^{(\ell)} - \hat{\boldsymbol{h}}_t^{(\ell)}\|_2^2$$

训练量约 655M token，序列长度 4K，学习率 10^{-2} 余弦衰减至 10^{-5}。

3.3 阶段 II：稀疏知识蒸馏

解冻所有参数，端到端微调。目标函数混合 next-token CE 损失与教师分布的 top-k 稀疏 KL 散度：

$$\min_\theta \left\{ -\sum_{t=1}^{T} \gamma \log p_\theta(y_t|\boldsymbol{x}_{1:t}) + \beta\, \mathrm{KL}\left[p_T^{(k)}(\cdot|\boldsymbol{x}_{1:t}) \| p_\theta^{(k)}(\cdot|\boldsymbol{x}_{1:t})\right] \right\}$$

其中 $\gamma = 0.9$, $\beta = 0.1$, $k = 256$。稀疏 KL 的关键优势：教师 logits 可**一次性预计算并存储**，阶段 II 无需在线访问教师模型，对长上下文蒸馏尤为重要。

3.4 阶段 III（可选）：专家合并

独立训练 K 个领域专家（数学、代码、STEM、对话），各从相同初始化权重 $\boldsymbol{\theta}^{(0)}$ 出发。训练完成后通过**线性权重合并**统一为单一模型：

$$\theta_{\text{merge}} = \sum_{i=1}^{K} \lambda_i \theta^{(i)}, \quad \lambda_i \geq 0, \ \sum_{i=1}^{K} \lambda_i = 1$$

默认均匀权重，可通过验证集调优 λ_i。该方案支持**模块化能力修补**：独立改进某领域专家后重新合并即可更新最终模型，无需端到端重训。

4. 评估指标

教师恢复率（teacher-recovery rate）：学生/教师得分之比，> 1 表示超越。

Win-and-Tie 率 C_α：在容忍度 α 下，学生匹配或超越教师的基准占比。对基准 b，若 $A_S(b) \geq (1-\alpha)A_T(b)$ 则视为 win/tie。$C_\alpha = \frac{1}{|B|}\sum_{b \in B} \mathbf{1}_\alpha(b)$。

临界容忍度 $\alpha^* = \inf\{\alpha \mid C_\alpha \geq 0.5\}$：使学生在至少一半基准上匹配教师所需的最小容忍度。α^* 越小，蒸馏质量越高。

5. 实验结果

5.1 基础模型评估

蒸馏 Llama3.1-8B 和 Olmo3-7B。阶段 I 使用 655M token（4K 上下文），阶段 II 分别使用 5B（Llama）和 20B（Olmo）token。

语言理解（MMLU 等 6 个 MC 任务）：xLSTM-Llama3.1-8B 实现**完全教师平价**，xLSTM-Olmo3-7B 接近平价；对比 LoLCATs 和 QRWKV6-7B 均有显著差距。

语言生成（数学、代码等）：先前方法差距巨大（LoLCATs 和 QRWKV6-7B 的 $\alpha^* = 1.0$）。本文方法：xLSTM-Llama3.1-8B 达到 $\alpha^* = 0.0$（**完全无损蒸馏**），xLSTM-Olmo3-7B 达到 $\alpha^* = 0.01$。

5.2 指令微调模型评估

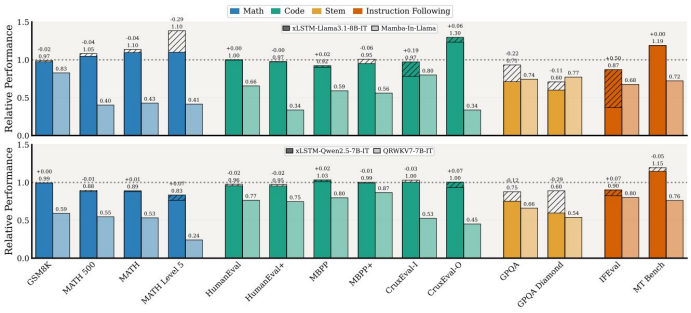

图 2：指令微调模型的教师恢复率。上：*xLSTM-Llama3.1-8B-IT vs Mamba-in-Llama*；下：*xLSTM-Qwen2.5-7B-IT vs QRWKV7-7B-IT*。条纹区域表示合并带来的增益或损失。

蒸馏 Llama3.1-8B-IT 和 Qwen2.5-7B-IT，采用**去中心化方案**：4 个专家（数学、STEM、代码、对话）各训练 ~5B token，使用 Nemotron Nano-2/3 和 Olmo-3 数据混合。

关键结果：(1) 语言理解和代码生成基本匹配教师；(2) 数学推理恢复大部分性能；(3) MT-bench（GPT-5.1 评判）上学生**偏好分数高于教师**；(4) xLSTM-Llama3.1-8B-IT 达 $\alpha^* = 0.02$，xLSTM-Qwen2.5-7B-IT 达 $\alpha^* = 0.05$，在所有容忍度上 Pareto 支配现有线性化方法。

合并效果：正向迁移显著——Llama 的 IFEval 指标大幅改善。但 STEM 推理（GPQA）出现领域干扰退化，数学和代码能力则对合并鲁棒。

5.3 推理效率

在 H100 80GB 上对比教师（Transformer）与学生（xLSTM 混合）：

- **Prefill**：$B=1$, $C=65$K 时吞吐量 $\sim 2\times$，TTFT 降低 $\sim 2\times$；
- **生成延迟**：$G=131$K 时延迟和 GPU 内存均**减半**，且内存保持恒定；
- **生成吞吐**：$B=8$ 时随上下文增长达 $\sim 4\times$ 加速；教师在更大 batch 时 OOM。

6. 消融实验

基于 Llama3.1-8B，2.5B token 预算：

架构组件：纯线性注意力 < mLSTM $\ll$ mLSTM + SWA < mLSTM + SWA + Sink。mLSTM 的门控机制显著优于线性注意力；mLSTM 与 SWA 的组合产生**协同效应**；sink token 进一步稳定性能。数据依赖输出门分析显示两条分支均对最终输出有显著贡献。

蒸馏目标：$\gamma=0.9$, $\beta=0.1$ 的混合损失最优。纯 KL 蒸馏因过度约束线性学生而性能下降，即使在教师原始训练数据上蒸馏也是如此。

PEFT vs. FFT：全参数微调（FFT）显著优于 LoRA（PEFT），因此默认采用 FFT。这与 LoLCATs 等使用 LoRA 的做法不同。

7. 与现有方法的对比

方法	架构	α^*（生成）
LoLCATs	线性注意力 +SWA	1.0
QRWKV6-7B	RWKV-6	1.0
Mamba-in-Llama	Mamba-2（50% 层）	较高
xLSTM（本文）	**mLSTM+SWA+Sink**	**0.0–0.05**

本文方法的优势：(1) 层内混合设计，每个头同时建模局部和全局依赖；(2) 全参数微调而非 LoRA；(3) 稀疏 KL 支持教师 logits 预计算，训练成本可控；(4) 专家合并实现模块化能力拼装。

8. 局限性与未来方向

- 在**合成长上下文**评估（如 Needle-in-a-Haystack）上仍有差距；
- STEM 推理中专家合并存在**领域干扰**，导致 GPQA 等退化；
- 尚未扩展至更大教师模型（如稀疏 MoE 模型）；
- 未探索**在策略蒸馏**（on-policy distillation）或 RL 专家精炼后再合并；
- 混合架构在生产服务系统（vLLM/SGLang）中的集成需要异构调度和内存管理支持，这是重要的系统研究方向。

ViFeEdit：无需视频数据的视频扩散 Transformer 编辑微调框架

Yu[1], Tan[1], Chen[1], Liu[2⋆], Wang[1⋆] — [1]NUS, [2] 上海交通大学, 2025

1. 动机与问题定义

扩散 Transformer（DiT）在图像与视频生成领域取得了卓越成果，但将其扩展至**视频编辑与可控生成**面临三大瓶颈：

- **配对视频数据稀缺**：构建高质量配对视频数据集成本极高（如 Ditto-1M 消耗超 10,000 GPU 天），且需逐帧对齐标注；
- **训练代价巨大**：视频数据的多帧依赖特性使训练仅在拥有大规模 GPU 集群的工业实验室中可行；
- **时空解耦困难**：现代视频 DiT（如 Wan 系列）采用 3D 全注意力机制，空间与时间建模高度耦合，难以分离。研究 [52] 进一步揭示注意力头在不同 prompt 和去噪步骤中动态分配空间/时间角色，加剧了解耦难度。

核心问题：**能否仅使用 2D 图像数据（完全不用视频）微调文本到视频 DiT，使其具备多样的视频编辑能力？** 本文给出肯定回答，提出 ViFeEdit——一个**无视频微调框架**，仅需 100–250 对图像数据和极低训练成本，即可让文本到视频 DiT 胜任风格迁移、刚性/非刚性替换、颜色修改、目标添加与移除等六类精细视频编辑任务。

2. 相关工作分类

现有扩散视频编辑方法分为三类：（1）**时序适配方法** [11,18,33,42,51]：在图像骨干中注入时序模块，计算量大且需逐视频微调；（2）**注意力/隐变量调制方法** [12,23,28,31,38,41,48,57]：无需训练但编辑能力局限于外观级别，无法处理结构性变换；（3）**端到端方法** [1,9,20,22,59,60,67]：在大规模配对视频上端到端训练，效果最强但数据与算力要求极高。ViFeEdit 开辟了**第四条路径**——仅用 2D 图像适配视频 DiT，兼顾效率与编辑能力。

3. 方法详解

3.1 预备知识：DiT 视频生成器

文本到视频 DiT 接收噪声视频隐变量 $Z \in \mathbb{R}^{B\times N\times d}$（$N = f\times h\times w$）与文本 token $C_T \in \mathbb{R}^{B\times M\times c}$，通过 3D 全注意力联合建模空间与时间依赖：

$$\mathrm{Attn}_{3D}(X) = \mathrm{Softmax}\left(\frac{XW^Q(XW^K)^\top}{\sqrt{d'}}\right)XW^V\cdot W^O$$

训练采用 Flow Matching 机制：$Z_t = t\epsilon + (1-t)Z_0$，$v_t = \epsilon - Z_0$，优化目标为：

$$\mathcal{L} = \mathbb{E}_{\epsilon,(Z_0,C_T),t}\left[\|u_\theta(Z_t, C_T, t) - v_t\|^2\right]$$

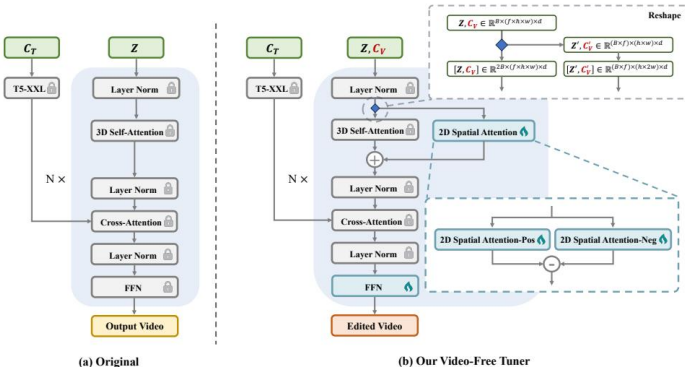

图 1：*ViFeEdit* 架构。*(a)* 原始 *Wan2.1 DiT* 块；*(b) ViFeEdit* 引入正负 *2D* 空间注意力分支与双路管线，源视频 C_V 仅在 *2D* 空间注意力中与噪声隐变量交互。

3.2 时空解耦：架构重参数化

直接用 2D 图像微调 3D 全注意力会破坏时间动态，导致推理时帧冻结。由于 3D 注意力中空间/时间角色动态分配 [52]，显式拆分不可行。ViFeEdit 提出**架构重参数化**：保持原始 3D 注意力**完全冻结**，额外引入一对互补的 2D 空间注意力模块 Attn_{SpaPos} 和 Attn_{SpaNeg}，最终输出为：

$$\mathrm{Attn}_{3D}(X) + \mathrm{Attn}_{SpaPos}(X') - \mathrm{Attn}_{SpaNeg}(X')$$

其中 X' 是将所有帧的时间位置编码设为相同索引后的隐状态，使 2D 注意力仅在空间域内计算。

关键设计特性：

- **正负对称初始化**：两个 2D 模块均用对应 3D 注意力参数初始化，初始时正负相消输出为零，保持模型原始行为，提供稳定的训练起点；
- **符号感知语义编辑**：正负分支显式解耦增强与抑制信号，实现细粒度空间编辑控制；
- **时间一致性保证**：3D 注意力完全冻结，预训练的时间建模能力完整保留——即使仅用 2D 图像训练，推理时仍能生成时间稳定的视频。

微调时仅更新正负 2D 空间注意力模块及 FFN 层，其余参数冻结。采用 LoRA（秩 32）进一步降低参数量。

3.3 双路管线

为将源视频条件注入骨干特征，ViFeEdit 复用 DiT 骨干编码条件信息（而非引入独立编码器），但采用**双路分离处理**：

3D 注意力路径：噪声隐变量 Z 与视频条件 C_V 沿 batch 维度拼接为 $[Z, C_V] \in \mathbb{R}^{2B\times N\times d}$，各自分配独立 3D 位置编码，作为独立样本处理——确保 3D 注意力不被条件信号干扰。

2D 空间注意力路径：Z 和 C_V 展平为 $\mathbb{R}^{(B\times f)\times(h\times w)\times d}$ 后沿空间维度（如 w）拼接，位置索引扩展至 $[0, 2w)$，时间位置索引统一设为 0。此设计使模型仅从 2D 配对图像学习编辑映射，同时逐帧强化生成视频 Z 与源视频 C_V 的一致性。

噪声先验初始化（可选）：受 SDEdit 启发，推理时用源视频初始化噪声隐变量：

$$Z_\alpha = (1-\alpha)C_V + \alpha\epsilon, \quad \alpha \in [0, 1]$$

Flow Matching 从 $t = \alpha$ 开始，α 控制先验强度。

分离时间步嵌入：Z 与 C_V 噪声水平不同（Z 为噪声隐变量，C_V 为干净视频），共享时间步嵌入会模糊条件引导。因此为 Z 分配当前 flow-matching 时间步 t，为 C_V 固定分配 $t = 0$（表示干净输入），沿 batch 维度拼接。此设计显著加速收敛并稳定优化。

4. 实验设置

基础模型：Wan2.1-T2V-1.3B。**训练数据**：风格迁移使用 OmniConsistency（100–200 对/风格）；其余编辑任务由 GPT-5 生成 prompt + FLUX.1-dev 生成源图 + Qwen-Image-Edit 生成目标图，各 250 对。每张图像作为单帧视频。训练使用 3 张 RTX 6000 Ada GPU，峰值显存约 18 GiB，风格迁移每 epoch 5 分钟、编辑任务每 epoch 9 分钟，20 epoch 以内完成。

评估：风格迁移采用 VBench（主体一致性、背景一致性、时间闪烁、运动平滑度、颜色）+ Qwen2.5-VL-7B 的 VLM 评分（结构一致性、运动一致性、风格保真度）；其余任务采用 FiVE-Bench 的 FiVE-Acc 指标（YN-Acc、MC-Acc、U-Acc、∩-Acc），在全视频帧上评估。所有视频 81 帧、480p。

基线：OmniConsistency（逐帧图像风格迁移）、VACE（端到端视频编辑，大规模视频预训练）、SDEdit、VidToMe、Pyramid-Edit、Wan-Edit。VACE 使用相同图像数据 LoRA 微调以公平比较。

5. 核心实验结果

5.1 一致风格迁移

在 3D Chibi、Ghibli、American Cartoon 三种风格上评测：

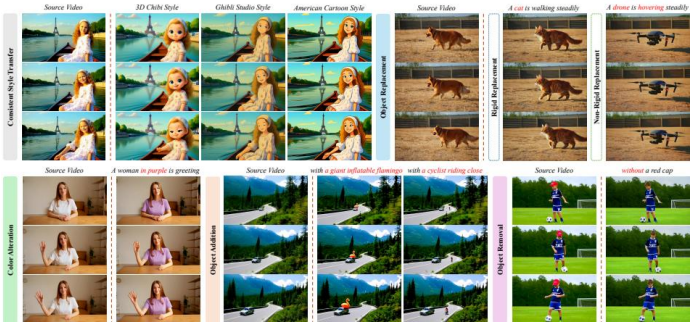

图 2: *ViFeEdit* 在六类视频编辑任务上的可视化结果，仅用 *2D* 图像数据训练。

方法 / 3D Chibi	主体一致	时间闪烁	风格 VLM
OmniConsistency	0.9711	0.9948	93.06
VACE*	0.9751	0.9945	91.13
Ours	**0.9811**	**0.9980**	**93.06**

OmniConsistency 基于 FLUX-dev 逐帧处理，缺乏时间建模导致时序一致性差、模糊帧出现突变；VACE 保持时间一致性但颜色漂移严重（Color 指标显著低于 Ours）。ViFeEdit 在所有指标上取得最优或可比结果。

与 Ditto-14B 对比（表 5）：Ditto 基于 Wan2.1-VACE-14B（14B 参数）+ 1M 视频对训练。ViFeEdit（1.3B + 100–200 图像对）在主体一致性、时间闪烁、颜色保持上**全面超越** Ditto-14B（如 American Cartoon：颜色 0.8720 vs 0.6755）。

5.2 视频编辑（FiVE-Bench）

方法	替换	颜色	添加	移除
SDEdit	26.75	17.50	5.56	0.00
VidToMe	43.75	49.00	11.11	5.00
Pyramid-Edit	57.75	50.50	77.78	0.00
Wan-Edit	46.00	39.00	50.00	0.00
VACE*	27.25	84.50	22.22	0.00
Ours	**77.75**	**91.50**	**100.0**	**80.00**

ViFeEdit 在所有任务上**大幅领先**：目标替换 FiVE-Acc 77.75（次优 57.75）；颜色修改 91.50（次优 84.50）；目标添加 100.0（次优 77.78）；目标移除 80.0（所有基线均为 0.0–5.0）。定性分析：SDEdit/Wan-Edit 仅做轻微局部编辑；VidToMe 缺乏局部控制导致背景连带改变；VACE* 背景颜色不一致；Pyramid-Edit 质量退化。

5.3 深度到视频生成

扩展至可控视频生成任务：使用 Depth-Anything-V2 提取深度图作为条件，250 对图像训练 20 epochs。结果显示 ViFeEdit 精确遵循深度条件，视觉保真度可比大规模视频数据预训练的 VACE 模型。

6. 消融实验

各组件逐步累加（以 3D Chibi 风格迁移为例）：（1）直接微调 + 条件拼接——模型难以学习干净表征；（2）加入**分离时间步嵌入**——确保干净参考视频，训练时间减半以上；（3）加入**时空解耦**——隔离图像数据学习过程，恢复时间一致性；（4）加入**双路管线**——进一步增强空间一致性。完整方法实现一致运动、背景保持与高质量风格迁移。

与替代策略对比：（1）**直接微调**（Direct Tuning）：微调 3D 注意力的 q, k, v, o 层破坏时间生成能力导致帧冻结；（2）**ControlNet 式零卷积**（Zero-Conv）：虽可实现类似初始化效果，但需从头训练额外模块，在纯图像监督下收敛困难，源视频对齐性差。ViFeEdit 的正负 2D 空间注意力复用预训练 3D 注意力的丰富空间先验，保持高一致性。

多任务 LoRA：将颜色修改、目标添加、目标移除三任务联合微调为单一 LoRA，无需为每个任务单独训练，验证了框架的可扩展性。多风格联合微调（Pixel Art + Oil Painting + Van Gogh，317 对）同样有效，且能准确区分 Van Gogh 与传统油画等相近风格。

7. 讨论与局限

核心贡献：（1）首个仅用 2D 图像数据适配文本到视频 DiT 至多样视频编辑任务的框架；（2）架构重参数化实现时空解耦，正负对称初始化复用 3D 预训练先验；（3）双路管线 + 分离时间步嵌入提升条件注入稳定性与收敛速度；（4）以 1.3B 模型 + 100–250 图像对的极低成本超越 14B 模型 + 百万视频对训练的端到端方法。

主要局限：

- 仍依赖配对图像数据（虽然量极少），纯零样本场景尚未覆盖；
- 基于 LoRA 微调，编辑能力上限受限于基座模型的生成质量；
- 目标移除与添加的评估样本较少（9–10 个），统计显著性有待更大规模验证；
- 对极端运动模糊和大面积遮挡场景的鲁棒性仍有提升空间；
- 当前仅在 Wan2.1-1.3B 上验证，扩展至更大模型（14B+）和更多架构的泛化性待探索。

EnterpriseOps-Gym：面向企业场景的有状态智能体规划与工具使用基准

Malay*, Nayak*, Nair, Davasam, Tiwari, Tejaswi, Nemala, Sunkara, Rajeswar — ServiceNow, 2025

1. 动机与问题定义

大语言模型（LLM）正从被动信息提供者转向主动执行复杂工作流的**自主智能体**。然而，将其部署为企业中可靠的 AI 工作者面临三大核心挑战：

- **长期规划与状态维护**：企业任务涉及数十步工具调用的长序列，智能体需在持续变化的状态中保持一致性；
- **跨系统协调**：操作跨越客户服务（CSM）、HR、IT 服务管理（ITSM）及协作工具（Email、Calendar、Teams、Drive），需维护跨域数据完整性；
- **严格策略合规**：企业环境中访问控制、SLA、流程规则等约束无处不在，违反策略的操作可能导致级联系统故障和安全风险。

现有基准存在根本性不足：通用工具调用基准（API-Bank、ToolLLM、ACEBench）将工具调用视为原子无状态操作；企业专用基准（WorkArena、CRMArena、EnterpriseBench）通常局限于单一供应商生态（如仅 ServiceNow 或 Salesforce），数据库表少于 25 张、工具不超 50 个、任务步长短、策略约束有限。EnterpriseOps-Gym 旨在填补这一关键空白。

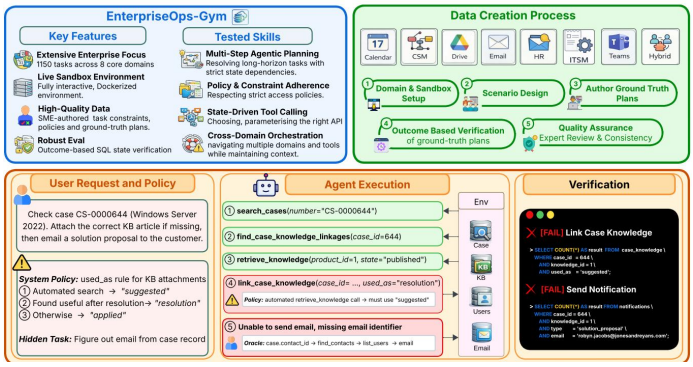

图 1：*EnterpriseOps-Gym* 概览。涵盖 *8* 个企业领域，专家设计任务并执行标准轨迹，智能体在沙箱中交互执行，由终态验证器评估目标完成、策略合规与副作用。

2. 基准设计与构建

2.1 领域选择

基于行业相关性、策略复杂度多样性和领域专家可用性，选定 **8 个互联领域**分两组：

运营骨干（策略密集型）：**CSM**——支持工单全生命周期与 SLA 管理；**HR**——涉及敏感员工数据和严格隐私规则；**ITSM**——覆盖事件管理和系统配置的后端 IT 运维。

协作工具（编排密集型）：**Email**——复杂邮箱工作流；**Calendar**——时间与资源访问策略；**Teams**——协作空间管理；**Drive**——文件系统完整性与安全。

Hybrid（跨域）要求智能体在碎片化工具间进行跨域编排，维护上下文和数据完整性。

2.2 沙箱环境

与专业数据标注公司 Turing 合作，组建 160+ 贡献者团队（软件工程师 + 领域专家 SME），构建**容器化 Docker 沙箱**。环境规模远超先前基准：

维度	EnterpriseOps-Gym
数据库表数量	**164**（先前最高 25）
功能工具数量	**512**（先前最高 73）
平均外键/表	**1.7**（先前最高 1.3）
任务数量	**1,150**（含 30 个不可行任务）
专家轨迹平均步数	**9.15**（最长达 34 步）
平均验证条件数	**5.3**（最复杂达 44 个）
每任务平均涉及表数	24.9（Hybrid 达 73）
每任务平均数据行数	3,443（CSM 超 10,000）

每个任务运行时初始化独立数据库实例，防止状态泄露。高外键密度意味着智能体需解析更多表间依赖以构建合法工具参数，引用完整性成为关键挑战。

2.3 任务构建流水线

四阶段严格流程：**(1) 场景设计**——标注者根据复杂度阈值（工具调用数、验证条件数、状态依赖、访问约束、策略冲突）设计多步场景，包括 30 个**不可行任务**（工具不足/策略违反/资源不可用），约束任务具有唯一终态；**(2) 标准轨迹执行与计划撰写**——标注者提供逐步计划并在沙箱中手动执行，记录每步调用的参数、响应和执行理由，同时撰写引用系统策略的自然语言推理计划；**(3) 基于结果的验证**——编写可执行 SQL 验证脚本检查终态，涵盖目标达成、完整性约束（外键关系）、权限合规、副作用检测；**(4) 多轮质量保证**——审核者评估任务可行性、指令清晰度、验证脚本正确性和覆盖度。初步过滤阶段使用 GPT-5、Gemini、Claude 自动压力测试，淘汰过于简单或定义有误的任务。

3. 实验设置

3.1 基线模型

评估 **14 个前沿模型**：闭源包括 Claude 4.5（Opus/Sonnet）、GPT（5.2 High/Low、5、5-Mini）、Gemini（3-Pro/Flash、2.5-Pro）；开源包括 Kimi-K2-Thinking、DeepSeek-V3.2、GPT-OSS-120B、Qwen3（235B/30B/4B）。统一使用 ReAct 推理-执行循环，默认 **oracle 工具**设置（完美检索器提供正确工具集），聚焦评估规划与执行能力。

3.2 评估指标

主指标为 **pass@1 任务完成率**（3 次运行平均），仅当所有验证条件全部通过时得分为 1。相比验证器级别成功率（可能因通过初始化等琐碎步骤而虚高），pass@1 更准确反映端到端实用性。

4. 核心实验结果

4.1 跨领域性能

模型	平均 pass@1
Claude Opus 4.5（最佳）	37.4%
Gemini-3-Flash	31.9%
GPT-5.2 (High)	31.8%
Claude Sonnet 4.5	30.9%
GPT-5	29.8%
DeepSeek-V3.2 (High)（最佳开源）	24.5%
GPT-OSS-120B (High)	23.7%
Qwen3-30B (Think)	16.8%

领域差异显著：协作工具相对较好（Email/Teams/Drive 最佳达 51–52%），策略密集型领域大幅下降——ITSM 最佳仅 28.5%，跨域 Hybrid 最佳 30.7%。开源模型在 CSM/ITSM/HR 上尤其吃力。Qwen3-30B 在 Email 上达 51.9%（并列最佳），表现出色。

性价比：Gemini-3-Flash 以 0.03 USD/任务达 31.9%，比 GPT-5（0.16 USD, 29.8%）和 Claude Sonnet（0.26 USD, 30.9%）便宜 80–90%。开源中 DeepSeek-V3.2（0.014 USD, 24.5%）性价比最优。

4.2 不可行任务拒绝能力

30 个不可行任务评估智能体安全拒绝行为（每任务平均 10 个验证检查确保无副作用，平均 3–4 个复合约束）。最佳模型 GPT-5.2 (Low) 和 DeepSeek-V3.2 仅达 **53.9%/53.8%**，远低于生产安全要求。多数模型盲目尝试执行，导致系统状态污染。

4.3 性能随任务步长衰减

按专家轨迹步数分层，所有模型 pass@1 随步长单调下降。闭源组从 4 步时 ∼35% 降至 16 步时 < 20%；开源组衰减更陡峭，趋向 ∼10%。错误在长序列中快速累积是自主可靠性的关键障碍。

4.4 思考预算影响

GPT-OSS-120B 在低/中/高思考预算下评估：低预算时 CSM/ITSM/HR 近乎零分（1.1%/1.1%/0.0%）；高预算解锁显著提升——Drive 8.6 → 41.0%，Calendar 8.7 → 35.6%，Teams 4.0 → 32.0%。但**非单调**：Email 在中预算峰值 45.2% 后回落，ITSM 提前饱和（1.1 → 6.1 → 6.1%），表明某些工作流存在思考预算无法突破的能力天花板。

5. 关键分析：规划是核心瓶颈

5.1 干扰工具实验

Claude Sonnet 4.5 在 oracle 工具集基础上增加 +5/+10/+15 个高相关干扰工具，性能**基本不变**（平均仅 ~1% 波动）。唯一变化是输出 token 增加 4–9%（模型用额外预算筛选工具）。**结论**：工具发现不是瓶颈，任务规划和策略遵守才是。

5.2 计划条件化执行

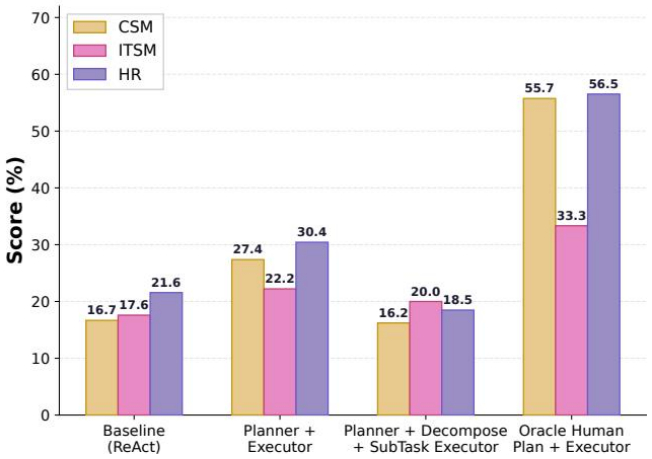

图 2：多智能体架构对比。人类计划条件化执行大幅领先所有自动化方案。

自动规划：Claude Sonnet 4.5 作为规划器生成高层计划，弱模型（Kimi-K2/Qwen3-30B/Qwen3-4B）作为执行器。在最难三域（CSM/ITSM/HR）上，**Claude 计划**带来 6–13% 提升。

人类计划：提供专家撰写的参考计划后，提升**巨大**——14–35 个百分点，约为自动规划增益的 2–3 倍。代表性结果：Qwen3-4B + 人类计划在 CSM 达 37.2%（↑33.4%）、HR 达 36.4%（↑29.3%），**可媲美甚至超越更大模型**。这表明一旦外化战略推理，剩余挑战主要是忠实指令跟随和精确工具调用——现代 LLM 普遍具备的能力。小模型反而因更严格遵循指令而受益。

5.3 多智能体架构

Claude Sonnet 4.5 测试三种架构：(1) ReAct 基线；(2) Planner+Executor（自动计划 + ReAct）；(3) Planner+Decompose+Subtask Executor（任务分解 + 子智能体）。Planner+Executor 在 CSM 提升 10.7%、HR 提升 8.8%。但**分解架构反而退化**——CSM 下降至 16.2%（低于基线 16.7%），因 EnterpriseOps-Gym 任务具有**强顺序状态依赖**，分解打断了这些依赖。所有自动化方案与人类计划差距巨大，表明进步需要**约束感知的计划生成能力**而非架构复杂度。

6. 失败模式分析

定性分析和 LLM 辅助验证器分类揭示四类典型失败：

- **缺失前置查询**：创建数据库对象前未查询前置条件，产生外键断裂的悬挂记录（如创建 HR 主题前未检索可用类别）；
- **级联状态传播失败**：状态转换触发的后续动作未被执行（如策略要求的通知或更新）；
- **错误 ID 解析**：向工具传递未验证的标识符而非通过先前工具交互解析正确 ID；
- **过早完成幻觉**：未执行所有必需步骤即声明任务完成。

将验证器分为三类后量化分析：**权限与流程合规**通过率最低——这对实际部署尤为关键，策略违反可导致级联系统故障和安全漏洞。

7. 与现有基准的对比

基准	表数	工具	拒绝	人类计划
API-Bank	0	73	×	×
WorkArena	7	30	×	×
CRMArena	16	27	×	×
EnterpriseBench	17	46	×	×
Ours	**164**	**512**	✓	✓

EnterpriseOps-Gym 在环境规模（数据库表、工具数、关系密度）上超出先前基准一个数量级，且是首个同时提供不可行任务评估和人类专家计划的企业基准。

8. 讨论与局限

核心发现：(1) 当前最佳模型仅 37.4% 成功率，远未达企业部署标准；(2) 规划是主要瓶颈而非工具使用——人类计划带来 14–35% 提升远超任何自动化方案；(3) 不可行任务拒绝能力严重不足（最佳 53.9%），构成生产安全风险；(4) 思考预算有领域特定天花板。

未来方向：(1) **约束感知计划生成**——在提交动作序列前显式推理策略约束、副作用依赖和前置结构；(2) **长期状态管理**——引入情景记忆或结构化状态表示以防止长序列错误累积；(3) **安全拒绝与升级**——可靠检测不可行/违规请求并干净退出。

局限：oracle 工具设置为最优检索假设，实际部署需额外解决工具发现问题；评估依赖 SQL 验证脚本的覆盖度；沙箱虽模拟真实约束但仍与生产系统存在差距；当前聚焦 8 个领域，未覆盖所有企业场景（如财务、法务）。基准设计为模块化可扩展，支持社区添加新领域、工具和工作流。