QZPaper Huggingface Daily

2026-03-19

---

1. **Video-CoE：通过事件链强化视频事件预测**
   本文针对多模态大语言模型在视频事件预测中缺乏逻辑推理和视觉利用不足的问题，提出 Chain of Events（CoE）范式，通过构建时序事件链强制模型关注视觉内容并建立视频到未来事件的逻辑关联，结合监督微调与强化学习显著提升预测性能。
2. **MetaClaw：在真实部署中持续元学习与进化的 LLM 智能体**
   本文解决 LLM 智能体部署后的持续适应问题，提出 MetaClaw 元学习框架，采用元模型（基座参数 + 技能库）表示智能体，通过经验蒸馏快速进化技能库与机会主义 RL 优化权重相结合，实现零中断服务下的混合时间尺度适应。
3. **MosaicMem：面向可控视频世界模型的混合空间记忆**
   本文针对视频世界模型的空间记忆瓶颈，提出 MosaicMem 以 patch 为单元的混合记忆方案，结合显式几何一致性与隐式注意力机制的优势，通过 Flow Matching 学习实现精确相机运动控制和动态场景生成。
4. **对齐使语言模型具有规范性而非描述性**
   本文通过对比 base 模型与对齐模型在多类策略博弈中对真实人类决策的预测能力，揭示对齐过程引入规范性偏差，使模型学会预测规范行为而非实际行为，在复杂交互场景中失效。
5. **Look Before Acting：增强视觉基础表征的 Vision-Language-Action 模型**
   本文分析发现 VLA 模型中深层对视觉信息的利用不足,提出 DeepVision-VLA 框架,通过 Vision-Language Mixture-of-Transformers 向深层注入多级视觉特征并引入 Action-Guided Visual Pruning 策略，显著提升机器人操作任务性能。
6. **GigaWorld-Policy：高效的以动作为中心的世界–动作模型**
   本文面向视觉-语言-动作模型的监督稀疏性问题，提出以动作为中心的世界-动作模型，训练时利用未来视觉作为密集监督源，推理时可直接输出动作实现低延迟闭环控制，保证预测的物理一致性。
7. **Temporal Gains, Spatial Costs：重新审视多模态大语言模型中的视频微调**
   本文通过系统实验揭示视频监督微调提升视频性能但削弱图像理解能力的”时序陷阱”现象，分析多个维度的影响因素，提出 Hybrid-Frame 自适应帧分配策略，为图像-视频协同优化提供解决方案。
8. **LoST：面向 3D 形状的语义层级分词**
   本文针对现有 3D 生成中 token 化基于几何细节层级导致早期 token 膨胀和粗层级不可用的问题，提出 LoST 按语义显著性排序 token 序列，结合 RIDA 损失对齐 3D 潜空间与语义特征，仅需少量 token 即可达到 SOTA 性能。

Video-CoE：通过事件链强化视频事件预测

Su*, Tang‡, Chen, Sun, Chu — AMAP, Alibaba Group, 2025

1. 问题动机与背景

多模态大语言模型（MLLM）在视频理解、推理和问答等任务上取得了显著进展，但**视频事件预测**（Video Event Prediction, VEP）仍被严重忽视。VEP 要求模型基于观察到的视频内容预测未来可能发生的事件，这对模型的细粒度时序建模和逻辑推理能力提出了更高要求。作者对多种开源与商用 MLLM 进行了系统评估，发现当前最优模型 Qwen3-VL 在 FutureBench 上平均准确率仅为 66.9%，揭示了两个核心失败原因：

- **缺乏面向未来事件的逻辑推理能力**：现有 MLLM 在 VEP 中倾向于依赖文本选项中的线索而非基于视频证据进行推理，形成“快捷方式”行为——先粗略描述视频，再逐一分析选项，缺少从视频内容到未来事件的逻辑链接；
- **视觉信息利用不足**：注意力分布分析表明，模型在预测时分配给视觉 token 的注意力远低于文本 token。这种文本中心的模态偏差削弱了鲁棒的预测推理能力。先前尝试的两种缓解方法——直接放大视觉注意力权重和使用 prompt 引导视觉定位——在 VEP 上均无效甚至导致性能下降。

2. Chain of Events (CoE) 范式

2.1 核心思想

作者提出 **Chain of Events (CoE)** 范式，通过构建时序事件链来隐式强制 MLLM 关注视觉内容并建立视频与未来事件之间的逻辑关联。定义事件 $E = (\mathcal{T}, \mathcal{D})$，其中 $\mathcal{T}$ 为起止时间戳，$\mathcal{D}$ 为文本描述。时序事件链 $EC = [E_1, E_2, \ldots, E_n]$ 按时间顺序排列。原始模型的预测过程为 $P = P(\hat{E} \mid V, Q, \mathcal{R})$，CoE 范式将其改进为两步：

第一步，模型对视频进行细粒度时序建模，构建事件链 $EC = \mathbf{MLLM}^{CoE}(V)$；**第二步**，基于视频和事件链联合推理 $\mathcal{R}' = \mathbf{MLLM}^{reason}(V, Q, EC)$，最终预测：

$$P = P(\hat{E} \mid V, Q, \mathcal{R}', EC).$$

CoE 通过两个机制解决现有 MLLM 的局限：(i) 推理过程包含视频内容与未来事件之间的逻辑连接；(ii) 通过事件链构建实现细粒度时序建模。

2.2 CoE-SFT：监督微调阶段

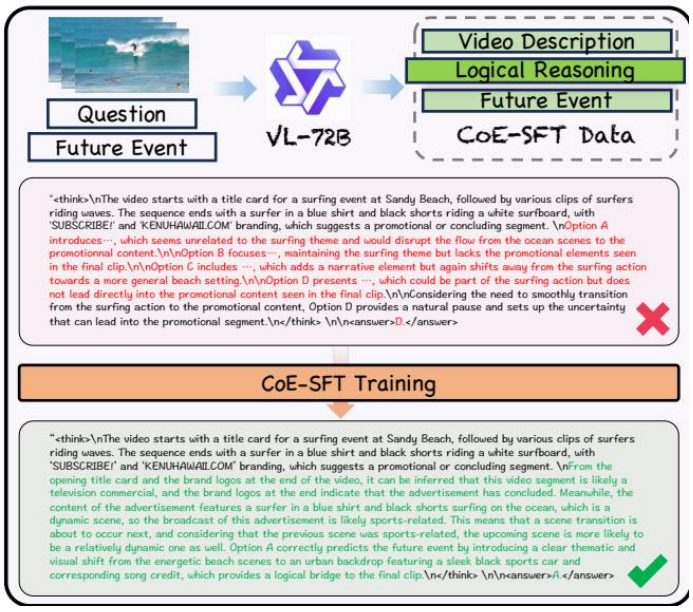

图 1：*CoE-SFT* 方法示意。利用 *Qwen2.5-VL-72B* 生成从视频到未来事件的逻辑推理过程作为训练数据。

如图 1 所示，CoE-SFT 利用强力教师模型 Qwen2.5-VL-72B 构建小规模训练数据集。具体地，向教师模型提供视频、问题和正确的未来事件，指示其输出从视频内容推导出未来事件的逻辑推理过程，同时避免分析其他选项。经人工质检，通过率超过 90%。值得注意的是，CoE-SFT 数据中**未构建事件链** EC，因为大规模 MLLM 生成的 EC 质量不达标可能反而阻碍训练。实验表明模型在 CoE-GRPO 训练后仍能有效保留基于视频内容的推理能力。

此外，作者提出**开放集 Judge 模型评估指标**：移除所有选项，要求模型直接推理预测未来事件，由 judge 模型评估推理有效性和答案正确性，采用组间比较协议报告胜率。

2.3 CoE-GRPO：强化学习阶段

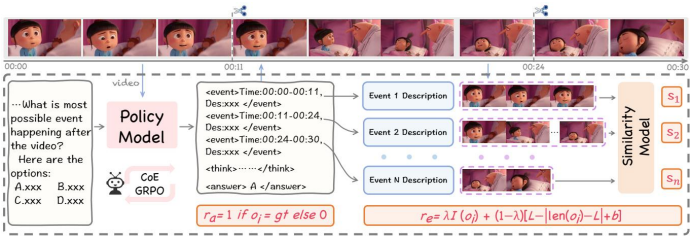

图 2：*CoE-GRPO* 方法示意。总体监督信号由三个组件构成：r_e（*CoE* 奖励）、r_s（相似度奖励）、r_a（准确度奖励）。

如图 2 所示，CoE-GRPO 是专为 VEP 设计的改进 GRPO 框架，通过解锁模型的时序定位和视频理解能力来构建事件链。引入特殊标签 `<event>` 和 `</event>` 标记事件边界，每个标签对包含起止时间戳 t_{start}、t_{end} 及语义描述 $\mathcal{D}$。

CoE 奖励 r_e 提供细粒度监督，控制事件链的正确构建和长度：

$$r_e^{(i)} = \lambda I(o_i) + (1-\lambda)[L - |\mathbf{len}(o_i) - L| + b],$$

其中 $I(o_i)$ 为指示函数（输出是否包含所有必需标签），$\mathbf{len}(o_i)$ 计算事件链中事件数，L 为理想长度超参数，b 为偏置项确保最大值为 1。

相似度奖励 r_s 防止模型作弊并确保事件描述与视频内容一致。根据事件时间戳裁剪原视频得到片段 $[clip_1, \ldots, clip_n]$，计算跨模态相似度：

$$r_s = \frac{1}{n}\sum_{j=1}^{n} \cos(v_j, t_j),$$

其中 v_j、t_j 分别为相似度模型嵌入的视觉和文本特征。

最终奖励为加权和：$r_i = \alpha r_a^{(i)} + \beta r_e^{(i)} + (1-\alpha-\beta) r_s^{(i)}$。优势函数通过组内归一化计算：$A_i = (r_i - \text{mean}(\{r_i\}))/(\text{std}(\{r_i\}) + \delta)$。策略更新遵循 DeepSeek-R1 的 GRPO 目标，含 PPO 裁剪和 KL 散度约束。

2.4 训练流程

两阶段训练：**阶段一** CoE-SFT 在小规模推理数据集上微调，使模型学会从视觉内容逻辑推理未来事件；**阶段二** CoE-GRPO 继续训练，专注于通过事件链构建实现细粒度时序建模。基座模型为 Qwen2.5-VL-3B/7B，最多使用 16 块 NVIDIA H20 GPU，最大帧数 32，GRPO 组大小 $G=4$，KL 系数 $\beta=0.04$，裁剪参数 $\epsilon=0.2$，学习率 1×10^{-6}，训练 150 步。

3. 实验结果

3.1 FutureBench 基准

模型/方法	1-Hop	2-Hop	3-Hop	Interp.	AVG
GPT-5	61.9	61.7	72.1	62.2	66.86
Qwen2.5-VL-72B	65.3	70.5	76.1	53.2	58.33
Qwen3-VL-30B	59.6	68.4	63.7	55.2	59.94
7B-Instruct	57.2	57.0	50.2	50.7	52.94
7B-SFT	60.7	74.2	66.2	65.0	64.39
7B-CoE-SFT	67.6	74.1	62.2	63.2	65.72
7B-GRPO	66.2	69.9	63.7	68.1	67.28
7B-CoE-GRPO	**80.9**	**83.9**	**71.6**	**71.4**	**75.00**

CoE-GRPO (7B) 在所有指标上全面超越所有基线 MLLM，包括 GPT-5 和 72B 模型，AVG 达到 **75.00%**，较 Instruct 基线提升 +22.06 个百分点，较 vanilla GRPO 提升 +7.72 个百分点。3B 模型上 CoE-GRPO 同样以 **68.28%** 超越所有非 CoE 方法。

3.2 AVEP 基准

CoE-GRPO-7B 在动词准确率上达到 **12.24/18.75**（Test/Val），大幅超越 Qwen2.5-VL-72B 的 8.00/7.95 和 vanilla GRPO 的 9.64/10.42。在 Action F1-Score 上达到 **8.29/9.88**,远超 GRPO 的 6.48/7.26 和所有其他基线。Noun F1-Score 为 **65.16/64.03**，同样为最优。

3.3 视觉注意力提升

实验量化了各方法对视觉 token 注意力的影响。CoE-GRPO 的胜率（WR）为 **0.77**，注意力提升率（IR）为 +9.20%；CoE-SFT 更达 WR=**0.93**，IR=+15.11%。对比之下，vanilla SFT 反而降低注意力（IR=−3.33%），vanilla GRPO 仅 +1.47%。这证实 CoE 范式有效解决了视觉信息利用不足的问题。

3.4 Judge 模型评估

开放集评估中，CoE-SFT 胜率 **38.13%**，CoE-GRPO 为 **32.42%**，远超 Instruct (16.21%)、SFT (7.88%) 和 GRPO (5.37%)。CoE-GRPO 略低于 CoE-SFT 是因为 judge 模型更熟悉 SFT 风格推理，但两者接近的表现证明 CoE-GRPO 有效保留了逻辑推理能力。

4. 消融实验

视觉注意力增强方法：Prompt 引导（AVG 45.74）和常量偏置（AVG 52.57）两种策略均导致性能下降，远不如 CoE（AVG 75.00），说明简单的注意力操控无法替代结构化的事件链建模。

组大小 G：$G=2$ 时 AVG 60.61，$G=4$ 时 74.61，$G=8$ 时 77.20。$G=4$ 在性能与成本间取得最优平衡。

事件链长度 L：$L=1$ 时 AVG 73.90，$L=3$ 时 **74.61**，$L=5$ 时 71.40。过短的链无法捕获足够视觉细节，过长引入冗余干扰推理，呈非单调关系。

相似度模型：VideoCLIP-XL（74.61）> CLIP-large（74.24）> ViCLIP（73.01），三者性能接近，证明方法对相似度模型选择具有鲁棒性。

相似度奖励：移除 r_s 后 AVG 从 74.61 降至 72.00，各指标均下降，验证了相似度奖励的有效性。

5. 训练曲线分析

准确率奖励 r_a 呈持续上升趋势；CoE 奖励 r_e 初期快速增长（模型学会事件链概念框架），随后稳步上升（逐步逼近目标长度 L）；相似度奖励 r_s 持续增加，表明事件描述与视频片段对齐程度逐步提升。高精度描述的相似度分数在 0.2–0.3 范围内，属于合理区间。

6. 与相关工作对比

与 NEP 对比：NEP 证明标准 GRPO 优于标准 SFT，但未深入分析 MLLM 在 VEP 上表现不佳的原因，也未提出针对性解决方案。CoE 首次系统揭示了逻辑推理缺失和视觉利用不足两大根因。

与视觉推理 RL 方法对比：Video-R1 (AVG 67.47)、VideoChat-R1 (46.59) 等通用 RL 方法主要针对帧级或局部区域感知，未针对事件预测优化。CoE-GRPO (75.00) 大幅超越。

与传统方法对比：EventFormer 在 AVEP 上 Verb 22.71、Action-F1 7.69，CoE-GRPO 的 Verb 18.75（Val）、Action-F1 9.88（Val）在整体指标上更优。

7. 局限性与未来方向

- **时序定位精度**：方法依赖模型的时序定位能力，当前 MLLM 的定位准确性仍有提升空间，进一步增强可带来额外收益；
- **历史事件结构**：仅探索了基础事件链形式，更复杂的关系感知事件链或事件图是有前景的方向；
- **跨模型和跨任务泛化**：CoE 范式不依赖特定基座模型，理论上可推广至所有 MLLM 和其他视频相关任务，但受资源限制未能全面验证；
- **数据扩展**：扩展曲线显示仅 2000 样本训练即获显著提升，上升趋势远未饱和，更多数据有望带来进一步收益。

MetaClaw：在真实部署中持续元学习与进化的 LLM 智能体

Xia*, Chen*, Yang*, Tu*, Liu*, Xiong*, Han, Qiu, Ji, Zhou, Zheng, Xie, Yao* — UNC, CMU, UCSC, UCB, 2026

1. 问题动机与背景

LLM 智能体在复杂多步任务中表现出色，但部署后面临根本性矛盾：**必须持续服务用户，但能力随任务分布漂移而过时**。在 OpenClaw 等平台上，单个智能体连接 20+ 消息通道，工作负载从文件系统操作漂移到多智能体消息流，冻结模型与实际使用模式日益脱节。

现有适应方法分三类，各有局限：

- **记忆方法**（Reflexion, Mem0, SimpleMem）：存储原始对话轨迹供检索，冗余且无法提取可迁移行为模式；
- **技能方法**（Voyager, ExpeL, Agent-KB）：将经验压缩为可复用行为指令，但技能库作为静态数据库，从未与权重优化协调；
- **RL 方法**（GRPO, DAPO）：更新模型权重，但在离线/小规模设置运行，忽略关键数据有效性问题——技能进化后，旧技能上下文下收集的轨迹携带过时奖励，混入会污染梯度更新。

核心观察：两种根本不同时间尺度的适应天然互补。行为启发式（如“读取前验证文件路径”）可在秒级从单次失败对话中蒸馏并即时注入；跨任务策略改进需分钟到小时级的梯度优化。两者相互强化：更好的策略产生更有信息量的失败供技能合成，更丰富的技能产生更高奖励的轨迹供策略优化。

2. 系统架构与形式化

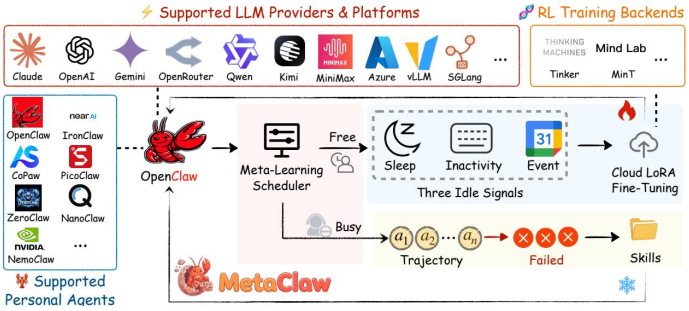

图 1：*MetaClaw* 概览。左：技能驱动快速适应分析失败轨迹即时扩展技能库；右：机会主义策略优化在空闲窗口触发 *RL* 权重更新。

智能体行为由**元模型** $\mathcal{M} = (\theta, S)$ 完全确定，其中 θ 为基座 LLM 策略参数，$S = \{s_1, s_2, \ldots, s_K\}$ 为技能指令库——简洁可复用的行为指令，推理时注入系统提示。给定任务 τ，动作生成为：

$$a \sim \pi_\theta(\cdot \mid \tau, \mathrm{Retrieve}(S, \tau))$$

其中 $\mathrm{Retrieve}(S, \tau) \subseteq S$ 通过嵌入余弦相似度检索相关技能。

关键数据分离：**支持数据** $\mathcal{D}^{\mathrm{sup}}$ 为驱动技能库适应的失败轨迹（反映适应前行为）；**查询数据** $\mathcal{D}^{\mathrm{qry}}$ 为适应生效后收集的轨迹（反映适应后行为），用于优化 θ。混合二者会导致 θ 对过时奖励信号优化。

2.1 技能驱动快速适应

给定当前元模型 (θ, S_g)，失败轨迹形成支持集 $\mathcal{D}_g^{\mathrm{sup}}$，通过无梯度经验蒸馏进化技能库：

$$S_{g+1} = S_g \cup \mathcal{E}(S_g, \mathcal{D}_g^{\mathrm{sup}})$$

其中 $\mathcal{E}$ 为技能进化器——一个 LLM 分析失败轨迹并合成新行为指令。索引 g 为技能代数，每次库变化递增。此步**仅修改 S，θ 不变**，通过提示注入即时生效，**零服务中断**。

技能库 S 扮演**双重角色**：作为元参数，跨整个任务流积累行为知识（$S_{g+1} \supseteq S_g$）；作为适应基，推理时 $\mathrm{Retrieve}(S, \tau)$ 提取任务特定子集提供即时特化。自然语言指令天然跨任务可迁移——从一次失败蒸馏的技能（如“修改前创建.bak 备份”）可泛化到所有涉及文件操作的任务。

2.2 机会主义策略优化

技能库可能在训练窗口开启前已推进多代。令 g^* 为训练时当前技能代，RL 缓冲区 B 积累跨代查询轨迹：

$$\theta_{t+1} = \theta_t + \alpha \nabla_\theta \mathbb{E}_{(\tau, \xi, g') \sim B}[R(\pi_\theta(\cdot \mid \tau, S_{g'}))]$$

其中 $g' \leq g^*$ 为每条轨迹收集时的技能代，R 为过程奖励模型（PRM）分数。关键：策略优化不是优化原始任务表现，而是优化**技能适应后的表现**——更好的 θ 使技能驱动适应产生更强的适应后行为。

实践中通过**云端 LoRA 微调**（GRPO）实现，由机会主义元学习调度器（OMLS）推迟至空闲窗口。仅当查询缓冲区积累足够轨迹时启动，避免高方差梯度。策略优化自然滞后于技能适应数天，强化两时间尺度的不对称性。

2.3 技能代版本控制

在线异步设置中，支持-查询分离需专门机制防止数据泄漏。核心问题：触发技能进化 $S_g \to S_{g+1}$ 的轨迹 (τ_i, ξ_i) 携带反映 S_g 下表现的奖励 r_i。若该轨迹进入 RL 缓冲区，策略优化会收到惩罚 θ 的梯度——针对技能适应**已经纠正**的失败，违反元学习目标。

解决方案：每个样本标记技能代版本 g_i。支持集 $\mathcal{D}_g^{\mathrm{sup}}$（触发进化的轨迹）被技能进化器消费后从 RL 缓冲区丢弃；查询集 $\mathcal{D}_{g+1}^{\mathrm{qry}}$（$S_{g+1}$ 生效后收集的轨迹）才有资格用于梯度更新。代数推进时，刷新缓冲区中所有版本 $\leq g$ 的样本。

2.4 机会主义元学习调度器（OMLS）

OMLS 为后台守护进程，监控三个互补空闲信号：

- **睡眠窗口**：用户配置睡眠时间表（如 23:00–07:00），提供最大连续训练块；
- **系统不活跃**：轮询 OS 输入设备空闲计时器（如 macOS `ioreg HIDIdleTime`），默认 30 分钟无键鼠活动则开启训练窗口，输入恢复时通过批次中间检查点优雅暂停；
- **日历感知调度**：查询 Google Calendar API，当前时间在会议中则推定用户不可用——最具预判性的信号，利用用户自身日程预测空闲。

任一信号指示用户缺席则开启训练窗口，任一信号指示用户返回则关闭。RL 训练器支持跨碎片化空闲窗口的暂停/恢复。

3. 代理架构与部署

MetaClaw 基于**代理架构**构建，无需本地 GPU。基座 LLM 通过 API 调用（GPT-5.2 / Kimi-K2.5），策略优化通过云端 LoRA 微调端点（TML Tinker API）完成。整个系统与现有个人智能体和 LLM 提供商透明集成。

4. 实验设置

4.1 MetaClaw-Bench

全新持续智能体基准，共 **934 道题，44 个模拟工作日**，评估智能体跨真实 CLI 任务序列流的适应能力。

Part I：30 工作日模拟（346 题，每天 10–15 题）。工作区状态跨轮次持久化，每题包含前一轮评估结果作为纠正反馈。题型含文件检查任务（自动化检查器验证输出）和多选题。难度随天数单调递增，25–30 天需复杂多步推理。

Part II：14 工作日模拟（588 题，每天 42 题：434 多选 + 154 文件检查）。文件检查任务为基于规则的转换，行为启发式合规性（如 schema 约定、时间戳格式）是主要瓶颈，更适合技能蒸馏。引入 5 条**隐式偏好规则**（P1–P5）逐步激活：ISO 8601 时间戳、日期前缀文件命名、元数据字段、修改前备份、完成日志。

AutoResearchClaw：23 阶段全自主研究流水线（文献搜索 → 假设生成 → 实验设计 → 代码合成 → 沙箱执行 → 结果分析 → 论文撰写 → 多智能体同行评审），测试跨领域泛化。

5. 核心实验结果

模型	条件	Part I Acc.	Part II Acc.
GPT-5.2	Baseline	41.1%	44.9%
GPT-5.2	+Skills	44.0% (+7.1%)	49.1% (+9.4%)
Kimi-K2.5	Baseline	21.4%	21.1%
Kimi-K2.5	+Skills	28.3% (+32.2%)	26.9% (+27.5%)
Kimi-K2.5	Full	**40.6%** (+89.7%)	**39.6%** (+87.7%)

核心发现 1：两种机制均有效，完整流水线增益最大。GPT-5.2 仅技能注入即在 Part II 将文件检查完成率从 58.4%

提升至 67.5%。Kimi-K2.5 完整流水线将 Part I 准确率从 21.4% 提升至 40.6%，端到端任务完成率提升 8.25×（2.0% → 16.5%），Part II 文件检查完成率从 18.2% 跃升至 51.9%（+185%）。MetaClaw (Full) + Kimi-K2.5 几乎追平 GPT-5.2 基线（40.6% vs 41.1%），表明技能注入 + 策略优化可大幅弥补模型能力差距。

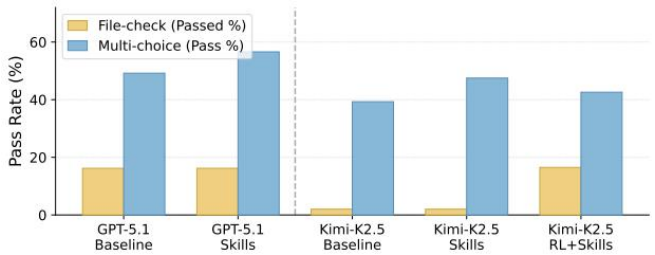

图 *2*：各任务类型通过率。文件检查（黄）仅靠技能不变，*MetaClaw (Full)* 下跃升 8.25×；多选（蓝）技能提升但 *Full* 下略降，反映策略向执行偏移。

核心发现 2：强模型受益少，弱模型受益多。GPT-5.2 基线已高（41.1%），技能注入提升空间有限；Kimi-K2.5 缺乏隐式程序性知识，技能库显式提供后收益更大。这表明 MetaClaw 对部署 "够用但非顶尖" 模型尤其有价值。

核心发现 3：技能单独无法解锁端到端完成，需权重优化。Part I 中技能注入未改变两模型的完成率，确认技能提升部分执行质量但无法可靠实现零缺陷输出。MetaClaw (Full) 弥补了这一差距。Part II 中技能已驱动显著完成率提升（18.2% → 33.8%），完整流水线进一步推至 51.9%，确认权重优化在技能注入基础上提供叠加收益。

RL 训练动态。Part II 文件检查完成率在第 8 天出现明显拐点：1–4 天 ∼9%，5–8 天 27–36%，9–10 天 55–64%，12 和 14 天达 100%。这一学习轨迹镜像 MAML 内循环更新结构：前几天积累支持轨迹，拐点标志 LoRA 微调获得足够梯度信号，后期收敛表明策略已内化技能库揭示的程序性规则。两阶段模式直接验证了互补时间尺度假设。

5.1 AutoResearchClaw 跨领域验证

指标	Baseline	+Skills	变化
阶段重试率 ↓	10.5%	7.9%	↓24.8%
精炼循环数 ↓	2.0	1.2	↓40.0%
流水线阶段完成 ↑	18/19	19/19	+5.3%
综合鲁棒性分数 ↑	0.714	0.845	**+18.3%**

仅使用技能注入（无 RL），MetaClaw 在结构完全不同的 23 阶段研究自动化流水线上将综合鲁棒性分数提升 18.3%，精炼循环减少 40%，流水线完成从 18/19 提升至 19/19 阶段。跨领域可迁移性结合零停机部署确认 MetaClaw 可作为通用持续学习层。

6. 分析与消融

逐日准确率趋势。所有条件从 1–10 天（>50%）到 25–30 天（<30%）均呈下降趋势，确认基准难度递增。MetaClaw 优势在中期（11–22 天）最显著——任务需要多步程序合规性，可通过失败蒸馏学习。MetaClaw (Full) 在 19–20 天前后达到约 0.8 的峰值准确率。晚期（23–30 天）复杂度使所有条件趋向相近低性能。

技能库分析。30 天会话中，技能进化器合成的技能聚类于三类失败模式：（1）**时间格式合规**——自然语言时间表达归一化为 ISO 8601 含时区偏移；（2）**修改前备份协议**——破坏性文件操作前创建.bak；（3）**命名约定遵循**——日期前缀文件命名模式（如 `20260408_*.json`）。这些跨任务行为启发式解释了单次失败如何产出改善后续不同结构题目表现的技能。

案例研究。Case 1（GPT-5.2, Skills）：Day 2 蒸馏的 "修改前创建.bak" 技能在 Day 19 解决了完全不同文件类型的合规错误，零权重更新。Case 2（Kimi-K2.5, Full）：技能注入提供 ISO 8601 格式上下文但不足以解决 `changes` 数组遗漏；RL 权重更新后四个字段完整输出，当日准确率从 8.3% 提升至 80.6%。两案例分别展示了两种机制的独特贡献。

7. 与相关工作的对比

MetaClaw 的独特定位在于**统一**技能进化与策略优化。与 Reflexion/Mem0 等记忆方法相比，MetaClaw 蒸馏可迁移行为模式而非存储原始轨迹。与 Voyager/ExpeL 等技能方法相比，技能库不再是静态制品，而是与权重优化协调的元参数。与 GRPO/DAPO 等 RL 方法相比，MetaClaw 通过技能代版本控制解决数据有效性问题，通过 OMLS 解决何时训练问题。与 MAML/PEARL 等元学习方法相比，MetaClaw 将元学习目标扩展至非平稳 LLM 智能体任务流，快速适应为无梯度（离散自然语言空间中的技能合成），慢适应为基于梯度（RL 策略优化）。

8. 局限性与未来方向

- **空闲窗口依赖**：OMLS 空闲检测依赖用户配置（睡眠时间、日历权限），可能不适用于所有部署环境；
- **基准局限**：MetaClaw-Bench 为作者编写的模拟而非真实用户会话，绝对增益可能不直接迁移至生产负载——主要价值在于一致的方向性趋势；
- **技能库增长**：当前技能库单调递增（$S_{g+1} \supseteq S_g$），长期可能导致检索噪声，技能退役/合并机制为潜在改进方向；
- **RL 延迟**：策略优化自然滞后技能适应数天，快速环境变化下可能不够及时；
- **云端依赖**：代理架构虽免去本地 GPU，但依赖云端 LoRA 微调端点的可用性和成本；
- **评估范围**：仅测试 GPT-5.2 和 Kimi-K2.5 两个骨干模型，更广泛模型家族的泛化性有待验证。

MosaicMem：面向可控视频世界模型的混合空间记忆

Yu[1,2,*,†], Qian[3,*], Li[*], Wang[4], Yin[5], Chakaravarthy[4], Anthony[4], Ye[6], Li[3,7], Wan[3], Garg[4] — [1]U Toronto, [2]Vector Inst., [3]U Osaka, [4]Georgia Tech 等, 2025

1. 问题动机与背景

视频扩散模型正从生成短视频片段向构建**世界模拟器**演进，要求在相机运动、场景重访和干预下保持时空一致性。Genie 3 等系统展示了实时交互与长期持久性的方向：不仅要生成逼真帧，还需实现物体持久性、视点一致性和因果稳定性。**空间记忆**（spatial memory）是实现这些目标的关键瓶颈，当前两种范式各有根本局限：

显式空间记忆（Explicit）：通过外部 3D 估计器将观测提升到点云/3D 高斯等几何缓存，重访时投影到查询视角作为条件。优势在于几何一致性由专用 3D 推理保证，减少训练数据偏差。但**核心缺陷**：仅适合静态场景——在多个独立运动物体存在时难以维护和更新一致的显式缓存，且全局 3D 重建中微小跨视角错位随时间累积导致伪影。

隐式空间记忆（Implicit）：将世界状态存储在模型隐表示中（如 Context-as-Memory、RTFM），通过注意力机制从已 pose 的参考帧中检索。优势在于端到端可微，可处理动态、外观变化和非刚性因素。但**核心缺陷**：即使提供完全正确的相机位姿，生成视频仍表现出不准确的自运动（egomotion drift）；且 "posed-frame memory" 高度冗余——逐帧转换上下文为记忆帧，拖慢生成速度并在有限上下文窗口下限制持久性。隐式状态也难以解释和操作。

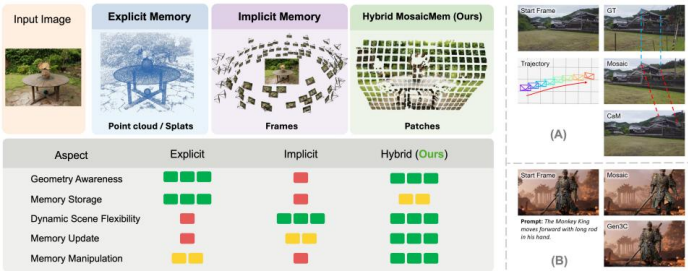

图 1：记忆机制比较与可视化。*MosaicMem* 统一显式与隐式记忆的优势。*(A)* 相比隐式记忆实现更精确的相机运动；*(B)* 相比显式记忆支持文本驱动的动态生成。

2. 核心方法：Mosaic Memory

MosaicMem 以 **patch**（而非点/splat 或完整帧）作为记忆的基本单元，有机结合两种范式的互补优势。

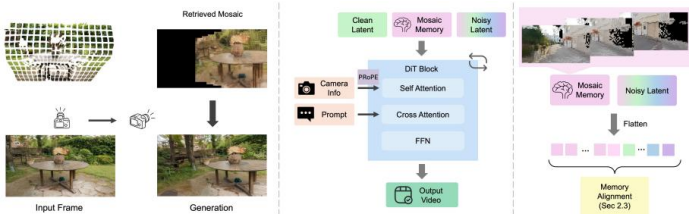

图 2：方法概览。左：*MosaicMem* 将 *patch* 提升到 *3D* 后在目标视角拼贴组合。中：架构总览，*PRoPE* 与 *MosaicMem* 联合控制相机运动。右：检索到的 *mosaic patch* 展平拼接至 *token* 序列作为条件。

2.1 任务定义与生成框架

给定输入图像 $\mathcal{I}$、文本提示集 $\mathcal{L} = \{\ell_1, \ldots, \ell_k\}$ 和相机位姿序列 $\mathcal{C} = \{c_1, \ldots, c_T\}$，目标是生成长时视频 $\mathcal{X} = \{X_1, \ldots, X_T\}$。系统基于 TI2V（text+image-to-video）模型，通过 Flow Matching 学习联合分布。从高斯噪声 $\mathcal{X}^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，学习神经向量场 u_θ 将其传输至 $\mathcal{X}^1$：

$$\frac{d\mathcal{X}^\lambda}{d\lambda} = u_\theta(\mathcal{X}^\lambda, \lambda \mid \mathcal{Z}, \mathcal{L}, \mathcal{C}, \mathcal{M}), \quad \mathcal{X}^1 = \mathcal{X}^0 + \int_0^1 u_\theta \, d\lambda$$

其中 $\mathcal{M}$ 为空间记忆，$\lambda \in [0, 1]$ 为连续 flow 时间。

2.2 Patch-and-Compose 机制

对给定 patch P，首先执行**几何提升**（类比显式记忆管线的前半段）：使用现成 3D 估计器推断深度和相机信息，将 patch 提升至 3D 空间。当观察者移动到新视角并重访 patch P 时，采用**隐式条件策略**（类比隐式记忆管线的后半段）：检索到的 patch 作为 DiT 的上下文，修改后的 RoPE 机制传达记忆 patch 与当前噪声 latent token 之间的对应关系。生成器灵活决定是依赖空间记忆进行一致重建，还是根据文本提示合成新内容和新动态。

关键优势：

- **灵活检索**：稠密或稀疏检索均可——视频高冗余性使得分布在不同时空位置的同场景记忆往往足以重建整个序列；与首帧重叠区域无需完整 Mosaic Memory，大幅减少条件 token 数；
- **可操作记忆空间**：单个物体 patch 可显式位移、复制或删除，支持空间记忆的直接操纵；
- **鲁棒长程更新**：存储独立局部 patch 而非全局重建结构，避免跨视角错位累积。

零样本验证：将 Mosaic Memory 直接注入原始 Wan 2.2 模型（无任何修改/微调），模型即可将上下文条件中的 Mosaic Memory 投影到正确时空位置并生成有意义的视觉内容，验证了管线的可行性。

2.3 记忆对齐：双重 Warping 机制

3D VAE 的高时空压缩引入空间-时间模糊，降低 DiT 中 RoPE 坐标的有效分辨率，导致检索 patch 可能无法精确对齐。为此提出两种互补的 warping 机制：

Warped RoPE：基于像素级精确对应的位置编码对齐。每个检索记忆 patch P 关联深度 D 和源时间步的相机内外参 $(\mathbf{K}_i, \mathbf{T}_i)$。给定原始 RoPE 坐标 (u, v)，反投影至 3D 世界空间并重投影至目标相机 $(\mathbf{K}_j, \mathbf{T}_j)$：

$$(u', v') = \Pi\big(\mathbf{K}_j \mathbf{T}_j \mathbf{T}_i^{-1} \mathbf{K}_i^{-1}(u, v, D)\big)$$

其中 $\Pi(\cdot)$ 为透视投影。(j, u', v') 共同定义该 patch 的 3D RoPE 坐标。保留重投影坐标的小数部分并在更高分辨率下采样 RoPE 以保持精度。

Warped Latent：直接在特征空间中变换检索到的记忆 patch——利用重投影坐标 (u', v') 对源 latent 特征执行可微双线性网格采样。

两种机制优势互补：Warped Latent 在相机运动精度上更优，但视觉质量和记忆检索不如 Warped RoPE；Warped RoPE 在极端场景（如相机运动极慢时）会在图像边界重复生成新观测物体。**混合训练两种策略效果最佳**。

3. PRoPE 相机控制

Mosaic Memory 隐式提供部分相机运动线索，但不足以可靠控制轨迹。引入 PRoPE（Projective Positional Encoding）的三个原因：(a) 大相机运动或稀疏记忆下需显式轨迹规范；(b) 3D VAE 的 4× 时间压缩使 Mosaic Memory 无法捕捉细粒度帧间运动；(c) 支持直接复用已生成视频 latent 加速生成。

给定逐帧相机投影矩阵 $\tilde{\mathbf{P}}_i \in \mathbb{R}^{4\times 4}$，PRoPE 通过投影变换 $\tilde{\mathbf{P}}_{i_1}\tilde{\mathbf{P}}_{i_2}^{-1}$ 编码两视角间的完整相对关系，并通过 GTA 风格变换注意力实现：

$$\mathrm{Attn}_{\mathrm{PRoPE}}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \mathbf{D} \odot \mathrm{Attn}(\mathbf{D}^\top \odot \mathbf{Q}, \mathbf{D}^{-1} \odot \mathbf{K}, \mathbf{D}^{-1} \odot \mathbf{V})$$

其中每个 token t 使用分块对角矩阵 $\mathbf{D}_t^{\mathrm{PRoPE}} = \mathrm{diag}(\mathbf{D}_t^{\mathrm{Proj}}, \mathbf{D}_t^{\mathrm{RoPE}})$。关键适配：时间压缩下一个 latent 帧索引 ℓ 对应四个原始帧 $\{4\ell + k\}_{k=0}^{3}$，需 "展开" 子索引 k 并应用 $\mathbf{D}_{\ell,k}^{\mathrm{Proj}} = \mathbf{I}_{d/8} \otimes \tilde{\mathbf{P}}_{\ell,k}$，确保每个时间压缩的 latent 帧以正确的逐帧投影条件参与注意力。

4. 数据构建：MosaicMem-World

现有第一人称视频数据集以前向导航为主，缺乏**显式重访**。MosaicMem-World 从四个互补来源聚合（各约数十小时）：(1) UE5 场景——单/混合动作轨迹含显式重访段；(2) 商业游戏环境（如 Cyberpunk 2077）——密集交互与复杂动态；

(3) 真实第一人称视频——引入真实外观/噪声/光照变化；(4) Sekai 等现有数据集——选择重访频率最高的序列。

统一预处理管线：Depth Anything V3 或 VIPE 重建深度和相机运动；Gemini 3 对每个 32 帧段生成 "静态 + 动态" 双重文本描述，支持跨段拼接构建任意长度训练片段。

5. 实验评估

实现细节：微调 Wan 2.2 5B（开源 TI2V DiT），AdamW 优化器，学习率 1×10^{-5}，8×H100 训练 250k 步，batch size 64。推理使用 50 步去噪。

方法	RotErr↓	TransErr↓	FID↓	Dynamic↑
显式记忆				
VMem	1.59	0.14	77.12	1.18
GEN3C	1.61	0.13	77.41	1.21
SEVA	1.42	0.12	74.67	1.22
VWM	1.50	0.13	75.83	1.41
隐式记忆				
WorldMem	5.87	0.49	85.72	1.67
CaM	4.65	0.43	85.32	1.72
MosaicMem	**0.51**	**0.06**	**65.67**	**2.58**

5.1 对比显式记忆

显式记忆基线（GEN3C, SEVA, VMem, VWM）虽有非零 Dynamic Score（源于有限相机运动），但运动动态远弱于 MosaicMem。定性结果显示，基线无法生成新的运动物体或驱动已观测物体的动画；MosaicMem 可跟随提示生成组合场景——如科幻环境中骑马的中世纪骑士、花园中行驶的汽车。由于缺乏动态场景演化，显式记忆的生成分布偏离真实数据分布，视觉质量也随之下降。

5.2 对比隐式记忆

MosaicMem 在相机运动精度（RotErr 0.51° vs CaM 4.65°, TransErr 0.06 vs 0.43）和记忆检索一致性（SSIM 0.75 vs 0.49, PSNR 23.57 vs 15.78, LPIPS 0.11 vs 0.42）上大幅超越 WorldMem 和 CaM。长程生成中 MosaicMem 展现可忽略的相机漂移，而 CaM 伪影逐渐累积最终导致生成崩溃。

5.3 消融实验

配置	RotErr↓	FID↓	SSIM↑
ControlMLP alone	6.51	89.17	0.37
PRoPE alone	4.91	86.44	0.45
MosaicMem w/o PRoPE	0.79	73.18	0.68
PRoPE + Warped Latent	0.66	75.46	0.65
PRoPE + Warped RoPE	0.70	71.89	0.69
MosaicMem (full)	**0.51**	**65.67**	**0.75**

消融表明：(1) PRoPE 优于 ControlMLP，MosaicMem 进一步优于 PRoPE alone——三者呈渐进式改进；(2) MosaicMem alone（无 PRoPE）在大旋转运动下无法检索足够 patch，缺乏相机控制引导；(3) Warped Latent 相机运动更精确但视觉质量/检索不如 Warped RoPE；(4) 混合两种 warping 策略的完整模型最优。

6. 长程视频生成

每次生成 80 帧段并纳入记忆空间更新，前段末帧作为下段首帧，迭代生成 **2 分钟**导航视频。MosaicMem 准确召回先前观测区域并忠实渲染运动物体；CaM 因相机运动不准确导致伪影逐渐累积，长程生成最终崩溃。

7. 记忆操纵与场景编辑

MosaicMem 存储 patch 及其 3D 时空位置，可直接编辑位置实现删除、复制、拼接和重定位。代表性应用：将两个不同场景的视频/图像注册到 Mosaic Memory 并空间连接，构建统一场景表示——用户可从中世纪场景无缝移动到现代街道再返回；或翻转 Mosaic Memory 注册在天空，创造 Inception 式超现实空间连接。

8. Mosaic Forcing：自回归生成

将双向 MosaicMem 模型通过 Causal Forcing（Self Forcing 和 Rolling Forcing 的升级版）蒸馏为因果架构。实现 **16 FPS**、640×360 的实时生成。

方法	Total↑	PSNR↑	RotErr↓	TransErr↓
Matrix-Game	75.11	18.57	5.32	0.38
RELIC	79.08	20.23	4.99	0.36
MosaicMem-WRoPE	77.81	19.01	1.63	0.16
MosaicMem (full)	**81.11**	**21.57**	**0.89**	**0.11**

VBench 协议下评估六项指标（主体/背景一致性、运动平滑度、时间闪烁、美学/成像质量），MosaicMem 在所有指标上显著超越 RELIC 和 Matrix-Game 2.0，尤其在大相机运动下优势突出。

9. 与相关工作的定位

空间记忆：GEN3C 维护点云缓存、Spatia 通过 visual SLAM 更新、VMem 用 surfel 索引可见性——几何一致但无法处理复杂动态。WorldMem 按 FOV 重叠检索、CaM 基于规则选择、WorldPack 用轨迹打包——灵活但漂移累积。MosaicMem 是首个混合策略。

相机控制：先前方法通过直接条件化相机参数、提升 2D 输入至 3D 渲染点云、或 Plücker 射线编码实现。PE-Field 将 2D 位置编码扩展为结构化 3D 场。Warped RoPE 采用类似几何重投影但扩展至视频（含时间坐标）。PRoPE 通过位置编码捕捉相对相机几何，实现改进的可控性。

10. 局限性与未来方向

- 依赖现成 3D 估计器质量——估计不准确时 patch 提升和对齐退化；
- 当前 patch 粒度由 VAE 压缩率决定，更细粒度的自适应 patch 划分待探索；
- Warped RoPE 在极慢相机运动下可能在边界重复生成物体（需 Warped Latent 互补）；
- 长程自回归生成中误差仍会缓慢累积，完全消除漂移需更强的记忆一致性约束；
- 记忆操纵目前限于简单几何操作（拼接/翻转），更复杂的语义级编辑（如物体属性修改）尚未实现；
- 训练数据中真实世界重访场景仍有限，更大规模、更多样的重访数据可进一步提升泛化能力。

对齐使语言模型具有规范性而非描述性

Eilam Shapira, Moshe Tennenholtz, Roi Reichart — Technion, 2025

1. 核心问题与动机

大语言模型（LLM）日益被用作人类行为的代理（homo silicus）：复现心理学/经济学实验结论、近似人群意见分布、预测调查实验结果。然而，几乎所有此类工作均使用**对齐后模型**（aligned model），隐含假设对齐对行为预测无害甚至有利。

本文挑战这一假设。对齐过程（RLHF/DPO）优化模型以产出人类评估者认可的回复——合作的、公平的、社会恰当的。但人类在策略情境中的实际行为往往并非如此：人们会虚张声势、报复、偏离规范。若对齐将模型行为分布收窄至评估者认可的模式，则引入了**规范性偏差**（normative bias）——模型学会预测人们认为应该做的，而非人们实际做的。

这一区分——**规范理论**（normative theory, 应然）与**描述理论**（descriptive theory, 实然）——是社会科学与行为科学的基石。本文的核心假设：对齐模型在人类行为接近规范预测的场景中表现良好，但在行为受交互历史塑造的复杂多轮策略博弈中表现不佳。

2. 实验设计

2.1 博弈族与人类数据

研究覆盖四类多轮策略博弈，共涉及 **10,050 个真实人类决策**：

- **讨价还价**（Bargaining）：基于 Rubinstein (1982) 交替出价模型，Alice 和 Bob 轮流提议分配一笔资金，含折扣因子 (δ_1, δ_2) 和自由文本信息。人类做二元接受/拒绝决策。1,788 个决策。
- **说服**（Persuasion）：20 轮 cheap talk 博弈。卖方观察产品质量后向买方发送信息；买方决定是否购买。单阶段均衡为 babbling，但多轮中涌现声誉动态。含完整历史买方和近视买方两种变体。3,180 个决策。
- **谈判**（Negotiation）：双边价格谈判，卖买方交替出价。各方有私有估价 V_A, V_B。人类可选接受、拒绝或行使外部选项（与 John 成交）。三元决策，1,182 个决策。
- **重复 2×2 矩阵博弈**：囚徒困境（PD）和性别之战（BoS），195 名参与者各玩 10 轮，共 3,900 个决策。

前三族来自 GLEE 基准，人类与 LLM 对手交互（人类不知对手为 LLM）。所有模型共产生超 **240 万**次预测。

2.2 模型对与预测方法

比较来自 23 个模型家族的 **120 对同厂商 base–aligned 模型**（从 1B 到 72B），严格限制同厂商配对以隔离对齐效应。每个模型使用其**原生格式**：base 用标准文本补全，aligned 用 chat template。

预测方法为 **token 概率提取**：在每个决策点构造提示（系统消息 + 对话历史），单次前向传播提取决策 token 的 log 概率，归一化得到预测分布：

$$p_{\text{accept}} = \frac{p(\text{yes})}{\sum_d p(d)}$$

其中 d 遍历所有决策 token。此方法确定性、无需生成，对 base 和 aligned 模型同等适用。

2.3 过滤与评估

两层过滤：（1）**质量过滤**——任一模型决策 token 平均概率质量 $< 80\%$ 则排除；（2）**最低相关过滤**——两个模型与人类决策的 Pearson 相关均 < 0.3 则排除。主指标为 Pearson 相关；统计检验使用单侧二项检验和 Wilcoxon 符号秩检验。

2.4 边界条件数据集

为检验假设边界，另设两个对照：

- **单次 2×2 矩阵博弈**：Zhu et al. (2025) 的 2,416 个程序生成博弈，覆盖 12 种拓扑，约 93,000 聚合人类决策。无重复交互。
- **二元彩票选择**：Marantz & Plonsky (2025) 的 1,001 个彩票问题。纯个人决策，无策略互动。

3. 核心实验结果

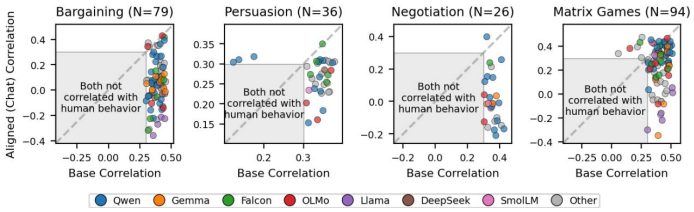

图 1：四类博弈中 *base*（x 轴）与 *aligned*（y 轴）模型与人类决策的 *Pearson* 相关。对角线以下表示 *base* 优势。*Base* 以 *9.7:1 (213:22)* 压倒性胜出。

3.1 多轮博弈：Base 模型大幅领先

如图 1 所示，在多轮博弈中 base 模型以 **213:22**（9.7:1）胜出，$p < 10^{-40}$。各博弈族均单独显著（$p < 10^{-6}$）：讨价还价 75:4、说服 32:4、谈判 25:1、矩阵博弈 81:13。

排除提示格式混淆：两个控制实验表明优势来自模型权重而非格式——（1）双方均用纯文本：base 仍以 5.0:1 胜（$p < 10^{-34}$）；（2）双方均用 chat template：base 仍以 5.3:1 胜。

提示措辞鲁棒性：测试 14 种提示变体（框架、角色、格式、结构 4 类），10 种有效变体中 base 共赢 **959/1003**（95.6%，$p < 10^{-200}$），每种变体单独 $p < 0.01$（表 1）。即使“自私”或“观察者”角色也无法缩小差距。

博弈参数鲁棒性：三类 GLEE 博弈共 18 个参数维度中，base 优势在几乎所有参数值下成立。唯一例外：讨价还价 $\delta_1 = 0.8$ 时 base 优势趋近平局（10:7，$p = 0.31$）。说服博弈中，卖方知道产品质量时优势更大（14.5:1 vs. 不知时 2.3:1），表明 base 模型更好地捕捉了策略信息利用。

3.2 逐轮动态：关键转折

第 1 轮（交互历史尚未发展）aligned 模型反而占优：讨价还价 61:32、谈判 39:33、说服 30:23。但**第 2 轮起** base 立即反超：讨价还价 82:4、谈判 56:1、说服 31:8。这一**同数据内的转折**有力表明，驱动 base 优势的是历史依赖动态的积累，而非博弈结构本身。

3.3 规模效应

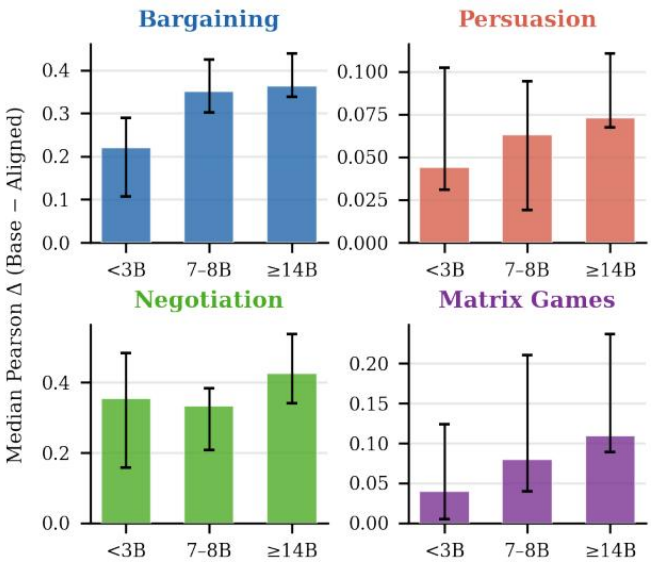

图 2：*Base* 减 *Aligned Pearson* 相关差异随模型规模变化（95% *bootstrap CI*）。优势随规模增长。

若 base 优势源于更丰富的预训练表示被对齐偏移，则应随模型规模增长。图 2 证实此点：讨价还价从 <3B 的 +0.22 增长到 ≥14B 的 +0.36；谈判从 +0.35 到 +0.43；矩阵博弈从 +0.04 到 +0.11。

3.4 所有模型家族一致性

23 个模型家族全部呈现 base 优势。七大家族中 base 赢得多数：Qwen 82:15、Gemma 28:2、Falcon 21:6、Llama 17:0、OLMo 16:3、DeepSeek 8:4、SmolLM 5:3。

4. 边界条件：优势反转

4.1 单次矩阵博弈

71 对有效模型中，aligned 以 **57:14**（4.1:1）胜出（$p < 10^{-6}$），且在**全部 12 种博弈拓扑**中均占优（表 2）。对比重复博弈（同结构 10 轮时 base 以 6.2:1 胜），反转极为显著。

规范性对齐的量化验证：对每个单次博弈计算混合策略 Nash 均衡概率。人类聚合选择与 NE 的相关为 $r = 0.616$，说明单次博弈中人类行为接近规范预测。Aligned 模型系统性地更接近 NE（均值 $r = 0.41$ vs. base 的 0.28；76 对中 59 对 aligned 更接近 NE，$p < 10^{-6}$）。这直接证实**对齐将预测推向规范模式**，在人类行为恰好遵循规范时这种偏移是有益的。

4.2 彩票选择

90 对中 aligned 以 **62:28**（2.2:1）胜出（$p = 2.19 \times 10^{-4}$）。非策略性个人决策中，理解决策结构和遵循指令的能力与预测任务一致，对齐有利。

5. 理论解释：分布收窄

对齐的选择性优势排除了最简单的替代解释——若对齐仅导致灾难性遗忘，则应均匀退化而非在单次博弈和彩票上反而获胜。相关知识被保留；对齐改变的是模型表达哪些行为模式。

KL 正则化奖励最大化产生最优策略 $\pi^*(x) \propto \pi_0(x)\exp(r(x)/\beta)$——对 base 分布的指数倾斜，将概率质量集中于高奖励（标注者认可的）行为模式，以牺牲分布尾部为代价。Xiao et al. (2025) 证明这种集中不是副作用而是**结构性质**：标准 RLHF 天然偏向主导偏好（“偏好坍塌”），保留完整偏好分布需要当前方法所缺乏的基于熵的正则化器。GX-Chen et al. (2026) 进一步证明标准 KL-RL 框架只能指定单峰目标，多样性坍塌是内建特性而非实现缺陷。

本文提供了该理论预测的**首个行为证据**——坍塌不仅在生成多样性中可测量（Kirk et al., 2024），更体现在对人类决策的**预测保真度**中。奖励倾斜所压制的分布尾部恰是多轮策略行为的所在：互惠、报复、声誉动态——标注者不会认可但人类经常表现的行为。

6. 与先前工作的对比

LLM 作为行为代理：此前工作（Aher et al., 2023; Argyle et al., 2023; Hewitt et al., 2024）几乎全部使用 aligned 模型。Suh et al. (2025) 发现 aligned 模型在零样本意见预测上远劣于 base，但证据限于意见和个体判断。本文**首次**将比较扩展到多轮策略交互。

对齐税：已知对齐退化推理基准（Munjal et al., 2026）和校准度（Kadavath et al., 2022），但此前以生成质量和基准分数衡量代价。本文首次以**行为预测保真度**衡量分布收窄的代价。

LLM 与策略博弈：此前研究 LLM 如何玩博弈（Capraro et al., 2025; Akata et al., 2025），但玩和预测根本不同——Nash 均衡处的模型反而预测不了系统性偏离均衡的人类行为。本文研究预测，使用 logprob 提取而非生成，实现 base–aligned 在相同输入上的直接比较。

7. 实践意义

- **多轮交互场景**（谈判、协商、模拟社会行为）：应优先使用 base 模型；
- **单次博弈或非策略性任务**：aligned 模型仍然合适；
- **社会科学模拟**：用 aligned 模型模拟选民、消费者、社交媒体行为可能得到理想化而非真实结果——尤其在规范与行为一致的场景中差异不可见，构成系统性方法论风险；
- **base vs. aligned 的选择**不仅是格式决策，而是**实质性建模假设**——决定 LLM 是“人类行为模型”还是“人类使用工具”。

8. 局限性与未来方向

- GLEE 数据中人类与 LLM 对手交互（非人-人），但参与者不知对手为 LLM，一定程度缓解顾虑；
- 分析限于二元/三元决策，连续动作空间有待探索；
- 120 对均为开源模型，无法评估闭源模型（但 1B–72B+ 一致趋势暗示可泛化）；
- 单次边界条件使用不同数据集，但多轮博弈第 1 轮的 aligned 优势提供了来自同一数据的收敛证据；
- 多轮中哪些因素驱动 base 优势（对手建模？历史整合？轨迹新颖性？）有待细分；
- 开发**保留经验行为分布同时增加有用性**的新对齐方法是自然方向；
- 极大规模下规范偏移是否仍存在值得检验。

核心结论：当前对齐方法中的规范–描述权衡可能是内在的——针对单一奖励模型（编码标注者偏好）的优化不可能同时保留完整的人类行为分布。在开发出能兼顾有用性与行为多样性的对齐方法之前，base 与 aligned 模型的选择始终是一个决定 LLM 作为行为模型还是使用工具的根本性建模假设。

Look Before Acting：增强视觉基础表征的 Vision-Language-Action 模型

Luo*, Chen*, Wu*, Sui*, Liu*† 等 — 北京大学 / Simplexity Robotics / 香港中文大学, 2025

1. 动机与问题背景

Vision-Language-Action（VLA）模型通过将视觉观测与自然语言指令映射为机器人动作，已成为机器人操作的主流范式。其核心依赖于**准确解释和整合视觉信息**来生成可靠动作。现有增强 VLA 视觉能力的方法主要从四个角度出发：引入视觉提示、设计辅助视觉目标、融合额外视觉模态、预测未来状态。然而，这些方法均将 LLM 骨干视为**黑盒**，缺乏对视觉信息如何在内部传播和利用的深入理解。

本文首次系统分析了多种 VLA 架构（OpenVLA、π_0、QwenVLA-OFT）中视觉信息的逐层利用方式，发现一个关键现象：

- **浅层**：动作 token 对任务相关视觉区域（机器人臂、被操作物体）的注意力集中且有效；
- **深层**：注意力逐渐弥散，动作预测对任务相关视觉 token 的敏感度显著下降；
- 定量验证：在深层遮蔽 ROI 视觉 token 对动作 MSE 影响极小，而浅层遮蔽导致显著性能退化。

作者将此归因于现有 VLA 的**串行架构**——视觉信息仅在第一层 LLM 注入，随 Transformer 层传播逐渐衰减。基于此洞察，本文提出 **DeepVision-VLA**，通过 Vision-Language Mixture-of-Transformers（VL-MoT）框架向深层注入多级视觉特征，并引入 Action-Guided Visual Pruning（AGVP）策略剪除冗余视觉 token。

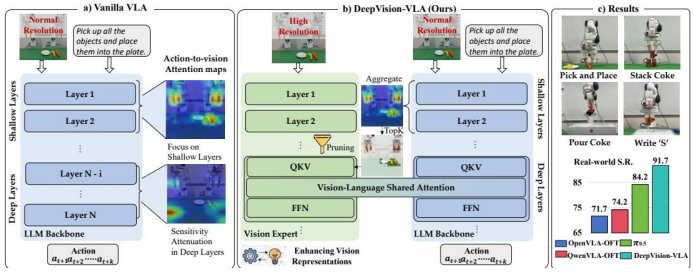

图 1：*(a)* 原始 *VLA* 中深层对视觉 *token* 的注意力逐渐减弱；*(b) DeepVision-VLA* 通过 *VL-MoT* 向深层注入多级视觉特征；*(c)* 在真实任务上显著超越基线。

2. 系统架构与方法

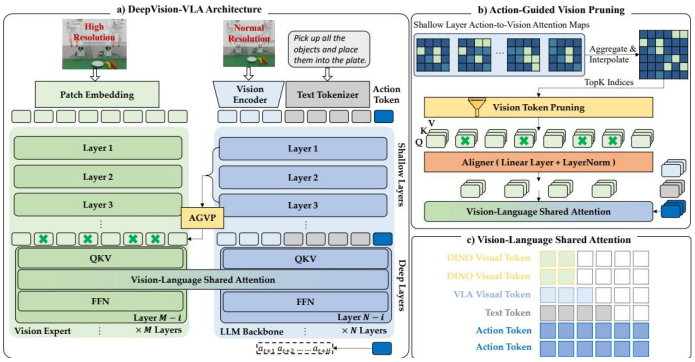

图 2：*DeepVision-VLA* 框架。*(a) Vision Expert* 通过 *VL-MoT* 与深层 *LLM* 共享注意力；*(b) AGVP* 利用浅层注意力剪枝 *Vision Expert token*；*(c)* 注意力掩码设计。

2.1 QwenVLA-OFT 基线

基线基于 **Qwen3-VL (4B)** 构建，采用并行动作预测范式与 ℓ_1 回归目标（源自 OpenVLA-OFT）。三个核心组件：

视觉编码器： SigLIP2-Large (0.3B)，使用 2D-RoPE 提供空间位置信息。输入图像 $I \in \mathbb{R}^{H\times W\times 3}$ 经 patch 化后，相邻 2×2 特征合并为单个 token，经两层 MLP 投影至 LLM 隐藏维度 d，得到 $\mathbf{V} = E_{\text{vis}}(I) \in \mathbb{R}^{N_v\times d}$。

LLM 骨干： 将视觉特征 $\mathbf{V}$、语言指令 token 和零初始化的动作 token 拼接为多模态输入序列。第 ℓ 层隐状态分解为 $\mathbf{Z}^\ell = [\mathbf{Z}_V^\ell; \mathbf{Z}_L^\ell; \mathbf{Z}_A^\ell]$，逐层更新 $\mathbf{Z}^\ell = \mathcal{F}^\ell(\mathbf{Z}^{\ell-1})$。区别于 OpenVLA-OFT 对所有 token 使用双向注意力，本文仅对**动作 token 使用双向注意力**，提示 token 保持因果注意力以保留预训练行为。

动作解码器： 两层 MLP 将最终动作嵌入 $\mathbf{Z}_A^L$ 映射为机器人动作向量 $\mathbf{a} \in \mathbb{R}^n$。

训练目标为模仿学习：

$$\theta^* = \arg\min_\theta \mathbb{E}_{(\tau,l)\sim\mathcal{D}}\left[\sum_{t=1}^{T} \ell(\pi_\theta(o_{\le t}, l), a_t)\right]$$

2.2 VL-MoT 框架

为增强深层的视觉感知，引入 **Vision Expert**（DINOv3, 0.8B），其提供比 SigLIP 更精细的空间表征，适合精确操作任务。

核心设计： 不简单拼接中间特征，而是直接暴露 Vision Expert 的 Query/Key/Value（QKV）表示，通过**共享注意力机制**与深层 VLA 层的 QKV 融合。对耦合层，Vision Expert 第 k 层特征 $\mathbf{E}^k \in \mathbb{R}^{M\times d_e}$ 与 LLM 第 ℓ 层 $\mathbf{Z}^\ell \in \mathbb{R}^{N\times d}$ 分别计算 QKV：

$$Q_E = \mathbf{E}^k W_Q^E,\ K_E = \mathbf{E}^k W_K^E,\ V_E = \mathbf{E}^k W_V^E$$

$$Q_Z = \mathbf{Z}^\ell W_Q^Z,\ K_Z = \mathbf{Z}^\ell W_K^Z,\ V_Z = \mathbf{Z}^\ell W_V^Z$$

经线性层对齐维度后，拼接并计算共享注意力：

$$Q = [Q_E; Q_Z],\ K = [K_E; K_Z],\ V = [V_E; V_Z]$$

$$A = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right), \quad H = AV$$

输出拆分回两个分支 $H = [H_E; H_Z]$，分别继续各自的 Transformer 操作。

关键设计选择： (1) Vision Expert 仅与最深 n 层 VLA 耦合（基于分析结果，$n = 16$），选取 DINOv3 最后 n 层的 QKV——深层编码高级语义和物体中心表征，与动作条件化特征最匹配；(2) Vision Expert token 保持**双向注意力**以保留预训练知识；(3) 此设计优于早期层采样和均匀采样策略。

2.3 Action-Guided Visual Pruning (AGVP)

直接融合 Vision Expert 全部特征图会引入冗余背景信息。AGVP 利用浅层 VLA 的可靠视觉定位能力进行任务导向剪枝。

在浅层集合 $\mathcal{L}_s$ 中，计算动作-视觉注意力图 $\mathbf{A}^\ell \in \mathbb{R}^{N_a\times N_v}$，先对动作 token 平均 $\mathbf{m}^\ell = \frac{1}{N_a}\sum_{i=1}^{N_a} \mathbf{A}_{i,\cdot}^\ell$，再跨层平均 $\mathbf{m} = \frac{1}{|\mathcal{L}_s|}\sum_{\ell\in\mathcal{L}_s} \mathbf{m}^\ell$。多层平均有效滤除噪声。

由于 Vision Expert 接收更高分辨率输入（512×512 vs 256×256），需插值注意力图 $\tilde{\mathbf{m}} = \mathcal{I}(\mathbf{m}) \in \mathbb{R}^{N_d}$ 以匹配分辨率。保留重要性最高的 Top-K token：$S_K = \text{TopK}(\tilde{\mathbf{m}}, K)$，剪枝后的 token $\bar{\mathbf{E}}^k = \mathbf{E}^k[S_K]$ 用于与深层 VLA 共享注意力。此策略在注入关键视觉区域的同时控制计算开销。

2.4 训练与推理

预训练： 使用 Qwen3-VL 和 DINOv3 预训练权重初始化，端到端训练。数据集整合 Open X-Embodiment、DROID、RoboMIND 等大规模跨具身数据集，含 **40 万 + 轨迹**，训练 1 个 epoch。

推理： 输入图像和语言指令 → 浅层 VLA 计算动作-视觉注意力图识别任务相关区域 → 剪枝 Vision Expert 多级特征 → 通过 VL-MoT 注入深层 → 动作解码器生成最终动作。全流程**无需额外标注或外部监督**，端到端可执行。

3. 实验结果

3.1 仿真实验（RLBench）

在 CoppeliaSim 上评估 10 个操作任务，每任务 100 条训练轨迹，Franka Panda 机器人单前视 RGB 观测。与 7 个基线对比，DeepVision-VLA 使用 VLA 分支 256×256 + Vision Expert 512×512 双分辨率，DINOv3-H 最后 16 层耦合 Qwen3VLA-OFT 最后 16 层，剪枝率 0.5。

方法	平均成功率
OpenVLA	40%
SpatialVLA	46%
CogACT	61%
$\pi_{0.5}$	65%
CoT-VLA	66%
QwenVLA-OFT (基线)	69%
HybridVLA	74%
DeepVision-VLA	**83%**

DeepVision-VLA 在 10 个任务中 8 个取得最高成功率。尤其在视觉挑战性强的任务上提升显著：**Sweep to Dustpan** 从 0.15 → 0.95（+80%）；**Wine at Rack** 从 0.65 → 0.85（+31%）。超越最强基线 HybridVLA **9%**，验证 VL-MoT + AGVP 的有效性。

3.2 消融实验

在 4 个代表性 RLBench 任务上（Close box / Close laptop / Sweep to dustpan / Phone on base），每任务 50 次 rollout。

VL-MoT 架构重要性：基线 65.5%；DINOv3 早期融合（输入层拼接）73%；中间特征对齐到冻结 DINOv3 67%；**VL-MoT 88%**——直接耦合深层 + 特征剪枝最有效。

Vision Expert 特征选择：DINOv3 前 16 层 61.5%；均匀采样 16 层 85%；**最后 16 层 88%**——深层语义更丰富、物体中心性更强。替换为 SigLIP（均匀 16 层）降至 77%，因 SigLIP 侧重图文对齐而非细粒度空间表征。

AGVP 引导机制：DINOv3 CLS token 65.5%（无提升）；指令-视觉注意力 84%；**动作-视觉注意力 88%**——动作 token 同时编码任务意图和动作条件化视觉定位，更适合操作场景。

参考层选择：单层（第 4/8/12/16 层）分别 85%/69%/82.5%/87.5%；**跨 4–19 层平均 88%**——多层引导更鲁棒。

3.3 真实世界实验

使用 Franka Research 3 + Intel RealSense D455 评估 4 个单臂任务，每任务 20 次 rollout。

方法	平均成功率
OpenVLA-OFT	71.7%
QwenVLA-OFT	74.2%
$\pi_{0.5}$	84.2%
DeepVision-VLA	**91.7%**

关键结果：**Pour coke to bottle** 两阶段均 100%（$\pi_{0.5}$ 第二步降至 70%）；**Write letter 'S'** 95%——需连续高精度空间跟踪，凸显架构优势；**Pick fruit to plate** 两步均 95%。超越最强基线 $\pi_{0.5}$ **7.5%**。

3.4 泛化实验

在 Pick fruit 和 Pour coke 任务上评估零样本泛化能力：

未见背景：加入花束等干扰物，基线 QwenVLA-OFT 下降 18%，DeepVision-VLA 仅下降 5%（Pick fruit Step 1: 0.90 vs 0.70）。视觉增强机制有效解耦被操作物体与环境噪声。

未见光照：改变阴影和非均匀光照条件，DeepVision-VLA 在 Pour coke 上保持 1.00，基线下降 22%。表明视觉增强策略实现了一定程度的光度不变性。

4. 与相关工作对比

现有 VLA 视觉增强方法大致分四类：视觉提示（RT-Trajectory 等叠加执行轨迹）、辅助视觉监督（ReconVLA 重建关键物体）、额外模态（DepthVLA 融合深度图、PointVLA 融合点云）、推理-行动范式（CoT-VLA 预测未来状态）。这些方法关注输入端或输出端，**忽视 LLM 内部视觉信息利用**。DeepVision-VLA 首次揭示深层视觉退化现象并从架构层面解决——通过 MoT 机制在 QKV 级别直接耦合视觉基础模型与 VLA 深层，比输入级融合（+8%）和特征对齐（+21%）更有效。

5. 局限性与未来方向

- Vision Expert 固定为 DINOv3，尚未探索其他视觉基础模型（如 SAM、MAE 系列）的适配效果；
- 当前仅验证单臂操作，双臂协调和灵巧手操作场景有待扩展；
- AGVP 依赖浅层注意力质量——当浅层视觉定位本身不可靠时（如极端遮挡），剪枝可能失效；
- VL-MoT 引入额外参数和计算（DINOv3 0.8B），对资源受限的实时部署场景仍需优化；
- 预训练数据规模（40 万轨迹）相对有限，扩展至更大规模数据集和更多具身平台是重要方向；
- 深层视觉退化现象的理论解释仍为开放问题——信息瓶颈或表征坍缩等机制有待进一步研究。

GigaWorld-Policy：高效的以动作为中心的世界–动作模型

Angen Ye, Boyuan Wang, Chaojun Ni, Guan Huang 等 — GigaAI, 2025

1. 动机与问题背景

视觉–语言–动作（VLA）模型基于视觉–语言模型（VLM）已取得优秀性能，但面临**监督稀疏性**的核心挑战：观测和任务条件高维且语义丰富，而动作监督信号稀疏且多样性低。模型可能依赖上下文捷径，将大量情境压缩为少数动作原型，而非学习物理一致的动作分布。

现有解决方案可分为三类，各有局限：

- **VLM-based VLA ＋ 未来视觉辅助监督**（如 World-VLA）：在 VLA 框架中预测未来视觉观测以增密监督，但 VLM 天然偏向判别式推理而非高保真生成，辅助损失难以保证预测动作的连续性和物理一致性；
- **联合动作–视频预测**（如 Motus、VideoVLA）：利用视频生成模型联合预测动作与未来视觉动态，提供密集时空先验。但推理时需迭代扩散采样生成未来视频，导致**高延迟**（Motus 推理 3231ms/步）；且视频预测误差会传播至动作解码，长时域控制尤为脆弱；
- **两阶段流水线**（如 Mimic-video）：先生成未来视频再通过逆动力学模型提取动作，继承视频预测误差且引入额外推理开销。

GigaWorld-Policy 提出**以动作为中心**的世界–动作模型（WAM）：训练时利用未来视觉动态作为推理信号和密集监督源；推理时未来视频预测为**可选项**，可直接输出动作，实现低延迟闭环控制。

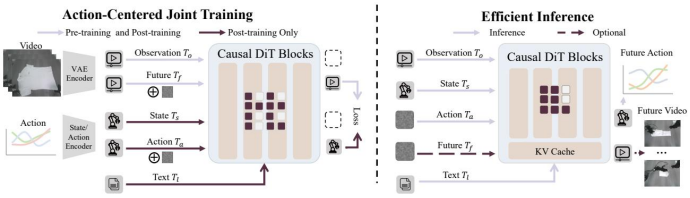

图 1：*GigaWorld-Policy* 架构总览。预训练阶段学习动作相关表示；后训练阶段联合进行动作块预测与未来视频预测作为辅助监督；推理时未来视频分支可选，实现快速推理。

2. 系统架构

GigaWorld-Policy 基于 **5B 参数的扩散 Transformer**（Wan 2.2 5B）构建，通过因果掩码方案统一动作生成与视觉动态建模。

2.1 问题形式化

在每个时间步 t，机器人接收多视角 RGB 观测 $o_t = \{o_t^v\}_{v\in S}$（$S = \{\text{left, front, right}\}$）、自然语言指令 l 和本体状态 s_t，策略预测长度为 p 的动作块 $a_{t:t+p-1}$。统一模型 g_Θ 参数化两个互补分布：

动作建模： $(a_{t:t+p-1}, c_t) \sim g_\Theta(\cdot \mid o_t, s_t, l)$，其中 c_t 为动作潜在条件信号，用于引导视觉预测。

视觉前馈动态建模： $(o_{t+\Delta}, \ldots, o_{t+K\Delta}) \sim g_\Theta(\cdot \mid o_t, s_t, l, c_t)$，$\Delta$ 为时间步长，$K = \lfloor p/\Delta \rfloor$，模型在 p 步范围内预测 K 帧未来观测。

2.2 输入 Token 构造

多视角合成： 将三个相机视角合并为单张合成图像 $o_t^{comp} = \text{Compose}(o_t^{left}, o_t^{front}, o_t^{right})$，保持各视角空间结构并促进跨视角一致性，无需修改骨干网络。未来帧采用**稀疏预测**策略，每隔 Δ 步预测一帧，在保留场景关键演变的同时减少监督冗余。

合成图像经预训练 VAE 编码为时空视觉 token T_o（当前）和 T_f（未来）；本体状态和动作经线性投影得 T_s 和 T_a；语言指令经预训练语言编码器得 T_l。

2.3 共享 Transformer 与因果注意力

不同于 MoE 设计，所有 token 类型共享**同一组 Transformer 块**的 Q/K/V 投影矩阵，紧密耦合动作 token 与视觉证据。视觉 token 使用 2D 位置编码，状态/动作 token 使用 1D 时序位置编码。

所有模态打包为统一序列 $T_t = [T_o; T_s; T_a; T_f]$，施加**分块因果注意力掩码**：

- T_s 和 T_o 可互相注意，但**不能**注意 T_a 或 T_f；
- T_a 可注意 $\{T_s, T_o\}$，但**不能**注意 T_f（防止未来帧信息泄漏至动作生成）；
- T_f 可注意 $\{T_s, T_o, T_a\}$，实现基于动作块的前馈动态预测。

语言指令 l 不参与统一自注意力序列，而是通过**交叉注意力**作为外部条件信号注入。此设计确保推理时视频预测为可选项。

3. 训练流程

3.1 课程式预训练

采用三阶段渐进式训练注入物理先验：

（1）大规模网络视频初始化： 从 Wan 2.2 5B 预训练视频模型初始化，继承多样化视频数据的时空先验。

（2）具身数据预训练： 在约 **10,000 小时**的机器人中心视频数据上进一步预训练，数据涵盖：真实机器人视频（Agibot 2500h、Open X-Embodiment 3500h、EGO4D 3500h、DROID 350h、RoboMind 300h 等）和大规模第一人称人类演示视频（EgoDex 800h）。此阶段使模型适应具身特定视角和操作相关的交互模式，提升对视角变化的鲁棒性。仅优化视频 flow matching 目标。

（3）后训练： 在目标机器人任务轨迹数据上联合优化动作预测与视觉动态建模，每个任务 50 条演示轨迹。

3.2 训练目标

基于 **Flow Matching** 优化。对模态 x（动作或未来视频 token），采样流时间 $s \sim \mathcal{U}(0,1)$ 和噪声 $\epsilon \sim \mathcal{N}(0, I)$，构造插值变量 $x^{(s)} = (1-s)\epsilon + sx$，目标速度 $\dot{x}^{(s)} = x - \epsilon$。

视频目标（z_f 为未来观测 VAE 潜变量）：

$$\mathcal{L}_{video} = \mathbb{E}_{s,\epsilon}\big[\|g_\Theta(z_f^{(s)}, s \mid T_s, T_o, T_a, T_l) - \dot{z}_f^{(s)}\|^2\big]$$

动作目标：

$$\mathcal{L}_{action} = \mathbb{E}_{s,\epsilon}\big[\|g_\Theta(a^{(s)}, s \mid T_s, T_o, T_l) - \dot{a}^{(s)}\|^2\big]$$

后训练联合损失 $\mathcal{L}_{all} = \lambda_{video}\mathcal{L}_{video} + \lambda_{action}\mathcal{L}_{action}$，其中 $\lambda_{action} = 5$，$\lambda_{video} = 1$，强调动作预测同时保留视频一致性正则化。

3.3 推理

推理时仅采样动作 token，不实例化任何未来视频 token。初始化 $a^{(0)} \sim \mathcal{N}(0, I)$，沿学习的速度场从 $s = 0$ 积分至 $s = 1$：

$$\frac{da^{(s)}}{ds} = g_\Theta(a^{(s)}, s \mid w_t), \quad s \in [0, 1]$$

得到 $a^{(1)}$ 后解码为连续动作块。动作块长度 $p = 48$。如需未来预测，可启用视频分支或复用动作去噪的 KV 缓存。

4. 实验结果

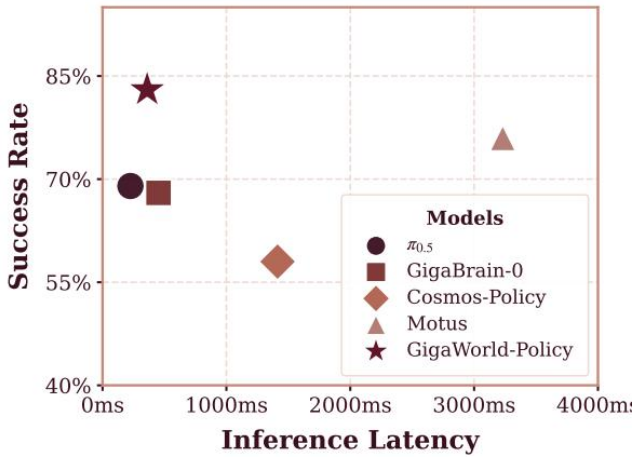

图 2：*GigaWorld-Policy* 在推理频率与真实世界成功率上的对比。

4.1 推理速度对比

方法	延迟 (ms)	仿真 SR	真实 SR
$\pi_{0.5}$ (VLA)	225	0.48	0.69
GigaBrain-0 (VLA)	452	–	0.68
Cosmos-Policy (WAM)	1413	–	0.58
Motus (WAM)	3231	0.88	0.76
GigaWorld-Policy	**360**	**0.86**	**0.83**

GigaWorld-Policy 实现 **360ms/步**推理延迟，相比 Motus 加速 **9**×，同时真实世界成功率提高 **7%**（0.76 → 0.83）。相比 $\pi_{0.5}$，延迟仅增加 60% 但真实世界性能提升 **14%**。

4.2 RoboTwin 2.0 仿真实验

在 50 个代表性操作任务上评估（含域随机化：背景、桌面杂物、桌高扰动、光照变化），每任务 2500 条 clean + 25000 条随机化演示训练。GigaWorld-Policy 平均 SR 达 **0.86**（Clean 0.87 / Rand 0.85），与 Motus（0.88/0.87）性能可比，但推理快 9×。相比 $\pi_{0.5}$（0.43/0.44），提升超过 **44 个百分点**。代表性任务：Adjust Bottle 1.00/1.00、Place Cans Plasticbox 1.00/1.00、Place Fan 0.92/0.94。在 RoboTwin 2.0 上相比 $\pi_{0.5}$，性能提升 **95%**。

4.3 真实世界实验

在 AgileX PiPER 6-DoF 机械臂上测试四个任务（每方法每任务 20 次试验，每次最多 5 次尝试）：清理桌面、扫描二维码、叠碗、扫垃圾。GigaWorld-Policy 在所有任务上均优于或持平基线。推理速度快带来**更高的闭环控制频率**，减少控制延迟、提高有效动作更新率和误差修正能力。

4.4 数据效率

GigaWorld-Policy 仅需 **10% 的训练数据**即可达到 $\pi_{0.5}$ 使用全部数据时的最高成功率，表明世界模型学到的视频先验表示显著提升了样本效率。

5. 消融实验

5.1 预训练组件消融

视频模型初始化	具身数据预训练	SR
×	×	0.45
✓	×	0.57
×	✓	0.73
✓	✓	**0.83**

从零训练 SR 仅 0.45；视频模型初始化提升至 0.57（+12%）；仅具身数据预训练达 0.73(+28%)；两者组合达 **0.83**(+38%)，表明两者提供**互补增益**。随具身数据比例增加，SR 从 57% 稳步提升至 83%。

5.2 未来帧预测数量

固定动作块长度 $p = 48$，变化采样间隔 Δ，预测 $K = \lfloor 48/\Delta \rfloor$ 帧未来帧：

Δ	0	4	8	**12**	24	48
SR	0.60	0.76	0.78	**0.83**	0.80	0.76

$K = 0$（无未来视频预测）退化为纯动作解码器，SR 仅 0.60。启用前馈动态建模后 SR 提升至 0.83（**+23%**），表明预期未来观测为决策提供有用时间先验。但过于密集的预测（$\Delta = 4$, $K = 12$）反而性能下降，说明**适度的未来建模即可充分提供信息**，过长预测范围回报递减。最优 $\Delta = 12$（$K = 4$ 帧）。

5.3 因果注意力掩码消融

对比因果掩码与全自注意力：SR 分别为 0.83 vs 0.81；视频生成质量 PSNR 28.41 vs 27.87、SSIM 0.901 vs 0.892。因果掩码更优因其强制了物理上有意义的因式分解——动作预测与前馈视觉动态分离。全自注意力下动作 token 可注意未来帧 token，引入信息泄漏，削弱动作条件化的动态学习。同时因果设计确保推理时视频分支可选。

6. 与现有方法的核心区别

- **vs. VLM-based VLA**（$\pi_{0.5}$ 等）：引入视频生成模型作为骨干，提供密集时空监督而非仅依赖稀疏动作标签，仿真性能提升 44%+；
- **vs. 联合 WAM**（Motus 等）：通过因果掩码使未来视频预测在推理时可选，避免迭代扩散采样的高延迟（9× 加速）和视频预测误差传播；
- **vs. 两阶段 WAM**（Mimic-video）：单模型端到端训练，无需独立的逆动力学模型，避免流水线误差累积；
- **课程式预训练**：从通用视频生成模型 → 具身数据预训练 → 目标机器人后训练，充分利用互补数据源的层级知识注入。

7. 局限性与展望

- 当前仅在 PiPER 6-DoF 机械臂和 RoboTwin 2.0 仿真平台上验证，跨具身形态（双臂、灵巧手、移动操作）的泛化有待探索；
- 虽推理延迟大幅降低至 360ms，但对于高频率实时控制场景仍有改进空间；
- 视频动态建模作为辅助监督的最优平衡点（帧数、步长）可能随任务复杂度变化，需要自适应机制；
- 预训练依赖大规模数据（~10,000 小时）和 6000 GPU 小时计算，资源需求显著；
- 未来方向包括：更强的 3D 世界模型集成、多任务跨具身统一策略、强化学习微调以及更高效的推理加速。

Temporal Gains, Spatial Costs：重新审视多模态大语言模型中的视频微调

Zhang[1,4], Li[2,3], Hei[2,3], Tao[2], Dai[2,3], Yan[2,3] 等 — [1]SJTU, [2]HKUST(GZ), [3]HKUST, [4]CityU, [5]FDU, [6]HIT, [7]TJU, 2025

1. 核心动机与问题

多模态大语言模型（MLLMs）通常经历多阶段训练，其中**视频监督微调**（Video-SFT）是提升视频理解能力的关键步骤。由于视频可自然视为图像序列，业界普遍假设 Video-SFT 不仅增强时序建模，还应至少保持静态图像理解能力。然而，本文通过系统实验揭示了一个截然不同的现象：

- Video-SFT **可靠提升**视频基准性能；
- 但**经常导致**静态图像基准性能下降或收益有限；
- 该权衡在不同架构、参数规模和帧采样设置下**一致存在**。

作者将这一图像–视频权衡现象命名为 **"时序陷阱"（Temporal Trap）**，揭示当前统一训练流水线尚未实现真正的图像–视频协同。

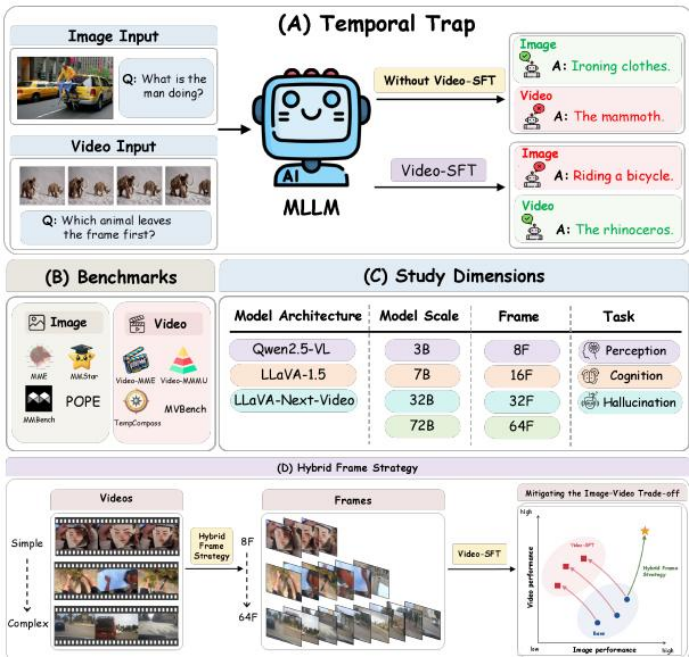

图 1：时序陷阱概览。*(A) Video-SFT* 提升视频性能但削弱空间能力；*(B)* 使用的图像/视频基准；*(C)* 研究维度；*(D) Hybrid-Frame* 自适应帧分配策略。

2. 实验设计

2.1 研究维度

沿三个关键维度系统实验：**模型架构**（Qwen2.5-VL、LLaVA-Next-Video、LLaVA-1.5）；**模型规模**（Qwen2.5-VL 的 3B/7B/32B/72B）；**帧采样设置**（Video-SFT 中均匀采样 8/16/32/64 帧）。

2.2 数据与评估

训练数据基于 LLaVA-Next-Video-178K，精选 20,000 个视频，来源 10 个不同数据集（VidOR、YouCook2、Charades、ActivityNet 等），覆盖描述、开放问答和选择题三种指令格式。图像基准包括 MME、MM-Star、MMBench、POPE；视频基准包括 Video-MME、MVBench、TempCompass、Video-MMMU，覆盖粗/细粒度感知、认知推理和幻觉检测。

3. 时序陷阱：三维度实验分析

3.1 模型架构的影响

所有架构在 Video-SFT 后均展现一致趋势：视频基准几乎全面提升，而大多数图像基准出现明显退化。LLaVA-1.5 图像性能下降最大（如 MME 中名人识别下降 80.59 分），LLaVA-Next-Video 差距较小，Qwen2.5-VL 相对稳定（得益于更强的时空对齐和混合图像–视频预训练），但时序陷阱在**所有架构中持续存在**。

3.2 模型规模的影响

增大模型规模可部分缓解 Video-SFT 对图像理解的负面影响，但并非严格单调。3B→32B 范围内，图像基准在 Video-SFT 后仍有明显波动；72B 模型的后 SFT 性能与基线模型大致相当甚至略有提升。注意力可视化进一步证实：随模型增大，目标对象的注意力从分散变为集中——更大模型能更好地在时序陷阱下保持稳定的空间表征。然而 72B 的额外成本在许多场景中难以承受。

3.3 训练帧数的影响

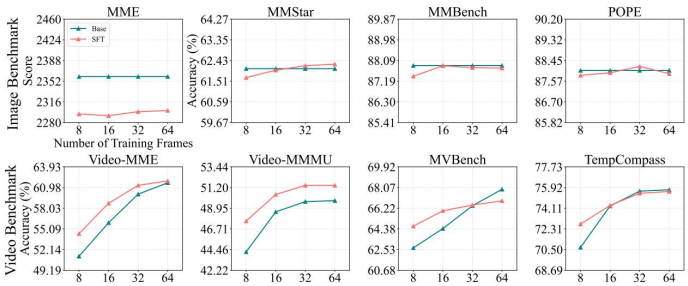

图 2：*Qwen2.5-VL-7B* 在 *8/16/32/64* 帧 *Video-SFT* 下图像与视频基准性能对比。

增加训练帧数**一致提升**视频基准性能，但收益逐渐饱和。对于图像基准：MME 在所有帧设置下均低于基线；MMStar 随帧数增加逐渐提升但增速放缓；MMBench 和 POPE 呈现**先升后降**趋势。这表明冗余时序信息在 Video-SFT 中会破坏模型的静态视觉表征，导致时序陷阱。

4. 理论分析

4.1 符号与前提

设 $\boldsymbol{\theta} \in \mathbb{R}^d$ 为统一 MLLM 的可训练参数，$\Phi_m(v)$ 为从视频 v 提取 m 帧的采样算子。定义图像与视频的总体目标：

$$\mathcal{L}_{\text{img}}(\theta) = \mathbb{E}_{(x,q,y)\sim\mathcal{D}_{\text{img}}}[\ell(f_\theta(x,q),y)]$$

$$\mathcal{L}_{\text{vid}}^{(m)}(\theta) = \mathbb{E}_{(v,q,y)\sim\mathcal{D}_{\text{vid}}}[\ell(f_\theta(\Phi_m(v),q),y)]$$

Video-SFT 梯度步：$\theta^+ = \theta - \eta g_{\text{vid}}^{(m)}$。定义**梯度对齐**：$\text{Align}(\mathcal{L}_a,\mathcal{L}_b;\theta) := \langle \nabla_\theta \mathcal{L}_a, \nabla_\theta \mathcal{L}_b \rangle$。

4.2 命题 1：图像损失增加的充分条件

在局部光滑性假设（Hessian 范数有界 $\|H_{\text{img}}\|_2 \le \beta_{\text{img}}$）下，若梯度**负对齐**：

$$\langle g_{\text{img}}, g_{\text{vid}}^{(m)} \rangle < 0$$

则存在 $\eta_0 > 0$ 使得对所有 $0 < \eta < \eta_0$，一步 Video-SFT 更新将增加图像损失 $\mathcal{L}_{\text{img}}(\theta^+) > \mathcal{L}_{\text{img}}(\theta)$。具体地，$\eta < \frac{-2\langle g_{\text{img}}, g_{\text{vid}}^{(m)} \rangle}{\beta_{\text{img}} \|g_{\text{vid}}^{(m)}\|_2^2}$ 即可。同时由下降引理，视频目标在 $\eta < 2/\beta_{\text{vid}}^{(m)}$ 下仍然下降——视频改进与图像退化可**同时发生**。

4.3 命题 2：时序预算的梯度偏差

将视频梯度分解为：$g_{\text{vid}}^{(m)} = g_{\text{sh}} + \alpha(m) g_{\text{tmp}} + \varepsilon^{(m)}$，其中 g_{sh} 为共享视觉分量（与图像正对齐），g_{tmp} 为时序专有分量（与图像非正对齐），$\alpha(m)$ 随 m 非递减。则期望对齐为 $\rho_{\text{sh}} - \alpha(m)\rho_{\text{tmp}}$。存在离散阈值 $m^\star$ 使得 $m < m^\star$ 时期望对齐为正（合作），$m \ge m^\star$ 时为非正（冲突）。**增加帧数可将迁移从合作翻转为冲突**。

4.4 命题 3：自适应帧分配的理论正当性

引入样本级最小充分时序预算 $m_{\min}(v,q)$，满足 $Y \perp\!\!\!\perp V \mid \Phi_{m_{\min}}(V,Q), Q$。对任意 $m \ge m_{\min}$ 的冗余帧不改善与图像目标的对齐，但增加视频梯度的二阶矩。选择 $m(v,q) = m_{\min}(v,q)$ 可最小化基于光滑性的图像损失增加上界。**理论证明样本自适应帧分配优于全局固定帧数**。

5. Hybrid-Frame 策略

基于命题 3 的自适应预算原则，实现指令感知的 Hybrid-Frame 策略。比较三种帧分配方案：

- **DINOv2-based**：基于帧间相似度，不够可靠（图像基准仍下降）；
- **Qwen2.5-VL-3B-based**：VLM 预测器，表现竞争力强；
- **Qwen3-VL-8B-based**：最佳整体性能。

VLM 预测器综合评估事件持续时间、运动连续性、因果关系、物体交互和细粒度视觉属性五个维度，自适应决定 8/16/32/64 帧。实际帧分布：57,604 样本 8 帧，11,394 样本 16 帧，5,365 样本 32 帧，137 样本 64 帧，平均约 11 帧。

设置	MMStar	POPE	V-MME	V-MMMU
Base	62.07	88.03	51.19	44.22
SFT-8F	61.67	87.82	54.41	47.56
Hybrid-8F	**62.33**	**88.20**	54.96	47.22
SFT-16F	62.00	87.93	58.74	50.44
Hybrid-16F	**62.33**	**88.20**	58.15	51.78
SFT-32F	62.20	88.20	61.30	51.44
Hybrid-32F	**62.33**	**88.20**	61.52	55.12
SFT-64F	62.27	87.89	61.93	51.44
Hybrid-64F	**62.33**	**88.20**	60.93	**55.91**

表 *1*：*Qwen2.5-VL-7B* 不同帧策略统一对比。*Hybrid-Frame* 在所有帧预算下图像指标最优，视频性能保持竞争力。

关键发现：Hybrid-Frame 在 MMStar 和 POPE 上达到最佳，**超过所有固定帧预算**（含 32F/64F）的 Video-SFT。在 LLaVA-1.5-7B 上同样有效：MMStar 从 28.47–29.40 提升至 32.47，POPE 从 71.69–73.40 提升至 75.66，验证策略的跨架构通用性。

6. 细粒度任务分析

Video-SFT 对不同视觉能力的影响**高度非均匀**：

- **细粒度感知**受损最严重：MME 中名人识别下降 54.71–80.59 分；MMStar 中属性与名人识别下降 3.39–6.78；
- **OCR 能力**显著退化：MME 中 OCR 下降 30.00（Qwen2.5-VL）至 97.50 分（LLaVA-1.5）；
- **认知推理**展现鲁棒性：Qwen2.5-VL 的数值计算（+7.50）、代码推理（+7.50）、文本翻译（+7.50）在 Video-SFT 后**反而提升**，表明视频数据中的因果/序列逻辑可能有益于推理能力。

输入模态差异实验进一步证实：将单张图像复制多帧模拟视频输入后，退化仍然持续（排除训练–推理模态不匹配假说）；且冗余帧数越多性能越差（Base 模型 MME：8 帧 2360 → 64 帧 2272），为 Hybrid-Frame 策略提供了额外支持。

7. 跨帧推理鲁棒性

在实际部署中常因延迟约束以 8 帧推理。实验表明以 16/32/64 帧训练但 8 帧推理时，MVBench 性能显著下降（从 64.62 降至 63.05），而 Hybrid-Frame 保持 63.94% 的高鲁棒性。Video-MME 上 Hybrid-Frame 亦达到 54.96（↑3.77），表现出强泛化能力。

8. 讨论与局限

- **核心发现**：Video-SFT 并非 “免费午餐”——时序增益伴随空间代价，这一权衡在架构、规模和帧数维度上一致存在；
- **理论贡献**：形式化了共享参数优化下图像–视频梯度冲突的充分条件，解释了帧预算如何加剧冲突，并为自适应帧分配提供数学正当性；
- **实践价值**：Hybrid-Frame 策略以极低成本（平均仅 11 帧 vs. 固定 32/64 帧）部分缓解时序陷阱，同时减少冗余计算；
- **局限**：研究覆盖代表性但非所有 MLLM 架构；未涉及流式/在线训练；Hybrid-Frame 仍为启发式而非完全理论最优；仅基于标准基准，未涵盖流式输入和交互式多模态推理；
- **未来方向**：融合视觉内容感知（帧间特征相似度）与多模型共识机制的连续帧分配；探索在统一训练中实现真正模态协同的方法。

LoST：面向 3D 形状的语义层级分词

Dutt[1,2], Shi[2], Guerrero[2], Huang[2], Ceylan[2], Mitra[1,2], Chen[2] — [1]UCL, [2]Adobe Research, 2025

1. 核心思想与动机

Token 化是生成模型的基础技术，对自回归（AR）3D 生成尤为关键。当前 SOTA 方法主要依赖**几何细节层级**（Level-of-Detail, LoD）层次结构（八叉树、渐进网格等），但这些空间层次结构最初为渲染和压缩设计，存在两大系统性缺陷：

- **粗尺度 token 膨胀**：即便经几何简化，早期阶段仍需大量空间 token 才能勾勒基本骨架，使 AR 模型处于高困惑度状态，削弱采样效率；
- **早期解码不可用**：激进几何简化导致粗层级过于粗糙，缺乏几何和语义完整性。“任意前缀生成”产出不可用的中间形状，限制 AR 工作流适用性。

本文提出 **Level-of-Semantics Tokenization (LoST)**：按**语义显著性**排序 token 序列 $\{\tau_1, \ldots, \tau_K\}$，使得早期前缀 $\tau_{\leq k}$ 即可解码为完整、可信的形状并捕获原始形状的主要语义，后续 token 逐步细化实例级几何与语义细节。为训练 LoST，引入**关系型距离间对齐**（RIDA）损失，将 3D 形状潜空间的关系结构与 DINO 语义特征空间对齐。

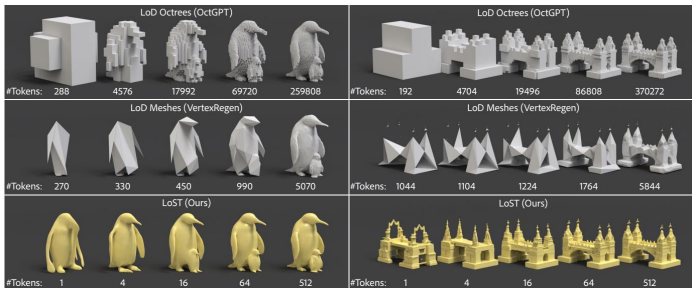

图 1：*LoST* 与 *LoD* 基线对比。*LoST* 的早期前缀即可解码为语义完整的形状，而 *OctGPT* 和 *VertexRegen* 的早期阶段产出几何/语义上不可信的形状。*LoST* 仅需极少 *token* 即可超越基线。

核心贡献：(1) 学习按语义显著性排序的 3D 形状 token，早期前缀可解码为完整可识别形状；(2) 设计 RIDA 损失，直接在 triplane 潜空间中提供语义监督；(3) 以简单 GPT-style Transformer 实现 SOTA 3D AR 生成，仅需先前方法 **0.1%–10%** 的 token 数量。

2. 系统架构

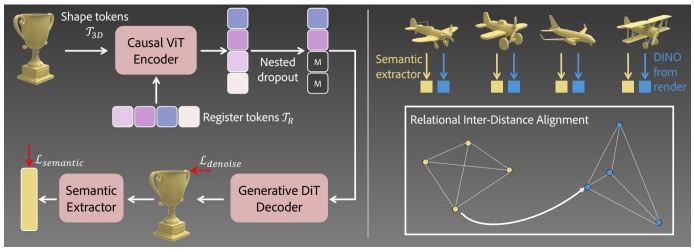

图 2：*LoST* 概览。左：编码器将 *3D* 形状潜表示映射为按语义显著性排序的 *token* 序列，条件生成式 *DiT* 解码器从任意前缀重建完整潜表示。右：语义提取器通过 *RIDA* 预训练，对齐 *3D* 潜空间与 *DINO* 特征空间的关系结构。

2.1 LoST 编码器

以 Direct3D 的 VAE 编码 3D 形状为 triplane 表示 $\mathbb{R}^{C\times H\times W\times 3}$（$C=16$，$32\times 32\times 3=3072$ 个特征向量）。使用 **ViT 编码器**对 patch 化 triplane 处理，但关键创新在于引入一组 **register token** $\mathcal{T}_R$——可学习参数，与 triplane token 拼接后通过注意力层处理。注意力掩码确保 register token 可注意到原始 token 但**反向不可**。编码后仅保留 register token，有效将几何信息重构为学习得到的 1D token 序列。

为确保 $\mathcal{T}_R$ 形成层级结构，采用两项关键策略：

- **因果掩码**：在 ViT 编码器中对 $\mathcal{T}_R$ 施加因果掩码，鼓励层级结构；
- **嵌套 Dropout**：训练时随机保留前缀（长度为 2 的幂：$[1, 2, 4, 8, \ldots, k]$），强制模型将粗信息前置至前几个 token，后续 token 编码更精细细节。

层级类型取决于损失函数：几何损失给出从低频到高频的几何层级（类似谱分析），语义损失给出语义层级。编码器使用 768 个 triplane token 和最多 $k=512$ 个 register token。

2.2 LoST 解码器

目标是从 register token 的任意前缀解码完整 3D 潜表示。极少 token 时存在固有歧义，确定性解码会导致模糊粗糙重建。因此将任务重构为**生成问题**：训练 **Diffusion-Transformer (DiT)** 模型 $\mathcal{G}$，以可变长度 $\mathcal{T}_R$ 前缀为条件，通过交叉注意力机制，从噪声 shape token 预测添加的噪声，生成完整信号。随前缀长度增加，生成逐渐过渡为重建（更长前缀减少歧义）。

3. RIDA：关系型距离间对齐

3.1 问题：3D 缺乏直接语义监督

2D 图像领域的 FlexTok 和 Semanticist 依赖 REPA 损失——将扩散模型内部表示与 DINO 特征对齐。但 3D 形状缺乏可直接比较的语义特征提取器。直接将 3D 生成模型内部表示与 2D DINO 特征对齐效果差，原因是两种表示的空间布局和固有维度不同。通过多视角渲染对齐维度则计算代价过高。

3.2 核心洞察与方法

关键洞察：只需对齐两个表示空间中对应样本集的**对比性相对距离**，而非回归绝对值。定义从 triplane 潜空间到新特征空间的映射，使相对距离匹配 DINO 空间。

教师空间：DINO 特征（空间 token $\mathbf{S}_i^t \in \mathbb{R}^{K\times d}$ + 全局嵌入 $\mathbf{z}_i^t \in \mathbb{R}^D$）。**学生空间**：Transformer 编码器 f_θ 将 triplane 编码 $\mathbf{X}_i$ 映射为语义空间网格 $\mathbf{S}_i^s$ 和全局嵌入 $\mathbf{z}_i^s$。

RIDA 损失由三部分组成：

(1) 全局关系对比 $\mathcal{L}_{\text{global}}$：用教师空间挖掘正/负样本集 $\mathcal{Z}_i^+$、$\mathcal{Z}_i^-$，采用多正样本 InfoNCE 损失：

$$\mathcal{L}_{\text{global}} := -\mathbb{E}_{\mathbf{z}_i\in\mathcal{B}}\left[\log \frac{\sum_{\mathbf{z}_j\in\mathcal{Z}_i^+}\exp(c_{ij})}{\sum_{\mathbf{z}_k\in(\mathcal{Z}_i^+\cup\mathcal{Z}_i^-)}\exp(c_{ik})}\right]$$

其中 $c_{ij}=\langle \mathbf{z}_i, \mathbf{z}_j\rangle$ 为余弦相似度。

(2) 实例间排序蒸馏 $\mathcal{L}_{\text{rank}}$：对比损失丢弃了教师空间内丰富的连续关系结构。受 RKD 启发，对每个锚点的相似度向量进行 z-score 标准化后匹配：

$$\widetilde{\mathbf{c}}_i^s = \frac{\mathbf{c}_i^s - \mu(\mathbf{c}_i^s)}{\sigma(\mathbf{c}_i^s)}, \quad \widetilde{\mathbf{c}}_i^t = \frac{\mathbf{c}_i^t - \mu(\mathbf{c}_i^t)}{\sigma(\mathbf{c}_i^t)}$$

$$\mathcal{L}_{\text{rank}} := \mathbb{E}_{\mathbf{z}_i\in\mathcal{B}}\left[\|\widetilde{\mathbf{c}}_i^s - \widetilde{\mathbf{c}}_i^t\|_2^2\right]$$

数学上等价于最大化 Pearson 相关系数——通过消除每锚点均值和标准差，纯优化**相对邻域排序**。

(3) 空间结构蒸馏 $\mathcal{L}_{\text{spatial}}$：蒸馏实例内 token 亲和关系。计算自亲和矩阵 $\mathbf{A}_i[k,\ell] = \langle \mathbf{S}_{i,k}, \mathbf{S}_{i,\ell}\rangle$，行 softmax 后最小化 KL 散度：

$$\mathcal{L}_{\text{spatial}} := \mathbb{E}_{i,k}\left[D_{\text{KL}}(\mathbf{a}_{i,k}^t \| \mathbf{a}_{i,k}^s)\right]$$

最终预训练目标：$\mathcal{L}_{\text{RIDA}} = \lambda_g\mathcal{L}_{\text{global}} + \lambda_r\mathcal{L}_{\text{rank}} + \lambda_s\mathcal{L}_{\text{spatial}}$，其中 $\lambda_g=1.0$，$\lambda_r=1.0$，$\lambda_s=0.5$。

3.3 语义引导的 LoST 训练

预训练的 f_θ 作为感知损失引导 DiT 生成器 $\mathcal{G}$：

$$\mathcal{L}_{\text{semantic}} := \mathbb{E}_{t,\mathbf{X}_0,\epsilon}\left[1 - \langle f_\theta(\hat{\mathbf{X}}_0), f_\theta(\mathbf{X}_0)\rangle\right]$$

最终训练目标：$\mathcal{L} = \mathcal{L}_{\text{denoise}} + \lambda_{\text{semantic}}\mathcal{L}_{\text{semantic}}$（$\lambda_{\text{semantic}}=1.0$）。

4. LoST-GPT：连续空间自回归生成

区别于先前工作，LoST **不量化** tokenizer 输出，保持 $\mathcal{T}_R$ 在连续空间。训练 GPT-style Transformer（基于 LlamaGen 架构），采用**扩散损失**（而非交叉熵）进行连续空间 next-token

预测：每个位置 Transformer 预测条件向量，小型 MLP 扩散头将其映射为最终 token 分布。条件生成使用 OpenCLIP 嵌入，前缀接入输入序列。仅在 **128 个 token** 上训练即达到 SOTA 性能。

5. 实验设置

训练数据：非使用 Objaverse，而是通过 Direct3D 的 image-to-3D 流水线自行生成 300k 形状。先用 Gemini 2.5 Pro 生成多样化提示词，Flux.1 合成图像，再提升为 3D。

模型配置：ViT 编码器（深度 12，维度 768，16 头）；register token 投影至 32 维（信息瓶颈）；DiT 解码器（深度 24，维度 1024，16 头）；均使用 2×2 patch 化。8×A100 训练 250 epochs。RIDA 学生 Transformer（深度 12，维度 768，8 头）训练 100 epochs 蒸馏冻结 DINOv2 ViTB14。

评估数据集：独立策划 1k 未见形状测试集。用 Step1X-3D（基于 3DShape2VecSet——与 LoST 使用的 triplane 表示不同）生成，确保评估中立性。

6. 核心实验结果

6.1 Token 化重建评估

方法 / Token 数	CD↓	FID↓	DINO↑
OctGPT ∼219	16.923	341.2	0.382
OctGPT ∼239k	0.470	88.5	0.695
VertexRegen ∼2730	4.290	186.6	0.463
VertexRegen ∼7530	0.034	86.1	0.791
LoST 1 token	2.271	**31.6**	**0.731**
LoST 4 tokens	1.328	**29.3**	**0.765**
LoST 16 tokens	0.723	**26.6**	**0.814**
LoST 64 tokens	0.382	**21.1**	**0.880**
LoST 512 tokens	0.234	**13.6**	**0.921**

LoST 在语义指标（DINO、FID）和几何指标（CD）上全面显著超越基线，尤其在**低 token 预算**下优势巨大。仅用 1–4 个 token 即常超越基线的数千 token 结果。单个 LoST token（FID=31.6）已远优于 OctGPT 239k token（FID=88.5）的语义重建质量。

6.2 自回归生成评估

方法	Token 数	FID↓	DINO↑
OctGPT	∼50,000	66.93	—
Llama-Mesh	∼3,758	118.58	—
ShapeLLM-Omni	1,024	48.70	0.680
LoST-GPT	**128**	**34.25**	**0.758**

LoST-GPT 以仅 128 个 token（总维度成本 128×32＝4096，而 ShapeLLM-Omni 为 1024×3584＝3.67M）**大幅超越所有竞争方法**，FID 降低 29.7%（vs. ShapeLLM-Omni），DINO 提升 11.5%。值得注意的是 ShapeLLM-Omni 是两阶段方法（AR 预测粗体素 +Trellis 精细化），即便有此优势仍被 LoST-GPT 超越。

6.3 语义检索评估

RIDA 特征在形状检索中显著优于原始 triplane 特征和直接回归基线。OOD 测试集上 mAP@3 从 17.47%（triplane）提升至 **28.28%**（RIDA）；分布内集合上从 16.42% 提升至 **44.28%**。直接回归 DINO 特征的基线因优化停滞而失败，验证了 RIDA 关系对齐策略的必要性。

7. 消融实验

RIDA 消融：无 RIDA 时，低 token 区间语义质量显著下降。1 个 token 时 DINOv2 相似度从 0.556 降至 0.528，512 token 时从 0.875 降至 0.867。RIDA 不影响几何重建（CD 相近），但大幅增强语义对齐。此外 RIDA 加速训练约 **40%**，作为稳定因子抵消嵌套 dropout 引入的训练波动。

扩展至其他 3D 表示：LoST 在 TRELLIS 潜空间上同样有效——将 16^3 体素网格重塑为 64^2 2D 网格后，LoST 仍能产出语义排序的变长表示。512 token 时 TRELLIS 版 CD=0.345，DINO=0.801，验证了方法的**表示无关性**。

8. 讨论与局限

- **核心贡献**：首个按语义显著性排序 3D 形状 token 的框架，使短前缀即可解码完整语义形状；RIDA 损失创造性地桥接 3D 潜空间与 2D 语义空间；以极少 token（128）实现 SOTA AR 3D 生成；
- **表示依赖**：当前基于 VAE triplane 潜表示实例化，扩展至 Gaussian Splats 等其他 3D 表示为自然下一步；
- **解码开销**：使用扩散解码器从 AR 生成 token 产出最终潜表示，相较纯 AR 解码增加计算需求；
- **少 token 区间**：极少 token 时仍可能出现伪影（2D 语义优先 tokenizer 亦有此问题），未来可通过拓扑感知正则化和部件一致性约束强化；
- **固定目标长度**：当前 AR 生成器使用固定目标长度，添加 EOS token 和复杂度感知停止策略（简单形状短、复杂形状长）为自然扩展方向。