QZPaper Huggingface Daily

2026-03-20

---

1. **VEGA-3D：释放视频生成模型中的隐式 3D 先验以增强场景理解**
   VEGA-3D 通过重新利用预训练视频扩散模型作为潜在世界模拟器，隐式提取 3D 空间先究，无需显式 3D 监督即可为多模态大模型注入稠密几何线索，解决其空间推理能力不足的问题。
2. **SAMA：面向指令引导视频编辑的分解式语义锚定与运动对齐**
   SAMA 采用分解式设计将指令引导视频编辑分为语义锚定和运动对齐两个互补阶段，通过类型嵌入和两阶段训练实现编辑保真度与时序一致性的平衡，无需依赖外部 VLM 先验。
3. **FASTER：重新思考实时 Flow VLA 的反应延迟瓶颈**
   FASTER 系统分析了 action chunking 策略中反应时间的本质，提出即插即用的加速方案将即时动作采样迭代压缩为单步，无需修改架构或额外训练即可实现 10 倍推理加速。
4. **3DreamBooth：高保真 3D 主体驱动视频生成模型**
   3DreamBooth 通过 1 帧单视角训练范式自然旁路时间注意力将隐式 3D 先验绑定到特定主体，配合 3Dapter 实现多视角条件注入，从少量参考图生成视角一致的高保真视频。
5. **MoTok：基于扩散的离散运动分词器——桥接语义与运动学条件**
   MoTok 提出感知-规划-控制三阶段框架，将运动生成分工为离散 token 处理语义抽象和扩散模型负责细粒度重建，实现语义条件与精细运动学约束的统一融合。
6. **MonoArt：基于渐进结构推理的单目铰接 3D 重建**
   MonoArt 提出渐进结构推理范式，将视觉观察逐步转化为规范几何、结构化部件表示、运动感知嵌入，无需多视图或预定义模板直接从单张图像重建结构化的可操纵铰接 3D 模型。
7. **CubiD：基于高维表征 Token 的立方离散扩散视觉生成**
   CubiD 首次针对高维表征 token 提出立方离散扩散方法，通过逐维量化和空间维度轴上的细粒度 mask 预测，统一了多模态理解与生成的高维 token 空间。
8. **LVOmniBench：面向长音视频理解的全模态 LLM 评估基准**
   LVOmniBench 构建了 275 个长视频基准（10-90 分钟，总计 140 小时）和 1014 个严格人工标注的多层次 QA 对，首次专门评估 OmniLLM 在长时音视频联合理解上的能力，时长超越现有基准 6-20 倍。
9. **Memento-Skills：让智能体设计智能体**
   Memento-Skills 通过外部技能记忆单元与有状态反思决策过程实现智能体的持续自进化，无需更新 LLM 参数即可从部署经验中学习，构建能够自主改进的任务特定智能体。
10. **F2LLM-v2：面向多语言世界的包容、高性能、高效嵌入模型**
    F2LLM-v2 发布了支持 200+ 语言的 8 种规模开源多语言嵌入模型，整合 6000 万高质量样本覆盖 282 种语言，在多个 MTEB 基准排名第一，彻底改善了嵌入研究中的英语中心偏差与透明度缺失问题。

VEGA-3D：释放视频生成模型中的隐式 3D 先验以增强场景理解

Wu[1], Liang[1†], Feng[1], Xia[2], Zhang[2], Li[2], Tan[2], Bai[1] — [1] 华中科技大学, [2] 百度, 2025

1. 动机与核心思想

多模态大语言模型（MLLM）在语义理解方面表现优异，但普遍存在**空间盲区**——在细粒度几何推理和物理动态理解上能力不足。现有解决方案遵循两种显式范式：（1）直接使用点云/深度等**显式 3D 模态**，受限于高质量 3D 数据的稀缺性；（2）通过额外重建或蒸馏将 2D 特征提升至 3D 空间的**几何脚手架**方法，需复杂多阶段训练。

本文提出一种**范式转移**：利用大规模视频生成模型中的**隐式空间先验**。核心假设是——为了合成时序一致的视频，生成模型必须隐式学习到鲁棒的 3D 结构先验和物理规律：遮挡需要持久的物体身份、相机运动揭示深度相关的视差运动、交互需遵循一致的动力学。这些约束促使潜在表示编码了几何一致的结构与运动，形成无需显式 3D 监督的强 3D 先验。

VEGA-3D（Video Extracted Generative Awareness）是一个**即插即用**框架，将预训练视频扩散模型重新利用为**潜在世界模拟器**（Latent World Simulator），通过噪声注入提取中间层时空特征，并经 token 级自适应门控融合机制与语义表示整合，在无显式 3D 监督下为 MLLM 注入稠密几何线索。

2. 系统架构

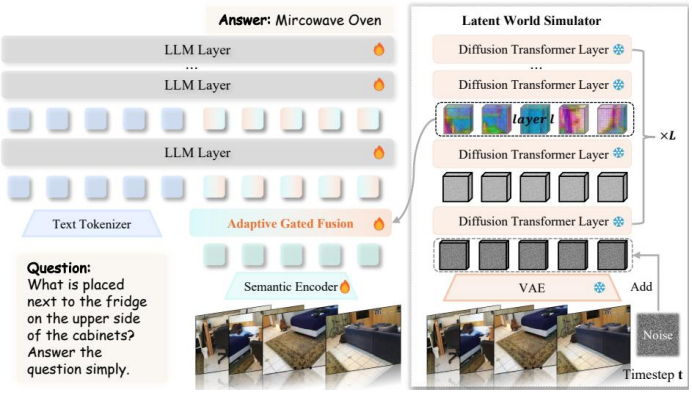

图 1：*VEGA-3D* 框架总览。冻结的视频生成模型作为潜在世界模拟器提取隐式 *3D* 先验，通过自适应门控融合与语义流动态整合。

框架采用**双分支视觉编码**，协同判别式编码器（SigLIP）的高层语义能力与生成式视频扩散模型（Wan2.1）的稠密 3D 结构先验，包含三个逻辑阶段。

2.1 3D 感知分析：多视图特征一致性

作者引入**多视图对应分数**（Multi-view Correspondence Score）量化评估不同特征骨干的几何能力。利用 ScanNet 数据集的带位姿 RGB 帧和稠密深度图，将各视图编码器特征投影到共享全局体素网格，对同一体素 m 在不同视图 v_i, v_j 中的特征向量计算余弦相似度：

$$S_{\text{voxel}}^{(m)} = \frac{\mathbf{h}_{m,v_i}^{\top}\mathbf{h}_{m,v_j}}{\|\mathbf{h}_{m,v_i}\|\|\mathbf{h}_{m,v_j}\|}$$

场景级分数为所有有效体素对的均值。

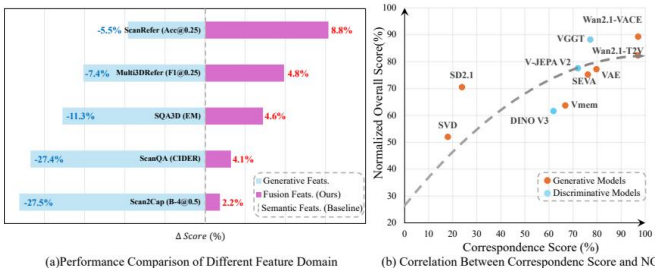

(a)Performance Comparison of Different Feature Domain (b) Correlation Between Correspondence Score and NC

图 2：特征分析。*(a)* 生成先验有效互补语义特征；*(b)* 多视图对应分数与下游 *3D* 理解性能强正相关。

关键发现：（1）多视图一致性与下游 3D 性能呈**强正相关**，是可靠的 3D 能力指标；（2）基于 **DiT 架构**的生成模型（如 Wan2.1）凭借全局注意力机制实现 $> 96\%$ 一致性，显著优于 UNet 架构（受限于卷积的局部归纳偏置和数据规模不足）。据此，VEGA-3D 选择 DiT 架构提供空间先验。

2.2 潜在世界模拟器：噪声注入与特征提取

采用预训练冻结的 **Wan2.1-T2V 1.3B** 作为默认生成编码器。给定输入视频 $\mathbf{V} \in \mathbb{R}^{T\times H\times W\times 3}$，先经 VAE 映射到潜在空间 $\mathbf{z}_0 = E(\mathbf{V})$。静态潜在表示不足以充分激活生成模型的推理能力——扩散模型在主动去噪过程中才强制结构一致性。因此沿 Flow Matching 噪声路径扰动：

$$\mathbf{z}_k = (1-t_k)\mathbf{z}_0 + t_k\epsilon, \quad t_k = k/K, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

其中 K=1000。将 $\mathbf{z}_k$ 输入骨干 $\Phi(\cdot)$，使用**空文本提示**（$\mathbf{c}_{\text{text}}$ = ""）确保特征仅依赖视觉信号和模型学到的物理规律。从第 l 个中间 DiT 层提取特征：

$$\mathbf{f}_{\text{raw}} = \phi^{(l)}(\mathbf{z}_k, k; \mathbf{c}_{\text{text}} = \text{""})$$

经自适应平均池化匹配语义分词后，得到生成表示 $\mathbf{f}_{\text{gen}} \in \mathbb{R}^{T\times N\times D_{\text{gen}}}$。默认在 k=300（t_k=0.3）、第 20 层 DiT 提取。

2.3 自适应门控融合

生成特征 $\mathbf{f}_{\text{gen}}$ 与语义特征 $\mathbf{f}_{\text{sem}}$ 处于根本不同的流形。先经独立 MLP 投影器对齐至 LLM 隐藏维度 D_{llm}：

$$\mathbf{F}_{\text{gen}} = P_{\text{gen}}(\mathbf{f}_{\text{gen}}), \quad \mathbf{F}_{\text{sem}} = P_{\text{sem}}(\mathbf{f}_{\text{sem}})$$

对第 i 个空间 token 计算标量门控 $g_i \in [0,1]$：

$$g_i = \sigma\big(\mathbf{W}_g^{\top}\,\text{Concat}(\text{LN}(\mathbf{F}_{\text{gen},i}), \text{LN}(\mathbf{F}_{\text{sem},i})) + b_g\big)$$

最终融合为凸组合：$\mathbf{F}_i^{\text{fused}} = (1-g_i)\cdot\mathbf{F}_{\text{gen},i} + g_i\cdot\mathbf{F}_{\text{sem},i}$。该门控作为**语义-几何仲裁器**：识别任务优先语义先验，空间推理任务则动态转向生成世界知识。

3. 实验结果

3.1 3D 场景理解

在 ScanRefer、Multi3DRefer、Scan2Cap、ScanQA、SQA3D 五个基准上评估。基于 Video-3D LLM 基线，VEGA-3D 取得全面提升，平均排名 **1.8**（最优）：

指标	基线	VEGA-3D	Δ
ScanRefer Acc@.25	58.1	**63.2**	+5.1
ScanRefer Acc@.5	51.7	**56.2**	+4.5
Multi3DRefer F1@.25	58.0	**60.8**	+2.8
Multi3DRefer F1@.5	52.7	**55.1**	+2.4
ScanQA CIDEr	102.1	**106.3**	+4.2
SQA3D EM	58.6	**61.3**	+2.7

在定位相关任务（grounding、spatial QA）上增益最显著——隐式 3D 结构先验充当**空间锚点**，有效减少 MLLM 的空间歧义。Scan2Cap 的 CIDEr 略有下降（83.8→83.2），暗示语义-几何权衡：强调结构线索可能弱化细粒度词汇细节。超越依赖重度几何监督的 3DRS（Avg. Rank 2.2）和使用额外数据集的 LLaVA-4D（Avg. Rank 2.8），**完全无需显式 3D 标注**。

3.2 空间推理（VSI-Bench）

在 VSI-Bench 上以 Qwen2.5VL-7B 为基线，VEGA-3D 总平均 **50.5**（基线 48.9），在物体计数（69.7 vs 68.3）、房间尺寸（60.8 vs 58.7）、相对距离（45.1 vs 39.7）、接近顺序（60.5 vs 57.8）等子类别均有提升。超越专门空间增强模型如 SpaceR-7B（45.9）、3DRS-7B（45.9），接近或超越更大参数量模型 VG-LLM-8B（50.1）。

3.3 机器人操作（LIBERO）

将生成先验注入 OpenVLA-OFT 视觉流，在已高度饱和的基线上进一步提升：平均成功率 **97.3%**（基线 97.0%），长时域任务提升最显著（95.2% vs 94.4%），物体交互达 **99.4%**。证明空间正则性和物理知识可直接迁移至主动物理智能体。

4. 消融实验

4.1 生成式 vs. 判别式先验

DiT 生成模型显著优于 UNet 生成模型（多视图一致性 $> 96\%$ vs $< 90\%$）。与判别式模型（DINOv3、V-JEPAv2）和 3D 基础模型（VGGT）对比，Wan2.1-T2V 在定位任务上表现最优。生成与语义特征**互补而非替代**：仅用生成特征性能大幅下降，融合产生协同增益。

4.2 噪声水平与 DiT 层深度

噪声比 t_k：性能在中间噪声水平（t_k=0.3）达峰。清洁潜在变量未充分利用去噪能力，过度噪声破坏结构信号。适度噪声最优地迫使模型调用其学到的物理知识恢复底层 3D 结构。**层选择**：第 20 层（中间层）提供空间推理的最优抽象，平衡浅层的低级纹理与深层的像素级渲染。

4.3 融合策略

仅用生成特征导致显著下降，验证生成先验是互补而非替代。在轻量融合变体中，自适应门控融合在大多数指标上最优：朴素 Add 操作在 SQA3D EM 上略高（61.8 vs 61.3），但在 grounding 和 captioning 上一致更弱——固定非自适应融合权重无法可靠解决语义-生成分布差距。Token 级门控动态平衡语义与几何先验，在多样任务间产生更一致增益。

4.4 推理开销

引入视频扩散骨干增加推理成本，但通过**场景级特征缓存**策略（每场景仅提取一次生成特征，所有问题复用），大幅降低边际开销。权衡可接受：以有限计算换取稳定且显著的性能增益。

5. 讨论与局限

核心贡献：（1）首次系统验证视频生成模型学到可迁移的时空先验，编码几何一致结构与运动，且中间表示和中间去噪阶段信息量最大；（2）即插即用框架将生成模型重用为潜在世界模拟器，引入 token 级自适应门控融合对齐异质特征空间；（3）在 3D 场景理解、空间推理、具身操作三大轴验证有效性。

核心洞察：下一代 MLLM 的 3D 空间感知能力提升可能不在于更多 3D 数据，而在于**释放生成基础模型中已沉睡的物理先验**。视频生成的进步可直接迁移为更强的下游 3D 理解——框架具有良好可扩展性。

局限性：（1）视频扩散骨干增加推理成本，未来将蒸馏至轻量编码器；（2）当前聚焦静态场景理解，动态场景理解为未来方向；（3）生成先验在需要精细词汇细节的任务（如 dense captioning）上的增益有限，存在语义-几何权衡。

SAMA：面向指令引导视频编辑的分解式语义锚定与运动对齐

Zhang*, Dong*, Song*†, Fang, Zhang, Wang, Chen, Zhang, Feng, Lu, Zhou, Yuan, Wang — Baidu, 清华大学, 城市大学香港, 浙江大学, 2026

1. 动机与问题定义

指令引导的视频编辑需要同时满足两个相互冲突的目标：(i) 按指令执行精确的语义修改；(ii) 保持编辑视频与源视频的时序一致运动。现有方法中，激进的语义修改会导致局部伪影、身份漂移和纹理闪烁，而强制时序一致性则会稀释编辑意图、降低指令保真度。

现有方法的主流策略是注入**显式外部先验**——VLM 提取的语义条件（如 InstructX）或结构信号（骨骼、深度图）。作者认为这种过度依赖构成了关键瓶颈：它阻止扩散主干网络学习**内在的语义-运动表征**，限制了模型的鲁棒性与泛化能力。

核心洞察：指令引导视频编辑的困难本质上源于**语义结构规划与运动建模之间缺乏分解**。语义编辑通常是稀疏且时序稳定的——少量锚定帧即可确定目标视觉修改；而运动一致性遵循物理与时间动力学，可从大规模原始视频中学习，无需编辑监督。

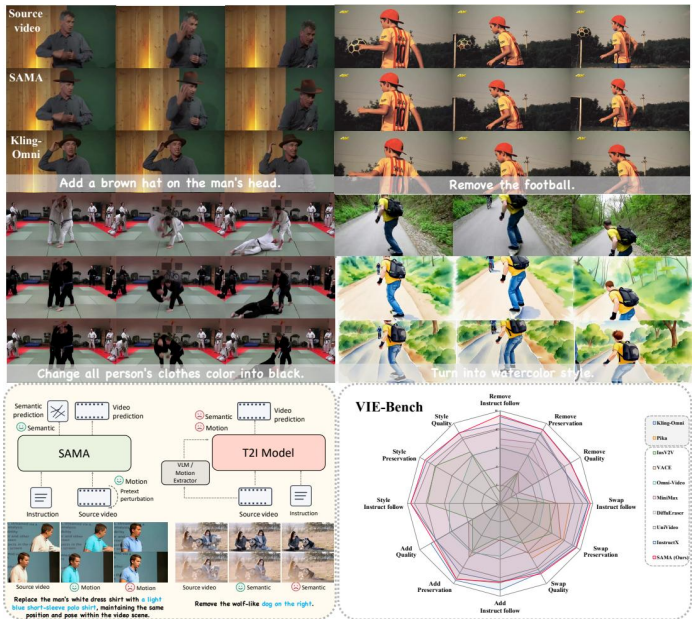

图 1：*SAMA* 概览。上方为与代表性开/闭源系统的定性比较；左下为语义-运动训练目标示意；右下为 *VIE-Bench* 细粒度性能对比。

2. 系统架构与整体流程

SAMA 基于视频扩散模型 **Wan2.1-T2V-14B**，采用 flow matching 范式训练。给定源视频 V_s 和编辑指令 y，目标是生成遵循 y 同时保持时空运动的编辑视频 V_t。

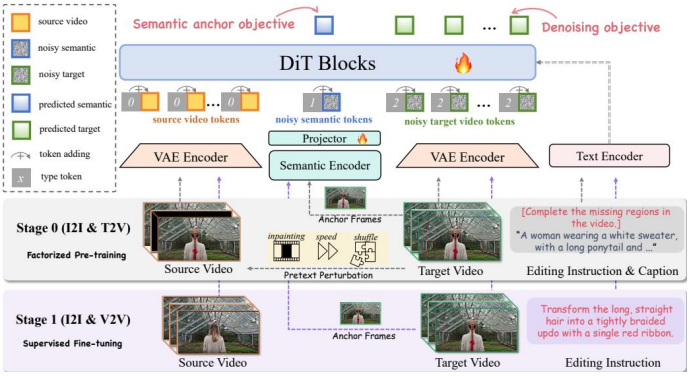

图 2：*SAMA* 整体流程。*Stage 0* 在扰动视频上完成预文本任务的分解预训练；*Stage 1* 在配对编辑数据上监督微调。语义锚定贯穿两个阶段。

Latent 标记化：源视频和目标视频编码为 VAE latent 序列 $\mathbf{z}_s$ 和 $\mathbf{z}_t$，拼接形成 in-context V2V 输入 $\mathbf{z} = [\mathbf{z}_s; \mathbf{z}_t]$。

类型嵌入（Type Embeddings）：为区分 token 角色，对每个 token 添加可学习类型嵌入：type id 0（源视频 latent）、type id 1（语义 token）、type id 2（目标视频 latent）。实验表明类型嵌入比 shifted RoPE 收敛更快更稳定（VIE-Bench 上 overall 6.975 vs. 6.498），因为它将 token 身份与位置编码解耦——位置编码继续捕获时空结构，token 身份由类型嵌入独立建模。

SAMA 在扩散主干内集成两个互补能力：**语义锚定**（SA）和**运动对齐**（MA），并通过两阶段训练策略实现分解学习。

3. 语义锚定（Semantic Anchoring）

SA 作为辅助目标贯穿分解预训练和 SFT 两个阶段。对视频样本，从目标视频均匀采样 N 帧作为稀疏锚定帧（实验中 $N = 1$）。每个锚定帧经 **SigLIP** 图像编码器提取 patch 级语义特征，通过池化聚合为 $M = 64$ 个局部语义 token（捕获区域级语义）加 1 个全局 token（总结整体内容），再经两层 MLP 投射到与 VAE latent 相同的嵌入空间。

语义 token 注入去噪序列：将投射后的语义 token $\hat{\mathbf{s}}$ 前置于目标 latent 序列，对两者施加相同的前向加噪过程，将拼接的含噪序列送入 DiT。去噪后读出语义 token 位置，经语义预测头输出预测 token $\mathbf{s}$。

目标函数：语义预测使用 ℓ_1 损失监督：

$$\mathcal{L}_{\text{sem}} = \|\hat{\mathbf{s}} - \mathbf{s}\|_1$$

整体训练目标结合 flow matching 损失和 SA 损失：

$$\mathcal{L} = \mathcal{L}_{\text{FM}} + \lambda \cdot \mathcal{L}_{\text{sem}}$$

其中 flow matching 损失为 $\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t,x_0,x_1}\|v_\theta(x_t, t) - (x_1 - x_0)\|_2^2$，$\lambda = 0.1$。

SA 的关键作用：（1）加速 DiT 收敛——加入语义预测目标后扩散损失下降更快；（2）稳定训练——损失方差显著降低；（3）在相同训练步数下产生更高质量编辑。

4. 运动对齐（Motion Alignment）

MA 在分解预训练阶段应用于视频样本。给定源视频 V_s 和指令 y，仅对源视频施加运动中心变换 $\tilde{V}_s = \mathcal{T}(V_s)$，目标侧始终使用原始视频。这迫使模型从源流中学习运动恢复与时序推理。

4.1 运动中心变换

受自监督视频表示学习启发，采用三种修复式扰动：

- **Cube Inpainting**：遮蔽 $\tilde{V}_s$ 中连续时空块（遮蔽率 30%），条件于剩余帧恢复缺失内容；
- **Speed Perturbation**：对 $\tilde{V}_s$ 施加 2× 时间加速，学习恢复正常动态，提升运动速率变化鲁棒性；
- **Tube Shuffle**：将 $\tilde{V}_s$ 划分为 $2 \times 2 \times 2$ 时空管网格并随机排列，迫使模型推理时空结构并恢复一致运动。

任务提示统一：为每个预文本任务在编辑指令前添加简短任务 token，如 “[Complete the missing regions in the video.]”（Cube Inpainting）、“[Restore the video to normal playback speed.]”（Speed Perturbation）、“[Restore the correct spatio-temporal order.]”（Tube Shuffle）。采样比例为无任务:Cube:Speed:Tube = 1:2:3:4。

5. 两阶段训练策略

5.1 Stage 0：分解预训练

从强 T2V 先验出发，在**图像编辑对**（NHR-Edit 72 万、GPT-Image-Edit 101 万、X2Edit 76 万）与**文本-视频数据**（Koala-36M 153 万、MotionBench 5.4 万）的混合上预训练。图像编辑提供广泛语义覆盖和指令落地能力，文本-视频数据提供多样真实运动模式。SA 同时应用于图像和视频样本，MA 仅应用于视频流。

关键发现：仅 Stage 0 即已展现出**强零样本视频编辑能力**——在 Replace/Add/Remove/Style/Hybrid 任务上均能产生跨帧一致的编辑，同时大体保留未编辑内容。这验证了分解假设：一旦模型学会联合推理语义意图和时间动态，鲁棒的指令引导视频编辑能力即可自然涌现。零样本的典型失败模式包括：属性编辑跨帧不一致、新增物体略模糊、移除编辑留有残影。

5.2 Stage 1：监督微调（SFT）

在配对视频编辑数据集上微调：Ditto-1M Style 子集（3936 对）、OpenVE-3M 四类子集（81.8 万对）、ReCo-Data（20.7 万对），混合少量图像编辑数据（NHR-Edit 72 万、Pico-Banana-400K 25.8 万）。SA 保持启用以维持稳定语义锚定。Stage 1 聚焦配对编辑监督对齐，改善编辑保真度并缓解剩余语义-运动冲突。

实现细节：学习率 2×10^{-5}；全局 batch size 图像 448、视频 112；分辨率 480p；支持多纵横比（$1/2, 2/3, 3/4, 1/1$ 及其倒数）；EMA 衰减 0.9998 每步更新。

6. 实验结果

6.1 VIE-Bench 综合评估

使用 GPT-4o 评判，SAMA 在所有开源模型中**全面领先**，并与闭源系统竞争：

方法	Add	Swap	Remove	Style
Kling-Omni	9.181	9.194	9.133	9.341
Runway	8.447	9.161	8.504	9.133
UniVideo	8.656	8.683	8.233	8.711
InstructX	8.349	9.072	8.322	9.196
SAMA	**8.711**	**9.340**	**9.144**	**9.259**

SAMA 在 Swap/Change 和 Remove 类别上**超越所有方法**（包括闭源），Swap/Change 均分 9.340 超过 Kling-Omni 的 9.194；Remove 均分 9.144 超过 Kling-Omni 的 9.133。

6.2 OpenVE-Bench 评估

使用 Gemini-2.5-Pro 评判，SAMA（14B）在 Style（4.05）、Local Change（3.93）、Local Remove（3.32）、Local Subtitle Edit（3.63）等多个类别取得最佳或近最佳成绩，总体优于所有开源方法。与闭源 Runway 相比，在 Style（4.05 vs. 3.72）和 Subtitle（3.63 vs. 3.62）上胜出。

6.3 ReCo-Bench 评估

使用 Gemini-2.5-Flash-Thinking 评判，SAMA 在 Add（总分 8.92）、Replace（9.10）、Remove（8.09）和 Style（9.25）四个任务上均取得**开源最佳**。Replace 任务：SAMA 的编辑准确度 $S_{EA} = 9.71$ 超过 ReCo 的 9.43 和 UniVideo 的 9.40；视频质量 $S_{VQ} = 8.98$ 同样领先。Remove 任务提升尤为显著：SAMA 总分 8.09 vs. ReCo 7.00 和 UniVideo 6.81。

6.4 定性分析

SAMA 在细粒度指令遵循上更可靠——正确处理相对位置线索（如“在左侧”）和属性约束（如“交替的深浅色头发”）；替换编辑（鸽子 $\rightarrow$ 松鼠、海豹 $\rightarrow$ 螃蟹）外观跨帧一致；移除后时序对齐更好（如移除后婴儿车位置保持）；风格化过程中身份/细节保持更佳。

7. 消融实验

在 Wan2.2-T2V-5B 上使用 Ditto-1M 子集训练，VIE-Bench 评估：

配置	指令遵循	保留	质量	总分
Baseline	6.575	6.261	6.100	6.312
+SA	7.002	6.744	6.342	6.696
+MA	6.969	6.620	6.544	6.711
SAMA (SA+MA)	**7.402**	**6.998**	**6.884**	**7.095**

SA 贡献：+0.384 总分提升；加速 DiT 收敛并降低损失方差；相同步数下编辑质量更高。**MA 贡献：**+0.399 总分提升；改善快速运动下的时序一致性并减轻运动模糊（网球场景中背景更清晰，屏幕文字可辨认）。**组合效果：**SA+MA 总分 7.095，比 baseline 提升 +0.783，表明两者**互补**而非冗余。

类型嵌入 vs. Shifted RoPE：在 Wan2.2-T2V-5B LoRA 设置下，类型嵌入总分 6.975（保留 7.533），Shifted RoPE 总分 6.498（保留 6.257），差距主要体现在内容保留上。

8. 与相关工作的对比

与同期工作相比，SAMA 的独特定位在于：

- **vs. 外部先验方法**（InstructX 使用 MLLM 引导、ControlVideo 使用深度/骨骼）：SAMA 不依赖外部结构条件，通过内在语义-运动分解实现鲁棒编辑，避免外部先验的错误传播；
- **vs. 数据驱动方法**（Ditto、OpenVE-Edit）：SAMA 的分解预训练无需配对视频编辑数据即可获得强编辑能力，减少对昂贵合成数据的依赖；
- **vs. In-context 方法**（UNIC、ICVE）：SAMA 通过语义 token 预测提供显式语义锚点，而非仅依赖 in-context 学习的隐式对齐；
- **vs. 语义对齐方法**（REPA、VideoREPA）：SAMA 将语义对齐从生成任务扩展至编辑任务，且结合运动中心预文本任务而非仅做表征蒸馏。

9. 局限性与未来方向

- 零样本模式仍存在属性编辑时序不一致、新增物体模糊、移除残影等问题；
- 当前仅在 480p 分辨率训练，长视频和高分辨率场景有待扩展；
- 快速运动场景虽经 MA 改善但仍有提升空间；
- 语义 token 化可进一步增强（当前 $N = 1$ 锚定帧、$M = 64$ token），更丰富的语义表征可能减少残余伪影；
- 未来工作聚焦长视频编辑、快速运动场景、以及更强的语义 token 化策略以进一步降低时序不一致性。

FASTER：重新思考实时 Flow VLA 的反应延迟瓶颈

Lu, Liu, Fan, Yang, Hou, Li, Ding, Zhao — The University of Hong Kong & ACE Robotics, 2026

1. 动机与问题定义

Vision-Language-Action (VLA) 模型通过将连续运动控制建模为生成式序列问题，在灵巧操作任务中取得了突破性进展。然而，从仿真迈向真实物理部署时，**实时性**成为核心瓶颈。现有实时 VLA 方法（如异步推理 [RTC, Training-time RTC, VLASH 等]）主要关注动作块间的**平滑性**——消除同步推理中的"停顿等待"问题，但严重忽视了另一关键维度：**反应能力**。

在开放世界场景中，VLA 系统必须对动态环境变化做出迅速精确的响应。延迟反应会在闭环控制中制造危险的"盲区"，限制策略的鲁棒性。本文首次系统分析了 action chunking 策略中反应时间的本质，并提出 FASTER（Fast Action Sampling for ImmediaTE Reaction），一种即插即用的加速方案，无需修改架构或额外训练开销。

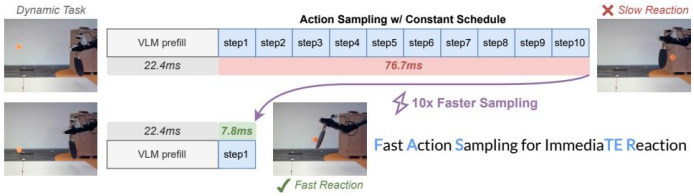

图 1：*FASTER* 将即时动作的采样迭代压缩为单步，相比 $\pi_{0.5}$ 和 *X-VLA* 实现 10× 加速，使乒乓球等高动态任务成为可能。

2. Action Chunking 推理管线分析

2.1 时序管线与反应时间建模

给定策略 π，模型在时刻 t 处理观测 $\mathbf{o}_t$ 预测动作序列 $\mathbf{A}_t = [\boldsymbol{a}_t, \ldots, \boldsymbol{a}_{t+H-1}]$（$H$ 为预测 horizon）。实际中仅执行前 s 个动作后触发新推理。部署采用客户端-服务器架构，存在同步与异步两种模式。

关键发现：反应时间是随机变量。由于外部事件相对推理周期随机发生，反应时间 Δt_{react} 服从均匀分布。同步模式下 $\Delta t_{\text{react}} \sim \mathcal{U}(\Delta t_{\text{infer}},\ 2\Delta t_{\text{infer}} + \Delta t_{\text{exec}})$；异步模式下 $\Delta t_{\text{react}} \sim \mathcal{U}(\Delta t_{\text{infer}},\ \Delta t_{\text{infer}} + \Delta t_{\text{exec}})$。期望反应时间分别为 $1.5\Delta t_{\text{infer}} + 0.5\Delta t_{\text{exec}}$ 和 $\Delta t_{\text{infer}} + 0.5\Delta t_{\text{exec}}$。

重要推论：从同步升级为异步推理带来的增益**有限**——仅减少 $0.5 \cdot \Delta t_{\text{infer}}$。真正改善反应性需要**同时**降低感知-执行延迟**并**提高推理-执行循环频率。

2.2 Time to First Action (TTFA)

反应时间严重依赖推理延迟，而如果动作不是同时生成，响应速度仅取决于系统产出**第一个动作**的速度。因此本文引入 **TTFA**（类似 LLM 中的 TTFT），精确刻画机器人可发起运动的最早时刻——这才是反应速度的真正瓶颈。

3. Pilot Study：动作块采样的非均匀性

3.1 常量时间表的低效性

现有 flow-based VLA 对整个动作块使用**常量时间步调度**——每个动作经历相同的去噪步数。这迫使系统在产出任何动作前完成所有 N 步采样（通常 $N = 10$），构成推理延迟的主要瓶颈。

3.2 实证分析

本文使用**直度**（straightness）度量分析采样路径特征：

$$S(\mathbf{A}) = \sum_{\tau=0}^{1} \mathbb{E}_t \left[\left\| (\mathbf{A}_t^1 - \mathbf{A}_t^0) - v_\theta(\mathbf{o}_t, \mathbf{A}_t^\tau, \tau) \right\|^2 \right] \Delta\tau,$$

其中 $S(\mathbf{A}) = 0$ 表示完美直线路径。同时分析各去噪步的清洁动作估计 $\tilde{\mathbf{A}}_t^{\tau\to 0} = \mathbf{A}_t^\tau - v_\theta(\mathbf{o}_t, \mathbf{A}_t^\tau, \tau)\tau$ 与最终输出的偏差。在 $\pi_{0.5}$ 微调模型上的实验清晰显示：**前 1–10 帧动作**具有显著更低的 straightness 值和更小的估计偏差——即近期动作的插值路径更直，仅需极少步即可精确估计，而常量调度对这些维度存在冗余过采样。这为 FASTER 的设计提供了坚实的实证基础。

4. FASTER 方法

4.1 Horizon-Aware Schedule (HAS)

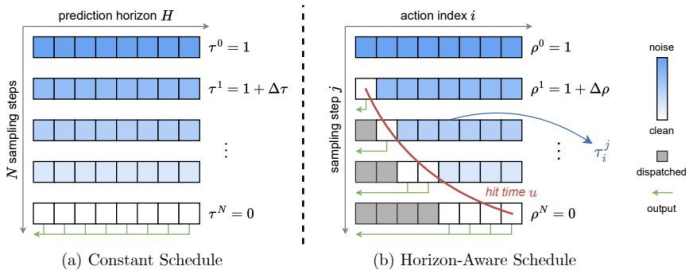

图 2：*(a)* 常量时间步调度 *vs* *(b)* *Horizon-Aware Schedule*：自适应分配 *hit time*，加速近期动作采样并支持流式输出。

受 Diffusion Forcing 启发，将 flow matching 时间步设为**索引依赖**的向量 $\boldsymbol{\tau} = \{\tau_i\}$。每个动作在不同的 **hit time** u_i 完成去噪：

$$u_i = \left(1 - \frac{i}{H-1}\right)^\alpha \cdot u_0, \quad i \in [1, H-1],$$

其中 u_0 指定第一个动作完成时的全局时间步，$\alpha \in (0, 1]$ 控制 hit time 分布曲线。$\alpha < 1$ 时近期动作快速完成，远期动作保持接近 0 的 hit time 以获得更多去噪步。给定全局时间步 ρ^j，各动作的局部时间表为：

$$\tau_i^j = \max\big(0,\ (\rho^j - u_i)/(1 - u_i)\big)\,.$$

设 $u_0 = (N-1)/N$，当 ρ^j 到达 u_0 时第一个动作即完成——**仅需单步 AE 采样**。TTFA 从 $\Delta t_{\text{VLM}} + N \cdot \Delta t_{\text{AE}}$ 缩减为 $\Delta t_{\text{VLM}} + \Delta t_{\text{AE}}$，实现 ∼10× 加速。

4.2 混合调度微调

直接以 HAS 微调预训练 VLA 存在两个问题：(1) 预训练模型在常量调度下优化，直接切换增大 gap；(2) 随机采样 ρ 时近期动作高概率获得零时间步，学习可能退化。解决方案：以概率 p 使用 HAS，$1-p$ 保留原始常量调度。混合策略使模型对两种调度均鲁棒，**无需架构修改或额外训练开销**。

4.3 与 Action Conditioning 的协同

HAS 天然兼容 Training-time RTC 的动作前缀条件化：在 HAS 下，前缀动作时间步为零、后续动作递增——与 action conditioning 的原理内在一致。通过对索引施加偏移 $-d$（d 为推理延迟），即时动作仍以单步完成。训练时 $d \sim \mathcal{U}\{0, d_{\max}\}$，仅对后缀动作计算损失。

4.4 流式客户端-服务器接口

FASTER 的渐进式生成使得早期动作可在完成时**立即派发**至机器人控制器，无需等待整个块完成。服务器端持续生成后续动作并补充客户端动作缓冲区。只要动作获取速率超过控制频率，机器人即可不间断运行——在消费级 GPU 上亦可满足。

Early-Stopping 策略：当需要高推理频率时（小 s），执行 horizon 内所有动作完成后即可跳过剩余采样步，进一步缩短推理延迟，降低可行的 $s_{\min}$，同时收紧 Δt_{react} 的上界。

5. 实验结果

5.1 反应速度分析

在 RTX 4090 和消费级 RTX 4060 上对 $\pi_{0.5}$ 和 X-VLA 进行评估（控制频率 30Hz）：

模型	方法	TTFA	$s_{\min}$	$\mathbb{E}[\Delta t_{\text{react}}]$
3*$\pi_{0.5}$ (4090)	Async	80.0ms	3	130.0ms
	FASTER	62.1ms	3	112.1ms
	加速比	1.29×	–	1.16×
3*X-VLA (4090)	Async	113.7ms	4	180.4ms
	FASTER	44.8ms	2	78.1ms
	加速比	2.54×	2×	2.31×
3*$\pi_{0.5}$ (4060)	Async	303.3ms	10	470.0ms
	FASTER	238.6ms	8	371.9ms
	加速比	1.27×	1.25×	1.26×
3*X-VLA (4060)	Async	399.5ms	12	599.5ms
	FASTER	129.2ms	6	229.2ms
	加速比	3.09×	2×	2.62×

X-VLA 上效果尤为显著——RTX 4060 上 TTFA 加速 3.09×。概率分析进一步显示：X-VLA 上 FASTER 的反应时间上界低于基线的下界，构成**严格性能支配**。

5.2 真实机器人实验

乒乓球任务：在 AgileX Cobot Magic 平台（6-DoF Piper 机械臂）上，仅 14 分钟遥操作数据微调 $\pi_{0.5}$。同步推理完全无法响应来球。Naive Async 和 Training-time RTC 具有相似反应能力，但后者通过 action conditioning 改善挥拍平滑度。FASTER 展现显著更快的反应——可从球拍接触时的角度直观判断：更早的反应使机器人有充足时间调整姿态和积累挥拍速度。RTX 4060 上优势尤为突出（推理仅 3Hz），凸显了降低延迟与提高频率的复合收益。

拾取饮料 & 折叠毛巾：异步方法显著优于同步，FASTER 取得更好或持平的完成分数与更短的任务时长。关键洞察：任务性能不仅取决于动作精度，还取决于与物理世界的实时交互——FASTER 在响应性与精度间实现更优平衡。

5.3 仿真实验

在 LIBERO 和 CALVIN ABC→D 基准上验证 HAS 是否保持原始性能：

方法	LIBERO Avg.	CALVIN Avg.Len
$\pi_{0.5}$ 原始	96.9	4.313
$\pi_{0.5}$+FASTER	96.5	4.292
X-VLA 原始	98.0	4.151
X-VLA+FASTER	97.0	4.058

尽管 HAS 采用激进采样，仿真性能仅有边际下降，证明 FASTER 在保持动作生成质量的同时实现了显著加速。

6. 消融实验

论文附录提供了详细消融分析：

- **hit time 参数** α：$\alpha < 1$ 时近期动作优先完成，$\alpha = 1$ 为均匀分配。较小 α 改善 TTFA 但过于激进可能影响远期精度；
- **混合概率** p：纯 HAS（$p = 1$）微调存在训练-推理 gap，混合策略（$p \approx 0.5$）最优；
- **Early-stopping**：有效降低 $s_{\min}$，在资源受限 GPU 上收益更大；
- 预测 horizon $H = 30$ vs $H = 50$：straightness 非均匀性模式一致，支持方法的通用性。

7. 与相关工作的对比

vs. 模型压缩方法（小 VLM 骨干、LLM 层压缩、视觉 token 剪枝、量化）：FASTER 正交于这些方法，可叠加使用。

vs. 异步推理方法（RTC, Training-time RTC, REMAC, VLASH）：这些方法优化平滑性，FASTER 首次明确以响应性为目标。且 FASTER 的 streaming 接口与 early-stopping 进一步加速闭环控制。

vs. 扩散加速（一步蒸馏、consistency model）：需额外训练或架构修改；FASTER 无需修改，直接作用于预训练 flow-based VLA。

8. 讨论与局限

- **核心贡献**：首次将 action chunking VLA 的反应延迟建模为均匀分布随机变量；提出 HAS 将 TTFA 压缩至单步；设计 streaming + early-stopping 接口联合优化延迟与频率；
- **即插即用**：无需架构修改、无额外训练成本，适用于所有 flow-based VLA（π_0, $\pi_{0.5}$, X-VLA, GR00T 等）；
- **局限**：高度激进的采样可能在仿真中对长 horizon 精度产生边际影响；方法依赖 flow matching 框架的线性插值假设；当前仅验证于 Euler solver，更高阶求解器的适配待探索；
- **未来方向**：与模型压缩/蒸馏技术联合优化；扩展至更复杂的多模态动态场景（人机协作、户外移动操作）；探索自适应 α 调度策略。

3DreamBooth：高保真 3D 主体驱动视频生成模型

Ko*, Park*, Kim, Park, Park — Yonsei University & Sungkyunkwan University, 2025

1. 问题动机与背景

在沉浸式 VR/AR、虚拟制片和电商等场景中，用户亟需一种能够从少量参考图像生成**视角一致、动态逼真**的定制化主体视频的生成系统。然而，现有主体驱动视频生成方法存在根本局限：

- **2D 局限**：现有方法（VACE、Phantom 等）仅依赖单张参考图或文本描述，将主体视为 2D 实体，缺乏对底层 3D 几何的理解；
- **未见视角退化**：当需要合成未见视角时，模型只能生成看似合理但任意的细节，无法保持真实 3D 身份一致性；
- **多视角视频数据稀缺**：直接在有限视频序列上微调极易导致时间过拟合——模型记忆特定运动轨迹而非空间身份。

本文提出统一优化与适配器范式的 **3D 感知视频定制化框架**，包含两个核心模块：**3DreamBooth**（基于 1 帧优化范式将 3D 先验注入模型）和 **3Dapter**（多视角条件注入模块），实现高保真、3D 条件化的视频生成。

2. 核心思想：解耦空间身份与时间动态

2.1 隐式 3D 先验的激发

预训练视频扩散模型（如 HunyuanVideo）已内含鲁棒的**隐式 3D 先验**——当提示生成" 一只狗" 的视频时，模型自然产生跨视角几何一致的时序帧。3DreamBooth 的核心直觉是：通过多视角静态图像训练，将这种隐式先验**显式绑定**到特定主体的唯一标识符 V 上。

2.2 1 帧训练范式

现代视频 DiT 通过联合时空注意力处理输入。当输入限制为单帧（$T = 1$）时，时间注意力通道被**自然旁路**，所有梯度更新仅作用于空间表征，无需显式冻结时间模块或插入额外空间适配器。推理时，未被触碰的时间机制自然驱动已学习身份的时间流动，实现平滑、视角一致的视频生成。

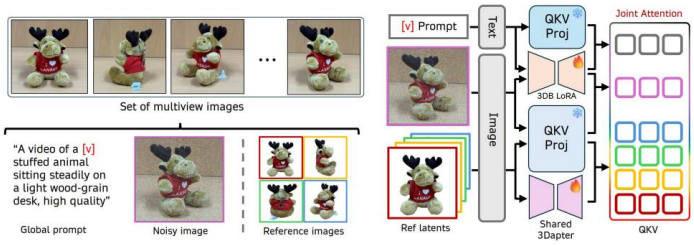

图 1：*3DreamBooth* 训练流程。左：从多视角图像中选取目标与参考条件。右：文本与噪声目标通过主分支（*3DB LoRA*），参考通过共享 *3Dapter*，特征拼接进行多视角联合注意力。

3. 3DreamBooth：3D 身份注入

给定主体的多视角静态图像集 $\mathcal{S} = \{s^{(i)}\}_{i=1}^{N_s}$，每张图像作为单帧视频（$T = 1$），配对统一文本提示 p（含唯一标识符 V 和类别名词 C，如"a video of a V C"）。通过 LoRA 优化预训练视频 DiT v_θ，注入可训练权重 ϕ_{3DB}，原始参数 θ 冻结。训练目标为速度预测损失：

$$\underset{\phi_{\text{3DB}}}{\operatorname{argmin}}\ \mathbb{E}_{i,\epsilon,t}\left[\|\bar{\boldsymbol{v}} - \boldsymbol{v}_{\theta,\phi_{\text{3DB}}}(\boldsymbol{z}_t^{(i)}, t, \boldsymbol{p})\|_2^2\right]$$

其中 $\boldsymbol{z}_t^{(i)}$ 为视角 $s^{(i)}$ 在扩散时间步 t 的噪声潜变量。通过跨所有视角使用一致提示，模型被迫将多视角空间变化直接内化到标识符 V 中。

文本驱动的瓶颈：单一 token V 作为主要条件存在严重**信息瓶颈**——文本嵌入本质上捕获粗粒度语义，难以编码高频纹理、特定文字或复杂几何细节。此外，从随机初始化 token 映射到复杂 3D 视觉流形的优化过程缓慢。

4. 3Dapter：多视角条件注入模块

4.1 单视角预训练

采用双分支前向传播架构。在 Subjects200K 数据集上预训练，该数据集包含参考-目标图像对 $\{(\boldsymbol{x}^{(i)}, \boldsymbol{y}^{(i)}, \boldsymbol{p}^{(i)})\}$，参考为白背景单物体，目标为同一物体在多样场景中。优化 3Dapter LoRA 权重 ϕ_{3Dapter}：

$$\underset{\phi_{\text{3Dapter}}}{\operatorname{argmin}}\ \mathbb{E}_{i,\epsilon,t}\left[\|\bar{\boldsymbol{v}} - \boldsymbol{v}_{\theta,\phi_{\text{3Dapter}}}(\boldsymbol{z}_t^{(i)}, t, \boldsymbol{x}^{(i)}, \boldsymbol{p}^{(i)})\|_2^2\right]$$

注意力机制中，将目标、参考和文本的 Q/K/V 张量沿序列维度拼接：$Q = [Q_z, Q_x, Q_p]$，$K = [K_y, K_x, K_p]$，$V = [V_y, V_x, V_p]$，执行标准缩放点积注意力。参考张量由冻结权重 + 3Dapter LoRA 产生。

4.2 多视角联合优化

预训练后，同时优化 3DreamBooth 和 3Dapter。从多视角图像集 $\mathcal{S}$ 中选取 N_c 个条件视角 $\mathcal{X} \subset \mathcal{S}$（覆盖 360°、去除背景），联合目标：

$$\underset{\phi_{\text{3DB}},\phi_{\text{3Dapter}}}{\operatorname{argmin}}\ \mathbb{E}_{i,\epsilon,t}\left[\|\bar{\boldsymbol{v}} - \boldsymbol{v}_{\theta,\phi_{\text{3DB}},\phi_{\text{3Dapter}}}(\boldsymbol{z}_t^{(i)}, t, \mathcal{X}, p)\|_2^2\right]$$

所有条件图像通过**共享**的 3Dapter 处理（而非每视角独立适配器），确保跨视角一致的几何特征提取。联合 Query 张量为：$Q = [Q_z, Q_x^{(1)}, \ldots, Q_x^{(N_c)}, Q_p]$。对每个条件视角分配独立的时间索引（$t = 1, \ldots, N_c$），通过 3D RoPE 防止不同视角空间特征纠缠。

4.3 动态选择性路由

联合注意力机制自然涌现出**动态选择性路由**行为：网络显式学习从拼接的多视角参考条件中查询和提取与当前目标视角最相关的几何线索，主动过滤无关视角的冲突信号，提供干净、无歧义的条件信息。交叉注意力热力图证实网络对相关视角分配更高权重。

5. 评估基准：3D-CustomBench

作者构建了包含 30 个不同物体的评估套件，物体特征为复杂 3D 结构、高纹理分辨率、一致光照。主要来自 MVImgNet，辅以自定义捕获的 360° 轨迹物体。每个物体使用约 30 张多视角图像优化，$N_c = 4$ 个条件视角，GPT-4o 自动生成验证提示。

6. 实验结果

图 *2*：定性对比。基线方法在未见视角下难以重建复杂结构与细粒度细节，本方法在 360° 旋转中忠实保持 *3D* 几何与纹理。

6.1 多视角主体保真度

方法	视角	CLIP-I↑	DINO-I↑	GPT-Overall↑
VACE	S	0.8964	0.7395	3.95
Phantom	S	0.8576	0.5861	3.31
3Dapter	S	0.8647	0.5899	2.67
3DreamBooth	M	0.8382	0.6530	3.53
3Dapter+3DB	M	**0.8871**	**0.7420**	**4.57**

完整模型在 GPT-4o 评估的 Shape（4.80）、Color（4.53）、Detail（4.04）、Overall（4.57）四维度全面领先。VACE 的 CLIP-I 略高归因于 CLIP 偏好高层语义而非细粒度几何精度。

6.2 3D 几何保真度

基于点云的 Chamfer Distance 评估：完整模型 CD=**0.0177**，相较最优单视角方法 Phantom（0.0338）**误差减半**。Completeness 指标（0.0172 vs 0.0388/0.0427）表明多视角条件有效恢复完整 360° 几何，而单视角方法无法推断未见视角的完整 3D 结构。

6.3 视频质量与文本对齐

在 VBench 的 Imaging Quality（74.33）上优于所有基线，Aesthetic Quality（0.5920）与 VACE 持平，Motion Smoothness（0.9918）和 ViCLIP（0.2388）具竞争力，表明 3D 条件化未损害基础生成能力。

7. 消融实验

- **仅 3Dapter**（单视角）：美学质量强但缺乏 3D 一致性（CD=0.0487），零样本视觉条件无法构建鲁棒 3D 先验；
- **仅 3DreamBooth**（多视角）：几何更好（CD=0.0239）但高频纹理细节不足，CLIP-I 仅 0.8382；
- **预训练必要性**：无预训练的随机初始化 3Dapter 在 400 步联合优化后完全崩溃；预训练版本提供鲁棒结构基础；
- **收敛加速**：3Dapter 集成后收敛速度大幅提升——完整模型 400 步即超越 3DreamBooth-only 1600 步的效果；
- **文本处理 LoRA**：对文本处理分支应用 LoRA 对个性化至关重要，使模型在注意力空间中将 V 绑定到高度特异的 3D 几何特征。

8. 实现细节与计算效率

基于 HunyuanVideo-1.5（8.3B 参数），LoRA rank=16, α=32。3Dapter 在 Subjects200K 上预训练 100K 步（4× RTX PRO 6000，约 4 天）。联合优化仅需 400 步（单卡约 13 分钟）。仅训练 ∼95.62M 参数（骨干的 1.15%），无需修改预训练权重。相比之下，VACE 需 128× A100，Phantom 需 30,000+ A100 GPU 小时。推理生成 720p、81 帧视频，50 步去噪。

9. 可扩展性

3DreamBooth 的 1 帧优化范式可直接迁移至其他 DiT 架构（如 Wan 2.1），无需 3Dapter 即可成功将多视角 3D 身份绑定到标识符 V，证明核心方法的通用性。

10. 局限性与未来方向

- 需要测试时优化（约 13 分钟/主体），非纯零样本方法——但真正零样本的 3D 感知视频定制需不存在的大规模多视角-视频对齐数据集；
- 当前实验集中于刚性/静态物体，对高度动态主体（人体复杂关节运动、状态剧变物体）的适应性待探索；
- 标识符 V 继承类别名词 C 的语义交互能力，但此范式在复杂时间状态变化场景下的鲁棒性需进一步验证；
- 未来方向包括扩展至视频编辑模型（利用参考视频实现 3D 感知主体插入真实世界画面）。

MoTok：基于扩散的离散运动分词器——桥接语义与运动学条件

Gu*, Zhang*, Xie*, Cai, Yang, Liu — NTU S-Lab & CUHK, 2025

1. 动机与核心问题

人体运动生成是动画、机器人和具身智能的核心技术。当前存在两大范式：**连续扩散模型**擅长运动学控制（轨迹跟踪、关键帧约束），**离散 token 生成器**适合语义条件（文本描述）。但二者各有短板——扩散模型难以融入语言模型式的灵活条件接口，而 token 方法将高层语义与底层运动细节纠缠，需要高 token 率或层次化编码来保证重建质量，增加了下游生成器负担并使细粒度运动学条件与语义条件产生竞争。

核心洞察： 应将运动生成分工——离散 token 负责语义抽象，扩散模型负责细粒度重建。据此提出 **Perception–Planning–Control** 三阶段框架：感知阶段编码异质条件；规划阶段在 token 空间预测离散序列；控制阶段通过扩散解码合成最终运动并施加运动学约束。

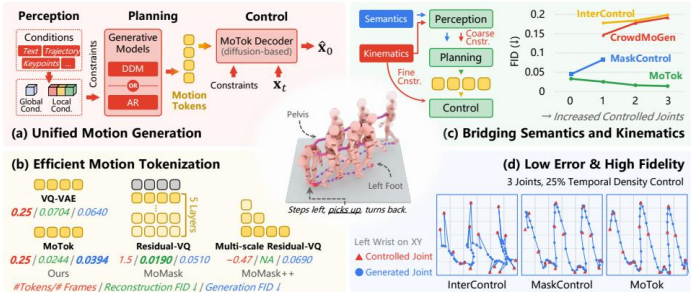

图 1：*(a)* 统一的 *Perception–Planning–Control* 流水线。*(b) MoTok* 以更少 *token* 实现紧凑运动分词。*(c)* 粗约束用于规划、细约束用于控制。*(d)* 轨迹对比。

对比维度	MoTok vs. MaskControl
Token 数量	仅 1/6
轨迹误差（Avg.Err.）	0.08cm vs. 0.72cm
FID（Random One）	0.029 vs. 0.083
约束增强时 FID	0.033 → 0.014（改善）

2. 系统架构：MoTok

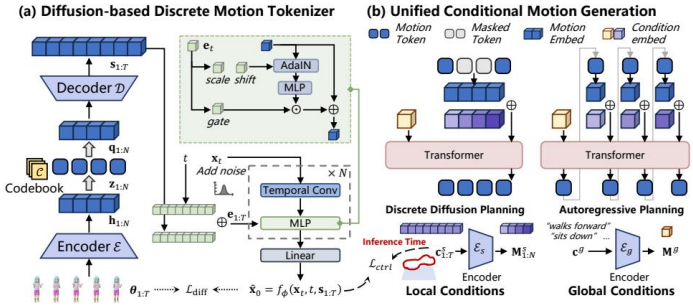

图 2：*MoTok* 架构与统一运动生成框架。*(a)* 分词器将运动分解为紧凑离散 *token* + 扩散重建。*(b)* 统一条件生成框架支持 *DDM* 和 *AR* 规划器。

MoTok 将运动表示分解为**紧凑离散编码**和**扩散解码器重建**两部分，由三个组件构成：

2.1 卷积编码器 $\mathcal{E}(\cdot)$

对运动序列 $\boldsymbol{\theta}_{1:T}$ 进行渐进式时间下采样，得到压缩潜在表示：$\mathbf{h}_{1:N} = \mathcal{E}(\boldsymbol{\theta}_{1:T}) \in \mathbb{R}^{N\times d}$，其中压缩比 $\rho = T/N$。

2.2 向量量化器 $\mathcal{Q}(\cdot)$

使用 $K=1024$ 的单层 codebook $\mathcal{C} = \{\mathbf{c}_k\}_{k=1}^{K}$，将每个潜在向量映射到最近码本条目：

$$\mathbf{z}_n = \arg\min_k \|\mathbf{h}_n - \mathbf{c}_k\|_2^2, \quad \mathbf{q}_n = \mathbf{c}_{z_n}$$

产出离散 token 序列 $\mathbf{z}_{1:N}$ 和量化潜在 $\mathbf{q}_{1:N}$。关键区别于 MoMask 的残差向量量化（RVQ），MoTok 仅使用**单层 codebook**，大幅减少 token 数量。

2.3 扩散解码器

核心创新： 不直接从量化潜在回归运动，而是先通过卷积解码器 $\mathcal{D}(\cdot)$ 上采样为逐帧条件信号 $\mathbf{s}_{1:T} = \mathcal{D}(\mathbf{q}_{1:N}) \in \mathbb{R}^{T\times d}$，再由条件扩散模型 $\mathcal{P}_\phi(\cdot)$ 重建运动：

$$\hat{\mathbf{x}}_0 = f_\phi(\mathbf{x}_t, t, \mathbf{s}_{1:T})$$

其中 f_ϕ 为神经去噪器，采用 AdaIN 风格的 MLP 块注入条件嵌入，并引入残差 1D 卷积增强时序建模。推理时从 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 逐步反向采样得到 $\hat{\mathbf{x}}_0$。

训练目标： 端到端训练，结合扩散重建损失（Smooth-ℓ_1）与 VQ commitment 损失：

$$\mathcal{L} = \mathcal{L}_{\text{diff}} + \lambda_{\text{commit}}\mathcal{L}_{\text{commit}}, \quad \lambda_{\text{commit}} = 0.02$$

设计优势： 将细粒度重建委托给扩散解码，离散 token 只需编码语义结构，实现激进压缩（$\rho=4$ 即 token 数为 MoMask 的 1/6）。同时扩散解码提供了在去噪过程中施加运动学约束的天然接口。

3. 统一条件运动生成

3.1 条件分类

全局条件 $\mathbf{c}^g$（如文本描述）提供序列级引导；**局部条件** $\mathbf{c}^s_{1:T}$（如关键点轨迹）提供时间对齐的运动学控制信号。全局条件编码为 $\mathbf{M}^g \in \mathbb{R}^d$（CLIP ViT-B/32），局部条件编码为 token 对齐序列 $\mathbf{M}^s_{1:N} \in \mathbb{R}^{N\times d}$。

3.2 规划阶段：离散 token 空间

支持两种生成器：

离散扩散（DDM）规划： 采用 MoMask 式 masked-token 扩散范式，构建长度 $N+1$ 的嵌入序列，首位放全局条件 $\mathbf{M}^g$，其余 N 位为运动 token 嵌入。局部条件通过加法融合注入：$\mathbf{H}_0[1+n] \mathrel{+}= \mathbf{M}^s_n + \mathbf{p}_n$。

自回归（AR）规划： 与 T2M-GPT 类似的因果生成。由于 next-token 预测的一步偏移，首个 token 的局部条件加到全局条件位置，后续 token 的条件加到前一 token 位置。

多条件 CFG： 当语义和轨迹条件同时存在时，采用**交替引导对**策略，等概率交替两组 CFG pair——分别 drop 文本或 drop 轨迹——避免单一模态偏向：

$$\mathbf{c}_{\text{cond}} = \{g, s\}, \ \mathbf{c}_{\text{uncond}} = \{\emptyset, s\} \quad \text{或} \quad \mathbf{c}_{\text{uncond}} = \{g, \emptyset\}$$

3.3 控制阶段：扩散解码中的精细约束

规划后的 token 经 MoTok 解码为逐帧条件，在扩散去噪过程中施加**优化引导**：

$$\hat{\mathbf{x}}_k \leftarrow \hat{\mathbf{x}}_k - \eta\nabla_{\hat{\mathbf{x}}_k}\mathcal{L}_{\text{ctrl}}(\hat{\mathbf{x}}_k, \mathbf{c}^s_{1:T})$$

其中 $\mathcal{L}_{\text{ctrl}}$ 衡量与局部条件的偏差（如轨迹误差）。这种**粗到细**设计使规划阶段关注语义、控制阶段处理运动学，避免二者竞争。

4. 实验结果

4.1 文本 + 轨迹可控生成（HumanML3D）

Table 1 结果表明 MoTok 在所有设置下均大幅超越 SOTA：

- **Pelvis 控制**：MoTok-DDM-4 FID 0.029（MaskControl 0.061），Avg.Err. 0.0049m（MaskControl 0.0098m），token 数仅为后者 1/6；
- **Random One 关节**：MoTok-DDM-2 FID 0.025（MaskControl 0.083），Avg.Err. 0.0008m（MaskControl 0.0072m）；
- **全关节（Pelvis+LFoot+LWrist+RFoot+RWrist）**：MoTok-DDM-2 FID **0.014**，随约束增强质量提升（0.033→0.014），而 MaskControl 等方法质量下降；
- 推理速度：**2.63s** vs. MaskControl 32.79s（H100 上）。

关键发现： 轨迹信息作为互补引导而非竞争约束——MoTok 在文本 + 轨迹联合控制下的 FID 优于纯文本生成，得益于条件层次化分离。

4.2 文本到运动生成

在 HumanML3D 上，MoTok-DDM-4 以 1/6 token 预算达到低于 MoMask 的 FID（0.039 vs. 0.045）；MoTok-DDM-2 进一步降至 **0.033**（全方法最优）。AR 变体同样显著提升：MoTok-AR-4 FID 0.053（T2M-GPT 0.141，近 3 倍改进）。在 KIT-ML 上 MoTok 达到最低 FID 0.144（基线最优 0.155）。R-Precision 保持竞争力（Top-3: 0.793–0.799），Diversity 接近真实运动分布（9.411–9.523 vs. 9.503）。

4.3 消融实验

解码器设计。在相同压缩比（$\rho=4$）下，卷积解码器 Recon FID = 0.0704，扩散解码降至 <0.04。DiffusionConv（引入残差 1D 卷积建模局部时序依赖）在所有指标上优于逐帧独立的 DiffusionHead——反映了噪声生成条件下时序一致性的重要性。

时序下采样率。呈非单调权衡：低下采样率产生密集 token 难以在噪声生成下建模，过度压缩丢失必要结构。中等压缩（$\rho=2$ 或 4）最优。

卷积核大小。$k=5$ 整体最优；更大核会过度平滑稀疏 token。最优核大小与压缩比耦合——低压缩率（更多 token）时 $k=7$ 更优，高压缩率时 $k=5$ 更优。

潜在维度。$d=768$ 提供充足容量，更小维度降低表达力导致生成质量和可控性下降。

双路径局部条件注入（Table 4）。仅在 generator 注入：FID 尚可但控制误差大（0.217m）；仅在 decoder 注入：FID 严重退化（0.365）；**双阶段注入**才能同时达到低 FID（0.029）和低误差（0.0049m）。验证了粗到细条件分离的必要性。

4.4 两阶段训练消融（Table 5）

冻结编码器和 codebook，仅训练解码器进行公平比较：扩散解码器在相同离散 token 信息下 Recon FID 从 0.0954 降至 0.0544（VQ 编码器）/0.1347 降至 0.0433（MoTok 编码器）。更有趣的是，MoTok token 在 Motion-to-Text 任务上也表现更优（R@1: 0.488 vs. 0.473；BLEU@4: 15.5 vs. 14.6），说明扩散解码器将高频细节恢复转移到解码端后，离散 token 保留了更丰富的**低频语义信息**。

4.5 CFG 缩放消融

所有变体呈单峰模式；最优 CFG scale 随压缩率变化——低压缩率（更多 token）需要更大 CFG scale 来补偿文本条件的相对弱化。

5. 条件注入变体与扩展

Cross-Attention 注入文本： R-Precision 提升（0.799 vs. 0.779）但 FID 略高，体现不同注入策略在语义对齐与运动真实感间的权衡。

全局运动学条件： 将轨迹特征以全局形式注入（Transformer 提取全局特征后置于文本特征之后），在保留局部注入的前提下几乎无额外增益，表明局部条件已足够。

运动编辑： 将源运动作为局部条件注入（类似轨迹控制），结合文本描述实现条件驱动的运动编辑，在 MotionFix 数据集上验证可行性。

6. 讨论与局限

核心贡献： (1) Perception–Planning–Control 三阶段范式统一 AR/DDM 生成器；(2) MoTok 通过扩散解码实现激进 token 压缩同时保持甚至提升生成质量；(3) 粗到细条件注入使运动学约束增强质量而非降低质量。

局限： (1) 扩散解码引入额外推理开销（尽管总体仍快于 MaskControl 10×+），未来可引入一致性模型加速；(2) 当前在 HumanML3D/KIT-ML 上验证，向更大规模数据集和更复杂运动的泛化有待探索；(3) 运动学条件目前限于轨迹和关键帧，更丰富的物理约束（接触力、碰撞）为未来方向；(4) 扩散解码器的时序建模能力受卷积核大小限制，更长距离依赖或需注意力机制。

MonoArt：基于渐进结构推理的单目铰接 3D 重建

Li*, Xie*, Xu, Wen, Hong, Liu — S-Lab, Nanyang Technological University, 2026

1. 问题动机与背景

从单张图像重建铰接（articulated）3D 物体是计算机视觉与图形学的核心挑战。铰接物体（如笔记本电脑、橱柜）在日常环境中无处不在，其重建不仅需要恢复几何形状，还需理解**部件结构**和**运动学关系**（关节类型、运动轴、运动范围等）。这对机器人操作、场景合成等下游任务至关重要。

现有方法存在三类局限：

- **多视图方法** [25,48,50]：需要同一物体不同铰接状态的多帧图像，实际中难以获取；
- **检索组装方法** [8,18,24]：从预构建资产库检索零件拼接，导致纹理错位和几何不准确；
- **辅助生成方法** [4,12,31]：依赖视频生成、视觉-语言模型或预定义运动方向，计算开销大或泛化性受限。

这些方法的共同问题在于**缺乏内在的 3D 结构理解**，无法从单张图像直接推断部件组成与空间关系。运动线索与物体结构之间的**纠缠**使得直接回归铰接参数不稳定。

2. 系统架构与方法

MonoArt 提出**渐进结构推理**范式：不直接从图像特征回归铰接参数，而是将视觉观察渐进转化为规范几何 → 结构化部件表示 → 运动感知嵌入，在统一架构内实现稳定且可解释的铰接推断。

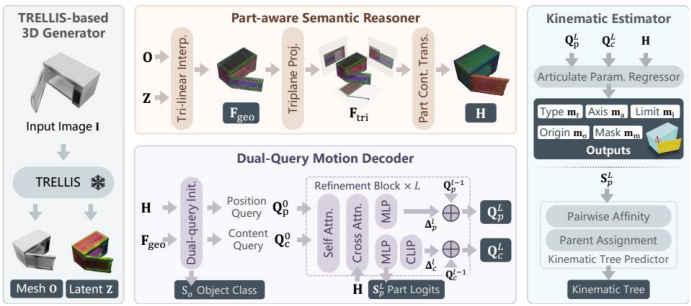

图 1：*MonoArt* 架构总览。从单张图像出发，经 *TRELLIS 3D* 生成器、部件感知语义推理器、双查询运动解码器和运动学估计器，渐进生成铰接 *3D* 重建。

框架包含四个核心组件：

2.1 TRELLIS-based 3D Generator

给定单张 RGB 图像 $\mathbf{I}$，使用冻结的 TRELLIS [52] 骨干网络生成结构化稀疏体素潜表示 $\mathbf{Z} \in \mathbb{R}^{N_z \times N_z \times N_z \times d_1}$（$N_z = 64$），其中活跃体素存储 d_1 维特征，空区域不激活。随后由 TRELLIS 的 mesh decoder 解码为显式 3D 网格 $\mathbf{O}$，作为下游部件推理和铰接推断的**规范几何基础**。TRELLIS 在整个流程中保持冻结，提供稳定的几何先验。

2.2 Part-Aware Semantic Reasoner

目标是从规范几何 $\mathbf{O}$ 和稀疏体素潜表示 $\mathbf{Z}$ 中导出**部件感知点特征** $\mathbf{H}$。包含三个子步骤：

三线性插值。在 $\mathbf{O}$ 表面采样 $M = 100{,}000$ 个点 $\{\mathbf{p}_m\}_{m=1}^M$，通过三线性插值从体素特征体 $\mathbf{Z}$ 获取点对齐特征：

$$\mathbf{f}_m = \mathrm{TrilinearInterp}(\mathbf{Z}, \mathbf{p}_m), \quad \mathbf{F}_{\text{geo}} = \{\mathbf{f}_m\}_{m=1}^M \in \mathbb{R}^{M \times d_1}.$$

三平面投影。将点特征 $\mathbf{F}_{\text{geo}}$ 正交投影到 XY/YZ/ZX 三个平面上，通过双线性插值累积至 $N_t \times N_t$ 的 2D 网格，生成 $\mathbf{F}_{\text{tri}} \in \mathbb{R}^{3 \times N_t \times N_t \times d_1}$（$N_t = 128$），融入全局空间上下文。

Part Contrast Transformer。三平面特征展平为 token 序列 $\mathbf{T} \in \mathbb{R}^{3N_t^2 \times d_1}$，经多层自注意力 Transformer 捕获跨平面全局交互，得到精炼 token $\mathbf{T}'$。每个表面点 $\mathbf{p}_m$ 通过三平面采样查询精炼特征图，经 MLP 提升至 $d_2 = 448$ 维：

$$\mathbf{h}_m = \mathrm{MLP}(\mathrm{TriQuery}(\mathbf{F}'_{\text{tri}}, \mathbf{p}_m)), \quad \mathbf{H} = \{\mathbf{h}_m\}_{m=1}^M.$$

$\mathbf{H}$ 编码部件感知结构表示，通过**三元组对比损失**（triplet loss）在 3D 部件标注下监督训练，强制同部件点特征相近、不同部件点特征远离。

2.3 Dual-Query Motion Decoder

铰接推理需同时建模「什么是可动部件」和「运动在哪里锚定」。采用**双查询**机制解耦语义表示和几何定位：

内容查询 $\mathbf{Q}_c \in \mathbb{R}^{N_q \times d_2}$ 编码部件语义；**位置查询** $\mathbf{Q}_p \in \mathbb{R}^{N_q \times 3}$ 表示空间运动锚点（$N_q = 100$）。

双查询初始化。对 $\mathbf{H}$ 和 $\mathbf{F}_{\text{geo}}$ 做全局池化并拼接，投影生成初始查询 $\mathbf{Q}_c^0$、$\mathbf{Q}_p^0$ 及辅助物体类别预测 S_o。

迭代精炼。$L = 6$ 层精炼块依次处理：(1) 自注意力建模部件间交互；(2) 交叉注意力从视觉特征 $\mathbf{H}$ 检索证据。位置查询和内容查询均采用**残差更新**：

$$\mathbf{Q}_p^l = \mathbf{Q}_p^{l-1} + \Delta_p^l, \quad \mathbf{Q}_c^l = \mathbf{Q}_c^{l-1} + \Delta_c^l.$$

每层还预测部件类别 logits $\mathbf{S}_p^l$，用于检索冻结 CLIP 文本嵌入的语义原型并融入内容分支，增强部件级语义一致性。

查询置信度估计。由于 N_q 为部件数上界，部分查询可能对应无效假设。从精炼内容嵌入 $\mathbf{Q}_{c,i}^L$ 预测置信度 $c_i \in [0,1]$，训练时由 Hungarian 匹配导出监督目标（匹配查询的目标与 mask IoU 成正比，未匹配为零）。推理时低于 0.5 的查询被丢弃，自动确定部件数量。

2.4 Kinematic Estimator

铰接参数回归。位置查询 $\mathbf{Q}_p^L$ 直接解释为**部件质心**。部件掩码通过查询-点匹配得到：$\mathbf{m}_m = \mathbf{Q}_c^L \mathbf{H}^\top \in \mathbb{R}^{N_q \times M}$。整合 $\mathbf{Q}_p^L$、$\mathbf{Q}_c^L$、$\mathbf{H}$ 后由轻量 MLP 头预测：

- 关节类型 $\mathbf{m}_t \in \mathbb{R}^{N_q \times N_t}$(fixed/revolute/prismatic/continuous)；
- 关节轴 $\mathbf{m}_a \in \mathbb{R}^{N_q \times 3}$（单位方向向量）；
- 关节枢轴 $\mathbf{m}_o \in \mathbb{R}^{N_q \times 3}$（采用残差形式 $\mathbf{m}_o = \mathbf{Q}_p^L + \Delta_o$）；
- 运动极限 $\mathbf{m}_l \in \mathbb{R}^{N_q \times 2}$（中心-跨度参数化：$c = (l_{\min} + l_{\max})/2$, $s = (l_{\max} - l_{\min})/2$）。

运动学树预测。通过可学习兼容性矩阵 $\mathbf{C} \in \mathbb{R}^{N_c \times N_c}$ 计算部件间语义连接分数：$\mathbf{S}_{i,j} = \mathbf{s}_i^\top \mathbf{C} \mathbf{s}_j$，归一化后得到父-子关系概率 $P(j|i) = \mathrm{Softmax}(\mathbf{S}_{i,j})$。选择最高概率的父节点，并强制单根无环约束构建有效运动学层次。

3. 训练策略

采用**四阶段训练**（4×A100，约 6 天）：

- **阶段 I**（100 epochs）：仅训练 Part-Aware Semantic Reasoner，使用三元组损失；
- **阶段 II**（20 epochs）：冻结推理器，训练双查询初始化分支（物体类别监督）；
- **阶段 III**（100 epochs）：联合优化推理器、运动解码器和铰接参数回归器，$\ell_{\text{stage3}} = \lambda_{\text{triplet}} \ell_{\text{triplet}} + \lambda_{\text{mask}} \ell_{\text{mask}} + \lambda_{\text{score}} \ell_{\text{score}} + \lambda_{\text{motion}} \ell_{\text{motion}}$；
- **阶段 IV**（30 epochs）：冻结所有前置模块，训练运动学树预测器。

优化器为 AdamW（权重衰减 0.01），FP16 混合精度，梯度裁剪 0.1，学习率 5×10^{-5} 经 10 epoch 预热后余弦退火至 10^{-6}。

4. 实验结果

4.1 评估协议

使用 **PartNet-Mobility** [51]（约 2K 铰接物体，含部件级几何和关节标注）。两种设置：(1) 7 类（遵循 SINGAPO）；(2) 全 46 类（遵循 PhysX-Anything）。

几何指标：对每个物体沿预测运动范围均匀采样 6 个铰接状态，计算 Chamfer Distance (CD)、F-Score（阈值 0.05）、PSNR 和 CLIP 相似度。**运动学指标**：关节类型准确率、轴方向误差（$e_{\text{axis}} = \min(\arccos(\cdot), \arccos(-\cdot))$）和枢轴距离误差。

4.2 主要定量结果

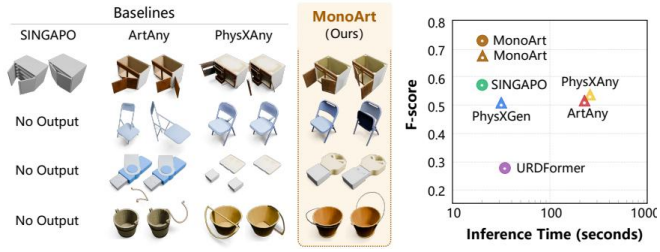

图 2: *F-Score vs.* 推理时间。*MonoArt* 同时实现最高精度和极低推理时间。

方法	CD↓	F-Score↑	Type%↑	Pivot↓
7 类设置				
URDFormer	4.73	0.275	35.22	0.404
SINGAPO	1.26	0.572	77.12	0.201
MonoArt	**0.77**	**0.728**	**88.26**	**0.085**
46 类设置				
ArtAny	2.07	0.514	43.32	0.347
PhysXAny	1.88	0.531	63.35	0.173
MonoArt	**1.25**	**0.670**	**67.47**	**0.108**

7 类设置下,MonoArt 在所有指标上大幅领先:F-Score 0.728（SINGAPO 0.572），关节类型准确率 88.26%（SINGAPO 77.12%),枢轴误差降至 0.085(SINGAPO 0.201,降幅 >57%)。46 类设置下同样最优，枢轴误差较 PhysXAny 降低 >40%。

推理速度：MonoArt 单实例仅需 **20.5s**（A6000），其中 18.2s 为 TRELLIS 3D 重建，铰接推理仅 2.3s 边际开销。对比：Articulate-Anything 229.9s、PhysXAnything 256.8s、SINGAPO 19.6s。

真实世界泛化：收集约 100 张网络野外图片，用户研究（20 人）中 MonoArt 获最高评分（几何 4.63/5，运动学 4.37/5），远超 PhysXAny（3.34/3.12）和 SINGAPO（2.55/2.87）。

4.3 消融实验

Part-Aware Semantic Reasoner 消融（表 2）：移除推理器后几何和运动学均显著退化（Type Acc. 从 67.47% 降至 24.72%，Pivot Err. 从 0.108 升至 0.237）。三元组损失远优于交叉熵损失（Type Acc. 67.47% vs. 57.74%）和无监督（41.60%），证实判别性部件感知特征的关键作用。特征可视化（PCA）显示三元组监督产生紧凑且分离良好的部件聚类。

Dual-Query Motion Decoder 消融（表 3）：禁用双查询初始化（DQI）后 Pivot Err. 从 0.108 急升至 0.329。仅更新位置或内容查询之一均次优，双分支残差更新最佳。精炼层数 $L = 6$ 最优，$L = 9$ 反而退化（过拟合）。$L = 0$（不精炼）时 Axis Err. 0.640 vs. $L = 6$ 时 0.423。

Kinematic Estimator 消融（表 4）：不使用质心残差预测关节原点使 Pivot Err. 从 0.108 升至 0.191。去除点嵌入 **H** 后 Type Acc. 从 67.47% 骤降至 27.14%，证实点级特征对参数回归的重要性。

5. 下游应用

机器人操作。MonoArt 推断的铰接参数（关节轴、类型、运动极限）可直接导入 IsaacSim [36]。野外图片重建的铰接物体可被 Franka 机械臂直接操作（抓取、开启），无需额外建模——实现实用的 real-to-sim 流水线。

铰接场景重建。结合 SAM3D [42] 的静态场景重建（逐物体掩码和 6D 位姿），MonoArt 对每个物体实例恢复几何和铰接参数，替换回场景中，将刚性场景转化为功能可操作环境，铰接物体保持运动学结构且与全局布局一致。

6. 讨论与局限

核心贡献：首个基于渐进结构推理的统一端到端单目铰接 3D 重建框架，无需多视图监督、检索库、视频合成或手工运动先验。通过显式建模几何 → 部件 → 运动的级联结构，实现了精度与效率的同步提升。

主要局限：

- **极端尺度不平衡**：对大物体上附着的极小部件（如打印机按钮），均匀点采样导致覆盖稀疏，特征不够判别性，铰接分割和参数化困难；
- **未见拓扑泛化**：依赖学习的部件-整体结构先验，对新颖拓扑或罕见铰接模式（如自行车）的运动参数预测可能不准确；
- **几何依赖**：铰接推理质量受上游 TRELLIS 3D 重建质量约束，18.2s/20.5s 的推理时间中绝大部分为 3D 生成开销；
- 未来方向包括自适应采样策略、扩展至更复杂铰接拓扑和大规模场景。

CubiD：基于高维表征 Token 的立方离散扩散视觉生成

Wang[1], Ma[1], Lin[2], Teng[1], Yu[3], Wang[4], Han[5], Feng[2], Jiang[2], Liu[1*] — [1]HKU, [2]ByteDance Seed, [3]CMU, [4]NJU, [5]CUHK, 2025

1. 动机与核心问题

统一多模态建模要求视觉和语言共享语义丰富的 token 空间。语言模型天然支持语义 token 的理解与生成，但视觉模型存在**割裂**——理解任务依赖高维语义特征（768–1024 维），生成任务却局限于低维压缩 token（8–32 维）。近期工作表明高维表征特征可实现高质量重建，若离散生成模型能直接建模这些高维 token，将实现**同一套离散 token 同时服务理解与生成**，为统一多模态架构铺路。

然而高维离散 token 的生成面临两大根本挑战：

- **离散化难题**：传统 Vector Quantization (VQ) 在高维空间（768+ 维）因维度灾难失效——数据稀疏、码本指数膨胀，量化特征偏离原始表征，破坏语义信息；
- **建模难题**：离散化后产生 $h \times w \times d$ 个 token（典型配置 $16 \times 16 \times 768 = 196{,}608$ 个）。自回归生成需 $O(hwd)$ 步，不可行；标准离散扩散（如 MaskGIT）以空间位置为原子单位进行 mask，无法捕获位置内各维度间的依赖关系。

本文提出 **Cubic Discrete Diffusion (CubiD)**，首个面向高维表征 token 的离散生成模型。核心思想：将 $h \times w \times d$ 张量视为统一的三维立方空间，在空间轴和维度轴上同时进行**细粒度 mask**——任意位置的任意维度均可被独立 mask 与预测，从而学习位置内（intra-position）和位置间（inter-position）的复杂依赖，且生成步数固定为 T（$T \ll hwd$），与特征维度解耦。

2. 系统架构与方法

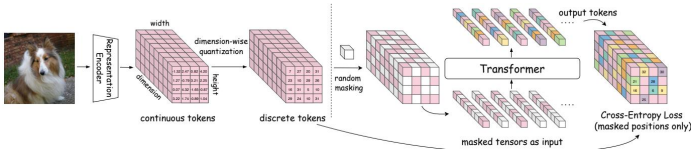

图 1：*CubiD* 概览。*(a)* 冻结编码器提取高维连续特征，经逐维量化得到 $h \times w \times d$ 离散 *token*。*(b)* 训练时在空间和维度轴上随机 *mask* 并预测，*Transformer* 学习跨轴依赖。

2.1 高维 Token 离散化：逐维量化

给定冻结预训练编码器 E（DINOv2 或 SigLIP2，patch size p），输入图像 $\mathbf{x} \in \mathbb{R}^{H \times W \times 3}$ 产生特征图 $\mathbf{z} = E(\mathbf{x}) \in \mathbb{R}^{h \times w \times d}$，其中 $h = H/p$, $w = W/p$, $d \in \{768, 1024\}$。

采用**逐维量化**（Dimension-wise Quantization, DQ）：对每个标量值独立量化为 L 个离散级别：

$$q_{x,y,i} = \text{Quantize}(z_{x,y,i}; L)$$

其中 $z_{x,y,i}$ 为空间位置 (x, y) 的第 i 维。与 VQ 不同，DQ 逐维独立操作，回避高维聚类困难，且为 training-free 方法可直接作用于冻结特征。

量化级别选择：DINOv2 在 $L = 8$ 时即达到连续基线重建质量（rFID = 0.57），SigLIP2 在 $L = 16$ 时达到基线（rFID = 0.69）。不同编码器的最优 L 反映了特征分布差异。

理解能力验证：在 LLaVA 框架下，SigLIP2-DQ 在 GQA（63.1 vs 63.2）、TextVQA（59.8 vs 59.6）、POPE（85.0 vs 85.4）、MME（1480 vs 1484）上与连续特征几乎一致，而 SigLIP2-VQ 全面大幅退化（GQA 54.9, TextVQA 45.6, MME 1189）。这证实 DQ 完整保留了高维 token 的语义理解能力。

2.2 立方离散扩散：跨轴细粒度 Mask 建模

训练过程。给定离散 token $\mathbf{q} \in \{0, \ldots, L-1\}^{h \times w \times d}$，施加二值 mask $\mathbf{M} \in \{0, 1\}^{h \times w \times d}$，每个元素**独立随机** mask。Mask 比例 r 从截断高斯分布采样：

$$r \sim \text{TruncNorm}(\mu = 1.0, \sigma, [0, 1.0])$$

$\mu = 1.0$ 偏向激进 mask，鼓励模型从极少上下文学习鲁棒预测。被 mask 位置替换为可学习的 [MASK] token，模型通过交叉熵损失预测原始类别：

$$\mathcal{L} = -\mathbb{E}_{\mathbf{q},\mathbf{M}} \left[\sum_{i \in \mathbf{M}} \log p(q_i | \mathbf{q}_{\bar{\mathbf{M}}}) \right]$$

其中 $\mathbf{q}_{\bar{\mathbf{M}}}$ 为可见 token 上下文。细粒度 mask 使模型在每个位置观察到部分维度，学习维度间如何联合编码信息并相互约束。

推理过程。从全 mask 张量出发，迭代去 mask。每步模型并行预测所有 mask token，随机选择子集去 mask。去 mask 数量遵循余弦调度，实现**粗到细**生成——早期确立整体结构，后期精修细节。关键优势：生成仅需 $O(T)$ 步（数百步），与维度 d 无关。

2.3 模型架构

CubiD 采用标准双向注意力 Transformer。每个空间位置的 d 个 token 被反量化为连续标量（[MASK] 映射为可学习值），拼接为 d 维向量，形成 $h \times w$ 长度的序列。Transformer 序列长度仅取决于空间分辨率而非 d，**计算复杂度与特征维度解耦**。每个输出 token 经 MLP 预测头产生 $d \times L$ 个 logits，同时预测该位置所有 d 个维度。

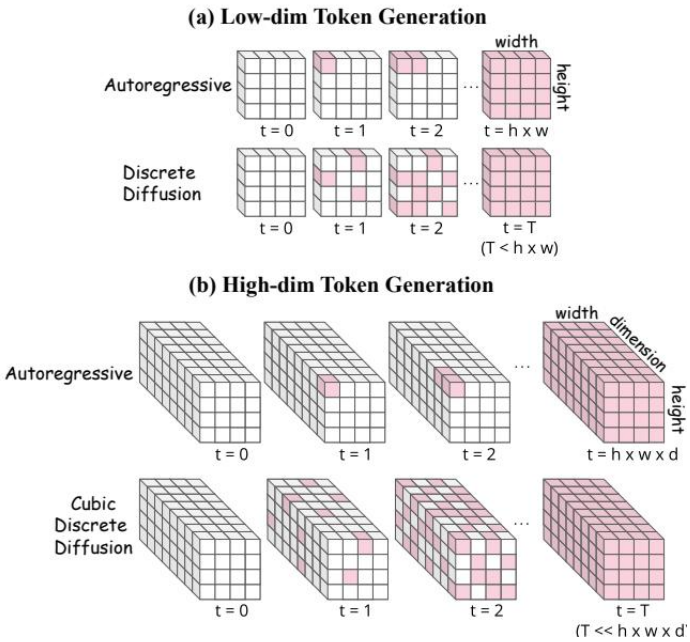

图 2：离散视觉生成方法对比。低维 *token* 中 *AR* 需 $h \times w$ 步、离散扩散 $T < hw$ 步；高维 *token* 中 *AR* 不可行（hwd 步），标准离散扩散无法建模位置内依赖。*CubiD* 在整个 *3D* 张量上细粒度 *mask*，$T \ll hwd$ 步完成生成。

三种模型规模：CubiD-L（1536 hidden dim, 946M 参数）、CubiD-XL（1920, 1.4B）、CubiD-XXL（3072, 3.7B），均使用 16 头注意力、MLP ratio 4。

3. 消融实验

3.1 Mask 比例分布

截断高斯的标准差 σ 控制 mask 场景多样性。$\sigma = 0.10$ 最优（gFID = 5.33），$\sigma = 0.05$ 过度集中于高 mask 率导致退化（7.65），$\sigma = 0.15$ 覆盖过均匀（5.81）。高维特征的固有冗余使激进 mask 训练有效。

3.2 Mask 粒度——核心消融

三种策略对比揭示细粒度 mask 的必要性：

- **Per-dim**（每维度 mask 所有空间位置）：gFID = 120.03，完全失败，严重纹理伪影——要求所有空间位置并行生成，破坏空间一致性；
- **Per-spatial**（每位置 mask 所有维度）：gFID = 22.22，图像模糊、局部不一致——768 维联合编码语义，整体 mask 阻止模型利用位置内相关性；
- **Per-element**（逐元素独立 mask，本文方法）：gFID = 5.33，图像清晰连贯。

这证实高维 token 中空间位置和维度均不可完全解耦，必须在两个轴上同时进行细粒度建模。

3.3 Mask Token 设计

可学习 mask token 最优（gFID = 5.33），固定零值次之（5.56），随机采样严重失败（56.38）——随机值与内容 token 同分布，模型无法区分 mask 与真实 token。

3.4 推理步数

尽管需生成 196,608 个离散 token，仅需数百步：64 步 gFID = 9.14，256 步 5.33，512 步 5.25 后饱和。相比 AR 方法需全部 196,608 步，效率提升**数百倍**。

3.5 模型缩放

946M → 1.4B → 3.7B，gFID 从 5.25 → 4.91 → 4.68，展现**稳定缩放行为**，表明立方离散扩散能有效利用增大的模型容量。

3.6 编码器泛化

DINOv2（gFID = 5.25）与 SigLIP2（5.87）均表现良好。DINOv2 略优可能源于其 ImageNet 预训练与评估指标更对齐。跨编码器一致性验证了方法的鲁棒性。

4. 主要结果

方法	Dim	参数	gFID↓	gFID (cfg)↓
低维离散扩散				
MaskGIT	16	227M	6.18	4.02^{re}
Token-Critic	16	368M	4.69	–
TiTok-S-128	16	287M	–	1.97
低维自回归				
LlamaGen-XXL	8	1.4B	14.6	2.34
VAR	32	2.0B	2.16	1.97
VFMTok-XXL	12	1.4B	1.95	2.19
VFMTok-3B	12	3.1B	2.04	2.07
高维离散（本文）				
CubiD-L	768	946M	2.38	2.37
CubiD-XL	768	1.4B	2.06	2.04
CubiD-XXL	768	3.7B	2.02	**1.88**

ImageNet 256 × 256 类条件生成结果。CubiD 是**唯一直接生成原生高维（768d）表征 token 的离散方法**，所有其他方法均使用 ≤128 维压缩 token。

关键发现：(1) CubiD-XXL 以 gFID = 1.88 达到**离散生成 SOTA**；(2) 表征 token 对 classifier-free guidance 依赖极低——无 cfg 时 CubiD-XXL（2.02）即超越大多数 VAE 方法（MaskGIT 6.18, LlamaGen 14.6）；(3) 对比 VFMTok：后者将表征特征重组为 12 维 VQ token，改变了 token 空间，限制理解任务适用性，且扩大参数（1.4B → 3.1B）反而退化（1.95 → 2.04）；CubiD 在原始高维空间直接生成，且持续受益于缩放（2.37 → 2.04 → 1.88）。

低维 token 实验：CubiD 在 DC-AE-f32c32 的 32 维 token 上（ImageNet 512 × 512）达到 gFID = 1.58，超越 USiT-2B（1.72, 1.58B 参数），以更少参数（0.95B）验证了方法的跨维度通用性。压缩至 32 维的表征 token 亦获 gFID = 1.55，但压缩不可避免地损失理解能力，故选择建模原始高维 token。

5. 与相关工作对比

vs. MaskGIT/离散扩散：MaskGIT 以空间位置为 mask 原子单位，适用于低维 token（每位置单 token），无法扩展至高维——无法捕获位置内 768 维间的依赖。CubiD 将 mask 粒度细化到逐元素，使离散扩散首次适用于高维 token。

vs. 自回归模型：AR 模型（LlamaGen, VAR）在低维 token 上表现优异，但高维场景需 $O(hwd) = O(196{,}608)$ 步，计算不可行。CubiD 以 $O(T)$（数百步）并行生成解决此瓶颈。

vs. VFMTok：VFMTok 通过 deformable attention 和 region-adaptive 机制将高维表征重组为 12 维 VQ token，从根本上改变了 token 空间，限制了 token 在理解任务中的复用。CubiD 保持原始表征空间不变，同一 token 同时服务理解和生成。

vs. RAE（连续扩散）：RAE 直接在高维连续空间做扩散生成，质量仍优于离散方法。但离散 token 与语言模型共享交叉熵范式，是统一多模态架构的更自然选择。

6. 局限性与未来方向

- **编码器重建上限**：生成质量受限于冻结编码器的重建能力（PSNR ≈ 18 dB），限制了精细细节生成。提升表征自编码器的重建质量是重要方向；
- **与连续生成的差距**：离散生成在统一建模上具优势（共享交叉熵目标），但与连续扩散方法（如 RAE）仍有质量差距，需离散生成建模技术的进一步发展；
- **推理效率**：需数百至上千步，多于连续扩散模型。借鉴离散语言模型的加速技术（如并行解码）是有前景方向；
- **分辨率扩展**：当前验证限于 256 × 256，更高分辨率下 $h \times w$ 增大带来更长序列，需探索高效注意力机制；
- **统一架构验证**：虽证明了同一离散 token 可服务理解与生成，但完整的统一多模态架构（如与 LLM 联合训练）尚待验证。

7. 总结

CubiD 首次证明了高维离散表征 token 的生成可行性与有效性。通过将 $h \times w \times d$ 张量视为统一立方空间进行逐元素 mask 建模，将不可行的 $O(hwd)$ 序列生成转化为 $O(T)$ 并行迭代。逐维量化完整保留了原始表征的语义理解能力（LLaVA 基准几乎无损），而立方离散扩散在 ImageNet 256 × 256 上以 768 维 token 达到 1.88 gFID 的离散生成 SOTA。同一套离散 token 同时服务理解与生成的验证，为未来统一多模态架构提供了坚实基础。

LVOmniBench：面向长音视频理解的全模态 LLM 评估基准

Tao*, Zheng*, Xu, Du, Shao, Wang, Chen, Jin, Zhu, Yu, Wang, Liu, Qin, Zhang, Yang, Wang — 浙大/西湖大学/蚂蚁/上交/UC Merced, 2025

1. 动机与问题定义

全模态大语言模型（OmniLLMs）在音视频理解方面取得显著进展，但现有评估基准存在根本性缺陷：

- **时长过短**：现有音视频基准（AVQA、Music-AVQA、WorldSense、OmniVideoBench 等）视频平均时长仅 10 秒至 6 分钟，远不及真实场景中数十分钟的典型视频长度；
- **模态割裂**：多数基准仅评估静态图像-音频对或短视频片段，无法考察长时序跨模态对齐与联合推理能力；
- **标注质量**：部分基准依赖 LLM 自动生成问题，难以捕捉复杂推理需求且易产生幻觉；
- **缺乏层次化评估**：已有基准未按认知难度对问题进行分级，无法实现模型能力的精细化诊断。

LVOmniBench 是首个专门评估 OmniLLMs 在**长时音视频联合理解**上的综合基准。核心特征：275 个高质量长视频（10–90 分钟，平均 34 分 29 秒，总计 140 小时），1,014 个严格人工标注的多选 QA 对，平均时长是现有基准的 **6–20 倍**。所有问题均要求跨模态音视频联合推理，按感知/理解/推理/逻辑四大类型和低/中/高三级难度进行层次化分级。

基准对比	平均视频时长（秒）
AVQA / Music-AVQA	10 / 60
WorldSense	141.1
OmniVideoBench	384.2
Daily-Omni	42.8
LVOmniBench（本文）	**2069.7（6×+）**

2. 数据集构建流程

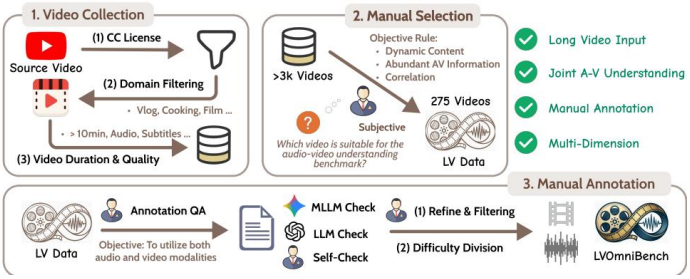

图 1：*LVOmniBench* 构建流程：视频收集 → 过滤 → 问题标注，全程严格人工把控。

2.1 视频收集与过滤

从 YouTube 采集遵循 Creative Commons 许可的视频，覆盖 **5 大类别、21 个细分子类**（娱乐、生活、DIY & 烹饪、纪录、影视）。通过关键词筛选收集超过 3,000 个原始视频（10–90 分钟，含同步音轨），经严格的时长、质量和音视频动态性过滤，最终精选 **275 个**高质量长视频。大多数视频时长集中在 20–45 分钟，符合真实场景分布。

2.2 问题标注

采用多选题格式（4 选项 A/B/C/D），每个视频标注 1–20 个问题（按时长和音视频事件密度调整）。严格标注准则：

- 问题**必须**需要音视频联合推理，防止单模态偏差，正确选项唯一无歧义；
- 不能仅凭常识回答；四个选项长度均匀，干扰项直接来源于视频/音频内容；
- 最小化显式时间戳使用，避免提供直接定位捷径。

首轮标注产生 1,500+ 候选 QA 对。

2.3 问题精炼与过滤

利用 Gemini 模型分别在三种单模态基线（仅视频、仅音频、仅文本）上进行推理测试。要求标注者修改或删除能被单一模态回答的问题（说明标注未真正整合音视频线索）。同时利用模型推理摘要过滤依赖常识和设计缺陷的问题，剔除过度依赖时间戳和显式描述的问题。最终获得 **1,014 个** QA 对。

2.4 难度分级

每个 QA 对从感知难度、信息粒度、时间跨度和推理复杂度多维度评估，分为**低/中/高**三级。最终分布：低 314、中 441、高 259。

3. 问题类型体系

感知（Perception）：评估基础声学和视觉特征提取能力——计数（Counting）、属性感知（Attribute Perception）、音乐感知（Music Perception）。验证模型从长上下文中提取细粒度信息的能力。

理解（Understanding）：评估实体识别、动作理解和场景中的上下文角色——人物中心理解（身份追踪、情绪识别、行为建模）和细粒度事件理解。测试模型在长时上下文中综合互补音视频线索的能力。

推理（Inference）：评估复杂时空动态理解和声音事件推理——声音推理（Sound Inference）、空间推理（Spatial Inference）、时间推理（Temporal Inference），要求严格的跨模态时空对齐。

逻辑（Logical）：要求多步推理、因果追踪和基于互补跨模态信息的复杂推理，不能通过浅层特征匹配或基础音视频对齐解决，需理解长程上下文依赖。

4. 数据集统计

总视频数	275	总问题数	1,014
类别数	21	问题类型	9
音频类型	语音 + 音效 + 音乐	难度分布	314:441:259
时长范围	613–5482s	平均问题长度	16.4 词
平均时长	34:29	选项格式	4 (A/B/C/D)

音频类型分布：语音 763、音乐 137、音效 114，反映真实场景中语音驱动交互的主导地位。

5. 实验设置

模型选择。闭源：Gemini 3.0 Pro/Flash、Gemini 2.0 Flash。开源 OmniLLMs：Ming-Flash-Omni-2.0-100B、MiniCPM-o 4.5、Qwen3-Omni-30B、video-SALMONN 2+ 7B、Qwen2.5-Omni-7B、VideoLLaMA2-7B。视频 LLMs：Qwen3-VL-8B/30B。音频 LLMs：Qwen2-Audio。

推理配置。Qwen2.5-Omni、Qwen3-Omni、Qwen3-VL、video-SALMONN 2+ 输入 768 帧；MiniCPM-o 4.5 限 64 帧；VideoLLaMA2-7B 限 16 帧。Gemini 系列 1 FPS 并启用深度思考模式。硬件：NVIDIA H100 (80GB) 和 L40S (48GB)。

6. 核心实验结果

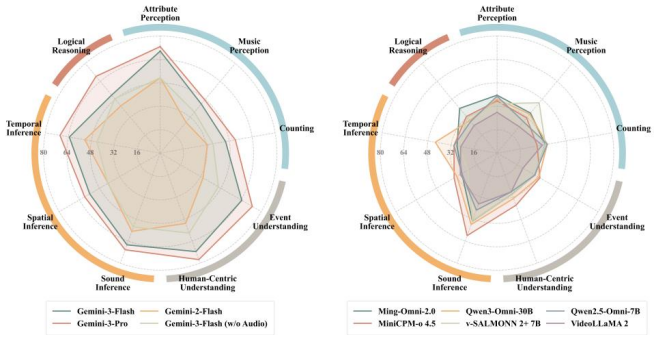

图 2：闭源与开源模型在各任务上的性能对比。蓝/红/橙/灰分别代表感知/逻辑/推理/理解任务。

6.1 闭源模型表现

模型	低	中	高	Avg.
Gemini 3.0 Pro	79.3	68.1	45.0	**65.8**
Gemini 3.0 Flash	76.6	63.0	31.0	59.0
Gemini 2.0 Flash	57.0	48.9	29.8	42.9

Gemini 3.0 系列准确率最高，Pro 达 **65.8%**，Flash 达 59.0%，较 Gemini 2.0 Flash 提升约 1.5 倍。准确率分布与标注难度梯度高度一致，Pro 在高难度问题上仍保持 45%。计数和音乐感知任务仍极具挑战性。非语言和抽象音频（音乐类）感知能力显著低于语音和音效类。

6.2 开源模型表现

模型	低	中	高	Avg.
Qwen3-Omni-30B	41.0	36.3	28.6	35.8
MiniCPM-o 4.5	43.4	34.1	25.1	34.8
Ming-Omni-2.0-100B	41.3	32.9	29.3	34.6
Qwen2.5-Omni-7B	37.7	29.9	28.3	32.0
VideoLLaMA2-7B	27.0	26.8	28.2	27.2

所有开源模型准确率均低于 **35%**，高难度任务性能退化至接近随机水平。30–35% 的准确率主要反映模型依赖浅层视觉先验而非真正的跨模态理解。各模型在不同子任务上各有所长：Qwen3-Omni 擅长时间推理，Ming-Omni 逻辑推理较强，MiniCPM-o 音频感知相对更好。

6.3 单模态基线与音频消融

视频 LLMs（Qwen3-VL-30B）仅达 36.3%，尽管专门针对长视频优化。**音频 LLMs**（Qwen2-Audio）仅 24.7%。验证了基准确实需要音视频联合推理。

关键消融：Gemini 3 Flash 仅用视频（去除音频）准确率从 59.0% 降至 **46.2%**（−12.8%），明确验证音频线索在基准中的必要性。

开源模型能否真正利用音频? 用 Gemini 2.5 生成 ASR 文本替代原始音频后，Qwen3-Omni 从 35.8% 升至 42.2%（+6.4%），Ming-Omni 从 34.6% 升至 40.5%（+5.9%）。说明开源模型**无法有效利用长音频信息**，ASR 文本作为显式补充线索反而效果更好。但 Gemini 3 Flash 使用原始音频（59.0%）优于 ASR 替代（52.0%），表明原始音频包含关键非语言信号（情感、语调、音乐性），超越纯文本语义。

7. 错误分析

对 Gemini 3 Flash 的 153 个错误预测进行人工分类：

感知错误（34%）： 分为音频和视觉两类（分别占 60% 和 40%）。音频感知失败主要源于模态偏差——模型过度依赖视觉线索而忽略音频信号；细粒度声学属性（音强、音色、音高）感知困难。视觉感知错误主要源于空间推理和细节理解不足（物体计数、空间方向、视觉属性识别）。

定位错误（19.6%）： 长音视频跨越数十分钟，精确时间定位至关重要。音视频联合定位研究仍严重不足。

跨模态语义鸿沟（19%）： 模型常孤立处理两种模态，难以以符合人类认知的方式融合对齐互补信息。即使能独立理解音频和视频流，跨模态对应能力仍然薄弱。

推理错误（23.5%）： 即使成功感知双模态及跨模态对齐，模型在逻辑演绎、数学推理、复杂时空动态（动作排序、事件因果）和空间关系推理方面仍频繁失败。

其他错误（4%）： OCR 错误（2%）和情感感知错误（2%）。

8. 关键发现与启示

闭源模型决定性领先。Gemini 3 Pro（65.8%）在所有任务和音频类别上全面超越开源模型（<35%）。与纯视频理解不同（开源已高度竞争），联合音视频处理和精细跨模态对齐仍是开源模型的显著短板。

长音频建模是核心瓶颈。随视频时长增加，模型性能相比短视频基准显著下降。音频具有高信息密度和严格的序列依赖性，当前长视频理解的 token 压缩策略对音频模态尚无有效解决方案。增强长音频建模能力是下一代 OmniLLMs 的关键。

跨模态对齐亟待突破。模型频繁出现模态偏差（过度依赖单一模态特征），非语言音频（音乐、音效）的跨模态对齐尤为薄弱。

9. 局限与未来方向

- 数据集规模可进一步扩展（更多视频、更长时长、更多语言）；
- 当前仅评估多选题格式，开放式问答和生成式评估待探索；
- 音视频联合时间定位研究严重不足，缺乏专门的方法和基准；
- 长音频高效处理机制（类比视频 token 压缩）是关键开放问题；
- 细粒度声学属性（音色、音高、音强）感知能力需显著提升；
- 原始音频信号的充分利用（vs. ASR 文本替代）是 OmniLLMs 的重要改进方向。

Memento-Skills：让智能体设计智能体

Zhou, Guo, Liu, Yu, Gong, Zhao, Chen, Zhang 等 — UCL, HKUST(GZ), Jilin Univ., 2025

1. 问题动机与背景

现代 LLM 智能体在部署时通常**参数冻结**——预训练完成后 θ 不再更新。这导致一个根本限制：智能体**无状态**，无法从自身部署经验中学习。每次遇到新任务仅依赖 θ 中编码的知识和有限上下文窗口。参数更新（微调）需要大量数据和算力，实际中大多数智能体以冻结模型运行。

现有自动技能学习方法要么仅生成文本指南(本质是 prompt 优化)，要么对单任务轨迹过拟合、迁移性差。Memento-Skills 提出将**可执行技能**作为外部记忆单元，通过 Read–Write 反思学习循环实现持续学习，**无需更新 LLM 参数**。系统本质上是一个 “设计智能体的智能体”——自主构建、适配和改进任务特定的智能体。

2. 理论基础：有状态反思决策过程

2.1 技能记忆与 SRDP

定义（技能记忆）： $\mathcal{M}_t = \{c_i\}_{i=1}^{N_t}$ 是有限、增长的可复用技能制品集合。每个 c_i 封装声明性规范、提示和可执行代码，而非传统 episodic memory 的原始转移记录。

定义（SRDP）： $\mathcal{D}_{\text{SRDP}} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, R, \gamma, \mathfrak{M}, p_{\text{LLM}} \rangle$，在标准 MDP 基础上增加 episodic memory $\mathfrak{M}$ 和 LLM 决策核 $p_{\text{LLM}}(a \mid s, c)$。策略形式化为：

$$\pi^{\mu}(a \mid s, \mathcal{M}_t) = \sum_{c \in \mathcal{M}_t} \mu(c \mid s, \mathcal{M}_t)\, p_{\text{LLM}}(a \mid s, c)$$

其中 μ 是检索策略。关键洞察：将状态扩展为 $x_t := (s_t, \mathcal{M}_t)$ 后恢复 Markov 性质。

2.2 Reflected MDP 与收敛保证

Reflected MDP $\mathcal{D}_{\text{ReMDP}} = \langle \mathcal{X}, \mathcal{C}, \mathcal{P}^{\text{LLM}}, R^{\text{LLM}}, \gamma \rangle$ 的转移核为：

$$\mathcal{P}^{\text{LLM}}(x' \mid x, c) = \sum_{a \in \mathcal{A}} p_{\text{LLM}}(a \mid s, c) \mathbf{1}\{x' = (s', \text{Write}(\mathcal{M}, s, a, r))\} \mathcal{P}(s' \mid s, a)$$

$\text{Write}(\mathcal{M}, s, a, r)$ 不是简单追加，而是封装技能级反思更新——失败归因和文件级重写。

定理 1.3（收敛性）： 在有界奖励 $|r| \le R_{\max}$ 和 $\gamma < 1$ 下，Reflected MDP 上的 KL 正则化软策略迭代收敛到最优检索策略 μ^*。

3. 系统架构

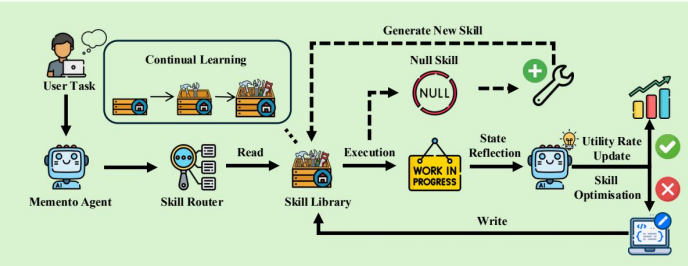

图 1: *Memento-Skills* 自进化智能体架构。用户提交任务后，技能路由器从技能库检索或生成新技能并执行，随后基于反馈写回技能库，形成持续学习闭环。

系统由以下核心组件构成（图 1）：

(1) 技能库（Skill Library）。存储可复用技能文件夹，每个技能包含声明性规范 `SKILL.md`、辅助脚本和提示。技能是记忆和策略的统一体——技能内容直接决定下一轮执行行为。

(2) 技能路由器（Skill Router）。行为对齐的对比检索模型，通过单步离线 RL 训练，优化执行成功率而非语义相似度。融合稀疏 BM25 召回和稠密 embedding 检索，经 reciprocal rank fusion 融合后可选 cross-encoder 重排。

(3) LLM 执行核心。冻结的 LLM（Gemini-3.1-Flash）在检索到的技能上下文条件下执行多步工作流。

(4) 自进化引擎（Evolution Engine）。将任务失败转化为系统成长：失败归因选择器识别最相关技能，技能重写器提出文件级更新，当技能效用低于阈值时触发技能发现（重构或合成新技能）。所有变异经自动单元测试门控保护。

4. Read–Write 反思学习循环

核心循环五步走：**Observe** → **Read** → **Act** → **Feedback** → **Write**。

Read（策略改进）： 路由器根据当前查询和累积 tip memory 检索最相关技能，条件化 LLM 生成动作。

Write（策略评估 + 改进）：

- **效用更新**：$U_{t+1}(c_t) = n_{\text{succ}}(c_t)/(n_{\text{succ}}(c_t) + n_{\text{fail}}(c_t))$；
- **Tip memory**：失败时生成通用提示追加到 $\mathcal{T}_{t+1}$；
- **技能进化**：失败归因选择器定位责任技能 $c^{\dagger}$。若 $U_t(c^{\dagger}) < \delta$ 且样本量 $\ge n_{\min}$，触发技能发现（DiscoverSkill）；否则原地优化（OptimiseSkill）；
- **反馈重试**：更新技能后重新执行，最多 K 轮。

这一机制类比**生物运动学习**：早期技能依赖高层规划，反复练习后神经通路固化为自动执行。类似地，新创建的技能可能脆弱、范围窄，经迭代修订后巩固为鲁棒的可复用例程。

5. InfoNCE 路由：单步软策略

纯语义路由器（BM25 或 embedding）捕捉的是语义相似度而非**行为相似度**——即执行该技能是否能产生期望结果。系统采用单步离线 RL 训练行为对齐路由器。

数据构建： 爬取约 8k 技能数据库，采样 3k 为种子，用 LLM 合成正查询和困难负查询（同领域同术语但目标技能不适用），经 LLM judge 过滤质量。

评分与损失： 编码器 $\text{enc}_\theta(\cdot)$ 将技能文档 d 和查询 q 映射到 $\mathbb{R}^m$，评分 $s(d, q) = e(d)^{\top} u(q)$。多正例 InfoNCE 损失：

$$\mathcal{L}_i = -\log \frac{\sum_{q \in \mathcal{Q}_i^+} \exp(s(d_i, q)/\tau)}{\sum_{q \in \mathcal{Q}} \exp(s(d_i, q)/\tau)}$$

单步离线 Q-learning 视角： 路由建模为单步 MDP（状态 q，动作 d，奖励 $r(q, d)$）。学习到的评分解释为软 Q 函数，产生 Boltzmann 路由策略：

$$\pi_\theta(d \mid q) = \frac{\exp(Q_\theta(q, d)/\tau)}{\sum_{d'} \exp(Q_\theta(q, d')/\tau)}$$

等价于 KL 正则化目标的最大化器：$\pi^* = \arg\max_\pi \{\mathbb{E}_{d \sim \pi}[Q_\theta(q, d)] - \tau \text{KL}(\pi \| \pi_0)\}$。温度 τ 控制探索-利用平衡。

6. 实验评估

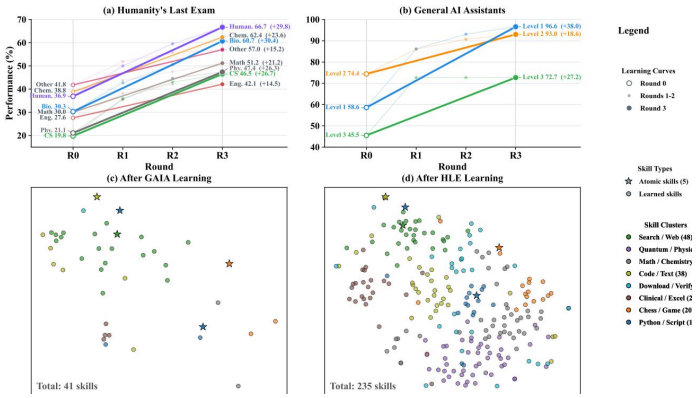

图 2: *Memento-Skills* 在 *HLE* 和 *GAIA* 上的自进化结果。*(a, b)* 反思学习轮次中任务性能持续提升；*(c, d)* 技能库对应增长并形成语义聚类。

6.1 基准与设置

GAIA：165 道真实多步推理题（100 训练 / 65 测试），需网页浏览、工具使用、多模态处理。**HLE**：2500 道专家级学术题跨 8 个学科（788 训练 / 342 测试）。基线为 Read-Write 消融（保留检索和执行但禁用所有技能优化）。底层 LLM 均为 Gemini-3.1-Flash。

6.2 GAIA 结果

最多 3 轮反思重试。训练成功率从首次的 65.1% 升至第三轮的 91.6%。测试集：Memento-Skills 达 **66.0**%，Read-Write 消融为 52.3%，**提升 13.7 个百分点**（相对提升 26.2%）。但 GAIA 问题高度多样，训练中优化的技能在测试中很少被触发——跨任务迁移有限，因缺乏领域结构对齐。

6.3 HLE 结果

四轮训练（R0–R3），整体成功率从 30.8% 升至 54.5%。人文学科和生物学受益最大（分别达 66.7% 和 60.7%），工程类较早饱和于 42.1%。测试集：Memento-Skills 达 **38.7**%，Read-Write 消融仅 17.9%，**提升 20.8 个百分点**（相对提升 116.2%）。HLE 的结构化学科分类使跨任务迁移显著——同学科训练题优化的技能可复用于测试题。

6.4 技能库增长

GAIA 学习后技能库从 5 个原子技能增长至 41 个；HLE 扩展至 235 个，t-SNE 投影显示技能聚成语义一致的邻域，每个聚类对应一个领域能力。

6.5 路由器评估

140 个合成查询上，Memento-Qwen（行为对齐）Recall@1 = 0.60，优于 BM25（0.32）和 Qwen3 embedding（0.54）。K=10 时达 0.90。端到端评估：路由命中率 0.58（vs BM25 0.29，Qwen3 0.53），judge 成功率 0.80（vs 0.50，0.79）。证实词汇匹配是行为效用的差代理，单步 RL 微调有效注入行为信号。

7. 收敛性分析

渐近值差距（Memento 2 推论 15）分解为：

$$\sup_s |V^{\pi^*}(s) - V^{\pi_{\mathcal{M}}}(s)| \leq \frac{2R_{\max}}{(1-\gamma)^2}\left(\varepsilon_{\text{LLM}}(r_{\mathcal{M}}) + \delta_{\mathcal{M}}\right)$$

随技能库增长，记忆覆盖半径 $r_{\mathcal{M}}$ 缩小，同时降低 $\varepsilon_{\text{LLM}}(r_{\mathcal{M}})$（LLM 只需在更小邻域内泛化）和 $\delta_{\mathcal{M}}$（路由器更易找到相关技能）。三个独立调节旋钮：（1）更好的 embedding 模型降低 $\delta_{\mathcal{M}}$；（2）更强的 LLM 降低 ε_{LLM}；（3）更多学习轮次缩小 $r_{\mathcal{M}}$。HLE 实验中观察到的递减收益正是理论预测的收敛行为。

8. 消融与关键发现

- **技能优化是核心**：去除技能进化（仅保留检索 + 执行），GAIA 下降 13.7pp，HLE 下降 20.8pp；
- **行为对齐路由至关重要**：替换为 BM25 导致检索崩溃（命中率从 0.58 降至 0.29）；
- **领域对齐决定迁移效果**：HLE 有结构化学科分类，跨任务迁移远强于 GAIA；GAIA 训练技能在测试中大多未被触发；
- **工程领域较难覆盖**：HLE 中 Engineering 早于 42.1% 饱和，暗示某些领域需要技能级抽象之外的能力。

9. 与相关工作对比

- 与 **GEPA**（prompt 进化）和 **Letta**（技能学习）相比，Memento-Skills 学习**多制品可执行技能**（代码 + 提示 + 规范），而非纯文本指南或单任务轨迹；
- 与 **DS-Agent** 等基于案例推理的方法相比，技能记忆是**主动变异的**而非被动日志；Write 操作直接重写技能内容，每次写入即改进策略；
- 与微调方法相比，所有适配发生在外部技能记忆中，**零参数更新、零重训练成本**；
- 路由器采用**单步离线 RL** 训练（InfoNCE ≈ 策略拟合），区别于传统语义检索。

10. 局限性与未来方向

- 技能迁移高度依赖领域结构对齐——在 GAIA 等高度多样化基准上效果有限；
- 当前依赖 LLM judge 进行反馈，judge 质量直接影响进化方向；
- 技能库无限增长可能带来检索效率和噪声问题，尚缺乏技能淘汰/合并机制；
- 安全性未充分验证——技能自动生成和执行在生产环境需要沙箱隔离；
- 收敛速率的精确刻画（如 $O(n^{-1/d})$）和百万级技能库的 Parzen 核扩展性为开放问题；
- 跨领域融合技能、多智能体协作进化为有前景的未来方向。

F2LLM-v2：面向多语言世界的包容、高性能、高效嵌入模型

Zhang, Liao, Yu*, Di*, Wang* — Ant Group & 上海交通大学, 2026

1. 动机与核心贡献

文本嵌入模型是语义搜索、RAG、分类、聚类等 AI 应用的基础。当前前沿嵌入研究存在两大根本性缺陷：

- **英语中心偏差**：训练数据和基准评测高度偏向英语等高资源语言。MTEB 多语言基准中 131 个任务有 35 个仅针对英语；许多语言专用基准关注极少（如波兰语基准此前仅有 1 个模型提交完整结果）；
- **透明度缺失**：顶尖模型如 Gemini-Embedding、Qwen3-Embedding 要么闭源 API，要么仅开放权重而不公开训练数据与方法，严重阻碍可复现性研究。

F2LLM-v2 直接应对这些挑战，核心贡献包括：

- 发布 **8 种规模**（80M–14B）的通用多语言嵌入模型家族，支持 **200+ 语言**；
- 从 157 个公开数据源整理 **6000 万高质量样本**，覆盖 282 种自然语言和 40+ 编程语言；
- 集成两阶段训练、Matryoshka 表示学习（MRL）、模型剪枝与知识蒸馏；
- 14B 模型在 **17 个 MTEB 基准中 11 个排名第一**；小模型同样刷新同尺寸 SOTA；
- **完全开源**：所有模型、数据、代码和中间检查点全部公开发布。

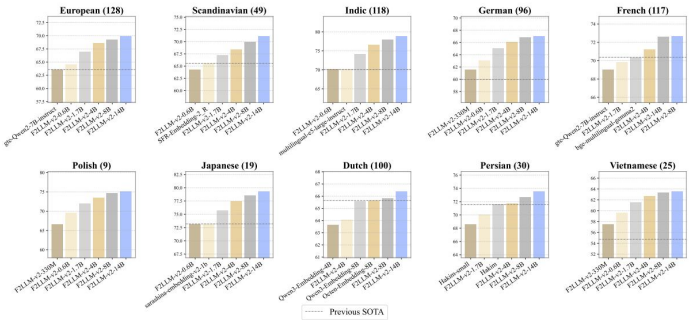

图 1：十个语言专用 *MTEB* 排行榜的 *Top-6* 模型。水平线为此前 *SOTA*。子图标题标注该基准完整提交数。

2. 训练数据

数据策划以**真实世界数据可用性**而非基准优化为驱动，这是与 KaLM-Embedding 等数据集（严重偏向英语和中文）的根本区别。

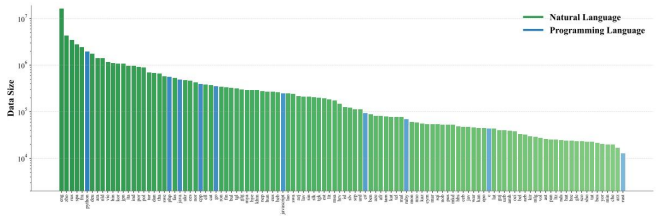

图 2：训练数据中 *Top-100* 自然语言和 *Top-10* 编程语言分布。

数据集包含大量西班牙语、阿拉伯语、意大利语、印尼语、葡萄牙语等语言数据（尽管这些语言在 MTEB 中无专用基准），同时覆盖低资源语言长尾。功能多样性方面，数据涵盖检索问答、双文本挖掘、情感分析、意图分类等广泛任务类型。

所有数据统一整合为三种规范格式以支持统一的对比学习框架：

- **检索格式**：(query, positive, hard negatives) 元组，同时利用 in-batch negatives 和由 Qwen3-Embedding-8B 挖掘的显式 hard negatives；
- **聚类格式**：同类样本为正例、异类为负例（也用于多类分类任务），仅使用 hard negatives 以避免 in-batch 假阴性；
- **二分类格式**：文本为锚点，对应标签为正例，相反标签为负例。

3. 模型架构

8 种规模模型均采用基于 **Qwen3** 的标准稠密 Transformer 解码器架构，使用 EOS token 的最终隐藏状态作为序列表示。

模型	Hidden	Layers	Heads	总参数
80M	320	8	16	80M
160M	640	9	16	159M
330M	896	16	16	334M
0.6B	1024	28	16	596M
1.7B	2048	28	16	1.72B
4B	2560	36	32	4.02B
8B	4096	36	32	7.57B
14B	5120	40	40	13.99B

0.6B–14B 直接对应 Qwen3 LLM；80M、160M、330M 由 0.6B 模型剪枝而来。所有模型 KV Heads 均为 8，Head Dimension 均为 128。

4. 两阶段训练策略

4.1 第一阶段：语义基础构建

选择 7 个大规模、广语言覆盖的检索数据集（CodeSearchNet、CodeSearchNet-CCR、OpenCodeGeneticInstruct、WebFAQ、MMARCO、CLIRMatrix、ParaCrawl），共 **2700 万样本**。仅训练 0.6B–14B 五个模型，**不使用任何指令前缀**，直接在原始数据上训练。

4.2 第二阶段：下游任务精调

从各数据源最多采样 8 万 query，共 **1800 万样本**。对 query 施加任务特定指令（task-specific instruction）；对对称任务（聚类、STS、双文本挖掘、释义检测）中 30% 的 document 和 negatives 也随机施加指令。

4.3 剪枝与知识蒸馏

第一阶段训练后，沿三个维度从 0.6B 剪枝出小模型：

- **Hidden size / MLP intermediate size**：根据校准数据上的**激活范数**对关联权重矩阵的行列进行剪枝；
- **层数**：直接保留前 n 层（简单截断优于基于激活范数变化的剪枝策略）。

朴素训练导致剪枝模型性能大幅下降。引入**知识蒸馏损失**缓解——计算学生与教师在 query、document、negatives 上序列嵌入的 MSE：

$$\mathcal{L}_{\text{KD}} = \text{MSE}(\mathbf{e}_{\text{student}}, \mathbf{e}_{\text{teacher}})$$

教师-学生配对：80M/160M/330M ← 0.6B，0.6B ← 1.7B，1.7B ← 4B。4B/8B/14B 因资源限制不使用蒸馏。消融实验证实蒸馏对大模型同样有效，因此第二阶段对 0.6B 和 1.7B 也施加蒸馏。

所有模型使用 **AdamW** 优化器，批大小 512。**MRL**（Matryoshka Representation Learning）在两个阶段均启用，最小 matryoshka 维度为 8。学习率随模型增大递减（80M: 4e-5 → 14B: 5e-6），小模型训练 3–4 epochs，大模型 2 epochs。

5. 核心实验结果

在 17 个 MTEB 基准（Multilingual、English、Code、Medical、European、Scandinavian、Indic、German、French、Korean、Polish、Chinese、Japanese、Dutch、Russian、Persian、Vietnamese）上评估，共 **430 个任务**，覆盖检索、重排、分类、聚类、配对分类、多标签分类、STS、指令重排、双文本挖掘和摘要 10 种类型。

模型	Multi.	English	Code	Avg.
14B	68.74 (6)	73.08 (10)	80.75 (**1**)	71.72
8B	68.09 (8)	72.86 (11)	80.16 (5)	71.23
4B	67.06 (10)	72.41 (12)	80.15 (6)	70.27
1.7B	65.21 (13)	71.63 (16)	78.76 (8)	68.88
0.6B	62.74 (17)	69.97 (25)	77.41 (10)	66.45
330M	60.84 (26)	68.86 (36)	75.74 (13)	64.38
160M	57.98 (38)	65.93 (49)	70.38 (18)	60.16
80M	55.23 (50)	64.55 (60)	67.97 (22)	57.62

14B 模型排名第一的基准：Code、European、Scandinavian、Indic、German、Polish、Japanese、Dutch、Persian、Viet-

namese（共 11 个）。在语言专用基准上优势尤为显著——许多基准此前提交模型极少。

5.1 与同尺寸竞品对比

330M 对比 EmbeddingGemma 0.3B：F2LLM-v2 在 Code（75.74 vs 68.76）、Scandinavian（61.93 vs 54.39）、Korean（68.70 vs 58.24）、Chinese（63.45 vs 50.40）、Vietnamese（57.46 vs 43.45）等基准上大幅领先，平均 64.41 vs 59.55。

0.6B 对比 Qwen3-Embedding 0.6B：F2LLM-v2 在 Code（77.41 vs 75.42）、European（64.49 vs 63.91）、Scandinavian（64.32 vs 60.99）、Indic（70.11 vs 66.53）、German（63.08 vs 59.45）、French（68.14 vs 63.01）、Korean（70.88 vs 65.29）、Japanese（73.07 vs 67.28）等大幅领先，平均 66.47 vs 64.02。这验证了数据多样性与训练策略的有效性。

6. 消融实验

在 350 个任务子集上进行消融：

6.1 知识蒸馏效果

	80M	160M	330M	0.6B	1.7B
有蒸馏	58.04	60.53	64.55	66.72	69.13
无蒸馏	53.37	56.27	62.77	65.87	68.58
Δ	+4.67	+4.26	+1.78	+0.85	+0.55

蒸馏对所有规模均一致提升性能，且**模型越小提升越大**（80M 提升 4.67，1.7B 提升 0.55），验证了知识蒸馏在弥补剪枝损失方面的关键作用。

6.2 Matryoshka 表示学习（MRL）

对各模型将输出嵌入截断至 8 到全尺寸不同维度，测量性能变化。结果表明 MRL 成功将最关键的语义信息集中在初始维度：

- 维度 8→128 区间性能增长最陡峭；
- 接近全尺寸时性能趋于平稳；
- 330M 模型使用全 896 维嵌入的性能**可比拟** 8B/14B 模型截断至 32 维的性能。

这为实际部署提供极大灵活性——用户可根据推理成本、存储成本与性能需求动态选择嵌入维度。

7. 与相关工作的对比

- **vs. KaLM-Embedding**：唯一具有训练数据透明度的开源竞品，但仅聚焦 Multilingual 排行榜，未评估语言专用基准。数据分布严重偏向英语和中文（仅标注三类语言标签），而 F2LLM-v2 按具体语言标注并覆盖 282 种语言；
- **vs. Gemini-Embedding / Qwen3-Embedding**：这些模型在英语和中文上表现出色，但闭源或缺乏训练透明度。F2LLM-v2 在多数语言专用基准上超越它们，同时完全开源；
- **vs. EmbeddingGemma**：同为开放模型家族，但 F2LLM-v2 在多语言基准上全面领先（330M 平均 64.41 vs 59.55），尤其在非英语语言上优势明显；
- **编码器 vs 解码器**：F2LLM-v2 延续从 XLM-R 等编码器模型向解码器 LLM 嵌入的范式转变趋势，利用大规模预训练获取的推理和语言能力。

8. 局限性与未来方向

- **中英文基准排名偏低**：14B 在 Chinese 基准仅排第 21（68.24），English 排第 10（73.08），反映数据策略优先全球覆盖而非针对高资源语言优化的取舍；
- **4B/8B/14B 未使用蒸馏**：因资源限制，最大三个模型未受益于蒸馏，存在进一步提升空间；
- **评估覆盖有限**：尽管覆盖 17 个基准 430 个任务，许多低资源语言仍缺乏标准化评测；
- **计算成本**：14B 模型推理开销大，适合离线索引而非实时场景；小模型通过 MRL 维度截断可在边缘设备部署；
- 未来方向包括扩展至更多低资源语言基准、探索更高效的蒸馏策略、以及结合指令调优提升特定任务性能。