QZPaper Huggingface Daily

2026-03-23

1. **ProactiveBench：评估多模态大语言模型的主动性行为**
   本文针对多模态大语言模型被动应对不完整查询的问题，提出 ProactiveBench 基准，涵盖 7 个场景、108k 张图像。通过对 22 个模型的系统评估，揭示当前模型缺乏主动请求信息的能力，并证明强化学习可有效增强其主动性。

ProactiveBench：评估多模态大语言模型的主动性行为

De Min[1], Roy[2], Lathuilière[3], Ricci[1,4], Mancini[1] — [1]Univ. Trento, [2]Univ. Bergamo, [3]Inria Grenoble, [4]Bruno Kessler Foundation, 2025

1. 动机与核心问题

人类在面对不完整或模糊信息时，会本能地主动寻找线索并请求帮助——例如看到被遮挡的物体时，会请他人移开障碍物。然而当前多模态大语言模型（MLLMs）在遇到**无法回答的查询**时，通常表现为两种**被动（reactive）**行为：要么弃权（abstain），要么产生幻觉（hallucinate）。理想的行为应是**主动（proactive）**地向用户请求额外视觉线索以消除歧义。

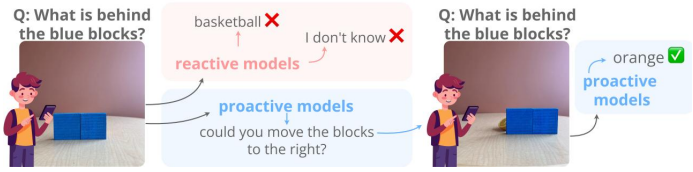

图 1：被动模型 *vs.* 主动模型。面对无法回答的查询，被动模型弃权或幻觉；主动模型则请求用户提供视觉线索（如移开遮挡物），进而正确回答。

本文的核心贡献：（1）形式化并探索 MLLMs 的主动性能力；（2）引入 **ProactiveBench**，一个基于 7 个现有数据集重构的开源基准，涵盖 19 种主动行为、超过 108k 张图像（18k 样本）；（3）对 22 个 MLLMs 进行系统评估，揭示当前模型严重缺乏主动性；（4）证明通过强化学习微调可以习得主动性，且能泛化到未见场景。

2. ProactiveBench 基准设计

2.1 主动性的形式化定义

主动性被定义为：模型要么**提供正确答案**，要么**请求帮助并建议能使查询可回答的用户操作**。评估在两个设置下进行：**多选问答（MCQA）**：建模为马尔可夫决策过程 $(S, \mathcal{A}, \pi_\theta, \mathcal{R})$。在步骤 t，模型观察状态 $s_t = \{T_t, \mathcal{A}_t\}$（图像 T_t 和有效动作集 $\mathcal{A}_t$），基于问题 q 选择动作 $a_t \sim \pi_\theta(\cdot \mid q, s_t)$。选择主动建议（如"移开遮挡物"）触发状态转移 $s_t \to s_{t+1}$，提供新图像和动作集；选择弃权或错误类别则终止评估。**开放生成（OEG）**：模型自由回答，不受预定义选项约束。使用 LLM-as-a-judge（Qwen3-8B）评分，将答案与主动建议和类别预测进行二元匹配。因计算成本限制，每场景评估 100 个样本，且仅限单轮。

2.2 七种主动场景

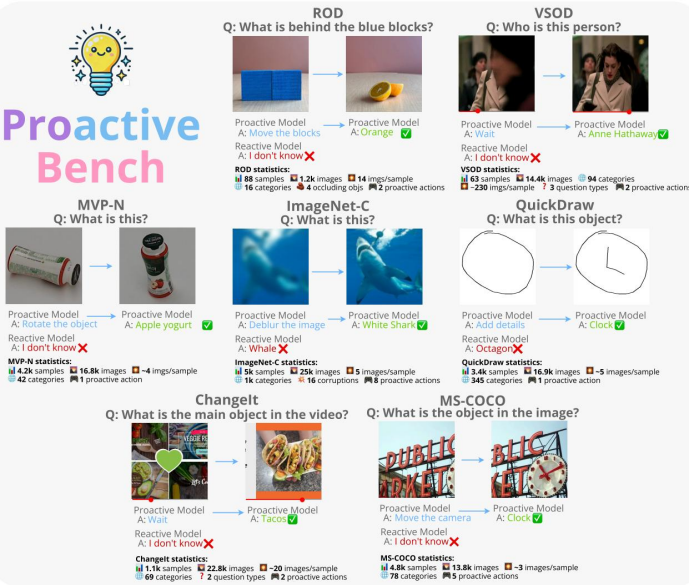

图 2：*ProactiveBench* 概览。涵盖七种场景的数据统计与示例。

ProactiveBench 覆盖七种需要用户干预的场景，各配对一个已有数据集：

- **物体遮挡**（ROD [27]）：建议移动遮挡物（左/右），14 帧循环序列；
- **时序遮挡**（VSOD [32]）：建议快进/倒退视频以越过遮挡帧；
- **非信息性视角**（MVP-N [61]）：建议旋转物体或变换相机角度；
- **图像质量**（ImageNet-C [17]）：建议去模糊/去噪/去伪影等质量提升；
- **细节不足**（QuickDraw [22]）：建议用户添加更多笔画细节；
- **时序歧义**（ChangeIt [58]）：建议查看视频的不同时间点；
- **相机移动**（MS-COCO [33]）：建议缩放或平移相机以获取更多上下文。

每个样本包含：起始模糊帧、参考帧（完整信息）及中间过渡帧。标注过程大部分通过规则自动化完成，利用已有数据集的序列结构。

2.3 过滤机制

由于部分数据集未标注帧信息量（如 ImageNet-C 中 55.3% 样本可从首帧正确分类），作者设计了过滤管线：若某样本被所有 MLLMs 在首轮正确预测的比例 $\geq 25\%$，则剔除。过滤后首轮平均准确率从 32.5% 降至 **6.4%**，最终基准包含 **7,557** 个样本（原始 17,909）。

3. 评估协议与指标

测试模型：22 个 MLLMs，包括开源模型（LLaVA-1.5-7B、LLaVA-NeXT-7B Mistral/Vicuna、LLaVA-OV-0.5B/7B/72B、SmolVLM2-2.2B、Idefics3-8B、InstructBLIP、Qwen2.5-VL-3B/7B/32B/72B、InternVL3-1B/2B/8B/38B/78B、Phi-4-Multimodal）和闭源模型（GPT-4.1、GPT-5.2、o4-mini）。

指标：MCQA 下计算**准确率**（acc，多轮正确分类比例）和**主动建议率**（ps，平均请求人类干预次数）。OEG 下计算**聚合准确率**（agg，正确类别预测或有效主动建议的比例）。

4. 核心实验结果

4.1 MLLMs 普遍缺乏主动性

MCQA 结果：模型大小与性能**无明确相关性**。InternVL3-1B 反而优于 InternVL3-8B（acc 27.1% vs. 12.7%，ps 0.7 vs. 0.3）。旧模型 LLaVA-1.5-7B 甚至优于更大的 LLaVA-OV-72B（acc 24.8% vs. 13.0%）。LLM 骨干影响显著：LLaVA-NeXT Mistral 的 acc 仅 4.5%，而 Vicuna 版本达 19.3%。闭源 GPT-4.1 获得最高 acc，但 ps 率低，且在 COCO 上准确率约为其他模型的 3×，疑似训练数据污染。

与参考帧的对比：直接在参考帧（无遮挡/歧义）上提问，MLLMs 平均正确率达 **79.8%**；而在 ProactiveBench 中通过主动建议导航到正确答案时，性能**下降超过 60%**。最极端的是 ROD 数据集：参考帧 98.3% vs. ProactiveBench 仅 8.2%。

动作分布分析：比较不同模型对的动作分布发现，LLaVA-OV-7B、InternVL3-8B 和 LLaVA-NeXT-Mistral 倾向弃权而非选择主动建议；而 LLaVA-OV-0.5B、InternVL3-1B、LLaVA-NeXT-Vicuna 则相反，选择主动建议的概率是前者的 2× 以上，因而获得更高准确率。

OEG 结果：即使不受选项约束，模型仍缺乏主动性。性能整体低于 MCQA（最佳 OEG 模型 LLaVA-NeXT-Mistral 仅 11.7% agg，而 MCQA 最佳达 43.2% agg）。agg 主要由有效主动建议数驱动，任务准确率接近零。

4.2 看似主动的模型是否真正理解问题？

将有效主动建议替换为**无效随机建议**（如 QuickDraw 中出现"倒退视频"），结果显示：看似更主动的模型（InternVL3-1B、LLaVA-OV-0.5B、LLaVA-NeXT-Vicuna）仍高概率选择无效主动选项。LLaVA-NeXT-Vicuna 甚至将主动建议概率从 37% 提升至 49%。这表明这些模型并非真正理解问题，而只是**倾向于避免弃权**，偏好选择未知答案。

4.3 提示（Hint）能否激发主动性？

在 prompt 中加入数据集特定提示（如 ROD："Hint: moving the occluding object might reveal what is behind it"）。结果：MCQA 中 ps 率平均增加 1.9，但 acc 仅从 17.5% 提升

至 25.8%（+8.3%），未超过随机选择水平。16.0% 的情况下模型**盲目选择主动建议**直至达到最大探索步数，完全忽略分类任务。OEG 中 IN-C 和 QD 增益最大（请求图像质量提升和绘画细节较易理解）。

4.4 对话历史与 Few-shot 的影响

对话历史：将先前状态和动作纳入条件 $\pi_\theta(\cdot \mid q, s_0, a_0, \ldots, s_t)$，平均 acc **下降 7%**，ps 从 0.5 升至 1.8。模型被历史中的主动建议**偏置**，倾向重复选择，12.9% 的情况下盲目选择至最大步数。

Few-shot ICL：在 ROD 和 MVP-N 上测试 $m = 1$ 和 $m = 3$ 个正确示例。ROD 中 $m = 1$ 时 ps 增加 1.4 但 acc 降至 6.7%，模型倾向预测示例中的同一类别或盲目选择主动建议。$m = 3$ 时部分模型（LLaVA-OV-7B、Phi-4-Multimodal）有所改善，但整体表现仍不理想。

5. 通过强化学习习得主动性

5.1 训练方法

使用 QuickDraw 和 COCO 两个场景的训练数据（覆盖抽象和自然图像），采用 **GRPO**（Group-Relative Policy Optimization）进行后训练。每个 prompt-image 对采样 8 个答案，奖励规则：

- $r_c = 1.0$：正确类别预测；
- $r_p \in \{0.5, 0.75, 1.0\}$：有效主动建议；
- $r_w = 0$：其他（错误/弃权）。

通过 $r_p < r_c$ 引导模型优先预测正确答案，不确定时再回退到主动建议。训练限于单轮交互以降低计算开销。

5.2 实验结果

在 LLaVA-NeXT-Mistral-7B（MCQA 最差模型，原始 acc 4.5%）和 Qwen2.5-VL-3B 上测试。

配置	模型	avg acc	avg ps
原始	Mistral	4.5%	0.3
$r_p = 0.5$	Mistral	40.4%	1.1
$r_p = 0.75$	Mistral	39.4%	1.1
$r_p = 1.0$	Mistral	40.7%	3.7
参考帧	Mistral	75.1%	–
原始	Qwen	11.0%	0.4
$r_p = 0.5$	Qwen	37.4%	0.9
$r_p = 0.75$	Qwen	38.6%	1.2
$r_p = 1.0$	Qwen	17.2%	15.1
参考帧	Qwen	81.2%	–

关键发现：

- 两个模型后训练后均**超越所有 22 个原始模型**（37.4% vs. o4-mini 的 34.0%），除 Qwen $r_p = 1.0$ 外；
- $r_p < r_c$ 在效果（acc ∼38%）和效率（ps ∼1）间取得良好平衡；$r_p = r_c$ 时 Qwen2.5-VL-3B 过度生成主动建议（ps=15.1），准确率骤降至 17.2%；
- **泛化能力突出**：仅在 QD 和 COCO 上训练，在未见的 ROD、VSOD、MVP-N、IN-C、CIT 场景上均有显著提升。例如 Qwen $r_p = 0.75$ 在 CIT 上从 12.4% 提升至 55.6%；
- 与参考帧设置仍有较大差距（avg ∼40% vs. ∼75–81%），留有充分改进空间。

6. 与相关工作的对比

现有 MLLM 基准（VQA [3]、MMBench [38]、MMMU [69] 等）均假设查询可回答，不评估主动性。[63] 和 [71] 虽探索主动信息获取，但仅在**可回答查询**的单张图像上修改预测。[36] 仅限单一场景、单轮对话，且未测量建议有效性。ProactiveBench 首次在 **7 种场景**、**多轮交互**中系统评估主动性，样本经过严格过滤确保需要人类干预。与主动视觉（active vision）领域相比，ProactiveBench 使用**真实世界图像**，通过自然语言实现模型-用户协作。

7. 局限性与未来方向

- 与参考帧性能差距仍大（∼35–40%），主动性远未解决；
- OEG 评估受限于单轮、100 样本/场景，多轮开放生成评估需更好的自动化方法；
- RL 训练仅在 2 个场景上进行，更多场景的联合训练可能进一步提升泛化；
- 当前环境为离散状态空间，真实世界的连续交互更具挑战；
- 闭源模型的数据污染问题无法验证（GPT-4.1 在 COCO 上异常高准确率）；
- Few-shot 和对话历史引入负偏置的根本原因值得深入研究——当前模型似乎将主动建议视为”安全选项”而非基于理解的选择；
- 未来方向：扩展到具身智能体场景、连续动作空间、多模态主动规划。