QZPaper Huggingface Daily

2026-03-25

1. **MinerU-Diffusion：将文档 OCR 重新定义为基于扩散解码的逆渲染**
   文档 OCR 采用自回归解码存在效率与错误问题，MinerU-Diffusion 将其重新定义为逆渲染任务，用并行扩散去噪替代顺序解码。采用 Block-wise 扩散架构提升长文档处理效率，通过掩码扩散的条件独立性实现全局一致性。
2. **WildWorld：面向生成式 ARPG 的大规模动态世界建模数据集**
   WildWorld 从怪物猎人荒野游戏采集 1.08 亿帧画面，配备 450+ 语义动作和逐帧显式状态标注，首次系统解决动作条件世界建模数据匮乏问题。提出 Action Following 和 State Alignment 评估指标，为生成式 ARPG 建立大规模基准。
3. **SpecEyes：通过推测性感知与规划加速智能体多模态 LLM**
   智能体多模态 LLM 的顺序工具链引入严重延迟瓶颈。SpecEyes 将投机范式提升至智能体级，采用轻量无工具模型和大型模型异构架构，通过工具需求判断实现智能体级旁路，显著加速推理。
4. **PEARL：个性化流式视频理解模型**
   PEARL 首次定义个性化流式视频理解任务，支持连续视频输入、动态概念定义和多轮交互。构建包含 132 个视频与 2173 条精细标注的 PEARL-Bench 基准，同时支持 Frame-level 和 Video-level 两种概念类型。
5. **DA-Flow：基于扩散模型的退化感知光流估计**
   严重退化输入致使光流估计性能大幅下降。DA-Flow 将图像修复扩散模型提升至视频域，利用其退化感知能力与时间对齐策略，首次精确估计退化输入下的光流，填补退化感知光流的研究空白。
6. **SIMART：通过 MLLM 将单体网格分解为仿真就绪的铰接资产**
   静态网格无仿真元数据，密集体素编码效率低下。SIMART 采用 Sparse 3D VQ-VAE 编码几何为稀疏 token，以统一 MLLM 框架联合执行部件分解与运动学参数预测，实现高效、可扩展的仿真就绪资产生成。
7. **UniGRPO：面向推理驱动视觉生成的统一策略优化**
   交错文本与图像生成需要统一强化学习框架。UniGRPO 将其建模为 MDP，用 GRPO 联合优化两个模态的生成策略，并引入 RatioNorm 机制解决扩散模型中的比率分布问题，实现推理驱动的视觉生成。
8. **RealMaster：将渲染场景提升为真实感视频**
   渲染场景精度高但缺乏真实感，视频编辑模型难以保留结构。RealMaster 采用两阶段方法：稀疏到稠密传播生成配对数据，使用 IC-LoRA 适配器蒸馏扩散模型为学习型渲染器，实现真实感的 sim-to-real 视频翻译。
9. **2Xplat：两个专家胜过一个通才——无位姿前馈 3DGS 的模块化框架**
   无位姿前馈 3DGS 单体架构存在目标冲突且无法利用位姿条件化机制。2Xplat 解耦为双专家架构，几何专家估计位姿、外景专家基于位姿生成高斯表示，显著降低计算成本且收敛迅速。

MinerU-Diffusion：将文档 OCR 重新定义为基于扩散解码的逆渲染

Dong*, Niu*, Wang‡, Zeng, Zhang, He✉ — 上海 AI 实验室 & 北京大学, 2026

1. 动机与核心思想

当前文档 OCR 系统主要依赖视觉-语言模型（VLM）的**自回归（AR）解码**，逐 token 从左到右生成结构化文本。这种范式存在三个根本性缺陷：

- **效率瓶颈**：推理延迟与输出序列长度线性增长，长文档（含表格、公式、版面）解码极慢；
- **错误累积**：因果分解下早期错误会沿序列传播，在复杂结构中尤为严重；
- **语义幻觉**：AR 解码器隐式将 OCR 建模为语言条件重建，当视觉信号弱或语义被打乱时过度依赖语言先验，产生语义幻觉。

本文核心洞察：文档 OCR 的从左到右因果生成顺序是**序列化的人为产物**，而非任务的内在属性。文档输出本质上是**空间耦合的离散随机场**——token 间的统计依赖主要来自空间布局和格式约束，而非因果生成顺序。因此，作者将文档 OCR 显式定义为**视觉条件下的逆渲染问题**，提出 MinerU-Diffusion：用**并行扩散去噪**替代自回归顺序解码。

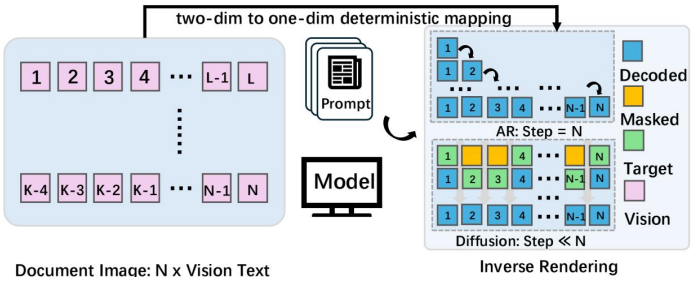

图 1：文档 OCR 逆渲染过程概览。AR 方法从左到右顺序解码；扩散方法通过迭代去噪并行重建。

掩码扩散模型假设给定部分观测序列和视觉输入后各 token 条件独立——在 OCR 场景中图像内容与文本近乎确定性映射，该假设高度合理。这使模型可并行解码长文本段，同时保持全局一致性，天然匹配 OCR 的确定性特质。

2. 方法论

2.1 问题定义：逆渲染视角

将文档 OCR 建模为统一结构化 token 序列 $y = (y^{(1)}, \ldots, y^{(L)}) \in \mathcal{V}^L$ 的逆渲染，其中 $\mathcal{V}$ 为共享词表（涵盖文本符号、版面标记、表格分隔符、数学运算符）。掩码扩散前向过程将干净序列 x_0 中的 token 按连续噪声调度 $t \in [0,1]$ 逐步替换为 [MASK]：

$$q(x_t \mid x_0) = \prod_{i=1}^{n} \mathrm{Cat}\big(x_t^i; (1-t)\delta_{x_0^i} + t\delta_{[\mathrm{MASK}]}\big).$$

训练目标由最大似然推导的 ELBO：

$$\mathcal{L}_{\mathrm{full}}(x_0, Q, \theta) = \int_0^1 \frac{1}{t|x_0|} \mathbb{E}_{q(x_t|x_0)} \Big[\sum_{i: x_t^i = [\mathrm{MASK}]} \log p_\theta(x_0^i \mid x_t, Q) \Big] dt,$$

其中 Q 为提示，$|x_0|$ 为序列长度。

2.2 Block-wise 扩散架构

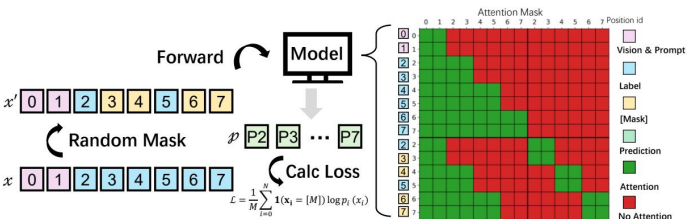

图 2：MinerU-Diffusion 训练架构。左：随机掩码后模型仅预测掩码位置。右：块注意力掩码结构。

直接对全序列施加 Full-Attn 扩散存在三个问题：(1) $O(L^2)$ 二次复杂度；(2) 全局扩散缺乏结构锚点，早期错误跨序列传播；(3) 文档结构具有强局部性，全注意力不必要地耦合独立区域。

MinerU-Diffusion 将输出分为 B 个连续块 $y = (y^{(1)}, \ldots, y^{(B)})$，$y^{(b)} \in \mathcal{V}^{L'}$，$L = BL'$，采用**混合分解**：

$$p_\theta(y \mid x) = \prod_{b=1}^{B} p_\theta\big(y^{(b)} \mid y^{(<b)}, x\big),$$

块间为粗粒度自回归，块内为并行扩散去噪。注意力掩码定义为：

$$\mathcal{M}_{ij} = \begin{cases} 1, & \text{if } b(i) = b(j), \\ 1, & \text{if } b(j) < b(i), \\ 0, & \text{otherwise.} \end{cases}$$

块边界充当结构锚点，防止长程对齐漂移。复杂度从 $O(L^2)$ 降至 $O(BL'^2)$，块间因果结构支持高效 KV-caching。模型以原生分辨率视觉特征为条件，确保后验精炼始终扎根于视觉证据。

具体实现采用 SDAR-1.7B-Chat-b32 作为扩散解码器（块大小 32），视觉编码器源自 Qwen2-VL-7B，总参数量 **2.5B**。推理时使用**动态置信度调度**：每步仅确认置信度超过阈值 τ 的 token，其余继续去噪，实现效率与精度的连续可控权衡。

2.3 两阶段课程学习与不确定性驱动精炼

扩散模型的任意顺序建模使训练不如 AR 稳定，且随机掩码分散监督信号导致数据利用效率低。为此提出两阶段课程学习：

Stage I：多样性驱动的基础学习。在大规模高熵数据集 $\mathcal{D}_{\mathrm{base}} \sim p_{\mathrm{div}}(x)$（约 6.9M 样本）上训练，覆盖多种版面、语言和文档类型，建立稳健的视觉-语义对齐和跨域泛化能力。损失景观平滑，收敛稳定。

Stage II：不确定性驱动的边界精炼。对每个样本执行 T 次随机推理，计算成对一致性分数：

$$C(x) = \frac{2}{T(T-1)} \sum_{i<j} S(\hat{y}^{(i)}, \hat{y}^{(j)}),$$

其中 S 为任务相关度量（PageIoU / CDM / TEDS）。低 $C(x)$ 样本入选硬样本集 $\mathcal{D}_{\mathrm{hard}} = \{x \mid C(x) < \tau\}$，经 AI 辅助人工标注后与随机回放混合：$\mathcal{D}_{\mathrm{SFT}} = \mathcal{D}_{\mathrm{hard}} \cup \alpha\mathcal{D}_{\mathrm{rand}}$。优化目标加入自适应权重 $w(x) = 1 + \beta(1 - C(x))$，使模型聚焦决策边界区域。约 630K 硬样本，4 个 epoch 精调。

3. 核心实验结果

3.1 全文档解析（OmniDocBench v1.5）

方法	参数	Overall
PaddleOCR-VL [AR]	0.9B	92.56
MinerU2.5 [AR]	1.2B	90.67
MonkeyOCR-pro-3B [AR]	3.7B	88.85
Gemini-2.5 Pro [AR]	–	88.03
Qwen2.5-VL-72B [AR]	72B	87.02
MinerU-Diffusion [dLM]	**2.5B**	**88.94**

在无 GT Layout 设置下，MinerU-Diffusion 取得 Overall 88.94，超越大多数 AR 模型（含 72B 的 Qwen2.5-VL）。在有 GT Layout 设置下进一步提升至 **93.37**，接近最优 AR 系统（PaddleOCR-VL 93.91、MinerU2.5 93.44），证明扩散解码在识别质量上具有高度竞争力。两设置间的差距（88.94 vs 93.37）表明版面理解仍是关键瓶颈。

3.2 元素级解析

表格识别（CC-OCR / OCRBench v2）：TEDS 73.77/81.18，TEDS-S 82.06/88.66，与多数 AR 基线匹配或超越，TEDS-S 的强表现说明扩散解码可可靠保持表格结构。

公式识别（UniMER-Test）：CPE/HWE/SCE/SPE 分别为 91.6/91.6/92.0/96.8，在复杂打印、手写和简单场景均表现强劲，大幅超越 GPT-4o（82.7/85.9/87.8/96.7），与强 AR 系统接近。

3.3 效率分析

置信度阈值 τ 控制解码并行度：τ=0.95 时 TPS=108.9（2.1× 加速），准确率 93%+；τ=0.6 时 TPS=164.8（**3.2**× 加速），准确率 $>$ 90%。相比 MinerU2.5 固定 52 TPS，实现了效率-精度的连续权衡。动态调度（τ=0.97）在 98.32 TPS 下达到 Overall 93.34，优于静态 step=6（91.56 TPS, 88.31）和 step=32（21.86 TPS, 93.02）。

4. 消融实验

置信度阈值 vs 精度： τ 从 0.5 到 0.95，Overall 从 87.61 升至 93.37（适度降低并行度减轻低置信度错误传播）；但 τ=0.99 时轻微下降，说明过度保守削弱并行信息交互的收益。Table TEDS 从 81.10 提升至 90.99。

Full-Attn vs Block-Attn： Full-Attn 存在三个缺陷：（1）$O(L^2)$ 二次开销；（2）必须预设固定解码长度 L，$L \gg N$ 时产生重复行，$L < N$ 时截断；（3）训练/推理均更慢。Block-Attn 将每步注意力交互从 L^2/B 降至 $2L$，且通过块边界自然终止避免重复问题。

两阶段课程学习： 单独 Stage 2 在无 GT Layout 下几乎失败（Overall 35.71），因缺乏稳定表示初始化导致高方差优化。单独 Stage 1 收敛平滑但饱和于 ∼85% 准确率。完整两阶段策略结合两者优势，Stage 1 建立低方差全局表示，Stage 2 执行不确定性驱动的边界精炼，最终达到 89%+ 准确率和 Overall 88.94（无 GT）/ 93.37（有 GT）。训练动态显示梯度范数始终稳定。

5. Semantic Shuffle 分析

为检验 AR 解码器是否依赖语言先验而非真正视觉读取，作者构建 **Semantic Shuffle** 基准：从 FOX 数据集 112 张英文文档中按比例打乱单词后重新渲染为图像，保持视觉呈现一致但破坏语义连贯性。

实验揭示鲜明对比：随着打乱比例增加，**AR 解码器性能急剧持续下降**，说明严重依赖语言合理性；而**扩散解码器保持几乎恒定的性能**，证明其更直接地对齐视觉信号，对语义无效输入具有鲁棒性。这从根本上验证了论文的核心假设——AR 解码器倾向于在语义被打乱时利用全局语言规律 “补全” 文本，而扩散解码范式更忠实于视觉证据。

6. 训练细节

三阶段训练流程：**Stage 0a**（LLaVA-Pretrain 550K，仅训练 MLP 适配器，对齐视觉与语言空间）→ **Stage 0b**（LLaVA-NeXT 739K，全参数解冻，提升多模态指令跟随）→ **Stage 1**（Layout&OCR 6.9M，全参数，序列长度 12288，9 epochs）→ **Stage 2**（硬样本 630K，序列长度 16384，4 epochs）。数据增强覆盖几何变换、背景干扰、颜色偏移和图像退化，但不对版面检测样本施加空间增强。

7. 与相关工作的对比

vs AR-VLM（MinerU2.5 等）： 效率优势显著（2–3.2× 加速），语义鲁棒性更强（Semantic Shuffle 上不退化），但在完全自动版面解析上仍有差距（88.94 vs 92.56）。

vs 全注意力扩散 LM： Block-Attn 解决了 Full-Attn 在长序列上的二次复杂度、位置不稳定和长度失配问题，使扩散解码可扩展至数千 token 的文档。

vs 离散扩散 LM（LLaDA，DREAM 等）： MinerU-Diffusion 专为文档 OCR 设计，通过块注意力、视觉条件化、不确定性驱动课程学习三者协同，首次在产业级文档解析基准上验证扩散解码的竞争力。

8. 局限与未来方向

- 版面理解仍是主要瓶颈（有/无 GT Layout 差距 ∼4.4 分），需改进版面检测模块；
- 在复杂打印公式（CPE）上与最优专用管线（MinerU2.5 96.6 vs 91.6）仍有差距，需更精细的符号级建模；
- 数据集聚焦中英文，低资源语言未评估；
- 扩散模型训练效率仍低于 AR（随机掩码分散监督信号），需更大数据量和更精心的训练策略；
- 未来可探索跨块全局精炼机制、更大规模模型缩放、以及扩散解码与 AR 解码的混合策略。

WildWorld：面向生成式 ARPG 的大规模动态世界建模数据集

Li[1,2,4], Meng[1,3], Shi[1], Peng[5], Wu[2,4], Zheng[1], Li[1], Zhang[1] — Alaya Studio / BIT / Tsinghua, 2025

1. 核心思想与动机

动力系统理论与强化学习将世界演化建模为**动作驱动的隐状态动力学**，视觉观测仅是状态的部分投影。近年来视频世界模型试图从数据中学习这种动作条件动力学，但现有数据集存在根本性不足：

- **动作空间贫乏**：大多数数据集仅提供简单动作标注（基本移动、相机旋转），语义信息有限；
- **动作与像素直接耦合**："向左移动"直接表现为视点变化，模型难以学习结构化的世界动力学；
- **缺少隐式状态转移**：如"射击"隐式影响"剩余弹药数"，弹药耗尽后同样的射击动作产生截然不同的视觉结果——这种状态中介关系在现有数据集中完全缺失；
- **长程一致性差**：动作与状态的纠缠导致小误差不断累积，长时预测出现严重不一致。

本文提出 **WildWorld**，从 3A 级动作角色扮演游戏《怪物猎人：荒野》(Monster Hunter: Wilds) 自动采集的大规模动作条件世界建模数据集，核心特点：

- **1.08 亿帧**游戏画面，覆盖多样交互场景；
- **450+ 种语义动作**（移动、攻击、技能释放等）；
- **逐帧显式状态标注**：角色骨骼、世界状态、相机位姿、深度图等 119 列标注；
- 衍生基准 **WildBench**，提出 Action Following 与 State Alignment 两项核心评估指标。

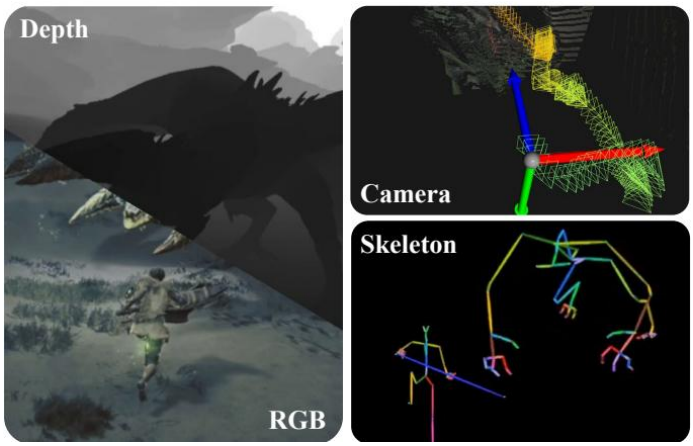

图 1：*WildWorld* 数据集概览。包含 *RGB* 帧及对齐的深度图、相机位姿、骨骼、动作/状态真值，支持细粒度动作级与样本级标注。

2. 数据集构建流程

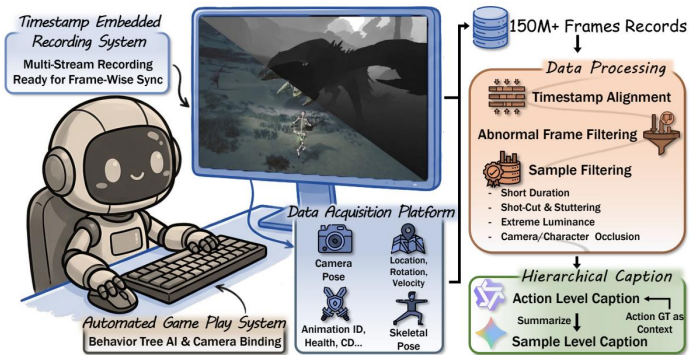

图 2：*WildWorld* 数据集策展流水线。

整体流程包含四个阶段：数据采集平台、自动化游戏录制管线、数据处理与标注管线。

2.1 数据采集平台

采集三类数据：**动作**（控制输入）、**状态**（世界演化）、**观测**（视觉表现）。游戏引擎处理玩家输入并维护世界状态，渲染管线消费引擎信息生成画面。具体记录内容：

- **动作与状态**：执行动作 ID、角色/怪物的绝对位置、旋转、速度、当前动画 ID、HP/耐力/攻防等属性；
- **骨骼姿态**：玩家角色与怪物的逐帧骨骼关键点；
- **世界观测**：RGB 帧、深度图、相机内外参；通过禁用 HUD 着色器获得无 UI 干净画面。

2.2 自动化游戏录制管线

自动对战系统：游戏采用任务制（最多 4 角色组队猎杀怪物）。任务选择通过 UI 编程随机采样任务-NPC 组合；战斗利用内置伙伴 AI 的行为树自动执行。尽管基于规则，组合动作空间大（数十种招式 × 随机怪物行为 × 多角色交互）使轨迹保持多样性。相机由游戏原生锁定系统管理。

录制系统：文本格式的动作/状态每个引擎 tick 统一序列化为 JSON。RGB 和深度通过 OBS Studio + Reshade 自定义着色器同时录制：Reshade 将全屏分为四子窗口分别呈现 RGB 与深度；RGB 用有损 HEVC（目标码率 16 Mbps，最高 20 Mbps），深度用**无损**编码保留几何精度。全屏 2K 分辨率产出 720p 子窗口。嵌入时间戳实现多源同步。

2.3 数据处理与标注管线

多维度过滤：(1) 时长过滤——丢弃少于 81 帧的短样本；(2) 时间连续性——相邻帧间隔超过 1.5× 目标间隔（30 FPS 下约 50ms）的样本被丢弃；(3) 亮度过滤——去除连续 15+ 帧亮度异常的样本；(4) 相机遮挡——通过第三人称弹簧臂收缩检测前景遮挡；(5) 角色遮挡——首帧骨骼投影重叠超过 30% 的样本被排除。

层级标注：基于逐帧动作 ID 将样本分割为动作序列段，每段内动作不变。对每段以 1 FPS 采样 RGB 帧（480p），使用 **Qwen3-VL-235B** 生成细粒度动作级标注（结合动作/状态真值作为提示上下文），再由 **Gemini 3 Flash** 汇总生成样本级标注。

3. 数据集统计

过滤后 WildWorld 包含 **1.08 亿帧**，每帧 **119 列标注**。

实体多样性：29 种怪物、4 种玩家角色、4 种武器（大剑、太刀、弓、双刀）。角色和武器近均匀分布，怪物呈长尾分布，含 7 种次要物种的多怪遭遇。

场景复杂度：5 种地图（沙漠、雪山、森林、沼泽、荒地），含天气（晴/雨）和昼夜变化。约 66% 为战斗片段，34% 为骑行探索。

时空动态：大多数片段 4,000–28,000 帧，部分超 40,000 帧（30+ 分钟）。相机到角色中位距离 15.69 单位，角色到怪物 12.63 单位，确保主体清晰可见。

动作丰富度：每帧角色状态编码为 (武器类型, bank ID, motion ID) 三元组，产生 **5,960 种唯一动作三元组**（24 banks, 455 motion IDs），覆盖移动、攻击、闪避、防御、道具使用等。怪物有 **2,132 种唯一动作对**（13 banks, 527 motion IDs）。Top-150 动作 ID 占 58.49% 样本，呈长尾分布。

4. WildBench 基准

WildBench 从四个维度评估交互式世界模型：

4.1 视频质量

使用 VBench 的四项指标：Motion Smoothness (MS)、Dynamic Degree (DD)、Aesthetic Quality (AQ)、Image Quality (IQ)。

4.2 相机控制

通过 ViPE 从生成视频估计相机轨迹，经标量对齐后计算 **ATE**（绝对轨迹误差）和 **RPE**（相对位姿误差），分别衡量整体精度和局部一致性。

4.3 Action Following（动作跟随）

按逐帧动作 ID 将样本分割为动作段，对每段提取生成视频与真值视频的对应帧，由 Gemini 3 Flash 判断动作是否一致。动作分为移动、快速位移、攻击三类，各配专用提示。最终分数为所有段的平均一致率。

4.4 State Alignment（状态对齐）

以角色/怪物姿态作为状态代理。从真值骨骼提取 2D 关键点轨迹，对生成视频用 **TAPNext** 追踪对应关键点。State Alignment 定义为所有关键点在阈值 $\{4, 8, 16, 32\}$ 像素下的平均坐标精度。

测试集构成：手动策展 200 个样本，覆盖不同难度、场景、角色/怪物类型及特殊事件（技能释放、击倒、死亡、暴击）。100 个玩家 +NPC 协作样本，100 个 1v1 样本。

5. 实验方法

5.1 对比模型

CamCtrl（相机条件）：微调 Wan2.2-Fun-5B-Control-Camera，直接使用 WildWorld 真值相机位姿计算 Plücker 嵌入注入模型。

SkelCtrl（骨骼条件）：微调 Wan2.2-Fun-5B-Control，输入首帧 + 骨骼视频（3D 关键点投影为彩色骨骼图）。

StateCtrl（状态条件）：基于 CamCtrl，将离散状态（怪物类型、武器类别）通过可训练嵌入、连续状态（坐标、HP）通过 MLP 映射到同一特征空间。采用**层级建模**：实体级编码 + 全局状态 + Transformer 建模实体关系，产出统一状态嵌入注入 DiT 中间层。引入状态解码器（保真损失）和状态预测器（时序一致性损失）。

StateCtrl-AR：推理时仅使用首帧真值状态，后续帧由状态预测器**自回归预测**。

所有模型训练分辨率 544×960，81 帧/样本，16 FPS，学习率 1×10^{-5}，250K 迭代，batch size 8，Adam 优化器。

6. 核心实验结果

方法	MS	DD	AQ	IQ	ATE↓	RPE↓	AF	SA
Baseline	96.4	99.0	50.8	65.6	4.63	0.18	53.8	15.3
CamCtrl	97.9	97.0	48.3	62.9	2.02	0.13	83.5	**21.1**
SkelCtrl	97.9	95.0	47.9	62.4	2.55	0.10	**92.8**	**22.0**
StateCtrl	97.5	99.0	**50.9**	**67.8**	**0.94**	**0.07**	85.7	16.1
StateCtrl-AR	97.4	99.0	50.9	67.8	1.01	0.08	74.7	16.1

AF = Action Following, SA = State Alignment. 视频质量为百分比。

6.1 关键发现

所有方法均优于基线。CamCtrl 在相机控制上将 ATE/RPE 分别降低 $\Delta2.61/\Delta0.05$；SkelCtrl 在 Action Following 和 State Alignment 上近乎翻倍提升；StateCtrl 在所有三项交互指标上均有改善，验证了 WildWorld 数据集的广泛适用性。

VBench 指标趋于饱和。所有方法 MS > 95%、DD > 95%，但实际动作建模能力差异巨大（AF 从 53.8 到 92.8），说明交互式世界模型需要 Action Following 和 State Alignment 这类更细粒度的评估指标。

视觉信号条件带来质量权衡。SkelCtrl 使用视觉信号作为控制输入，在交互指标上增益最大，但 AQ（47.9 vs 50.9）和 IQ（62.4 vs 67.8）显著低于 StateCtrl。定性分析显示 StateCtrl 生成更清晰的前景主体，而 SkelCtrl 更好地还原了沙尘飞溅等动态效果——前者被感知为更高画质。

自回归模式展现潜力。StateCtrl-AR 仅用首帧状态自回归预测后续状态，性能接近完整 StateCtrl，但 Action Following 下降（74.7 vs 85.7），归因于迭代预测的误差累积——与自回归视频生成中观察到的现象一致。该范式可与自回归视频生成结合，进一步推动发展。

6.2 评估指标可靠性验证

Action Following 指标与人类判断达到 **85% 一致率**（10 名志愿者，每段 3 人标注，约 5% 不一致段被丢弃）。State Alignment 在真值视频上直接运行关键点追踪达到 **43.23%** 坐标精度，验证了指标的有效性和上限。

7. 与相关工作的对比

与 Sekai、OmniWorld、GameGen-X、MIND 等数据集/基准相比，WildWorld 的独特优势：

- **显式状态标注**：不仅有视觉观测，还有逐帧结构化世界状态（骨骼、HP、位姿等），而非仅依赖隐式视觉表征；
- **动作空间规模**：450+ 种语义动作远超现有数据集的简单移动/相机控制；
- **状态中介机制**：动作通过底层状态转移影响视觉，而非直接耦合像素变化；
- **评估体系**：Action Following 和 State Alignment 直接评估交互建模能力，而非仅关注感知质量或物理合理性。

与引入隐式状态表征的工作相比，WildWorld 提供**显式、语义明确**的状态标注，支持对状态动力学的直接学习与分析。

8. 讨论与局限

核心贡献：(1) 首个具有显式状态标注的大规模交互式世界建模数据集（1.08 亿帧，119 列/帧）；(2) WildBench 基准及 Action Following / State Alignment 评估指标；(3) 系统性实验揭示现有模型在语义丰富动作建模和长程状态一致性方面的不足。

主要局限：

- 数据来源为单一游戏（怪物猎人：荒野），泛化到其他游戏/真实场景需进一步验证；
- 自动 AI 对战可能在策略多样性上不及真实玩家；
- State Alignment 上限 43.23%（受关键点追踪精度限制），仍有改进空间；
- 当前状态条件模型的长程误差累积问题尚未根本解决；
- StateCtrl-AR 的自回归预测质量受限于状态预测器能力，结合更强的序列模型是有前景方向；
- 将显式状态建模扩展到更复杂的开放世界场景（多实体交互、环境状态变化）是重要的未来方向。

SpecEyes：通过推测性感知与规划加速智能体多模态 LLM

Huang*, Huang*, Wan, Zheng, Ji#, Luo# — 厦门大学, Rochester 大学, Ohio State 大学, 2025

1. 动机与问题

智能体多模态大语言模型（Agentic MLLM，如 OpenAI o3、Gemini Agentic Vision）通过迭代调用视觉工具（zoom-in、crop、OCR 等）实现逐步感知-推理-工具调用循环，在细粒度视觉任务上表现卓越。然而，这种级联循环引入严重的**顺序瓶颈**：

- **延迟爆炸**：单查询端到端延迟随**智能体深度** D 线性增长，每步必须等待上一步工具输出完成；
- **并发崩塌**：每个查询的工具链维护独立状态，GPU 批处理被实质无效化，硬件并行度大量闲置。

形式化：智能体系统 $\mathcal{A} = (\mathcal{S}, \mathcal{T}, \pi)$，状态转移 $s_{d+1} = f(s_d, t_d(s_d))$ 构成严格马尔可夫数据依赖——a_{d+1} 依赖 t_d 的输出，无法并行化。单查询延迟：

$$L_{\text{agent}}(q) = \sum_{d=0}^{D(q)} (c_{\text{llm}} + c_{\text{tool}}(t_d))$$

系统吞吐上界 $\Theta_{\text{agent}} \leq B / \sum_i L_{\text{agent}}(q_i)$，随平均 D 增大而急剧恶化。

现有加速方法均在循环内部操作：token 级投机解码加速单步生成但不减少工具调用次数；多模态 token 剪枝/时序压缩降低单步计算但不消除重复调用。**核心洞察**：大量查询根本不需要深层工具辅助推理——轻量无工具模型即可正确回答。

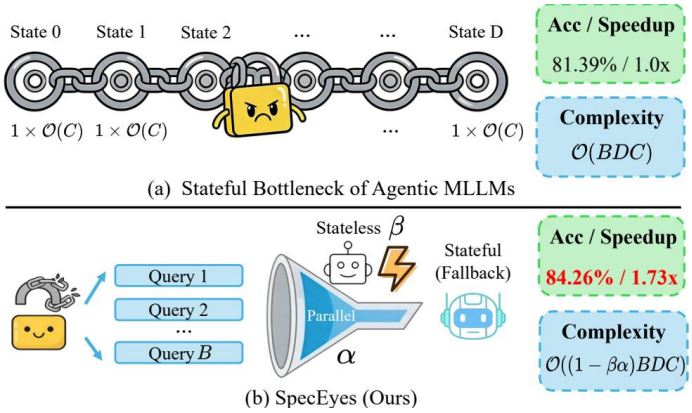

图 1：动机与概览。上方：智能体 *MLLM* 的有状态顺序瓶颈，服务复杂度 $\mathcal{O}(BDC)$。下方：*SpecEyes* 通过无状态小模型和认知门控实现智能体级投机旁路。β 为工具无关筛选比例，α 为投机接受率。

2. SpecEyes 框架

SpecEyes 将投机范式从 token 级提升至**智能体级**，采用“快思考-慢思考”异构架构：轻量无工具模型 $\mathcal{M}_S$（Qwen3-VL-2B）快速投机回答，大型智能体模型 $\mathcal{M}_L$（DeepEyes/Thyme）仅处理确实需要多步工具交互的查询。

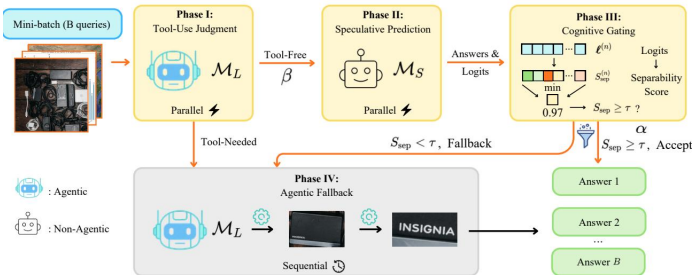

图 2：*SpecEyes* 四阶段漏斗流水线。吞吐加速约 $1/(1-\beta\alpha)\times$。

2.1 Phase I：启发式工具需求判断

$\mathcal{M}_L$ 以轻量二分类方式判断查询是否需要工具：$g(q, I) = \mathcal{M}_L(q, I; \mathcal{P}_{\text{judge}}) \in \{0, 1\}$。$g$=0 的查询进入 Phase II，$g$=1 直接跳至 Phase IV。该步仅生成一个二元 token，开销可忽略。使用 $\mathcal{M}_L$ 而非 $\mathcal{M}_S$ 是因为其工具调用经验使其更擅长判断工具必要性。

2.2 Phase II：投机预测

对 g=0 的查询，$\mathcal{M}_S$ 直接生成答案 $\hat{y}_S$ 及完整 logit 分布 $\{\ell^{(n)}\}_{n=1}^{|\hat{y}_S|}$。该推理**无状态**，可对批内所有查询并行执行。

2.3 Phase III：认知门控（置信切换）

基于 answer separability score S_{sep} 判断是否接受 $\hat{y}_S$：$S_{\text{sep}}(\hat{y}_S) \geq \tau$ 则接受并直接返回，否则回退至 Phase IV。

2.4 Phase IV：智能体回退

低置信查询路由至完整智能体循环：$\hat{y}_L = \pi(s_0 \xrightarrow{t_0} s_1 \xrightarrow{t_1} \cdots \xrightarrow{t_{D-1}} s_D)$，保留全部工具访问能力。

端到端延迟：设 β 为 Phase I 工具无关比例，α 为 Phase III 接受率：

$$\mathbb{E}[L_{\text{SpecEyes}}] = c_J + \beta c_S + (1 - \beta\alpha) L_{\text{agent}}$$

其中 $c_J + \beta c_S \ll L_{\text{agent}}$。当 $\beta\alpha > 0.6$ 时，延迟被轻量前端主导，实现显著加速。

3. Answer Separability 认知门控

3.1 传统置信度的不足

基于 softmax 概率的几何均值置信度 $S_{\log}(\hat{y}_S) = \exp(\frac{1}{|\hat{y}_S|} \sum_n \log p_{\max}^{(n)})$ 存在两个问题：(1) softmax 大 logit 下过度自信（校准失败）；(2) 低熵位置（标点等）的 $p_{\max}^{(n)}$ 虚高，几何聚合未显式度量 top 预测与竞争者的分离度。

3.2 Answer Separability Score

对第 n 个 token 的 logit 向量按降序排列 $\ell_{[1]}^{(n)} \geq \ell_{[2]}^{(n)} \geq \cdots$，定义 token 级可分性：

$$S_{\text{sep}}^{(n)} = \frac{\ell_{[1]}^{(n)} - \mu_K^{(n)}}{\sigma_K^{(n)} + \epsilon}$$

其中 $\mu_K^{(n)}$、$\sigma_K^{(n)}$ 为 top-K logits 的均值和标准差。两个关键优势：(i) **尺度不变性**——分子分母随 logit 幅度线性缩放，中和 softmax 校准伪影；(ii) 通过方差项 $\sigma_K^{(n)}$ **显式建模竞争格局**。

3.3 Token 到答案的聚合

三种策略：mean（均值）、min（最小值）、bottom（最低 r 比例均值）。系统默认采用 **min 聚合**，基于如下风险论证：

命题 1. 定义答案级错误事件 $\mathcal{E} = \bigcup_n \mathcal{E}_n$。若每个 $P(\mathcal{E}_n)$ 关于 $S_{\text{sep}}^{(n)}$ 单调递减，则对 $\min_n S_{\text{sep}}^{(n)}$ 设阈值确保每个 token 都超过置信阈值，从而对联合概率 $P(\mathcal{E})$ 提供最紧的上界。

min 策略本质上是**最坏情况守卫**：任何 token 出现低可分性即触发回退，优先保证精度。

4. 异构并行服务架构

4.1 批并行前端

Phase I（筛选，延迟 c_J）和 Phase II（投机推理，延迟 c_S）均为无状态单轮前向传播，完全可批并行化，并行前端开销仅 $c_J + c_S$。

4.2 漏斗形服务

接受的查询（$\alpha\beta B$ 个）立即返回；残余集 $|\mathcal{R}| = (1 - \beta\alpha)B$ 回退至顺序智能体执行。吞吐加速比：

$$\Theta_{\text{SpecEyes}} / \Theta_{\text{agent}} \approx 1/(1 - \beta\alpha)$$

由筛选比例 β 和门控接受率 α 共同决定。跨所有基准平均 $\beta \approx 80\%$，$\alpha \approx 71\%$。

5. 实验结果

设置：三个基准——V* Bench（细粒度感知，Direct Attributes 115 题 + Relative Position 76 题）、HR-Bench（高分辨率 4K/8K，各 800 题）、POPE（幻觉检测，3 个分割各 3000 题）。$\mathcal{M}_S$=Qwen3-VL-2B，$\mathcal{M}_L$=DeepEyes/Thyme，工具步数上限 5 步，单卡 A100 40GB，贪心解码。K=64，ϵ=10^{-6}。

方法	平均准确率	平均加速
DeepEyes 基线	81.39%	1.00×
SpecReason	66.85%	0.43×
SpecEyes (min)	**84.26%**	**1.73×**
Thyme 基线	82.29%	1.00×
SpecReason	83.78%	0.48×
SpecEyes (min)	**83.99%**	**1.42×**

DeepEyes 骨干下，SpecEyes (min) 平均加速 1.73×，准确率反而从 81.39% 提升至 84.26%（+2.87%）。V* Attr 保持 90.43% 不变（1.53×），Pos 从 82.89% 提升至 89.47%（1.90×）。POPE 受益最大（2.13–2.19×），准确率均高于基线（如 Adversarial: 78.43% → 85.13%），表明跳过不必要的工具轨迹还能减少幻觉错误。HR-Bench 加速适中（1.08–1.13×），因查询更频繁地需要细粒度工具检查。

Thyme 骨干下确认泛化性：1.42× 平均加速，准确率 82.29% → 83.99%。POPE 获益最大（1.70–1.78×），HR-Bench 8K 出现 0.95× 的边际减速——高分辨率输入抑制 β 和 α，$\mathcal{M}_S$ 的固定开销略超节省。

SpecReason 持续减速（DeepEyes 下 0.43×，Thyme 下 0.48×），因小模型缺乏结构化工具调用能力，平均产生 414 tokens 和 3.48 轮交互开销。Qwen3-VL-2B 纯推理的加速上界为 4.13×（但准确率仅 78.93%），SpecEyes 在保持推理质量的同时捕获了大部分延迟收益。

6. 置信度校准分析

通过 KDE 可视化 $\mathcal{M}_S$ 在 V* 上正确/错误样本的置信分布：S_{log} 和 $S_{\text{sep}}^{\text{mean}}$ 的 Δ（双峰间距）小，分布严重重叠；$S_{\text{sep}}^{\text{bottom}}$ 改善 Δ 但中间区域仍有残余重叠；$S_{\text{sep}}^{\text{min}}$ 实现**最大** Δ——错误样本坍缩至低分峰，正确样本形成尖锐高分模态，双峰分离清晰，与命题 1 一致。单一阈值即可在保持准确率的同时最大化接受率。

7. 消融实验

门控阈值：降低阈值单调增加接受率和加速比，准确率平缓下降。V* 和 POPE 在阈值 0.94–0.99 的宽范围内准确率保持在基线水平之上，证明大量查询可安全旁路。HR-Bench 更敏感，阈值低于 0.97 准确率开始下降。存在宽广的操作区间同时改善准确率和速度，阈值并非脆弱超参而是平滑的 Pareto 前沿控制旋钮。

批大小：增大批大小持续提升加速比（准确率不变），符合异构漏斗设计——投机阶段无状态可批并行，开销随批大小摊薄。高旁路率数据集（V*, POPE）从批处理获益更多，HR-Bench 较早饱和。

Top-K 选择：K 作为控制旋钮——增大 K 单调提升加速但降低准确率（纳入弱对比信号的 token 膨胀置信估计）。K=64 为平衡默认值：V* Attr 匹配基线 90.43%（1.50×），Pos 达 89.47%（1.94×）。

8. 讨论与局限

核心贡献：(1) 首次形式化智能体 MLLM 的有状态瓶颈；(2) 首个智能体级投机加速框架，旁路整个工具链而非加速链内单步；(3) 基于 answer separability 的认知门控，无需标注、尺度不变；(4) 异构并行漏斗将投机接受率转化为吞吐倍增。

局限：当前投机模型在深度 D=0（完全无工具）操作，在大部分查询确实需要工具的基准（如 HR-Bench）上加速有限。未来方向为**多深度投机** $D=1, 2, \ldots, n$——允许投机模型执行有限次轻量工具调用再门控，在最早充分深度截断查询，进一步减少对重型骨干的回退。此外，认知门控的阈值仍需在小验证集上离线标定（约 5–10 分钟），自适应阈值策略值得探索。

PEARL：个性化流式视频理解模型

Zheng*, An*, Lin, Liu, Yang, Zhang, Li, Zhang, Zhang, Li, Zhang, Li☒, Zhang# — PKU, Adobe, CASIA, Stepfun, CUHK, 2026

1. 动机与问题定义

人类对新概念的认知本质上是一个**流式过程**——我们持续识别新的物体或人物身份，并随时间更新记忆。然而，当前多模态个性化方法存在根本性局限：Yo'LLaVA、MC-LLaVA 等方法仅限于静态图像任务；PVChat 虽开创了个性化视频理解，但仅支持离线场景和单轮交互，无法适应开放式、流式的真实环境。

本文首次提出并形式化定义**个性化流式视频理解**（Personalized Streaming Video Understanding, PSVU）任务。与传统设置相比，PSVU 具有三大核心特性：

- **连续流式视频输入**：视频以场景序列持续到达，而非预录制的离线片段；
- **动态概念定义**：用户可在任意时间戳即时引入新概念（人物/动作），而非依赖预定义概念池；
- **多轮交互**：支持在后续任意时间步对已定义概念进行灵活查询。

形式化定义：流式视频 $V = [\mathcal{X}_1, \mathcal{X}_2, \ldots]$，用户在时间戳 t_c 引入新概念形成演化集合 $\mathcal{C} = \{C_1, C_2, \ldots\}$。对于在 $t_q \geq t_c$ 时刻发出的查询 Q，模型需动态构建上下文生成响应：

$$A = \mathcal{M}(\mathcal{C}_{sub}, \mathcal{V}_{context}, Q)$$

其中 $\mathcal{C}_{sub} \subseteq \mathcal{C}$ 为查询相关概念子集，$\mathcal{V}_{context}$ 为必要的视觉上下文。核心挑战在于：（1）维护无界流式历史与演化概念的计算成本；（2）实时准确检索个性化 $\mathcal{C}_{sub}$ 和 $\mathcal{V}_{context}$。

2. PEARL-Bench：首个 PSVU 基准

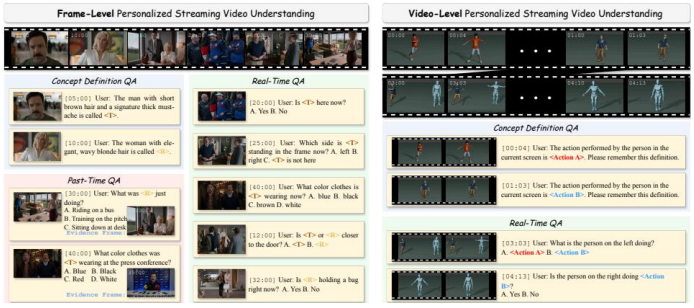

图 1：*PEARL-Bench* 概览。左：*Frame-level* 场景；右：*Video-level* 场景。

2.1 基准设计与数据统计

PEARL-Bench 是首个同时支持长视频流式输入、多轮概念交互以及 Frame-level 和 Video-level 两种个性化概念类型的基准。包含 **132 个视频、2,173 条精细标注**，平均视频时长 **1,458 秒**，所有标注均关联精确时间戳。

两种概念类型：

- **Frame-level 概念**：单帧注册的静态实体（如特定人物/物体），112 个视频，平均 1,657 秒；
- **Video-level 概念**：跨连续帧展开的动态动作（如个性化手势/动作序列），20 个视频，平均 303 秒。

三类查询：

- **Concept-Definition QA**（498 条）：在特定时间戳引入新概念，模型将其注册到记忆中；
- **Real-Time QA**（1,281 条）：查询已定义概念在当前时刻的状态，纯基于当前场景回答；
- **Past-Time QA**（394 条）：询问已定义概念的历史状态/活动，需检索历史片段进行长程时序推理。

2.2 数据构建流程

视频收集与过滤：Frame-level 视频来自动漫、电影、真人秀等多样领域；Video-level 视频因标注困难，采用数字人合成方案——利用 Mixamo 平台随机组合 8 种角色、20 种动作、20 种背景场景。

标注流程：Concept-Definition QA 标注概念出现的时间戳并提出注册问题，使用 SSA 数据库中的 10k 常见名字随机替换原始概念名以防止模型利用先验知识。Real-Time QA 标注当前时刻的概念相关问题，由强 VLM 生成选择题干扰项，严格排除无需概念知识即可回答的问题。Past-Time QA 额外标注历史证据时间戳，确保正确回答必须依赖历史片段检索。

质量控制：10 名多模态研究经验超 1 年的研究员参与，6 人负责标注、4 人负责审核。采用自动化过滤 + 人工验证双管线：自动阶段通过消融实验过滤不需要概念/历史信息即可回答的简单问题；人工阶段进行多轮检查。

2.3 与现有基准对比

现有个性化基准（MyVLM、Yo'LLaVA、MC-LLaVA、UnifyBench、MMPB）均为图像基准，不支持视频/流式/多轮交互。PVChat 和 This-is-My 虽引入视频但限于短离线视频（<5 秒），且**无一支持 Video-level 个性化**。PEARL-Bench 首次实现全维度覆盖。

3. PEARL 框架

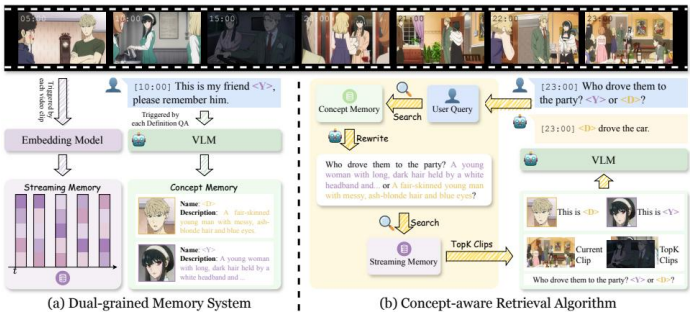

图 2：*PEARL* 框架。*(a)* 双粒度记忆系统；*(b)* 概念感知检索算法。

PEARL 是一个**免训练、即插即用**的框架，核心由双粒度记忆系统和概念感知检索算法组成。

3.1 双粒度记忆系统

将概念中心知识与流式观测**显式解耦**：

Streaming Memory（流式记忆）：维护场景片段集合。通过 PySceneDetect 检测场景边界将视频流分割为有序片段序列 $V = [\mathcal{X}_1, \mathcal{X}_2, \ldots]$。对每个新片段 $\mathcal{X}_i$，使用多模态嵌入模型 $f_{\text{emb}}(\cdot)$（Qwen3-VL-Embedding-2B）计算嵌入 $\mathbf{e}_i = f_{\text{emb}}(\mathcal{X}_i)$，存储对 $(\mathcal{X}_i, \mathbf{e}_i)$。场景检测阈值 27.0，片段时长限制 1.0–8.0 秒。

Concept Memory（概念记忆）：当概念定义查询 Q_{def} 在时间戳 t_c 发出时，模型创建包含三个组件的新条目：(i) 概念名称；(ii) 视觉证据——Video-level 存储当前片段，Frame-level 存储当前帧；(iii) 文本描述——使用标准化提示模板生成概念显著特征的紧凑描述。Frame-level 描述聚焦永久稳定特征（性别、面部、发型、体型），忽略衣着等临时元素；Video-level 描述聚焦核心运动模式，忽略执行者身份和背景。

3.2 概念感知检索算法

当用户在 t_q 发出查询时，需获取三类信息：

概念检索：识别查询 Q 中提及的概念名称，以此为键从 Concept Memory 检索对应条目，得到 $\mathcal{C}_{sub}$。

历史片段检索：使用模型 $\mathcal{M}$ 将查询重写为 $\tilde{Q}$——将每个概念名称替换为其关联描述（如将 "XiaoJing" 替换为 "一个长黑发的年轻女性"），使嵌入模型能有效匹配语义。计算 $\mathbf{e}_Q = f_{\text{emb}}(\tilde{Q})$，与所有已存储片段嵌入 $\{\mathbf{e}_i\}_{i \leq t_q}$ 计算余弦相似度，选取 **top-K** 最相关片段，并对每个选中片段扩展其相邻 N 个片段以捕获局部时序上下文，得到 $\mathcal{V}_{context}$。默认 $K = 4$，Frame-level $N = 1$，Video-level $N = 0$，采样 1 FPS。

最终将检索到的概念条目、历史片段、当前片段 $\mathcal{X}_{t_q}$ 和原始查询 Q 输入 VLM 生成响应。

4. 实验结果

4.1 实现细节

基座模型使用 LLaVA-OV-7B、Qwen2-VL-7B 和 Qwen3-VL-8B。离线模型统一采样 64 帧；在线模型保持原始采样配置。采用循环选项轮换评估策略（4 次旋转均正确才计对）以消除选项位置偏差。

4.2 主要结果

方法	F-RT	F-PT	F-Avg	V-RT
Human	97.61	96.45	97.03	97.49
Text-only (Q3-8B)	11.06	17.45	14.26	7.04
Gemini3-pro	47.40	48.98	48.19	24.51
InternVL3.5-8B	30.35	35.06	32.71	5.57
Qwen3-VL-8B	27.33	30.20	28.77	25.51
StreamForest-7B	29.18	40.86	35.02	10.85
TimeChat-Online	31.89	35.28	33.59	22.29
ReKV (LLOV-7B)	26.20	37.46	31.83	24.11
LLOV-7B+PEARL	33.41	42.64	38.03	19.94
Q2-7B+PEARL	33.30	44.42	38.86	24.34
Q3-8B+PEARL	**54.99**	**49.49**	**52.24**	**48.39**

Frame-level 结果：PEARL 在三种基座模型上分别带来 8.55%、9.36%、23.47% 的平均提升。Qwen3-VL-8B+PEARL 超越专有模型 Gemini3-pro-preview 4% 以上。与共享相同 backbone 的 ReKV 相比，LLaVA-OV-7B+PEARL 在 Real-Time 和 Past-Time 上分别领先 7.21% 和 5.18%，证明增益来自框架设计本身。

Video-level 结果：所有模型在 Video-level 上得分显著低于 Frame-level，反映需推理跨帧连续动作的更大难度。Qwen3-VL-8B+PEARL 以 48.39% 大幅领先最佳在线基线 ReKV 达 24.28%，同时超越 Gemini3-pro 近 24%。

离线模型的关键局限：为满足低延迟推理，离线模型仅能处理受限视觉上下文（64 帧），且缺乏显式记忆机制保存和检索长程历史证据，导致回答所需视觉信息常缺失。

4.3 消融实验

在 Qwen3-VL-8B Frame-level 上逐步启用 PEARL 各组件：

- **Text-only**：Real-Time 11.06%，接近随机；
- **+ 当前片段**：仅微弱提升至 15.84%/20.30%；
- **+Concept Memory**：Real-Time **飙升至 51.41%**（+35.57%），证明概念记忆**不可或缺**——没有概念信息模型无法将用户定义名称关联到个性化实体；
- **+Streaming Memory**：Past-Time **跃升至 45.69%**（+20.26%），证明历史片段检索对时序推理至关重要；
- **+Query Rewriting**（完整 PEARL）：两项指标进一步提升，平均准确率额外增加 4.28%——将个性化名称转化为描述性语义使嵌入模型能更有效匹配。

4.4 效率分析

LLaVA-OV-7B+PEARL 端到端延迟仅 775ms，不仅准确率高于所有在线基线，速度也快于所有在线基线。Qwen3-VL-8B+PEARL 延迟 2,111ms，虽略高但准确率大幅领先 StreamForest-7B 达 17.22%。延迟分解显示，PEARL 核心模块（概念检索、查询重写、流式记忆检索）引入的延迟**极低且与模型无关**，底层 LLM 推理构成主要延迟瓶颈。

4.5 超参分析

Past-Time QA：$K = 0$ 时无历史片段可用，指标极低；K 增大时准确率快速提升并在 $K \geq 3$ 后趋于平稳；$N = 1$ 与 $N = 2$ 差距极小，表明 1 个相邻片段已捕获大部分有用信息。Real-Time QA 对 K、N 不敏感，过多历史片段反而引入噪声导致小幅下降。

4.6 模型规模影响

在 Qwen2-VL（2B/7B）和 Qwen3-VL（4B/8B）系列上验证：（1）PEARL 在所有规模上均带来显著且一致的提升（Qwen3-VL-4B/8B 分别提升 18.00%/23.47%），证明设计的鲁棒性；（2）**离线模型的规模悖论**——标准离线模式下增大模型规模并未带来显著增益，说明传统离线范式从根本上不适合 PSVU 任务。只有整合 PEARL 后，模型规模增大的收益才被释放。

5. 讨论与局限

核心贡献：（1）首次定义 PSVU 任务并构建首个综合基准 PEARL-Bench，涵盖 Frame-level 和 Video-level 两种个性化模式；（2）提出免训练即插即用的 PEARL 框架，通过双粒度记忆系统和概念感知检索算法实现 SOTA 性能；（3）在 3 种架构上证明一致的提升效果。

局限性：

- 概念描述质量依赖基座 VLM 的视觉理解能力，对外观高度相似的概念区分力有限；
- 当前检索基于全局语义嵌入相似度，对需精细空间定位的查询（如局部遮挡场景）可能不足；
- Video-level 概念理解仍具挑战（最佳模型 48.39% vs. 人类 97.49%），复杂动作的时序建模有待提升；
- 评估仅在 7–8B 规模模型上进行，更大规模模型和多模态检索模型的潜力尚未探索；
- 流式场景检测和片段分割策略较为简单（固定阈值），自适应分割策略可能进一步提升性能。

未来方向：扩展至更大规模模型、引入细粒度空间检索（如区域级嵌入）、支持更复杂的多概念交互推理、以及面向真实部署的端到端系统优化。

DA-Flow：基于扩散模型的退化感知光流估计

Min[1], Lee[1], Choi[1], Cho[1], Kim[1], Lee[2], Ahn[2], Lee[2], Park[2], Kim[1†] — [1]KAIST AI, [2]Hanwha Systems, 2025

1. 问题动机与背景

光流估计（Optical Flow Estimation）是计算机视觉中的基本稠密对应问题，旨在估计连续视频帧之间的逐像素运动场。以 RAFT、SEA-RAFT、FlowSeek 为代表的深度方法在高质量输入上已取得优异精度，但**真实世界视频几乎不可能是干净的**——运动模糊、传感器噪声、压缩伪影和低分辨率频繁共存，严重降低视觉质量。RobustSpring 首次系统基准测试了稠密匹配模型在各类退化下的鲁棒性，但一个根本性问题仍悬而未决：能否从严重退化的输入中准确估计光流？本文将焦点从鲁棒性转向精度，提出**退化感知光流**（Degradation-Aware Optical Flow）新任务：直接从严重退化输入估计稠密对应。该任务本质上是**病态的**——退化破坏精细纹理并衰减运动边界，使传统匹配证据不足。简单地用合成退化增强训练数据远不够；需要的是既能**保留空间结构**用于稠密匹配、又能**感知退化模式**以恢复丢失信息的表示。

核心洞察：图像修复扩散模型的中间表示天然具备退化感知能力（因修复本身就是高度欠定的逆问题，模型必须从退化输入恢复干净结构），但**缺乏时间感知**。视频修复扩散模型虽然联合建模退化与时间动态，但通过 3D 卷积或时间注意力将多帧编码为时间压缩的共享潜变量，帧级空间结构不再可分离，不适合逐像素对应匹配。

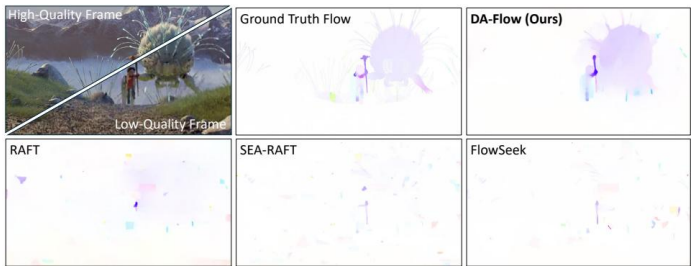

图 1：*DA-Flow* 与基线方法在 *Spring* 基准上的定性比较。在严重退化下，现有方法无法恢复可靠对应，*DA-Flow* 能准确估计底层运动。

2. 方法论

2.1 问题形式化

给定低质量视频 $\mathbf{V}_{\mathrm{LQ}}$ 和对应高质量视频 $\mathbf{V}_{\mathrm{HQ}}$（各含 N 帧 $\mathbf{I}^i \in \mathbb{R}^{3\times H\times W}$），目标是学习退化感知光流模型 $\mathcal{M}$，对连续帧 $(k, k{+}1)$ 估计：

$$\widehat{\mathbf{f}}_{k\to k+1} = \mathcal{M}(\mathbf{I}^k_{\mathrm{LQ}}, \mathbf{I}^{k+1}_{\mathrm{LQ}}) \approx \mathbf{f}^*_{k\to k+1}$$

其中 $\mathbf{f}^*$ 为真实光流。标准光流流水线 $\mathcal{M} = \mathcal{U}\circ\mathcal{C}\circ\mathcal{E}$（特征编码器 $\mathcal{E}$、相关算子 $\mathcal{C}$、迭代更新算子 $\mathcal{U}$）中，$\mathcal{E}$ 最直接受退化影响，因此本文聚焦构建退化感知特征编码器，保持 $\mathcal{C}$ 和 $\mathcal{U}$ 不变。

2.2 提升图像修复模型至视频域（Lifting）

基础架构采用基于 DiT 的图像修复模型 DiT4SR，使用 MM-DiT（Multi-Modal Diffusion Transformer）架构。原始模型将每帧独立处理（时间维折叠进 batch 轴），三种模态 token 序列（HQ 潜变量 $\mathbf{F}_{\mathrm{HQ}}$、LQ 条件 $\mathbf{F}_{\mathrm{LQ}}$、文本 $\mathbf{F}_{\mathrm{Text}}$）在每帧内通过 MM-Attention 联合关注，但**帧间无交互**。

全时空注意力提升：将每个模态流从 $\mathbf{F}_m \in \mathbb{R}^{(BF)\times T\times C}$ 重塑为 $\bar{\mathbf{F}}_m \in \mathbb{R}^{B\times(FT)\times C}$，将所有帧的空间 token 拼接为单一序列。模态投影和拼接后得到时空查询/键/值 $\tilde{\mathbf{Q}}, \tilde{\mathbf{K}}, \tilde{\mathbf{V}} \in \mathbb{R}^{B\times(3FT)\times C}$，计算全时空 MM-Attention：

$$\text{MM-Attn} = \mathrm{softmax}\left(\frac{\tilde{\mathbf{Q}}\tilde{\mathbf{K}}^\top}{\sqrt{C}}\right)\tilde{\mathbf{V}}$$

每个 token 现在关注**所有帧、所有模态**的所有空间 token，实现显式帧间推理。此设计保持每帧独立空间潜变量（稠密匹配关键），同时实现可控时间交互。在 YouHQ 数据集（38,576 高分辨率视频）上微调 $F{=}3$ 连续帧片段，使用扩散损失 $\mathcal{L}_{\mathrm{diff}}$。

2.3 扩散特征分析

从提升模型的全时空 MM-Attention 层提取注意力特征：给定帧对 $(k, k{+}1)$，取帧 k 的 query 特征 $\tilde{\mathbf{Q}}^k_{\mathrm{HQ}}$ 和帧 $k{+}1$ 的 key 特征 $\tilde{\mathbf{K}}^{k+1}_{\mathrm{HQ}} \in \mathbb{R}^{B\times T\times C}$。**零样本评估**：将特征重塑为 $\mathbb{R}^{h\times w\times C}$，构建代价体 $\mathbf{C}(i,j) = \tilde{\mathbf{Q}}^k_{\mathrm{HQ}}(i)\cdot\tilde{\mathbf{K}}^{k+1}_{\mathrm{HQ}}(j)$，通过 softargmax 获取流场并上采样至原始分辨率。

关键发现：(1) 微调后的 Lifting 特征在所有层级排名中 EPE 一致低于未微调 Baseline，证实全时空注意力微调使模型学会了帧间对应；(2) Lifting 特征在整个去噪轨迹上保持**稳定**，而 Baseline 对提取时间步高度敏感；(3) 与 post-AdaNorm 特征相比，Query/Key 特征因注意力机制天然编码成对空间关系，更适合几何对应。最终选择 top-4 层 $\{3, 13, 16, 17\}$ 用于 DA-Flow。

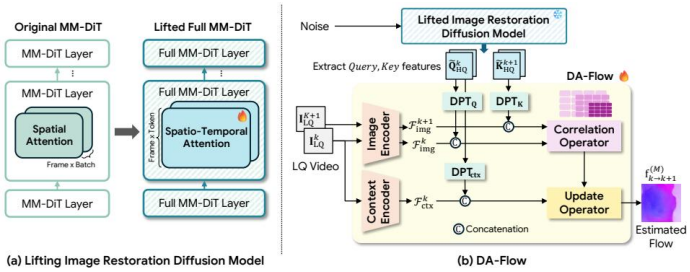

图 2：*DA-Flow* 整体架构。融合提升扩散特征与 *CNN* 特征的混合编码器。

2.4 DA-Flow 架构

DA-Flow 基于 RAFT 构建，保留原始相关算子 $\mathcal{C}$ 和迭代更新算子 $\mathcal{U}$，引入提升扩散模型 $\mathcal{D}_\phi$ 与传统特征编码器 $\mathcal{E}$ 并行：

$$\mathcal{M}_\theta = \mathcal{U}\circ\mathcal{C}\circ(\mathrm{Up}(\mathcal{D}_\phi), \mathcal{E})$$

特征上采样（Up）：扩散特征分辨率为输入的 1/16，直接传入 $\mathcal{C}$ 会限制 4D 代价体质量。聚合 top-L 层特征后通过**独立 DPT 上采样头**恢复 $H/8\times W/8$ 分辨率：Query Head 和 Key Head 产生对应特征用于代价体构建，Context Head 产生空间条件特征用于迭代更新：

$$\mathcal{F}^{k,\uparrow}_{\mathrm{Q}} = \mathrm{DPT}_{\mathrm{Q}}(\{\tilde{\mathbf{Q}}^{k,l}_{\mathrm{HQ}}\}_{l=1}^{L}), \quad \mathcal{F}^{k+1,\uparrow}_{\mathrm{K}} = \mathrm{DPT}_{\mathrm{K}}(\{\tilde{\mathbf{K}}^{k+1,l}_{\mathrm{HQ}}\}_{l=1}^{L})$$

混合特征编码：扩散特征提供退化感知全局表示但缺乏空间局部化。RAFT 的 CNN 编码器（图像编码器 $\mathcal{E}_{\mathrm{img}}$ 和上下文编码器 $\mathcal{E}_{\mathrm{ctx}}$）通过卷积架构保留局部细节。两类特征沿通道拼接形成混合表示：

$$\mathcal{F}^k = \mathrm{Concat}(\mathcal{F}^k_{\mathrm{img}}, \mathcal{F}^{k,\uparrow}_{\mathrm{Q}}), \quad \mathcal{F}^k_{\text{h-ctx}} = \mathrm{Concat}(\mathcal{F}^k_{\mathrm{ctx}}, \mathcal{F}^{k,\uparrow}_{\mathrm{ctx}})$$

$\mathcal{F}^k, \mathcal{F}^{k+1}$ 用于构建相关体，$\mathcal{F}^k_{\text{h-ctx}}$ 提供迭代更新的空间条件。

损失函数：由于真实退化视频无法获取真实光流，使用 SEA-RAFT 在 HQ 帧对上生成伪真值 $\mathbf{f}^*$，以 LQ 帧为输入训练。采用标准多尺度流损失：

$$\mathcal{L}_{\mathrm{flow}} = \sum_{i=1}^{M}\gamma^{M-i}\|\mathbf{f}^{(i)}_{k\to k+1} - \mathbf{f}^*_{k\to k+1}\|_1$$

其中 M 为迭代精炼步数，γ 为权重衰减因子。

3. 实验结果

3.1 实验设置

两阶段训练：(1) 提升扩散模型用 $\mathcal{L}_{\mathrm{diff}}$ 训练，$F{=}3$ 帧；(2) 冻结 $\mathcal{D}_\phi$，用 $\mathcal{L}_{\mathrm{flow}}$ 训练流估计管线，$M{=}12$ 次迭代精炼。两阶段各 20K 步，batch size 32，4 × H100 GPU，学习率 5×10^{-5}。退化管线采用 RealBasicVSR 的 Real-ESRGAN 帧级退化 + 视频压缩。推理时 10 步去噪 + 20 次精炼迭代。

3.2 定量结果

在 Sintel、Spring、TartanAir 三个基准（均经相同退化管线生成 LQ 输入）上评估 EPE 和 1/3/5px 离群率：

方法	Sintel EPE↓	Spring EPE↓	TartanAir 1px↓
RAFT	10.69	3.944	75.17
SEA-RAFT	10.18	2.703	77.85
FlowSeek	10.24	2.861	76.96
DA-Flow	**6.912**	**2.207**	**72.35**

DA-Flow 在 Sintel 上 EPE 降低 **32%**（10.18→6.91），Spring 上降低 **18%**（2.70→2.21）。在 TartanAir 上所有离群率阈值（1/3/5px）均最优（72.35/37.61/25.40 vs 次优 75.17/42.96/30.04），EPE 略高于 FlowSeek（8.87 vs 7.69），归因于少数大位移像素不成比例地膨胀平均误差。所有基准离群率一致更低表明 DA-Flow 在绝大多数像素上更准确。

3.3 消融实验

Lifting 特征 vs Baseline 特征（Tab. 2）：使用未微调全注意力模型特征的 Baseline* 在 Sintel 上所有步 EPE 均 ≥7.41，DA-Flow 在步 3 达最优 6.72。Spring 上 DA-Flow 在 1px 离群率上全步领先（30.49–31.23 vs 31.86–32.74）。

微调 RAFT 基线（Tab. 4）：在相同数据上微调 RAFT（RAFT*）EPE 为 7.033，DA-Flow 为 6.912，1px 离群率 56.99 vs 55.80，证明优势来自退化感知扩散特征而非仅训练数据。

架构组件消融（Tab. 5，Sintel）：

- 仅双线性上采样无 CNN 编码器：EPE 7.224；
- DPT 上采样无 CNN：EPE 8.075（最差）；
- 双线性 + CNN：EPE 7.123；
- **DPT + CNN（DA-Flow）**：EPE **6.912**，所有指标最优。

CNN 编码器提供互补的细粒度空间信息；DPT 上采样在有 CNN 特征支撑时才能充分发挥多尺度聚合优势。

去噪步敏感性：DA-Flow 在步 3–5 达 Sintel 最优 EPE（∼6.72），步 8–9 约 7.0–7.6；Spring 上各步 EPE 稳定在 2.17–2.29，体现 Lifting 特征的时间步鲁棒性。

3.4 视频修复应用（Tab. 6）

将 DA-Flow 结合 MGLD 引导机制用于视频修复（在图像空间而非潜变量空间执行引导）。在 YouHQ40 上：PSNR 从 22.50（MGLD）提升至 **23.47**，LPIPS 从 0.266 降至 **0.215**，翘曲误差 E_{warp} 从 4.53×10^{-3} 降至 3.48×10^{-3}，验证 DA-Flow 估计的准确光流有效改善时间一致性。

4. 与相关工作的对比

vs 传统光流方法（RAFT/SEA-RAFT/FlowSeek）：这些方法针对干净输入设计，退化下特征编码器直接受损，误差传播至下游。DA-Flow 通过退化感知扩散特征从根源解决问题。

vs 直接使用视频扩散特征：FlashVSR 等视频修复扩散模型将多帧压缩为单一潜变量，插值恢复逐帧特征后几何对应质量远逊于 Lifting（图 9），证实图像扩散模型 + 帧间注意力提升的策略优于直接采用视频扩散 backbone。

vs DIFT/DiffTrack 等扩散对应方法：DIFT 从图像生成扩散模型提取特征实现零样本对应，DiffTrack 从视频扩散 Transformer 提取时间对应。DA-Flow 的独特之处在于从修复扩散模型出发，天然编码退化模式，且通过 Lifting 在保持帧级空间结构的同时获得时间感知。

5. 局限性与未来方向

- **推理速度**：需多步去噪（10 步），运行时间远高于传统流网络。一步蒸馏（one-step distillation）是有前景的加速方向；
- **伪真值依赖**：训练依赖预训练流模型在 HQ 帧上的输出作为监督，其精度上限制约 DA-Flow 的最终性能；
- **退化管线假设**：评估使用合成退化管线（Real-ESRGAN + 视频压缩），与真实世界退化分布可能存在差距；
- **大位移**：TartanAir 上 EPE 略高于 FlowSeek，表明在极大位移场景下仍有改进空间；
- **未来方向**：扩展至更多退化类型、真实退化数据集；结合端到端训练联合优化修复与流估计；探索轻量化架构以提升实用性。

SIMART：通过 MLLM 将单体网格分解为仿真就绪的铰接资产

Zhang[1,2], Qin[1], Wang[1], Xie[1], Li[1], Wang[2] — [1]ByteDance Seed, [2]NTU, 2025

1. 动机与问题背景

高质量的铰接（articulated）3D 资产对于具身智能和物理仿真至关重要，但当前 3D 生成技术主要产出**静态单体网格**，缺乏运动学和物理元数据，无法直接用于仿真（即非"sim-ready"）。现有铰接物体创建方法存在两类根本缺陷：

- **多阶段流水线累积误差**：传统方法将部件分解、关节参数推断和后处理装配解耦为独立模块。部件分解往往不具备铰接感知——2D 视觉语言模型的先验迁移到 3D 边界不可靠，而 3D 原生分割方法（如 PartField、P3SAM）优化表面一致性，但可能遗漏力学上有意义的连接边界，产出外观合理但违反运动学约束的部件。关节估计进一步放大脆弱性——无论从 2D 线索预测还是从不完美几何优化，推断的关节常与恢复的部件几何不兼容，导致物理上无效的铰接；
- **密集体素 token 化的效率瓶颈**：统一 MLLM 范式理论上可同时理解 3D 资产并生成 URDF 规格，但现有 3D-native MLLM 尝试受限于密集体积编码——$O(N^3)$ 复杂度将大量 token 浪费在空白空间上，导致上下文长度爆炸和显存耗尽，即便是理解任务也难以扩展至复杂铰接物体。

核心挑战：开发一种高效、稀疏的 3D 表征，同时支持 MLLM 理解和可扩展的高保真生成。

2. SIMART 框架概述

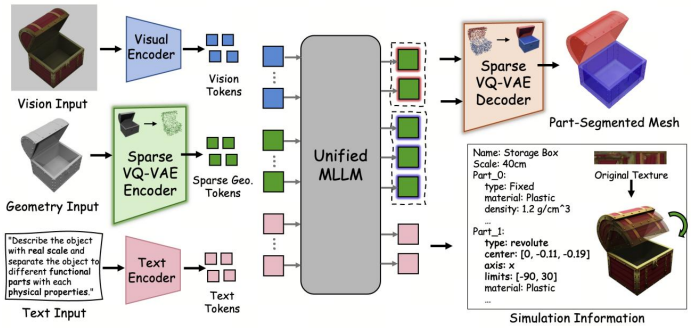

图 1：*SIMART 流水线。Sparse 3D VQ-VAE 编码几何为紧凑 token，经统一 MLLM 骨干融合视觉/文本输入进行部件定位和关节参数估计，输出 URDF 元数据与分解网格。*

SIMART 是一个统一的多模态大语言模型框架，**联合执行部件级网格分解与运动学参数预测**。给定多模态输入 $\mathcal{T} = \{I_{vis}, G_{geo}, T_{txt}\}$（视觉观测、原始几何、语言指令），输出仿真就绪资产 $\mathcal{A} = (\mathcal{M}_{seg}, \mathcal{P}_{sim})$，其中 $\mathcal{M}_{seg} = \{m_1, \ldots, m_n\}$ 为部件分割网格，$\mathcal{P}_{sim}$ 包含关节类型/轴/限位、全局尺度、摩擦和密度等仿真元数据。

2.1 统一 MLLM 骨干

采用 **Qwen3-VL** 架构，利用其大规模图像-文本预训练能力和对物理世界的涌现理解。输入为三种模态 token 的拼接序列（总长 $L = N_v + N_g + N_t$）：

- **视觉 token** $F_{vis} \in \mathbb{R}^{N_v \times D}$：RGB 图像经 ViT 编码器提取语义上下文；
- **几何 token** $F_{geo} \in \mathbb{R}^{N_g \times D}$：原始网格经 Sparse 3D VQ-VAE 编码为稀疏离散索引；
- **文本 token** $F_{txt} \in \mathbb{R}^{N_t \times D}$：任务指令，引导模型生成部件定位标记和结构化 URDF 元数据。

模型输出混合序列，同时满足几何约束和符号结构要求——既生成部件级体素 token（供 VQ-VAE 解码器重建），又生成结构化 JSON 格式的 URDF 规格（关节层级、物理属性）。

2.2 Sparse 3D VQ-VAE

这是 SIMART 的核心技术创新，解决密集体素表征的效率问题。架构采用 3D-UNet 编码器将 64^3 体素网格映射至紧凑潜空间 $Z \in \mathbb{R}^{16\times16\times16\times C}$，再聚合为 $8\times8\times8$ 潜网格（特征维度 64）。关键创新——**稀疏零 token 机制**：

$$\hat{z}_i = \begin{cases} \mathbf{e}_{zero}, & \text{if Voxel } i \text{ is unoccupied} \\ \arg\min_{\mathbf{e}_j \in \mathcal{C}\setminus\{\mathbf{e}_{zero}\}} \|z_i - \mathbf{e}_j\|_2, & \text{otherwise} \end{cases}$$

未占据体素直接赋予专用零 token $\mathbf{e}_{zero}$，仅占据区域参与向量量化。这在典型场景下**减少约 70% token 数量**。码本 $\mathcal{C}$ 包含 4096 个条目，第 0 号索引保留为零 token。

坐标感知 token 化：由于稀疏 token 不再具有固定位置映射，每个占据体素序列化为三元组 $\langle\text{voxel}\rangle[xyz][K]$，其中 $xyz = 64x + 8y + z$（$x, y, z \in [0, 7]$）编码空间位置，$K \in [0, 4095]$ 为码本索引。这使 MLLM 能在变长序列上执行细粒度几何推理。

训练：采用二元交叉熵重建损失 $\mathcal{L}_{rec}$ 与承诺损失：

$$\mathcal{L}_{total} = \mathcal{L}_{rec}(G_{geo}, \hat{G}_{geo}) + \|sg[E(G_{geo})] - \hat{z}\|_2^2 + \beta\|E(G_{geo}) - sg[\hat{z}]\|_2^2$$

在 TRELLIS 数据分布的 50 万物体子集上预训练，权重从 TRELLIS VAE 初始化，两阶段训练每阶段 60K 步。

涌现零 token 现象：即使没有显式零 token 监督，密集 VQ-VAE 训练中也会自然涌现 2–4 个码本条目收敛为空区域表征（如实验中 voxel-1849 被识别为空间代理）。显式保留第 0 号索引使该行为更鲁棒、可解释。

2.3 仿真就绪资产处理

几何重建：MLLM 生成的部件级体素 token 经 VQ-VAE 解码器重建为稀疏点云 S_p。为将离散种子映射到高保真输入网格，采用**基于图的表面分割算法**——以高斯核初始化顶点概率分布：

$$P(v, p) \propto \exp\left(-\frac{d(v, S_p)^2}{2\sigma^2}\right)$$

其中 $d(v, S_p)$ 为到部件 p 最近种子的距离，σ 为相对于网格包围盒的尺度超参。通过迭代图平滑和多数投票确定最终面标签 $\mathcal{M}_{seg}$，保留原始纹理。

运动学规格：SIMART 直接生成结构化 URDF，定义父子层级、关节配置（fixed/revolute/prismatic/free/hinge/rigid）及物理属性（关节限位、材料密度、表面摩擦），配合分割子网格产出可直接导入仿真器的完整资产。

3. 实验设置

数据集：MLLM 指令微调使用 PhysXNet 和 PartNet-Mobility 的 39,600 个 3D 物体（5,600 铰接 + 34,000 静态）。每个铰接模型渲染 20 种运动学状态作为数据增强，合成 URDF 生成和部件定位两个指令跟随数据集，各含 **960K QA 对**。

SIMART-Bench：为解决 PartNet-Mobility 分布同质性问题，整合域内（ID）资产与通过 AIGC（Hunyuan3d-V3.1 等）合成的分布外（OOD）物体，覆盖 10+ 类别、36 个统一资产，配合 P3SAM 自动分割 + 人工精炼 + Web UI 关节标注的 GT 流水线。

实现：VQ-VAE 在 8×A100 上训练；Qwen3-VL-8B 骨干在 32×A100 上微调 30K 步。输入图像 252×252 像素，45 度等距视角。

4. 核心实验结果

4.1 铰接物体与运动学感知

评估指标：关节类型准确率（Type↑）、轴角度误差（Axis↓）、原点 L2 距离（Origin↓）、部件 IoU↑、Chamfer Distance（CD↓）。

方法	Type↑	Axis↓	Orig↓	IoU↑	CD↓
域内（*ID*）物体					
Urdformer	0.496	0.585	0.610	0.002	0.624
Art.-Anything	0.891	0.315	0.174	0.202	0.239
PhysX-Any.	0.686	0.312	0.322	0.128	0.278
Particulate	0.822	0.208	0.204	0.643	0.140
SIMART	**0.928**	**0.080**	**0.111**	**0.690**	**0.087**
AI 生成物体					
Urdformer	0.544	0.557	0.476	0.016	0.650
Art.-Anything	0.765	0.243	0.232	0.069	0.244
PhysX-Any.	0.658	0.481	0.324	0.100	0.334
Particulate	0.817	0.166	0.168	0.618	0.106
SIMART	**0.831**	**0.136**	**0.145**	**0.777**	**0.079**

SIMART 在 ID 和 AI 生成基准上**全部五项指标均达 SOTA**。除 Particulate 外，现有方法无法处理原始网格输入，几何对齐极差（IoU 极低、CD 极高）。SIMART 凭借 MLLM 高级推理能力显著超越依赖独立点分割模块的 Particulate——轴误差从 0.208 降至 0.080（ID），IoU 从 0.618 提升至 0.777（AI 生成）。

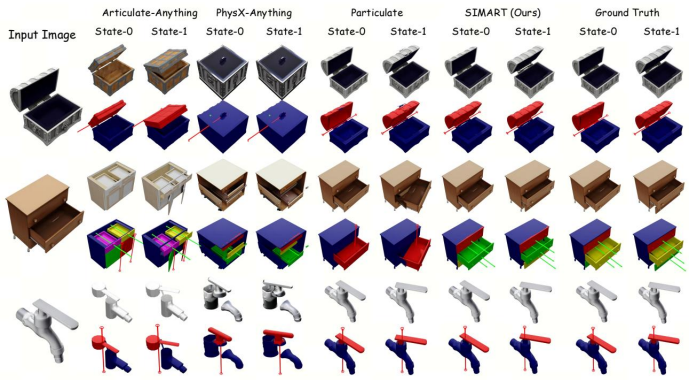

图 *2*：定性对比。每个物体展示两种运动状态。生成式基线常产出简化或错位的网格，*SIMART* 实现精确部件分割和结构一致性。

4.2 3D 部件理解（Part Grounding）

在 AI 生成物体上评估语义-几何定位能力：

方法	IoU↑	CD↓
PhysX-Anything	0.067	0.347
P3SAM + Qwen3-VL-235B	0.507	0.234
SIMART	**0.807**	**0.018**

SIMART 的 IoU（0.807）远超 P3SAM+Qwen3-VL 基线（0.507），表明坐标感知 token 化和 VLM 骨干的世界知识有效地将功能描述链接到物理坐标。

4.3 消融实验

配置	Type↑	Center↓	IoU↑	CD↓	Token↓
Dense token		OOM			4138
Force Sparse	0.661	0.157	0.678	0.100	862
Zero Sparse	0.794	0.108	0.745	0.074	516
+Vision (ours)	**0.937**	**0.074**	**0.832**	**0.055**	516

关键发现：

- **密集 token 直接 OOM**：MLLM 需为每个部件输出完整体素网格，token 总量随部件数线性增长（平均 4138 token），超出 Qwen3-VL 微调显存容量；
- **稀疏化大幅降低 token**：Force Sparse 保留占据坐标 token，从 4138 降至 862（-79%），但性能受限；
- **零 token 机制显著提升**：进一步压缩至 516 token（-40%），同时 Type 准确率从 0.661→0.794，IoU 从 0.678→0.745——专用零 token 避免 MLLM 在无关背景 token 上浪费注意力；
- **视觉特征至关重要**：加入视觉输入后 Type 从 0.794→0.937，IoU 从 0.745→0.832，视觉信息在形态相似但铰接结构不同的物体上解决几何歧义。

VQ-VAE 重建质量消融（MSE/CD $\times 10^5$）：8^3 稀疏配置 MSE=1.84、CD=4.19；扩展至 $16 \times 8 \times 8$ 可降至 1.15/2.27 但 token 长度翻倍；码本从 4096 扩至 8192 无显著改进（CD 从 4.19 仅变为 4.56），验证零 token 机制下 4096 码本已足够；去除零 token（Force Sparse）CD 从 4.19 暴涨至 56.10。

5. 应用场景

物理仿真：SIMART 将原始网格转化为高保真资产并导入 NVIDIA Isaac Sim 进行机器人操作测试。MLLM 内在推理能力估计真实世界尺度，确保虚拟空间物理一致性。优势包括：可扩展训练场景生成、实时动态反馈的交互式学习、多模态观测数据用于 VLA 模型基准测试。

VR/AR：结合 SAM3D 的点击选择界面，用户可将静态虚拟环境转化为具有真实运动学约束的交互组件——从几何生成到铰接数字孪生的端到端流程，丰富混合现实场景的交互逻辑。

6. 与相关工作的对比

vs. 重建方法（ArtGS、ArticulatedGS 等）：这些方法需要多视角、多铰接状态的监督（如柜门开/关图像），在野外难以获取，泛化性差。SIMART 仅需单一静态网格。

vs. 生成方法（CAGE、SINGAPO 等）：受限于铰接 3D 数据集的稀缺性和有限多样性，类别级先验容易过拟合，对罕见类别失效。SIMART 通过 MLLM 的大规模预训练知识获得跨类别泛化。

vs. 2D-MLLM 方法（Articulate-Anything 等）：依赖渲染图像进行运动结构推断，缺乏 3D 几何理解和生成路径，导致物理上不一致的关节估计。SIMART 直接处理 3D 网格。

vs. 3D-MLLM 方法（PhysX-Anything、URDFAnything 等）：受密集体素 token 化的 $O(N^3)$ 复杂度限制，需大量下采样损害几何保真度。SIMART 的稀疏 token 化在保持保真度的同时将 token 减少 70%。

7. 局限性与未来方向

- **数据稀缺**：现有铰接数据集规模和质量不一致，仍是开放世界泛化的主要限制。未来计划利用 SIMART 作为基础工具生成预验证铰接预测，加速数据标注循环；
- **分辨率限制**：64^3 体素化和 8^3 潜网格在极精细几何细节上可能不足，更高分辨率需平衡显存开销；
- **部件数量扩展**：尽管稀疏化大幅缓解，token 数仍随部件数线性增长，极多部件物体可能接近上下文窗口限制；
- **物理属性估计**：材料密度、摩擦等物理参数主要依赖 MLLM 的先验知识，精度受限于训练数据覆盖。

UniGRPO：面向推理驱动视觉生成的统一策略优化

Liu[1,2*], Ye[2*], Yuan[2], Zhu[2], Gao[2], Wu[2‡], Li[2], Wang[2], Nie[2], Huang[2§], Ouyang[1] — [1]CUHK, [2]ByteDance Seed, 2025

1. 动机与核心思想

统一多模态模型正朝着交错生成（interleaved generation）方向发展，主流架构采用**自回归（AR）建模文本 + Flow Matching 生成图像**的组合。为推进这一范式，本文提出面向交错生成的**统一强化学习框架**。

核心观察：交错生成的基本单元是**单轮推理驱动的图像生成**——模型先通过推理扩展用户提示词（Prompt → Thinking），再进行图像合成（→ Image）。本文将该多模态生成过程建模为具有**稀疏终端奖励**的马尔可夫决策过程（MDP），提出 **UniGRPO**，通过 GRPO 联合优化文本与图像生成策略。

设计哲学：采用极简主义方法论（minimalist methodology），无缝整合两种模态各自成熟的训练方案——标准 GRPO 用于推理文本，FlowGRPO 用于视觉合成——避免过度设计。同时引入两项关键改进以确保向多轮交错生成的可扩展性。

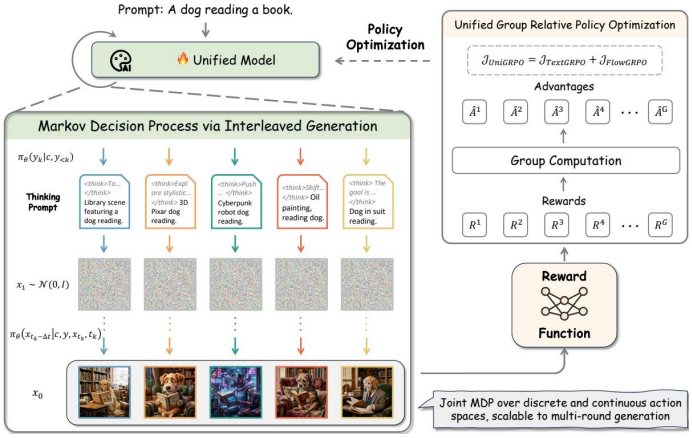

图 1：*UniGRPO* 概览。将交错生成建模为联合 *MDP*，离散语言动作 y_k（*next-token prediction*）与连续视觉动作 $x_{t_k-\Delta t}$（*flow matching*）共享组相对优势信号。

2. 理论基础

2.1 Text GRPO

对自回归文本组件，给定提示 c，策略 π_θ 生成一组 G 个输出 $\{y_i\}_{i=1}^G$。组内相对优势：

$$\hat{A}_i = \frac{R_i - \text{mean}(\{R_j\}_{j=1}^G)}{\text{std}(\{R_j\}_{j=1}^G)}$$

目标函数采用重要性采样裁剪：

$$\mathcal{I}_{\text{Text}}(\theta) = \frac{1}{G}\sum_{i=1}^{G}\frac{1}{|y_i|}\sum_{k=1}^{|y_i|}\left(\min\left(r_{i,k}\hat{A}_i,\ \text{clip}(r_{i,k}, 1-\epsilon, 1+\epsilon)\hat{A}_i\right) - \beta_{\text{txt}} D_{\text{KL}}\right)$$

其中 $r_{i,k} = \pi_\theta(y_{i,k}|y_{i,<k})/\pi_{\theta_{\text{old}}}(y_{i,k}|y_{i,<k})$。

2.2 Flow GRPO

FlowGRPO 将 Flow Matching 的确定性 ODE 转换为 SDE 以引入探索所需的随机性：

$$\Delta x_{t_k} = \left[v_\theta(x_{t_k}, t_k) + \frac{\sigma_{t_k}^2}{2t_k}\left(x_{t_k} + (1-t_k)v_\theta(x_{t_k}, t_k)\right)\right]\Delta t + \sigma_{t_k}\sqrt{\Delta t}\,\epsilon$$

采用 FlowGRPO-Fast 变体：SDE 时间窗口内带梯度跟踪，其余步骤用 ODE 采样。

RatioNorm 机制：标准重要性比裁剪在扩散模型中失效——比率分布系统性左偏（均值 < 1）且跨时间步方差不一致。GRPO-Guard 提出的 RatioNorm 对对数重要性比进行标准化：

$$\log \tilde{r}_{t_k}(\theta) = \sigma_{t_k}\sqrt{\Delta t}\left(\log r_{t_k}(\theta) + \frac{\|\Delta\mu_\theta(x_{t_k}, t_k)\|^2}{2\sigma_{t_k}^2\Delta t}\right)$$

恢复裁剪边界的有效性。最终 Flow 目标仅在 SDE 时间步子集 $\mathcal{T}_{\text{SDE}}$ 上计算。

3. UniGRPO 方法

3.1 多模态生成作为 MDP

将交错生成建模为序贯 MDP $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R})$：

- **状态空间**：文本阶段 $s_k^{\text{txt}} = (c, y_{<k})$；图像阶段 $s_k^{\text{img}} = (c, y, x_{t_k}, t_k)$；
- **动作空间**：文本阶段 $a_k^{\text{txt}} \in \mathcal{V}$（词表中的单个 token）；图像阶段 $a_k^{\text{img}} = x_{t_k-\Delta t} \in \mathbb{R}^d$（下一流步的 latent）；
- **转移**：确定性——文本追加 token，图像推进 latent；
- **奖励**：仅在图像完全去噪后给出稀疏终端奖励 $R(x_0, c)$。

3.2 联合优化目标

对给定提示 c，先采样 G 条推理链 $\{y_i\}$，每条再生成图像轨迹 $\{x_i\}$，基于终端奖励计算组相对优势 $\hat{A}_i$，更新统一目标：

$$\mathcal{I} = \mathcal{I}_{\text{Text}} + \lambda\mathcal{I}_{\text{Flow}}$$

所有实验中 $\lambda = 1$，平等权衡推理与合成任务。

3.3 关键改进一：去除 CFG

标准 Flow Matching 推理依赖 Classifier-Free Guidance（CFG），每步需两次模型评估（条件/无条件）。在多条件生成（如图像编辑）中至少需三次评估，多轮交错生成中开销进一步倍增。更重要的是，CFG 创建分支计算图，严重复杂化梯度估计。

UniGRPO **完全去除 CFG**，强制线性无分支 rollout。虽然去除 CFG 通常降低提示遵循度，但 RL 训练通过**显式最大化期望奖励**（评估文图对齐和视觉质量）将对齐能力内化到策略权重中，补偿了 CFG 的缺失。

3.4 关键改进二：基于速度场的正则化

在 SDE 公式下，逐步转移概率为高斯分布，精确局部 KL 散度等价于预测速度的平方差，带有逆噪声方差 $1/\sigma_{t_k}^2$ 的加权。然而此加权导致不均匀惩罚——高噪声方差时间步 KL 惩罚过小，形成 RL 优化器可利用的时间漏洞。

本文去除时间步依赖加权，直接对**无加权速度场**施加 MSE 惩罚：

$$\mathcal{L}_{\text{MSE}}(\theta) = \|v_\theta(x_{t_k}, t_k, y) - v_{\text{ref}}(x_{t_k}, t_k, y)\|^2$$

该均匀正则化迫使 RL 微调的向量场在所有噪声水平上均贴近预训练参考模型，显著减少策略利用漏洞，有效缓解 reward hacking。

4. 实验设置

预训练模型：采用 Bagel 作为骨干——一种具有交错生成潜力的统一多模态架构。原始 Bagel 指令遵循能力有限，先在内部策展数据集上进行 SFT 显著提升基线性能。

奖励模型：使用 RewardDance 中基于 InternVL 微调的可微奖励模型，评估生成图像与用户提示的一致性。值得注意的是 UniGRPO 兼容更广泛的非可微验证器奖励，而 ReFL 等基线受限于可微目标。

基线方法：ReFL（直接反传奖励梯度）、ReFL w/ Thinking（带推理的 ReFL）、ReFL$^+$TextGRPO（两阶段方案）、FPO/AWR（使用前向过程获取 x_t 并以 ELBO 近似 $\log p_\theta(x_0|c)$）、UniFPO（FPO 的统一框架版本）。

评估指标：(1) **TA Benchmark**（内部 150 条提示，每条生成 4 张图，VLM 多考点二值评分）；(2) **GenEval**（标准组合生成基准，含物体计数、空间关系、属性绑定等）。

5. 核心实验结果

方法	Think	TA	GenEval
Bagel	×	0.6810	0.78
Bagel	✓	0.7132	0.79
SFT	×	0.7486	0.83
SFT	✓	0.7769	0.82
ReFL	✓	0.8120	0.84
FPO	✓	0.8159	0.85
FlowGRPO	✓	0.8208	0.86
TextGRPO	✓	0.8078	0.88
ReFL+TextGRPO	✓	0.7987	0.87
UniFPO	✓	训练崩溃	
UniGRPO	✓	**0.8381**	**0.90**

关键发现：(1) UniGRPO 在 TA (0.8381) 和 GenEval (0.90) 上均达到 SOTA；(2) UniFPO 训练崩溃，凸显 GRPO 公式的稳定性优势；(3) 联合优化推理 + 合成策略优于单独优化任一组件（FlowGRPO 0.8208 / TextGRPO 0.8078 → UniGRPO 0.8381）；(4) 原始 Bagel 的推理模块并不一致提升 GenEval，但 UniGRPO 成功利用推理链达到最优。

GenEval 细分：UniGRPO 在 Single Obj. 0.99、Two Obj. 0.99、Counting 0.91、Colors 0.91、Position 0.73、Attr. Binding 0.86，各子类均表现均衡。特别是 Position（0.73）相比 FlowGRPO（0.60）提升显著，表明推理链有效改善空间关系理解。

定性分析：原始 Bagel 生成过饱和且有合成伪影；SFT 缓解伪影但牺牲清晰度（模糊）；UniGRPO 显著提升美学质量和文图对齐，生成逼真、细节丰富的图像。推理层面，基线模型虽生成详细推理文本但可能失焦，UniGRPO 优化推理过程使其高度目的化和任务导向——思维链紧密耦合并有效引导后续图像合成。

6. 消融实验

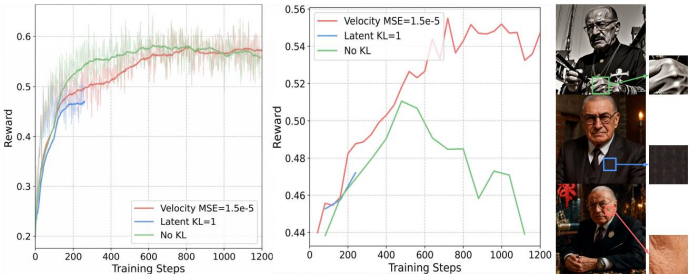

图 2：正则化策略消融。无正则化导致 *reward hacking*（验证奖励先升后降，图像过饱和）；*Latent KL* 即使使用大系数仍出现网格伪影；速度场 *MSE* 确保稳定训练与高保真生成。

6.1 CFG-Free 训练的影响

对比有/无 CFG 的 UniGRPO 训练：虽然训练时使用 CFG 产生更高奖励，但去除 CFG 后在**评估时**（均使用 CFG）性能相当甚至更优。这证实 CFG 对 RL 对齐训练并非必要，可安全去除昂贵的分支 rollout。

6.2 正则化策略比较

三种策略对比（图 2）：(1) **无 KL**——验证奖励初始上升后下降，生成不自然的过饱和纹理，典型 reward hacking；(2) **Latent KL**（标准做法）——训练奖励显著下降表明 KL 系数足够大，但仅 250 步即出现网格状伪影，提前终止；(3) **Velocity MSE**（本文方法）——训练动态稳定，生成高保真逼真纹理图像。速度场 MSE 的优势在于**均匀约束**所有时间步，不存在 Latent KL 因 $1/\sigma_{t_k}^2$ 加权导致的低惩罚漏洞。

7. 与相关工作的对比

与并发工作的区别：R3 采用生成-理解-再生成循环但仅在特定基准验证；DualGRPO 联合优化**分离的** LLM 和扩散模型（树结构 rollout，与真正交错生成不兼容）；PromptRL 训练不相交的语言/流模型且数据有限；SepGRPO 交替训练 MLLM 和 DiT 模块但**非端到端联合优化**。UniGRPO 在**单一统一模型**上以通用提示、1024 分辨率训练，算法设计基于改进的 FlowGRPO 确保可扩展性。

8. 超参数配置

训练时间步 25，评估时间步 50，CFG Scale 1（即无 CFG），图像分辨率 1024。组大小 $G = 24$，批大小 32，推理专家学习率 1×10^{-6}，去噪专家学习率 3×10^{-5}，PPO epoch 2。TextGRPO KL 权重 0，FlowGRPO MSE 权重 1.5×10^{-5}，SDE 窗口 $[0, 5]$（窗口大小 3），噪声水平 0.8。

9. 局限性与未来方向

扩展至多轮交错生成：当前验证于单轮生成（Prompt→Reasoning→Image），统一 MDP 公式天然扩展至多轮交互（交互式编辑、视觉叙事、多轮对话）。CFG-free 线性 rollout 策略在长程上下文一致性维护中预期具有显著计算优势和训练稳定性。

多模态过程奖励建模：当前依赖稀疏终端奖励（仅评估最终图像），可能导致低效的信用分配——模型可能在推理有缺陷的情况下仍生成高质量图像。引入**多模态过程奖励模型**（PRM）对中间推理步骤提供密集反馈，验证“思考”的逻辑性和与视觉意图的对齐，是提高样本效率和可解释性的关键方向。

其他局限：(1) 目前需要可微奖励模型以公平对比基线，虽然框架本身兼容黑盒验证器；(2) 开源基础模型尚不支持完整交错生成，当前验证限于基本单元；(3) 训练计算开销较大（组大小 24，1024 分辨率）。

RealMaster：将渲染场景提升为真实感视频

Cohen-Bar[1,2], Sobol[2,3], Bensadoun[2], Sheynin[2], Gafni[2], Patashnik[1], Cohen-Or[1], Zohar[2] — [1]Tel Aviv Univ., [2]Meta Reality Labs, [3]Technion, 2025

1. 问题动机与背景

当前视频生成模型（如 Stable Video Diffusion、MovieGen、Wan 等）能够合成高度逼真的视频，但缺乏对场景元素的精确控制，且无法保证 3D 一致性。相反，3D 渲染引擎提供精细的场景控制和天然的几何一致性，但其输出往往停留在“恐怖谷”——缺乏真实世界高频细节。

Sim-to-Real 翻译旨在弥合这一鸿沟，但面临两个看似矛盾的目标：

- **结构精度**：输出必须精确保留输入的几何、运动和动态细节；
- **全局语义变换**：材质、光照和纹理必须整体变换以达到真实感。

现有视频编辑方法在此任务上面临根本性困境：要么未识别输入的合成本质而几乎不做修改，要么修改过多而破坏场景结构和角色身份。这源于 sim-to-real 与标准视频编辑的本质区别——输入已接近真实感，细节不能像风格迁移那样被抽象化，模型必须在保留精细细节的同时添加真实世界的高频纹理。

RealMaster 提出了一种新范式：**将视频扩散模型作为 3D 引擎之上的学习型第二阶段渲染器**，结合传统图形学的控制力与生成模型的真实感。

2. 方法概览

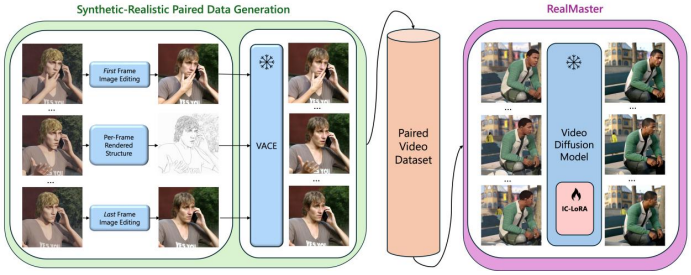

图 1：*RealMaster* 两阶段方法概览。阶段 1：基于锚点帧的稀疏到稠密数据生成；阶段 2：*IC-LoRA* 模型训练与推理。

如图 1 所示，RealMaster 采用两阶段方法：（1）构建高质量配对训练数据的**数据生成管线**；（2）训练 **IC-LoRA** 适配器将管线行为蒸馏为具有更强泛化能力的模型。

2.1 数据生成管线：稀疏到稠密传播

Sim-to-real 视频翻译的核心挑战是缺乏配对数据。由于图像级 sim-to-real 翻译比视频级更成熟可靠，本文采用**稀疏到稠密策略**：

关键帧增强。给定渲染视频序列，使用现成图像编辑模型 Qwen-Image-Edit 将**首帧和尾帧**翻译为真实感域，作为定义目标外观的“外观锚点”。编辑提示为“make it look photo-realistic”。

基于边缘的关键帧传播。利用 VACE（一种条件视频生成模型）将锚点帧的外观传播到中间帧。具体而言，从输入视频提取**边缘图**作为结构条件信号，VACE 在真实感锚点帧和边缘图的联合条件下生成完整视频。边缘条件将生成锚定到输入的结构和运动上，使 VACE 在保留场景布局和动态的同时传播锚点外观。

身份一致性过滤。使用 ArcFace 余弦相似度过滤生成的配对数据：仅保留源视频与编辑视频中检测到的人脸平均余弦相似度 ≥ 0.4 的片段。从初始 3,050 个片段中保留 1,216 个训练片段（约去除 60%）。

2.2 模型训练：IC-LoRA 蒸馏

在预训练文本到视频扩散模型 **Wan2.2 T2V-A14B** 之上训练轻量级 LoRA 适配器（rank = 32）。采用 **IC-LoRA**（In-Context LoRA）架构：训练时将渲染输入视频编码为**干净参考 token**（时间步固定为 $t = 0$），与待去噪的含噪 token 共享位置编码，优化模型向对应的真实感目标去噪。

训练极为轻量：仅需 1,216 个配对片段，在**单张 H200 GPU** 上训练 1,200 步（约数小时），使用 AdamW 优化器，学习率 1×10^{-4}，batch size 8，分辨率 800×1200，每片段 81 帧。

2.3 推理时优势

训练后的模型克服了数据生成管线的多项限制：

- **无需锚点帧**：管线需要序列首尾帧，不适合流式/自回归生成；训练模型可直接推理；
- **处理中途出现的物体**：管线依赖两个边界锚点定义外观，对序列中途出现的物体/角色缺乏监督；模型通过学到的先验泛化处理；
- **避免过度编辑**：图像编辑模型有时会过度修改锚点帧；模型学会利用基础模型的先验“折扣”合成数据中的瑕疵。

3. 实验设置

数据集。使用 SAIL-VOS 数据集（基于 GTA-V 虚拟环境），验证集取 100 个片段。GTA-V 提供复杂光照转换、高速运动、精细几何细节和多角色交互等挑战性场景。视频从 8 fps 上采样至 16 fps（逐帧重复），分辨率 800×1200，81 帧/片段。

基线方法。与三种强视频编辑方法比较：

- **Runway-Aleph**：商业视频编辑系统；
- **LucyEdit**：开源文本引导视频编辑；
- **Editto**：专门使用合成-真实配对数据训练的 sim-to-real 方法。

评估指标。涵盖四个维度：

- **身份一致性**：输入与编辑视频间的平均 ArcFace 余弦相似度（每视频均匀采样 5 帧）；
- **结构保持**：输入与编辑视频所有帧的 DINO 特征 ℓ_2 距离（越低越好）；
- **真实感**：GPT-4o 评分（1–10），分为 GPT-RS$_{\text{no-ref}}$（仅编辑帧）和 GPT-RS$_{\text{with-ref}}$（附带原始帧参考）两种设置；
- **时间一致性**：VBench 的 Temporal Flickering（帧间视觉稳定性）和 Motion Smoothness（运动连贯性）。

4. 定量结果

方法	GPT$_{\text{nr}}$↑	GPT$_{\text{ref}}$↑	ArcF↑	DINO↓	T.F.↑	M.S.↑
Editto	5.10	3.84	0.204	41.79	0.972	0.972
Runway	4.98	5.33	0.300	38.04	0.976	0.972
LucyEdit	3.48	4.20	0.375	36.68	0.976	**0.986**
Ours	**5.30**	**7.33**	**0.473**	**30.28**	**0.976**	0.973

RealMaster 在大多数指标上显著领先：

- **真实感**：GPT-RS$_{\text{no-ref}}$ 达 5.30（最佳），GPT-RS$_{\text{with-ref}}$ 达 **7.33**，大幅领先第二名 Runway-Aleph 的 5.33（+37.5%）；
- **身份保持**：ArcFace 达 **0.473**，远超 Editto（0.204）和 Runway（0.300）；
- **结构保持**：DINO 距离仅 **30.28**，比最优基线 LucyEdit（36.68）低 17.4%；
- **时间一致性**：Temporal Flickering 并列最佳（0.976），Motion Smoothness 具竞争力（0.973 vs LucyEdit 的 0.986，但后者通过模糊视频提升该指标，牺牲了结构精度）。

5. 定性比较与用户研究

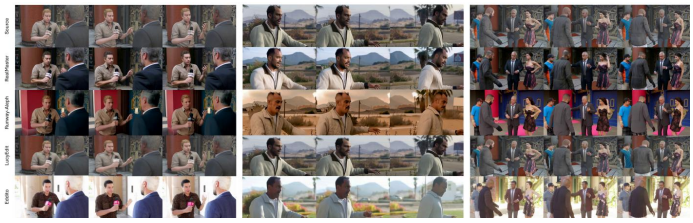

图 2：与基线方法的定性比较。基线要么改变场景内容（身份漂移、颜色偏移），要么真实感不足。

如图 2 所示：Runway-Aleph 能提升真实感但改变物体颜色且不保持角色身份；LucyEdit 使输出更偏“游戏风格”并改变大量原始场景细节；Editto 虽专门训练但显著偏离原始场

景内容。RealMaster 在保持结构和身份的同时大幅提升真实感。

用户研究。45 名参与者完成 675 次成对比较，在真实感、忠实度和整体视觉质量三个维度上评估。RealMaster 的偏好率：

对比	真实感	忠实度	整体
vs. Editto	63%	94%	78%
vs. LucyEdit	93%	85%	93%
vs. Runway-Aleph	64%	88%	70%
总体	**73%**	**89%**	**80%**

在忠实度上优势尤为突出（89%），验证了 RealMaster 在保持输入结构方面的显著优势。

6. 消融实验

对数据生成管线的三种传播策略进行消融比较，并与训练后模型对比：

变体	ArcF↑	DINO↓	T.F.↑	M.S.↑
多锚点	0.357	33.98	0.950	0.969
深度条件	0.334	34.27	0.952	0.954
边缘条件	0.468	32.29	0.954	0.954
RealMaster	**0.473**	**30.28**	**0.976**	**0.973**

- **多锚点**（每 0.5 秒一个锚点帧）：独立图像编辑的不一致性在插值中被放大，导致闪烁（T.F. 仅 0.950）；
- **深度条件**：提供粗略几何引导但丢失高频线索，面部表情和身份保持最差（ArcFace 0.334）；
- **边缘条件**（本文默认）：更可靠地保留物体边界和面部细节，管线中最优；
- **训练后模型 vs 管线**：在边缘管线基础上进一步提升所有指标，尤其时间一致性提升显著（T.F. 0.954 → 0.976, M.S. 0.954 → 0.973）。模型能泛化到管线失败的场景（如中途出现的物体），并避免图像编辑模型的过度修改。

7. 额外应用

动态天气效果。视频扩散模型内含丰富的自然现象先验。仅通过修改推理时的文本提示，RealMaster 即可在渲染场景中引入雨雪等动态天气效果（如湿润表面反射、雨滴、积雪），这些效果在传统渲染器中需要粒子系统、着色器修改和环境光照调整等大量工程投入。

跨模拟器泛化。尽管模型仅在 SAIL-VOS（GTA-V 引擎）上训练，但可直接泛化到 CARLA 驾驶模拟器的场景——后者使用不同渲染引擎、自我中心视角且聚焦车辆而非行人。这表明模型学到的是从渲染到真实外观的**通用映射**，而非过拟合于特定训练域的视觉特征。

8. 讨论与局限

RealMaster 将 sim-to-real 翻译重新定义为**结构忠实度与全局真实感变换的平衡问题**，核心洞见是将生成视频模型视为 3D 引擎之上的 “学习型第二阶段渲染器”，分离结构控制与视觉实现。

关键贡献：（1）基于锚点的稀疏到稠密传播策略高效生成配对训练数据；（2）IC-LoRA 蒸馏使模型超越管线限制；（3）在 GTA-V 复杂场景上显著超越所有基线。

主要局限：

- 输出真实感受限于图像编辑模型（Qwen-Image-Edit）的能力——小尺寸远距物体编辑效果保守；
- 方法保留但不改进输入的运动——若模拟器动画本身不自然（如僵硬的人体运动），输出仍会继承这些缺陷；
- 快速摄像机/角色运动导致时间伪影，继承自基础视频扩散模型对大帧间位移的处理局限。

未来方向：（1）实时流式变体，实现低延迟因果 sim-to-real 翻译以支持交互式应用；（2）引入人体动态和姿态的学习先验来纠正僵硬或合成运动，进一步缩小模拟与真实视频之间的差距。

2Xplat：两个专家胜过一个通才——无位姿前馈 3DGS 的模块化框架

Jeong[1⋆], Lee[2⋆], Kang[2], Yang[1], Sun[2], Nam[1], Park[1†] — [1]Yonsei Univ., [2]Sungkyunkwan Univ., 2026

1. 动机与问题定义

3D Gaussian Splatting (3DGS) 已成为实时高质量新视角合成的主流表示，广泛应用于 AR/XR、远程呈现、机器人和自动驾驶等领域。然而传统 3DGS 依赖耗时的逐场景迭代优化（数十分钟至数小时），前馈方法虽可在单次前向传播中直接预测高斯参数（数秒完成），但大多假设已知精确相机位姿。SfM/SLAM 位姿估计本身耗时且可能失败，严重削弱前馈方法的效率优势。

无位姿前馈 3DGS 旨在从未标定多视角图像直接重建高斯表示。当前主流方法采用**单体式（monolithic）架构**——单一网络通过共享特征同时预测相机位姿和 3DGS 参数。本文从三个角度论证其局限性：

- **目标冲突**：高质量外观合成不必严格遵守精确几何——强几何约束可能限制半透明、高频结构、视角依赖着色等复杂效果的建模；而统一模型需同时优化几何精度与视觉保真度，两者存在内在矛盾；
- **无法利用位姿条件化架构**：SOTA 有位姿前馈方法（Epipolar Transformer、PRoPE、GTA、CaPE、RayRoPE）通过将视觉特征与相机位姿对齐获得显著增益。单体架构只能依赖隐式估计的几何知识，无法干净地接入这些先进机制；
- **容量不足**：生成高保真 3DGS 属性需要大量表征容量和复杂空间推理（多视角一致性、精细结构、视角依赖外观），远非几何骨干网络的轻量扩展所能胜任。

2. 核心思想：双专家架构

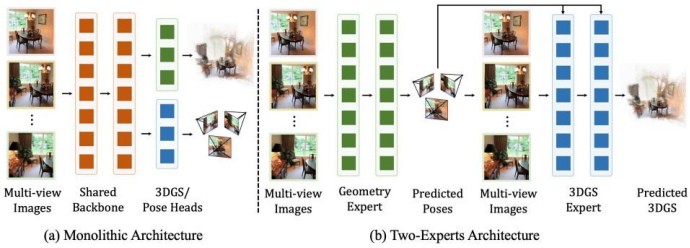

图 1：*(a)* 单体架构：共享骨干 + 任务特定头联合预测位姿与 *3DGS*。*(b)* 双专家架构：几何专家先估计位姿，外观专家再基于预测位姿生成 *3D* 高斯。

2Xplat 将无位姿前馈 3DGS 显式**解耦**为两个顺序模块：

几何专家 F_{pose}：从多视角图像估计所有视角的相机参数（内参 K_i 与外参 R_i, t_i）。采用 **Depth Anything 3 (DA3)** 作为默认骨干——DA3 通过深度/点图/射线图/位姿多任务联合训练达到 SOTA 位姿精度。

外观专家 F_{3dgs}：基于上下文图像及预测位姿生成像素对齐的 3D 高斯表示。采用 **Multi-view Pyramid Transformer (MVP)**——当前有位姿前馈 3DGS 的 SOTA，集成 PRoPE 位姿条件化、register tokens、交替注意力和双层次金字塔架构，从零训练即可达到高保真重建。

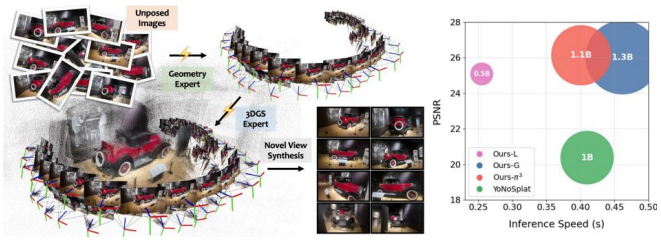

图 2：*DL3DV* 场景示例（左）与 *PSNR vs.* 推理速度对比（右，224×224，*12* 视角）。

关键优势：(1) 外观专家可直接利用 PRoPE 等先进位姿条件化机制；(2) 不引入任何随机初始化模块，两个预训练专家直接端到端微调，**<5K 迭代即可收敛**（对比 YoNoSplat 需 16 台 GH200 + 150K 迭代）；(3) 位姿已知时可直接绕过几何专家，自然兼容有位姿/无位姿两种场景。

3. 方法细节

3.1 问题形式化

给定 N 张未标定图像 $\{I_i \in \mathbb{R}^{H\times W\times 3}\}_{i=1}^{N}$（$N = N_c + N_t$，上下文视角 + 目标视角），模型输出像素对齐 3D 高斯 $\{G_j \in \mathbb{R}^{H\times W\times d_g}\}_{j=1}^{N_c}$ 和相机参数 $\{\hat{p}_i = [K_i, R_i, t_i]\}_{i=1}^{N}$。

3.2 联合训练

几何专家首先预测所有视角的相机参数：$\{\hat{p}_i\}_{i=1}^{N} = F_{\text{pose}}(\{I_i\}_{i=1}^{N})$。外观专家基于上下文图像和预测位姿生成高斯：$\{G_i\}_{i=1}^{N_c} = F_{\text{3dgs}}(\{I_i\}_{i=1}^{N_c}, \{\hat{p}_i\}_{i=1}^{N_c})$。通过可微 3DGS 渲染器渲染目标视角，总损失为：

$$\mathcal{L} = \frac{1}{N_t}\sum_{i=1}^{N_t}\mathcal{L}_{\text{render}}(\hat{I}_i, I_{N_c+i}) + \frac{1}{N}\sum_{j=1}^{N}\mathcal{L}_{\text{cam}}(\hat{p}_j, p_j)$$

渲染损失采用 MSE + 感知损失：$\mathcal{L}_{\text{render}} = \mathcal{L}_{MSE} + \lambda_{perc}\mathcal{L}_{perc}$，其中 $\lambda_{perc} = 0.5$。

位姿损失采用相对位姿形式以消除全局参考系歧义。相对位姿 $\hat{T}_{i\leftarrow j} = \hat{T}_i^{-1}\hat{T}_j$ 包含旋转和平移分量，旋转损失为角度误差 $\mathcal{L}_R(i,j) = \arccos\left(\frac{\text{tr}(R_{i\leftarrow j}^{\top}\hat{R}_{i\leftarrow j})-1}{2}\right)$，平移损失为 Huber 损失 $\mathcal{L}_t(i,j) = H_\delta(\hat{t}_{i\leftarrow j} - t_{i\leftarrow j})$，加上内参 ℓ_2 损失 $\mathcal{L}_K$。权重 $\lambda_R = 0.1$，$\lambda_t = 10$，$\lambda_K = 0.5$。

3.3 训练效率分析

双专家分解以相机位姿为中间接口。单体架构虽用预训练权重初始化骨干，但附加的随机初始化层和预测头无法直接受益于大规模预训练，在小数据集微调时易过拟合。2Xplat 直接复用两个成熟预训练专家，无新增随机初始化模块，通过轻量端到端微调即可收敛。实际训练仅需 8 台 H200 GPU 运行 2K–5K 迭代，使用 AdamW 优化器（lr $= 2\times10^{-5}$，$\beta_1 = 0.9$, $\beta_2 = 0.99$, weight decay 0.05）。

4. 核心实验结果

4.1 DL3DV 低分辨率新视角合成

在 224×224 分辨率、6/12/24 输入视角下评估。2Xplat **无位姿无内参**模型显著超越所有基线，**包括使用真值位姿和内参的方法**：

方法（6v）	PSNR↑	SSIM↑	LPIPS↓
MVSplat（有位姿）	22.66	0.760	0.173
DepthSplat（有位姿）	23.42	0.797	0.136
YoNoSplat（有位姿）	24.72	0.817	0.139
Ours（有位姿）	**26.63**	**0.856**	**0.121**
AnySplat（无位姿）	19.03	0.554	0.235
YoNoSplat（无位姿）	24.53	0.804	0.142
Ours（无位姿）	**26.01**	**0.839**	**0.126**
Ours†（无位姿 +EPA）	**26.67**	**0.855**	**0.122**

关键发现：(1) 2Xplat 无位姿模型（26.01 dB）已超越所有有位姿基线（最高 24.72 dB）；(2) 随输入视角增加（6→24），2Xplat 性能持续提升（26.01→25.89 dB），而竞争方法显著下降（YoNoSplat: 24.53→22.17 dB），体现了多视角信息利用能力；(3) 无需 EPA 即已超越依赖 EPA 的基线。

4.2 高分辨率评估

960×540 分辨率、16–128 视角下，2Xplat 是唯一无位姿方法，但取得与有位姿 SOTA 竞争性结果：128 视角时 Ours† 达 28.30 dB（vs. MVP 有位姿 29.02 dB，3DGS-30K 优化 29.43 dB）。

4.3 RE10K 室内场景

6 视角无位姿设置下，Ours† 达 27.24 dB，大幅超越 YoNoSplat†（24.57 dB）和有位姿 DepthSplat（24.16 dB），在室内外场景均表现优异。

4.4 位姿估计

尽管仅在 RE10K 上微调 2K 迭代，位姿估计 AUC@5°/10°/20° 分别达 0.718/0.843/0.912，与专门进行大规模位姿训练的 YoNoSplat（0.722/0.852/0.923）相当，表明双专家流水线可有效解决全局参考系歧义。

4.5 跨数据集泛化

DL3DV 训练模型**零样本**迁移至 ScanNet++：128 视角时 Ours† 达 22.30 dB / LPIPS 0.240（vs. YoNoSplat† w/ GT k: 19.28 dB / 0.325），泛化能力显著更强。在 Tanks&Temples 和 Mip-NeRF360 上也取得与有位姿方法竞争性结果。

5. 消融实验

5.1 骨干网络选择

测试 π^3、DA3-L、DA3-G 三种几何骨干：

方法	参数量	速度	PSNR↑	LPIPS↓
YoNoSplat (π^3)	1B	0.33s	19.72	0.229
Ours-L (DA3-L)	0.5B	0.15s	25.76	0.135
Ours-G (DA3-G)	1.3B	0.31s	26.16	0.132
Ours-π^3	1.1B	0.27s	26.02	0.138

所有骨干均大幅超越 YoNoSplat，且 DA3-L（0.5B 参数）即达 25.76 dB，说明性能增益主要来自**双专家架构设计**而非模型规模。

5.2 位姿监督方式

比较相对损失、绝对损失和无位姿损失：相对损失在渲染质量（26.16 dB）和位姿精度（AUC@5°: 0.718）之间取得最佳平衡。无位姿损失渲染略优（26.37 dB）但位姿精度显著下降（AUC@5°: 0.686）。

6. 与现有方法的关系

“几何先行、外观后续”范式在先前工作（FlowCam、SelfSplat、Rayzer、E-Rayzer）中已有探索，但主要聚焦自监督学习策略和几何估计，对高容量外观模型和位姿条件化架构的利用不足。2Xplat 从不同视角重新审视：**将强几何估计器与强位姿条件化 3DGS 生成器显式组合**，通过端到端微调使外观专家对位姿噪声具有鲁棒性。

部分近期方法（PoW3R、DA3、YoNoSplat）支持可选输入位姿，但这种统一设计要求网络隐式切换有/无位姿两种运行模式，学习此切换机制非易事。2Xplat 的模块化设计自然兼容两种场景——有位姿时直接绕过几何专家。

7. 局限性与未来方向

- **位姿精度**：位姿监督仅作为正则化信号，位姿估计精度略低于专门位姿方法，但渲染质量大幅领先；
- **冗余计算**：两个专家可能共享某些低级视觉推理，实验表明此冗余不损害效率反而有益，但更有原则的特征共享机制值得探索；
- **几何质量**：当前聚焦渲染质量，几何重建精度（如深度、法线）的提升为未来方向；
- **扩展性**：更大规模场景和更多视角的高效处理有待进一步研究。

8. 总结

2Xplat 以概念上极其简洁的双专家设计——几何专家估计位姿、外观专家生成高斯——挑战了无位姿 3DGS 领域的统一架构范式。在 <5K 迭代内，该方法大幅超越所有无位姿方法，并达到与有位姿 SOTA 相当的水平。核心启示：**模块化设计原则**在复杂 3D 几何估计与外观合成任务中具有显著优势，将几何推理与外观建模解耦比在共享表示中纠缠两者更为有效。