QZPaper Huggingface Daily

2026-03-30

---

1. **Out of Sight but Not Out of Mind：面向动态视频世界模型的混合记忆**
   该论文解决视频世界模型中动态主体离开视野后丢失或畸变的问题，提出混合记忆范式以同时保存静态背景和动态主体轨迹，并构建了首个包含大规模出入画面事件的高保真视频数据集 HM-World。
2. **ShotStream：面向交互式叙事的流式多镜头视频生成**
   该论文提出因果式多镜头生成架构，将多镜头合成重新定义为自回归 next-shot 任务，支持运行时动态调整内容和风格，在单张 GPU 上实现 16FPS 的交互式长叙事视频生成。
3. **PackForcing：短视频训练即可实现长视频采样与长上下文推理**
   该论文提出三分区 KV 缓存设计，通过永久保留语义锚点、动态压缩历史记忆和保留最近上下文，解决自回归视频生成中误差累积和内存爆炸问题，使短视频训练即可生成长视频。
4. **MedOpenClaw：面向未整理完整影像研究的可审计医学影像智能体推理**
   该论文提出 MedOpenClaw 运行时和 MedFlow-Bench 基准，使医学 VLM 智能体能在标准医学查看器中交互操作完整影像研究，产生透明且可审计的诊断推理轨迹和证据。
5. **RealChart2Code：基于真实数据与多任务评估的图表转代码生成**
   该论文提出 RealChart2Code 基准，包含 2896 个基于真实 Kaggle 数据的复杂图表实例，设计图表复制、再现和修正三个任务，全面评估模型的可视化生成、语义理解和迭代修改能力。
6. **KITScenes LongTail：面向长尾驾驶场景的推理轨迹数据集**
   该论文引入 KITScenes LongTail 数据集，提供长尾驾驶场景的多视角视频、高层指令和多语言专家推理轨迹，并提出语义一致性度量和多操作评分来评估端到端驾驶中的推理和决策能力。
7. **Natural-Language Agent Harnesses：自然语言智能体控制框架**
   该论文提出将智能体控制框架外部化为可移植、可执行的自然语言制品，通过智能运行时解释执行，实现跨系统的框架复用，提高控制逻辑的可比较性和可消融性。
8. **Know3D：利用视觉-语言模型知识引导 3D 生成**
   该论文提出 Know3D 框架，利用视觉-语言模型的语义知识通过多模态扩散模型作为中间桥梁，指导 3D 生成模型合理推断不可见区域结构，实现语义可控的单视图 3D 重建。
9. **Sommelier：面向全双工语音语言模型的可扩展开源多轮音频预处理流水线**
   该论文提出 Sommelier 流水线，用于全双工语音语言模型的数据预处理，通过保留重叠语音、反馈语和打断等对话特性，支持高吞吐的 Web 规模音频处理，为全双工 SLM 训练提供关键数据基础。

Out of Sight but Not Out of Mind：面向动态视频世界模型的混合记忆

Chen, Liang, Zhou, Ding, Liu, Wan, Bai — 华中科技大学 & 快手科技, 2025

1. 问题动机与背景

视频世界模型（Video World Models）在模拟物理世界方面展现出巨大潜力，广泛应用于自动驾驶和具身智能等领域。**记忆机制**是决定生成内容时空一致性的关键——它使模型在视角切换或长时外推时保持历史上下文。然而，现有记忆方法（Vmem、Context-as-Memory、WorldMem、MemoryPack 等）存在共同盲区：**将世界视为静态画布**。它们擅长记忆和重建静止环境，但物理世界充满由独立运动逻辑支配的动态主体（行走的行人、奔跑的动物）。当动态主体离开相机视野后再重新出现时，现有方法常导致：

- 主体**冻结**为静止状态（被固化为背景的一部分）；
- 主体**畸变**（外观扭曲、身份丢失）；
- 主体**消失**（完全无法恢复）。

核心挑战在于三个层面：（1）**时空解耦**——需将相机自运动与主体独立轨迹分离；（2）**视野外推断**——主体离开画面后模型失去直接视觉证据，须在潜空间隐式模拟其运动；（3）**特征纠缠**——扩散潜变量中静态背景与动态主体特征高度耦合，检索历史上下文时易导致主体冻结或畸变。

为此，本文提出 **Hybrid Memory（混合记忆）**范式，要求模型同时扮演静态背景的精确存档者和动态主体的持续追踪者，在主体出视野期间维持运动连续性。围绕该范式，本文贡献三重：（1）提出混合记忆概念及形式化定义；（2）构建首个大规模混合记忆数据集 HM-World；（3）设计专用记忆架构 HyDRA。

2. HM-World 数据集

自然视频中完美捕获无遮挡出入画面事件极为稀缺，因此作者基于 **Unreal Engine 5** 构建渲染管线，沿四个维度组合生成数据：

场景多样性：17 种风格各异的 3D 场景作为环境背景。**主体多样性：**49 种不同主体（不同外观的人类和多物种动物），以 1–3 个一组放置于场景中，每个主体关联独立运动动画。**主体轨迹：**10 条预定义运动路径。**相机轨迹：**28 种精心设计的相机运动，核心创新在于引入**往返式相机运动**（如先左移后右移），主动诱发主体出入画面事件。每条轨迹配置多个初始位置以增强多样性。

经过四维度组合并过滤无出入事件的片段，最终获得 **59,225** 条高保真视频片段。每条样本标注包括：渲染视频、MiniCPM-V 生成的描述文本、相机位姿、每帧所有主体的 3D 位置、以及主体出入画面的精确时间戳。

数据集	动态主体	出入事件	主体位姿	相机可动	数量
WorldScore	✓	×	×	✓	3K
Context-as-Mem	×	×	×	✓	10K
Multi-Cam Video	✓	×	×	✓	136K
360°-Motion	✓	×	✓	×	5.4K
HM-World	✓	✓	✓	✓	**59K**

HM-World 是唯一同时具备动态主体、出入画面事件、主体 3D 位姿和可动相机的数据集，填补了混合记忆研究的数据空白。

3. HyDRA 方法

3.1 问题形式化

给定上下文帧序列 $X_{ctx} \in \mathbb{R}^{N\times C\times H\times W}$ 和完整相机轨迹 $P = \{P_{ctx}, P_{tgt}\}$，目标是预测目标帧 $X_{tgt} \in \mathbb{R}^{M\times C\times H\times W}$。与静态场景不同，上下文帧中包含按独立运动逻辑运动的动态主体，随相机视角变化频繁出入视野。

3.2 基础架构与相机注入

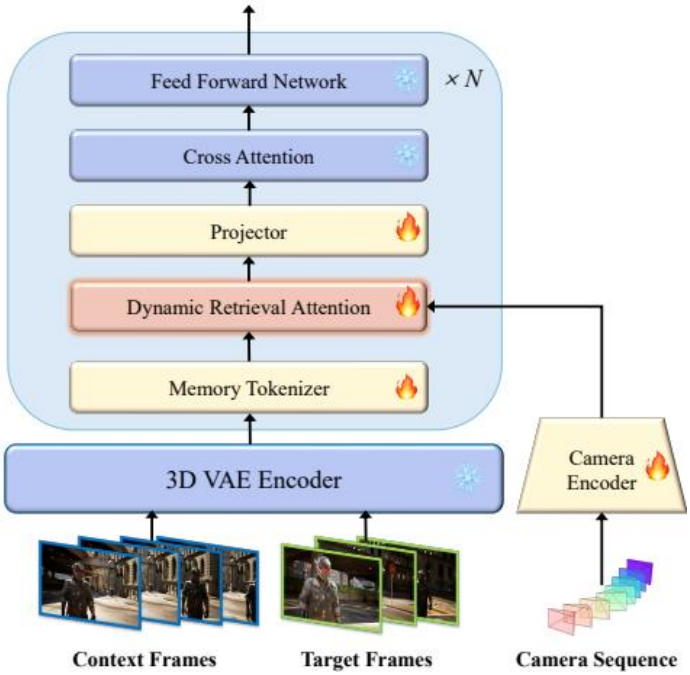

图 1：模型整体架构。基于全序列视频扩散模型，*DiT* 块集成动态检索注意力。

模型基于 **Wan2.1-T2V-1.3B** 全序列视频扩散模型，包含因果 3D VAE 和 Diffusion Transformer（DiT）。每个 DiT 块集成动态检索注意力、投影器、交叉注意力和 FFN。训练采用 **Flow Matching**：3D VAE 将视频帧编码为潜变量 z_0，通过线性插值获得加噪潜变量 z_t，模型学习预测真实速度 $v_t = z_0 - z_1$，损失函数为：

$$\mathcal{L}_\theta = \mathbb{E}_{z_0,z_1,t}\|u(z_t,t;\theta) - v_t\|^2$$

相机注入：将长度为 f 的相机位姿序列 $P = \{(R_i,t_i)\}_{i=1}^f$（$R_i \in \mathbb{R}^{3\times3}$ 旋转矩阵，$t_i \in \mathbb{R}^3$ 平移向量）展平拼接为 $c_{cam} \in \mathbb{R}^{f\times12}$，经 MLP 编码器 $\mathcal{E}_{cam}$ 编码后空间广播并逐元素加到潜特征上：$H_{out} = H_{in} + \mathcal{E}_{cam}(c_{cam})$。

3.3 记忆令牌化

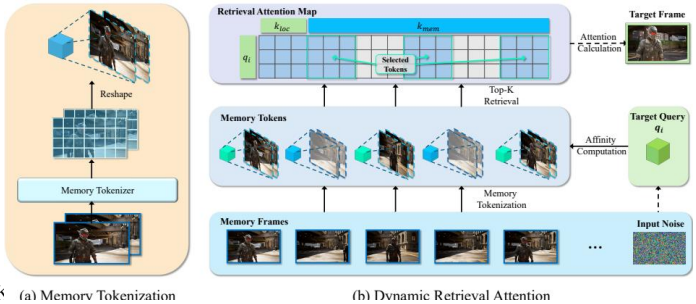

图 2：*HyDRA* 概览。*(a)* 记忆令牌化模块通过 *3D* 卷积压缩记忆。*(b)* 动态检索注意力按时空相关性检索 *Top-K* 令牌。

朴素地将全部记忆潜变量 Z_{mem} 注入生成过程不仅带来计算开销，还引入无关噪声误导模型。直接在原始潜变量上检索也不够理想——混合记忆任务涉及高度动态的主体和复杂的相机空间关系，原始潜变量缺乏表达运动信息的能力。

为此，作者设计基于 **3D 卷积**的记忆令牌化器 $\mathcal{T}_{mem}$，同时处理空间和时间维度，扩展时空感受野以捕获长时运动信息：

$$M = \mathcal{T}_{mem}(Z_{mem}), \quad M \in \mathbb{R}^{C'\times f'_{mem}\times h\times w}$$

其中 3D 卷积核大小为 $2\times4\times4$（时间 × 高 × 宽）。通过将原始潜变量压缩为密集、时空感知的记忆令牌，模型有效过滤无关上下文并保留关键运动和外观线索。

3.4 动态检索注意力

给定去噪目标潜变量 Z_{tgt} 和记忆令牌 M，分别投影为 Query Q、Key K_{mem} 和 Value V_{mem}。对每个目标潜变量 i，先通过空间池化将 q_i 降采样为 $\tilde{q}_i \in \mathbb{R}^{C' \times h \times w}$ 以对齐记忆令牌分辨率，然后计算**时空亲和度**：

$$S_{i,j} = \frac{1}{\sqrt{d}} \sum_{y=1}^{h} \sum_{x=1}^{w} \langle \tilde{q}_i(x,y), k_{mem,j}(x,y) \rangle$$

基于亲和度执行 **Top-K 选择**策略，筛选与当前目标最强相关的记忆令牌子集：

$$\mathcal{T}_i = \mathrm{TopK}(S_i, K), \; K_{sel} = \{k_{mem,j} | j \in \mathcal{T}_i\}, \; V_{sel} = \{v_{mem,j} | j \in \mathcal{T}_i\}$$

为保持局部去噪稳定性，强制将目标帧 i 的**局部时间窗口** $\mathcal{W}_i$ 内的 Key/Value 纳入注意力计算。最终拼接 $K'_i = [K_{sel}, K_{loc}]$，$V'_i = [V_{sel}, V_{loc}]$，执行标准注意力：

$$\mathrm{Attention}(q_i, K'_i, V'_i) = \mathrm{Softmax}\left(\frac{q_i (K'_i)^T}{\sqrt{d}}\right) V'_i$$

该机制直接替换基础模型中的标准 3D 自注意力层，通过基于 QK 交互的细粒度时空相关性评估，相比 FOV 重叠等基于静态几何的方法能更准确地定位隐藏主体的运动和外观线索。

4. 评估指标

除标准指标（PSNR、SSIM、LPIPS）和 VBench 的 Subject/Background Consistency 外，作者提出新指标 **DSC (Dynamic Subject Consistency)**：利用 YOLOv11 裁剪主体区域，CLIP 提取语义特征，计算：

$$\mathrm{DSC}_{GT} = \mathrm{sim}(F^{pred}, F^{gt}), \quad \mathrm{DSC}_{ctx} = \mathrm{sim}(F^{pred}, F^{ctx})$$

分别评估动态主体相对真值和历史上下文的运动与外观一致性。

5. 核心实验结果

5.1 定量对比

训练配置：基于 Wan2.1-T2V-1.3B，编码 77 帧上下文，3D VAE 时间下采样 4×，32 GPU 训练 10K 迭代，batch size 32。检索令牌数 10，局部窗口 5。

方法	PSNR	SSIM	LPIPS	DSC_{ctx}	DSC_{GT}	Subj.	Bg.
Baseline	18.70	.517	.356	.812	.837	.903	.925
DFoT	17.69	.482	.410	.803	.826	.893	.913
Ctx-as-Mem	18.92	.530	.342	.816	.839	.911	.922
WorldPlay	14.86	.355	.500	.822	.832	.910	.925
HyDRA	**20.36**	**.606**	**.289**	**.827**	**.849**	**.926**	**.932**

HyDRA 在所有指标上全面领先：PSNR 提升 1.66（vs Baseline）/ 1.44（vs Ctx-as-Mem）；SSIM 从 0.517/0.530 提升至 0.606；DSC_{GT} 达 0.849，证明其追踪隐藏主体并维持外观运动一致性的能力。与零样本评估的商业模型 WorldPlay 相比，PSNR 差距达 5.5，但 WorldPlay 在 DSC_{ctx} 上的 0.822 表明大规模训练模型具备一定混合一致性。

5.2 定性对比

在复杂出入画面事件中：Baseline 和 Context-as-Memory 出现严重主体畸变和运动不连贯；DFoT 无法维持主体完整性导致完全消失；WorldPlay 虽保持外观一致性但运动卡顿和动作不自然。HyDRA 成功维持主体身份和运动连贯性。开放域实验（互联网视频 + 往返相机运动）同样验证了 HyDRA 在未见场景中的泛化能力。

6. 消融实验

6.1 记忆令牌化器卷积核大小

T	$H \times W$	PSNR	SSIM	DSC_{ctx}	DSC_{GT}
2	2×2	20.11	.599	.820	.843
2	**4×4**	**20.36**	**.606**	**.827**	**.849**
2	8×8	20.23	.610	.822	.843
1	4×4	19.08	.554	.819	.841

空间维度变化影响较小（PSNR 差异 ≤ 0.24），但**时间维度从 2 降至 1 导致 PSNR 骤降 1.28**，DSC_{GT} 下降 0.008，定性结果显示主体出现明显不一致。这证明令牌化器中的**时间交互对捕获长时动态信息至关重要**。

6.2 检索令牌数量

仅检索 5 个令牌时 PSNR 为 19.31，信息损失严重，定性上出现幻觉（如一只长颈鹿变成两只）。检索 10 和 15 个令牌性能接近（PSNR 20.36 vs 20.33），表明适量令牌即可提供充分时空信息而不引入冗余噪声。

6.3 检索策略对比

方法	PSNR	DSC_{ctx}	DSC_{GT}	Subj.
FOV Overlap	19.78	.820	.844	.908
Dynamic Affinity	**20.36**	**.827**	**.849**	**.926**

动态亲和度检索全面优于 FOV 重叠，Subject Consistency 从 0.908 提升至 0.926。原因：FOV 方法基于静态 3D 几何计算，选择的记忆令牌在整个推理过程中固定不变，容易误检索不含主体的空镜头；动态亲和度方法基于特征级相关性动态计算，在不同去噪时步和 DiT 层自适应选择不同令牌，赋予模型更广的记忆感受野和灵活性。

7. 相关工作对比

现有视频世界模型记忆方法可分为：（1）**基于 3D 结构的检索**（Vmem 使用 surfel 索引）；（2）**基于 FOV 重叠的检索**（Context-as-Memory、WorldMem）；（3）**基于上下文打包/压缩**（MemoryPack、RELIC 均匀空间下采样）；（4）**基于时序记忆**（Memory Forcing 平衡探索与一致性）。这些方法均面向静态场景或简单动态环境设计，未针对复杂动态场景中移动主体出入视野的问题优化。Genie 3 展现了优异的动态一致性但为闭源模型。HyDRA 填补了这一方法与数据集的双重空白。

8. 局限性与未来方向

- **多主体场景退化**：当场景包含 3 个以上主体或严重遮挡时，HyDRA 维持一致性生成的能力下降；
- **数据集局限**：HM-World 基于 UE5 渲染，与真实世界存在域差距；主体种类和运动模式虽丰富但仍有限；
- **扩展方向**：探索更先进的记忆机制处理复杂多主体动态；将方法扩展至无约束真实世界环境；结合更强的基座视频生成模型提升整体质量。

ShotStream：面向交互式叙事的流式多镜头视频生成

Luo[1,†], Shi[2], Zhuang[1], Chen[1], Liu[2], Wang[2], Wan[2], Xue[1,3] — [1]MMLab, CUHK [2]Kuaishou [3]CPII, 2025

1. 问题动机与背景

当前文本到视频模型（Sora、Kling、Wan2.1 等）在单镜头高保真视频合成方面表现优异，但长叙事视频创作要求**多镜头生成**——生成多个连续镜头并在主题、场景风格和叙事逻辑上保持一致性，类似电影中的正反打（shot-reverse shot）等拍摄技法。现有多镜头方法主要依赖**双向注意力架构**，存在两大根本性局限：

- **交互性不足**：需要一次性提供所有镜头的 prompt 进行统一生成，无法在运行时动态调整单个镜头的内容、风格或角色，修改任一镜头均需完全重新生成；
- **延迟过高**：双向注意力计算复杂度随上下文长度二次增长，即使引入稀疏注意力优化，HoloCine 生成 240 帧多镜头视频仍需约 25 分钟。

ShotStream 提出了一种**因果式多镜头架构**，将多镜头合成重新定义为**自回归 next-shot 生成**任务——每个后续镜头基于历史镜头上下文生成，从而天然支持流式 prompt 输入。用户可在运行时动态指导叙事方向（调整内容、切换视觉风格、引入新角色），实现实时交互式长叙事视频生成，在单张 NVIDIA H200 GPU 上达到 **16 FPS**。

2. 系统架构概览

ShotStream 采用**师生蒸馏**框架，分两步构建：（1）微调文本到视频模型为双向 next-shot 教师模型；（2）通过 Distribution Matching Distillation（DMD）将其蒸馏为高效的 4 步因果学生模型。

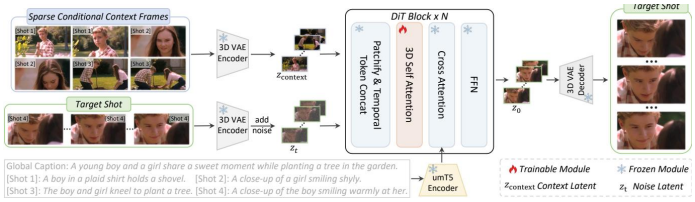

图 1：双向 *Next-Shot* 教师模型架构。历史镜头经稀疏采样后通过 *3D VAE* 编码为 *latent*，与噪声 *latent* 沿时间维度拼接注入 *DiT*。

2.1 双向 Next-Shot 教师模型

教师模型基于 **Wan2.1-T2V-1.3B**，目标为给定历史镜头生成下一个镜头。由于历史镜头包含数百帧且存在高度视觉冗余，系统采用**动态采样策略**：给定 S_{hist} 个历史镜头和最大条件帧预算 f_{context}（实验设为 6 帧），从每个历史镜头均匀采样 $\lfloor f_{\text{context}}/S_{\text{hist}} \rfloor$ 帧，剩余预算分配给最近的镜头以最大化信息保留。

条件注入机制：采样的上下文帧 V_{context} 经 3D VAE 编码器 ε 转换为条件 latent $z_{\text{context}} \in \mathbb{R}^{f_{\text{context}} \times c \times h \times w}$，与含噪目标 latent z_t 分别 patchify 后沿**帧维度拼接**：

$$x_{\text{input}} = \text{FrameConcat}(x_{\text{context}}, x_t)$$

训练时仅对目标视频 token 加噪，上下文 token 保持干净，使 DiT 原生 3D 自注意力层直接建模条件与噪声 token 间的交互，**无需引入额外层或参数**。

多 Caption 注入：不同于先前方法对条件帧和目标帧统一使用目标 caption，ShotStream 为每个条件帧注入其对应镜头的 caption——各镜头帧通过 cross-attention 同时关注全局 caption 和局部镜头 caption，有效绑定历史视觉信息与文本描述。

训练策略：仅微调 DiT 块中的 **3D 时空注意力层**（冻结其他参数），在 320K 多镜头视频数据集上训练 10K 步，Adam 优化器，学习率 1e-5，batch size 64。

2.2 因果学生模型与蒸馏

教师模型需约 50 步去噪，延迟高。通过 DMD 蒸馏为 **4 步因果生成器**，但因果架构面临两大挑战：（1）跨镜头一致性维护；（2）自回归误差累积。

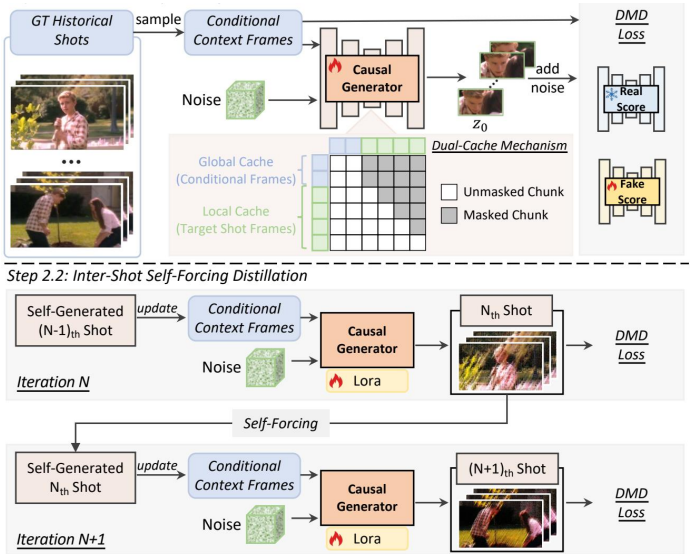

图 2：因果架构与两阶段蒸馏流程。双缓存记忆机制（*global/local cache*）配合 *RoPE* 不连续指示器；两阶段 *self-forcing* 渐进式蒸馏。

双缓存记忆机制。为维持视觉连贯性，设计两级缓存：

- **Global Context Cache**：存储历史镜头的稀疏条件帧，保证**镜头间一致性**（inter-shot consistency）；
- **Local Context Cache**：保留当前镜头内已生成帧，保证**镜头内一致性**（intra-shot consistency）。

朴素地合并两个缓存会引入时间歧义——因果模型难以区分历史上下文和当前镜头上下文。为此提出 **RoPE 不连续指示器**：对第 k 个镜头中第 t 个 latent，其时间旋转角为：

$$\Theta_t = \phi t + k\theta$$

其中 ϕ 为基础时间频率，θ 为镜头边界处的相位跳跃，显式解耦 global 和 local 上下文。

两阶段渐进式蒸馏。误差累积源于训练-推理间隙——训练时条件为真实历史镜头，推理时条件为自生成的不完美历史。解决方案：

阶段 1：Intra-shot Self-forcing（约 500 步收敛）。以真实历史镜头为条件，因果生成器逐 chunk 自回归生成当前镜头。local cache 使用自生成的前序 chunk 而非真实数据，建立基础 next-shot 能力。生成器学习率 2e-6，critic 学习率 4e-7，更新比 1:5。

阶段 2：Inter-shot Self-forcing（1000 步 LoRA 微调）。模型以**自生成的历史镜头**为条件，逐镜头展开整个多镜头视频，每个镜头内部仍逐 chunk 生成（intra-shot self-forcing）。DMD 损失仅应用于新生成的镜头。此过程忠实模拟推理时的自回归展开，有效弥合训练-推理间隙。

推理流程与训练完全对齐：逐镜头生成，每生成新镜头后更新 global cache 采样；当前镜头内逐 chunk 生成，利用 KV caching 保证效率。模型 chunk size 为 3 个 latent 帧，global cache 2 chunks，local cache 7 chunks。

3. DMD 蒸馏目标函数

DMD 最小化学生分布 p_{gen} 与平滑数据分布 p_{data} 之间的逆 KL 散度，梯度近似为两个 score 函数之差：

$$\nabla_\phi \mathcal{L}_{\text{DMD}} \approx -\mathbb{E}_t \left(s_{\text{data}} - s_{\text{gen},\xi}\right) \frac{dG_\phi(\epsilon)}{d\phi}$$

其中 G_ϕ 为学生生成器，s_{data} 和 $s_{\text{gen},\xi}$ 分别为在真实数据和学生输出分布上训练的 score 函数。基础模型采用 Rectified Flow 框架，训练目标为 MSE 损失：

$$\mathcal{L}_{RF}(\theta) = \mathbb{E}_{t,x,z} \| v_\theta(x_t, t, c_{\text{text}}) - (z - x) \|_2^2$$

4. 实验设置

数据集：内部收集的 320K 多镜头视频，每段含 2–5 个镜头、至多 250 帧，配有层次化标注（全局叙事 caption + 镜头级 caption）。**评估集**：利用 Gemini 2.5 Pro 生成 100 条多样化多镜头 prompt。**硬件**：32× NVIDIA H800 GPU 集群训练。

评估维度（五方面）：（1）镜头内一致性：DINO 主体相似度 + CLIP 背景相似度；（2）镜头间一致性：DINOv2 主体/背景 + ViCLIP 语义相似度；（3）TransNet V2 检测镜头边界后计算 Shot Cut Accuracy（SCA）；（4）文本对齐度；（5）VBench 美学质量与动态度。

5. 核心实验结果

5.1 定量对比

方法	架构	FPS	镜头间 Sub.	Trans.Ctrl
Mask2DiT	双向	0.149	0.612	0.513
EchoShot	双向	0.643	0.392	0.664
CineTrans	双向	0.413	0.412	0.572
Self Forcing	因果	16.36	0.542	0.633
LongLive	因果	16.55	0.594	0.693
Rolling Forc.	因果	15.32	0.561	0.684
Infinity-RoPE	因果	16.37	0.453	0.715
ShotStream	**因果**	**15.95**	**0.654**	**0.978**

ShotStream 在所有主要指标上全面领先：**镜头内一致性**（Sub. 0.825, Bg. 0.819）、**镜头间一致性**（Semantic 0.762, Sub. 0.654, Bg. 0.645）、**镜头切换控制**（0.978，远超所有基线）、**文本对齐**（0.234）、**美学质量**（0.571）和**动态度**（63.56）。相比双向模型吞吐量提升超 **25**×，同时匹配或超越因果长视频模型的速度。

5.2 用户研究

54 名参与者对 24 组多镜头视频进行盲评（8 种方法随机排列，可多选），ShotStream 在三个维度均获压倒性偏好：**视觉一致性 87.69%**（次高 Infinity-RoPE 16.92%）、**Prompt 遵循度 76.15%**（次高 LongLive/Rolling Forcing 16.15%）、**视觉质量 83.08%**（次高 Rolling Forcing 23.08%）。

5.3 定性分析

在复杂叙事多镜头 prompt 测试中，Mask2DiT、CineTrans、Self Forcing、Rolling Forcing 均无法生成与各镜头 prompt 对齐的内容；EchoShot 和 Infinity-RoPE 能适配单镜头指令但镜头间一致性差；LongLive 混淆了序列中两个女性角色的身份。ShotStream 同时忠实遵循多镜头 prompt、保持高视觉一致性并实现自然平滑的镜头转换。

6. 消融实验

6.1 双向教师模型设计

上下文帧采样策略：动态采样（Ours）在镜头间语义一致性上显著优于仅采第一帧（0.762 vs. 0.671）和首尾帧（0.762 vs. 0.709）策略。

条件帧 Caption 策略：注入各历史镜头对应 caption（Multi-Captions）相比统一使用目标 caption，镜头间 Sub. 一致性从 0.609 提升至 0.654，文本对齐从 0.194 提升至 0.234，验证了文本-视觉绑定对上下文学习的关键作用。

条件注入方式：帧维度拼接（Frame Concat）优于通道拼接（Channel Concat），因为 3D 自注意力可直接建模条件与目标 token 间的关系（Trans. Control 0.978 vs. 0.912）。

训练策略：仅微调 3D 注意力层优于全参数微调（镜头间 Sub. 0.654 vs. 0.631，动态度 63.06 vs. 60.85），表明冻结其他参数有效保留了基础模型能力。

6.2 因果学生模型设计

双缓存区分策略：无区分指示器时镜头间 Sub. 仅 0.507（vs. Ours 0.654）；可学习嵌入为 0.518；RoPE 不连续偏移最优（0.654），且为**无需训练**的方案，验证了显式解耦 global/local 上下文的必要性。

蒸馏训练策略：仅阶段 1（ground-truth 历史）动态度仅 59.66 且镜头间一致性次优（Sub. 0.604）；仅阶段 2（无阶段 1 基础）美学质量骤降至 0.467、动态度仅 52.86；两阶段渐进式训练取得最优综合性能。定性结果进一步表明，inter-shot self-forcing 显著改善了长期视觉风格和色彩一致性。

7. 技术细节

因果适应初始化：遵循 CausVid 协议，用教师权重初始化学生模型并转换为因果注意力，在 5K 教师 ODE 轨迹对上回归训练 2000 步（学习率 1e-6，batch size 64），桥接双向-因果间隙。

生成规格：832×480 分辨率视频，每个案例含 5 个连续镜头共 405 帧。模型操作单位为 chunk（3 个 latent 帧），global cache 2 chunks，local cache 7 chunks。

8. 与相关工作的对比

关键帧方法（Captain Cinema、StoryDiffusion 等）仅在关键帧层面强制一致性，镜头内内容孤立。**统一序列建模**（LCT、MoC、HoloCine）虽联合处理所有镜头但受限于双向架构的延迟与交互性。**自回归长视频模型**（Self Forcing、LongLive、Rolling Forcing）虽支持因果生成但**局限于单场景**，多镜头叙事能力不足。ShotStream 首次将自回归建模扩展至连贯的多镜头叙事视频生成，兼具低延迟与交互性。

与 LongLive 的 KV-recache 机制相比，ShotStream 的双缓存 + RoPE 不连续指示器提供了更结构化的历史管理；与 Infinity-RoPE 的 training-free RoPE Cut 相比，ShotStream 通过两阶段蒸馏从根本上解决了误差累积问题。

9. 局限性与未来方向

- **复杂场景伪影**：当场景和文本 prompt 高度复杂时仍会出现视觉伪影和不一致，主要受限于 1.3B 骨干模型容量——扩大基础模型规模有望改善；
- **加速空间**：当前 16 FPS 仍有提升余地，可集成稀疏注意力（MoGA）和 attention sink 机制进一步降低延迟；
- **叙事复杂度**：当前验证集主要覆盖 5 镜头场景，超长叙事（数十镜头）的稳定性尚待探索；
- **训练数据依赖**：需要高质量多镜头视频数据集及层次化标注。

PackForcing：短视频训练即可实现长视频采样与长上下文推理

Mao[1,2,*], Rui[1,3,*], Ying[1,2], Zheng[1], Li[1], Chi[2,†], Zhang[1,3,†] — [1]Alaya Studio (Shanda AI Tokyo), [2]Fudan, [3] 上海创新研究院, 2026

1. 动机与核心问题

自回归视频扩散模型通过逐块（block-by-block）生成策略突破了双向模型的固定长度限制，但面临两大瓶颈：

- **误差累积**：去噪过程中小误差逐步放大，导致语义漂移——Self-Forcing 在 60s 内 CLIP 分数从 33.89 骤降至 27.12；
- **KV 缓存无界增长**：2 分钟 832×480@16FPS 视频的全注意力上下文膨胀至 ~749K token，需 ~138GB KV 存储（30 层 Transformer），远超单 GPU 显存。

传统应对手段（历史截断、滑动窗口）严重损害长程一致性。DeepForcing 引入注意力锚点与参与式压缩，但最终仍依赖缓冲区激进截断，不可逆丢失中间历史记忆。**核心矛盾**：缓解误差累积需要丰富的上下文历史，但硬件约束迫使丢弃关键记忆。

PackForcing 提出三**分区 KV 缓存**设计，同时解决误差累积与内存瓶颈，仅用 5 秒短视频训练即可零样本或微调生成 2 分钟连贯视频——24× 时间外推。

2. 系统架构

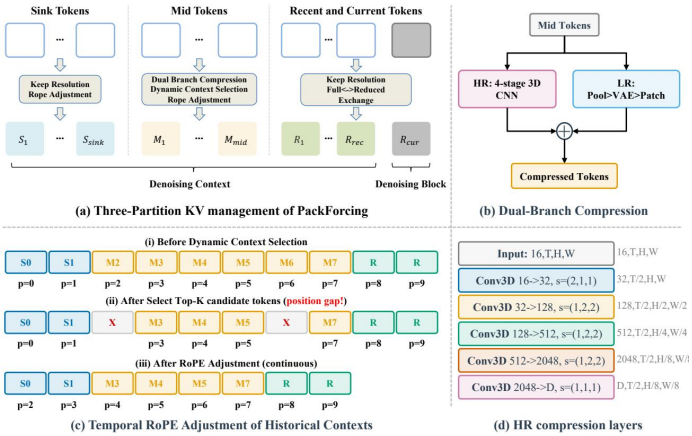

图 1：*PackForcing* 总览。*(a)* 三分区 *KV* 管理；*(b)(d)* 双分支压缩模块；*(c)* 动态上下文选择与 *Temporal RoPE* 调整。

2.1 三分区 KV 缓存设计

将单调增长的生成历史解耦为三个功能分区，各施以针对性策略：

(1) Sink Token（全分辨率，永不驱逐）。受 StreamingLLM 注意力锚点现象启发，最早生成的帧作为关键语义锚点。设 N_{sink} 为锚帧数（默认 8，即 2 个块），对应 KV 缓存：

$$\mathcal{C}^l_{\text{sink}} = \{(\mathbf{K}^l_j, \mathbf{V}^l_j)\}_{j=1}^{N_{\text{sink}}/B_f}$$

锁定场景布局、主体身份和全局风格，仅占总 token 预算 $< 2\%$，却在整个生成过程提供稳定全局参考，有效防止语义漂移。

(2) 压缩 Mid Token（~32× token 缩减，动态路由）。位于 sink 与 recent 之间的大量历史，全分辨率保留代价过高且冗余极大。通过双分支模块（Sec. 2.3）生成高度压缩的 KV 对 $(\tilde{\mathbf{K}}^l_j, \tilde{\mathbf{V}}^l_j)$，并通过动态上下文选择（Sec. 2.5）仅检索 N_{mid} 个最相关块：

$$\mathcal{C}^l_{\text{mid}} = \{(\tilde{\mathbf{K}}^l_j, \tilde{\mathbf{V}}^l_j)\}_{j\in\mathcal{S}_{\text{mid}}}, \quad |\mathcal{C}^l_{\text{mid}}| \le N_{\text{mid}} \cdot N_c$$

每块从原始 n=6,240 token 压缩至 N_c=182 token（~32× 缩减）。

(3) Recent & Current Token（全分辨率，双分辨率移位）。最近生成的帧保持原始分辨率以确保局部时序连贯：

$$\mathcal{C}^l_{\text{rc}} = \{(\mathbf{K}^l_j, \mathbf{V}^l_j)\}_{j=i-N_{\text{recent}}/B_f}^{i}$$

关键创新：在生成当前块时**并行**计算全分辨率 KV（用于即时预测）和低分辨率备份（用于未来滑入 mid 分区），完全隐藏压缩延迟。

有界注意力上下文。生成块 i 时，三分区拼接形成定长上下文：

$$\mathcal{C}^l = \mathcal{C}^l_{\text{sink}} \parallel \mathcal{C}^l_{\text{mid}} \parallel \mathcal{C}^l_{\text{rc}}$$

token 总数恒定（~27,872），**独立于视频总长度** T，确保 $O(1)$ 注意力复杂度，且**不丢弃任何历史记忆**——全部历史持久存储于缓冲区（全分辨率或压缩态），仅动态检索最相关子集参与计算。

2.2 双分支高分辨率压缩

mid 分区需实现 ~32× token 缩减同时保留结构与语义。单路径压缩面临陡峭权衡：激进空间降采样保留布局但丢失纹理，语义池化保留含义但破坏空间结构。

HR 分支（渐进式 3D 卷积）：直接在 VAE 隐变量 $\mathbf{z} \in \mathbb{R}^{B\times C\times T\times H\times W}$ 上操作。级联步进 3D 卷积 + SiLU 激活：先 2× 时间压缩，再三阶段各 2× 空间压缩，最终 1×1×1 投影至模型隐维度 d=1536，总 128× 体积缩减 (2×8×8)。

LR 分支（像素空间重编码）：将隐变量 $\mathbf{z}$ 解码回像素帧，施加 3D 均值池化（时间 2×，空间 4×），再用冻结 VAE 编码器重编码回隐空间 + 标准 patch embedding。此解码-池化-编码路径在像素空间操作，比直接隐空间池化更好保留感知布局。

特征融合：两分支输出维度相同，逐元素相加：$\tilde{\mathbf{h}} = \mathbf{h}_{\text{HR}} + \mathbf{h}_{\text{LR}} \in \mathbb{R}^{B\times N_c\times d}$。考虑原始 patch embedding 已执行 1×2×2 空间缩减，双分支模块净 token 缩减为 ~32×（6,240 → 182）。

2.3 增量 RoPE 调整

位置失配问题。骨干网络使用 3D RoPE，维度分配 44+42+42=128。缓存的 key 已编码其绝对位置 p 的旋转：$\mathbf{k}^{(p)}_{\text{cached}} = \mathbf{k}_{\text{raw}} \odot e^{i\boldsymbol{\theta}_p}$。当驱逐 Δ 个块（$\delta = \Delta B_f$ 帧）以维持容量时，sink key 仍编码位置 $0, \ldots, N_{\text{sink}}-1$，而存活的最早 mid key 编码位置 $N_{\text{sink}}+\delta$，产生位置间隙，破坏注意力依赖的位置连续性。

利用 RoPE 旋转的乘法性质 $e^{i\boldsymbol{\theta}_p} \cdot e^{i\boldsymbol{\theta}_\delta} = e^{i\boldsymbol{\theta}_{p+\delta}}$ 以及驱逐仅影响时间轴，对 sink key 施加**仅时间维度**的高效调整：

$$\mathbf{k}'_{\text{sink}} = \mathbf{k}_{\text{sink}} \odot [e^{i\boldsymbol{\theta}_t(\delta)}, \mathbf{1}_h, \mathbf{1}_w]$$

调整后 sink 位置变为 $\delta, \delta+1, \ldots$，无缝衔接 mid 位置。每次驱逐事件仅需一次复数乘法，开销 $< 0.1\%$。消融实验（表 8）：无 RoPE 调整时 CLIP 早晚段差距 2.53，启用后缩至 0.95（62% 改善）。

2.4 动态上下文选择

并非所有压缩块同等重要。基于查询-键亲和度的**非破坏性**软选择机制：仅检索 top-K 最相关 mid 块参与注意力，未选中 token 安全归档以备未来场景变化时重新激活（区别于 DeepForcing 的永久剪枝）。

重要性分数：$s_m = \sum_{j,i\in\mathcal{S}_q} \frac{1}{B\cdot N_{\text{opt}}} \sum_{b,h} \frac{Q_{b,h,i} K^\top_{m,b,h,j}}{\sqrt{d_h}}$

三项工程优化将开销压至 $< 1\%$：(1) 确定性查询子采样（比率 γ，保留 $\max(32, \lfloor\gamma L_q\rfloor)$ token）；(2) 半头评估（仅用 $N_h/2$ 个注意力头）；(3) 步缓存——仅在每块首个去噪步计算亲和度，后续步复用索引。

3. 注意力模式的经验分析

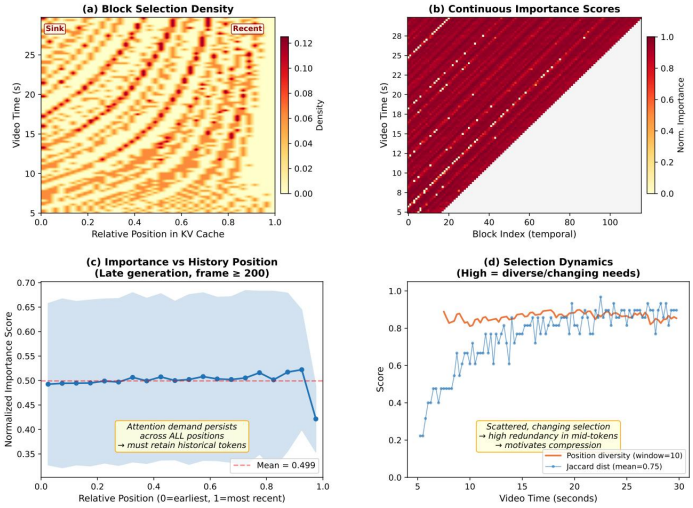

图 2：因果视频生成中的注意力模式。*(a)* 注意力遍布全历史；*(b)* 重要 *token* 稀疏分布；*(c)* 晚期重要性近平坦（均值 *0.499*）；*(d)* 高 *Jaccard* 距离 *(0.75)* 证明检索高度动态。

480 帧生成中的注意力分析揭示两个关键洞察：**(1)** 注意力需求**持续覆盖全部历史**，晚期阶段各位置重要性近平坦（均值 0.499），否定了 FIFO 驱逐的合理性；**(2)** 高关注 token **稀疏且动态分布**，连续选择集的 Jaccard 距离达 0.75（75% 块在每步更换），位置多样性 > 0.85。这共同证明：mid 区 token 各自仅偶尔被需要但聚合需求覆盖全历史——正是激进压缩的理想对象。

4. 实验结果

4.1 实验设置

骨干为 Wan2.1-T2V-1.3B，生成 832×480@16FPS 视频。缓存设置：N_{sink}=8，N_{recent}=4，N_{top}=16。块大小 B_f=4，蒸馏去噪 S=4 步。仅在 20 帧时间窗（∼5s）上训练 3,000 步（batch 8），使用 AdamW（β_1=0, β_2=0.999）。评估使用 VBench-Long 128 条 MovieGen 提示，7 项核心指标 + 10s 间隔 CLIP 分数。

4.2 主实验（60s 与 120s）

方法	Dyn.Deg.	Over.Cons.	Subj.Cons.	Img.Qual.
60s 生成				
CausVid	48.43	23.36	84.53	65.69
LongLive	44.53	25.73	92.00	69.06
Self-Forcing	35.93	24.92	80.41	66.62
Rolling-F.	33.59	25.73	91.62	71.06
DeepForcing	53.67	21.75	92.55	67.75
PackForcing	**56.25**	**26.07**	90.49	69.36
120s 生成				
CausVid	50.00	23.13	83.24	65.41
Self-Forcing	30.46	23.42	74.40	62.49
DeepForcing	52.84	21.38	91.95	68.21
PackForcing	**54.12**	**26.05**	**92.84**	**69.67**

PackForcing 在两个时长下均取得最高 Dynamic Degree（56.25 / 54.12），超越最强基线 CausVid 达 +7.82 / +4.12，证明持久记忆机制为模型提供可靠时序基础，使其能够自信合成复杂连续运动。关键优势在于**长时稳定性**：Self-Forcing 从 60s 到 120s Subject Consistency 下降 6.01、Aesthetic Quality 下降 5.47，而 PackForcing 仅下降 1.01 和 0.49。

4.3 长程文本-视频对齐

方法	0-10s	30-40s	50-60s	Δ
Self-Forcing	33.89	29.99	27.12	6.77
CausVid	32.65	31.13	30.79	1.86
DeepForcing	33.47	32.28	32.27	1.20
PackForcing	**34.04**	**33.37**	**32.90**	**1.14**

PackForcing 全程维持最高对齐度，60s 内 CLIP 仅下降 1.14 分（Self-Forcing 下降 6.77），直接验证 sink token 锚定全局语义的能力。

4.4 消融实验

Sink 大小。N_{sink}=0 导致严重语义漂移：Overall CLIP 从 35.09 降至 31.24，Subject Consistency 从 93.11 降至 74.72。N_{sink}=16 最大化一致性但扼杀运动（Dynamic Degree 降至 35.16）。N_{sink}=8 最优平衡：动态丰富度 49.84，Image Quality 73.18，Aesthetic Quality 66.46，Subject Consistency 在 N_{sink}=16 的 1% 以内。

压缩分支。仅 HR 分支：Img.Qual. 68.12 / Over.Cons. 25.41 / CLIP 32.97；仅 LR 分支：67.45 / 25.18 / 33.11；HR+LR 融合：**69.36 / 26.07 / 33.54**。两分支互补——HR 提供空间细节，LR 提供语义上下文。

驱逐策略。Dynamic Select 相比 FIFO 在 Subject Consistency 上 +0.8（88.62 vs. 87.82），CLIP +0.12（33.54 vs. 33.42），因亲和度驱动优先保留高注意力块。Random 最差（86.31 / 33.01）。

4.5 计算效率

方法	KV Cache	Peak GPU	速度
Full cache	∼138GB	OOM	—
Window-only	3.1GB	24GB	18FPS
PackForcing (Part.)	**4.2GB**	27GB	15FPS

PackForcing 将 120s 视频的 KV 缓存从 ∼138GB 严格限界至 ∼4.2GB，可在单张 H200 GPU 上运行，速度 15FPS。相比仅滑动窗口方案，仅增加 1.1GB 内存和 3FPS 延迟，却获得完整长程记忆。

5. 24× 时间外推的机制解释

两大机制支撑 5s → 120s 的 24× 外推：**(1) 上下文尺寸不变性**——通过压缩和管理 KV 缓存，注意力上下文在训练和推理中均恒定为 ∼27,872 token，避免序列长度分布偏移触发误差累积；**(2) 表示兼容性**——端到端联合训练双分支压缩层，使压缩 token 与全分辨率 token 对齐在同一隐空间子空间中，Transformer 可无缝注意到高压缩历史特征。

6. 与相关工作的对比

PackForcing 是**首个在因果视频生成中引入显式学习型 KV 压缩**的方法。已有方法的缺陷：CausVid/Self-Forcing 无 KV 压缩且无有界内存；Rolling-Forcing 有界但无长程记忆；LongLive 仅部分保留长程信息；DeepForcing 有界且有注意力锚但依赖不可逆截断。PackForcing 唯一同时实现 KV 压缩 + 有界内存 + RoPE 调整 + 完整长程记忆。

在 LLM 领域，KV 缓存管理主要关注 token 选择/驱逐（attention sink、heavy-hitter 等），因文本表示已高度紧凑。视频 token 编码密集时空网格且帧间冗余巨大，这种结构性冗余恰好适合学习型 128× 体积压缩——远超纯 token 选择所能达到的缩减比。

7. 局限性与未来方向

- 固定压缩比（128× 体积 / ∼32× token）未能自适应场景复杂度，可探索动态比率；
- 基于注意力的重要性评分可能遗漏视觉显著性的某些方面，学习型重要性预测器值得探索；
- 扩展至更高分辨率（如 1920×1080）需研究空间压缩与质量的交互；
- LongLive 在 Subject Consistency 上略优（92.00 vs. 90.49），但代价是 Dynamic Degree 仅 44.53（PackForcing 56.25）——在不牺牲动态多样性的前提下进一步增强严格主体保持是主要方向；
- 三分区原则具有通用性，可扩展至视频以外的其他自回归域。

MedOpenClaw：面向未整理完整影像研究的可审计医学影像智能体推理

Shen, Hu, Liu, Wu, Zhu, Shen, Xu, Jin, Wiestler†, Rueckert†, Pan† — TUM, Imperial, Oxford, CMU, NUS 等, 2026

1. 问题动机与背景

当前医学视觉语言模型（VLM）的评估严重**简化了临床现实**：基准测试依赖人工预选的诊断相关 2D 图像，模型仅需对单张或少量图像回答问题。这一设定存在三个根本缺陷：

- **遗漏研究级复杂度**：真实放射科工作流是研究级过程——医师需浏览完整 3D 检查、选择相关序列/模态、在数十至数百层切片中导航、调整窗宽窗位或融合设置、跨视图比较证据，常需进行测量或专业分析后才能做出判读；
- **诊断信息跨切片分布**：许多临床发现不可能在单张图像中识别——只有在相邻切片、跨序列对比或定位相关区域后才能显现（如 MRI 半月板“双层触碰规则”、CT 结节动态增强）；
- **缺乏可审计性**：模型返回答案但不提供可重放的决策轨迹——在哪里查看、收集了什么证据、最终结论如何达成均不透明，无法满足临床和监管对透明性的要求。

为弥合静态图像感知与交互式临床工作流之间的鸿沟，本文提出两个核心组件：(1) **MedOpenClaw**——可审计运行时，使 VLM 智能体在标准医学查看器（如 3D Slicer）中动态操作完整影像研究；(2) **MedFlow-Bench**——首个要求智能体执行的全研究交互式医学影像基准测试。

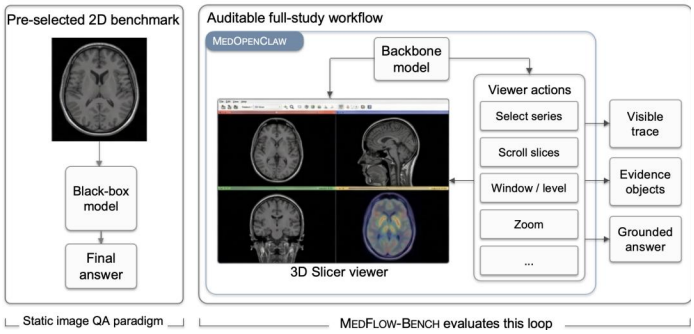

图 1：左：传统 *VQA* 基准依赖预选 *2D* 图像，决策过程不透明。右：*MedOpenClaw* 通过有界查看器接口与 *3D Slicer* 交互，产生透明推理轨迹、证据对象和有据最终答案。*MONAI* 等工具可无缝集成。

2. MedOpenClaw 运行时架构

MedOpenClaw 是**运行时与 API 层**（非模型），位于骨干 VLM 智能体与医学查看器之间，不修改查看器源码，通过固定接口暴露研究级检查操作。动作空间按三**层架构**组织：

2.1 第一层：原始查看器操作

支持基本导航与显示控制：选择序列（series selection）、滚动切片（scrolling）、调整窗宽窗位（windowing）、融合设置等。这些操作对应人类读片医师在查看器中的核心交互。

2.2 第二层：证据操作

允许智能体捕获和导出可审查制品：书签视图（bookmarked views）、绘制掩模（drawn masks）、测量日志（measurement logs）。确保决策过程中的关键视觉证据被显式记录。

2.3 第三层：可选专家工具

高级分割或定量分析工具，如基于 MONAI 的参考工具包，专在此层操作。这一分层架构不仅是软件抽象，更直接指导评估设计——MedFlow-Bench 的三赛道恰好对应这一分层。

有界接口设计。可调用表面严格显式化：3D Slicer 已支持的功能通过文档化的 WebServer REST 端点封装（HTTP 请求/响应）；REST 接口未覆盖的操作（DICOM 导入、定量测量、DICOM SEG 导出）通过命名桥接处理器暴露。**关键限制**：虽然 3D Slicer 包含嵌入式 Python 控制台，但系统禁止执行任意代码——仅暴露预定义操作，以缩小攻击面、强化可审计性并简化部署。

天然可审计性。运行时记录每一次工具调用及其参数、结果查看器状态快照和生成制品。诊断轨迹完全可事后重建：访问了哪些视图、执行了什么操作、最终答案基于何种证据。

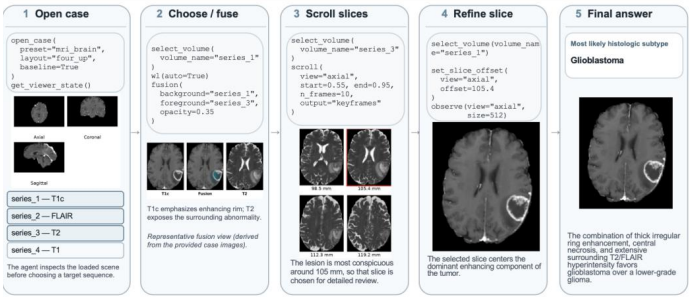

图 2：*Brain MRI* 模块 *Tool-Use* 设定下的可审计执行轨迹示例。智能体依次枚举可用体积、检查各 *MRI* 序列（*T1c, FLAIR, T2, T1*）、请求跨序列观察、滚动轴向关键帧后提交诊断。完整操作链（工具参数、视觉输出、最终报告）均可外部审查。

2.4 从评估到临床助手

可观察的逐步执行直接映射人类放射科医师工作流。由于交互透明且有界，框架可从自主评估运行时无缝转化为交互式人机协同助手——**MedCopilot**。它利用完全相同的可审计工具使用轨迹，自主处理繁琐的查看器交互（如模态融合、关键切片定位），降低人工开销，使临床医师专注于最终诊断验证。

3. MedFlow-Bench：研究级评估基准

3.1 基准设计与独特性

MedFlow-Bench 评估研究级推理而非静态图像感知，在已有基准中**唯**一同时具备：全研究交互访问、跨模态推理、主动探索、鉴别诊断和智能体执行要求。一个基准 episode 定义在研究级而非图像级，包含：(i) 完整体积检查和研究元数据的研究包；(ii) 要求病例级/研究级决策的任务提示；(iii) 由评估赛道决定的允许动作空间；(iv) 用于评分的规范答案模式。

3.2 临床模块

当前发布覆盖两个代表性临床模块：

Brain MRI 模块：使用 UCSF-PDGM 数据集（术前多序列脑肿瘤 MRI），在固定标签集上进行病例级诊断，报告**病例级准确率**。

Lung CT/PET 模块：使用 NSCLC radiogenomics 数据集（配对非小细胞肺癌 CT/PET，含病理标注），评估五项结构化预测任务：肿瘤位置、病理 T 分期、病理 N 分期、组织学类型、组织病理学分级。报告**病例精确准确率**（主要指标）及问题级准确率（辅助指标）。

每个 episode 在两种回答协议下评估：MCQ（多选题，提供显式选项）和 Open-ended（开放式，移除选项，使用 LLM 评审对照规范答案衡量鲁棒性）。

3.3 三赛道设计

所有赛道使用相同病例、任务和指标，仅解空间不同：

- **Track A（Viewer-Only）**：纯全研究视觉感知测试。仅允许原始工具（序列选择、滚动、窗宽窗位），聚焦视觉搜索、切片间综合和序列级推理；
- **Track B（Tool-Use）**：主系统赛道，开放专家模块和证据工具的完全访问。测试模型能否判断何时需要专家工具（如 MONAI 包）、设置参数并将返回制品整合回诊断轨迹；
- **Track C（Open-Method）**：可绕过 MedOpenClaw，使用任意管线（原生 3D 基础模型、研究压缩编码器等），确保基准作为通用标准。

4. 实验结果

评估 GPT-5.4、GPT-5-mini、Gemini-3-flash 和 Gemini-3.1-pro，均使用 MCQ 协议。

4.1 Track A：Viewer-Only 基线

模型	Brain	Chest	Loc.	T	N	Hist.	Grade
GPT-5.4	0.61	0.32	0.46	0.32	0.38	0.36	0.07
GPT-5-mini	0.43	0.20	0.14	0.17	0.09	0.06	0.04
Gemini-3-flash	0.56	0.52	0.42	0.21	**0.83**	**0.72**	**0.44**
Gemini-3.1-pro	**0.63**	0.31	0.43	0.31	0.35	0.34	0.11

关键发现：前沿模型已能通过导航查看器解决相当比例的研究级任务。Brain MRI 上 Gemini-3.1-pro 达到最高 0.63，GPT-5.4 紧随其后 0.61。Lung CT/PET 上，宏观任务（肿瘤位置）表现尚可（GPT-5.4: 0.46, Gemini-3.1-pro: 0.43），但**细粒度任务性能急剧下降**——组织病理学分级所有模型均难以超越随机基线（GPT-5.4 仅 0.07）。Gemini-3-flash 在 Lung CT/PET 上异常突出（N 分期 0.83，组织学 0.72），平均工具调用次数也最多（19.6 次），暗示更充分的探索可能带来收益。

4.2 Track B：工具使用瓶颈

骨干	配置	Brain	Chest
2*GPT-5-mini	原始工具	0.43	**0.20**
	+ 分割工具包	**0.45**	0.14
2*GPT-5.4	原始工具	**0.61**	**0.32**
	+ 分割工具包	0.57	0.27

"工具使用悖论"：这是本文最重要的实证发现——为智能体配备专业分割工具**不仅未提升准确率，反而使其下降**。GPT-5.4 在 Brain MRI 上从 0.61 降至 0.57，Lung CT/PET 上从 0.32 降至 0.27。

根因分析：底层分割算法本身是可靠的，问题在于当前 VLM 智能体**缺乏精确的空间定位能力**。例如调用局部阈值分割工具时需提供准确空间坐标引导算法，但模型常无法输出毫米级精度坐标，导致工具生成错位或解剖学错误的掩模。智能体随后依赖这些有缺陷的自生成视觉证据，误导后续诊断推理。结论：提供可靠专家工具**不充分**——若智能体的基础空间控制能力尚未成熟，工具反而有害。

5. 与相关工作的对比

静态医学 VQA 基准（VQA-RAD, SLAKE, OmniMedVQA, MedXpertQA 等）测试固定图像上的视觉识别和医学知识，但从预选 2D 视图出发而非完整研究。**医学智能体**研究（MedRAX, MedAgent-Pro, MDAgents 等）使推理循环更显式，但多数仍操作固定图像或抽象工具接口。**全研究/交互系统**（VoxelPrompt, CT-Agent, RadABench 等）更接近临床工作流，但在体积推理、环境设计或软件集成交互方面各有侧重。

MedFlow-Bench 是**唯一**同时满足以下条件的基准：全研究交互访问、多影像模态、跨模态病例推理、主动探索、鉴别诊断和智能体执行要求。关键区别还在于**可审计性**——RadABench 使用合成动态环境但不强制执行轨迹记录，而 MedOpenClaw 的有界设计从架构层面保证每个操作可追溯。

6. 讨论与核心洞察

空间定位是下一个前沿：AI 社区在逻辑和语言条件推理上取得巨大进展，但基准暴露了**细粒度空间定位的关键差距**。可靠的工具增强执行仍极具挑战，因为模型尚不能输出临床算法所需的毫米级精确坐标。

可审计性是临床信任的前提：在真实医院部署 AI，黑箱决策不可接受。将 VLM 限制在有界运行时中——每次序列选择、窗宽调整、切片滚动均显式记录——自然产生临床和监管框架所需的透明证据链。

基准与应用的桥接：与静态 2D 基准（高分常无法转化为临床实用性）不同，解决 MedFlow-Bench 直接贡献于构建更好的人机协同系统——因为动作空间完美映射人类放射科医师工作流。

7. 局限性与未来方向

- **模态覆盖有限**：当前仅 Brain MRI 和 Lung CT/PET 两个模块，未来将扩展至超声、乳腺 X 线、纵向研究（前后检查对比）；
- **评估设定单一**：当前为单轮任务，未来引入多轮对话评估赛道和需综合电子健康记录（EHR）的任务；
- **工具生态待丰富**：随空间定位改善，将整合 MONAI 生态更多专用算法；
- **模型评估范围**：初始版本仅评估少数前沿商用模型，开源医学 VLM 和原生 3D 基础模型的评估待补充；
- **空间定位瓶颈**：解决 VLM 精确坐标输出能力是使 Tool-Use 赛道真正有效的关键挑战，可能需要专用空间感知训练或视觉定位预训练。

RealChart2Code：基于真实数据与多任务评估的图表转代码生成

Zhang*, Li*, Li*, Guo, Wu, Zheng, Yang, Zhang, Li, Yan 等 — USTC, THU, CUHK, UCAS, CASIA 等, 2026

1. 动机与问题背景

视觉语言模型（VLM）在代码生成领域展现出强大能力，但在复杂多面板可视化图表的复现任务上仍存在显著不足。现有 Chart-to-Code 基准（如 Plot2Code、ChartMimic）主要聚焦于简单图表类型和单面板布局，且多依赖预存的图表-代码对（存在数据泄露风险）或合成数据，缺乏对**真实世界复杂数据**和**多轮迭代修正**能力的系统评估。随着 LLM 快速发展，此类基准已不足以区分模型在复杂场景下的真实能力。

本文提出 **RealChart2Code**，一个包含 **2,896** 个实例的大规模基准，具有四个核心区分点：

- **真实数据**：基于 Kaggle 真实数据集构建，而非合成或任意构造数据；
- **高复杂度**：涵盖复杂复合图表和多面板布局，涉及 7 类可视化意图和 50 种图表类型；
- **交互式框架**：模拟真实开发中的多轮对话修正工作流；
- **多任务评估**：设计三个挑战性任务全面评估模型的可视化生成、语义理解和图表修改能力。

2. 任务定义与基准架构

Chart-to-Code 任务形式化为条件代码生成：给定图表图像 V 和提示 P，模型 $\mathcal{F}(\cdot)$ 生成可执行代码 $C = \mathcal{F}(V, P)$，使其渲染结果准确复现 V 的视觉和结构元素。

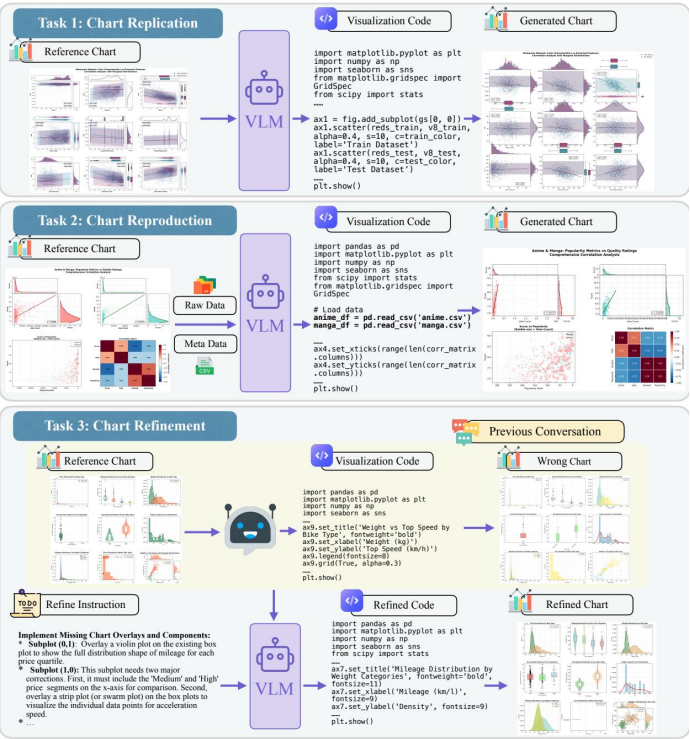

图 1: *RealChart2Code* 三个核心任务：*Chart Replication*、*Chart Reproduction* 和 *Chart Refinement*。

如图 1 所示，RealChart2Code 评估模型在三个任务变体上的表现：

2.1 Chart Replication（图表复制，1,016 实例）

最基础的 Chart-to-Code 任务：模型仅接收图表图像，需逆向工程出可视化代码。测试核心的**视觉到代码翻译能力**——模型需从像素级视觉信息中推断布局、样式、颜色映射等，并生成合成数据匹配参考图表特征。

2.2 Chart Reproduction（图表再现，1,016 实例）

在图表图像基础上额外提供**原始数据文件和元数据**，评估模型使用大规模真实数据源生成正确图表的能力。此任务考验模型的数据加载、转换、映射和聚合能力——需正确识别使用哪些数据集和列、应用何种数据变换、以及多数据集间的关联关系。

2.3 Chart Refinement（图表修正，864 实例）

模型需在**多轮对话**中根据用户反馈修正预定义错误的图表代码，评估迭代调试能力。注入的错误类型多样，包括图表类型错误、数据映射错误、元素重叠等常见问题。这是首个系统评估多轮会话中代码修正能力的基准。

3. 数据集构建流程

采用四阶段流水线：

数据收集与过滤。从 Kaggle 初始筛选超过 8,000 个数据集（含 100,000+ 文件、300 亿行数据），基于社区投票数、下载量和可用性评分进行自动化筛选，再经专家人工审核选出 **1,036** 个高质量数据集，最终包含 3,271 个原始数据文件，约 **8.6 亿行**数据。

可视化任务设计。基于 7 类高级可视化意图（关联、偏差、排序、分布、组成、变化、分组）和 50 种图表类型的分类法，设计 1,016 个独特复杂可视化场景。每个场景同时用于 Replication 和 Reproduction 任务，产生 2,032 个实例。

Ground-Truth 代码实现。由 5 名 Python 专家开发者使用 Matplotlib 及相关库手工实现所有参考代码（非模型生成），确保可执行性、可复现性和代码规范性。

错误注入。对部分 Ground-Truth 代码手工注入多种类型错误（视觉/样式错误、数据映射错误、图表类型错误），构建 864 个 Chart Refinement 任务。

数据集覆盖范围。涵盖金融、工业、健康、科研、社会、媒体、技术、环境 8 大领域，细分 35 个子主题。t-SNE 可视化显示图像和 CSV 数据分布广泛分散于特征空间中，表明视觉风格、布局和数据特征具有充分多样性。

4. 评估框架

4.1 功能正确性

首先评估 **Pass Rate**（通过率）：生成代码在沙箱环境中无错误执行的百分比。未通过者自动得 0 分。沙箱基于 Docker 容器化（Python 3.13），预装 Matplotlib、Seaborn、Plotly、Squarify 等库，每次执行无网络访问，120 秒超时。

4.2 视觉准确性

部署**多智能体评判面板**，通过投票系统在 8 个关键维度上以 3 分制（0/1/2）评分：图表类型一致性、空间布局一致性、文本元素一致性、坐标轴配置一致性、配色方案一致性、样式格式一致性、组件完整性、数据模式一致性。对 Chart Reproduction 任务，数据模式一致性替换为**代码级数据对齐验证**（而非视觉检查）。此外还评估视觉清晰度、构图平衡性和排版质量三个设计质量指标。

4.3 评估可靠性验证

智能体间一致性：Fleiss' $\kappa = 0.824$（高稳定性）。基于 Claude-4.5-Sonnet 结果抽样 600 个任务的人类评估对比：Cohen's $\kappa = 0.83$，表明自动评估与人类专家判断强相关。各维度中 Layout 一致性最高（$\kappa = 0.99$），Color 最低但仍可靠（$\kappa = 0.72$）。

5. 实验结果

评估 14 个主流 VLM（5 个闭源 + 9 个开源），使用 greedy decoding，最大输出 32,768 tokens，结果取三次独立运行的平均值。

模型	Repl.	Repro.	Refine.	AVG
Claude-4.5-Opus	7.8	7.4	9.4	**8.2**
Gemini-3-Pro-Prev.	9.0	6.7	8.5	8.1
Claude-4.5-Sonnet	7.1	5.7	8.0	7.0
GPT-5.1	5.7	4.8	5.8	5.4
Gemini-2.5-Flash	5.2	4.8	6.0	5.3
Qwen3-VL-235B	3.3	2.4	5.1	3.6
InternVL-3.5-241B	3.5	2.5	4.3	3.4
ChartCoder	3.5	2.3	3.9	3.2
GLM-4.5V-106B	2.8	2.1	2.0	2.3
DeepSeek-VL-7B	0.4	0.3	1.4	0.7

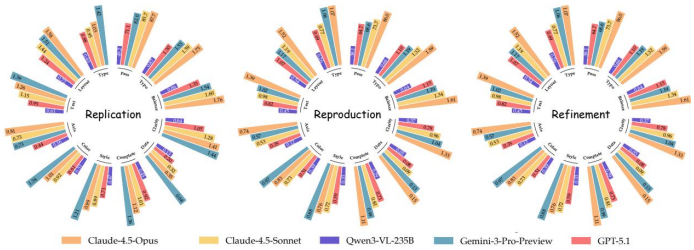

图 *2*：顶级模型在各任务和指标上的性能雷达图，涵盖 *8* 项视觉准确性指标、通过率和 *3* 项质量指标。

5.1 核心发现

发现 1：闭源与开源模型差距显著。Claude-4.5-Opus 以 AVG 8.2 领先，Gemini-3-Pro-Preview 紧随其后（8.1）。开源最优 Qwen3-VL-235B 仅 3.6，不及闭源领先者的一半。在 Chart Replication 上 Gemini-3-Pro-Preview 以 9.0 分居首，显示其强大的视觉推理能力。

发现 2：简单基准上的优异表现不能迁移至 RealChart2Code。Qwen3-VL-235B 和 InternVL-3.5-241B 在 ChartMimic 上分别达到 80.4 和 76.9 分，但在 RealChart2Code 上骤降至 3.6 和 3.4。即使是顶级闭源模型，Gemini-3-Pro-Preview 在 ChartMimic 饱和至 >96 分，但在 RealChart2Code 上性能降至约 50%。这表明现有基准的复杂度不足以区分具有真正高级视觉推理能力的模型。

发现 3：通过率差异巨大。闭源模型 Pass Rate 普遍在 64–91%，而小型开源模型（如 DeepSeek-VL-7B）仅 5.9–31.4%，反映代码生成的基本功能正确性存在根本性差距。Chart Refinement 任务通过率普遍高于其他两个任务，因为模型起始于已有代码（尽管有错误）。

6. 错误分析

对所有失败实例进行系统分类，发现四类主要错误：

开源模型主要受**语法和执行错误**困扰——频繁产生不存在的库名或无效函数调用的幻觉，导致代码直接执行失败。即使代码能执行，也常因空间推理不足产生**布局和结构失败**（子图重叠、网格定义错误等）。

闭源模型展现出稳健的代码编写能力，语法错误极少。其失败模式以**数据映射错误**为主——视觉结构正确但特定数据系列映射到错误坐标轴或视觉属性不匹配。

迭代修正中的“退行性编辑”。Chart Refinement 任务揭示了关键弱点：模型成功应用用户要求的修改后，常在**已正确的代码部分引入新错误**。即使 SOTA 模型也难以在多轮对话中平衡局部代码更新与全局一致性。

7. 跨基准性能对比分析

在 ChartMimic 和 Plot2Code 上同步评估所有模型。归一化至 0–100% 后对比显示：

- Gemini-3-Pro-Preview 在 ChartMimic 饱和（>96%），但在 RealChart2Code 降至约 50%；
- 开源模型差距更大：Qwen3-VL 在 ChartMimic 达 ∼85%，在 RealChart2Code 降至 <25%；
- Claude-4.5-Opus 在 ChartMimic（95.1）和 Plot2Code（9.0 Rating）上均表现优异，在 RealChart2Code 上也保持领先，显示其能力在复杂场景中退化最小；
- ChartCoder（专用模型）在 ChartMimic 上表现尚可（75–77），但在 RealChart2Code 上仅 3.2，说明专门化训练未能泛化至真实复杂场景。

8. 讨论与局限

核心贡献：首个系统评估大规模真实数据图表生成和多轮迭代修正的基准；揭示闭源/开源模型能力差距及错误模式差异；评估框架与人类判断强相关。

主要局限：

- 代码实现仅限于 Matplotlib，尽管其命令式特性能有效反映模型底层可视化理解和逻辑推理能力；
- 多智能体评判虽与人类高度相关，但可能遗漏细微视觉瑕疵（如轻微元素重叠、精确颜色差异）；
- 当前尚未针对 Plotly、D3.js 等交互式可视化库进行评估。

未来方向：开发自动化流水线生成高质量合成数据，以解决复杂训练样本稀缺问题，提升模型在复杂布局上的泛化能力。

KITScenes LongTail：面向长尾驾驶场景的推理轨迹数据集

Wagner⋆, Taş⋆, Villa, Hauser, Shen, Steiner 等 — KIT, FZI, UC3M, TU Madrid, UofT, TU Delft, 2025

1. 动机与核心贡献

自动驾驶在感知层面已取得显著进展，但在**长尾场景**（施工区、恶劣天气、道路封闭、事故等罕见事件）中的决策泛化仍是根本性挑战。现有数据集（nuScenes、Waymo 等）主要面向感知任务，缺乏对规划与推理的系统支持。同时，大语言模型（LLM）的进步使得上下文泛化和可解释推理成为可能，语言成为表达目标、约束和决策理由的自然媒介。

本文引入 **KITScenes LongTail** 数据集，专注于端到端驾驶中的长尾事件，提供多视角视频、轨迹、高层指令和**多语言专家推理轨迹**（英语、西班牙语、中文），支持 in-context learning 和 few-shot 泛化。三大核心贡献：

- 长尾驾驶场景数据集：多视角视频（360° FoV）、高层驾驶指令、领域专家标注的多语言推理轨迹；
- **语义一致性度量**：量化推理轨迹中描述的驾驶动作与预测轨迹之间的匹配程度；
- **多操作评分（MMS）**：覆盖多种可行操作、驾驶舒适性和指令遵循的轻量级评价指标。

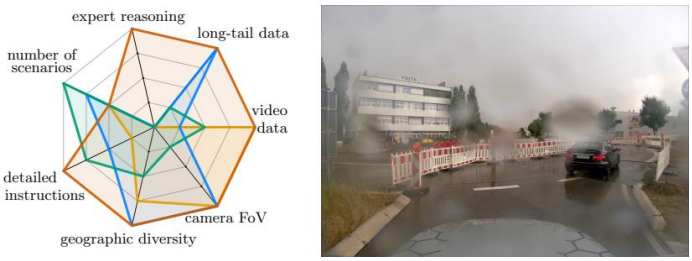

图 1：左：各数据集优劣对比。中：长尾场景示例（施工区 + 雨天）。右：对应专家推理轨迹的起始部分。

2. 相关工作与定位

2.1 现有数据集的局限

KITTI、nuScenes、Waymo Open、Argoverse 2 等经典数据集实现了多传感器、多城市的 360° 覆盖，但主要面向感知（检测、跟踪、预测），对行为泛化和罕见事件提供有限支持。DriveLM-Data 使用规则/人工 Q&A 标签但依赖 ChatGPT-3.5 评测语义对齐（可解释性差、计算昂贵）；CoVLA-Dataset 使用 VLM 自动生成行为描述，存在模型坍缩风险。两者均仅对单一专家轨迹评估，忽略驾驶的多模态性。

2.2 端到端驾驶基准

nuScenes 评估协议计算对专家轨迹的 L_2 误差和碰撞率（非反应式、单一操作）；NAVSIM 引入非反应式仿真指标（进度、碰撞时间）；Bench2Drive 基于 CARLA 反应式仿真（但存在域差距）；Waymo Open E2E 聚焦长尾但不提供视频数据和推理轨迹。本数据集在表 1 中的对比显示，它是唯一同时具备长尾数据、专家推理、多操作评估、舒适度评估、真实视频和细粒度指令的数据集。

3. 数据集构建

3.1 场景收集与分布

数据收集历时两年（始于 2023 年末），覆盖卡尔斯鲁厄、海德堡、曼海姆及黑森林地区的城市、郊区和高速公路环境。路线特意包含大量施工区和交叉口，并筛选恶劣天气、道路封闭、事故等罕见事件。总计 **1000 个 9s 场景**，划分为训练集（500）、测试集（400）和验证集（100）。

场景类型分布大致均匀，包括：施工区、超车、交叉口、夜间、大雨、降雪以及特殊选定场景。采用 **Pareto 原则**确定长尾边界——以 nuScenes 为参考，用秩-频率图和 80% 累积频率阈值划分。nuScenes 中约 88% 场景为白天拍摄，因此夜间为长尾；直行和常规转弯占约 90%，超车和变道属于长尾。此外保留交叉口名义驾驶以更好评估指令遵循。

3.2 多视角视频与帧级拼接

提供 360° 水平视场、六个视角的多视角视频数据。两种图像格式：原始（3200×2200px）和 pinhole（3488×2272px，兼容 ViT 的 16×16 分块），帧率 5Hz，视频长度 4s。帧级拼接方法采用**渐进式图像畸变**生成 360° 视图（5746×512px）：将图像分为垂直段，对每段应用单应性与恒等变换的混合，而非单一全局单应性，实现平滑过渡。

3.3 高层驾驶指令

所有指令由领域专家人工标注。分布：直行 45.2%、右转 14.5%、左转 6.2%、使用右车道 7.7%、使用左车道 6.5%、超车 13.6%。超车指令具有细粒度表述（如 “超越右侧行驶的卡车”），远优于 Bench2Drive/Waymo Open E2E 的 {left, right, straight} 三选一。特殊场景中指令可能**无法执行**（对向来车、障碍物等），用于测试模型的上下文感知能力。

3.4 多语言推理轨迹

邀请具有不同文化背景的自动驾驶领域专家标注。专家回答五个问题：问题 1 为开放式（描述驾驶场景中的观察）；问题 2–3 针对 0–3s 内的转向和加速原因；问题 4–5 针对 3–5s 内的转向和加速原因。加速/转向命令通过启发式分类为轻微/强烈加减速、保持速度以及轻微/大幅左右转向或直行。

标注语言为专家母语或流利语言（英语、中文、西班牙语），以捕捉最直觉的推理。受 Molmo 等工作启发，允许口述后用 Whisper 转录，但最终由专家自行选择口述或书写。这种结构化多语言方法确保了全面且文化多元的驾驶动作解释。

4. 评价指标

4.1 语义一致性度量

使用 **Rocchio 分类器**和句子嵌入度量推理轨迹与规划轨迹之间的语义一致性。具体方法：对规划轨迹用相同启发式分类驾驶动作，使用 EmbeddingGemma 0.3B 生成推理轨迹的嵌入，然后进行 Rocchio 分类：

$$\hat{y} = \arg\max_{c \in \mathbf{C}} \cos(z, \mu_c)$$

其中 $\mathbf{C}$ 为所有驾驶动作类别，z 为嵌入，μ_c 为类别 c 的参考嵌入。语义一致性分数为推理轨迹预测的动作 $\hat{y}$ 与轨迹导出动作匹配的比率。该方法对同义词鲁棒（如 “保持当前速度” vs “维持速度”），优于 BLEU 等传统指标。

4.2 多操作评分（MMS）

L_2 误差仅对单一专家轨迹评估，忽略驾驶的多模态性。反应式仿真在短时间视界（< 5s）内因人类反应时间而非必要。本文提出 MMS，一种**轻量级、可复现**的评价方案。

每个场景提供 5 类共 3 条参考轨迹：（1）**专家级轨迹**（基准分 10）；（2）**速度错误**（±20% 速度扰动，基准分 7）；（3）**忽略指令**（合理但不遵循指令，基准分 4）；（4）**驶离道路**（基准分 1）；（5）**碰撞**（基准分 0）。

舒适性惩罚 CP $\in \{0, 1, 2\}$：基于 jerk（急动度）和 tortuosity（曲折度）相对于参考轨迹的偏离。Jerk 计算为 $\frac{1}{T}\sum_t \|\Delta^3 Y_{t,:}/\Delta t^3\|$；tortuosity 为路径长度与端点距离之比 $\sum_{t=2}^{T} \|Y_{t,:} - Y_{t-1,:}\| / \|Y_{T,:} - Y_{1,:}\|$。阈值分别为 44%（jerk）和 6%（tortuosity），基于数据集统计的标准差/均值比。

轨迹相似性采用 Ettinger 等人的速度依赖阈值 miss rate 方法计算横向和纵向相似度 sim。最终 MMS 由四种情况确定：（1）与过去轨迹不一致则为 0；（2）匹配碰撞/驶离道路参考（$s \geq 0.4$）则取参考分数；（3）匹配好/可接受行为则取 $s \cdot \mathrm{MMS}_{\mathrm{ref}}$（下限 $3.5 - \mathrm{CP}$）；（4）未匹配任何参考则为 $3.5 - \mathrm{CP}$。

5. 实验结果

5.1 MMS 与 L_2、DrivingScore 的关系

在 Bench2Drive 场景上使用 SimLingo 录制数据验证。结果表明 MMS 与闭环 DrivingScore (DS) 的 Pearson 相关性为 $r = 0.59$，远高于 L_2 与 DS 的相关性（$r = -0.45$）。MMS 还能正确惩罚大幅摇摆的轨迹。

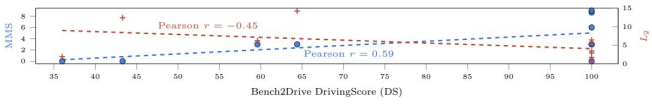

图 2：*MMS* 与 L_2 分别对 *DrivingScore* 的相关性。*MMS*（$r = 0.59$）显著优于 L_2（$r = -0.45$）。

5.2 端到端驾驶评估

评估模型包括开源 VLM(Pixtral 12B、Gemma 3 12B、Qwen3-VL 8B)、闭源模型（Gemini 3 Pro、Gemini Robotics ER 1.5、GPT-5）以及经典端到端模型（UniAD、DMAD）。

Zero-shot：闭源模型和经典端到端模型显著优于开源 VLM。Gemini 3 Pro 取得最高 MMS（avg 4.99），GPT-5 次之（4.48）。开源 VLM 表现较差（Pixtral 仅 0.05，Qwen3-VL 1.18，Gemma 3 1.11）。

Few-shot：开源模型性能**大幅提升**——Pixtral 0.05 → 4.12、Qwen3-VL 1.18 → 4.14、Gemma 3 1.11 → 3.95。

Few-shot CoT：直接 CoT 反而**降低**了开源模型的表现（Pixtral 4.12 → 3.36、Qwen3-VL 4.14 → 3.47）。作者将此归因于**上下文-记忆冲突**：预训练/指令微调阶段的推理轨迹集中于数学和编程，与驾驶动作推理存在域差距。

Few-shot CoT + 运动学模型：使用简单自行车运动学模型将 CoT 推理中的驾驶动作（10 种离散加速度 + 10 种转向角，速度依赖）转换为轨迹。结果**显著最优**——Gemma 3 达到 4.61（所有开源设置最高），Qwen3-VL 4.47，Pixtral 4.27。这证明推理轨迹中的驾驶动作描述确实包含有价值的决策信息。

所有模型在**夜间场景**表现最好，在**降雪、交叉口和特殊选定场景**上最差。交叉口性能差可能因可行轨迹更多导致指令遵循困难（大多 MMS 约为 4，即“忽略指令”级别）。

5.3 语义一致性分析

对 CoT 推理输出的分析显示，语义一致性普遍**较低**：Qwen3-VL 平均 0.51、Gemma 3 0.30、Pixtral 0.27。即 49%–73% 的场景中，推理轨迹描述的动作与规划轨迹不匹配。加速一致性（0.32–0.83）高于转向一致性（0.12–0.22），表明模型对转向决策的语义表达尤为薄弱。

进一步分析 Gemma 3 发现：中间推理轨迹中描述的驾驶动作**比最终规划轨迹更接近专家轨迹**——模型“知道该怎么做”但“做不到”。这直接启发了运动学模型方案的设计，即信任推理中的动作描述而非模型直接输出的轨迹。

5.4 多语言推理的影响

Gemma 3 12B 在英语、西班牙语、中文三种 CoT 推理下的 MMS 分别为 3.80、3.66、3.55。英语略优（可能因预训练数据偏差），但差异不大，表明多语言推理均能提供有效的驾驶决策支持。

6. 讨论与局限

核心发现：（1）Zero-shot 在长尾场景中表现脆弱，few-shot 显著改善规划质量；（2）CoT 推理与最终轨迹的低语义一致性揭示了当前 VLM 的域泛化瓶颈；（3）运动学模型桥接推理与规划的方法简单有效；（4）MMS 比 L_2 更好地反映实际驾驶质量。

未来方向：

- 基于 RL 的微调（如 DeepSeek-R1、OpenAI o1 方法）联合优化运动轨迹和推理轨迹；
- 研究不同推理风格/语言的微调是否提升特定场景性能；
- 评估世界模型（如 VL-JEPA）的内部表征是否带来更扎实的长尾推理；
- 比较 AI 推理轨迹与人类专家推理的相似度，推进可解释性研究；
- 扩展至更大规模视觉-语言-动作模型的评估。

局限性：数据集规模（1000 场景）相对有限；地理覆盖集中于德国西南部；推理轨迹标注受限于三种语言；MMS 为非反应式评估，对长时间视界场景可能不足；运动学模型方案依赖离散化动作空间，精度受限。

Natural-Language Agent Harnesses：自然语言智能体控制框架

Pan[1], Zou[2], Guo[1], Ni[1], Zheng[1]* — [1] 清华大学深圳国际研究生院, [2] 哈尔滨工业大学（深圳）, 2026

1. 问题动机与背景

现代智能体（Agent）的成败越来越取决于其**控制框架（Harness）**——管理多步推理、工具调用、记忆、委托和终止的编排层，而非单次模型调用。已有研究表明，reason–act 循环、检索增强生成（RAG）、自反馈（Reflexion）等外部化控制模式对性能具有决定性影响。然而，当前控制框架设计存在根本性问题：

- **不可移植**：控制逻辑分散在控制器代码、框架默认值、工具适配器、验证脚本和运行时特定假设中，难以跨运行时迁移；
- **不可比较**：两个系统名义上仅差一个设计决策，实际却同时在 prompt、工具中介、制品约定、验证门和状态语义上存在差异，导致评估退化为控制器捆绑包比较而非模块级证据；
- **不可消融**：控制逻辑的隐式性使得清晰的模块消融极为困难。

动机来源： AGENTS.md 和 AgentSkills 等自然语言制品表明，实用系统可以将仓库级约定和可复用流程打包为可移植文本。近期工作进一步将技能视为可从经验创建、可进化、可评估的对象。然而这些工作建立的是可复用控制知识的可行性，而非显式可执行的控制框架表示——它们不将框架级契约、角色边界、状态语义、失败处理和运行时适配器作为一等公民在共享运行时下联合执行。

核心问题： 智能体控制框架的高层控制逻辑能否被外部化为一个**可移植、可执行**的制品？

2. 方法论

2.1 控制框架与模式层

本文将 harness 定义为管理任务族多次模型/智能体调用的编排层，包含三个维度：(i) **控制**：工作分解与调度；(ii) **契约**：必须产出的制品、必须满足的验证门、终止规则；(iii) **状态**：跨步骤、分支和委托工作者持久化的内容。Harness 与 runtime 的边界是分析性的——通用服务（工具适配、沙箱、子生命周期）归运行时，任务族策略（阶段、制品契约、验证器）归 harness。

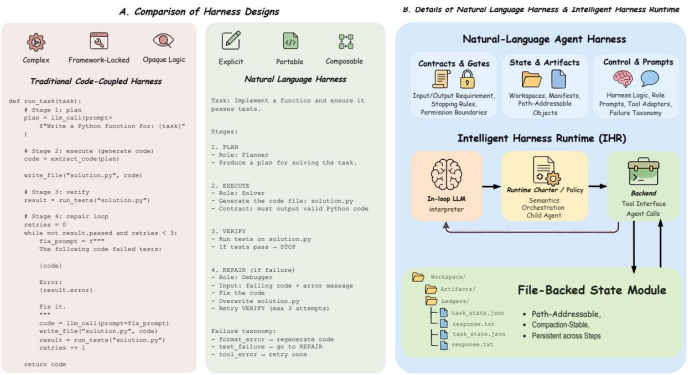

图 1：框架总览。*IHR* 包含 *in-loop LLM*、带工具和子智能体支持的后端、以及定义策略语义的运行时宪章，执行以自然语言表达控制逻辑的 *NLAH*。

2.2 智能运行时 IHR

由于 NLAH 以自然语言编写，执行需要解释。IHR 将 LLM 置于运行时循环内：每一步读取 (i) harness 文本、(ii) 当前状态与环境、(iii) 运行时宪章，然后选择符合契约和预算的下一步动作。IHR 分解为三个组件（图 1）：

- **In-loop LLM**：解释 harness 逻辑并驱动决策；
- **后端**：提供终端工具和一等多智能体接口（如 `spawn_agent`, `wait_agent`）；
- **运行时宪章**：定义契约、状态、编排和子生命周期的语义。

从模型调用到智能体调用。 将单次补全提升为受显式执行契约约束的智能体调用：任务 $T = (p, F_{\text{in}}, \kappa)$，其中 p 为任务提示，F_{in} 为输入资源，κ 为执行契约（必需输出、预算、权限范围、完成条件、输出路径）。智能体调用：$\text{AgentCall}(T, \Omega_t^{\text{in}}) = (A_t, \Delta\Omega_t, y_t)$，返回制品集、环境修改和规范化响应。

2.3 自然语言智能体控制框架 NLAH

NLAH 是面向 IHR 执行的结构化自然语言 harness 表示，**不替代**底层确定性代码，而是承载可编辑、可审查的编排逻辑。其核心组件：

- **契约**：输入输出要求、格式约束、验证门、权限边界、重试/终止规则；
- **角色**：角色 prompt（求解器、验证器、研究员、编排器），职责不重叠；
- **阶段结构**：显式工作拓扑（如 plan → execute → verify → repair）；
- **适配器与脚本**：确定性动作的命名钩子（测试、验证器、检索、解析）；
- **状态语义**：跨步骤持久化的内容（制品、账本、子工作区）及重新打开方式；
- **失败分类**：驱动恢复的命名失败模式（缺失制品、路径错误、验证失败、工具错误、超时）。

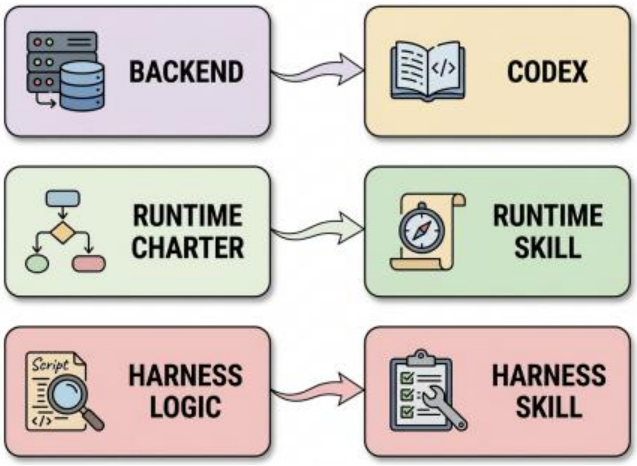

图 2：实例化映射：后端 + 运行时技能（宪章）+ *Harness* 技能（任务族逻辑）。

2.4 文件支持的状态模块

长期自主执行在关键状态隐式或短暂时会失败。该可选模块将持久状态外部化为路径可寻址制品，强制三个属性：**外部化**（状态写入制品而非仅存于短暂上下文）、**路径可寻址**（后续阶段通过路径重新打开精确对象）、**压缩稳定**（状态在截断、重启和委托下存活）。规范工作区包含 `TASK.md`、`RESPONSE.md`、`task_history.jsonl`、子工作区等。

3. 实验设计

3.1 三个研究问题

RQ1（行为效应）：在固定预算下，共享运行时宪章和基准特定 harness 逻辑如何改变智能体行为与任务结果？**RQ2（可组合性）**：模式显式化后，模块能否在模式层面组合与消融？**RQ3（迁移）**：原生代码 harness 与重构的自然语言 harness 在共享运行时下有何差异？

3.2 实例化与基准

后端使用 Codex CLI v0.114.0 + GPT-5.4（reasoning effort: xhigh），Ubuntu 24.04，每任务容器限制 32 vCPU / 84 GiB / 40 GiB 存储。**编程基准**：SWE-bench Verified（125 样本），研究 TRAE 风格多候选搜索和 Live-SWE-Agent 两种 harness 族。**计算机使用基准**：OSWorld（36 样本），研究 OS-Symphony harness。

4. 实验结果

4.1 RQ1：行为效应

Harness	Setting	Perf.	Prompt	Tool	Time
TRAE	Full IHR	74.4	16.3M	642.6	32.5
	w/o RTS	76.0	11.1M	451.9	16.6
	w/o HS	75.2	1.2M	51.1	6.7
Live-SWE	Full IHR	72.8	1.4M	58.4	7.6
	w/o RTS	76.0	1.1M	41.0	5.5
	w/o HS	75.2	1.2M	51.1	6.7

关键发现 1：过程指标变化远大于解决率。SWE-bench 上 TRAE 和 Live-SWE 解决率在窄带内波动（72.8–76.0），但 Full IHR 的 token 消耗、调用次数和运行时间远超消融版本。TRAE Full IHR 约 **90% 的 prompt token、completion token、工具调用和 LLM 调用**发生在委托的子智能体中（而非父线程），体现多阶段探索、候选比较、制品交接和额外验证。

关键发现 2：多数实例不翻转。125 个 SWE 样本中超过 110 个在 Full IHR 和各消融间一致。Full IHR 更像**解决集替换器**而非均匀前沿扩展器——创造部分独有胜利，但也丧失轻量设置保留的直接路径修复。最有信息量的失败是**对齐失败**：harness 重塑局部成功信号的方式并不总与基准接受条件一致。

4.2 RQ2：模块组合与消融

Bench	Basic	F-State	Evid.	Verif.	S-Evol.	M-Cand.
SWE	75.2	76.8	76.8	74.4	**80.0**	72.8
OSW	41.7	47.2	41.7	33.3	44.4	36.1

模块效果集中在小规模可解前沿而非均匀移动整个基准。模块分为两大类：

改善求解循环的模块。**Self-evolution**（自进化）效果最显著（SWE: +4.8, OSW: +2.7），其主要收益并非开放式反思，而是**更有纪律的接受门控尝试循环**——在失败信号明确之前保持窄搜索。File-backed state（SWE: +1.6, OSW: +5.5）和 evidence-backed answering 主要改善过程结构——留下持久外部签名（任务历史、清单、分析旁文件），提升可审计性和交接纪律。

结构不等于性能的模块。Verifier（SWE: −0.8, OSW: −8.4）和 multi-candidate search（SWE: −2.4, OSW: −5.6）表现消极。Verifier 的典型失败模式：验证器级接受可能与基准级接受产生偏差（如 sympy__sympy-23950 验证器报告 “solved” 但官方评估器仍失败）。Multi-candidate search 在当前预算下开销过重。**核心洞察**：显式模块在收紧中间行为到评估器接受条件路径时有帮助，在仅添加局部过程层（其成功概念与最终基准弱对齐）时效果有限。

4.3 RQ3：代码到文本的 Harness 迁移

Harness	实现	Perf.	Prompt	Tool	Time
OS-Sym	Code	30.4	11.4M	651	361.5
OS-Sym	NLAH	**47.2**	15.7M	683	140.8

OS-Symphony 在 OSWorld 上的配对迁移研究显示：迁移后 NLAH 实现达到 **47.2 vs. 30.4**，不仅数值更优，行为差异更为深刻：

- **可靠性机制重定位**：原生代码 harness 将控制外部化为截图驱动的修复循环（验证前一步、检查当前屏幕、选择下一个 GUI 动作），而 NLAH 重新围绕文件支持的状态和制品支持的验证组织——运行生成任务文件、账本和显式制品，更易从脆弱的 GUI 修复切换到文件/shell/包级操作；
- **搜索功能保留但拓扑重定位**：搜索从辅助子智能体分支变为带内运行时支持；
- **验证强化**：原生轨迹常在屏幕合理性处停止，迁移后运行更多以路径可寻址证据（写入文件、重新打开文档、包级对象、系统查询）收束。

案例佐证：系统配置任务中，原生运行陷入 GUI 焦点修复，NLAH 切换到 shell 端配置并在显式 sshd 验证后关闭。电子表格任务中，原生运行达到视觉进展但未能稳健关闭，迁移 harness 确定性地写入目标制品并在完成前重新打开验证。演示文稿任务中，原生 harness 挣扎于对象绑定和拖拽控制，迁移 harness 直接编辑.pptx 包并验证生成的幻灯片制品。

5. 讨论

代码 vs. 自然语言。本文不主张自然语言应替代代码。自然语言承载可编辑的高层 harness 逻辑，代码负责确定性操作、工具接口和沙箱执行。科学主张在于比较单元：将 harness 模式逻辑外部化为可读、可执行对象。

自然语言的持续价值。一个自然的担忧是更强的基础模型是否会降低自然语言控制的价值。实验支持不同解读：当自然语言用于指定 harness 级控制（角色、契约、验证门、持久状态语义、委托边界）而非仅一次性 prompt 措辞时，其价值依然重要。

Harness 表示搜索。一旦 harness 成为显式对象，即成为搜索空间——可手动设计、检索、迁移、重组合和系统消融。长远来看，这暗示对 harness 表示的自动搜索与优化，使 harness 工程成为更受控的科学对象。

6. 局限性与未来方向

- 自然语言精确度低于代码，依赖隐藏服务端状态、专有调度器或训练诱导行为的机制无法从文本忠实恢复；
- **运行时污染**：强共享运行时宪章可能吸收本应归因于 harness 文本的部分行为；
- 模块消融并非严格因果识别，文本表示引入指令显著性和 prompt 长度等混杂因素；
- 当前结果基于预算限制下的基准子集（SWE 125 / OSWorld 36 样本),完整基准结果待后续使用 GPT-5.4-mini 补充；
- 可移植 harness 逻辑可能降低传播风险工作流的门槛，部署需结合来源追踪、审查、权限控制和沙箱隔离；
- 未来方向包括自动化 harness 搜索与优化，以及将 harness 工程发展为 **harness 表示科学**。

Know3D：利用视觉-语言模型知识引导 3D 生成

Chen*, Chen*, Li, Wang, Jia, Zheng, Jia, Liu†, Wang† — 北京大学, Math Magic, 香港科技大学, 大连理工大学, 2026

1. 问题动机与背景

单视图 3D 生成是一个本质上**病态问题**（ill-posed）：输入图像仅包含可见部分的信息，不可见区域的合成依赖模型内化的先验知识。现有方法面临两个关键失败模式：

- **语义偏离**：生成的不可见区域偏离用户的创意或语义意图，模型无法将未观测区域的合成与用户指定的语义约束对齐；
- **结构不合理**：生成的几何结构违反基本的语义常识约束（如咖啡杯背面缺少把手）。

根本原因在于 **3D 训练数据的匮乏**。与互联网规模的图像、文本、视频数据相比，3D 数据集（Objaverse、TexVerse 等）在数量和多样性上均有限。因此 3D 生成模型内化的世界知识和结构常识自然受限，且高质量的语义对齐文本-3D 配对数据更加稀缺。

现代视觉-语言模型（VLMs）已从互联网规模的多模态数据中学习到丰富的语义知识和常识推理能力。如果这些知识能有效迁移到 3D 生成模型中，将为推断未观测结构提供宝贵指导。然而，直接注入 VLM 知识面临挑战：

- **自回归方式**（Shape LLM 类方法）：直接用 LLM/VLM 以自回归方式生成 3D 表示，性能不及专用 3D 生成模型，且破坏了预训练的语义能力；
- **直接特征注入**：VLM 表征高度抽象，缺乏显式几何基础，与 3D 形状合成所需的空间结构化特征空间不对齐。

Know3D 提出一种新框架：利用**多模态扩散模型作为中间桥梁**，将 VLM 的语义知识翻译为图像空间的结构先验，从而实现语义可控的 3D 生成。

2. 系统架构

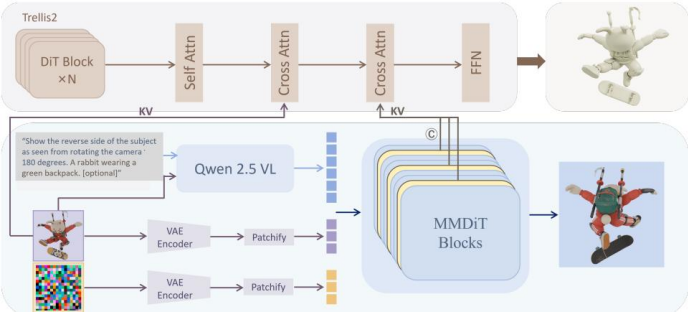

图 1：*Know3D* 整体架构。*Qwen2.5-VL* 编码多模态输入引导去噪过程，*MMDiT* 中间层隐藏状态作为条件信号注入 *3D* 生成模型。

如图 1 所示，Know3D 由两个核心模块组成：（1）语义感知的前-后视图生成；（2）基于 VLM 知识的 3D 生成引导。

2.1 语义感知的前-后视图生成

基础模型选择。采用 Qwen-Image-Edit-2511 作为基础，该模型集成了 Qwen2.5-VL（负责语义理解）和 Diffusion Transformer（DiT，负责图像生成）。尽管该模型已具备强语义理解能力，但存在两个不足：（1）空间感知能力差，无法准确理解"背面视图"概念；（2）常改变主体的原始姿态。因此需要微调以增强空间感知的稳定性。

数据集构建。从高质量 3D 资产中渲染前-后视图对。对每个资产均匀采样 $2N$ 个方位角视图，选取 N 个前视图并与其对面视图配对形成 $(I_{\text{front}}, I_{\text{back}})$。为每对标注背面显著组件的文本描述集 $D = \{d_1, d_2, \ldots, d_m\}$，使用 VLM 生成初始部件级描述后人工修正。

随机提示策略。构建条件提示 $P = P_{\text{view}} \oplus P_{\text{back}}$，其中 P_{view} 是固定的 180° 相机旋转描述，P_{back} 以概率 0.5 从描述集 D 中随机采样。这一策略使模型同时学习无条件背面生成和语义控制生成。

训练目标。基于条件流匹配（CFM）目标。从 VLM 提取多模态隐藏状态 $H_{\text{vlm}} = \text{Qwen2.5-VL}(I_{\text{front}}, P)$，通过 VAE 编码器获取空间潜变量 $Z_{\text{front}} = \mathcal{E}(I_{\text{front}})$。给定噪声潜变量 $Z_t = (1-t)Z_{\text{back}} + t\epsilon$，优化速度场估计器：

$$\mathcal{L}_{\text{CFM}}(\phi) = \mathbb{E}_{t, Z_{\text{back}}, \epsilon} \| v_\phi(Z_t, t, H_{\text{vlm}}, Z_{\text{front}}) - (\epsilon - Z_{\text{back}}) \|_2^2$$

2.2 基于 VLM 知识的 3D 生成引导

核心发现：MMDiT 中间层隐藏状态的优越性。作者对比了三种特征表示方式：（1）完全去噪的 VAE 潜变量；（2）将 VAE 潜变量解码为图像后经 DINOv3 提取特征；（3）去噪过程中 MMDiT 中间层隐藏状态。实验表明，**MMDiT 隐藏状态**同时具备强空间感知和丰富语义信息，能最佳引导 3D 生成。理想特征应具备：充分的空间感知以促进 3D 模型学习，以及一定程度的语义感知和鲁棒性。

知识提取与注入。Qwen2.5-VL 编码前视图和文本提示为高级语义特征，VAE 编码器提取视觉特征。经完整迭代去噪后，从 n 个 MMDiT 层（第 20、30、40 层）在特定去噪时间步 t 提取中间隐藏状态，沿通道维度拼接形成结构-语义条件信号：

$$H_{\text{DiT}} = \text{Concat}(h^{(1)}, h^{(2)}, \ldots, h^{(n)})$$

并行交叉注意力分支。基于 TRELLIS2 设计并行交叉注意力分支注入 H_{DiT}。保留骨干网络原有的自注意力和图像条件交叉注意力层不变，避免干扰预训练的 3D 生成先验。H_{DiT} 经线性投影和层归一化后作为新交叉注意力层的键和值，输出经零初始化线性层缩放以确保训练稳定：

$$F_{\text{sa}} = \text{Self-Attn}(F)$$
$$\Delta F_{\text{img}} = \text{Cross-Attn}(F_{\text{sa}}, F_{\text{img}}, F_{\text{img}})$$
$$\Delta F_{\text{dit}} = \text{ZeroLinear}(\text{Cross-Attn}(F_{\text{sa}}, H'_{\text{DiT}}, H'_{\text{DiT}}))$$
$$F_{\text{out}} = F + \Delta F_{\text{img}} + \Delta F_{\text{dit}}$$

两阶段 3D 几何生成。遵循 TRELLIS2 的两阶段范式：第一阶段生成粗稀疏结构 V_{ss} 建模全局拓扑先验，第二阶段恢复高保真精细几何 V_{geo}：

$$V_{\text{ss}} = D_{\text{ss}}(G_{\text{ss}}(z, \tau, F_{\text{front}}, H_{\text{DiT}}))$$
$$V_{\text{geo}} = D_{\text{geo}}(G_{\text{geo}}(z, \tau, F_{\text{img}}, H_{\text{DiT}} \mid V_{\text{ss}}))$$

两阶段均采用 CFM 目标优化：$\mathcal{L}_{3D} = \mathbb{E}_{\tau, x_0, \epsilon} \| v_\theta(x_\tau, \tau, F_{\text{img}}, H_{\text{DiT}}) - (\epsilon - x_0) \|_2^2$。

3. 实验设置与训练细节

数据集。前-后视图生成训练使用 TexVerse 中 5k 高质量 3D 资产，FoV 从 $\{35°, 50°, 85°, 105°, 135°\}$ 中采样，仰角从 $[-15°, 45°]$ 中采样，每个 mesh 渲染 12 个均匀方位角视图形成 6 个前-后对。3D 生成训练使用 TexVerse 60k mesh，每个 mesh 渲染无扰动集（45° 间隔，4 对）和扰动集（随机 FoV 缩放和角度偏移，4 对）。

训练策略。前-后视图生成阶段：以 LoRA（rank=64）微调 Qwen-Image-Edit-2511 的所有可训练注意力层，学习率 1e-4，全局批量 32，32×A800 GPU 训练 20k 迭代。3D 生成阶段：冻结 Qwen-Image-Edit 参数以保留泛化视觉先验，TRELLIS2 网络以 LoRA（rank=64）微调，新增条件层全量微调，学习率 1e-4，全局批量 64，32×A800 GPU 训练 70k 迭代。MMDiT 特征取第 20/30/40 层隐藏状态沿通道拼接。

4. 实验结果

4.1 与基线方法的定量比较

在 HY3D-Bench 上与单视图和多视图方法对比，使用 ULIP 和 Uni3D 衡量图像与生成 mesh 的语义一致性。

Model	test		val	
	ULIP	Uni3D	ULIP	Uni3D
Direct3D-S2	.2034	.3292	.2040	.3303
Hi3DGen	.2082	.3206	.2030	.3213
Step1X-3D	.2068	.3233	.2033	.3265
TRELLIS	.2143	.3421	.2133	.3464
TRELLIS.2	.1948	.3308	.1967	.3358
HY3D-2MV	.2108	.3413	.2111	.3400
HY3D-2.1	.2140	.3434	.2122	.3433
Know3D	**.2174**	**.3518**	.2127	**.3512**

Know3D 在 test 集上 ULIP 达到 **0.2174**，Uni3D 达到 **0.3518**，均为最优。val 集上 Uni3D 同样最优（**0.3512**）。与

直接使用合成视图作为多视图输入的 Hunyuan3D-2mv 相比，Know3D 在 ULIP 和 Uni3D 上均表现更好，验证了知识提取与注入设计的有效性。

几何质量对比（Table 4）。在 HY3D-Bench 上进一步评估几何和背面法线图质量。Know3D 在 test 集上达到 PSNR **16.038**、SSIM **0.752**、LPIPS **0.190**、CD **0.0574**，全面优于 TRELLIS.2（PSNR 14.185, CD 0.0635）和 Hunyuan3D-2mv（PSNR 15.035, CD 0.0637）。

4.2 背面语义可控性

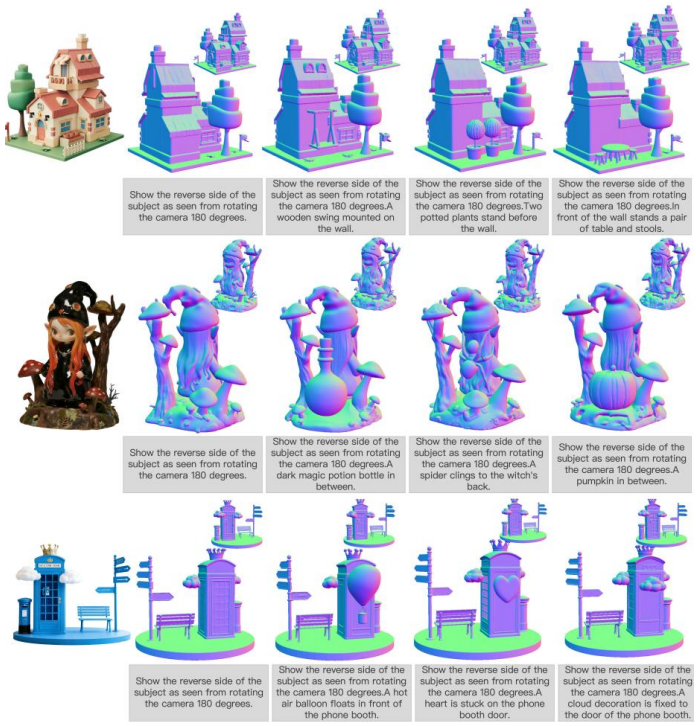

图 2：背面语义控制可视化。最左列为输入前视图，其余列展示不同文本提示下的背面法线图渲染。

如图 2 所示，Know3D 的核心优势在于通过自然语言指令语义控制背面内容。无约束情况下即可生成几何合理且与前视图语义一致的背面结构；在不同文本提示下，可灵活修改未见背面内容，同时保持与前视图的几何一致性。例如，对同一把椅子输入，可通过不同提示生成带靠垫/无靠垫/镂空花纹等多种背面设计。

4.3 与多视图基线的对比

Hunyuan3D-2mv 直接将合成的背面图像作为多视图输入，虽然在条件视角上实现了合理对齐，但在新视角下产生扭曲和不合理的几何结构。Know3D 通过隐藏状态注入而非直接像素级图像输入，保持了结构一致性——即使 Qwen-Image 生成的背面图像存在瑕疵，MMDiT 隐藏状态仍能提供合理的结构-语义引导。

5. 消融实验

5.1 MMDiT 去噪时间步的影响

评估从不同时间步 $t \in \{0, 0.25, 0.5, 0.75\}$ 提取 MMDiT 隐藏状态的效果：

Timestep t	IoU ↑	CD ↓
0.0	0.343	—
0.25	**0.352**	**2.262**
0.5	0.349	—
0.75	0.336	2.452

$t = 0.25$ 取得最佳综合性能（最高 IoU、最低 CD）。假设在此中间阶段，MMDiT 已解析出全局布局和核心语义组件：更早时间步的特征侧重低级像素细节，与 3D 结构先验对齐较差；更晚阶段受噪声干扰增大，引导可靠性降低。

5.2 不同特征表示的比较

Feature Source	IoU ↑	CD ↓
VAE encoder	0.308	2.803
DINOv3	0.342	2.385
MMDiT (t=0.25)	**0.352**	**2.262**

MMDiT 隐藏状态在两项指标上均大幅领先。VAE 潜变量性能最差（IoU 仅 0.308），因其主要为像素级重建优化，丢弃了高级语义和结构线索。DINOv3 特征虽优于 VAE，但当 Qwen-Image 生成不合理的背面图像时，DINOv3 倾向于拟合错误结果。而 MMDiT 隐藏状态仍能生成合理结果，表明其不仅具有强 3D 感知能力，还蕴含丰富语义信息——对错误生成具有**鲁棒性**。

6. 与相关工作的对比

vs. 原生单视图 3D 生成（TRELLIS、Hunyuan3D-2.1 等）：这些方法仅能复制可见前视图，背面生成完全随机且不可控。Know3D 首次实现了通过自然语言控制背面语义。

vs. Text-to-3D 方法（DreamFusion 等）：基于分数蒸馏的方法可控性和细粒度几何精度仍不及图像引导方法；原生 text-to-3D 方法也无法实现对特定未观测区域的精细语义控制。

vs. Shape LLM 方法（MeshLLM、LLaMA-Mesh 等）：受限于表示分辨率，无法实现高保真 3D 内容生成，且自回归范式破坏了预训练语义能力。

vs. 统一多模态模型（Janus-Pro、Show-o 等）：3D 生成领域缺乏大规模多模态预训练数据，Know3D 通过扩散模型桥梁而非直接端到端训练，巧妙利用了 2D 领域已有的大规模预训练成果。

7. 局限性与未来方向

- **基础模型依赖**：生成资产的结构鲁棒性受底层多模态基础模型影响。当基础模型无法完全理解指令时，3D 生成仍会被误导至错误形状（如将”背面有拉链”误解为”背面有两条带子”）；
- **潜在改进方向**：采用更强的 MLLM，或探索更有效的多模态引导和信息注入方式；
- **当前评估范围**：主要在 HY3D-Bench 上评估，更广泛场景（如复杂多物体场景、极端视角）的泛化能力有待验证；
- **仅控制背面**：当前框架聚焦于背面视图的语义控制，扩展至任意未观测视角的控制是自然延伸方向；
- **核心贡献**：首次将传统随机的背面”幻觉”过程转变为语义可控过程，证明 MMDiT 中间层隐藏状态蕴含丰富的 3D 结构和语义先验，为知识驱动的 3D 生成开辟了新方向。

Sommelier：面向全双工语音语言模型的可扩展开源多轮音频预处理流水线

Jung[1,2], Kim[1,2], Kim[2], Kim[2], Choo[1†], Park[1,2†] — [1]KAIST AI, [2]NAVER Cloud, 2025

1. 动机与问题定义

随着 AI 范式从文本 LLM 向语音语言模型（SLM）演进，**全双工**（full-duplex）系统——即同时听与说的实时自然人机交互——成为核心需求。然而现有系统仍以半双工（turn-based）级联 ASR→LLM→TTS 流水线为主，固有延迟高、丢失副语言线索（语气、情感）、且难以处理打断、重叠语音和反馈语（backchannel）。

训练全双工 SLM 面临**数据瓶颈**：

- **数据稀缺**：大规模语音资源（如 Moshi 的数百万小时无监督音频）主要为单流，缺乏多说话人重叠标注；高质量对话语料（如 Fisher）规模小（千小时级），不满足 SFT 需求；
- **处理困难**：真实对话含频繁重叠、反馈语和声学杂波，放大说话人分割（diarization）和转录错误；长音频包含非对话区域（音乐、噪声、长静音），需仔细过滤同时保留说话人结构与多轮上下文；
- **吞吐需求**：Web 规模音频处理需高吞吐以在实际工业计算预算内完成。

Sommelier 是**首个面向全双工 SLM 的可扩展开源数据预处理流水线**，核心设计哲学：保留而非剥离重叠、反馈语和打断——让模型学习对话如何展开，而非仅学内容。

2. 系统架构

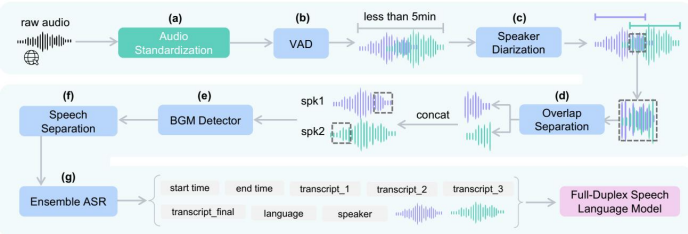

图 1：*Sommelier* 整体流水线。蓝色为神经模型组件，绿色为算法组件。

流水线采用**模块化框架**，每个组件可独立开关或重配置，允许在数据纯度与对话真实性之间灵活权衡。

2.1 音频标准化（§2.1）

使用 pydub 和 librosa 将多样格式统一为标准格式（16kHz、16-bit、Mono），并执行响度归一化至 −20 dBFS，消除来源差异。

2.2 VAD 与说话人分割（§2.2）

为防止 diarization 模型 OOM，先用 Silero VAD 在静音间隔处切分长音频为 < 5 分钟片段，保留对话上下文。说话人分割采用 NVIDIA **Sortformer**（取代常用的 pyannote 3.1），实验证明其在极短话语（如反馈语）和快速轮替场景下显著优于 pyannote（详见 §3.2）。

2.3 重叠语音处理（§2.3）

对话音频中频繁出现轮替和短话语。论文将重叠场景系统化为四种情况：Case 1 按重叠切分（丢失完整话语信息）；Cases 2/3 将重叠分配给一方（引发 ASR 混淆）；**Case 4**（被选为基线）允许双方片段均包含重叠，保留完整信息。

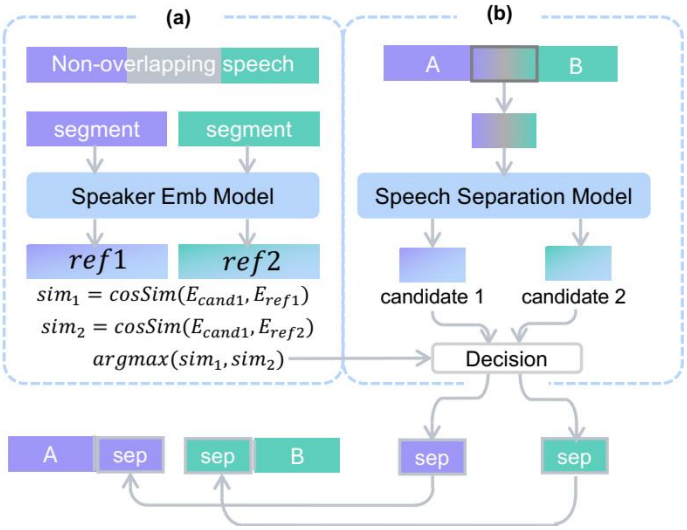

图 2：重叠语音分离流程。*(a)* 利用非重叠片段计算说话人嵌入相似度；*(b)* 分离重叠区域并基于相似度匹配说话人身份。

具体流程：（1）从非重叠区域（> 2s）提取说话人嵌入 $(e_{ref_1}, e_{ref_2}) = (\mathcal{M}_{emb}(a_0), \mathcal{M}_{emb}(a_1))$；（2）将重叠音频 $a_{overlap}$ 送入 SepReformer 分离模型得到候选 a_{cand1}，a_{cand2}；(3) 计算余弦相似度 $S_1 = \mathrm{sim}(\mathcal{M}_{emb}(a_{cand1}), e_{ref_1})$，$S_2 = \mathrm{sim}(\mathcal{M}_{emb}(a_{cand1}), e_{ref_2})$，按最高相似度分配说话人身份；(4) 将分离片段与原始非重叠部分拼接为单说话人流。关键发现：**仅输入重叠部分**比输入整段效果更好。

2.4 背景音乐移除（§2.4）

广播/戏剧音频含 BGM，使用 **PANNs** 估算各片段背景音乐概率，阈值 > 0.3 时用 **Demucs** 提取人声。为减少音质损失，仅对被 PANNs 标记的片段选择性应用。关键发现：将完整 2 分钟音频送入 Demucs 比逐短片段处理效果显著更好。排除了 SAM-Audio（RTF 0.73 on A100，延迟过高不可扩展）。

2.5 集成 ASR（§2.5）

单一 ASR（如 Whisper）易产生幻觉（静音/噪声段生成重复/无意义文本）。采用 **ROVER** 集成策略，融合三个 SOTA 模型（Whisper-large-v3 + Canary + Parakeet）：词级对齐后优先多数投票（≥ 2 模型一致即接受），否则回退 Whisper 保持一致性。残余幻觉用 **RepetitionFilter** 过滤（n-gram $n = 15$, count ≥ 5）。同时提取 Whisper 词级时间戳，为流式 SLM 提供音频-文本严格同步。

3. 核心实验结果

3.1 全双工模型微调验证（§3.1）

对 Moshi（moshiko-pytorch-bf16）进行 LoRA 微调（83 小时 Sommelier 处理数据，8×A100，2000 步，lr=2×10^{-6}，rank=128），用 Full-Duplex-Bench 1.0 评估。

能力	Base Moshi	+Sommelier
Backchannel TOR↓	1.000	**0.291**
Backchannel Freq↑	0.001	**0.052**
Backchannel JSD↓	0.957	**0.630**
Smooth TOR↑	0.941	**1.000**
Interruption GPT-4o↑	0.765	**3.684**

微调后模型在反馈语、平滑轮替和打断处理上均显著改善。反馈语频率从 0.001 提升至 0.052，时序分布 JSD 从 0.957 降至 0.630；打断响应的 GPT-4o 相关性评分从 0.765 跃升至 3.684。Pause Handling 表现与基线相当，推测源于 Moshi 架构限制或缺少 prompt audio。延迟增加实为**正面信号**——基线短延迟反映模型无视用户输入持续说话，微调后延迟升高表明模型主动处理输入并准备恰当回应。

在 Full-Duplex-Bench v1.5 上，微调模型在所有重叠场景（Background Speech、Talking to Other、User Backchannel、User Interruption）的音频质量显著提升：SI-SDR 从 5.43 dB 跃升至 20.76 dB（Background Speech），停止/响应延迟

降至亚秒级。

关键数据发现：训练数据中单说话人持续 > 1 分钟的长轮替导致 loss 不稳定且模型无响应。有效策略为选取每轮 ≤ 10s、至少连续 3 轮的片段，且左声道仅分配单一说话人。

3.2 说话人分割模型选择（§3.2）

在 VoxConverse（≤ 4 说话人）上对比：

模型	DER(%)	JER(%)	DER($\leq$1s,%)
pyannote 3.1	8.40	17.68	20.21
Sortformer	**7.16**	**14.69**	**16.87**

Sortformer 在全局指标和短话语/快速轮替等关键场景上均优于 pyannote 3.1，轮替 DER 从 0.051 降至 0.006（降低 88%），对交互性强的对话更适合。

3.3 重叠分离语音质量（§3.3）

在 LibriSpeech 测试集上合成 900 样本（SIR $\in \{0, 5, 10\}$ dB，重叠率 $\rho \in \{0.2, 0.5, 1.0\}$，9 种条件），评估 WER / STOI / UTMOS：

SIR	ρ	WER: Ori/Sep/Orc	STOI	UTMOS
0dB	1.0	48.9/15.6/5.3	.78/.91/1.0	1.70/3.02/3.84
5dB	1.0	52.5/9.1/4.0	.76/.94/1.0	1.79/3.12/3.91
10dB	0.5	29.7/10.1/5.2	.88/.96/1.0	2.58/3.21/3.86

重叠率是任务难度的关键决定因素（SIR 影响有限）。分离后 UTMOS 接近 Oracle 上界（≈ 3.0 vs. ≈ 3.9），证明方法在保持自然度的同时有效恢复可懂度。Speaker 2（次要/较弱说话人）获益尤为显著——完全重叠时 WER 从 0.923 降至 0.193（10dB），表明模块对混合中较弱说话人的恢复能力极强。

3.4 ASR 集成性能（§3.4）

数据集	模型	WER(%)	时间 (s)
LS-Clean	Whisper	3.63	0.39
	MoE（Ours）	**2.04**	1.40
LS-Other	Whisper	6.26	0.35
	MoE（Ours）	**3.92**	1.27
TEDLIUM3	Whisper	12.19	0.36
	MoE（Ours）	**10.66**	1.33

集成在 LibriSpeech-Other 上 WER 降低 **37%**（6.26% $\rightarrow$ 3.92%），噪声数据收益最大。推理时间约为 3×（主要受限于最慢模型 Canary），但有效消除了 Whisper 幻觉（如 “Yeah., Yeah., Yeah...” 被修正为 “Yeah, big decision for Dan”）。

3.5 延迟分析（§3.5）

单进程 A100 上处理 120s 音频总 RTF = 0.1746（去除可选 FlowSE 降噪后 RTF = 0.133）。峰值显存 23GB 支持单 GPU 3 并发进程（RTF 降至 0.0443）。**8×A100 处理 10,000 小时音频仅需约 55 小时**，满足工业级可扩展性需求。各阶段耗时：VAD+Sortformer 1.91s (RTF 0.016)、SepReformer 0.15s (RTF 0.001)、ASR 集成 13.91s (RTF 0.116, 主瓶颈)、FlowSE 4.99s (RTF 0.042)。

4. 上下文感知字幕生成

使用 Qwen3-Omni-Captioner 生成丰富元数据（情感、性别、年龄组、场景描述）。为避免短片段脱离上下文（如反讽），采用**上下文感知字幕**：以前两段音频作为 ICL 提示，计算条件概率 $P(C_3|I, a_1, a_2)$ 生成第三段字幕 C_3，捕获跨段语义关联。

5. 相关工作对比

现有大规模语音数据集（LibriSpeech、GigaSpeech）以朗读/独白为主，缺乏交互动态；对话数据集（Fisher、Switchboard）受限于电话音质（8kHz）和小规模（千小时级）。Web 规模数据集（WenetSpeech、Emilia）优化单流处理，将重叠视为噪声而非特征。开源处理流水线（Dolma、RedPajama 等）主要服务文本 LLM，语音领域的 “数据配方” 仍为黑盒。Sommelier 填补了**面向全双工对话的开放处理标准**的空白。

6. 局限性与展望

- 仅处理语音数据，不覆盖非语音声学事件或通用音频场景（与全模态方法相比范围受限）；
- 重叠分离后音频保真度不可避免地略低于原始多通道录制（Oracle），分离过程可能引入轻微声学伪影；
- ASR 集成 3× 延迟开销，主瓶颈为最慢模型 Canary；
- 当前验证仅在 Moshi 上进行，泛化至其他全双工架构（如 GPT-4o 级系统）待验证；
- 数据选择策略（< 10s 轮替、≥ 3 连续轮）为经验性约束，理论最优策略待研究；
- 未来方向：扩展至多语言、多模态场景，集成更高效分离模型以进一步降低 RTF，探索自动化数据质量评估与反馈闭环。