QZPaper Huggingface Daily

2026-04-03

1. **DataFlex：面向大语言模型的统一数据中心动态训练框架**
   DataFlex 统一框架将数据提升为一等优化变量，支持数据选择、领域混合和样本重加权三大动态训练范式，基于 LLaMA-Factory 实现即插即用的训练层替代，系统化解决 LLM 数据中心训练的碎片化问题。
2. **The Latent Space：基础、演化、机制、能力与展望**
   潜在空间综述突破离散 token 空间局限，阐述连续潜在表示在 LLM/VLM/VLA 中的基础定义、演化历程与双维度分类（机制 × 能力），揭示其在推理、规划、建模等任务中的表达力与高效性优势。
3. **SKILL0：面向技能内化的上下文智能体强化学习**
   SKILL0 通过从有到无的渐进课程学习，将推理时增强的技能内化到模型参数，采用视觉上下文压缩与自适应策略实现零样本自主智能体行为，解决传统 RL 结构化引导与知识外置的矛盾。
4. **Generative World Renderer：面向真实场景的可扩展生成式双向渲染**
   利用游戏引擎采集 4M 帧同步视频和 G-buffer 数据集，通过 ReShade 拦截与自动化筛选突破逆向渲染的数据瓶颈，推进 G-buffer 条件的生成式渲染，显著提升 SOTA 模型在真实场景的适应性。
5. **EgoSim：面向具身交互生成的自我中心世界模拟器**
   EgoSim 设计闭环自我中心世界模拟器，通过几何动作感知的观测生成与交互感知的状态更新，维护可持续演化的 3D 场景，实现空间一致的长序列交互视频生成与跨具身迁移。
6. **LatentUM：通过潜在空间统一模型释放交错跨模态推理潜力**
   LatentUM 将理解与生成统一到共享语义潜在空间，通过 MBAQ 视觉分词器和 MoME 混合编码器实现早期融合，消除像素空间中介的编解码偏差，直接支持灵活的交错跨模态推理与生成。
7. **OMNI-SIMPLEMEM：自主研究驱动的终身多模态智能体记忆发现**
   Omni-SimpleMem 通过自主研究管线自动发现终身多模态记忆框架，采用选择性摄入、热冷存储分层与混合检索，在 Bug 修复和架构创新驱动下实现 F1 提升 411%，突破人工研究效率瓶颈。
8. **Steerable Visual Representations：用自然语言引导视觉表征**
   SteerViT 在冻结 ViT 中插入轻量级文本引导交叉注意力层，赋予预训练视觉表征可控的语言条件化能力，仅增 21M 参数即实现早期视觉语言融合，支持检索分类分割等多任务下的表征质量。
9. **VOID：视频物体及其交互删除——物理合理的反事实视频编辑**
   VOID 通过反事实数据集监督和交互感知条件化，建模物体移除对场景中其他物体的因果影响，生成物理合理的视频编辑结果，解决传统修复方法无法处理复杂物理交互的限制。

DataFlex：面向大语言模型的统一数据中心动态训练框架

Liang*, Zhao*, Qiang*, Chen* 等 — 北京大学、上海高等算法研究院、LLaMA-Factory Team, 2025

1. 动机与问题背景

大语言模型（LLM）的成功不仅依赖于模型架构与优化算法，**训练数据的规模、质量和组成**同样起决定性作用。数据中心训练（Data-Centric Training）旨在优化模型参数的同时，动态优化训练数据的选择、组成和加权。然而，现有方法存在严重**碎片化**问题：

- 各方法以独立代码库发布，接口不一致、训练/评估协议异构、依赖版本过时；
- 缺乏统一框架进行系统性评估与公平比较；
- 多数方法作为孤立算法组件设计，未考虑通用的数据-模型交互抽象；
- 在大规模分布式训练场景下（如 DeepSpeed ZeRO-3），集成多种数据中心策略面临工程挑战。

DataFlex 提出**数据中心动态训练系统**概念并给出具体实现：将数据提升为一等优化变量，在统一框架下支持动态数据选择（Data Selection）、领域混合优化（Data Mixture）和样本重加权（Data Reweighting）三大范式，同时兼容在线（online）和离线（offline）算法。框架基于 LLaMA-Factory 构建，作为训练层的即插即用替代（drop-in replacement）。

2. 相关工作概述

2.1 数据选择

离线方法在训练前确定子集：基于质量评分（DeBERTa/ChatGPT/GPT-4 评估）、多样性（k-center greedy）、复杂度标签等。优点是部署简单无训练时开销，缺点是无法适应模型状态变化。**在线方法**在训练过程中更新选择策略：LESS 通过梯度近似估计样本影响力，NICE 支持不可微评估指标的黑箱优化，Data Selection via Optimal Control 将选择形式化为轨迹优化问题。

2.2 数据混合

离线混合：DoReMi 通过代理模型 + minimax（Group-DRO）目标导出领域权重；DoGE 用双层优化学习对分布外场景鲁棒的比例。**在线混合**：ODM 将领域分配建模为多臂老虎机（Exp3 算法）；Aioli 建模跨领域交互效应；Adaptive Data Optimization 拟合逐领域损失曲线并重新分配训练质量。

2.3 在线数据重加权

根据当前损失动态调整每个样本的重要性——难样本赋高权重，简单/冗余样本降权，可改善收敛速度和整体性能。

3. 系统架构

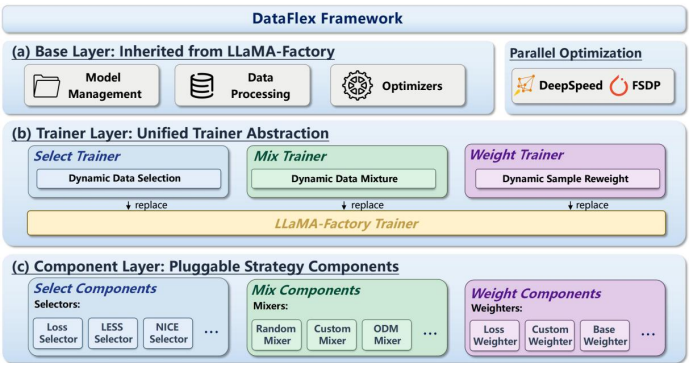

图 1：*DataFlex* 高层架构。每个 *Trainer* 配备可插拔的算法组件（*Selector/Mixer/Weighter*）。

DataFlex 采用**三层模块化架构**：

3.1 基础层（Base Layer）

继承自 LLaMA-Factory，提供模型管理、数据处理和优化的标准基础设施。复用成熟后端，避免重复实现通用训练功能，保持与现有微调工作流的兼容性。

3.2 训练器层（Trainer Layer）

核心抽象，替换原始 LLaMA-Factory 训练器，提供三种动态训练模式：

- **Select Trainer**：按指定策略动态选择训练样本子集；
- **Mix Trainer**：在训练过程中动态调整跨领域/数据源的混合比例；
- **Weight Trainer**：在反向传播中动态修改逐样本训练权重。

3.3 组件层（Component Layer）

每个 Trainer 关联一组可插拔策略组件（Selector/Mixer/Weighter），封装算法特定逻辑但共享统一接口。所有组件通过**集中注册表**管理，新算法可通过装饰器注册并在运行时自动发现和实例化。

3.4 统一训练器-组件交互模式

三种范式共享相同交互模式：观察当前模型状态 → 计算数据中心决策 → 反馈至后续优化步。Select/Mix Trainer 按可配置间隔（`warmup_step` + `update_step`）调用组件；Weight Trainer 在预热后每步应用逐样本加权。

3.5 配置与易用性

配置文件复用 LLaMA-Factory 的 YAML 格式，仅需添加 `dataflex` 段指定：`train_type`（如 `dynamic_select`）、`component_name`（如 `less`）和调度参数。启动命令 `dataflex-cli train <config.yaml>` 与 `llamafactory-cli` 完全对齐。

3.6 系统效率与可扩展性

继承混合精度训练、分布式数据并行和 DeepSpeed 集成。针对梯度获取挑战（ZeRO-3 下参数分片），提供 `safe_get_full_grad` 接口从分片中重建完整梯度，`safe_get_full_optimizer_state` 访问优化器状态。梯度操作按可配置间隔执行而非每步执行，选择/加权决策跨步缓存复用。

4. 集成算法

范式	方法	类别
数据选择	LESS, NICE	基于梯度
	Loss, Delta Loss	基于损失
	NEAR, TSDS	基于分布
数据混合	DoReMi	离线
	ODM	在线
数据重加权	Loss Reweighting	基于损失

5. 实验结果

5.1 数据选择与重加权

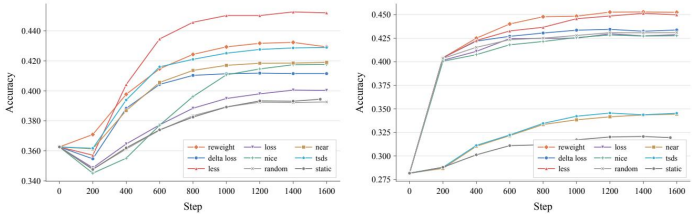

图 2：不同数据选择策略在 *Mistral-7B*（左）和 *Llama-3.2-3B*（右）上的 *MMLU* 准确率曲线。

在 Open-Hermes-2.5 的 100k 子集上，使用 LoRA（$r = 32$, $\alpha = 64$）微调，AdamW 优化器，学习率 5×10^{-7}，8×H20 GPU。

Mistral-7B： LESS 达到最高准确率 0.452，超越静态基线（0.394）5.8 个百分点。Reweight 和 TSDS 并列第二（0.429），NEAR 达 0.419，NICE 达 0.418。离线方法在早期训练（200–600 步）收敛更快。

Llama-3.2-3B： 动态方法优势更加显著。静态基线仅 0.319，而所有在线方法均超过 0.427。Reweight 最优（0.453），LESS 紧随（0.450），Delta Loss 达 0.434。离线方法（NEAR 0.344，TSDS 0.345）在小模型上表现较差，表明模型容量有限时动态选择更为关键。

5.2 数据混合

在 SlimPajama 上从零训练 Qwen2.5-1.5B，七个领域（CC 54.1%，C4 28.7%，GitHub 4.2%，Book 3.7%，ArXiv 3.4%，Wiki 3.1%，SE 2.8%）。

方法	MMLU Acc↑	ALL PPL↓
SlimPajama-6B		
Baseline	25.27	4.217
DoReMi	25.84	4.134
ODM	**26.04**	4.244
SlimPajama-30B		
Baseline	25.51	3.584
DoReMi	**25.97**	3.562
ODM	25.63	**3.429**

6B 规模：ODM 在 MMLU 上最优（26.04%），DoReMi 在整体 PPL 上最优（4.134）。两者互补——DoReMi 优化高资源领域（CC 4.108, C4 4.358），ODM 优化小领域（SE 3.243, ArXiv 2.904, Book 4.613）。

30B 规模：DoReMi MMLU 最优（25.97%），ODM PPL 最优（3.429）。ODM 在 7 个领域中 5 个达到最低 PPL（SE 2.382, Wiki 2.713, GitHub 2.255, ArXiv 3.487, Book 4.746）。静态基线在任何领域都不再最优。DoReMi 优化后权重显著增加 Book/Wiki/SE 比例，CC 从 54.1% 降至 34.1%。

互补性分析：DoReMi 通过 minimax 过量损失优化改善高资源领域 PPL；ODM 通过在线 Exp3 探索更激进地上调少数领域权重。30B 规模下互补性更显著——ODM 有更多步数收敛，DoReMi 优化权重带来更高下游准确率。

5.3 效率评估

在线数据选择（LESS 对比）：

比例	方法	Acc(%)	时间 (s)	加速
0.05	LESS	34.91	1,640	–
	DataFlex	38.35	1,579	3.7%
0.1	LESS	37.97	3,735	–
	DataFlex	40.25	3,573	4.3%
0.5	LESS	41.57	14,398	–
	DataFlex	40.93	13,377	7.1%
1.0	LESS	40.38	30,239	–
	DataFlex	42.37	28,734	5.0%
1.0	8-GPU	43.01	12,965	57.1%

DataFlex 在单 GPU 下一致降低运行时间（3.7%–7.1%），同时保持或提升准确率。8-GPU 配置将时间从 28,734s 缩减至 12,965s（57.1% 加速），达到最高准确率 43.01%——得益于交错选择-训练策略使梯度基于最新权重更新，选择过程自适应精炼训练池。原始 LESS 因实现限制仅支持单 GPU。

离线数据选择（TSDS 对比）：训练集从 5k 扩展到 100k 时，DataFlex 一致实现约 1–3% 加速（69.91s → 69.03s @ 100k）；验证集从 50 变化到 1000 时，改进约 1.5–3.5%。虽然绝对加速温和，但在需反复调用选择算子的迭代实验中优势积累明显。

6. 工程改进亮点

相比原始代码库，DataFlex 在三个关键方面做出工程改进：

分布式训练支持：原始 LESS 仅支持单 GPU，DataFlex 集成 DeepSpeed ZeRO 和 FSDP，支持从分片参数重建完整梯度和优化器状态，使梯度数据选择可扩展至更大模型和更长上下文。

依赖兼容性：原始代码锁定特定版本（如 transformers 4.36.2, torch 2.1.2），升级可能导致编译错误。DataFlex 依托 LLaMA-Factory 持续跟踪最新开源模型和依赖。

工作流统一：原始 LESS 将梯度提取、数据准备、训练分散为独立脚本需手动协调；DoReMi 原始实现缺乏多节点支持且要求模型前向返回非标准信息。DataFlex 将所有阶段整合为统一管线，通过 `mixture_manager` 和动态重建分布式 dataloader 实现即时数据集成。

7. 讨论与局限

DataFlex 将数据中心训练的三大范式统一于一个框架，降低了碎片化，提高了可复现性和可比性。实验验证了动态方法在 MMLU 准确率和困惑度上一致优于静态基线。

主要局限：

- 当前仅集成 7 种数据选择、2 种混合和 1 种重加权方法，覆盖面有待扩展；
- 效率改进在离线场景下幅度有限（1–3%），主要优势在在线和多 GPU 场景；
- 实验规模限于 1.5B–7B 参数模型和最多 30B token，更大规模训练的验证尚待进行；
- 框架设计依赖 LLaMA-Factory 生态，对非 HuggingFace 架构的模型需额外适配；
- 数据选择和混合策略的最优调度参数（warmup、update 间隔）仍需针对具体任务手动调优。

The Latent Space：基础、演化、机制、能力与展望

Xu* 等 (30+ 位作者) — NUS, Fudan, Tsinghua, ZJU, Shanghai AI Lab 等, 2026

1. 核心动机与问题

现代语言模型（LLM/VLM/VLA）通常被理解为在显式 token 空间中进行生成，但越来越多的研究表明，模型的许多关键内部过程更自然地发生在**连续潜在空间**（latent space）而非人类可读的文本轨迹中。这一转变源于显式空间计算的四大结构性局限：

- **语言冗余**：自然语言中大量 token 服务于语法连贯而非语义内容；
- **离散化瓶颈**：有限词表将连续内部状态量化为离散符号，导致信息损失；
- **顺序解码低效**：每个 token 需完整前向传播和全词表概率计算；
- **语义丢失**：细粒度不确定性、中间计算轨迹、跨模态对齐等难以用语言表达。

潜在空间研究已从早期的潜在推理扩展到规划、建模、感知、记忆、协作和具身智能等广泛领域，但文献仍碎片化。本综述旨在提供**统一的、最新的潜在空间全景**，围绕五个顺序问题组织：Foundation（定义）、Evolution（演化）、Mechanism（机制）、Ability（能力）、Outlook（展望），并提出**双维度分类法**——机制轴（Architecture/Representation/Computation/Optimization）× 能力轴（Reasoning/Planning/Modeling/Perception/Memory/Collaboration/Embodiment）。

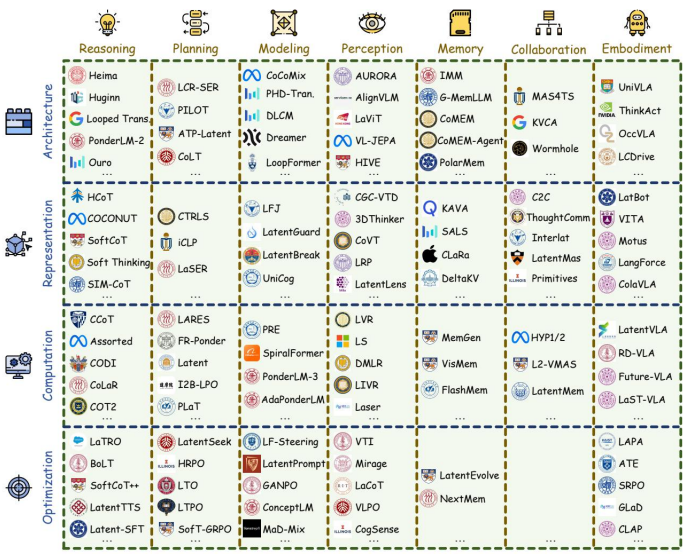

图 1：潜在空间方法按机制（4 类）× 能力（7 类）双维度分类全景。单一方法可归属多个类别。

2. Foundation：潜在空间的定义与对比

2.1 概念定义

给定输入序列 $\mathbf{x} \in \mathcal{V}$，标准自回归模型在 token 空间生成 $\mathbf{y} \sim \Phi_\theta(\cdot \mid \mathbf{x})$。潜在空间方法引入额外连续变量 $\mathbf{z} \in \mathcal{H}$（$\mathcal{H} = \mathbb{R}^d$），使生成条件化于：

$$\mathbf{y} \sim \Phi_\theta(\cdot \mid \mathbf{x}, \mathbf{z})$$

其中 $\mathbf{z}$ 编码难以在 token 空间直接表达的全局语义、多模态特征、中间推理状态或结构约束。

2.2 与显式空间的对比

从**表征属性**看，潜在空间具有四大优势：（1）**机器原生**——高维实值向量，免去人类可读编解码开销；（2）**连续灵活**——在连续流形上操作，摆脱离散分词和自回归语言约定；（3）**高效**——消除语言冗余、表征转换开销和顺序解码瓶颈；（4）**高保真**——避免离散化量化损失，保留丰富的连续信息。从**功能能力**看，潜在空间具备可操作性（可微流形上的拼接、线性组合、语义引导）、表达力（原则上可表达包含整个显式空间的表征）、可扩展性和泛化性。但其代价是**可评估性、可控性和可解释性**不足——人类难以直接审查连续向量的中间过程。

2.3 与生成式视觉模型潜在空间的区别

视觉生成模型（VAE/VQ-VAE/Latent Diffusion）的潜在空间由**重建目标**驱动，保持局部欧几里得几何和显式时空结构（图像为空间网格，视频沿时间轴扩展）。而语言模型潜在空间由**预测目标**（next-token prediction）塑造，无空间拓扑或物理动力学约束，几何结构隐式且非均匀。

3. Evolution：发展的四个阶段

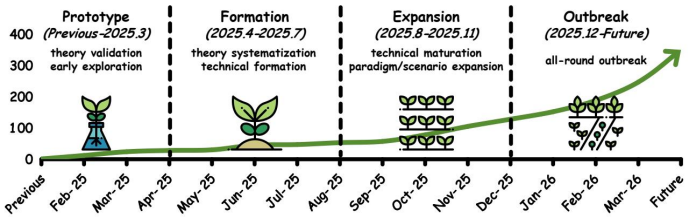

图 2：潜在空间研究时间线，分为原型、形成、扩展、爆发四阶段，纵轴为相关工作数量。

3.1 原型阶段（∼2025.03）

理论验证：HCoT 证明完整 CoT 轨迹可压缩为紧凑特殊 token 表征；Zhang & Viteri 发现“潜在思考向量”（steering vectors），注入推理时即可诱发 CoT 式推理。**早期探索：**COCONUT 提出首个完整框架——将最后隐状态反馈为下一输入嵌入，形成绕过离散词表瓶颈的连续思维循环，关键发现是连续向量可编码多个潜在下一步的**叠加态**，实现潜在空间中的**涌现式宽度优先搜索**。Huginn 提出通过**循环深度**（recurrent depth）扩展测试时计算。SoftCoT 提供首个即插即用方法。

3.2 形成阶段（2025.04–07）

理论系统化：Zhu 等（Reasoning by Superposition）首次证明连续思维向量作为叠加态可同时编码多个搜索前沿，提供 COCONUT 行为的严格复杂度分析。CoT^2 量化了并行度与嵌入维度的关系。Saunshi 等证明循环 Transformer 可表达严格超过标准 Transformer 的计算类。**技术形成：**Assorted（离散/文本混合 token）、CODI（自蒸馏）、BoLT（预训练引导）等拓展表征设计；HRPO、System-1.5、CoLaR 分别引入潜在强化学习、自适应计算分配和动态推理压缩。Mirage 使 VLM 进行视觉思考，UniVLA 引入跨具身的潜在动作表征。

3.3 扩展阶段（2025.08–11）

潜在空间从文本中心扩展为**多模态多域生态**。文本域：MemGen 开创潜在记忎，LTPO 将潜在思维向量视为可优化参数。视觉域：LVR/Monet 在视觉嵌入空间进行自回归推理，3DThinker 扩展至 3D 心理模拟。多智能体：C2C 通过 KV-cache 投影实现 LLM 间直接语义通信，LatentMAS 通过共享潜在工作记忆实现协作（显著减少输出 token 同时提升精度）。具身域：LAPA/LAWM 从无标签视频自监督预训练潜在动作。

3.4 爆发阶段（2025.12∼ 至今）

全面爆发：架构专门化（Dreamer 深度循环设计、LoopFormer 弹性循环、DLCM 概念级推理）；优化精细化（ReLaX/Active Latent Planning 从模仿学习转向 RL 规划、LED 解决训练后探索崩溃、Latent Thinking Optimization 直接优化潜在轨迹）；视觉（ILVR/CrystaL 视觉-文本交错推理）、多智能体（L2-VMAS/Wormhole 异构通信）、具身（Motus/VLA-JEPA 统一潜在动作世界模型）全面拓展。

4. Mechanism：四大机制轴

4.1 Architecture（架构）

按潜在空间在模型空间 $\Phi = \{\Phi^{back}, \Phi^{comp}, \Phi^{aux}\}$ 中的集成位置分三类：

Backbone（主干）：潜在计算嵌入主生成架构本身。$\mathbf{h}_{t+1} = \Phi^{back}(\mathbf{h}_{1:t}, \mathbf{x}, \mathbf{y}_{1:t})$。三种范式：（1）参数共享——Huginn 用共享循环块替代深层堆叠（3.5B, 8 层, 5280 维），通过额外循环步换取性能；Looped Trans. 引入循环正则化稳定隐状态

动态。(2) 迭代式——Ouro 递归推理作为替代缩放轴；Loop-Former 弹性深度按输入复杂度调整迭代次数；PonderLM2 使用 Jacobi 式并行更新实现多步隐状态演化。(3) 增强式——DLCM 编码器-解码器将 token 级操作提升至概念空间；Dreamer 序列-深度稀疏注意力混合；MLRA 低秩注意力。

Component（组件）： 保留主干架构，插入功能模块 $\mathbf{z} = \Phi^{comp}(\mathbf{h}, \mathbf{x})$。涵盖五大组件族：(1) 生成——AURORA 用 VQ-VAE 生成视觉 token；CoLaR 用 MLP 生成嵌入。(2) 投影——LF-Steering 用 SAE 进行语义投影；SoftCoT++ 用线性层。(3) 对齐——AlignVLM 混合层实现视觉对齐。(4) 控制——TaH/FR-Ponder 用 MLP 触发器决定何时进入潜在推理。(5) 存储——VisMem 用 LoRA 生成潜在视觉记忆；PolarMem 用图拓扑存储状态；L2-VMAS 双视觉记忆向量库。

Auxiliary Model（辅助模型）： 额外模型提供监督信号或中间特征 $\mathbf{z} = \Phi^{aux}(\mathbf{x})$。如 HCoT/CODI 用 LLM 生成潜在链；Mirage 用视觉模型生成特征；VLA-JEPA 用 JEPA 进行视觉投影。

4.2 Representation（表征）

分四类：(1) **Internal**——直接复用模型内部隐状态，如 COCONUT 将最后隐状态反馈为输入嵌入。(2) **External**——引入外部特征，如视觉编码器输出或预训练嵌入。(3) **Learnable**——可训练的潜在 token/嵌入，如 SoftCoT 的软思考 token、CCoT 的沉思 token。(4) **Hybrid**——混合多种来源，如 Assorted 混合离散潜在 token 与文本 token，CoCoMix 混合概念向量与 token 嵌入。

4.3 Computation（计算模式）

四种模式：(1) **Compressed**——将长显式推理链压缩为少量潜在向量（如 HCoT 对比语义对齐压缩 CoT，CCoT 沉思 token 压缩）。(2) **Expanded**——在潜在空间中扩展计算量以增强表达力（如 Huginn 循环深度扩展、COCONUT 连续思维循环）。(3) **Adaptive**——动态分配计算预算（如 System-1.5 在语言/潜在空间间自适应切换、CoLaR 推理时可控压缩率、PonderLM2 按输入复杂度调整迭代次数）。(4) **Interleaved**——潜在与显式计算交替进行（如 SpiralThinker 文本-潜在迭代交错、ILVR 视觉-文本交错推理、Mirage 潜在视觉 token 与文本交替生成）。

4.4 Optimization（优化策略）

三阶段：(1) **Pre-training**——BoLT 将网络文本视为思维过程的压缩结果进行引导预训练；Ouro 通过循环语言模型将优化融入预训练。(2) **Post-training**——HRPO 潜在强化学习；SofT-GRPO 用 Gumbel 重参数化解决连续潜在推理的 RL 可微性问题；CODI 自蒸馏（同一模型同时作为教师和学生）；LED 利用循环深度上的熵变化解决后训练探索崩溃。(3) **Inference**——LTPO 将潜在思维向量视为可优化参数进行在线策略梯度；SoftCoT 即插即用投影，无需微调；Latent Thinking Optimization 发现潜在思维本身可编码奖励相关信息，直接优化潜在轨迹。

5. Ability：七大能力域

5.1 推理（Reasoning）

潜在推理的核心优势：COCONUT 的连续思维向量编码多个搜索前沿的叠加态，实现**隐式宽度优先搜索**（在 ProsQA 图搜索上提升 ~20%）。CoT^2 证明并行度与嵌入维度的定量关系。实践中，SoftCoT 在 GSM8K 上以零额外 token 开销提升推理精度；CoCoMix 在多个推理基准上超越标准 CoT；SpiralThinker 通过文本-潜在交错在复杂推理上取得一致性提升。

5.2 规划（Planning）

潜在空间天然支持紧凑的长程规划。Latent Sketchpad 在潜在空间维护视觉草图板辅助规划；Active Latent Planning 用 RL 在潜在空间中进行显式规划探索；CoWVLA 在潜在运动空间中引入世界模型推理进行自动驾驶规划。

5.3 建模（Modeling）

潜在空间支持更高效的序列建模。DLCM 在概念空间（而非 token 空间）建模，减少序列长度同时保留语义完整性；iCLP 用 VAE 生成潜在 token 实现更紧凑的序列表示。

5.4 感知（Perception）

视觉潜在方法让 VLM 在内部进行视觉操作而非将视觉信息转为文本。AURORA 用 VQ-VAE 生成视觉 token；LVR/Monet 在视觉嵌入空间自回归推理；3DThinker 从有限 2D 视角进行 3D 心理模拟；AlignVLM 混合层缩小模态差距。

5.5 记忆（Memory）

MemGen 开创潜在记忆——规划记忆、程序记忆和工作记忆在无显式监督下涌现。VisMem 提出认知启发的短期/长期潜在视觉记忆。CoMEM 为视觉智能体扩展连续记忆。G-MemLLM 用门控逻辑实现记忆库。

5.6 协作（Collaboration）

C2C 通过 KV-cache 投影和融合实现 LLM 间直接语义通信。LatentMAS 通过共享潜在工作记忆实现多智能体协作，**显著减少输出 token 同时提升精度**。Dery 等通过 K-V cache 对齐和轻量适配器实现异构内部状态间的翻译。L2-VMAS 和 Wormhole 分别扩展至视觉和异构多智能体。

5.7 具身（Embodiment）

潜在动作建模成为 VLA 的核心设计范式。UniVLA 从互联网视频学习任务中心潜在动作。Motus/VLA-JEPA 开发统一潜在动作世界模型。LAPA/LAWM 从无标签视频自监督预训练。SwiftVLA/LoLA 证明潜在动作表征在 VLA 预训练和部署中日益核心。

6. Outlook：挑战与未来方向

关键挑战：

- **可解释性**：连续向量缺乏人类可读性，模型内部推理过程不可直接审查和调试——这是潜在空间最根本的代价；
- **可控性**：如何精确引导潜在空间中的计算过程，避免不可预测行为；
- **评估**：缺乏标准化的潜在空间评估基准和指标体系，不同方法难以公平比较；
- **统一接口**：不同工作采用不同架构假设、优化目标和潜在接口，缺乏统一标准；
- **安全对齐**：潜在空间中的推理可能绕过基于文本的安全过滤和对齐机制。

未来方向：

- **潜在空间作为通用计算范式**：从特定任务的技术启发式走向通用的、第一等级的计算基底——类似于从汇编到高级语言的抽象跃迁；
- **跨模态统一潜在空间**：在语言、视觉、动作和交互之间建立统一的连续表征接口，实现真正的多模态融合而非拼接；
- **潜在空间的理论基础**：进一步发展表达力分离定理、收敛保证和泛化理论；
- **可解释潜在推理**：开发解码和可视化潜在轨迹的工具，平衡效率与透明性；
- **潜在优化与 RL 的深度集成**：解决连续空间中奖励信号稀疏、探索崩溃等问题；
- **大规模系统集成**：将潜在通信和记忆机制集成到生产级多智能体和具身系统中。

总结：本综述首次将潜在空间定位为语言模型的**通用计算与系统范式**，通过 Foundation–Evolution–Mechanism–Ability–Outlook 五层叙事和机制 × 能力双维度分类法，统一组织了 200+ 篇涵盖推理、规划、感知、记忆、协作和具身的相关工作。核心洞见：潜在空间不再是隐藏的实现细节，而是正在成为下一代智能系统的**机器原生计算基底**。

SKILL0：面向技能内化的上下文智能体强化学习

Lu[1,2], Yao[2], Wu[3], Han[2], Gu[2], Cai[2], Lu[1], Xiao[1], Zhuang[1], Shen[1] — [1] 浙江大学, [2] 美团, [3] 清华大学, 2025

1. 动机与问题定义

Agent Skills（智能体技能）已成为增强 LLM 智能体的标准机制：将结构化的程序性知识和可执行资源打包为技能库，在推理时动态检索并注入上下文。然而，这种**推理时技能增强**范式存在三个根本性局限：

- **检索噪声**：语义检索引入不相关或误导性指导，污染智能体上下文；
- **Token 开销**：注入的技能内容在多轮交互中累积，严重限制可扩展性；
- **知识外置**：模型仅在执行技能而非学习技能——能力驻留在上下文中而非模型参数内。

这一观察对应人类技能习得理论（Anderson, 1982）：从显式指导阶段到内化自主执行阶段的渐进过程。推理时增强将智能体永久锚定在第一阶段。SKILL0 提出一个根本性不同的问题：**技能能否被内化到模型参数中，使推理时无需任何技能检索即可实现零样本自主行为？**

朴素 RL 在两个方向均失败：无技能上下文时缺乏结构化引导无法学习复杂行为；全程提供技能则模型永远依赖外部知识。SKILL0 的核心洞察是设计一种**从有到无**的训练课程——以技能开始，以零技能结束，系统性地将能力从上下文转移到参数中。

2. 系统架构

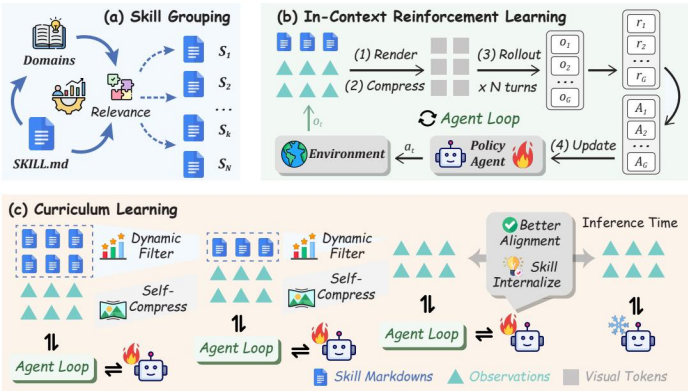

图 1：*SKILL0* 概览。*(a)* 相关性驱动的技能分组；*(b)* 技能增强的上下文强化学习回路；*(c)* 动态课程学习。

SKILL0 由三个核心模块组成：技能管理与上下文渲染、上下文强化学习（ICRL）、以及自适应课程学习。

2.1 智能体回路与技能管理

将任务自动化形式化为序列决策问题。给定指令 I，智能体生成动作序列 $\{a_1, a_2, \ldots, a_T\}$。每步 t，环境 $\mathcal{E}$ 返回文本观察 o_t，智能体按策略 $\pi_\theta(a_t \mid I, h_t)$ 采样动作，其中 $h_t = \{o_1, \ldots, o_t\}$ 为历史。

技能组织为**两级层次化技能库** SkillBank：（1）**通用技能**捕获跨任务的战略性原则（如探索策略、目标跟踪启发式）；（2）**任务特定技能**存储针对类别 k 的专业知识。技能以 Markdown 文件 S_k 形式存储于目录结构 `skills/{task}/{category}.md` 中，库 $\text{SkillBank} = \{S_k\}_{k=1}^{N}$ 共 N 个文件。训练时不通过语义相似度检索，而是按**在线策略有用性准则**选择子集 $\mathcal{S} \subseteq \text{SkillBank}$。

2.2 上下文渲染

为解决多领域扩展时的 Token 开销问题，引入**视觉上下文压缩**机制：将文本交互上下文（历史 h_t 和技能 $\mathcal{S}$）渲染为紧凑 RGB 图像，经视觉编码器压缩：

$$\mathcal{V}_t = \texttt{Enc}(h_t, \mathcal{S}; c_t)$$

其中 $\mathcal{V}_t \in \mathbb{R}^d$ 为视觉上下文嵌入。关键创新：压缩比 $c_t \in (0, 1]$ 非固定超参，而是由策略在每步与动作共同自适应生成：

$$(a_t, c_t) \sim \pi_\theta(a_t, c_t \mid I, \mathcal{V}_t)$$

文本采用语义着色方案（指令黑色、观察蓝色、动作红色），使视觉编码器能清晰区分不同上下文成分。

3. 上下文强化学习（ICRL）

ICRL 结合技能提示的样本效率与归纳偏置，以及强化学习的探索能力。核心设计：**训练时提供技能作为上下文引导，推理时完全移除**，直接优化从上下文依赖执行到内在能力的转变。

3.1 复合奖励

为同时激励高效压缩和技能内化，定义复合奖励。设 $\mathcal{T}_{\text{succ}}(\tau) \in \{0, 1\}$ 为轨迹成功指示器：

$$r_t^{\text{comp}} = \begin{cases} \ln(c_t), & \text{if } \mathcal{T}_{\text{succ}}(\tau) = 1 \\ 0, & \text{otherwise} \end{cases}, \quad \tilde{r}_t = r_t + \lambda \cdot r_t^{\text{comp}}$$

对数形式反映高压缩率的边际递减收益。$\lambda \geq 0$ 控制任务性能与压缩效率的权衡。

3.2 训练目标

对每个查询 $q \sim \mathcal{D}$，采样 G 条轨迹 $\{\tau_i\}_{i=1}^{G}$，优化目标为：

$$\mathcal{L}_{\text{SKILL0}}(\theta) = \mathbb{E}\left[\frac{1}{\sum_{i=1}^{G}|\tau_i|}\sum_{i=1}^{G}\sum_{t=1}^{|\tau_i|}\text{clip}(r_{i,t}(\theta), A_i, \epsilon)\right] - \beta \cdot \mathbb{D}_{\text{KL}}[\pi_\theta \| \pi_{\text{r}}$$

其中优势 A_i 通过组内奖励归一化计算，$r_{i,t}(\theta) = \pi_\theta(\tau_{i,t} \mid q, \tau_{i,<t}) / \pi_{\theta_{\text{old}}}(\tau_{i,t} \mid q, \tau_{i,<t})$ 为重要性采样比率。

4. 自适应课程学习

为避免上下文空间的突变分布偏移，设计**线性衰减**技能预算 $M^{(s)}$：

$$|S^{(s)}| \leq M^{(s)} = \left\lceil N \cdot \frac{N_S - s}{N_S - 1} \right\rceil$$

逐步限制偏差至 $M^{(s)} - M^{(s+1)} \approx \frac{N}{N_S - 1}$，确保策略 $\pi_\theta(a_t, c_t \mid I, \mathcal{V}_t^{(s)})$ 的分布偏移平稳，安全过渡到完全自主状态 $\mathcal{S}^{(N_S)} = \emptyset$。

理论保证：在 Lipschitz 连续假设下，线性衰减保证相邻阶段视觉上下文偏差 $\|\mathcal{V}_t^{(s+1)} - \mathcal{V}_t^{(s)}\| \leq L_E \lceil N/(N_S - 1) \rceil$ 及策略 KL 散度 $\mathbb{D}_{\text{KL}}(\pi^{(s)} \| \pi^{(s+1)}) \leq L_\pi L_E \lceil N/(N_S - 1) \rceil$ 均一致有界。

课程分两阶段执行：

(a) 离线相关性驱动技能分组。将验证集按领域对齐划分为 N 个子任务 $\{\mathcal{T}_k\}_{k=1}^{N}$，每个 S_k 对应专属子任务用于评估效用。

(b) 在线有用性驱动动态课程。将训练分为 N_S 阶段，每 d 步评估每个 S_k 的有用性 Δ_k：在当前策略 π_θ 下，分别评估 $\mathcal{T}_k$ 在有/无 S_k 条件下的准确率差值。然后执行**过滤**（剔除 $\Delta_k \leq 0$ 的技能）→ **排序**（按 Δ_k 降序）→ **选择**（取 top-$M^{(s)}$），确保仅保留当前策略仍受益的技能。

5. 实验结果

5.1 实验设置

在两大基准上评估：**ALFWorld**（文本交互家务任务，6 类 3827 实例）和 **Search-QA**（搜索增强问答，含单跳 NQ/TriviaQA/PopQA 和多跳 HotpotQA/2Wiki/MuSiQue/Bamboogle）。基座模型为 Qwen2.5-VL 3B/7B，4 张 H800 训练至多 180 步。$N_S = 3$，SkillBank 初始化自 SkillRL。

5.2 主要结果

方法 (3B)	ALF	Cost	SQA	Cost
Zero-Shot	15.2	1.21k	15.9	0.48k
GRPO	79.9	1.02k	36.4	0.61k
AgentOCR	78.2	0.38k	34.2	0.26k
SkillRL†	82.4	2.21k	38.9	0.87k
SKILL0	**87.9**	**0.38k**	**40.8**	**0.18k**
方法 (7B)				
GRPO	81.8	0.95k	41.9	0.73k
AgentOCR	81.2	0.43k	40.1	0.36k
SkillRL†	89.9	–	47.1	–
SKILL0	**89.8**	**0.41k**	**44.4**	**0.34k**

SKILL0 (3B) 在 ALFWorld 上达 87.9%，超 AgentOCR **+9.7**；Search-QA 上达 40.8，超 AgentOCR **+6.6**。7B 模型上分别达 89.8 和 44.4，大幅超越 EvolveR、GRPO 等 RL 方法。与需要推理时技能增强的 SkillRL 相比，SKILL0 在无任何技能注入条件下达到竞争甚至更优性能。在更广泛对比中，SKILL0 (7B) 远超记忆增强方法（ExpeL 46.3、Mem0 54.7、MemRL 21.4）及闭源模型（GPT-4o 48.0、Gemini-2.5-Pro 60.3）。

Token 效率极高：SKILL0 每步仅消耗 <0.5k tokens（3B: ALFWorld 0.38k, Search-QA 0.18k），比 SkillRL 低 **5 倍以上**。

5.3 训练动态分析

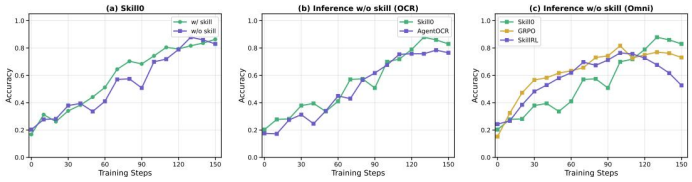

图 *2*：训练动态。*(a)* 有/无技能验证性能对比；*(b)* 与 *AgentOCR* 无技能对比；*(c)* 与 *GRPO/SkillRL* 无技能对比。

(a) 有技能验证时早期收敛更快，无技能验证初始较低但逐渐追赶，呈现清晰的**技能内化趋势**。(b) 在严格公平的无技能推理下，SKILL0 仍优于 AgentOCR，证实性能优势源自内化知识。(c) GRPO 和 SkillRL 在训练中期即趋于饱和，而 SKILL0 持续稳定提升，最终达到最高性能上界。

技能有用性 Δ_k 呈**先升后降**特征模式：早期策略尚未学会利用技能（低 Δ_k）→ 中期学会以技能为锚（Δ_k 上升）→ 后期课程退火迫使内化（Δ_k 回归零）。

6. 消融实验

技能预算 M。$N_S = 3$ 时，ALFWorld 预算为 [6,3,0]。对比实验：Fixed Full 和 [6,6,6] 在移除技能后分别崩溃 −12.3 和 −13.3，而 SKILL0 反而获得 +1.6 增益。静态低预算 [3,3,3] 限制早期探索导致不稳定学习；恒定满预算导致训练-推理 Gap 和技能过度依赖。

动态课程三步策略。Filter&Rank&Select 达最高 87.9%（w/o skill），是唯一正迁移设置（$\Delta = +1.6\%$）。去除 Filter 引入上下文噪声（-2.7%）；去除 Rank 造成严重崩溃（$\Delta = -13.7\%$，降至 62.9%），证明严格筛选有用技能对稳定策略学习至关重要。

验证间隔 d。$d = 10$ 为最优权衡：ALFWorld 87.9, Search-QA 48.9。$d = 5$ 在 Search-QA 上边际提升（49.6）但计算开销显著增加；$d = 20$ 性能大幅下降。

7. 与相关工作的对比

与记忆方法（Reflexion、ExpeL、Mem0 等存储原始轨迹）相比，SKILL0 将抽象化的技能知识直接内化到参数，避免了冗长噪声上下文。与技能增强 RL（SkillRL 使用技能进化 + 推理时注入）相比，SKILL0 通过课程退火消除推理时技能依赖，实现真正零样本。与 ZeroSearch 等无检索方法相比，SKILL0 保留了技能的结构化先验作为训练引导，而非完全放弃外部知识。

8. 局限与展望

- SKILL0 依赖初始 SkillBank 质量——若技能本身低质量或覆盖不全，内化效果受限；
- 离线相关性驱动技能分组需在新任务域上重新划分，迁移成本非零；
- 当前仅验证于文本交互（ALFWorld）和搜索 QA 场景，向 GUI 自动化、代码生成等更复杂环境的扩展有待验证；
- 视觉上下文压缩依赖视觉编码器质量，极端压缩率下信息损失需进一步研究；
- 技能内化作为新范式（“训练时有技能，推理时零技能”），为构建真正自主的 LLM 智能体开辟了从工具增强走向自足智能的路径。

Generative World Renderer：面向真实场景的可扩展生成式双向渲染

Huang[1,2], Wang[1,*], Tan[1], Ru[1,3], Zhang[1,3], Zheng[1], Liu[4], Chuang[2], Zhang[1] — [1]Alaya Studio / Shanda AI, [2]NTU, [3]UTokyo, [4]NYCU, 2026

1. 动机与问题定义

数字世界建模包含两个基本任务：**正向渲染**（Forward Rendering）从场景属性（几何、材质、光照）合成逼真图像；**逆向渲染**（Inverse Rendering）将观测图像分解回物理组分。近年来生成模型开始将二者统一于同一框架，其核心中介表示为 **G-buffer**——提供显式几何与材质指导的中间表示。

然而，将双向渲染扩展至真实场景面临严峻的**数据瓶颈**：

- 缺乏大规模、多样化、**时间连续**的视频序列及同步高保真 G-buffer 真值；
- 现有合成数据集场景复杂度有限、相机轨迹静态、材质模型简化、缺乏恶劣天气条件；
- 导致持续性**域间隙**（domain gap）：模型无法处理真实世界的复杂反射、精细植被几何、动态运动和时间闪烁等长尾复杂性。

本文通过从两款 AAA 游戏（**Cyberpunk 2077** 和 **Black Myth: Wukong**）策划大规模连续视频数据集来解决此瓶颈，同时推进视频逆向渲染和 G-buffer 条件正向合成。

核心贡献：

- **大规模数据集**：4M 帧、720p/30fps 连续视频，含 5 通道同步 G-buffer（depth、normals、albedo、metallic、roughness），覆盖多样城市/自然环境与天气条件；
- **高效数据策划流水线**：基于图形 API 拦截与双屏拼接的新型采集框架；
- **增强渲染性能与评估**：在本数据上微调显著提升 SOTA 模型（DiffusionRenderer），并提出基于 VLM 的真实场景评估协议。

2. 数据集构建

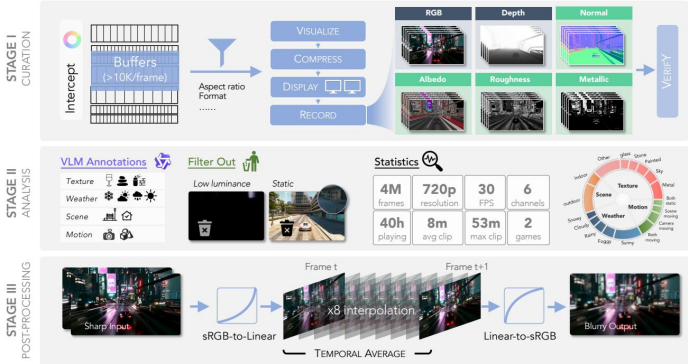

图 *1*：数据策划流水线。*Stage I*：*G-buffer* 拦截与自动化筛选；*Stage II*：元信息标注与质量过滤；*Stage III*：运动模糊合成。

2.1 G-buffer 拦截

利用 **ReShade** 在图形 API 层拦截渲染管线。现代游戏采用引擎/标题特定的 G-buffer 编码，无标准化布局。流水线分两步：（1）使用 **RenderDoc** 离线帧分析，识别候选渲染 pass 及其关联 render-target 附件（格式、分辨率、采样数）；（2）实现游戏特定 ReShade 插件，挂钩图形 API 回调监控逐帧 render-target 绑定。运行时维护小型候选附件池，仅 GPU-copy 满足稳定不变量（格式一致、尺寸一致、循环绑定模式）的目标。

法线转换：管线只能获取世界空间法线，但需要相机空间法线以匹配先前工作。因缺乏视图矩阵访问，通过深度缓冲逆投影与有限差分重建：

$$\mathbf{n} = \text{normalize}\left(\frac{\partial \mathbf{P}}{\partial x} \times \frac{\partial \mathbf{P}}{\partial y}\right)$$

其中 $\mathbf{P}$ 为从深度缓冲重建的视图空间位置。

材质通道解耦：Metallic 和 roughness 常打包于同一 render target 的不同通道，视频录制可导致通道串扰。因此将各通道渲染至空间上分离的屏幕区域，确保压缩噪声不交叉污染材质属性。

2.2 同步多屏录制

逐帧直接导出多通道 G-buffer 因存储带宽和 GPU-to-CPU 回读延迟而代价过高。替代方案：将目标 buffer 着色至屏幕，使用硬件加速捕获（OBS）录制。采用**“拼接”合成策略**：所有 G-buffer 渲染至统一画布，以近无损码率捕获。为突破单显示器分辨率限制，**拼接两台 2K 显示器**，每通道有效分辨率达 720p。因扩展显示区域增大视场角，对源 buffer 进行中心裁剪后平铺至最终输出，保持预期宽高比。

2.3 场景遍历策略

Cyberpunk 2077：半自动驾驶设置 + 长距离航点生成连续轨迹（变速），并捕获步行街道与室内场景以拓宽覆盖。**Black Myth: Wukong**：从完整存档探索序列，避免战斗，遍历多样环境与路线。

2.4 数据集统计与标注

部署 **Qwen3-VL-235B** 对每个视频片段均匀采样 5 帧进行标注，覆盖四个维度：纹理（plastic/metal/brick/sky/stone/glass 等）、天气（sunny/cloudy/foggy/rainy/snowy）、场景（indoor/outdoor）、运动模式（四类相机-场景动态组合）。

分布分析显示两款游戏**材质互补**：Cyberpunk 2077 金属值占比较高（金属丰富的城市环境），Black Myth: Wukong 粗糙度较高（自然场景、粗糙漫反射材质）。亮度分布上，Wukong 集中于低值（遮挡导致阴影区域多），Cyberpunk 更均衡。

2.5 后处理：运动模糊合成

以关闭引擎运动模糊的清晰帧为基准，额外发布离线运动模糊变体以缩小域间隙。通过 **RIFE** 插值 8 个 RGB 子帧，在线性域平均后转换回 RGB：

$$I_t^{\text{blur}} = \text{RGB}\left(\frac{1}{K}\sum_{i=1}^{K} \text{Lin}(\tilde{I}_{t,i})\right)$$

3. VLM 评估协议

真实场景缺乏 G-buffer 真值，传统逐帧指标不足。本文提出基于 **VLM（Gemini 3 Pro）**的评估协议：给定测试视频，构建固定布局网格（RGB 参考 + 各方法输出同步播放），提示 VLM 评价三个维度：

- **语义正确性**：材质合理性（金属 vs 非金属，区分玻璃/湿面/光泽塑料）；
- **空间质量**：边缘对齐、细节 vs 噪声、空间一致性；
- **时间一致性**：闪烁、边界抖动/爬行、身份一致性。

聚焦 metallic 和 roughness 通道，因其具有强语义与外观先验。VLM 输出结构化排名，与人类专家判断高度相关。

4. 实验设置

以 **DiffusionRenderer** 为主基线（当前唯一可用的视频逆向渲染方法），另含 RGB↔X 和 DNF-Intrinsic 两个图像级基线。使用 Cosmos 版 DiffusionRenderer 检查点，以 57 帧/24fps/1280×720 片段全量微调。训练用 Cyberpunk 2077，测试用 Black Myth: Wukong。微调含/不含运动模糊两个变体，选择运动增强版本。另微调 113 帧长片段变体显著改善长视频推理。

5. 定量评估结果

5.1 Black Myth: Wukong 基准

39 个测试视频片段（各 57 帧），覆盖多样材质、光照和动态事件：

指标	DR	DNF	Ours
Depth AbsRel↓	1.118	0.862	**0.697**
Depth $\delta<1.25$↑	0.267	0.361	**0.609**
Normal AngErr↓	45.01°	53.21°	**42.57°**
Normal Acc@11.25°↑	0.110	0.065	**0.150**
Albedo si-PSNR↑	19.90	15.59	**21.44**
Metallic RMSE↓	0.230	0.245	**0.104**
Roughness RMSE↓	0.281	0.566	**0.266**

微调模型在深度和法线估计上达到最佳性能，scale-invariant albedo 分数最优，metallic/roughness 精度**大幅领先**（metallic RMSE 从 0.230 降至 0.104）。

5.2 Sintel 基准

在 MPI-Sintel final pass 上跨数据集评估（含运动模糊和景深效果）：深度 RMSE log 从 0.911 降至 **0.745**，$\delta < 1.25$ 从 0.331 升至 **0.478**；Albedo LPIPS 从 0.505 降至 **0.486**，si-PSNR 从 17.46 升至 **17.80**。证明跨数据集泛化能力。

5.3 VLM 真实场景评估

40 个真实视频案例，使用 Gemini 3 Pro 评估：

	方法	Sem.↓	App.↓	Temp.↓
2*R	DR	2.45	2.40	2.10
	Ours+MB	**1.78**	**1.83**	**1.83**
2*M	DR	2.35	2.28	2.00
	Ours+MB	**1.75**	**1.60**	**1.85**

微调后所有指标提升，运动增强进一步改善时间一致性。

5.4 用户研究验证

招募 25 名 CG 专家进行配对偏好测试，验证 VLM 评估准确性。在 VLM 偏好本文模型的样本中，人类-VLM 一致率达 metallic **85%**、roughness **75%**；在 VLM 偏好 DR 的样本中分别为 70% 和 61%。Roughness 一致率较低源于更模糊的视觉线索。

6. 定性评估与应用

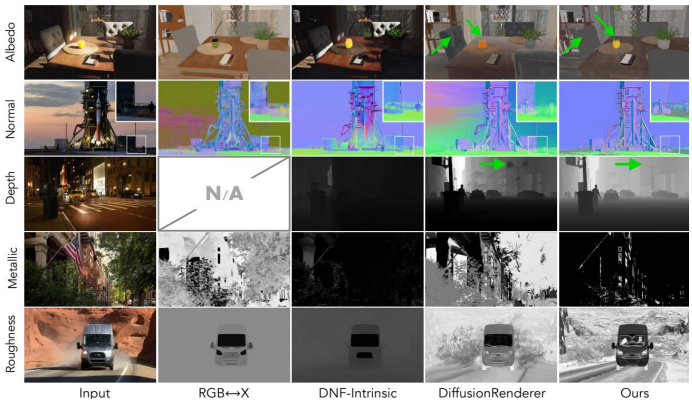

图 2：真实场景逆向渲染定性比较（上至下：*albedo*、*normal*、*depth*、*metallic*、*roughness*）。

与 DiffusionRenderer 相比，本方法生成更干净的 albedo（彻底去光照）、更精确的深度和法线（保持结构、抵抗户外光照伪影）、语义准确的 metallic/roughness 预测（克服烟雾和体积散射等瞬态大气干扰）。

重光照应用：使用冻结的 DiffusionRenderer 正向渲染器，分别以基线和本文微调逆向渲染器估计的 G-buffer 为条件合成图像。本文改进的 G-buffer 生成的结果与目标环境贴图一致性显著更好，特别是在天空区域。归因于数据驱动范式增强了解耦固有场景属性与环境光照的能力。

游戏编辑应用：基于 **Wan 2.1-T2V-1.3B** 架构，以 G-buffer 为条件输入，结合 Qwen3-VL 生成的描述性字幕（聚焦光照和环境效果），用户可通过文本提示编辑游戏风格。与 ControlNet（边缘图引导）、SDEdit（随机编辑）和 DiffusionRenderer+DiffusionLight 基线对比：

- ControlNet 仅保留基本几何但材质不保真，且边缘提取不稳定导致严重时间不一致；
- SDEdit 偏离过大，关键小物体消失破坏游戏逻辑；
- DiffusionRenderer 保持几何材质但难以进行激进编辑（如戏剧性风格迁移），且依赖环境贴图限制用户可用性；
- **本方法**因训练数据天然包含复杂游戏视觉效果（体积雾、雨），模型学到灵活先验，可无缝幻象并整合丰富大气效果。

7. 消融实验

在 Sintel 上消融运动模糊增强：加入运动模糊后，深度 RMSE log 从 0.773 降至 **0.745**，$\delta < 1.25^3$ 从 0.756 升至 **0.776**；Albedo LPIPS 从 0.513 降至 **0.486**，si-LPIPS 从 0.513 降至 **0.491**。真实视频泛化中时间稳定性显著提升，特别是强运动模糊下减少闪烁和边界爬行。

8. 讨论与局限

本文核心洞察：**扩展和改进训练数据是克服真实场景逆向渲染固有歧义性的直接且极具前景的路径**。数据集的关键设计选择——连续长序列（非短片段）、多样天气条件、运动模糊变体、AAA 级视觉复杂度——共同使模型能够处理真实世界的长尾复杂性。

局限性与未来方向：

- 数据来源限于两款游戏，场景多样性仍有上限；扩展至更多游戏标题可进一步提升泛化；
- G-buffer 拦截依赖游戏特定的逆向工程（渲染 pass 识别），不同引擎需定制适配；
- 法线通道通过深度差分重建引入近似误差，非原生相机空间法线；
- 评估协议依赖 VLM 的材质知识先验，对 roughness 等模糊属性判断一致性较低；
- 数据集以 CC BY-NC-SA 4.0 授权发布，限非商用研究用途，遵守游戏开发者 EULA 和粉丝内容政策；
- 未来可结合更多 G-buffer 通道（如 AO、emission）并扩展至更高分辨率和帧率。

EgoSim：面向具身交互生成的自我中心世界模拟器

Hao*, Jia*, Wang, Liu, Yi†, Ma†, Pang, Xu — 上海交大 / 上海 AI 实验室 / 港大, 2026

1. 动机与问题定义

视频扩散模型的进步推动了交互式世界模拟器的发展，但现有方法存在两大核心瓶颈：

- **缺乏显式 3D 锚定**：PlayerOne、Hand2World 等方法隐式编码场景状态，在大视角变化下产生结构漂移，无法保证 3D 一致性；
- **静态场景假设**：DWM 虽显式解耦 3D 静态场景与动态变化，但场景仅重建一次、交互后不更新，无法支持多阶段连续模拟（如开门后门应保持开启）；
- **数据瓶颈**：现有方法依赖同步多视角视频或合成环境数据，规模远小于网络级单目自我中心视频，严重限制泛化能力。

EgoSim 提出**闭环自我中心世界模拟器**，将 3D 场景建模为**可更新的世界状态**，通过几何-动作感知的观测模拟模型生成空间一致的交互视频，并通过交互感知的状态更新模块持续维护 3D 场景。同时设计可扩展数据管线，从大规模野外单目视频中提取训练数据，突破数据瓶颈。

核心能力	关键指标
视觉质量（EgoDex）	PSNR 25.056 / SSIM 0.896
空间一致性（Depth-ERR）	8.888（vs. InterDyn 44.345）
相机一致性（Cam-ERR）	0.0013（降低一个数量级）
跨具身迁移（AgiBot）	PSNR 15.18→18.67（预训练后）
训练数据规模	500K clips（可扩展）

2. 系统架构与问题形式化

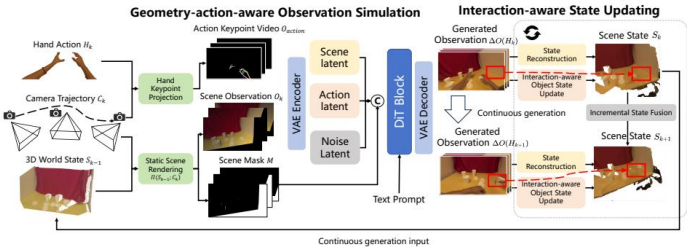

图 1：*EgoSim* 概览。闭环模拟循环：几何-动作感知观测模拟 → 交互感知状态更新。

将连续世界模拟形式化为三元组：环境状态 S、交互动作 A、视觉观测 O。在第 k 阶段，输入动作显式解耦为相机轨迹 C_k 和手部交互序列 H_k，即 $A_k = (C_k, H_k)$。

模拟循环包含两步顺序操作。**观测生成**：通过渲染静态背景并叠加手部动作引起的动态残差：

$$O_k = \mathcal{I}(S_{k-1}; C_k) + \Delta\mathcal{O}(H_k)$$

状态更新：从生成的观测中提取最新物理布局并持久化回 3D 场景：

$$S_k = \mathcal{U}(S_{k-1}, O_k)$$

该局部化状态更新确保被操纵对象（如已打开的门）不会在后续渲染中恢复原始布局。

2.1 几何-动作感知观测模拟

视觉状态转换通过几何-动作感知视频生成模型实现。条件信号由两部分组成：（1）**场景观测视频** O_k——将 3D 点云沿相机轨迹渲染，提供背景和精确相机运动线索；（2）**手部关键点视频** O_{action}——提取 3D 手部关键点并通过相机内外参投影至 2D 平面，强制执行深度相关的透视缩短。系统刻意采用**核心关节关键点**而非稠密手部网格，因为关键点是跨具身的通用动作表示，便于从人手泛化到机器人末端执行器。此外引入二值掩码视频 M 标记因遮挡或不完全扫描导致的未观测区域。

去噪网络 ϵ_θ 实例化为 Diffusion Transformer (DiT)，处理拼接潜变量 $z_{in}^{(t)} = \mathrm{Concat}(z_t, z_{bg}, z_{hand}, M)$，训练损失为：

$$\mathcal{L}_{\text{gen}} = \mathbb{E}_{z_0,t,\epsilon\sim\mathcal{N}(\mathbf{0},\mathbf{I})}\left[\|\epsilon - \epsilon_\theta(z_{in}^{(t)}, t)\|_2^2\right]$$

DiT 使用预训练 inpainting 权重初始化（Wan-2.1-Fun-14B-InP），使模型作为带生成先验的恒等函数——保留已知背景 O_k，仅在动作条件区域激活生成。输入通道扩展至 52 以容纳动作条件。

2.2 交互感知状态更新

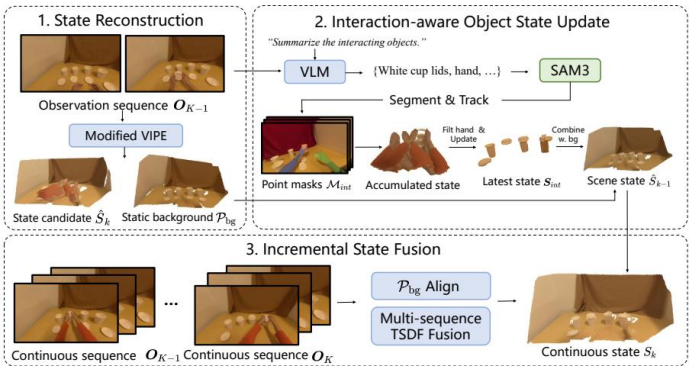

图 2：交互感知状态更新的三阶段实现：状态重建、对象状态更新、增量融合。

该模块为**无需训练**的管线，包含三个阶段：

状态重建。对第 K 次观测序列 $\{O_0, \ldots, O_{n-1}\}$，通过改进的 VIPE 管线重建状态候选 $\hat{S}_k$：DepthAnything3 估计相机内参，SAM3 提取实例掩码，双遍 DROID-SLAM 预测对齐的深度和相机位姿（第一遍跟踪稀疏特征并选择关键帧赋予度量深度，第二遍时间插值为非关键帧分配 6-DoF 位姿），多视角深度处理器解决尺度歧义。Grounding DINO + SAM3 检测交互对象并在重建时与静态对象解耦。

交互感知对象状态更新。五阶段层次化过滤流程：（1）视觉语言模型识别交互对象短语；（2）SAM3 开放词汇跟踪估计 3D 点掩码 $\mathcal{M}_{int}^i$；（3）以具身为中心的实例标记为主体参考；（4）IoU>0.15 筛选候选，深度一致性（中位深度差 <0.15m）过滤假阳性；（5）回溯检查更新最后观测帧的交互状态。排除 $\mathcal{M}_{int}$ 的点云融入静态背景 $\mathcal{P}_{bg}$，交互对象取最新帧几何合成入最终 $\hat{S}_k$。

增量状态融合。通过 Sim3 Umeyama 算法（基于重叠相机位姿 C_k 和 C_{k-1}）对齐坐标系，TSDF 融合合并点云（体素 0.003m，最大深度截断 3.0m），重叠区域由 $\hat{S}_k$ 更新。统计离群点移除（20 邻居，标准差比 2.0）提取干净的全局点云。

3. 可扩展数据管线

3.1 自动化数据处理

训练 EgoSim 需要对齐的四元组：静态 3D 场景、相机轨迹、具身动作序列、交互视频。管线全自动从大规模单目视频提取：

- **静态场景初始化**：提取首帧，SAM3 生成手部掩码，Qwen-Image-Editing 移除手部，DepthAnything3 估计深度并反投影为初始点云；
- **相机轨迹估计**：DepthAnything3 提取逐帧相机参数（旋转、平移、内参），渲染点云获得几何一致参考视频；
- **动作提取**：人手用 HaMeR 估计 21 关键点 MANO 骨架；机器人用关节轨迹 +URDF 计算 3D 关键点并映射为简化骨架（拇指 + 食指），实现**统一跨具身表示**；
- **数据清洗**：异常帧检测（平移 >0.1m 或旋转 >50°）、Pose Kalman 平滑、手部动作时序离群检测与去重。

处理 EgoDex 240K + EgoVid 160K + AgiBot 100K clips，共 **500K clips**，远超 DWM (110K) 和 Hand2World (<8K)。

3.2 EgoCap：低成本真实世界采集

使用未标定智能手机的两阶段采集：(1) 扫描环境构建 3DGS 地图（ARTDECO 流式重建 + 动态内参自标定）；(2) 录制自我中心交互，稠密匹配定位器恢复 6-DoF 轨迹；(3) 三次样条 +SLERP 插值 +Savitzky-Golay 全局平滑优化轨迹，重渲染产生对齐的配对数据。

4. 实验结果

4.1 定量对比（Normal Setting）

骨干初始化自 Wan-2.1-Fun-14B-InP，生成 832×480、61 帧、16FPS 视频。DiT 全量微调 4000 步（AdamW, lr=1×10^{-5}, 8×H200 GPU）。推理使用 Flow Matching 50 步，CFG=1.0。

方法	PSNR↑	SSIM↑	LPIPS↓	D-ERR↓	C-ERR↓
EgoDex (桌面场景)					
Wan-InP	17.998	0.447	0.708	42.335	0.0300
Mask2IV	20.622	0.814	0.299	38.339	0.0181
InterDyn	22.250	0.830	0.255	44.345	0.0226
EgoSim	**25.056**	**0.896**	**0.170**	**8.888**	**0.0013**
EgoVid (野外场景)					
InterDyn	14.612	0.466	0.484	38.180	0.0308
EgoSim	**16.684**	**0.509**	**0.421**	**19.260**	**0.0105**

EgoSim 在视觉质量和空间可控性上全面领先。Depth-ERR 从 InterDyn 的 44.345 降至 8.888（降低 **80%**），Cam-ERR 降低**一个数量级**（0.0226→0.0013），证明显式点云渲染提供了无歧义的空间锚定。InterDyn 无法解耦相机运动与手部运动，导致严重背景漂移；Mask2IV 难以保持手部和被操纵对象的身份一致性；CosHand 作为逐帧生成方法缺乏时序连贯性。

4.2 连续生成

在 EgoDex 上评估 121 帧（两个 61 帧片段 + 中间状态更新）序列。EgoSim (Continuous) 达到 PSNR 19.165、SSIM 0.835、LPIPS 0.220，Depth-ERR 从 8.888 升至 10.943，Cam-ERR 从 0.0013 升至 0.0017。性能下降主要源于生成伪影的累积误差和更新状态中的固有噪声，但整体仍保持鲁棒。可视化显示交互对象的 3D 状态被正确更新和注册——如杯盖正确盖合、面包被准确放置并在后续状态中维持。

4.3 消融实验

配置	PSNR	SSIM	LPIPS	D-ERR	C-ERR
w/o 轨迹渲染	23.380	0.845	0.244	10.238	0.0015
w/o 掩码约束	23.988	0.886	0.186	14.124	0.0022
完整 EgoSim	**25.056**	**0.896**	**0.170**	**8.888**	**0.0013**

相机轨迹渲染：去除后复制初始静态帧，PSNR 降至 23.380——缺少移动 3D 点云的物理约束，模型无法准确捕捉背景视差。**掩码约束**：全黑掩码仍达 PSNR 23.988，证明 inpainting 先验使 EgoSim 作为带生成先验的恒等函数有效工作；提供精确可见性掩码进一步优化动态交互与幻觉区域的融合。**可更新 3D 状态**的关键组件消融：去除交互对象过滤导致静态点云被手部等动态元素污染（鬼影）；去除 TSDF 融合产生碎片化噪声表面；去除空间掩码过滤引入浮动伪影。

4.4 跨具身机器人模拟

在 AgiBot-World 双臂机器人操作数据集上部署 EgoSim。50K 交互片段训练、150 片段测试。机器人末端执行器运动学直接投影至 3D 关键点空间。

- **w/o 手部预训练**：PSNR 15.180, SSIM 0.662, LPIPS 0.350；
- **w/ 手部预训练**：PSNR **18.670**, SSIM **0.725**, LPIPS **0.282**。

仅需 200 步微调（预训练模型）或 100 步微调（EgoCap 真实场景），即可实现有效迁移。在复杂叠衣任务中，从零训练模型无法生成正确的布料变形，预训练模型则准确模拟物理动力学——自我中心人手交互数据提供了可泛化的动力学先验。

5. 与现有方法的对比

- **vs. DWM**：DWM 场景重建一次不更新，依赖合成/配对数据（110K）；EgoSim 可更新状态 +500K 真实数据；
- **vs. PlayerOne**：依赖同步 ego-exo 视频对（难扩展），隐式场景编码限制空间一致性；
- **vs. Hand2World**：<8K 数据，蒸馏双向为自回归模型，无显式 3D 表示；
- **vs. InterDyn/Mask2IV**：2D 信号无 3D 锚定，无持久世界状态，空间误差高出数倍至数十倍。

6. 讨论与局限

核心贡献：（1）首个支持可更新 3D 世界状态的闭环自我中心模拟器；（2）交互感知状态更新模块处理关节物体操纵和多部件组装；（3）从野外单目视频提取对齐训练四元组的可扩展管线；（4）统一关键点表示实现跨具身迁移。

局限性：（1）单目深度和相机位姿估计在严重遮挡或高动态环境中偶尔失败，导致点云初始化不完美；（2）连续生成中累积误差逐步增大；（3）依赖 DepthAnything3、SAM3 等外部模型的精度；（4）当前仅支持人手和机器人夹爪，未扩展至更多具身类型。

未来方向：集成鲁棒多视角先验和基于物理的接触约束以进一步提升模拟保真度；扩展至更长时域和更复杂的多智能体交互场景。

LatentUM：通过潜在空间统一模型释放交错跨模态推理潜力

Jin[1], Zhou[1], Yang[2], Zhang[3], Liu[1], Zhu[2], Deng[1] — [1] 上海交通大学, [2] 清华大学, [3]UCSD, 2026

1. 动机与核心思想

统一模型（Unified Models, UMs）在跨模态理解与生成方面具有重要前景，但现有 UM 主要聚焦于视觉生成任务（文生图、图像编辑、视频生成），尚未发挥其真正价值。本文主张 UM 应用于**交错跨模态推理**——如通过逐步视觉推理解决空间规划问题、通过自我反思改进视觉生成、以及基于逐步动作干预建模物理世界视觉动态。

现有 UM 面临的核心问题：理解和生成使用**不相交的视觉表征**（理解用语义特征如 CLIP，生成用像素重建特征如 VQVAE），二者位于不同特征空间。模型无法直接推理自身生成的视觉内容，必须先将生成特征解码为像素再重新编码为语义特征。这种**像素空间中介**引入：

- **编解码偏差（Codec Bias）**：像素编解码过程中的信息损失和失真；
- **跨模态失配**：理解与生成表征之间的语义鸿沟；
- **计算冗余**：不必要的解码-重编码开销。

LatentUM 的核心贡献：将所有模态嵌入**共享语义潜在空间**，生成的视觉 token 可被模型自身直接解读，无需像素空间中介，天然支持灵活的交错跨模态推理。关键洞察：跨模态推理偏好**语义正确性**而非像素级保真度。

2. 系统架构

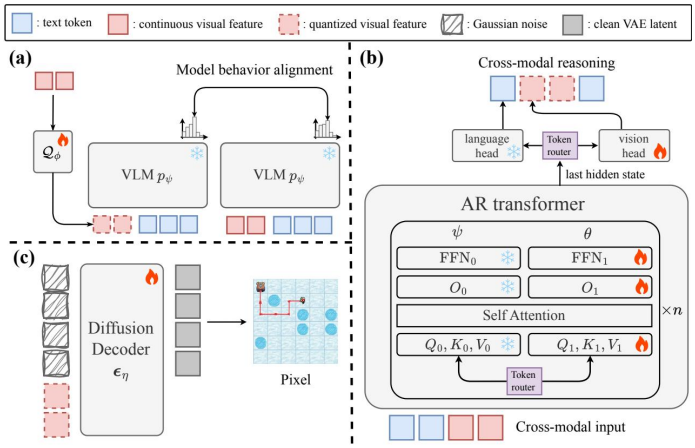

图 1: *LatentUM 架构概览。(a) MBAQ 视觉分词器通过 KL 散度对齐量化特征与原始特征的 VLM 输出分布；(b) MoME 双分支共享自注意力；(c) 解耦像素解码器。*

LatentUM 由三个核心组件构成：

2.1 视觉分词器：模型行为对齐量化（MBAQ）

选择 CLIP 特征作为视觉表征基础——其通过对比预训练天然与语言对齐。然而连续 CLIP 特征维度极高（$d \sim 4096$），直接建模需额外引入扩散模型，增加复杂度。

LatentUM 采用**多码本量化**（MCQ）：将每个 d 维 token 分为 $C = 8$ 个 chunk，每个 chunk 用独立码本（大小 $K = 2048$）量化，有效词汇量为 $K^C = 2048^8$，仅需 $K \times C = 16384$ 个码本条目。离散码矩阵 $\mathbf{Z} \in [K]^{C \times L}$。

MBAQ 目标：传统量化优化像素重建，MBAQ 优化视觉理解能力保持。给定 VLM p_ψ 和 VQA 数据集，训练量化器 $\mathcal{Q}_\phi$ 最小化 VLM 在原始特征 $\mathbf{V}$ 与量化特征 $\mathcal{Q}_\phi(\mathbf{V})$ 上的输出分布 KL 散度：

$$\mathcal{L}_{\mathrm{KL}}^{i,j} = \mathbb{D}_{\mathrm{KL}}\left[p_\psi(\mathbf{Y}_j^i \mid \mathbf{Y}_{<j}^i, \mathbf{X}^i, \mathbf{V}^i) \,\|\, p_\psi(\mathbf{Y}_j^i \mid \mathbf{Y}_{<j}^i, \mathbf{X}^i, \mathcal{Q}_\phi(\mathbf{V}^i))\right]$$

结合 MCQ commitment loss $\mathcal{L}_{\mathrm{MCQ}}$（含码本损失、commitment 损失、熵正则化促进均匀码本使用），总目标 $\mathcal{L}(\phi) = \mathcal{L}_{\mathrm{KL}} + \lambda \mathcal{L}_{\mathrm{MCQ}}$，$\lambda = 1.0$。量化器参数量仅 101M。

2.2 混合模态专家（MoME）

朴素统一训练会引入语言与视觉任务间的梯度冲突。MoME 在每个 Transformer 层维护**两个并行分支**：

- **理解分支** ψ：处理交错文本与视觉特征的理解任务；
- **生成分支** θ：专注生成离散视觉 token。

两分支**共享自注意力机制**（实现跨模态信息流），但维护独立的 FFN 和投影矩阵。路由由 `<BOI>` 特殊 token 决定。生成的视觉码经反量化后**重缓存至理解上下文**，使后续 token 基于 ψ 的 KV cache 推理——这是实现交错推理的关键。

2.3 视觉预测头

轻量级因果 Transformer（3 层，283M 参数），在每个视觉 token 位置**自回归预测 C 个码本索引**，捕获同一 token 内码索引间的依赖关系。

2.4 解耦像素解码器

生成的语义特征不针对像素重建优化，但可通过独立的扩散解码器 ϵ_η（基于 Stable Diffusion 3.5 Medium MMDiT）渲染为像素。以量化特征 $\tilde{\mathbf{V}}$ 为条件信号：$\mathcal{L}_{\mathrm{diff}}(\eta) = \mathbb{E}_{t,\epsilon,\mathbf{x}_0}[\|\epsilon - \epsilon_\eta(\mathbf{x}_t, t, \tilde{\mathbf{V}})\|^2]$。**核心设计**：解码器独立训练、可选调用，主模型从不优化像素重建，保持潜在空间聚焦语义。

3. 训练流程

3.1 预训练

基于 InternVL3.5-4B 架构与预训练权重实现 LatentUM$_{\mathrm{Base}}$。理解分支 ψ 直接初始化自 InternVL3.5-4B 并**冻结**，仅训练生成分支 θ（3633M 参数）。在 32M 文图对（BLIP3o）上以多码 next-token prediction 目标训练：

$$\mathcal{L}_{\text{MC-NTP}}(\theta) = -\frac{1}{L}\sum_{\ell=1}^{L}\frac{1}{C}\sum_{c=1}^{C}\log p_\theta(\mathbf{Z}_{c,\ell} \mid \mathbf{Z}_{<c,<\ell}, \mathbf{X})$$

训练 4 天 × 64 H100 GPU。像素解码器独立训练（微调条件分支 990M 参数），2 天 × 32 H100。

3.2 后训练：监督微调

联合微调 ψ 和 θ，在交错多模态序列上进行 next-token prediction。关键技术：多帧交错推理时，视觉 token 需同时经 θ（计算生成损失）和 ψ（构建后续理解上下文）处理，通过**特殊注意力掩码**在单次前向传播中并行处理两路序列。

3.3 后训练：强化学习（GRPO）

模型生成 $G = 16$ 个跨模态 rollout，采用 GRPO 优化。奖励来源有二：（1）外部奖励模型；（2）**自奖励**——模型利用自身理解能力评估生成结果。给定生成的视觉特征 $\tilde{\mathbf{V}}$ 和验证问题 ν（多选题），计算 $\mathcal{R}_g = \exp(\rho_{\mathrm{gt}}/\tau)/\sum_i \exp(\rho_i/\tau)$。理解分支 ψ 固定，仅优化 θ，解耦奖励评估与策略学习。

4. 核心实验结果

4.1 视觉理解

LatentUM$_{\mathrm{Base}}$ 在连续特征设定下几乎完全保留 InternVL3.5-4B 的理解能力：MME-P 1654、POPE 88.9、SEED 76.3、MMBench 80.3、MMMU$_{\mathrm{val}}$ 54.6，全面优于 Janus Pro、Show-o2 等同量级 UM。**量化特征设定**下性能下降极小（MME-P 1638、MMMU 52.3），部分指标甚至超越使用原始连续特征的基线，验证 MBAQ 保留了语义信息。

4.2 视觉生成

模型	GenEval Overall ↑
FLUX.1 [Dev]（专用）	0.66
Qwen-Image（专用）	0.87
Janus Pro	0.80
Bagel	0.82
BLIP3o 8B	0.84
LatentUM$_{\mathrm{Base}}$	0.85
LatentUM$_{\mathrm{Vis\text{-}Gen}}$（自奖励）	**0.87**
+ pixel-reward	**0.92**

LatentUM$_{\mathrm{Base}}$ 在 GenEval 上以 0.85 超越所有 UM，尽管训练数据量最少。通过 GRPO 自反思后训练的 LatentUM$_{\mathrm{Vis\text{-}Gen}}$ 达 0.87；替换为外部 pixel-reward 进一步提升至 0.92，**在 UM 中达 SOTA**。

在 GenEval2（MLLM-as-judge，更鲁棒）上优势更显著：LatentUM$_{\mathrm{Vis\text{-}Gen}}$ TIFA$_{\mathrm{GM}}$ 31.3 / TIFA$_{\mathrm{AM}}$ 72.9，大幅超越 Bagel+CoT（23.1/70.9）和 BLIP3o 8B（13.3/59.4），验证自奖励机制的有效性。

4.3 交错跨模态推理：视觉空间规划

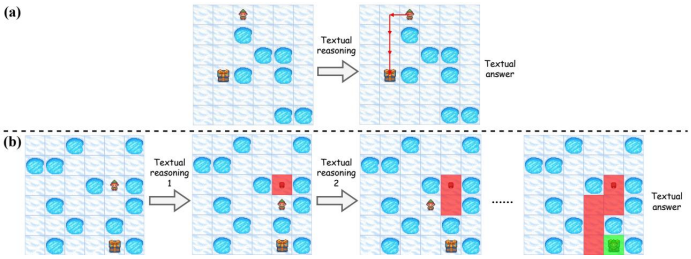

图 2：两种交错推理范式。*(a)* 粗粒度：先分析迷宫布局，生成完整视觉规划，再推导解。*(b)* 细粒度：逐步交替文本推理与视觉状态更新。

在 Visual Spatial Planning（VSP）基准上评估两种推理范式：
粗粒度规划：三阶段——文本分析迷宫布局 → 生成完整视觉规划 → 推导解答。使用 ThinkMorph 的 6000 训练样本。
细粒度逐步规划：每个文本动作（如"向上移动"）后生成更新的视觉状态作为下一步上下文，将复杂空间规划分解为细粒度视觉-文本推理步骤。构建 18000 训练样本。

模型	Lv.3	Lv.4	Lv.5	Lv.6	Avg.
Mirage	0.93	0.83	0.76	0.51	0.76
ThinkMorph	–	–	–	–	0.76
LatentUM（粗）	1.00	0.85	0.83	0.71	0.85
LatentUM（细）	1.00	1.00	1.00	0.97	**0.99**

$\text{LatentUM}_{\text{Vis-Plan}}$ 在两种范式下均全面超越所有基线。与 ThinkMorph（基于 Bagel，依赖像素空间中介）对比尤为关键：**共享语义表征比像素空间桥接更有效**。细粒度范式（0.99）远超粗粒度（0.85），表明统一潜在表征支持更深层交错推理。

4.4 世界建模

在 NWM 基准的机器人导航场景中，$\text{LatentUM}_{\text{WM}}$ 在 RECON 数据集上微调后，将导航动作表示为文本 token，预测未来视觉状态的离散语义 token。结果：ATE 1.34、RPE 0.34，超越 Transfusion-RAE，与专用 NWM 模型竞争。此外展现**零样本语言条件导航**能力——无需语言监督即可根据自由文本指令（如"靠近左边的房子"）生成准确的未来视觉状态。

5. 消融实验

5.1 语义特征 vs 像素重建特征

替换为 VQVAE 特征（LlamaGen），架构和数据完全相同。LatentUM 在 GenEval 和 GenEval2 上均显著优于 VQVAE 基线，尤其在文本渲染和指令遵循方面差距明显，确认**语义对齐的视觉特征对指令遵循至关重要**。

5.2 MBAQ vs 特征重建量化

对比 MSE 损失和 cosine similarity 损失的直接特征重建量化器。MBAQ 在 5 个视觉理解基准上**一致优于**两种重建基线，表明在量化训练中融入 next-token prediction 行为比单纯特征重建更有效。

6. 讨论与局限

核心贡献：（1）首个将理解和生成统一于共享语义潜在空间的模型，消除像素空间中介；（2）MBAQ 量化方案保留理解能力而非像素保真度；（3）MoME 架构缓解跨模态梯度冲突；（4）在 VSP（0.99）、GenEval（0.92）、GenEval2 上达到 UM SOTA；（5）初步验证世界建模可行性。
主要局限：

- 限于固定分辨率生成（448 × 448），预训练规模相对有限；
- 世界建模 rollout 仍依赖像素空间循环接口（解码后重编码），非完全潜在空间循环预测；
- MBAQ 目前仅对齐单个 VLM（InternVL3.5-4B）的行为，所学语义表征的泛化性未充分探索；
- 未来方向包括扩展预训练规模、可变分辨率与长上下文生成、改进长时间预测的时序一致性、以及开发完全潜在空间的世界建模与规划流程。

OMNI-SIMPLEMEM：自主研究驱动的终身多模态智能体记忆发现

Liu[1], Ling[2], Qiu[1], Liu[3], Han[1], Xia[1], Tu[3], Zheng[4], Xie[3], Fleming[5], Ding[1], Yao[1] — [1]UNC, [2]UPenn, [3]UCSC, [4]UCB, [5]Cisco, 2026

1. 动机与问题

AI 智能体日益需要在长时间跨度中与用户交互，积累文本、图像、音频、视频等多模态信息流。然而，如何有效**保留、组织和检索**这些多模态经验仍是关键瓶颈。构建有效的终身多模态记忆需要在架构设计、检索策略、提示工程和数据管线配置等维度上导航一个**庞大且高度耦合**的设计空间。

现有方法分两类，均有显著局限：(1) **原始存储 + 嵌入检索**（RAG 范式），随记忆增长面临存储膨胀和检索噪声；(2) **结构化记忆管理**（如 MemGPT、Generative Agents），通常仅处理文本，丢弃丰富的视觉和听觉信号。两类方法均依赖人工研究循环（每天仅能探索约 3 个配置），且传统 AutoML 只能搜索预定义数值超参空间，**无法**执行代码理解、Bug 诊断、架构重设计和跨组件推理——而这些恰恰贡献了最大的性能提升。

本文部署 **AUTORESEARCHCLAW**（23 阶段自主研究管线）来发现 OMNI-SIMPLEMEM，一个统一的多模态终身记忆框架。从朴素基线（LoCoMo F1=0.117）出发，管线在两个基准上自主执行约 50 次实验，迭代诊断失败模式、提出架构修改、修复数据管线 Bug，**内循环无需人工干预**。

发现类型	关键量化影响
Bug 修复（JSON format 缺失）	F1 +175%
架构变更（BM25 混合检索）	F1 +44%
提示工程（约束位置优化）	特定类别 +188%
数据修复（时间戳校正）	F1 +7%
超参调优（全部累计）	低于上述任一项

最终系统在 LoCoMo 上 F1 提升 +411%（0.117 → 0.598），在 Mem-Gallery 上提升 +214%（0.254 → 0.797），均达到 SOTA。

2. 系统架构

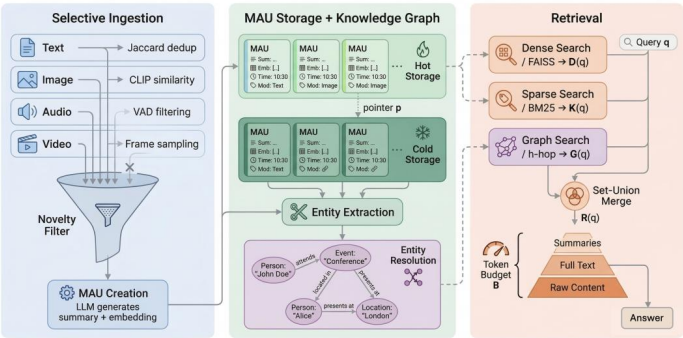

图 1：*OMNI-SIMPLEMEM* 架构。左：选择性摄入通过新颖度过滤创建 *MAU*；中：热/冷双层存储 + 知识图谱；右：混合检索 + 金字塔渐进扩展。

管线从 SimpleMem（纯文本终身记忆框架）出发，通过迭代实验收敛到围绕三个原则组织的架构：**选择性摄入、渐进检索、结构化知识**。

2.1 选择性摄入与 MAU

新颖度过滤。轻量感知编码器在数据进入存储前评估信息新颖度：视觉通道用 CLIP 嵌入比较连续帧检测场景变化；音频通道用 VAD 语音概率门控过滤静音；文本通道用 Jaccard 重叠与近期摘要比较过滤近重复。此过滤显著降低存储需求而不损失语义内容。

多模态原子单元（MAU）。通过过滤的信号被封装为 MAU：$\mathcal{M} = \langle s, \mathbf{e}, p, \tau, m, \ell \rangle$，其中 s 为文本摘要，$\mathbf{e} \in \mathbb{R}^d$ 为嵌入向量，p 指向冷存储中的原始内容，τ 为时间戳，m 为模态标签，ℓ 为结构化链接。系统采用**双层存储设计**：热存储保存摘要、嵌入和元数据用于快速检索，冷存储保存大型资产（图像、音频、视频），通过 p 按需延迟访问。

2.2 混合稠密-稀疏检索

给定查询 q，FAISS 稠密检索通过 L2 归一化 MAU 嵌入的内积搜索得到语义相似候选 $\mathcal{D}(q)$；BM25 稀疏检索在 MAU 摘要上进行关键词匹配得到 $\mathcal{K}(q)$。管线自主发现的关键策略是**集合并集合并**——基于分数的重排序（标准方法）会破坏语义排序并降低性能，因此稠密结果保留原始排序，仅追加 BM25 独有结果：

$$\mathcal{R}(q) = \mathcal{D}(q) \cup \big(\mathcal{K}(q) \setminus \mathcal{D}(q)\big)$$

2.3 金字塔渐进检索

候选集 $\mathcal{R}(q)$ 中每个候选由余弦相似度 $\mathrm{sim}(q, \mathcal{M}_i) = \mathbf{e}_q^\top \mathbf{e}_i$ 评分。金字塔机制在三个层级渐进扩展内容：

- **Level 1**：仅返回 top-k 候选的摘要（∼10 token/条）；
- **Level 2**：相似度超过阈值 θ 的候选加载完整文本或详细描述；
- **Level 3**：在显式 token 预算 B 下从冷存储加载原始内容（图像、音频），按相似度/token 贪心扩展。

所有转换由**确定性规则**（非 LLM 判断）控制，避免额外延迟。消融实验证实金字塔扩展是最关键组件（移除导致 −17% F1）。

2.4 知识图谱增强检索

许多查询需要跨多个连接事实的推理（如 “我在三月会议上认识的人送了我什么礼物?”）。系统维护知识图谱 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$，在 MAU 创建时由 GPT-4o 以 JSON 模式提取实体和有向关系三元组。实体类型涵盖 7 类（Person、Location、Event、Concept、Time、Organization、Object）。

实体解析通过混合相似度（名称嵌入余弦相似度 + Jaro-Winkler 字符串相似度）超过阈值时合并实体，防止节点碎片化。查询时提取种子实体 $\mathcal{V}_q \subset \mathcal{V}$，执行 h 跳有界邻域扩展，每个到达的实体按距离衰减相关性评分：$r_{\mathcal{G}}(v) = \beta^{d(v,\mathcal{V}_q)} \cdot \mathrm{conf}(v)$，其中 $\beta \in (0,1)$ 为衰减因子。高分图实体关联的 MAU 与混合搜索结果合并。

3. 自主优化过程与发现分类

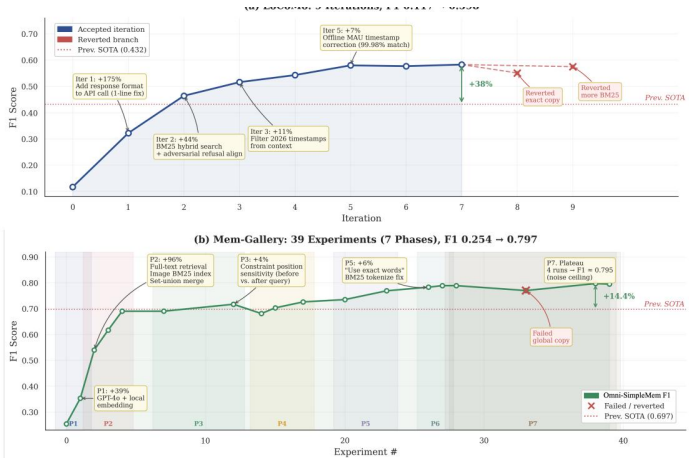

图 2：*LoCoMo*（上，*9* 次迭代）和 *Mem-Gallery*（下，*39* 次实验，*7* 阶段）的优化轨迹。× 标记失败/回滚实验。

管线在约 72 小时内完成约 50 次实验（人工研究者需约 4 周）。每步分析先前结果、生成改进假设、实现代码变更、评估指标，根据结果决定继续（≥ 0.5% 提升）、迭代（结果模糊）或转向（连续两次退化则回滚）。

LoCoMo（9 次迭代，F1： 0.117 → 0.598）。最具影响的发现（Iter 1，+175%）是识别出 API 调用缺少 `response_format` 参数——一行 Bug 导致 9× 冗余输出摧毁了 F1 精度。Iter 5 发现全部 4,277 个 MAU 时间戳被损坏为摄入日期，自主生成关键词匹配脚本修正 99.9% 而无需重新摄入。Iter 2 发现 FAISS+BM25 集合并集合并显著优于基于分数的融合。

Mem-Gallery（39 次实验，F1： 0.254 → 0.797）。最大单次提升（+53%）来自发现返回**完整原始对话文本**而非 LLM 摘要能大幅改善 token 重叠 F1——反直觉，因摘要传统上被认为更高效。管线还发现提示约束**位置**（问题前 vs. 后）比约束内容更重要，单一类别因此提升 +188%。Phase 7 四次独立运行 F1 在 [0.791, 0.797]，确认性能天花板后管线自主终止。

管线提出**六类发现分类**：Bug 修复、架构变更、提示工程、数据修复、格式对齐、超参调优。关键观察：**前三者的单项**

贡献均超过全部超参调优的累计贡献，证明此类能力根本超越传统 AutoML 的范围。

4. 实验结果

4.1 主要结果

在 5 种 LLM 后端（GPT-4o/4o-mini/4.1-nano/5.1/5-nano）上与 6 个基线（MemVerse、Mem0、Claude-Mem、A-MEM、MemGPT、SimpleMem）对比：

LoCoMo： OMNI-SIMPLEMEM 在所有后端上达到最高 overall F1（0.492–0.613），大幅超越当前 SOTA SimpleMem（0.342–0.432）。在 multi-hop、single-hop 和 open-domain 类别上优势尤为显著。

Mem-Gallery： F1 达 0.749–0.810，一致超越所有基线。最强基线 SimpleMem（GPT-5.1 下 F1=0.538）仍落后超过 25 个百分点。先前 SOTA MuRAG 为 0.697，OMNI-SIMPLEMEM 以 0.797 超越。

4.2 消融实验

在 LoCoMo 上跨 4 个 LLM 后端的均值 ΔF1：

移除组件	ΔF1	相对
金字塔扩展	−10.2	−17%
BM25 混合检索	−8.5	−14%
LLM 摘要	−7.3	−12%
top-k 20→5	−4.2	−7%
元数据上下文	−1.4	−2%

最关键的两个组件（金字塔扩展和混合检索）恰好是获得最多优化迭代的组件，表明管线正确分配了搜索预算。

4.3 效率分析

OMNI-SIMPLEMEM 在 8 并行 worker 下达到 **5.81 queries/sec**，比最快基线快 3.5×。所有基线受限于顺序 LLM 生成（占单查询时间 85–97%），而 OMNI-SIMPLEMEM 通过**线程安全只读 FAISS/BM25 索引**实现检索-生成管线并行化。单 worker 下检索延迟 118ms、生成 846ms；8 worker 下检索摊销至 461ms 但生成延迟几乎不变（821ms）。

4.4 多跳检索案例

查询 “Caroline 和 Melanie 都画过什么主题？”（答案：sunsets）。稠密检索返回 Caroline 画日落的 MAU 和 Melanie 艺术项目的 MAU（分散在不同会话中）；BM25 补充含 “paint” 关键词但稠密排名较低的 MAU；集合并集保留稠密排序并追加 BM25 独有结果。知识图谱扩展从种子实体 CAROLINE 和 MELANIE 出发，通过独立关系路径链接到 PAINTING 和 SUNSET 概念。金字塔 Level 1 加载两条路径的摘要，相似度超过 θ 后 Level 2 扩展完整对话文本，LLM 正确识别 “sunsets”（F1=1.0）。对比 MemGPT 因缺乏跨会话实体链接而幻觉出 “Horses”（F1=0.0）。

5. Autoresearch 适用性分析

论文识别出多模态记忆特别适合自主研究管线的**四个属性**：

- **即时标量评估指标**：F1 提供紧密优化循环反馈；
- **模块化架构**：摄入、存储、检索、生成可独立修改；
- **快速迭代周期**：每次实验 1–2 小时，支持数天内探索数十个假设；
- **版本控制代码修改**：失败实验可干净回滚。

6. 局限与未来方向

- 管线仍依赖**预定义评估指标**，无法优化难以量化的用户体验维度；
- 知识图谱构建依赖 GPT-4o 调用，摄入成本较高（类似 MemVerse 的 3 次 LLM 调用/项）；
- 当前仅在两个基准上验证，更大规模和更多样的场景（如长视频流、实时交互）有待探索；
- 自主管线的发现可解释性有限——虽知 “什么有效” 但不总能解释 “为什么有效”；
- 默认配置在不同 LLM 后端间存在差异（如 GPT-4.1-nano 上 F1 仅 0.492），鲁棒性有提升空间；
- 将 autoresearch 范式推广到其他复杂 AI 系统（如规划、工具使用）是有前景的方向。

Steerable Visual Representations：用自然语言引导视觉表征

Ruthardt[1], Gaur[2], Ramanan[2], Tapaswi[3], Asano[1] — [1]UTN, [2]CMU, [3]IIIT-H, 2025

1. 动机与问题定义

预训练视觉 Transformer（ViT）如 DINOv2、MAE、SigLIP 提供通用图像表征，广泛用于检索、分类与分割等下游任务。然而，这些表征倾向于聚焦图像中**最显著的视觉线索**（如主体物体），无法引导其关注不显眼的概念。这源于摄影偏差和以物体为中心的数据集设计。例如，室内场景中 DINOv2 编码聚焦于 “猫”，忽略 “遥控器” 或 “书架”。

多模态大语言模型（MLLM）可通过文本提示引导，但其表征偏向语言空间，在通用视觉任务上效果下降。现有视觉-语言模型（如 CLIP）在编码**之后**才融合文本（后融合），文本无法影响视觉编码过程本身。

作者提出可引导视觉表征应满足的三项准则：

- **可引导性**：表征应随输入文本自适应，可控制编码 “什么” 及嵌入空间的组织方式；
- **表征质量**：引导后的表征应支持检索、分类、分割等多样化视觉任务；
- **早期视觉-语言融合**：语言应在视觉编码的早期层即介入特征提取过程。

如表 1 所示，现有方法无法同时满足三项准则：单模态 ViT 不可引导；CLIP 等跨模态编码器为后融合，视觉特征独立于查询；OV 定位模型（SAM3）可引导但特征专用于定位、不通用；MLLM 部分可引导但参数量 ≥1B 且表征偏语言。SteerViT 仅添加 **21M 可训练参数**，在冻结 ViT 内部实现早期融合，同时满足全部三项准则。

2. 系统架构

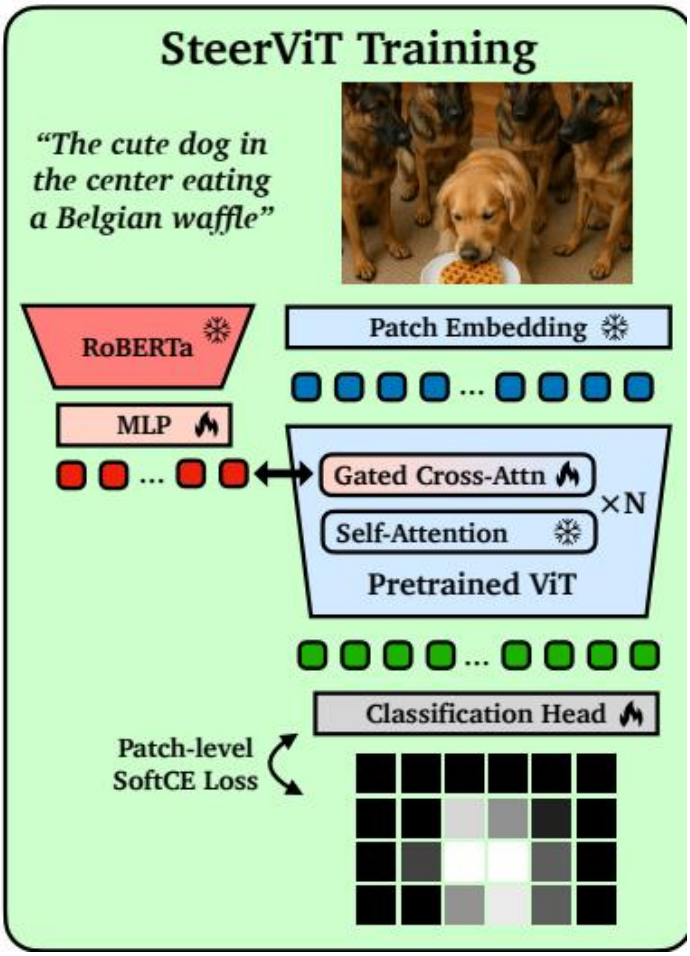

图 1: *SteerViT* 架构。在冻结 *ViT* 块中插入轻量级视觉 → 语言交叉注意力层，通过 *patch* 级分割代理任务将文本线索融入 *patch token*。

SteerViT 由四个组件构成：

2.1 A. 视觉编码器

对图像 $X_v \in \mathbb{R}^{H\times W\times 3}$，ViT 生成 N 个 patch token $Z_v \in \mathbb{R}^{N\times d_v}$ 及可选 [CLS] token。所有原始 ViT 参数在训练中**完全冻结**，新容量仅来自插入的交叉注意力层。主实验采用 DINOv2 ViT-B/14，同时验证了 SigLIP 和 MAE 的适用性。

2.2 B. 文本编码器

采用冻结的 RoBERTa-Large 生成 token 级嵌入 $Z_t \in \mathbb{R}^{L\times d_t}$，$L$ 为文本 token 数。

2.3 C. 多模态适配器

每个文本嵌入经 ℓ_2 归一化后通过可训练的两层 MLP，投影至视觉对齐空间 $H_t \in \mathbb{R}^{L\times d_v}$。消融实验表明 MLP 优于单层线性投影（PODS 提升 1.7 点）。

2.4 D. 门控交叉注意力层

核心创新：**反转** Flamingo 的门控交叉注意力（CA）——让视觉隐状态关注语言 token（Flamingo 中是语言关注视觉）。CA 层插入每隔一个 Transformer 块中（12 层 ViT-B 插入 6 个 CA 层）。视觉 patch token $Z_v^{(\ell)}$ 为 query，适配后文本 token H_t 为 key/value：

$$\hat{Z}_v^{(\ell)} = \mathrm{CA}(Z_v^{(\ell)}, H_t) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

其中 $Q = Z_v^{(\ell)}W_Q$，$K = H_tW_K$，$V = H_tW_V$。输出通过 **tanh 门控**整合进残差流：

$$Z_v^{(\ell+1)} = Z_v^{(\ell)} + \tanh(\alpha_\ell)\cdot \hat{Z}_v^{(\ell)}$$

α_ℓ 为逐层可学习标量，**初始化为零**。由于 $\tanh(0)=0$，初始化时模型等价于原始冻结 ViT。梯度信号通过 $\frac{\partial Z_v^{(\ell+1)}}{\partial \alpha_\ell} = \mathrm{sech}^2(\alpha_\ell)\cdot \hat{Z}_v^{(\ell)}$ 传播（$\mathrm{sech}^2(0)=1$），α_ℓ 可在优化中逐步偏离零，渐进激活语言条件化路径。

推理时连续调控：可通过缩放因子 $\omega \in [0,1]$ 对 α_ℓ 进行后处理，平滑插值于原始 ViT（ω=0）与完全文本条件化（ω=1）之间。实验发现 ω=0.6 为 DINOv2 和 SigLIP 的最优 Pareto 点——此时略超原始 ViT 表征质量的同时解锁高可引导性。对 MAE，表征质量随 ω 单调提升（40→50），说明文本条件化为 MAE 注入了语义结构。

2.5 训练目标

选择**指称分割**（referential segmentation）作为代理任务：给定图像 X_v 和指代目标的文本提示 X_t，预测哪些 patch 对应被指称区域。真值 y_i 为像素级二值掩码 patchify 后的前景像素占比。线性分类头将每个 patch 表征映射为掩码概率 p_i，采用**软交叉熵损失**：

$$\mathcal{L} = -\sum_{i=1}^{n\times n} y_i \log p_i$$

该损失鼓励 CA 层将文本信息路由至对应视觉 patch token。在 patch 而非 pixel 级别操作避免了像素级解码器，降低训练复杂度。消融表明分割优于指向（Pointing）训练目标：FG-CLS +7.3, ADE20k +8.0, PODS +12.4。

2.6 训练数据

混合 RefCOCO/+/g、Visual Genome、LVIS 和 Mapillary Vistas，共 **162k 唯一图像**和 **2.28M 图像-文本对**，覆盖多样视觉域和文本表达风格。训练配置：DINOv2 ViT-B/14 + RoBERTa-Large，336×336 分辨率，batch size 12，500k 迭代（~84 H100 GPU 小时），AdamW + 余弦调度（warmup 至 3×10^{-4}，衰减至 3×10^{-5}）。

3. 核心实验结果

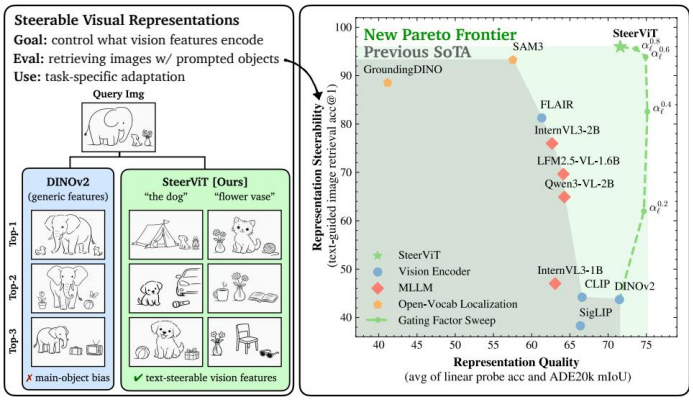

图 2: *SteerViT* 在可引导性与表征质量之间实现 *Pareto* 改进。左：条件检索示例。右：各模型在文本引导检索 *vs.* 视觉表征质量上的对比。

3.1 CORE 条件检索：引导全局语义

提出 **CORE**（COnditional REtrieval）基准：从 SUN397 选取 6 个场景各 100 张图，使用 FLUX.2 为每张图嵌入 5 个场景相关物体，以 one-vs-all 检索衡量模型将全局特征从场景级相似性引导向指定非显著物体的能力。

方法	CORE Acc@1 (%)
MAE	21.8
DINOv2	43.7
CLIP / SigLIP	44.3 / 38.3
FLAIR（后融合）	81.3
InternVL3-1B / 2B	47.0 / 76.0
SAM3	93.3
SteerViT	**96.0**

关键发现：（1）查询无关编码器坍缩至显著概念，MAE 仅略超随机（20%）；（2）后融合无效——CLIP/SigLIP 加文本仅提升 0.02%；（3）SteerViT 从 DINOv2 的 43.7% 提升至 96.0%；（4）条件化随机错误类别时 SteerViT 下降 47.7 点，证实可引导性由文本驱动。在真实图像基准 GeneCIS 上，SteerViT 零样本 R@1 达 25.4%（DINOv2: 9.6%，专用方法: 18.7%）。

3.2 MOSAIC 定位：文本实现定向注意力

将 4 张 PASCAL-VOC 图像拼成 2×2 马赛克（363 张），测量 [CLS]-to-patch 注意力与真值分割的 PR-AUC。DINOv2 聚焦最显著物体，仅 14.3%；**SteerViT 达 50.2%**，可将注意力精确路由至文本指定的物体。值得注意的是，尽管训练数据仅包含单实例，SteerViT 展现出**多实例定位的涌现能力**。

3.3 保持视觉表征质量

在 ImageWoof、Waterbirds、StanfordCars 上训练线性探针（FG-CLS），并在 ADE20k 上评估二值分割。SteerViT 在可引导性和表征质量两个维度上实现 **Pareto 改进**（图 2 右）：OV 定位模型可引导但特征不通用，MLLM 参数量巨大且密集预测差，SteerViT 两者兼顾。DINOv2 基础上 FG-CLS 从 89.0 略降至 87.7，但通过 ω=0.6 调控可恢复甚至超越原始质量。

3.4 文本精度控制语义粒度

在 PODS（个性化物体判别）基准上，SteerViT 的表征质量随提示精度显著提升：粗粒度（"mug"）时 27.9% PR-AUC，实例级描述时跃升至 **58.1%**，超越在合成数据上微调的 DINOv2（48.0%），且仅需**单一模型**（对比 DINOv2 需 100 个物体特定模型）。检索 NDCG 达 77.3%（微调 DINOv2: 79.6%）。

3.5 引导嵌入空间拓扑

UMAP 可视化 500 张 PASCAL-VOC 图像的全局特征：DINOv2 按物体类别刚性聚类；SteerViT 条件化 "animal" 后形成动物/非动物两大簇且保留细粒度结构；条件化 "bird" 增强鸟/非鸟可分性；条件化 "eye"（组合属性）将所有有眼的类别（含人类）聚合，突破语义类别边界。这表明 SteerViT 可通过文本同时控制**语义抽象层次**和**聚类准则**，且此行为在训练中未被显式鼓励——属涌现能力。

3.6 零样本域迁移：异常检测

在工业 MVTec AD 数据集上进行零样本异常分割，条件化为 "the anomaly in the <object>"。SteerViT 达 **82.1 PRO**，大幅超越 SAM3（54.5）、CLIPseg（34.6），接近专用方法 FADE（84.5）。在 VisA 数据集上，SteerViT ROC$_P$=92.1 和 PRO=82.0 均**超越 FADE**（91.5/79.3）。这是极端 OOD 场景下无任务特定训练的结果。

4. 消融实验

架构消融（表 4, DINOv2 ViT-B/14）：

- **早期 vs. 后融合**：后融合 CORE 达 93.3 但 PODS 仅 36.6（SteerViT: 58.1），早期融合对细粒度视觉-语言建模至关重要；
- **tanh 门控**：去除后 FG-CLS−4.2, PODS−11.0，无门控交叉注意力破坏冻结特征；
- **MLP 投影器**：替换为线性层后 FG-CLS−1.0, PODS−1.7；
- **FFN**：添加 Flamingo 式前馈网络反而降低性能（+67% 参数但 CORE−1.0, MVTec−2.8），故最终架构省略 FFN。

跨骨干泛化（表 5）：

- DINOv2: 43.7→96.0, SigLIP: 38.3→91.3, MAE: 21.8→74.9（均为 CORE）；
- 早期融合在所有骨干上优于后融合，对 MAE 和 SigLIP 优势更显著（+33.9/+15.9 vs. DINOv2 +2.7）；
- 层级分析：SteerDINOv2 在最终层才剧烈偏离基础模型，SteerSigLIP 渐进偏离，SteerMAE 在中间层偏离后回归原始空间。

训练目标：分割远优于指向（Pointing）——分割教模型物体"长什么样"而非仅"在哪里"。

训练时长：可引导性 50k 迭代即涌现（CORE 95.3%），但深层语言理解持续改善至 500k（PODS: 49.9→58.1, RefCOCOg: 63.4→70.6）。

模型缩放：ViT-S→B→L 持续改善；RoBERTa-Base→Large 也提升视觉任务表现，表明更丰富的文本嵌入为 ViT 残差流注入更多语义结构。

5. 讨论与局限

SteerViT 开创了**"条件化视觉于语言"**的新范式（而非传统的"条件化语言于视觉"），通过仅 21M 参数的轻量级交叉注意力实现冻结 ViT 的文本可引导性，同时保持表征质量。类比 prompting 适配 LLM，语言可作为后处理引导机制将丰富视觉编码器扩展至新域而无需微调。

主要局限：

- 可引导性依赖文本提示质量——粗粒度提示可能不足以捕捉细粒度区分；
- 当前仅验证了 patch 级分割精度，像素级精细分割需额外解码器；
- 在 VNN-COMP 等需要极紧界的任务上，IBP/CROWN 式方法仍有差距；
- 异常检测中某些无可见缺陷的类别（如翻转螺母）零样本无法处理；
- 尚未扩展至大规模视觉/语言模型（ViT-G 等）和视频领域。

核心贡献总结：（1）首个在冻结 ViT 内部通过早期融合实现文本可引导视觉表征的框架；（2）在可引导性-表征质量二维空间实现 Pareto 改进；（3）文本提示实现跨域零样本泛化（个性化物体判别、工业异常检测），匹配或超越专用方法。

VOID：视频物体及其交互删除——物理合理的反事实视频编辑

Motamed[1,2], Harvey[1], Klein[1], Van Gool[2], Yuan[1], Cheng[1] — [1]Netflix, [2]INSAIT Sofia University, 2026

1. 问题动机与背景

视频物体移除（video object removal）是视频编辑中的核心任务。现有方法擅长修复被移除物体“背后”的内容并消除光度级伪影（阴影、反射），但当被移除物体与场景存在**复杂物理交互**（碰撞、支撑、操控）时，现有模型无法修正下游因果效应，产生物理不合理的结果。

例如：移除多米诺骨牌链中间的几块后，后续骨牌仍在倒塌——这在物理上不可能；正确结果应是后续骨牌保持直立。这要求编辑模型具备**高层因果推理**能力：先回答“如果这个物体不存在，场景会怎样演化？”，再合成对应的反事实视频。

- 视频分解方法（Omnimatte 系列）擅长提取阴影/反射等光度效应，但无法解耦物体间的物理交互（如碰撞导致的运动变化）；
- 文本引导视频编辑模型（Runway、VACE）缺乏物理直觉，且文本难以精确描述所有下游效应；
- 视频修复方法（ProPainter、DiffuEraser）仅做空间填补，不涉及因果推理。

VOID 将视频物体移除扩展至**动态交互场景**：不仅移除指定物体，还建模其移除对场景中其他物体的因果影响，生成物理合理的反事实视频。

2. 系统架构与方法论

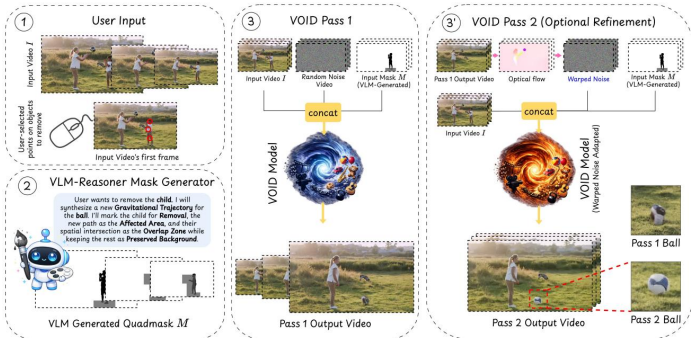

图 1：*VOID* 系统流程。用户点击指定待移除物体；*VLM* 扩展掩码识别受影响区域；第一遍预测反事实轨迹；可选第二遍通过光流扭曲噪声稳定物体形变。

给定输入视频 $\mathbf{V} = \{I_t\}_{t=1}^{T}$ 和标识目标物体的掩码序列 $\mathbf{M}_o = \{m_t\}_{t=1}^{T}$，目标是学习模型 f 生成反事实视频 $\hat{\mathbf{V}} = f(\mathbf{V}, \mathbf{M}_o)$，其中目标物体 O 及其所有诱导交互均被消除。模型需要：(i) 移除目标物体；(ii) 重新生成受复杂关系影响的区域；(iii) 保留未受影响的区域。

2.1 反事实数据集构建

现有视频修复数据集主要关注光度效应，缺乏物理交互的监督信号。VOID 利用两个来源生成配对数据：

刚体动力学（Kubric）。采样多个物体的初始位置和速度，模拟交互生成视频 $\mathbf{V}$；定义目标物体 O 后，移除 O 并保持其他物体初始条件不变重新模拟，得到物理一致的反事实视频 $\hat{\mathbf{V}}$。生成约 **1900** 对视频。渲染时随机化相机轨迹和焦距缩放，帮助解耦物体效应与相机运动。

铰接体交互（HUMOTO）。利用 4D 动捕数据集，O 对应执行各种活动的人体。分别渲染有/无人体的视频得到 $(\mathbf{V}, \hat{\mathbf{V}})$。随机化物体、背景和人体纹理，生成约 **4500** 对视频。

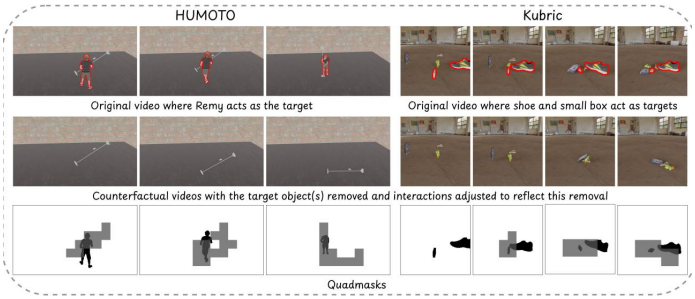

图 2：反事实监督示例。上：含目标物体的原始视频；下：移除目标物体后重新模拟的反事实视频。

2.2 交互感知 Quadmask 条件化

先前工作 Generative Omnimatte 使用 trimask（三色掩码：黑色 = 待移除物体，浅灰 = 可能受影响区域，白色 = 保持不变区域），但存在两个歧义：(1) 几乎整个图像标为浅灰，模型学到只需修改极小部分；(2) 待移除物体与动态效应区域重叠时无法区分。

VOID 提出 **quadmask**（四色掩码），引入第四种颜色（深灰）表示待移除物体与受影响区域的**重叠部分**。例如：移除一个接球的小孩时，其上半身区域既是待移除区域（小孩本身），也是效应区域（球的新轨迹将经过此处）。Quadmask 通过深灰色明确编码这种双重语义，消除歧义。训练时通过渲染引擎精确确定受影响区域并网格化。

2.3 骨干初始化与反事实生成

VOID 基于 **CogVideoX** 扩散 Transformer 骨干，从 Generative Omnimatte 的预训练权重初始化（提供层化物体-效应解耦的先验），然后在反事实视频对上用 quadmask 条件微调。这将模型从层化移除模型转变为**动态反事实重写模型**，重新激活底层视频模型的物理合理轨迹合成能力。

2.4 第一遍：反事实轨迹合成

$$\hat{\mathbf{V}}_{\mathrm{p1}} = \mathrm{VOID}(\mathbf{z}, \mathbf{V}, \mathbf{M}_q), \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

第一遍通常能捕获大致正确的运动假设（如失去支撑的物体自由下落、不再受阻挡的物体继续运动），但经历新合成运动的物体可能出现**结构形变**（弯曲、拉伸、漂移），类似于无运动引导的 CogVideoX image-to-video 伪影。

2.5 第二遍：光流扭曲噪声稳定化

受 Go-with-the-Flow 启发，利用第一遍输出 $\hat{\mathbf{V}}_{\mathrm{p1}}$ 的光流场生成时间相关的扭曲噪声 $\mathbf{z}_{\mathrm{warp}}$，引导扩散模型沿预测运动轨迹一致地去噪：

$$\hat{\mathbf{V}} = \mathrm{VOID}_{\mathrm{warp}}(\mathbf{z}_{\mathrm{warp}}, \mathbf{V}, \mathbf{M}_q)$$

$\mathrm{VOID}_{\mathrm{warp}}$ 使用相同数据和 quadmask 条件训练，但以训练目标 $\hat{\mathbf{V}}$ 的光流对齐噪声替代随机噪声。**第二遍并非总是需要**——同一 VLM 判断移除是否引发显著物体运动（如自由下落或轨迹变化），仅在检测到此类动态时触发。实验表明第二遍显著改善物体刚性保持。

2.6 推理时 VLM 引导的 Quadmask 生成

推理时从用户提供的二值掩码 $\mathbf{M}_o$ 出发，需要推断受影响区域以构建 quadmask $\mathbf{M}_q$。流程：

- 将 $\mathbf{V}$ 和 $\mathbf{M}_o$ 输入 VLM，生成受移除物体影响的物体描述列表；
- 使用 SAM3 获取覆盖所有受影响物体的掩码 $\mathbf{M}_a^{\mathrm{orig}}$；
- 在输入视频上叠加粗粒度空间网格，VLM 预测反事实场景中受影响物体的位置 $\mathbf{M}_a^{\mathrm{count}}$；
- 合并：$\mathbf{M}_a := \mathbf{M}_a^{\mathrm{orig}} \vee \mathbf{M}_a^{\mathrm{count}}$；
- 构建 quadmask：仅在 $\mathbf{M}_o$ 中为黑色；$\mathbf{M}_o$ 与 $\mathbf{M}_a$ 重叠为深灰；仅在 $\mathbf{M}_a$ 中为浅灰；其余为白色。

3. 实验结果

测试集包含 **75 个真实世界视频**（物体操控、支撑移除、碰撞、铰接交互、阴影/反射移除）和 **30 个合成视频**（Kubric + HUMOTO 测试集，加上先前工作的 10 个经典阴影/反射案例）。

3.1 真实世界评估

人类偏好研究。25 名参与者各评估 5 个场景（共 125 次比较），从 7 个模型的输出中选择最真实的结果。VOID 以 **64.8%** 的选择率大幅领先，Runway 18.4%，Gen-Omnimatte 11.2%，DiffuEraser 4.0%，ROSE 1.6%，ProPainter 和 MiniMax-Remover 均为 0%。

VLM-as-a-Judge。使用 Gemini 3 Pro、GPT-5.2、Qwen 3.5-32B 三个 VLM 评分，每个模型输出在 6 个维度（交互

物理、物体移除、背景伪影、时间一致性、场景保持、清晰度）上评分 0–5，满分 30。

模型	Gemini3	GPT5.2	Qwen3.5
ProPainter	19.05	14.55	22.21
DiffuEraser	22.53	17.00	23.04
MiniMax-Rem.	23.46	16.31	22.45
ROSE	24.22	18.59	22.96
Gen-Omni.	24.34	19.23	23.44
Runway	25.05	20.21	22.79
VOID (ours)	**26.13**	**23.16**	**24.49**

三个评判器一致将 VOID 排名第一。**交互物理**维度优势最为显著（Gemini3 评分：VOID 3.66 vs Runway 2.61），直接验证了因果推理能力。

3.2 合成数据集评估

模型	PSNR↑	DreamSim↓	FVD↓	VLM↑
ProPainter	30.48	0.10	471.13	21.38
DiffuEraser	30.11	0.10	496.61	21.30
MiniMax-Rem.	29.96	0.09	448.43	22.83
ROSE	29.21	0.11	480.18	21.62
Gen-Omni.	29.44	0.12	437.88	20.40
Runway	26.68	0.15	442.76	21.67
VOID	**31.49**	**0.07**	**260.31**	**25.10**

VOID 在 PSNR、DreamSim、FVD 和 VLM-Judge 上均取得最优。FVD 优势尤为突出（260.31 vs 次优 437.88），表明视频级时空一致性显著领先。LPIPS 上略逊（0.12 vs 最优 0.10），因该逐帧指标对局部平移敏感，可能惩罚效应位置正确但速度略有偏差的合理生成。

3.3 泛化至未见效应

VOID 展现出令人惊喜的泛化能力，成功处理训练中**从未见过**的交互类型：

- 移除持球人后**气球上浮**（训练数据无浮动物体）；
- 移除按搅拌机按钮的人后**搅拌机不启动**（训练数据无电器设备）；
- Jenga 塔在猫被移除后不再倾斜；保龄球被移除后球瓶保持直立；
- 移除障碍鸭子后球的滚动轨迹改变；移除 Big Ben 塔后水面反射消失。

这些泛化表明 VOID 并非简单记忆训练数据中的视觉线索，而是**综合利用 VLM 的因果推理能力和视频扩散基础模型的物理直觉**，以通用方式应用于远超合成训练数据分布的场景。

4. 消融实验

在 75 个真实世界测试用例上使用 Gemini 3 Pro 评判，对数据组成和掩码策略进行消融：

变体（数据量）	交互物理	总分
Kubric-Only (1200)	2.63	20.36
HUMOTO-Only (1200)	2.50	20.12
Both Datasets (1200)	3.04	21.93
Gen-Omni. Mask (Full)	3.30	23.39
VOID (Full)	**3.66**	**26.12**

关键发现：(1) **混合数据集**在数据量相同时优于单一来源（21.93 vs 20.36/20.12），多样性比数据量更重要；(2) **Quadmask 显著优于 trimask**——使用 Gen-Omnimatte 式 trimask（无 VLM 引导）使总分从 26.12 降至 23.39，所有维度均退化；(3) **第二遍细化**在 VLM 选中的 10 个需要显著动态重配的案例上，总分从 23.5 提升至 26.0，交互物理评分从 2.90 跃升至 3.90。

VLM 选择的影响。使用 Gemini 3 Pro 生成掩码时总分 26.12，GPT-5.2 为 24.34，Qwen3-32B 为 23.91，说明掩码质量对最终结果有重要影响。

5. 与相关工作的对比

- **vs 视频修复**（ProPainter、DiffuEraser）：仅做空间填补，无因果推理，物理交互场景完全失败（人类偏好 0–4%）；
- **vs 效应移除**（ROSE、Gen-Omnimatte、Object-Wiper）：擅长光度效应但无法处理动力学交互，trimask 缺乏精确的受影响区域引导；
- **vs 文本引导编辑**（Runway）：即使提供详细文本描述（包含预期物理后果），仍缺乏物理直觉，且文本难以穷举所有效应（18.4% 偏好率）；
- **VOID 的独特性**：首次将 VLM 因果推理（识别受影响区域和反事实位置）与视频扩散模型的生成能力结合，通过 quadmask 提供像素级精确引导，实现物理合理的反事实视频生成。

6. 局限性与未来方向

- **域差距**：当测试视频相机角度异常或过于接近物体时，仍可观察到性能下降；
- **视频长度与分辨率**：生成视频仅数秒，分辨率有待提升；
- **训练数据**：完全依赖渲染引擎（Kubric + HUMOTO）的合成数据，未来可探索更真实的训练数据源；
- **标准指标局限**：LPIPS 等逐帧相似度指标对局部平移敏感，可能惩罚物理正确但位置略偏的生成，反而奖励留有阴影伪影的结果（论文附录有具体案例）；
- **更强基座模型**：VOID 的泛化能力源于底层 VLM 和视频扩散模型的世界知识，随着更强生成模型的出现，框架性能有望进一步提升。