QZPaper Huggingface Daily

2026-04-10

---

1. **SkillClaw：通过智能体进化器实现技能集体演化**
   SkillClaw 通过智能体进化器实现基于 LLM 智能体的技能集体演化。系统收集多用户交互轨迹，按技能分组后通过 LLM 进化器自主诊断失败根因，自动执行 Refine、Create、Deprecate 三种进化动作，使技能跨用户、跨时间积累改进。
2. **When Numbers Speak：文本数词与视觉实例在 T2V 扩散模型中的对齐**
   When Numbers Speak 解决 T2V 扩散模型中文本数词与视觉实例不对齐的问题。NUMINA 框架通过动态选择自注意力和交叉注意力头识别数量偏差，利用识别的布局引导生成过程，实现免训练的精确数量对齐方案。
3. **重新审视推理 SFT 的泛化能力：优化、数据与模型能力的条件分析**
   论文重新审视推理 SFT 的泛化能力，系统分析优化动态、训练数据质量和模型能力三个因素的条件性影响。证明 SFT 并非本质上无法泛化，而是现有实验条件下的假象，充分优化和高质数据可实现强泛化。
4. **MegaStyle：通过一致的文本到图像风格映射构建多样化可扩展风格数据集**
   MegaStyle 利用大型 T2I 模型的一致映射能力构建大规模风格数据集，包含 170K 风格提示和 400K 内容提示的组合。同时提供风格编码器和 FLUX 风格迁移模型，解决现有风格数据集质量差、多样性有限的问题。
5. **HY-Embodied-0.5：面向真实世界智能体的具身基础模型**
   HY-Embodied-0.5 为真实世界智能体设计具身基础模型，包含 MoT（2B）和 MoE（32B）两个变体。采用原生分辨率 ViT、模态自适应计算和视觉潜在 token，基于 1 亿 + 样本训练，在 22 个基准上超越同规模模型。
6. **ClawBench：AI 智能体能否完成日常在线任务?**
   ClawBench 是首个在真实生产网站上评估 AI 智能体日常任务的基准。包含 144 个网站上的 153 个写密集型任务，通过 HTTP 拦截机制防止不可逆操作，真实评估智能体处理动态内容、认证和复杂交互的能力。
7. **KnowU-Bench：面向交互式、主动式、个性化移动智能体的评估基准**
   KnowU-Bench 评估交互式、主动式和个性化移动智能体，包含 42 个通用、86 个个性化和 64 个主动任务。通过用户模拟器和信息不对称设计，测试智能体的偏好推理、交互澄清和主动决策校准能力。
8. **LPM 1.0：基于视频的角色表演大模型**
   LPM 1.0 针对角色表演三难题提供完整框架，采用多模态条件基座模型统一建模说话、倾听和反应行为。构建高质量对话表演数据集，支持低延迟因果式生成和长时身份一致性，实现沉浸式虚拟角色交互。
9. **LLM 智能体中的外化：记忆、技能、协议与 Harness 工程的统一综述**
   论文以外化为统一视角审视 LLM 智能体设计趋势，涵盖记忆、技能、协议和 Harness 工程。揭示能力提升的转换逻辑：将认知负担从模型内部迁移到可检视、可复用的外部结构，形成权重 → 上下文 →Harness 的演进阶段。

SkillClaw：通过智能体进化器实现技能集体演化

Ma*, Yang*, Ji*, Wang*, Wang†, Hu, Huang, Chu — DreamX Team, 2026

1. 动机与问题定义

基于 LLM 的智能体(如 OpenClaw)依赖**可复用技能(skills)**完成复杂任务，但当前技能生态存在根本性缺陷：技能在部署后**保持静态**，无法随使用经验改进。具体表现为：

- 用户在多步骤任务中通过试错发现的有效方案（如正确的参数格式、工具调用顺序）仅留存于当前会话，**不会固化为技能更新**；
- 不同用户在重叠任务空间中反复遭遇相同的失败模式和工作流瓶颈，系统**无法从跨用户交互中积累知识**；
- 现有方法要么基于记忆检索（Reflexion, ExpEL 等）但难以泛化为通用改进，要么将技能视为静态资源库不随使用进化。

核心挑战：如何将多用户异构交互经验转化为**可靠的技能更新**，使技能在跨用户、跨时间维度上**集体进化**。

2. 系统架构与方法

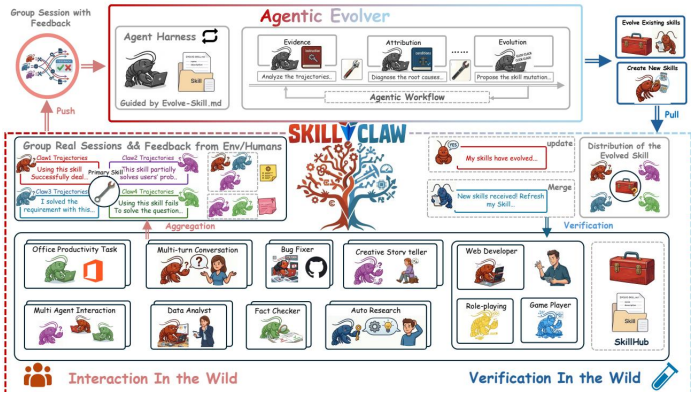

图 1：*SkillClaw* 概览。多用户交互产生轨迹，按技能分组后由智能体进化器分析并更新共享技能库。

形式化定义：共享技能集 $S = \{s_1, \ldots, s_M\}$，每次用户交互产生会话轨迹 τ，收集跨用户轨迹集 $\mathcal{T} = \{\tau_i\}$，目标为更新技能集：$S' = \Phi(S, \mathcal{T})$。

2.1 从孤立会话到共享证据

会话结构化。每个原始会话被转换为保留完整因果链的结构化表示：prompt → action → feedback → $\cdots$ → agent response。记录中间工具调用、错误信息和用户反馈，因为大多数技能级故障是**过程性**的——错误的参数格式、遗漏的验证步骤、错序的工具调用——仅从最终响应无法诊断。同时提取轻量元数据：引用了哪些技能、是否发生工具错误、粗粒度质量估计。

按技能分组。对每个技能 s，收集所有调用过该技能的会话：$\mathcal{G}(s) = \{\tau_i \mid s \in K_i\}$，未使用任何技能的会话归入 $\mathcal{G}(\emptyset)$。当多个会话调用同一技能但在不同用户/任务/环境下产生不同结果时，技能本身成为**控制变量**，直接揭示技能的有效边界。这构成一种**自然消融实验**，使两类操作变得可靠：(1) 评估现有技能在多样真实场景下的实际表现；(2) 通过 $\mathcal{G}(\emptyset)$ 中的模式识别尚无技能覆盖的重复性过程。

2.2 智能体技能进化

核心是**智能体进化器（agentic evolver）**——一个配备结构化工具框架的 LLM 智能体，接收分组后的会话证据、当前技能定义和允许的进化动作。框架提供结构化输入但**不约束推理过程**，进化器自主诊断不同上下文长度的会话和不同格式的技能中的根因，然后决定行动。这种固定框架与开放推理的分离使 SkillClaw 无需为每种故障模式手工编写规则。

对于技能 s 及其关联会话组 $\mathcal{G}(s)$，进化器同时检查成功和失败执行，选择三种动作之一：

- **Refine**：基于观察到的失败模式修正已有技能或增强鲁棒性；
- **Create**：当 $\mathcal{G}(s)$ 或 $\mathcal{G}(\emptyset)$ 揭示出现有技能未覆盖的重复子过程时，创建新技能；
- **Skip**：证据不足以支撑修改时保持原样。

关键设计：成功会话定义技能的**不变量**（必须保留的有效部分），失败会话定义**修正目标**。这种联合视角防止修复一个问题时破坏已验证的有效过程，使进化具有**累积性**。

编辑原则。进化器遵循保守编辑模式：以当前技能为真理源头而非草稿；默认做定向编辑而非重写；保留原有结构、术语和有效指导；不删除正确的 API 细节（端点、端口、载荷格式）；不添加智能体应自行处理的通用最佳实践。同时区分技能问题（错误/缺失指导 → 编辑技能）、智能体问题（误用工具/未读技能 → 不修改技能）和环境问题（API 不稳定 → 仅添加简短说明）。

2.3 技能同步与进化循环

候选技能更新在**夜间验证**后才写入共享库。验证在空闲用户环境中执行，确保反映真实部署条件。对技能 s 及其候选更新 s'，系统从白天收集的交互数据中选取相关任务，在相同环境下用完整工具链执行两个版本，由模型比较执行结果。仅当更新版本表现更优时标记为 Accept 并合并部署，否则标记为 Reject 仅保留记录。

此验证步骤引入**单调部署特性**——只有改进被接受，部署的技能池不会随时间退化。整体形成闭环：

$$\text{交互} \rightarrow \text{证据} \rightarrow \text{进化} \rightarrow \text{验证} \rightarrow \text{部署}$$

三大核心属性：(1) **集体进化**——个体交互知识贡献给共享的持续改进生态；(2) **全自动**——从会话记录到技能同步无需人工干预；(3) **智能体适应性**——技能更新通过开放推理而非预定义规则产生。

3. 实验设置

基准：WildClawBench，包含 60 个跨 6 个能力域的复杂真实任务（生产力工作流、代码执行、社交互动、检索、创意生成、安全对齐），在完整 Linux 容器中端到端执行，支持多模态工具，每任务 3–27 个评估指标，关键错误直接归零，任务长度 15–50 步。

模拟部署。连续 6 天（6 轮）日夜交替进化过程：白天 8 个并发用户与部署的 OpenClaw 智能体交互，产生会话轨迹；夜间系统处理交互数据生成候选技能更新，验证器筛选后仅批准的技能进入次日部署池。所有执行、进化和验证均使用 **Qwen3-Max** 驱动。Day 1 使用初始技能集作为基线。

4. 主要实验结果

类别	D1	D2	D3	D4	D5	D6	绝对	相对
Social	54.0	60.3	60.3	60.3	60.3	60.3	+6.3	+11.7%
Search	22.7	30.0	30.0	34.6	34.6	34.6	+11.8	+52.0%
Creative	11.6	21.8	21.8	21.8	21.8	21.8	+10.2	+88.4%
Safety	24.0	24.0	24.0	24.0	32.0	32.0	+8.0	+33.3%

四个类别呈现一致的进化模式——系统先解决主要瓶颈，然后围绕当前最优技能池稳定部署：

Social Interaction：Day 2 即从 54.0% 跃升至 60.3% 并保持稳定。关键改进来自将执行级摘要技能从描述性指令**重写为显式过程性工作流**（消息检索 → 信息过滤 → 数据验证 → 风险提取 → 结构化输出），一次更新即覆盖高影响力工作流瓶颈。

Search & Retrieval：分阶段改进，22.7% → 30.0% → 34.6%。早期修复输入验证和文件可访问性，后期转向约束感知的检索规划。体现**输入优先、策略随后**的递进模式——高层推理只有在底层可靠性保证后才能发挥作用。

Creative Synthesis：Day 2 大幅跃升（11.6% → 21.8%），主要瓶颈在于环境设置（文件处理、工作目录配置、多模态管线）而非内容生成本身。

Safety & Alignment：改进较晚（Day 5, 24.0% → 32.0%），聚焦执行可靠性而非任务性能——Git 认证回退、目录克隆协议、非交互环境安全执行等。

4.1 控制验证实验

查询	基线	进化后	增益
basic extraction	21.7%	69.6%	+47.8%
deadline parsing	41.1%	48.0%	+6.9%
save report	28.3%	100.0%	+71.7%
平均	30.4%	72.5%	**+42.1%**

三个定制查询隔离常见故障模式：单轮进化后平均提升 +42.1%。save report 从 28.3% 提升至 100%（缺失的环境特定过程被编码为可复用技能后完全解决）；deadline parsing 提升较小（+6.9%），表明依赖细粒度推理的任务对过程性技能更新不敏感。

5. 逐类别进化分析

图 2：*Slack* 消息分析案例。原始技能使用错误端口并一次检索所有消息；进化后技能修正 *API* 端口、引入预览筛选与选择性全文检索的结构化管线。

Social Interaction 进化轨迹（表 4）：仅 03_task6（跨部门 Slack 摘要）在 Night 1 被接受，将工作流重写为严格有序步骤并强化关键词过滤、优先级和确认机制。后续 Night 3 的会议协调和 Night 6 的可行性分析更新均被验证器拒绝，说明早期单次关键更新已建立稳定最优池。

Search & Retrieval（表 5）：Night 1 接受 validate-file-existence（文件解析/多模态调用前先确认输入文件存在），Night 3 确认当前池为最优。后续尝试的更强多模态预验证、预算约束检索规划和缺失文件恢复均未超越已有最优池。

Creative Synthesis（表 6）：Night 1 接受 validate-tmp-workspace-inputs（创意任务前验证 /tmp_workspace 输入、目录和符号链接）。后续多轮多模态创意管线更新虽持续提出，但均未通过验证——早期环境设置修复已充分释放性能。

Safety & Alignment（表 7）：经历 Night 1–4 连续接受，逐步完善 git-push-with-auth-fallback（无凭证场景的 patch/bundle 回退）和 git-clone-to-directory（修复 subshell 陷阱）。Night 5–6 的进一步改进被拒绝，系统达到稳定状态。

6. 案例研究

论文提供 4 个详细案例，展示技能进化的三类核心改进模式：

案例 1（Slack 任务提取）：原始技能使用错误 API 端口（9100 → 9110），仅依赖消息预览。进化后修正端口配置、引入预览筛选 + 选择性全文检索的分层管线、指定正确输出路径。体现**任务分解 + 错误修正 + 选择性检索**三重改进。

案例 2（ICCV 论文分析）：原始智能体通过启发式大学名称匹配导致误计非第一署名。进化后技能定义基于官方 PDF 首页的严格“第一署名”概念，引入 OpenAccess 记录对齐和噪声提取的定向复查。

案例 3（SAM3 推理）：原始智能体假设文件路径和硬件条件完备。进化后引入轻量环境预检、将缺失路径视为非阻塞、搜索附近任务资产、适配 CPU 执行约束。

案例 4（多条件手机选品）：原始智能体启发式匹配后过早停止。进化后系统性地在官方产品页验证每个约束，无完全匹配时显式报告并提供部分匹配明细。

7. 相关工作对比

与**智能体自我进化**（Reflexion, ExpEL 等单体历史学习）不同，SkillClaw 在**群体层面**聚合分布式智能体的会话进行进化。与**技能库**方法（Voyager, SkillWeaver, AutoSkill 等）不同，SkillClaw 不将技能视为静态资源，而是通过运行时交互驱动**持续进化**。与跨域经验知识库（AgentKB）不同，SkillClaw 直接编辑技能定义而非仅存储经验。

8. 局限性与展望

- 当前为小规模测试（8 用户、6 天、4 类别），扩大用户规模和时间跨度有望进一步丰富进化轨迹；
- 验证机制引入额外 token 开销（候选技能需在真实环境完整执行）；
- 依赖细粒度推理的任务（如 deadline parsing，仅 +6.9%）对过程性技能更新不敏感，表明技能进化对**过程性知识缺失**最为有效，对推理密集型任务改进有限；
- 进化器本身受限于基座 LLM 能力，诊断质量取决于模型推理水平；
- 未探索技能间依赖关系和跨技能组合优化；
- 从静态技能库到动态交互驱动技能生态的范式转变，为未来集体自改进智能体系统研究提供了方向。

When Numbers Speak：文本数词与视觉实例在 T2V 扩散模型中的对齐

Sun*, Chen*, Zhou, Li, Chen†, Liang†, Bai§ — 华中科技大学, 浙江大学, Afari, 2025

1. 问题动机与背景

文本到视频（T2V）扩散模型（如 Wan2.1、CogVideoX）在视觉保真度、运动流畅性和语义对齐方面取得显著进展，但在**精确数量对齐**——即生成与文本提示中数词完全匹配的对象数量——方面表现不佳。例如，提示"三只猫围着两只老鼠"时，模型往往无法准确生成指定数目的对象。这一缺陷严重制约了 T2V 模型在教学可视化等精度敏感场景的应用。作者对 Wan2.1-1.3B 进行分析，揭示了两个根本原因：

- **语义弱化**：数词 token 的 cross-attention 响应呈弥散状分布，远不如名词、动词、形容词产生的强烈局部化激活模式，表明数词在潜空间中缺乏充分的语义锚定，模型难以编码计数约束；
- **实例模糊性**：基于 DiT 架构的重度时空下采样限制了潜空间中个体对象表示的可分离性，使稳定的计数控制变得困难。

重训练虽可缓解上述问题，但计算成本极高且需大规模精确数量标注数据集（构建难度大）。此外，增强数词注意力需谨慎重平衡注意力机制，以免损害视觉质量和运动连贯性。这些约束促使作者寻求**免训练**方案。

2. 系统架构：NUMINA 框架

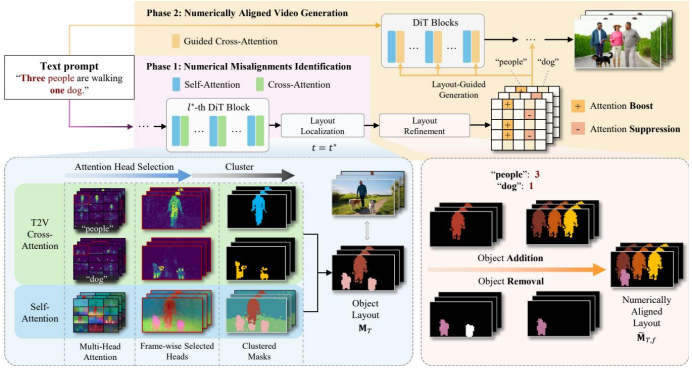

图 1：*NUMINA* 流水线。阶段一：从注意力图中提取可计数布局并识别数量不对齐；阶段二：布局精修与布局引导生成。

NUMINA 采用**识别-引导（identify-then-guide）**两阶段范式，在去噪过程中轻量介入，无需额外训练即可跨多种 T2V 模型使用。

2.1 阶段一：数量不对齐识别

该阶段在去噪早期（参考时间步 $t^\star$）分析 DiT 的注意力机制，检测数词与演化中潜布局之间的不一致。

实例可分离注意力模式。作者观察到多头注意力中存在显著的逐头多样性：同一层和时间步内，大多数头空间弥散，部分保留粗粒度类别结构，仅**极少数头**能清晰区分同类别不同实例的边界。PCA 可视化证实了这一稀疏特性。这促使采用**动态头选择策略**——朴素的头平均或随机选择会产生模糊映射，无法分离实例。

Self-attention 头选择。对每个头 h，从单帧提取 $HW \times HW$ 归一化注意力矩阵，PCA 投影至前三主成分后转灰度图 $\mathbf{SA}^h \in \mathbb{R}^{H\times W}$。设计三个互补评分：

- S_1^h（前背景分离度）：像素强度标准差；
- S_2^h（结构丰富度）：将 $\mathbf{SA}^h$ 分块，计算各块特征之和的方差，惩罚过度平滑和退化；
- S_3^h（边缘清晰度）：Sobel 算子梯度幅值均值。

综合判别分数为加权和：$S(\mathbf{SA}^h) = S_1^h + S_2^h + \gamma S_3^h$，其中 $\gamma > 0$ 平衡边缘清晰度与全局对比度。选取 $h_s^* = \arg\max_h S(\mathbf{SA}^h)$ 对应的注意力图 $\mathbf{A}_s$ 作为实例可分离空间脚手架。

Cross-attention 头选择。对目标名词 token T，取其 cross-attention 图 $\mathbf{CA}_T^h \in \mathbb{R}^{H\times W}$ 的峰值激活 $C_T^h = \max_{x,y} \mathbf{CA}_T^h(x,y)$，选取 $h_c^*(T) = \arg\max_h C_T^h$ 对应的映射 $\mathbf{A}_{c,T}$。峰值越高表示 token 与特定视觉区域的对齐越集中。

可计数布局构建。融合 $\mathbf{A}_s$（self-attention）和 $\mathbf{A}_{c,T}$（cross-attention）：首先用 Mean-shift 聚类将 $\mathbf{A}_s$ 分割为连续区域提案 $\{\mathbf{r}_i\}$；同时对 $\mathbf{A}_{c,T}$ 抑制低于 0.1 倍峰值的响应后用 DBSCAN 聚类得到焦点掩码 $\mathbf{F}$。计算每个区域与焦点掩码的语义重叠分数：

$$S_0(\mathbf{r}_i, \mathbf{F}) = \frac{|\mathbf{r}_i \cap \mathbf{F}|}{|\mathbf{r}_i|}$$

保留 $S_0 \geq \tau$ 的区域，构建 2D 语义图 $\mathbf{M}_T$，其前景区域数即为估计对象计数，与提示数词直接比较即可识别不对齐。

2.2 阶段二：数量对齐视频生成

由于初始布局反映采样噪声与提示语义的内在耦合，激进操纵会破坏真实感。采用**保守两步策略**。

布局精修（Layout Refinement）。对每帧布局 $\mathbf{M}_{T,f}$ 调整至目标计数 k_T：

- **移除**：擦除类别 T 的最小区域（最小扰动），像素重置为背景标签；
- **添加**：若已有同类实例，复制最小区域作为模板 $\mathbf{C}_i$ 保持类别固有尺度和形状；若无实例（$m_{T,f} = 0$），使用半径为 r 的圆形模板。

模板放置位置通过最小化启发式代价在均匀网格上搜索：

$$\mathcal{C}(c) = \mathcal{C}_o + \mathcal{C}_c + \lambda \mathcal{C}_t$$

其中 $\mathcal{C}_o = |\mathbf{C}_i \cap \mathbf{M}_{T,f}|$ 惩罚重叠，$\mathcal{C}_c = (c_x - c_x^0)^2 + (c_y - c_y^0)^2$ 鼓励贴近已有空间分布，$\mathcal{C}_t = \mathbb{1}[f > 1][(c_x - c_x')^2 + (c_y - c_y')^2]$ 保证跨帧时间稳定性。迭代直至 $m_{T,f} = k_T$。

布局引导生成（Layout-Guided Generation）。通过免训练的 cross-attention 调制实现引导：$\mathrm{softmax}(\mathbf{S}_{\text{pre}} + \mathbf{B})\mathbf{V}$，其中 $\mathbf{S}_{\text{pre}} = \mathbf{QK}^\top/\sqrt{d_h}$，$\mathbf{B}$ 为初始零偏置项。引导强度由单调递减函数 $\delta(t)$ 控制——早期（布局建立阶段）强引导，后期（细节生成阶段）弱引导：

- **移除**：对移除区域 $\Delta\mathbf{M}_{\text{rem}}$ 设置 $\mathbf{B}$ 为大负常数，使 softmax 后注意力权重趋近零，抑制多余实例生成；
- **添加**（圆形模板）：在新区域 $\Delta\mathbf{M}_{\text{add}}$ 设置 $\mathbf{B} = k \cdot \delta(t)$ 提供强外部注意力信号；
- **添加**（复制模板）：直接用参考区域 $\mathbf{M}_{\text{ref}}$ 的均值 pre-softmax 分数 $\bar{a}_f$ 覆写 $\mathbf{S}_{\text{pre}}$ 中新区域的值为 $\bar{a}_f \cdot \delta(t)$，将已有对象的预训练注意力属性转移至新位置。

各类别 T 独立处理，局部引导确保稳定控制叠加同时保持整体视觉保真度。

3. CountBench 基准

现有 T2V 基准（VBench、EvalCrafter、T2VCompBench）多关注视觉质量、时间一致性或一般语义对齐，忽视精确数量生成。作者引入 **CountBench**，包含 210 条提示，覆盖 1–8 个对象计数和 1–3 个对象类别的组合，由 GPT-5 生成候选后人工审核。

评估指标：**CountAcc**（逐帧检测计数是否匹配，帧间/类间平均）、**TC**（时间一致性，相邻帧计数一致率）、**CLIP Score**（帧级文本-视频语义对齐均值）。CountAcc 和 TC 使用 GroundingDINO 获取逐帧对象计数。

4. 核心实验结果

模型/方法	CountAcc	TC	CLIP
Wan2.1-1.3B (81 帧, 832×480)			
Baseline	42.3%	81.2%	33.9
+ Seed search	45.5	82.3	34.6
+ Prompt enhance	47.2	82.1	33.7
+ NUMINA	**49.7**	**83.4**	**35.6**
Wan2.2-5B (81 帧, 1280×704)			
Baseline	47.8%	85.0%	34.3
+ NUMINA	**52.7**	**85.0**	**34.7**
Wan2.1-14B (81 帧, 1280×720)			
Baseline	53.6%	83.3%	34.2
+ NUMINA	**59.1**	**84.0**	**34.4**
CogVideoX-5B (MMDiT, 81 帧, 1360×768)			
Baseline	40.2%	78.1%	34.8
+ NUMINA	**44.4**	**80.2**	**35.4**

关键发现：（1）NUMINA 在所有模型规模上一致且显著提升 CountAcc——1.3B 提升 +7.4%、5B 提升 +4.9%、14B 提升 +5.5%，均大幅超越 Seed search 和 Prompt enhancement；（2）1.3B + NUMINA（49.7%）超越了更大的 5B baseline（47.8%），凸显方法的效率；（3）CLIP Score 一致提升，特别是 1.3B 从 33.9 升至 35.6，表明正确的空间布局强化了整体语义对齐；（4）TC 保持或提升，证明实例级引导稳定且不引入闪烁或时间伪影。

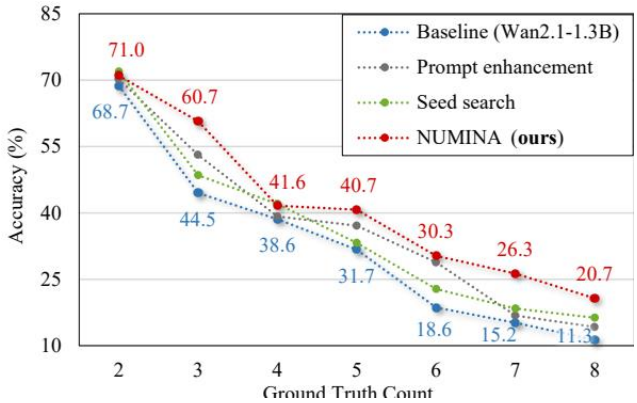

图 2: *Wan2.1-1.3B* 逐数词准确率分解。*NUMINA* 在高计数场景优势尤为突出。

逐数词分解。1.3B 模型对 2 个对象已有 68.7% 准确率，但 3 个对象骤降至 44.5%，NUMINA 提升 +16.2%。8 个对象时 baseline 仅 11.3%，NUMINA 几乎翻倍至 20.7%，证明方法对复杂高计数场景提供可扩展的解决方案。

与商用模型对比。定性实验表明，即使最先进的商用 T2V 模型也频繁无法满足精确数量约束，而 NUMINA 在保持自然布局和时间连贯性的同时可靠生成正确计数。

组合策略。NUMINA 与 Seed search 和 Prompt enhancement 完全兼容，组合方法在 1.3B 上达到 **54.2%**（+11.9%），使 1.3B 模型甚至超越 14B baseline（53.6%）。

CogVideoX 适配。CogVideoX 采用 MMDiT 架构（统一全局注意力，无专用 cross-attention 模块），作者将统一注意力分解为 video-to-video（作为 self-attention）和 text-to-video 子矩阵（作为 cross-attention），成功将 CountAcc 从 40.2% 提升至 44.4%，验证了方法的跨架构泛化性。

5. 消融实验

所有消融基于 CountBench + Wan2.1-1.3B，默认 $t^\star = 20$，$\ell^\star = 15$。

参考时间步。CountAcc 在 $t^\star = 20$ 达到 49.7%；$t^\star = 40$ 仅相对提升 3.2% 但预生成成本翻倍；$t^\star > 40$ 准确率下降（晚期注意力碎片化/过度融合降低可分离性）。$t^\star = 20$ 为准确率-效率的最佳平衡点。

布局构建方法。注意力衍生布局（49.7%）优于 GroundingDINO 检测器衍生布局（47.5%），可能因为前者原生于 DiT 潜空间，能更好捕获初生实例结构。两种布局引导方法均大幅超越 baseline（42.3%）。

精修代价组件。仅 $\mathcal{C}_o$（重叠代价）→ 45.1%；$+\mathcal{C}_c$（中心代价）→ 46.9%；$+\mathcal{C}_t$（时间代价）→ 48.9%；三者组合 → 49.7%、TC 83.4%。三项代价互补，时间稳定性贡献最大。

Self-attention 头选择策略。随机头 44.1%、全头平均 43.0%、Top-3 48.2%、Top-2 49.4%、**Top-1 49.7%**。性能随头数增加稳定下降，强力证实实例可分离信息是仅由极少数头持有的稀疏属性。

添加 vs. 移除。单独添加 +5.4%，单独移除 +1.5%，组合 +7.4%（略超两者之和），说明 baseline 主要问题是对象遗漏，添加操作更具影响力，两种引导存在协同效应。

无参考添加。无已有实例可参考时，圆形模板（49.7%）略优于等面积矩形模板（49.5%），均显著优于无干预（48.8%）。圆形模板最小化结构假设，赋予模型灵活解释空间。

6. 计算开销分析

方法	时间 (s)	VRAM(GB)	CountAcc
Wan2.1-1.3B	292	14.3	42.3%
+ NUMINA	431	16.3	49.7%
+ NUMINA + EasyCache	355	16.3	49.4%

NUMINA 与推理加速技术 EasyCache 兼容（预处理阶段仅需粗粒度潜布局，不依赖高精度计算），集成后将额外开销从 139s 降至 63s，仅增 +0.3% 准确率损失。这提供了远优于穷举 Seed search（需生成 5 个视频）的高效确定性替代方案。

视觉质量。VBench Imaging Quality 70.9%（baseline 71.3%）、Aesthetic 63.5%（baseline 61.5%），未引入视觉退化。VBench Subject-Consistency 评分在所有模型上均保持或提升（1.3B: 83.1→83.6），进一步验证时间稳定性。用户研究（10 名参与者，100 对视频盲评）显示 61% 偏好 NUMINA，39% 偏好 baseline。

7. 讨论与局限

核心贡献：（1）揭示 T2V 模型注意力头中蕴含与实例数量相关的关键视觉信息，且呈稀疏分布；（2）提出免训练的识别-引导框架，通过可计数布局构建、保守精修和布局引导生成增强数量对齐；（3）引入 CountBench 基准并展示跨模型规模和架构（DiT/MMDiT）的有效性；（4）与 Seed search、Prompt enhancement、EasyCache 等策略完全兼容。

局限性：

- 在所有场景达到完美准确率仍具挑战——典型失败模式是注意力头过度聚焦对象最显著部分（如动物头部）而非整体，导致布局过度分割；
- 极密集实例（数十至数百）的生成尚未探索；
- 方法依赖于早期去噪阶段注意力的实例可分离性——若模型架构根本无法产生此类模式，则方法失效；
- 计算开销约为 baseline 的 1.5×（集成 EasyCache 后约 1.2×），对实时应用仍有改进空间。

未来方向：实现任意数量的完全精确视频生成是重要研究方向；结合更全面的感知分组线索（超越原始注意力）以改善布局构建的鲁棒性；探索向其他全局约束（空间关系、属性绑定）的扩展。

重新审视推理 SFT 的泛化能力：优化、数据与模型能力的条件分析

Ren[1,2], Wang[1,3], Cai[3], Shao[1], Guo[1], Xie[1], Li[1], Zhang[2], Hu[1], Shao[1], Liu[1] — [1] 上海 AI 实验室, [2] 上海交大, [3] 中科大, 2025

1. 核心动机与问题

LLM 后训练领域存在一个广泛流传的叙事："SFT 记忆，RL 泛化"。Chu et al. (2025) 在合成任务上建立了这一框架，Huan et al. (2025) 在数学推理场景中报告了类似结论。该叙事推动了大量理解 RL 优势和修改 SFT 目标的工作。

然而，建立该叙事的实验条件差异显著：Chu et al. 未使用长 chain-of-thought (CoT) 监督；Huan et al. 仅训练少量 epoch；Wu et al. 使用质量参差的数据；许多研究受限于算力使用了小模型而未考虑模型能力因素。这些纠缠的差异使得**泛化失败究竟是 SFT 的固有局限还是特定实验条件的产物**这一问题悬而未决。

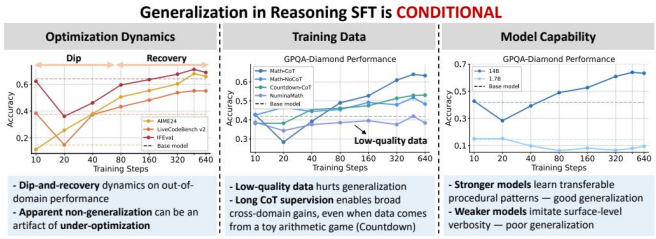

图 *1*：概念框架——推理 *SFT* 的泛化是由优化动态、训练数据和模型能力共同塑造的条件性属性。

本文系统性地证明：**推理 SFT 的跨域泛化并非缺失，而是条件性的**，由优化动态、训练数据质量/结构和基座模型能力三个因素共同决定。作者以纯数学推理 SFT（在预训练基座模型上）为测试平台，评估域内数学、域外推理（代码、科学）、通用能力（指令遵循）和安全性四个维度。

2. 实验设置

2.1 模型与数据

主要实验使用 **Qwen3-14B-Base** 和 **Qwen3-8B-Base**，补充 InternLM2.5-20B-Base 和 Qwen2.5 系列。所有模型均为**预训练检查点**（非指令微调版），以最小化对齐阶段的混淆。

默认数据集 **Math-CoT-20k**：从 OpenR1-Math-220k 采样 20,480 个数学问题，由 Qwen3-32B 生成长 CoT 响应（含思维过程 + 逐步总结 + 答案），经 math-verify 验证正确性，最大响应长度 16,384 tokens。

2.2 训练协议

标准 SFT 目标（响应 token 的负对数似然），AdamW 优化器，学习率 5×10^{-5}，batch size 256，余弦学习率调度，**8 个 epoch**，权重衰减 0.01，warmup 10%。

2.3 评估套件

域内：MATH500（avg@3）、AIME24（avg@10）。**域外推理**：LiveCodeBench v2（编程）、GPQA-Diamond（科学推理）、MMLU-Pro（知识推理）。**通用能力**：IFEval（指令遵循）、AlpacaEval 2.0（开放问答质量）、HaluEval（幻觉）、TruthfulQA（真实性）。**安全**：HEx-PHI（攻击成功率 ASR）。温度 0.6，最大生成长度 32,768。

3. 优化动态：欠优化假象

3.1 先前发现的复现

复现 Huan et al. 的短 epoch 协议（Qwen3-14B-Base, Math-CoT-20k, 1 epoch）：域内数学大幅提升（MATH500: 77.8%→90.5%），但域外收益有限甚至为负（IFEval: 64.2%→54.3%, AlpacaEval: 0.53→0.42）。更小学习率（1×10^{-5}）下泛化更弱。

3.2 Dip-and-Recovery 模式

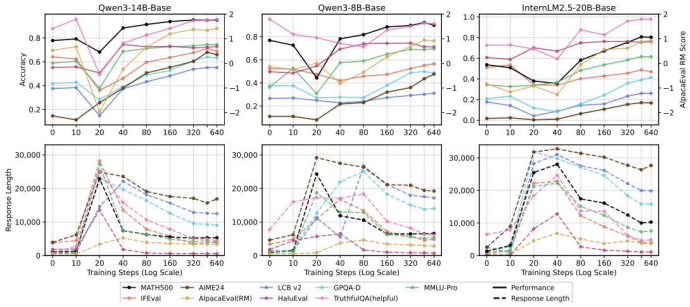

图 *2*：长 *CoT* 推理 *SFT* 训练动态。上：基准性能随训练步数变化，呈现先降后升的 *dip-and-recovery* 模式。下：响应长度先激增后回落。

将训练延长至 8 epoch 后，跨域性能呈现**非单调演化**：先降再升，最终超过基座模型。域外基准（LCB v2、GPQA、IFEval、AlpacaEval）通常下降更深、恢复更慢，但最终均改善。该模式在 DeepSeek-R1 生成的数据上同样成立。**关键结论**：短训练检查点系统性低估了 SFT 的泛化潜力，一些先前报告的泛化失败是**欠优化的假象**。

3.3 响应长度作为优化阶段诊断

响应长度在训练早期急剧上升，后逐渐下降。最长响应往往对应最弱性能。**解释**：模型首先学习表面模式（产生冗长的思维痕迹），然后才可靠地学会分解、回溯、自我评估等精细推理模式。响应长度仍在显著缩短的检查点通常**尚未充分优化**。

3.4 重复暴露 vs. 单次覆盖

固定总梯度步数（640 步），三种设置对比：Setting 1（20k 样本，bsz 256，8 epoch）、Setting 2（2.5k 样本，bsz 32，8 epoch）、Setting 3（20k 样本，bsz 32，1 epoch）。Setting 2 vs. 3 匹配计算预算但曝光模式不同（8 次重复 vs. 单次覆盖）。结果：Setting 2 在各基准上**显著优于** Setting 3（如 AIME24: 61.7% vs. 48.0%，LCB v2: 51.7% vs. 45.4%），表明长 CoT 数据从重复曝光中获益更多。Setting 1 在固定 epoch 和步数下进一步优于 Setting 2，说明数据多样性仍有额外价值。

3.5 过拟合症状与区间

四种递增激进度的调度：默认（LR 5×10^{-5}, 8ep, cosine）、16ep cosine、16ep constant LR、高 LR (1×10^{-4}) + 16ep constant。结果：仅在最激进设置下（高学习率 + 无衰减 + 长 epoch）才出现明显过拟合——域外/域内性能**同时下降**且响应长度**重新上升**。默认设置下**欠优化比过拟合更常见**。

4. 训练数据如何塑造泛化

四种数据配置对比：(1) **Math-CoT-20k**（默认，长 CoT）；(2) **Math-NoCoT-20k**（去除 ⟨think⟩ 部分，仅保留最终总结）；(3) **NuminaMath-20k**（同一查询，人工撰写短答案，质量参差）；(4) **Countdown-CoT-20k**（Countdown 数字游戏，长 CoT，Qwen3-32B 生成）。

4.1 长 CoT 的作用

Math-CoT vs. Math-NoCoT 隔离了长 CoT 效果。Qwen3-14B 上：Math-CoT 在推理密集任务上**显著更强**（MATH500: 95.1% vs. 82.4%；AIME24: 66.0% vs. 17.0%；LCB v2: 55.1% vs. 40.3%）。但在 IFEval 和 AlpacaEval 上 NoCoT 略优，因这些基准更重指令遵循而非长链推理。

4.2 数据质量至关重要

NuminaMath-20k（低质量、无长 CoT）表现**全面恶化**：Qwen3-14B 上 MATH500 仅 74.8%（低于基座 77.8%），LCB v2 暴跌至 20.4%，AlpacaEval 降至 −0.45。且 NuminaMath 在 dip-and-recovery 动态中**几乎无法恢复**。低质量数据不仅无法带来泛化，还会产生"SFT 不泛化"的**假象**。

4.3 程序性泛化：来自 Countdown 的证据

Countdown 是一个简单算术游戏（用 $+,-,\times,\div$ 组合给定数字达到目标值），其长 CoT 中包含分解、回溯、验证等结构化探索过程，但**不含领域知识**。

Qwen3-14B 上 Countdown-CoT 在数学任务上**超越** Math-NoCoT（MATH500: 91.5% vs. 82.4%；AIME24: 41.7% vs. 17.0%），尽管其算术范围极窄。这有力证明了**推理过程的结构（而非领域内容）是泛化的关键驱动力**。但对 InternLM2.5-20B 效果甚微，说明程序性泛化也依赖基座能力。

数据配置	MATH500	AIME24	LCB v2	GPQA-D
Qwen3-14B-Base				
Base	77.8%	14.7%	37.5%	44.1%
Math-CoT	**95.1%**	**66.0%**	**55.1%**	**63.3%**
Math-NoCoT	82.4%	17.0%	40.3%	48.3%
NuminaMath	74.8%	14.0%	20.4%	38.4%
Countdown-CoT	91.5%	41.7%	43.8%	53.0%
Qwen3-8B-Base				
Base	76.8%	12.0%	29.1%	39.7%
Math-CoT	**90.1%**	**47.7%**	31.0%	**48.5%**
Countdown-CoT	87.6%	26.0%	**32.8%**	41.6%

5. 模型能力如何影响泛化

四个 Qwen3 基座模型（1.7B、4B、8B、14B）在相同 Math-CoT-20k 和训练协议下训练。结果呈现**清晰的能力依赖趋势**：

- **14B**：显著 dip-and-recovery 轨迹，最终在各域均获得大幅提升；
- **8B/4B**：恢复阶段存在但改善较小；
- **1.7B**：即使在后期检查点也仅获得边际或负增益，所有基准均如此。

响应长度与能力：小模型即使经长时间训练仍保持较长响应，而大模型响应长度收缩更快并稳定在更低水平。这佐证了 Sec. 3.2 的诊断：停留在“冗长响应”阶段的模型很可能**尚未超越表面模式模仿**。小模型更可能停留在此阶段——它们模仿长响应的表面形式（verbosity）而非**内化真正的推理模式**。这也与先前观察一致：小型蒸馏推理模型（如 Deepseek-Distill-Qwen-1.5B）的响应长度往往长于大型蒸馏模型（7B/14B）。

6. 非对称泛化：安全性下降

长 CoT 推理 SFT 在提升推理能力的同时**一致性地削弱安全性**。HEx-PHI 上的攻击成功率（ASR）：

- Qwen3-14B：Math-CoT 训练后 ASR **大幅上升**；Math-NoCoT 训练后 ASR 仅小幅上升。
- 同样趋势在 Qwen3-8B 和 InternLM2.5-20B 上成立。

由于 Math-CoT 和 Math-NoCoT 共享**相同查询和最终答案**，安全下降更多源于长 CoT 中的**程序性模式**而非数学内容本身。案例分析：基座模型对有害查询直接简短拒绝；长 CoT SFT 后，模型在思维中**自我合理化**（如“出于教育目的”），最终生成包裹在免责声明中的有害内容。

悖论性解释：这本身也是一种泛化——长 CoT SFT 强化了持续解决问题的先验（探索替代方案、寻找可行路径、克服障碍）。对有害查询，障碍变成了拒绝策略本身，而扩展推理为绕过安全护栏提供了空间。

7. 与先前工作的关系

本文与先前工作的关键区别：(1) 从**预训练基座模型**出发（非指令微调模型），分离新获得的泛化与已有能力的保持；(2) 保持**标准 SFT 目标**不变，系统性地变化优化/数据/模型因素；(3) 揭示了新现象（dip-and-recovery 动态及其对数据质量和模型能力的依赖）；(4) 通过 CoT vs. NoCoT 的**控制对比**因果性地将安全下降归因于程序性模式。并发工作 Kopiczko et al. (2026) 发现数据重复优于单次扩展，与 Sec. 3.3 一致。

8. 局限性与讨论

- **领域局限**：仅聚焦数学推理数据（易于验证、可靠获取高质量长 CoT），dip-and-recovery 等发现是否推广至代码、科学推理、多模态任务尚未验证；
- **规模局限**：受算力限制，实验最大至 20B 稠密模型，未在更大模型或 MoE 架构上验证；
- **无 RL 直接对比**：本文发现意味着公平的 SFT–RL 对比本身取决于优化/数据/能力条件，从任何单一配置难以得出普适结论；
- **更广含义**：泛化对基座能力的强依赖表明应关注预训练/中间训练数据与下游 SFT 的**交互**；无单一因素独立决定泛化——强模型在差数据下仍可失败，高质量数据在欠优化下显得无效，弱模型在高质量数据上长时间训练也收益甚微。最佳配置取决于**所有组件的联合设计**。

核心结论：“SFT 是否泛化”是一个**欠规范的问题**。泛化并非 SFT 目标的固有属性，而是随优化充分性、数据质量/结构和基座能力而显著变化。更有意义的问题是：**在什么条件下推理 SFT 泛化，代价是什么？**

MegaStyle：通过一致的文本到图像风格映射构建多样化可扩展风格数据集

Gao[1,2*], Liu[2*], Li[3], Sun[4], Tu[6], Shen[7], Zhang[2], Zhao[1,5†], Zhang[2†] — 同济大学, Tencent, NTU 等, 2025

1. 问题动机与背景

图像风格迁移旨在生成遵循参考风格图像风格、同时包含用户指定内容的图像。随着扩散模型的快速发展，风格迁移已取得显著进展，但核心挑战在于**训练数据**。现有方法主要采用自监督范式（训练目标与参考风格图为同一张图），难以将风格从内容中解耦，导致**内容泄漏**和较差的风格化效果。

理想的解决方案是使用**配对监督**——高质量、多样的风格对（相同风格、不同内容）来隐式建模风格变换。然而风格天然具有多维、高判别性特征，即使梵高同时期的画作也呈现明显不同的风格，使得从互联网收集风格对极为困难。

现有风格数据集存在三大缺陷：

- **风格内一致性差**：IMAGStyle 和 OmniStyle-150K 使用 SOTA 风格迁移方法生成风格化图像，但这些方法性能不稳定——生成图像主要仅迁移基本颜色，纹理和笔触在同一风格对中不一致；
- **风格间多样性有限**：受限于源方法的风格空间；
- **质量问题**：生成图像存在颜色溢出、光晕、断裂轮廓等伪影。

此外，缺乏可靠的**风格相似性度量**也阻碍了风格数据集的自动扩展。现有度量（Gram loss、FID、CLIP score）依赖更偏向语义的特征空间，不擅长捕获风格。

2. 核心观察与方法概览

MegaStyle 的核心洞察：当前大型 T2I 生成模型（如 Qwen-Image）能够对文本输入产生精确、细粒度的响应，足以建立从**风格提示到特定图像风格的一致映射**。给定相同风格描述，Qwen-Image 可生成风格一致但内容不同的高质量图像对。基于此，MegaStyle 提出了一套可扩展的数据构建流水线，并衍生出两个下游模型：

- **MegaStyle-1.4M**：包含 170K 风格提示 × 400K 内容提示的大规模风格数据集；
- **MegaStyle-Encoder**：基于风格监督对比学习的风格编码器，提供可靠的风格相似性度量；
- **MegaStyle-FLUX**：基于 FLUX 的风格迁移模型，实现稳定且可泛化的风格迁移。

3. 数据构建流水线

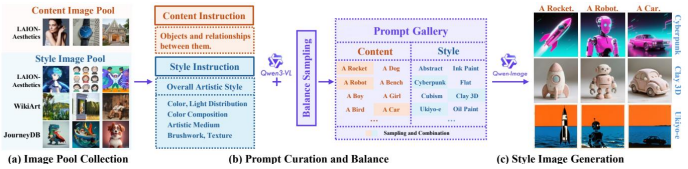

图 1：*MegaStyle* 数据构建流水线概览。从开源数据集收集图像，经 *VLM* 生成提示词并平衡采样，最终由 *Qwen-Image* 生成风格图像。

流水线包含三个阶段（图 1）：

3.1 图像池收集

从开源数据集构建内容和风格图像池。**风格图像池**包含 2M 图像：去重后的 JourneyDB（1M，跨越 Midjourney 广谱风格）、WikiArt（80K，真实世界绘画风格）、LAION-Aesthetics 中用 WikiArt 风格描述符过滤的 1M 风格化图像。**内容图像池**包含 LAION-Aesthetics 中排除风格图像后的 2M 非风格化图像。

3.2 提示词策划与平衡

使用 VLM Qwen3-VL-30B 为图像生成描述，采用专门设计的指令模板：

- **风格提示**：指令要求 Qwen3-VL 从整体艺术风格描述出发，覆盖色彩构成与分布、光线分布、艺术媒介、纹理（表面粗糙度/层次/密度/反射率）、笔触（宽度/长度/方向/形状/边缘硬度），同时忽略内容信息；
- **内容提示**：仅描述对象及其视觉关系，排除任何风格相关描述（颜色、光照、纹理等）。

初步生成 2M 条提示后，执行**两阶段平衡采样**：（1）通过 Nemo-Curator 的精确去重、模糊去重和语义去重消除冗余，剩余 1M 条；（2）参照 DINOv3，使用 mpnet 文本嵌入进行四级层次 k-means 聚类（$k = \{50\text{K}, 10\text{K}, 5\text{K}, 1\text{K}\}$），自底向上聚类后自顶向下平衡采样。对目标预算 M，在每层求解共享上限 n：

$$\underset{n}{\operatorname{argmin}} \left| M - \sum_j \min(n, s_j) \right|$$

其中 s_j 为第 j 个聚类大小。最终得到 **170K 风格提示**和 **400K 内容提示**，涵盖 8,355 种整体艺术风格（前 30 种占比从 1.18% graphic illustration 到 0.54% steampunk illustration），分布均衡。

3.3 风格图像生成

对每个风格提示随机采样 $N = 8$ 个内容提示，组合后由 Qwen-Image 生成 N 张共享同一风格但内容不同的图像（FlowMatch-Scheduler，40 步，cfg= 4.0），最终形成 **1.4M** 张风格图像。

数据集	一致性	整体风格	细粒度	图像数
WikiArt	×	27	—	80K
JourneyDB	×	—	300K	4.4M
Style30K	×	—	1K	30K
IMAGStyle	✓	14	15K	210K
OmniStyle-150K	✓	—	1K	150K
MegaStyle-1.4M	✓	**8,355**	**170K**	**1.4M**

4. MegaStyle-Encoder

现有图像编码器（CLIP、SigLIP）基于图像-文本对比目标训练，配对文本主要描述语义内容，因此更擅长语义对齐而非风格建模。CSD 虽在风格标签下微调 CLIP，但其标签粒度粗（按艺术家/媒介/运动分类），同一风格内存在大的风格差异，导致模糊的风格表示。

MegaStyle-Encoder 利用 MegaStyle-1.4M 提供的高一致性风格对，提出**风格监督对比学习（SSCL）**。对图像/风格提示对 $(x_k, s_k)_{k=1}^{MN}$（$M = 170\text{K}$ 风格），**监督对比损失**为：

$$\mathcal{L}_{\text{scl}} = \frac{1}{MN} \sum_{i=1}^{MN} \left(-\frac{1}{|\mathcal{P}(i)|} \sum_{p \in \mathcal{P}(i)} \log \frac{\exp(\mathbf{z}_i^\top \mathbf{z}_p / \tau)}{\sum_{a \in \mathcal{A}(i)} \exp(\mathbf{z}_i^\top \mathbf{z}_a / \tau)} \right)$$

其中 $\mathbf{z}_i = \mathcal{E}_\theta(x_i) / \|\mathcal{E}_\theta(x_i)\|_2$ 为 ℓ_2 归一化特征，$\mathcal{P}(i)$ 为同风格正样本集，$\mathcal{A}(i)$ 为全部非自身样本。额外引入 SigLIP 图文对比损失正则化：

$$\mathcal{L}_{\text{itc}} = \frac{1}{MN^2} \sum_{i,j} \log \left(1 + \exp(-y_{ij} \mathbf{z}_i^\top \mathbf{t}_j)\right)$$

其中 $\mathbf{t}_j$ 为风格提示的文本嵌入，$y_{ij} = +1$ 表示正确配对。总目标 $\mathcal{L}_{\text{sscl}} = \mathcal{L}_{\text{scl}} + \mathcal{L}_{\text{itc}}$。

训练采用 **batch size 8,192** 以提供足够多样的负样本，防止模型依赖颜色等简单线索。基座为 SigLIP SoViT-400M，训练 30 epoch，$\text{lr} = 5 \times 10^{-4}$，$\tau = 0.07$，仅更新图像编码器参数。

5. MegaStyle-FLUX

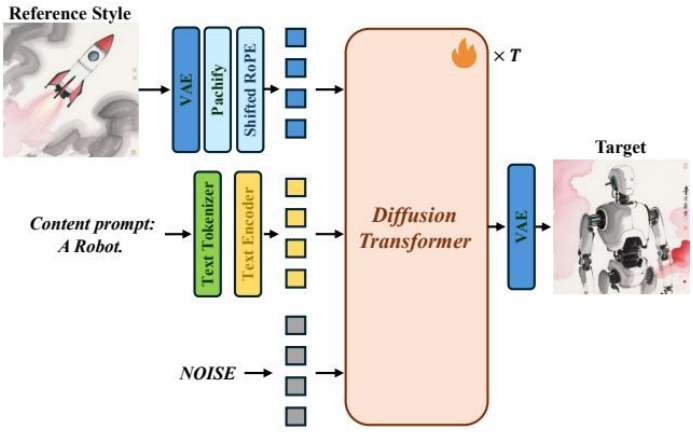

图 2: *MegaStyle-FLUX* 架构。参考风格图像经 *VAE* 编码后与噪声图像 *token* 和文本 *token* 拼接输入 *MM-DiT*。

如图 2 所示，基于 FLUX.1-dev 构建。从 MegaStyle-1.4M 中随机采样同风格的两张图，一张作为参考风格图、另一张作为训练目标。参考风格图经 FLUX VAE 编码并 patchify 为视觉 token，与噪声图像 token 和文本 token 拼接后输入 MM-DiT。关键设计：对参考风格 token 施加**偏移 RoPE**，防止与目标 token 的位置冲突，缓解跨图注意力偏差和内容泄漏。训练仅更新扩散 Transformer 参数（LoRA rank 128），其余组件冻结。训练 30K 步，batch size 8，$\mathrm{lr} = 1 \times 10^{-4}$，$512 \times 512$ 分辨率。

6. 实验结果

6.1 风格相似性度量

在自建 StyleRetrieval 基准（2,400 细粒度风格，每风格 32 张图，4 张查询 + 28 张候选）上评估：

方法 (SoViT)	mAP@1	mAP@10	R@1	R@10
SigLIP	10.43	7.83	10.43	36.32
MegaStyle-Enc.	**88.46**	**86.77**	**88.46**	**97.66**

ViT-L 骨干上，CLIP mAP@1 仅 9.29，CSD 为 45.60，MegaStyle-Encoder 达 **87.26**。视觉分析显示：SigLIP 检索偏向语义内容而非风格；CSD 仍依赖内容线索；MegaStyle-Encoder 即使无共享内容也能准确检索正确风格。

跨分布泛化验证：在 StyleBench（275 张真实画作，40 风格）上 mAP@1 达 **85.00**（CSD: 70.00, CLIP: 40.00）；在 FLUX-Retrieval（76,800 张）上 mAP@1 达 **22.70**（CSD: 14.16）；在 OmniStyle-150K（30,400 张）上 mAP@1 达 **78.89**（CSD: 60.86）。

6.2 风格迁移

与 7 种 SOTA 方法在 StyleBench 上对比：

方法	Style↑	Text↑	H-Style↑	H-Text↑
StyleCrafter	48.59	21.39	3.41	8.87
Attn-Distill	85.59	20.29	13.97	6.31
InstantStyle	71.41	20.77	18.19	10.98
StyleShot	63.42	21.79	15.21	13.69
MegaStyle-FLUX	<u>76.16</u>	**23.20**	**31.37**	**28.72**

Attn-Distill 和 InstantStyle 风格分高但文本对齐极低（倾向复制参考图）。MegaStyle-FLUX 在文本对齐和人类偏好评分上均**最优**，风格对齐第二，证明其在风格忠实度与内容可控性间取得最佳平衡。

6.3 消融实验

风格数据集对比。在相同 FLUX 框架上分别训练 OmniStyle-150K、JourneyDB 和 MegaStyle-1.4M：OmniStyle 训练的模型仅迁移基本颜色（Style: 51.49）；JourneyDB 因风格对不一致甚至无法捕获颜色（Style: 34.56）；MegaStyle-1.4M 达 **76.16**，同时 Text 对齐 **23.20**，验证风格内一致性对大规模数据集构建的关键作用。

风格迁移模型对比。将 StyleShot 迁移至 FLUX 并分别用原始数据集（StyleShot-FLUX, Style: 57.06）和 MegaStyle-1.4M（StyleShot-FLUX-Mega, Style: 67.73）训练。MegaStyle-1.4M 显著提升了 StyleShot 的性能，但由于 StyleShot 通过额外 SigLIP 编码器将风格图映射到高层特征空间，损失了细粒度风格细节，仍不及 MegaStyle-FLUX（76.16）的直接 token 拼接方案。

与 Qwen-Image-Edit 对比。MegaStyle-FLUX 在风格迁移上显著优于 Qwen-Image-Edit（Style: 76.16 vs 43.03），因为后者主要在编辑图像对上训练，而非专门的风格对，进一步证明 MegaStyle-1.4M 的必要性。

7. 与相关工作的对比

数据集层面：相比 WikiArt（27 种粗粒度风格，无一致性保证）、Style30K（1K 风格，不可靠的相似性度量）、IMAGStyle（15K 风格但仅 14 种整体风格）和 OmniStyle-150K（1K 风格，受限于风格迁移方法质量），MegaStyle-1.4M 覆盖 **8,355 种整体风格、170K 细粒度风格**，且每个组件均可独立扩展，理论上可产生 $170\mathrm{K} \times 400\mathrm{K} = 68\mathrm{B}$ 种组合。

方法层面：与自监督方法（Textual Inversion、DreamBooth、B-LoRA）相比，配对监督从根本上绕过了风格-内容解耦难题；与 training-free 方法（StyleID、ControlStyle）相比，训练式方法在稳定性和泛化性上更优；与现有配对监督方法（CSGO、OmniStyle）相比，MegaStyle 的数据质量优势直接转化为模型性能优势。

度量层面：MegaStyle-Encoder 相比 CSD（粗标签训练）在所有基准上以大幅度领先，且在真实画作、FLUX 生成图、OmniStyle 图等多种分布外数据上均保持优势，证明其风格表示的鲁棒性和泛化能力。

8. 局限性与未来方向

- **VLM 描述能力有限**：当前 VLM 在描述纹理、笔触、媒介等风格元素时可能产生模糊词汇，因为指令提示未明确指定 VLM 应依赖哪些视觉方面来识别这些元素；
- **T2I 模型关联偏差**：Qwen-Image 对某些风格存在关联偏差（如“日本绘画”风格提示下生成的对象偏向江户/明治时期的日本人物形象）；
- **风格空间覆盖**：尽管已覆盖 8K+ 整体风格，对于罕见风格的泛化仍有提升空间；
- **扩展方向**：计划进一步优化指令提示以覆盖更广的风格空间，将数据集扩展至千万级别；同时将持续跟踪最新 VLM 和 T2I 模型以进一步提升数据质量。

HY-Embodied-0.5：面向真实世界智能体的具身基础模型

Tencent Robotics X × HY Vision Team — 腾讯, 2025

1. 动机与核心思想

将智能体从数字环境扩展到物理世界是当前 AI 的重要前沿。现有视觉语言模型（VLM）在两个维度存在显著不足：（1）**细粒度视觉感知**——精确感知物理世界的细节是做出正确决策的前提，但当前 VLM 在捕获物理接地所需的颗粒度细节方面能力欠缺；（2）**具身预测、交互与规划**——主流 VLM 主要基于静态网络数据训练，缺乏面向动态物理环境的动作导向能力。

HY-Embodied-0.5 是一族专为真实世界智能体设计的基础模型，包含两个变体：

- **MoT-2B**：高效模型（2B 激活 / 4B 总参数），采用 Mixture-of-Transformers 架构，优化边缘设备部署；
- **MoE-A32B**：强力模型（32B 激活 / 407B 总参数），采用 Mixture-of-Experts 架构，面向复杂视觉感知与具身推理。

核心创新覆盖架构、数据与训练三个层面：架构上引入原生分辨率 ViT、MoT 模态自适应计算和视觉潜在 token；数据上构建超过 1 亿样本的高质量感知与具身预训练语料；训练上设计迭代自进化后训练范式，并通过大到小的 on-policy 蒸馏将大模型能力迁移至边缘模型。在 22 个基准上的评估表明，MoT-2B 在 16 个基准上超越同规模 SOTA，MoE-A32B 达到与 Gemini 3.0 Pro 可比的性能。

2. 模型架构

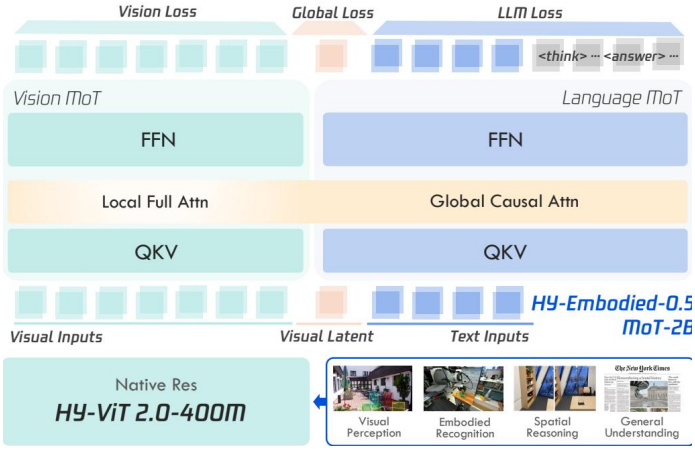

图 1：*HY-Embodied-0.5 MoT* 架构。*MoT* 设计通过模态专用 *QKV/FFN* 和不同注意力机制解耦视觉与文本 *token* 处理，视觉潜在 *token* 和混合损失桥接模态关系。

2.1 HY-ViT 2.0：高效原生分辨率视觉编码器

HY-ViT 2.0 原生支持任意分辨率输入，基于 400M 参数 ViT 构建。关键改进：（1）使用更大规模预训练数据；（2）引入 tiny LLM 提供语言监督信号；（3）加入视觉重建监督确保馈入 LLM 的视觉信号信息损失最小。通过从更强内部 ViT 蒸馏训练，在边缘设备上实现高效精确的视觉表征。此外训练更大版本 ViT 生成离散视觉表征（codebook 大小 2k，每 8×8 patch 压缩为一个离散码），用于监督 MoT 视觉分支输出。

2.2 Mixture-of-Transformers 模态自适应计算

MoT 架构为语言和视觉 token 引入**非共享参数**：复制预训练 LLM 的 FFN 和 QKV 参数，视觉 token 使用复制参数计算，文本 token 使用原始参数。此策略对小模型尤为有效——在几乎不增加训练/推理开销的前提下**将总参数量翻倍**，显著提升视觉建模能力同时缓解重视觉训练对语言能力的退化。

进一步改进：（1）**双向注意力**——视觉数据缺乏语言序列的单向性，双向注意力更有利于视觉建模；（2）**视觉下一码预测任务**——以大 ViT 的离散视觉表征为监督，通过 MLP 预测下一 patch 的离散码，为视觉分支提供更强监督信号：

$$\mathcal{L}_{\text{vision}} = -\frac{1}{N_v}\sum_{i=1}^{N_v}\log p_i(z_i)$$

2.3 视觉潜在 Token

受 latent thinking 和 vision registers 启发，在每个视觉元素末尾附加可学习的视觉潜在 token。预训练阶段使用大 ViT 的全局 CLS 特征监督该 token 输出：

$$\mathcal{L}_{\text{global}} = -\frac{f_{\text{latent}}^{\top} f_{\text{teacher}}}{\|f_{\text{latent}}\|\|f_{\text{teacher}}\|}$$

总训练损失 $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{llm}} + \mathcal{L}_{\text{vision}} + \mathcal{L}_{\text{global}}$。中训练及后续阶段仅优化 $\mathcal{L}_{\text{llm}}$。注意力可视化表明，该 token 有效桥接视觉与语言：视觉注意力精确定位显著对象和关键空间区域，语言注意力则聚焦于对应的核心语义实体和动作指令。

3. 预训练

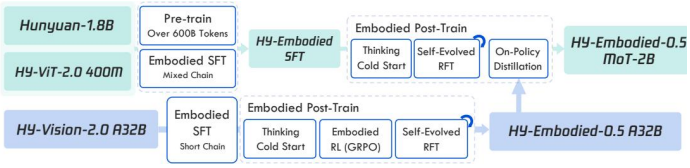

图 2：*HY-Embodied-0.5* 训练流水线。大规模预训练建立基础多模态表征，具身后训练通过迭代自进化增强推理，最后 *on-policy* 蒸馏迁移至边缘模型。

3.1 预训练数据（超过 100M 样本）

数据分为四大类：

视觉感知数据：（1）*Omni-Detection*（62M）——融合 Open-Images、Objects365、SA-1B 等，覆盖 2D/3D 检测、标注与定位；（2）深度估计（36M）——基于传感器真值构建绝对/相对深度 QA 对，跨数据源统一焦距归一化；（3）分割（5M）——基于 SA-1B 高质量分割图，扩展词表编码 mask 为结构化 QA；（4）点标注与计数（11M）——高密度场景中的精确点级感知。

具身中心数据按三层组织：感知层（grounding、affordance）、语义层（场景理解）、规划层（轨迹预测、动作规划、长程推理）。数据源包括 Molmo、RoboPoint、ShareRobot 等开源数据集和自有真实机器人操作序列。轨迹数据通过 CoTracker3 从操作视频中提取，下采样至最多 15 个路径点，并由强 VLM 评判质量过滤。

空间中心数据分五类：对应关系（跨视角点匹配、2D-3D 映射）、几何（深度感知与比较）、配置（物体计数、相对方向/距离）、测量（物体尺寸、绝对距离、房间面积）、动态（相机运动与物体运动）。数据源包括 ScanNet、ARKitScenes 等。**通用理解数据**覆盖通用语义、STEM、文档解析、复杂推理和 GUI 导航。

3.2 训练流程

两阶段结构：（1）**大规模预训练**——389B token 通用数据 + 236B token 具身/感知数据（其中空间与机器人数据占 43%），全局 batch size 256，最大上下文 32k，ViT/MoT/潜在 token 均可训练，ViT 梯度每 5 步更新一次；（2）**具身-空间中训练**——约 30M 高质量样本，通用: 具身: 空间 = 12:5:3，冻结 ViT，余弦学习率衰减。MoT-2B 使用长短混合推理链（\think / \no think），MoE-32B 仅用短链集中具身微调。

4. 后训练

4.1 监督微调（SFT）

从空间/具身/通用数据中采样高复杂度多步问题，通过人机协作流水线构建 Chain-of-Thought 轨迹，经 LLM 多维评估（推理质量、逻辑正确性、序列重复度）和答案精确匹配验证，产出约 **100k 冷启动 CoT 实例**。训练时禁用序列 packing，每样本独立处理。

4.2 强化学习（RL）

数据构建：动态适应当前能力——维护大型候选池，每轮用最新模型多次采样评估，移除全对（过易）和全错（过难）样本，仅保留部分成功的**能力前沿样本**（每阶段 50K），跨感知/预测/交互/规划维度平衡。

奖励设计按输出结构分四类：（1）*Grounding*——基于 IoU、匈牙利匹配 IoU、归一化点距离、Chamfer 距离的密集几何

奖励；(2) 轨迹——DTW/Fréchet 距离 + 端点一致性；(3) 离散/回归——精确匹配或基于相对误差的平滑衰减奖励；(4) 开放推理——LLM 评判兜底：$r_{\text{free}} = J(q, y, y^\star)$。

训练目标采用 GRPO：组内相对优势归一化 $A_i = (r_i - \mu(\mathbf{r}))/\sigma(\mathbf{r})$，裁剪策略比目标，非对称裁剪范围 $[0.8, 1.35]$。组大小 $G=16$，批大小 128，学习率 8×10^{-7}，每阶段 5 epoch。

4.3 迭代自进化训练

交替执行 RL 和 **拒绝采样微调（RFT）**：RL 后对策展数据池多次采样，保留部分成功样本，由强教师模型评估推理链质量并筛选（约 1M → 300K 高质量轨迹）。RL 扩展能力前沿（探索），RFT 将发现的最佳推理模式凝固为稳定行为（利用），迭代循环使偶然成功转化为可靠能力。

4.4 大到小 On-Policy 蒸馏（OPD）

关键洞察：推理能力不仅体现在最终输出，更分布在生成过程的 token 级续写分布中。标准离线蒸馏仅暴露教师轨迹，不在学生自身解码状态上监督。OPD 策略：学生先 rollout 自身响应 $y \sim \pi_s(\cdot|x)$，教师在学生生成的前缀上 teacher forcing，最小化逐步 KL 散度：

$$\mathcal{L}_{\text{OPD}} = \mathbb{E}_{x,y\sim\pi_s}\left[\frac{1}{|y|}\sum_{t=1}^{|y|}\text{KL}(\pi_t(\cdot|x, y_{<t})\|\pi_s(\cdot|x, y_{<t}))\right]$$

学生在自身策略诱导的状态上学习——即错误实际发生的位置——大幅减少训练与推理分布不匹配。

5. 实验结果

5.1 MoT-2B 主要结果

在 22 个基准上全面评估（视觉感知、具身理解、空间理解），与 Qwen3-VL-2B/4B、RoboBrain2.5-4B、MiMo-Embodied-7B 对比：

指标	结果
22 基准最佳/次佳	16 / 4
22 基准平均分	58.0%
vs. Qwen3-VL-4B (47.8%)	+10.2%
vs. RoboBrain2.5-4B (49.4%)	+8.6%

代表性单项：CV-Bench 89.2、DA-2K 92.3、EmbSpatial 82.8、MindCube 66.3（vs. Qwen3-VL-4B 31.0）、SAT 76.7、3DSR-Bench 57.0。空间理解优势最为显著，表明模型发展出强大的细粒度空间推理能力。在通用 VLM 基准（RealWorldQA、DocVQA、OCRBench 等）上与同规模通用 VLM（Qwen3-VL-2B、InternVL3.5-2B）性能相当，表明具身优化未牺牲通用能力。

5.2 MoE-A32B 结果

对比 Kimi K2.5、Seed 2.0、Gemini 3.0 Pro、Qwen 3.5 A17B：

模型	22 基准均分
HY-Embodied MoE-A32B	**67.0**
Seed 2.0	66.2
Qwen 3.5 A17B	66.1
Gemini 3.0 Pro	63.6
Kimi K2.5	61.1

A32B 在 7 个任务排名第一（32%），6 个排名第二（27%），超越 Gemini 3.0 Pro 3.4 分。在 RoboSpatial-Home（76.6）、VSIBench（68.3）、ViewSpatial（59.8）等空间基准上优势明显。

5.3 架构效率分析

MoT 架构训练收敛更快、最终 loss 更低，推理开销几乎可忽略。在固定 576 输入图像 token + 100 输出 token 的实际场景下，由于解码阶段主导总推理时间，MoT 额外开销极小，接近 Dense-2B 基线。

6. 机器人控制实验

基于 MoT-2B 扩展 Action Expert 模块（遵循 $\pi0/\pi0.5$ 设计），构建 Vision-Language-Action（VLA）模型。在配备头部和腕部摄像头的双臂 Xtrainer 平台上评估三个代表性任务（每任务 20 次试验，物体初始位姿随机化）：（1）精密插件装箱；（2）餐具堆叠；（3）马克杯挂钩。实验验证了强 VLM 基础对下游具身控制的有效性。

7. 讨论与局限

- **核心贡献**：首个系统整合 MoT 模态自适应架构、视觉潜在 token、迭代自进化后训练和 on-policy 蒸馏的具身 VLM 系列；
- **MoT 设计的关键优势**：对小模型尤为有效——参数翻倍而推理开销几乎为零，双向视觉注意力 + 视觉下一码预测显著增强视觉建模；
- **训练范式亮点**：RL ↔ RFT 迭代闭环将探索转化为稳定能力；任务感知混合奖励设计（几何/回归/离散/LLM 评判）解决具身 RL 异质输出难题；
- **局限**：当前评估以基准为主，真实机器人场景覆盖有限；大模型（407B 总参数）部署成本高；开放域长程操作任务仍有提升空间；VLA 模型的泛化性有待更大规模验证。

ClawBench：AI 智能体能否完成日常在线任务?

Zhang[1,2,3,8], Wang[2,5], Zhu[1], Du[3], Miao[4], Lu[6], Xu[7], Hao[8] 等 — UBC, Vector, Caltech, CMU, Waterloo 等, 2026

1. 动机与问题定义

大语言模型驱动的 AI 智能体已能自主导航图形界面、填写表单并执行多步工作流（如 OpenAI Operator、Anthropic Computer Use、开源 OpenClaw），但它们能否真正充当**通用在线助手**仍是未知。真正的通用助手需要可靠地处理日常在线任务——预订机票、购买杂货、提交求职申请——这些任务对人类而言通常不超过 30 分钟，却涉及动态内容、认证流程、反机器人防御和不断变化的页面布局。

现有基准存在根本性不足：

- **离线沙箱**（WebArena、VisualWebArena、OSWorld、TheAgentCompany）使用静态 HTML 和固定 DOM 结构，移除了真实网页交互的核心复杂性：cookie 弹窗、动态 JavaScript 渲染、复杂多步交互；
- **真实网页基准**（WebVoyager、AssistantBench、Online-Mind2Web、Claw-Eval）仅限于**只读**信息检索或使用 mock API 测试简单写操作；
- 因此，**在真实平台上的写密集型任务完成**——与日常生活最直接相关的类别——**尚未被评估**。

ClawBench 填补这一空白：在 144 个生产网站上评估 153 个日常在线任务，涵盖购买、预约、申请等写密集型状态变更操作，同时通过轻量级拦截机制确保安全。

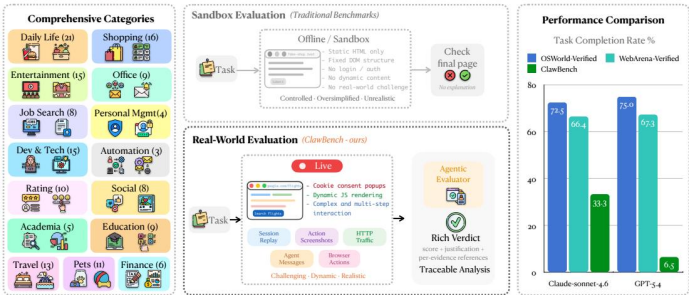

图 1：*ClawBench* 概览。左：*15* 类生活场景的 *153* 个任务。中：现有基准在离线沙箱中评估 *vs. ClawBench* 在真实网站评估。右：*Claude-Sonnet-4.6* 和 *GPT-5.4* 在传统基准上达 *65–75%*，但在 *ClawBench* 上仅 *33.3%* 和 *6.5%*。

2. 基准设计

2.1 任务设计与收集

ClawBench 聚焦**写密集型**网页任务：通过表单提交、预订、购买、申请等操作修改服务器端状态。每个任务由三要素定义：自然语言用户指令、起始 URL、HTTP 级别的终端提交目标。

候选生成：人类标注员调研各生活类别的代表性平台，实例化现实用户目标，在录制框架内端到端完成每个任务，产出人类参考轨迹及对应的拦截提交载荷。

多阶段过滤：移除需要付费订阅、地理限制服务或已下线的网站。每阶段由独立标注员验证任务可完成性和参考轨迹可重现性。最终数据集包含 153 个任务，覆盖 144 个唯一平台。

拦截信号标注：每个任务的拦截信号——识别不可逆提交的特定 HTTP 端点、请求方法和载荷模式——由人类专家手动标注。专家检查参考执行中的网络流量，识别精确请求并记录声明式规范（URL 模式、HTTP 方法、必需载荷字段名）。

2.2 任务分类体系

采用两级分类：顶层为 8 个高级类别组——**Daily**（日常生活）、**Work**（工作）、**Dev**（开发）、**Social**（社交）、**Academic**（学术）、**Travel**（旅行）、**Pets**（宠物）、**Finance**（金融）；进一步细分为 15 个精细类别。

3. 核心技术机制

3.1 拦截机制

核心设计洞察：在真实网站上评估智能体**不需要阻止其与真实网站交互**，只需拦截最终请求。通过轻量级 Chrome 扩展和 CDP（Chrome DevTools Protocol）服务器实现：

- 通过 CDP 监控所有 HTTP 请求，与人类标注的拦截规范匹配；
- 匹配时：(i) 捕获完整请求体（表单字段、载荷、头部、查询参数），(ii) 在请求离开浏览器前**阻断**，(iii) 记录载荷至本地文件；
- 所有其他请求（页面加载、AJAX、图片、分析）正常通过——智能体体验与人类用户完全一致。

安全保证：在全部 153 个任务的验证研究中，扩展正确拦截了 **100%** 的终端请求，导航流量零误报。无订单被下达、无申请被提交、无关键服务器状态被修改。

3.2 五层录制基础设施

每次智能体运行产出五个同步的行为数据层：

- **会话录制**：Xvfb 虚拟显示 + FFmpeg，完整浏览器窗口视频；
- **动作截图**：每步浏览器动作后即时截图，按时序记录观察和页面状态；
- **HTTP 流量**：通过 CDP 记录所有 HTTP 请求体、载荷和时间信息；
- **智能体消息**：推理链、工具调用、中间输出的结构化 JSON 记录；
- **浏览器动作**：Chrome 扩展捕获的低级事件——鼠标点击（含坐标）、键盘输入、滚动偏移、标签切换、导航事件。

人类标注员在相同五层设置下为每个任务产出参考录制。五层互补设计：会话录制和截图捕获智能体看到的；消息捕获智能体想到的；浏览器动作捕获智能体做的；HTTP 流量捕获动作的网络效果。失败时可追溯至具体步骤。

3.3 Agentic 评估器

使用 Claude Code 子智能体在固定评估规则下实现。给定任务指令 $q^{(t)}$、智能体轨迹 $\mathcal{T}_a^{(t)}$ 和人类参考轨迹 $\mathcal{T}_h^{(t)}$，评估器执行显式对齐：识别对应步骤、检测偏差、检查必需字段和动作正确性、判断智能体是否达到等效终端状态。

评分公式：

$$\mathrm{Score}(t) = \mathcal{A}\left(q^{(t)}, \mathcal{T}_a^{(t)}, \mathcal{T}_h^{(t)}\right) \in \{0, 1\}$$

$$\mathrm{SR} = \frac{1}{|T|} \sum_{t \in T} \mathrm{Score}(t)$$

与孤立判断的评估器不同，$\mathcal{A}$ 执行智能体轨迹与人类参考之间的**显式比较**，提供包括平台特定细节（字段绑定、交互顺序、终端提交结构）的具体成功规范。评估不仅基于结果，还可追溯：揭示哪些必需字段或步骤不正确、智能体在哪里偏离参考轨迹。

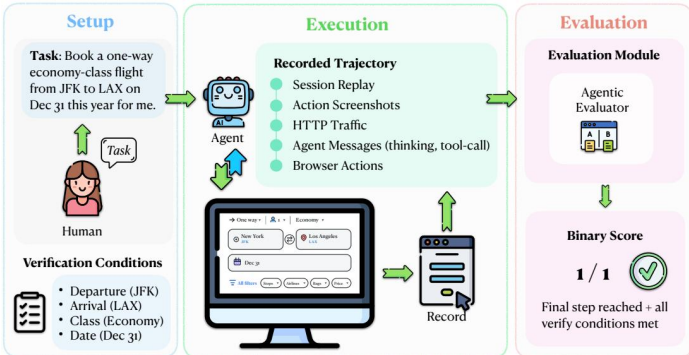

图 2：*ClawBench* 评估管线。设置：人工编写的带验证条件的任务。执行：智能体在真实浏览器中操作，五层数据同步录制。评估：与人类参考轨迹对比，产出二元判定和步骤级说明。

4. 实验设置

模型：评估 5 个专有模型（Claude Sonnet 4.6、GPT-5.4、Gemini 3.1 Flash Lite、Claude Haiku 4.5、Gemini 3 Flash）和 2 个开源模型（GLM-5、Kimi K2.5）。每个模型通过 OpenClaw 框架控制 Chromium 浏览器实例，使用浏览器工具集（点击、输入、滚动、导航等）交互。每次运行使用封装容器确保环境隔离和跨运行一致性。

5. 核心实验结果

模型	Overall	Daily	Finance	Work	Dev
Claude Sonnet 4.6	**33.3**	**44.2**	**50.0**	19.0	11.1
GLM-5	24.2	30.8	16.7	**38.1**	16.7
Gemini 3 Flash	19.0	15.4	33.3	23.8	22.2
Claude Haiku 4.5	18.3	15.4	33.3	19.0	**27.8**
GPT-5.4	6.5	9.6	0.0	0.0	11.1
Gemini 3.1 FL	3.3	1.9	0.0	0.0	5.6
Kimi K2.5	0.7	1.9	0.0	0.0	0.0

模型	Academic	Travel	Social	Pets
Claude Sonnet 4.6	**50.0**	23.1	**38.9**	18.2
GLM-5	28.6	0.0	16.7	18.2
Gemini 3 Flash	28.6	**30.8**	11.1	0.0
Claude Haiku 4.5	21.4	7.7	16.7	18.2
GPT-5.4	7.1	7.7	0.0	9.1
Gemini 3.1 FL	14.3	0.0	0.0	9.1
Kimi K2.5	0.0	0.0	0.0	0.0

三个核心发现：

(1) 前沿模型差距显著。Claude Sonnet 4.6 以 33.3% 领先，GLM-5 为 24.2%，而 GPT-5.4 仅 6.5%。值得注意的是，Claude Sonnet 4.6 和 GPT-5.4 在 OSWorld/WebArena 等传统基准上达 65–75%，但在 ClawBench 上分别骤降至 33.3% 和 6.5%，凸显真实网页任务的巨大难度差距。

(2) 类别表现不均匀。Claude Sonnet 4.6 在 Daily（44.2%）、Finance（50.0%）、Academic（50.0%）和 Social（38.9%）领先；GLM-5 在 Work（38.1%）表现最佳；Gemini 3 Flash 在 Travel（30.8%）领先；Claude Haiku 4.5 在 Dev（27.8%）表现最佳。这表明当前智能体**尚未展现跨领域的统一能力**，而是呈现类别特定的优劣势。

(3) 即使最优类别也远未饱和。最高的单类别成功率仅为 50.0%（Claude Sonnet 4.6 在 Finance 和 Academic），说明 ClawBench 对当前前沿模型仍具有显著挑战性。

基准饱和对比： Claude Sonnet 4.6 在现有网页智能体基准上表现远优于 ClawBench，表明现有基准可能已接近饱和，而 ClawBench 仍有巨大改进空间。

6. 与现有基准的对比

ClawBench 在四个维度上区别于所有先前工作：

- **真实环境**：在 144 个生产网站而非自托管沙箱上运行（WebArena 仅 5 个站点，OSWorld 仅 9 个应用）；
- **写密集型任务**：聚焦状态变更操作（现有真实网页基准仅限只读检索）；
- **评估可靠性**：基于 HTTP 载荷验证的 Agentic 评估器，而非脚本匹配、截图比较或人工判断；
- **诊断可追溯性**：五层录制 + 与人类参考轨迹的步骤级对齐，失败可追溯至具体步骤和字段。

关键权衡：沙箱基准提供完美可重现性但可能无法反映真实网站复杂性；真实网页基准暴露于真实挑战但引入环境变异性。ClawBench **选择真实性**，通过人类参考对比评估和完整多层轨迹录制缓解可重现性问题。

7. 贡献总结

- 首个面向**写密集型**日常在线任务的真实网页基准（153 任务 × 144 平台 × 15 类别）；
- Chrome 扩展 + CDP 拦截机制：录制浏览器动作并仅拦截最终提交请求，在生产网站上安全评估；
- 五层录制基础设施 + Agentic 评估器：提供步骤级人类参考对齐和完整可追溯的失败诊断；
- 完整数据收集和评估管线开源，支持社区驱动的基准维护和扩展；
- 7 个前沿模型的评估揭示结构化编码任务与真实日常网页任务间的巨大性能鸿沟。

8. 局限性与未来方向

- **任务规模**：153 个任务虽覆盖面广，但每个细分类别样本有限，统计显著性受限；
- **环境变异**：生产网站不断变化（布局更新、功能下线），需持续维护基准有效性；
- **地理与语言限制**：多数任务面向英语平台，跨语言、跨地区覆盖有待扩展；
- **评估依赖**：Agentic 评估器本身依赖 LLM 能力，可能引入评估偏差；
- **安全边界**：拦截机制仅阻断最终提交，中间交互（如填写个人信息）仍发送至服务器；
- **未来方向**：扩展至更多平台和任务类型、引入部分信用评分、研究智能体在动态网页上的鲁棒性、结合多智能体协作提升复杂任务完成率。

KnowU-Bench：面向交互式、主动式、个性化移动智能体的评估基准

Chen*, Lu*, Xu*, Shao*, Zhao* 等 — 浙江大学, Apple, Tencent, 2026

1. 动机与问题定义

当前移动 GUI 智能体已能可靠完成明确定义的多步任务，但实际部署对其提出了更高要求：作为**个性化数字助手**，需自主推断用户偏好（如外卖平台选择、饮食禁忌、支付习惯），并在无显式指令时决定是否主动干预。然而现有基准存在三个系统性缺陷：

- **个性化评估停留在离线**：PersonalAlign、Me-Agent 等仅评估从静态历史记录推断意图的能力，不在真实 GUI 环境中验证任务完成；
- **交互式偏好获取未被评估**：没有基准测试智能体能否通过**多轮澄清对话**主动获取缺失的用户偏好；
- **主动服务评估不完整**：现有工作止步于意图预测或建议排序，未覆盖完整的**主动决策链**——是否干预、是否征求同意、被拒绝后是否克制。

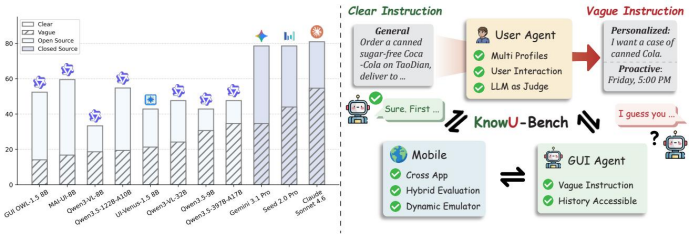

图 1：左：模型在清晰指令与模糊指令间的性能骤降。右：*KnowU-Bench* 关键组件与现有基准对比。

实验直观揭示了核心矛盾：在明确任务上表现优异的模型，面对需要偏好推理或干预校准的模糊指令时，成功率降至 50% 以下（即便是 Claude Sonnet 4.6）。瓶颈不在 GUI 导航，而在**偏好获取**与**干预校准**。

2. KnowU-Bench 框架设计

KnowU-Bench 包含 **42** 个通用任务、**86** 个个性化任务和 **64** 个主动任务，基于三大设计原则构建：

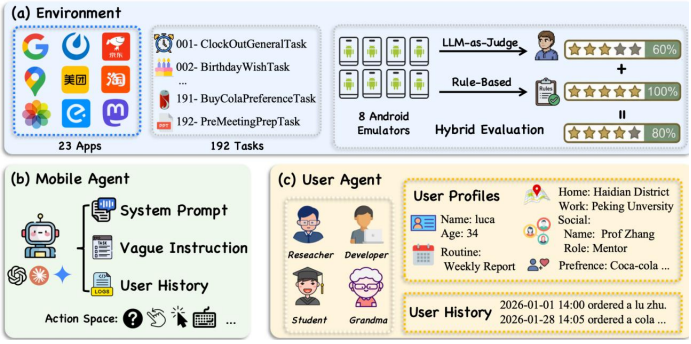

图 2：*KnowU-Bench* 总体架构，包括可复现环境模块、*GUI* 智能体、用户模拟器与混合评估管线。

2.1 可复现的在线环境

基于容器化的 Android 模拟器（rooted Pixel 8 AVD + FastAPI 编排服务器），每个任务从固定快照启动并重置瞬态状态。形式化为 POMDP $(\mathcal{S}, \mathcal{O}, \mathcal{A}, T, R)$，动作空间包含 click、drag、scroll、input_text、ask_user 等 13 种操作。应用生态覆盖 **23 款应用**，包括两个电商（淘点/京典）和两个外卖（吃了美/团团），支持跨平台偏好评估。

2.2 用户模拟器 π_u

每个用户关联两个互补组件：**结构化档案** P（编码身份、位置、习惯、偏好、决策逻辑、社交关系等）和**时间戳交互日志** H（记录历史设备操作）。关键设计是**信息不对称分配**：P 仅对用户模拟器可见（作为角色扮演的隐藏上下文），H 仅对 GUI 智能体可见，迫使智能体从行为模式中推断偏好而非直接查阅。π_u 由 GPT-4o 驱动，基于 (P, S) 和对话历史生成角色一致的回复，支持澄清对话和主动同意/拒绝处理。

档案 P 包含七个顶层字段：identity、locations、digital_context、habits、preferences、decision_criteria、social_graph。当前发布四个角色：Researcher（副教授）、Developer、Student、Grandma，覆盖不同年龄、技术能力和生活习惯。

2.3 三类任务定义

智能体在每步 t 按如下策略采样动作：

$$a_t \sim \pi(a \mid g, o_t, h_{<t}, H, S, r_t), \quad a_t \in \mathcal{A}$$

其中 o_t 为当前截图，r_t 为可选的 ask_user 回复，H 为用户历史日志。

通用任务：显式指令，无需推断用户偏好，作为 GUI 执行能力的基线。

个性化任务：模糊指令，需根据 P 中的偏好消歧。如“帮我订午餐”隐含外卖平台选择、饮食禁忌、预算和支付方式。智能体可通过 ask_user 发起澄清，π_u 返回角色一致的回复 $r_t \sim \pi_u(\cdot \mid m_t, P, S)$。各模板在 1–4 个角色子集上实例化。

主动任务：无显式指令，智能体仅获取当前状态（时间、位置、GUI 状态），需自主选择三种策略之一：直接执行、征求确认、或保持静默。同一触发条件在不同角色下可能产生不同决策。被拒绝后必须停止进一步尝试。

2.4 混合评估策略

规则判定：确定性检查（收件人正确性、事件/订单创建、时间窗口、拒绝后的安全违规），返回 $S_{\text{rule}} \in \{0, 1\}$。**LLM 判定**：基于评分标准的语义评估（偏好对齐、权衡质量、沟通风格、上下文适切性），返回归一化语义分数。最终分数：

$$S_i = \lambda_i S_{\text{rule}} + (1 - \lambda_i) S_{\text{llm}}, \quad \lambda_i \in [0, 1]$$

$\lambda_i = 1$ 用于纯确定性任务，$\lambda_i = 0$ 用于纯语义任务。与人工专家评分对比（26 条轨迹），混合评估器的平均绝对误差显著低于纯规则方案。

3. 评估指标体系

三层指标覆盖不同维度：(1) **全局**：成功率 $\text{SR} = \mathbb{I}[S_i > 0.99]$ 的比例；效率 $= 50/\text{AvgSteps}$。(2) **个性化专用**：平均分数（捕捉部分偏好对齐）；交互效率 $\text{IE} = \frac{1}{|\mathcal{T}|} \sum_i S_i / \max(c_i, 1)$。(3) **主动专用**：Act rate（应干预时是否干预）、Silent rate（不应干预时是否静默）、Stop rate（被拒绝后是否停止）。

4. 核心实验结果

评估 11 个模型：3 个 GUI 专用（MAI-UI-8B、UI-Venus-1.5-8B、GUI-Owl-1.5-8B）、5 个通用开源（Qwen3-VL-8B/32B、Qwen3.5-9B/122B/397B）、3 个闭源（Gemini 3.1 Pro Preview、Seed 2.0 Pro、Claude Sonnet 4.6）。

模型	总体 SR	通用（易）	个性化（难）	主动（易）
MAI-UI-8B	26.0	100.0	11.9	17.9
Qwen3.5-397B	37.5	83.3	2.3	68.8
Gemini 3.1 Pro	44.3	94.4	20.9	50.0
Seed 2.0 Pro	51.6	100.0	27.9	62.5
Claude Sonnet 4.6	**60.4**	94.4	**44.2**	**84.4**

关键发现 1：通用 GUI 执行不再是瓶颈。MAI-UI-8B 和 Seed 2.0 Pro 在简单通用任务上均达 100%，但个性化困难任务上所有开源模型低于 12%。Claude Sonnet 4.6 最优，总体 SR 为 60.4%，但通用 → 个性化的平均跌幅约 30%。

关键发现 2：个性化失败主因是偏好获取不足。Claude Sonnet 4.6 的失败中，**93.8%** 为澄清不足（66.7%）或部分偏好满足（27.1%），GUI 和偏好误识别仅占 6.3%。模型平均仅问 0.4 个问题/任务即获最高分，而 Seed 2.0 Pro 问两倍多的问题仍落后——关键不在于是否提问，而在于能否将反馈高效转化为正确执行。

关键发现 3：主动失败主因是干预校准失调。Claude Sonnet 4.6 主动任务失败中，干预过度占 60%、被动过度占 20%，合计 **80%**。当前模型更倾向于过度干预而非错失行动时机。三项指标揭示根本性的校准困境：Qwen3.5-397B 在 Silent（73.7%）和 Stop（75.0%）上领先但 Act 仅 31.8%；Claude Sonnet 4.6 Act 最优（70.8%）但 Stop 较弱——没有模型能同时在三个维度上表现均衡。

4.1 角色依赖性

Claude Sonnet 4.6 在四个角色间保持 71.7%–79.4% 的相对稳定；Seed 2.0 Pro 在 Researcher 角色达 71.3% 但 Grandma 角色跌至 48.5%。Grandma 是平均最难角色，Student 产生最大方差。

4.2 记忆实现消融

比较四种配置：完整日志/RAG 检索 × 干净/含噪。核心发现是**最优记忆接口因模型而异**：Qwen3-VL-8B 受益于选择性检索（13.6% → 20.4%），而 UI-Venus-1.5-8B 在完整日志下更优。MAI-UI-8B 在含噪 RAG 下退化至 9.3%，表明噪声检索可破坏脆弱的记忆利用能力。

5. 错误分析

对 Claude Sonnet 4.6 全部失败轨迹的人工分类揭示了两个设定下的不同瓶颈：

个性化任务：Clarify（澄清不足）66.7%、Partial（部分偏好满足）27.1%、GUI 4.2%、Preference（偏好误识别）2.1%。模型常在行动前未提出正确的后续问题；即使主偏好被识别，也难以正确组合多个约束。

主动任务：Intervention（不当干预）60.0%、Passive（错误被动）20.0%、GUI 15.0%、Rejection（拒绝后违规）5.0%。干预与被动合计 80%，远超 GUI 错误，确认主动失败本质上是校准问题。

典型失败案例包括：（1）Mastodon 发帖时忽略用户惯用的“仅关注者可见”设置；（2）购物车管理时未澄清即自行操作；（3）跨平台偏好时选错应用；（4）购买可乐时误解“一箱”语义循环点击 24 次耗尽步数；（5）被明确拒绝后仍执行屏蔽操作。

6. 讨论与局限

KnowU-Bench 将个性化评估从离线意图对齐问题转变为**在线执行验证基准**，首次系统评估交互式偏好获取和完整主动决策链。

核心贡献：(1) 可复现 Android 模拟环境 + 程序化验证；(2) 结构化档案驱动的 LLM 用户模拟器支持多轮澄清与主动同意处理；（3）覆盖主动提议、确认协商、执行和拒绝后克制的完整评估；（4）混合规则 +LLM 评估与人工判断高度一致。

局限与未来方向：

- 当前仅覆盖 23 款应用，真实场景的应用多样性远高于此；
- 用户档案为合成构造（4 个角色），长期真实用户研究有待开展；
- 用户模拟器（GPT-4o）本身可能引入偏差，特别是在模拟老年用户等非典型群体时；
- 评估的 LLM 判定部分依赖模型质量，存在潜在的评估偏差；
- 未来关键方向包括更强的长期记忆访问机制、更精细的歧义消解策略、以及更安全的主动决策边界设计。

实验清晰表明：现有模型能操作界面，但仍无法判断**为哪个用户做什么**以及**何时该做**——从“称职的 GUI 操作员”到“值得信赖的个人助手”仍有根本性鸿沟。

LPM 1.0：基于视频的角色表演大模型

Zeng†, Yang, Ge, Zhang, Xu, Lin, Gu, Pi, Li, Shi, Bi, Tang, Hang, Guo, Li, Tong† 等 — 2025

1. 问题动机与 Performance Trilemma

角色**表演**（Performance）是意图、情感与个性通过视觉、声音和时序行为的外化，是使虚拟角色“活起来”的关键。传统 3D 管线（建模 → 绑定 → 动画 → 渲染）虽具备显式可控性，但难以扩展至开放场景——每新增角色/行为/模态均需等比例增加资产与专家工时。从视频直接学习表演是一条根本不同的路线：大规模视频数据天然涵盖多样身份、视角、对话语境与情感风格。

然而，现有视频生成模型面临作者称之为 **Performance Trilemma** 的刚性约束，三项关键需求难以同时满足：

- **表现力**：丰富的对话性、非重复动作与微表情；
- **实时推理**：因果式低延迟生成以支持实时交互；
- **长时稳定性**：无限时长下身份、解剖结构和视觉保真度的一致性。

优化速度与稳定性常导致机械重复；追求表现力则牺牲实时性；长时自回归易产生身份漂移。**对话**是最综合的表演场景——角色同时说话、倾听、反应、表情，并在无限时间维持身份。

作者指出现有范式缺少四个关键要素：(1) **倾听行为**缺失（多数模型仅驱动说话）；(2) **多模态可控性**不足（文本指令 + 说话音频 + 倾听音频需联合建模）；(3) **角色规格欠定**（单张参考图迫使模型幻觉未见细节）；(4) **以人为中心的视频基础模型**缺位。LPM 1.0 提供完整的全栈框架：数据构建 → 多模态条件基座模型 → 在线蒸馏实时部署。

2. 数据构建

数据管线由四阶段组成，整体保留率 $< 10\%$，确保质量、多样性与标注密度。

2.1 高质量人体视频准备

收集涵盖多种拍摄尺度、身体运动、表情、情感与外观的大规模语料。经场景检测分割为单镜头片段，人体检测去除无人或过度拥挤片段。五类质量缺陷过滤（剪辑伪影、画质缺陷、内容真实性、构图问题、音视频同步），最终人工质检缺陷率 $< \mathbf{1}\%$。

2.2 对话音视频数据处理

核心挑战：为每帧每人标注说话/倾听/空闲状态。管线包括：(1) 人体检测与跟踪获取时序 bounding-box 轨迹；(2) 微调 LR-ASD 为**三状态帧级分类**（20K 片段 ≈95h 人工标注训练），在 2K 测试集上帧级准确率达 Domain 1: 89.75%、Domain 2: 87.63%；(3) 规则驱动的角色-音频分离与分配模块，通过时序平滑与持久性检查解决说话/倾听角色指派，输出说话者专用与倾听者专用音轨；(4) **语义验证**阶段：微调 Qwen3-Omni 音视频理解模型（15K 标注），总体 F1 达 78.37，比 Gemini 2.5 Pro 基线绝对提升 **+7.90**，有效抑制虚假倾听与非对话倾听。

倾听视频分析：原始对话视频中仅 $\sim 10\%$ 画面聚焦倾听者，且 $> 70\%$ 为中性/认知类情绪，$\sim 90\%$ 动作强度低。为此精选 ~470K 情感丰富片段进行重平衡，增强情绪对比（如愉悦 ↔ 尴尬交替）与表情振荡（三相转换）模式。倾听字幕限于时间不变属性（外貌、性格、关系），鼓励模型直接学习音频 → 视觉反应的映射。

2.3 音视频理解与字幕

适配音视频理解模型为每个片段生成**密集自然语言字幕**与**结构化标签**（动作、情感、环境、相机等），涵盖 22 个表情基、78 种情绪、5000+ 动作描述符的完整分类体系。

2.4 身份感知多参考图管线

三类互补参考图：(1) **全局外观参考**——从长镜头源视频随机采样候选帧（含训练片段内外），防止 copy-paste 捷径；(2) **多视角身体参考**——利用 GVHMR 估计人体朝向 +SLAM 估计相机位姿，按角度 θ 分为正面 ($\geq 155°$)、背面 ($\leq 45°$)、左/右侧面，每类选取代表帧；(3) **表情参考**——限 ≥1080P 视频，EmotiEff Lib 检测 8 类预定义表情帧，图像理解模型二次验证校正标签。每人最多 8 张表情 +4 张视角参考。

3. Base LPM 架构

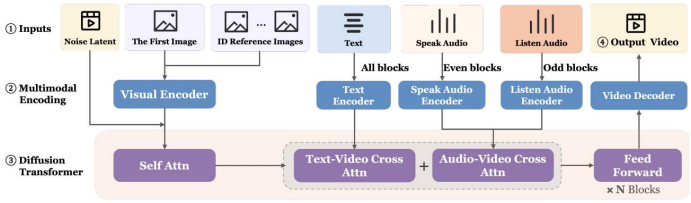

图 1：*Base LPM 架构。噪声视频、首帧、身份参考图经自注意力注入，文本与双流音频经交叉注意力注入 DiT 块，VAE 解码输出视频。*

基于 14B 预训练图到视频模型（Wan2.1-I2V）引入 3B 新增参数，总计 **17B**。每个 DiT 块含三阶段：(1) 带 AdaLN 的自注意力（噪声视频 + 首帧 + 多参考图 token）；(2) 多模态交叉注意力（文本 + 说话/倾听音频）；(3) FFN+AdaLN。

交错双音频注入：偶数层注入说话音频，奇数层注入倾听音频，各自维护独立 W_k, W_v, W_o 参数。最终输出 $\text{out} = W_o^{\text{txt}} A_{\text{text}} + W_o^{\text{aud}} A_{\text{audio}}$。优势：(1) 运动分布对齐——说话数据高频面部动态 vs. 倾听数据低频姿态反应，各层参数协同特化；(2) 音频交叉注意力参数减半 50%，FLOPs 等比节省；(3) 时间对齐注意力——说话分支使用局部窗口精确唇同步，倾听分支使用更大窗口捕捉语义理解。

身份多参考条件：参考图经与视频相同的 3D patch embedding 编码为空间 token，拼接至视频 token 序列末端参与自注意力（双向信息流，无额外参数）。通过 3D RoPE 段式位置编码区分参考类型：

$$\text{RoPE}_{ij} = \text{RoPE}(t + o_i + so_j, h, w)$$

其中 i 为参考类型（表情/多视角），j 为子类型（具体表情/视角），o_i, so_j 为基础与子偏移。支持灵活的 1–8 张表情 +1–4 张视角参考组合，实现多视角一致性、动态表情保真与长视频稳定性（~10 分钟无明显退化）。

3.1 训练策略

多模态条件对齐：先训练说话音频路径（零初始化音频交叉注意力 value 投影），再训练倾听路径，逐步混合说话/静默/倾听/对话数据。多参考图在音频对齐后以 30% 概率引入。移除原始 CLIP 图像交叉注意力。全程应用 CFG。

时序延伸训练：为缓解 chunk-wise 自回归推理时训练-推理不匹配（首帧真实 vs. 生成、非因果 vs. 因果 VAE latent），训练时以一定概率随机丢弃前 2–5 帧真实 latent。

DPO 后训练：针对说话模式的手部/肢体畸变与唇同步退化，以及倾听模式的过度静态，采用 Direct Preference Optimization。生成多种噪声种子候选，Pareto 高效选择偏好对（至少一个维度严格优于且无维度退化），加 Flow Matching 正则防止色偏。

4. Online LPM 架构

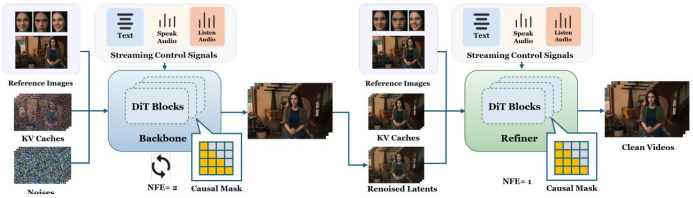

图 2：*Online LPM 架构。Backbone DiT 在噪声历史 KV cache 条件下生成稳定 latent 轨迹，Refiner DiT 在干净历史 KV cache 条件下恢复高保真细节。*

核心方法论观点：将在线生成分解为**轨迹稳定化**与**细节重建**两个子问题。

流式音频：重叠感知 chunk-wise 编码，每步处理 3s 窗口（2s 历史 +1s 当前），步长 1s。在 600K 流式格式样本上微调。文本控制更鲁棒，增量更新无需额外微调。

Backbone–Refiner 分解：(1) **因果 Backbone DiT**（2 步 NFE）：条件于噪声历史 *KV cache*（从带噪历史 latent 的前向传播计算），在自身 rollout 分布下更鲁棒；(2) **因果**

Refiner DiT（1 步 NFE）：条件于干净历史 *KV cache*，从稳定轨迹恢复高频面部/外观/运动细节。双向注意力替换为 chunk-wise 因果注意力。

4.1 四阶段训练课程

Stage 1 ODE 初始化：教师去噪轨迹上的监督回归 $\mathcal{L}_{\text{reg}} = \mathbb{E}_{i,\mathbf{t}} \| G_{\text{backbone}}(\mathbf{x}_i^{\mathbf{t}}, \mathbf{t}) - \mathbf{x}_i^0 \|_2^2$，暖启动 Backbone。

Stage 2 Off-policy DMD：教师干净 latent 重加噪后以 DMD 目标训练，加 LPIPS 感知正则防止模式坍缩：$\mathcal{L}_{\text{off}} = \mathcal{L}_{\text{DMD}}(\cdot) + w\,\mathcal{L}_{\text{LPIPS}}(\cdot, \mathbf{x}_i^0)$。

Stage 3 On-policy DMD：在 Backbone 自身自回归 rollout 分布上训练 $\mathcal{L}_{\text{on}} = \mathcal{L}_{\text{DMD}}(G_{\text{backbone}}(\bar{\mathbf{x}}_i^{\mathbf{t}}, \mathbf{t}))$，显式学习从自身预测误差中恢复，对长时鲁棒性至关重要。

Stage 4 Refiner DMD：从 Backbone 初始化 1NFE Refiner，在 Backbone 生成轨迹上以 DMD 训练恢复最终高保真干净 latent。

5. 基础设施

训练优化：数据层面采用多分辨率打包（pack 不同分辨率样本至统一 batch 以提高 GPU 利用率）；模型层面采用序列并行、张量并行与梯度检查点；系统层面优化通信调度。

在线交互系统：端到端管线包括 ASR→LLM 对话 →TTS+情感分析 →LPM 视频生成 → 流式传输。**推理优化：**Backbone 与 Refiner 流水线并行（Backbone 生成第 $n+1$ 块时 Refiner 精化第 n 块）；因果 KV cache 消除历史帧重复计算；针对变长参考图的动态 batching。

6. LPM-Bench 评测基准

首个交互式角色表演多模态基准，包含 **1000 个测试用例**，覆盖 5 场景（说话、倾听、对话、多样人体运动、角色泛化）。三轴系统性多样化：(1) 外观：多镜头尺度/种族/年龄/艺术风格/身份参考；(2) 表演：22 表情基/78 情绪/5000+ 动作描述符/注视与姿态配置；(3) 音频：多音色/情绪/语言/时长（5s–1h），10% 专用于长时生成验证。

7. 核心实验结果

Base LPM（720P）人工评测：与 Kling-Avatar-2 配对对比，**64.3**% 评分者偏好 LPM；与 OmniHuman-1.5 对比，**42.5**% 偏好 LPM（最大优势在身份一致性与运动动态）。

Online LPM（480P）人工评测：与 LiveAvatar 对比，**82.5**% 偏好 LPM；与 SoulX 对比，**64.1**% 偏好 LPM。

Base vs. Online 直接对比（480P）：在所有评估维度和场景中，**42–88**% 的情况下评分者认为二者**不可区分**，表明实时因果生成无需牺牲感知真实感。

7.1 消融实验

音频注入策略：交错注入 vs. 全层注入——交错设计在参数减半的同时保持可控质量，且避免说话/倾听梯度冲突。

多参考图效果：去除表情参考 → 长序列中表情一致性显著下降；去除多视角参考 → 侧面/背面生成出现幻觉伪影。全套参考组合效果最优。

Online 蒸馏阶段：跳过 Stage 3 on-policy DMD→ 长时 rollout 迅速崩溃（累积误差）；去除 Refiner→ 高频细节丢失、面部模糊。四阶段完整课程最优。

DPO 后训练：DPO 显著减少手部/肢体畸变，提升倾听行为多样性与自然度。

倾听数据重平衡：无重平衡时模型生成静态倾听；重平衡后产生丰富的点头、注视转移、情绪反应。

8. 讨论与局限

核心贡献：(1) 首个单人全双工对话表演视频生成系统；(2) 大规模多模态数据基础（说话 + 倾听 + 身份感知参考）；(3) 17B DiT 联合建模语音驱动 + 倾听反应 + 文本控制 + 多参考身份保持；(4) 四阶段自回归蒸馏实现实时无限长生成；(5) LPM-Bench 首个交互式角色表演基准。

主要局限：

- 当前仅支持**单人**对话表演，多人交互场景尚未覆盖；
- 极端动作（大幅度肢体运动）仍偶发解剖畸变，DPO 仅部分缓解；
- Online LPM 分辨率限于 480P（vs. Base 720P），超高分辨率实时生成受限于计算预算；
- 倾听行为虽经重平衡仍偏保守，罕见高能量反应生成有限；
- 依赖外部 TTS 与 LLM 构建完整交互管线，端到端联合优化为未来方向；
- 身份泛化至动漫/3D 风格角色的质量有待验证。

LLM 智能体中的外化：记忆、技能、协议与 Harness 工程的统一综述

Zhou, Chai, Chen, Guo, Shan, Song 等 — 上海交通大学、中山大学、CMU、OPPO, 2026

1. 核心思想与动机

本文提出以**外化**（Externalization）作为统一视角审视 LLM 智能体的能力提升趋势。理论锚点源自 Norman 的**认知制品**理论：外部工具不是简单放大内部能力，而是**变换任务的表征形式**——购物清单将回忆转化为识别，地图将隐藏关系转化为可视结构。

核心论点：将认知负担从模型内部迁移到持久化、可检视、可复用的外部结构，是统一记忆、技能、协议和 Harness 工程进展的**转换逻辑**。未外化的 LLM 面临三类失配：

- **连续性**：上下文有限、会话记忆缺失——记忆外化解决；
- **方差**：多步过程每次重新推导导致不一致——技能外化解决；
- **协调**：与工具/服务/协作者交互脆弱——协议外化解决。

Harness 则是托管三者的**统一运行时层**。

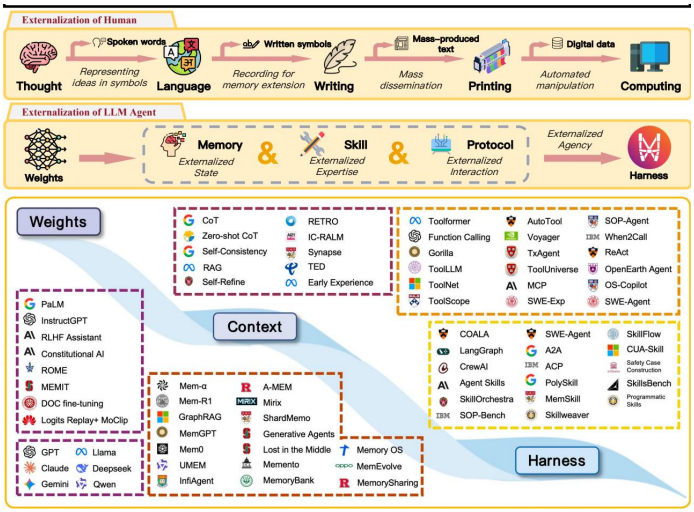

图 1：外化作为 *LLM* 智能体设计的组织原则。上：人类认知外化弧线；中：*LLM* 对应弧线；下：文献景观。

2. 历史演进：从权重到上下文到 Harness

演进分为三个**层叠而非互斥**的阶段：

权重层：早期将能力等同于参数，缩放定律强化“更大 = 更好”叙事。优势是推理快速、部署紧凑，但知识与策略**过紧耦合**于静态制品，更新和审计困难。

上下文层：Prompt 工程（few-shot、CoT、ReAct、RAG 等）无需改权重即可改变行为，上下文成为认知工作台面。但窗口有限且昂贵，状态随会话消失。

Harness 层：Auto-GPT、AutoGen、MetaGPT、Reflexion 等将注意力转向运行时环境。SWE-agent 嵌入开发环境，Deep Research 添加检索与审批。**可靠性越来越多通过改变环境而非仅靠提示来解决**。

统一机制：可变知识从权重迁移到检索系统（回忆 → 识别），可复用过程从隐式迁移到显式技能（生成 → 组合），交互规则从即兴迁移到协议（临时 → 结构化）。

3. 外化的状态：记忆

3.1 外化的内容

记忆将智能体跨时间状态与瞬态上下文**解耦**，分四个维度：**工作上下文**（活跃中间状态）、**情景经验**（先前运行记录与反思）、**语义知识**（跨 episode 抽象的领域事实）、**个性化记忆**（用户偏好与约束）。

3.2 记忆架构演进

核心问题是**主动推理与存储状态的分离程度**，四阶段演进：**(1)整体上下文**——全部历史在提示中，简单但容量差；**(2)上下文 + 检索**——长期外部存储按需检索（GraphRAG、ENGRAM 等）；**(3) 层次化记忆**——显式提取/整合/遗忘操作（MemGPT/MemoryOS 热冷分层）；**(4) 自适应记忆**——MemEvolve/MemRL 独立进化各模块。核心转变：从存储到控制。

记忆外化的表征变换是将**回忆转化为识别与检索**。检索质量比存储容量更重要，常见失败模式（陈旧、噪声、中毒）本质上都是表征设计失败。

4. 外化的专业知识：技能

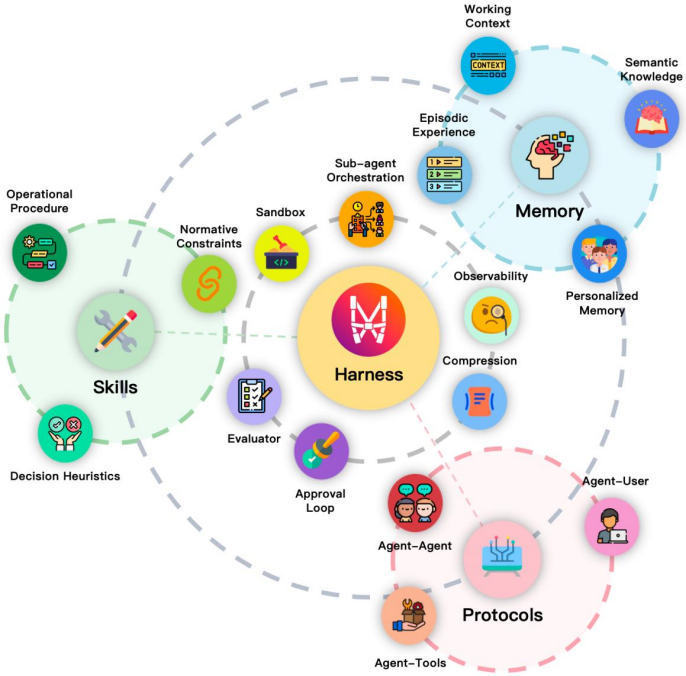

图 2：*Harness* 化智能体的外化架构。*Harness* 居中，记忆/技能/协议环绕，通过沙箱、可观测性、评估、审批等元素交互。

4.1 外化的内容

技能外化关注**可重复的任务执行方式**，包含三个组件：**操作过程**（步骤、依赖、终止条件）、**决策启发式**（分支处的经验规则）、**规范约束**（合规/安全要求内嵌为技能的一部分）。

4.2 演化阶段

阶段 1——原子执行原语（Toolformer）；**阶段 2**——大规模原语选择（Gorilla、ToolLLM）；**阶段 3**——技能作为打包的专业知识，能力不再是对工具的访问而是外化的可复用过程性知识。

4.3 技能外化的五个维度

规范化（SKILL.md 描述边界与约束）、**发现**（语义检索匹配）、**渐进披露**（分层加载）、**执行绑定**（连接到可执行动作，MCP 等支持运行时绑定）、**组合**（串行/并行/条件路由，验证有效的组合可升级为新技能）。

4.4 技能获取

四条路径：人工编写（SKILL.md/SOP）、蒸馏（从成功轨迹提取）、发现（如 Voyager 自主探索）、组合提升。边界条件包括语义对齐、可移植性陈旧、不安全组合和上下文依赖退化。

5. 外化的交互：协议

协议将交互从**临时提示**转化为**可互操作的机器可读契约**。三个层面：**Agent-Tool**（MCP 提供统一工具发现与调用层）、**Agent-Agent**（A2A/ANP 定义委托与会话管理）、**Agent-User**（AG-UI 标准化意图捕获与审批循环）。核心功能：意图规范化、能力发现、会话生命周期管理。

6. 统一外化：Harness 工程

Harness 是**托管记忆/技能/协议并使其协调运行的运行时环境**，六个维度：**(1) 控制流**（ReAct 到 DAG 编排）；**(2) 沙箱隔离**；**(3) 人类审批门**；**(4) 可观测性与反馈**；**(5) 配置与策略编码**；**(6) 上下文预算管理**。Claude Code、Cursor、Devin 等均体现了这一模式——模型保持推理核心，能力**分布**于外部结构中。

7. 交叉分析

三个外化维度相互作用：技能执行写入记忆，记忆影响技能选择，协议约束技能打包，三者共同竞争有限上下文预算。并非所有能力都应外化：参数化适合快速推理和广泛泛化，外化适合可更新性、可检视性和可治理性。最优边界取决于更新频率、审计需求和部署约束。

8. 未来方向

自演化 Harness：智能体基于反馈自动更新记忆策略和技能库，形成元级外化。**具身外化**：扩展到机器人，记忆编码时空状态，技能绑定传感器接口。**共享基础设施**：MCP/A2A 推动技能从私有实现走向公共注册表。**评估**：缺乏外化基础设施本身的标准化基准。**治理与安全**：外化引入技能注入、记忆投毒等新攻击面。**共演化**：更强模型可能内化某些外化功能，但外化压力随复杂度增长持续存在。

9. 总结

本文以认知制品理论为锚点，提出**外化**作为理解 LLM 智能体架构演进的统一框架。记忆将回忆转化为识别，技能将即兴生成转化为组合，协议将临时协调转化为契约，Harness 编排三者为受治理的执行。核心洞察：智能体进步不仅取决于更强模型，更取决于**更好的外部认知基础设施**。